



**НАУКА
и глобальные вызовы
XXI века**



**ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ
В РЕШЕНИИ АКТУАЛЬНЫХ СОЦИАЛЬНЫХ
И ЭКОНОМИЧЕСКИХ ПРОБЛЕМ XXI ВЕКА**



Пермь, 2021

Пермское отделение Научного совета при Президиуме РАН
по методологии искусственного интеллекта
Российская ассоциация искусственного интеллекта
Пермский государственный национальный исследовательский университет
Пермский национальный исследовательский политехнический университет
Национальный исследовательский университет «Высшая школа экономики»
Пермский государственный гуманитарно-педагогический университет
Пермский государственный медицинский университет
им. академика Е.А.Вагнера
Институт народнохозяйственного прогнозирования РАН
Финансовый университет при Правительстве РФ

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В РЕШЕНИИ АКТУАЛЬНЫХ СОЦИАЛЬНЫХ И ЭКОНОМИЧЕСКИХ ПРОБЛЕМ XXI ВЕКА

*Сборник статей по материалам Седьмой всероссийской
научно-практической конференции с международным участием*

(г. Пермь, 21–22 октября 2021 г.)



Пермь 2021

УДК 004.8: 3
ББК 32.813 + 6/8
И868

Искусственный интеллект в решении актуальных социальных и экономических проблем XXI века : сборник статей по материалам Седьмой всероссийской научно-практической конференции с международным участием (г. Пермь, 21–22 октября 2021 г.) / под редакцией Л. Н. Ясницкого ; Пермский государственный национальный исследовательский университет. – Пермь, 2021. – 456 с.

ISBN 978-5-7944-3696-9

В сборнике представлены материалы Седьмой всероссийской научно-практической конференции с международным участием «Искусственный интеллект в решении актуальных социальных и экономических проблем XXI века», которая проводилась 21–22 октября 2021 г. в г. Перми в рамках Пермского естественнонаучного форума «Математика и глобальные вызовы XXI века».

Сборник предназначен для научных и педагогических работников, преподавателей, аспирантов, магистрантов, студентов и всех, кто интересуется проблемами и перспективами развития и применения методов искусственного интеллекта.

**УДК 004.8: 3
ББК 32.813 + 6/8**

*Издается по решению кафедры прикладной математики и информатики
Пермского государственного национального исследовательского университета*

*Сборник подготовлен при финансовой поддержке
гранта РФФИ: № 19-010-00307.*

Статьи публикуются в авторской редакции, авторы несут ответственность за содержание статей, за достоверность приведенных в статье фактов, цитат, статистических и иных данных, имен, названий и прочих сведений

ISBN 978-5-7944-3696-9

© ПГНИУ, 2021

ОГЛАВЛЕНИЕ

ПЛЕНАРНЫЕ ДОКЛАДЫ	7
НАУКА И ГЛОБАЛЬНЫЕ ВЫЗОВЫ ХХI ВЕКА	8
ПРЕПОДАВАНИЕ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА В ПЕРМСКОМ УНИВЕРСИТЕТЕ: 1998 – 2021	19
ОПЫТ ПРЕПОДАВАНИЯ ТЕРАПИИ В МЕДИЦИНСКОМ ВУЗЕ С ИСПОЛЬЗОВАНИЕМ МЕТОДОВ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА	26
ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ И ФИЛОСОФИЯ.....	31
БАЗОВЫЕ ПОНЯТИЯ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА В ФОРМЕ ТЕЗАУРУСА	32
ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ ГЛАЗАМИ ОБЫВАТЕЛЯ.....	44
ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ КАК ИНТЕГРАЦИЯ ЕСТЕСТВЕННОГО И ИСКУССТВЕННОГО ИНТЕЛЛЕКТОВ.....	52
ИСКУССТВЕННАЯ ФИЛОСОФИЯ	60
ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В МЕДИЦИНЕ.....	65
РОБОТЫ И ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В МЕДИЦИНЕ	66
МУЛЬТИМОДАЛЬНЫЙ КЛАССИФИКАТОР ФУНКЦИОНАЛЬНОГО СОСТОЯНИЯ СИСТЕМЫ ДЫХАНИЯ.....	80
НЕЙРОСЕТЕВАЯ СИСТЕМА ОЦЕНКИ РИСКА РАЗВИТИЯ ИНСУЛЬТА	86
ИСКУССТВЕННЫЕ НЕЙРОННЫЕ СЕТИ ЗАДАЧЕ ВЫЯВЛЕНИЯ ПАЦИЕНТОВ ГРУППЫ РИСКА РАКА МОЛОЧНОЙ ЖЕЛЕЗЫ.....	96
ПРОГНОЗИРОВАНИЕ ИНСУЛЬТА МЕТОДОМ НЕЙРОСЕТЕВОГО МОДЕЛИРОВАНИЯ	101
ПРИМЕНЕНИЕ МЕТОДОВ МАШИННОГО ОБУЧЕНИЯ ДЛЯ УТОЧНЕНИЯ ДИАГНОЗА НА ЭТАПЕ ОБРАБОТКИ ДАННЫХ В ДИАГНОСТИКЕ РАКА МОЛОЧНОЙ ЖЕЛЕЗЫ.....	110
НЕЙРОСЕТЕВОЕ МОДЕЛИРОВАНИЕ ПРОГНОЗИРОВАНИЯ СЕРДЕЧНОГО ПРИСТУПА	115
ГИБРИДНЫЙ НЕЙРОСЕТЕВОЙ КЛАССИФИКАТОР ИНФЕКЦИОННЫХ ЗАБОЛЕВАНИЙ НА ОСНОВЕ ЛОКАЛЬНЫХ МОДЕЛЕЙ ГРАФИКА КОУЛА.....	121
ПРОГНОЗ СЕРДЕЧНОЙ НЕДОСТАТОЧНОСТИ С ПОМОЩЬЮ НЕЙРОСЕТЕВОЙ МОДЕЛИ ...	127
ОПРЕДЕЛЕНИЕ НАЛИЧИЯ ПНЕВМОНИИ ПО СНИМКАМ ГРУДНОЙ КЛЕТКИ	135
НЕЙРОСЕТЕВАЯ СИСТЕМА ОЦЕНКИ ЧИСЛА НОВО ЗАРАЖЁННЫХ КОРОНАВИРУСОМ ЧЕЛОВЕК В СТРАНАХ МИРА	141
ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В ПСИХОЛОГИИ И СОЦИОЛОГИИ.....	149
ИЗУЧЕНИЕ ЗАВИСИМОСТИ МЕЖДУ БЕЗРАБОТИЦЕЙ И ПСИХИЧЕСКИМИ ЗАБОЛЕВАНИЯМИ.....	150
АЛГОРИТМ И ТЕХНОЛОГИИ ИССЛЕДОВАНИЯ ВЛИЯНИЯ РЕКЛАМНЫХ РОЛИКОВ НА СТРЕССОВОЕ СОСТОЯНИЕ ЛЮДЕЙ.....	158

СОЗДАНИЕ НЕЙРОСЕТЕВОЙ МОДЕЛИ ДЛЯ ПРОГНОЗИРОВАНИЯ УРОВНЯ ВЫГОРАНИЯ ЧЕЛОВЕКА	162
НЕЙРОСЕТЕВАЯ СИСТЕМА ОПРЕДЕЛЕНИЯ ИГРОВОЙ ЗАВИСИМОСТИ	168
ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В ЭКОНОМИКЕ, ПРОИЗВОДСТВЕ И БИЗНЕСЕ.....	174
ПРОГНОЗИРОВАНИЕ УДОВЛЕТВОРЕННОСТИ ПАССАЖИРОВ АВИАПЕРЕЛЕТОМ	175
СИСТЕМА ДЛЯ ОЦЕНКИ СТОИМОСТИ ПОСУТОЧНОЙ АРЕНДЫ ЖИЛОЙ НЕДВИЖИМОСТИ ПЕРМИ	181
РАЗРАБОТКА ИНЖЕНЕРНОГО ПРОГРАММНОГО МОДУЛЯ ПРОГНОЗИРОВАНИЯ ПАРАМЕТРОВ ТЕПЛОНОСИТЕЛЯ ПО СТВОЛУ СКВАЖИНЫ В ПРОЦЕССЕ ПРОВЕДЕНИЯ ПАРОЦИКЛИЧЕСКИХ ОБРАБОТОК НА ПРИМЕРЕ ПЕРМО-КАРБОНОВОЙ ЗАЛЕЖИ УСИНСКОГО МЕСТОРОЖДЕНИЯ В ЗАВИСИМОСТИ ОТ ГЕОЛОГО-ПРОМЫСЛОВЫХ ДАННЫХ	188
ОЦЕНКА СОСТОЯНИЯ ЗАРЯДА АККУМУЛЯТОРНОЙ БАТАРЕИ ВСТРОЕННЫХ И ПОРТАТИВНЫХ УСТРОЙСТВ С ИСПОЛЬЗОВАНИЕМ НЕЙРОННЫХ СЕТЕЙ	197
ПРИМЕНЕНИЕ НЕЙРОСЕТЕВЫХ ТЕХНОЛОГИЙ ДЛЯ ОЦЕНКИ КРЕДИТОСПОСОБНОСТИ ЗАЁМЩИКА.....	203
НЕЙРОСЕТЕВОЕ ПРОГНОЗИРОВАНИЕ СТОИМОСТИ АРЕНДЫ КВАРТИР В ГОРОДЕ ПЕРМЬ	208
СРАВНИТЕЛЬНЫЙ АНАЛИЗ МЕТОДОВ ЭКОНОМИКО-МАТЕМАТИЧЕСКОГО МОДЕЛИРОВАНИЯ МАССОВОЙ ОЦЕНКИ ЖИЛОЙ НЕДВИЖИМОСТИ	215
ПРОГНОЗИРОВАНИЕ ПАССАЖИРОПОТОКА В ПЕРМИ С УЧЕТОМ ПОГОДНЫХ УСЛОВИЙ И ПАНДЕМИИ	222
ПРИМЕНЕНИЕ САМООРГАНИЗУЮЩИХСЯ КАРТ КОХОНЕНА ДЛЯ АНАЛИЗА БАЗЫ ПАТЕНТОВ	229
ПРЕДИКТИВНАЯ АВТОМАТИЧЕСКАЯ СИСТЕМА ДЕТЕКЦИИ ПОВРЕЖДЕНИЙ СТАЛЬНЫХ ТРОСОВ ЛИФТОВ ГРАЖДАНСКОГО НАЗНАЧЕНИЯ НА ОСНОВЕ НЕЙРОННЫХ СЕТЕЙ ...	235
НЕЙРОННАЯ СЕТЬ ДЛЯ ОПРЕДЕЛЕНИЯ ВЛИЯНИЯ ВНЕШНИХ ФАКТОРОВ НА СТОИМОСТЬ КВАДРАТНОГО МЕТРА ЖИЛОЙ ПЛОЩАДИ	242
ПРИМЕНЕНИЕ НЕЙРОСЕТЕВОГО МОДЕЛИРОВАНИЯ ПРИ ВЕРОЯТНОСТИ БАНКРОТСТВ ДЛЯ УПРАВЛЕНИЯ КРЕДИТНЫМИ РИСКАМИ	249
ПРОГНОЗИРОВАНИЕ СТОИМОСТИ МОБИЛЬНЫХ ТЕЛЕФОНОВ МЕТОДАМИ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА	255
ИНТЕЛЛЕКТУАЛЬНЫЙ ПРОГРАММНЫЙ КОМПЛЕКС МОДЕЛИРОВАНИЯ ОПТИМИЗАЦИИ УПРАВЛЕНИЯ ПРОИЗВОДСТВОМ ПРОДУКЦИИ ПРЕДПРИЯТИЯ.....	261
ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В ПЕДАГОГИКЕ.....	269
НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗИРОВАНИЯ ПОСТУПЛЕНИЯ АБИТУРИЕНТА В ВУЗ «ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»	270

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В ДЕМОГРАФИИ	278
НЕЙРОСЕТЕВАЯ СИСТЕМА ОЦЕНКИ ТЕКУЩЕГО ПОЛОЖЕНИЯ СЕМЬИ ДЛЯ ЗАВЕДЕНИЯ ПЕРВОГО РЕБЕНКА	279
ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В ЛИНГВИСТИКЕ	286
ПРОГНОЗИРОВАНИЕ ВОЗРАСТНОЙ АУДИТОРИИ ЧИТАТЕЛЕЙ НА ОСНОВЕ АННОТАЦИЙ ХУДОЖЕСТВЕННЫХ КНИГ	287
ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В КИНЕМАТОГРАФИИ.....	295
НЕЙРОСЕТЕВАЯ ОБРАБОТКА ДАННЫХ О ФИЛЬМАХ ДЛЯ ОЦЕНКИ ПОТЕНЦИАЛЬНОЙ ПРИБЫЛИ	296
ПРОГНОЗИРОВАНИЕ УСПЕХА ФИЛЬМА В ПРОКАТЕ С ПОМОЩЬЮ НЕЙРОСЕТЕВОЙ МОДЕЛИ	304
ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В ПРОБЛЕМАХ МИГРАЦИИ НАСЕЛЕНИЯ	311
ПРОГНОЗИРОВАНИЕ УРОВНЯ ИММИГРАЦИИ НА ОСНОВЕ НЕЙРОННЫХ СЕТЕЙ	312
ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В МЕТЕОРОЛОГИИ.....	320
НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗА ГОЛОЛЕДА В ГОРОДЕ ПЕРМИ	321
ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В ПРОБЛЕМАХ БЕЗОПАСНОСТИ	328
НЕЙРОСЕТЕВАЯ СИСТЕМА МОНИТОРИНГА ПОЖАРНОЙ ОБСТАНОВКИ ПО АНАЛИЗУ ВИДЕОДАННЫХ С БЕСПИЛОТНЫХ ЛЕТАТЕЛЬНЫХ АППАРАТОВ.....	329
ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В СПОРТЕ	335
ОЦЕНКА ПОСЕЩЕМОСТИ МАТЧЕЙ БАСКЕТБОЛЬНОГО КЛУБА "ПАРМА" (ПЕРМСКИЙ КРАЙ)	336
НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗИРОВАНИЯ РЕЗУЛЬТАТОВ КУБКА МИРА ПО БИАТЛОНУ	344
НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗИРОВАНИЯ РЕЗУЛЬТАТОВ БОЕВ БЕЗ ПРАВИЛ НА ПЛОЩАДКИ UFC	350
НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗИРОВАНИЯ ПОБЕДИТЕЛЯ МАТЧА БИЛЛАРДНОЙ ИГРЫ СНУКЕР	361
ПРОГНОЗИРОВАНИЕ РЕЗУЛЬТАТА КИБЕРСПОРТИВНЫХ МАТЧЕЙ	368
НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗИРОВАНИЯ РЕЗУЛЬТАТОВ СЕЗОНА НЕМЕЦКОЙ ФУТБОЛЬНОЙ ЛИГИ «БУНДЕСЛИГИ»	373
ВОЗМОЖНОСТЬ ПРОГНОЗИРОВАНИЯ ИСХОДА ФУТБОЛЬНОГО МАТЧА НА ПРИМЕРЕ РОССИЙСКОЙ ПРЕМЬЕР-ЛИГИ.....	381
НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗИРОВАНИЯ И АНАЛИЗА ПОСЕЩЕМОСТИ МАТЧЕЙ АНГЛИЙСКОЙ ПРЕМЬЕР ЛИГИ.....	390
НЕЙРОСЕТЕВАЯ МОДЕЛЬ ПРОГНОЗИРОВАНИЯ ЗАНЯТОГО МЕСТА ФУТБОЛИСТА В ГОЛОСОВАНИИ ЗА «ЗОЛОТОЙ МЯЧ».....	397

ИНСТРУМЕНТЫ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА	406
МЕТОДЫ И ИНСТРУМЕНТЫ СОЗДАНИЯ ИНТЕЛЛЕКТУАЛЬНЫХ СИСТЕМ УПРАВЛЕНИЯ... .	407
СВЕРТОЧНАЯ НЕЙРОННАЯ СЕТЬ НА ОСНОВЕ ЗНАНИЙ ДЛЯ РАСПОЗНАВАНИЯ СИМВОЛОВ.....	412
СРАВНЕНИЕ РАЗЛИЧНЫХ СПОСОБОВ РАСПОЗНАВАНИЯ КЛЮЧЕВОГО СЛОВА С ПОМОЩЬЮ НЕЙРОННЫХ СЕТЕЙ	423
СРАВНЕНИЕ ОСНОВАННЫХ НА ФИЗИКЕ ПОЛНОСВЯЗНЫХ НЕЙРОННЫХ СЕТЕЙ И СЕТЕЙ РАДИАЛЬНЫХ БАЗИСНЫХ ФУНКЦИЙ	427
АНАЛИЗ СТАТИСТИЧЕСКОЙ ИНФОРМАЦИИ НА ОСНОВЕ МЕТОДОВ МАШИННОГО ОБУЧЕНИЯ	436
ДОВЕРЕННЫЙ ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ, ПОСТРОЕННЫЙ С ИСПОЛЬЗОВАНИЕМ НЕЙРОНОВ СРЕДНЕГО ГАРМОНИЧЕСКОГО.....	441
РАЗРАБОТКА СИСТЕМЫ КОММУНИКАЦИИ ИНТЕЛЛЕКТУАЛЬНЫХ АГЕНТОВ НА ОСНОВЕ ОНТОЛОГИЧЕСКОГО ПОДХОДА	446
АЛГОРИТМЫ АНАЛИЗА ЗНАЧЕНИЙ ЦЕЛЕВЫХ ПОКАЗАТЕЛЕЙ НА ДОСТИЖИМОСТЬ ПРИ ПОЛИЭДРАЛЬНЫХ ОГРАНИЧЕНИЯХ	450

«Думаю, она [Конференция] хорошо отображает тот факт, что ваша Пермская школа и ваша системная деятельность – лучшее, что есть в нашей стране в области многоплановой разработки проблем ИИ.»

Д.И.Дубровский, Сопредседатель Научного совета при президиуме РАН по методологии искусственного интеллекта, д.ф.н., профессор.

ПЛЕНАРНЫЕ ДОКЛАДЫ

НАУКА И ГЛОБАЛЬНЫЕ ВЫЗОВЫ XXI ВЕКА

Фиговский Олег Львович

Ассоциация изобретателей Израиля,
г. Хайфа, Израиль

В статье описаны основные тенденции развития проектов, связанных с нанотехнологиями, искусственным интеллектом и роботизацией, описаны необходимые подготовительные этапы для обеспечения успеха науки в РФ, кратко говорится об организации науки и образования Израиля, обеспечившей научное и образовательное лидерство этой страны в мире.

Ключевые слова: искусственный интеллект, роботы, наука, высшее образование, организация науки, университеты, цифровизация обучения.

В этой статье мне хочется осветить наиболее значимые аспекты развития науки, технологий и техники в аспекте искусственного интеллекта, в меньшей мере, нанотехнологий, а также описать некоторые пути достижения основных целей этого развития, прежде всего, связанных с вопросами образования.

Одной из главных целей любых научных исследований является обеспечение наибольшего количества свободного времени у членов общества после внедрения в жизнь этого общества результатов деятельности ученых.

К сожалению, в современном мире многие думают, что глобальной целью любой деятельности является обеспечение себя сверхдоходами. Но получение сверхдоходов подменяет основные ориентиры развития социума на ложные, о чем сказано, хотя и косвенно, в последнем докладе Римского Клуба [1].

Известный американский футуролог Рэй Курцвейл, предполагая, что технологии развиваются по экспоненциальному закону, в 2017 году разработал прогноз существования человечества на 100 лет вперед, буквально расписав итоги внедрения результатов научных исследований на временные периоды, начиная с 2019 года [2]. Верификация его прогнозов прошедшими 2019 и 2020 годами дает основание утверждать, что Р. Курцвейл не во всем был прав. Так, например, он ошибся в предсказании повсеместного внедрения на планете в 2019 году беспроводных средств коммуникаций и передачи энергии. Футуролог не учел того обстоятельства, что технические системы развиваются не по экспоненциальному закону, а, скорее, по колебательному «закону синуса», когда скорость их развития периодически увеличивается или уменьшается [3].

Приведем небольшой пример колебательного принципа внедрения технологий в жизнь на примере одной из специальностей механико-математического факультета Пермского государственного национального исследовательского университета (ПГНИУ). Недавно по моей просьбе был проведен устный опрос студентов одной из специальностей факультета.

Результаты опроса показали, что студенты-программисты начали активно игнорировать получение информации с помощью глобальной сети интернет и цифровых технологий, а социальные сети стремительно теряют свою популярность среди молодежи, вплоть до того, что студенты ликвидируют личные аккаунты в соцсетях. Студенты начали предпочитать цифровым источникам информации работу в библиотеках и чтение печатных книг. Это радует, так как интернет, как показали психологи, в основном, порождает клиповое мышление [4], а шлемы и иные технические средства виртуальной реальности заставляют человека жить в вымышленном мире, значительно уменьшая его способности как для общения в «живом» мире, так и восприятия самого «живого» мира.

Если говорить о состоянии молодых людей, длительно работающих за компьютером, то бросается в глаза, прежде всего, массовое ухудшение физических способностей юношей и девушек. Первые, порой, выглядят, как некие аморфные тела, не способные пробежать самую малую дистанцию без одышки. Этот, казалось бы, незначительный факт, сигнализирует о возможном начале вырождения человека как вида. Чтобы избежать вырождения нужно, прежде всего, людям, активно пользующимся в профессиональной деятельности средствами цифровых технологий, заниматься спортом: эта рекомендация, на наш взгляд, в недалеком будущем, может быть принята в некоторых наиболее мудрых странах на законодательном уровне.

Таким образом, решение задач широкого внедрения информационных технологий в жизнь общества должна носить, прежде всего, комплексный характер, предусматривающий все аспекты существования социума.

Но кратко остановимся на основных направлениях развития технологий с применением искусственного интеллекта.

Обращает на себя, прежде всего, то, что создание робототехники стремительно движется в направлении автономных роботов, т.е. роботов, самостоятельно, вне человека принимающих решения. Особенную тревогу вызывает использование таких машинных способностей, предназначенных для решения боевых задач.

Хочется подчеркнуть, что именно на решение задач войны с помощью роботов направлена превалирующая часть финансовых затрат практически всех развитых государств мира, занимающихся разработкой методов ИИ.

Так как автономным принятием решений с помощью ИИ в боевых действиях преследуется, в числе прочего, глобальная цель – высвобождение времени людей, – то можно сказать, что роботы в этом случае удовлетворяют главной цели развития технологий, описанной в начале статьи. Если произойдет очередная мировая война, то она будет скоротечной, стремительной, с массовым уничтожением всего сущего на Земле. И эта война будет вестись роботами, самостоятельно принимающими решения и практически без участия человека в боевых действиях.

Зачастую разработчики боевых роботов повторяют и используют идеи, описанные ранее в литературных произведениях писателями-фантастами. О глобальной войне с помощью роботов можно, например, прочитать в рассказе

«Последняя битва» американского писателя Роберта Шекли, вышедшей из печати в семидесятых годах прошлого века. А о современных боевых роботах и боевых дронах, основанных на применении ИИ, можно узнать из совместных работ автора настоящей статьи и профессора ПГНИУ О.Г. Пенского [5, 6].

Не будем больше говорить о боевых роботах и «боевом» искусственном интеллекте, тем более, что информацию о конкретных проектах можно легко найти в ресурсах сети интернет.

Для создания любого типа роботов – боевых и не боевых – необходимы, прежде всего, исследования ученых.

Поэтому остановимся на наиболее перспективных, на наш взгляд, направлениях научных изысканий.

Современная наука сегодня может, наверное, решить, если не все, то большинство поставленных перед ней задач. Прогнозы футурологов гласят, что человечество движется в эпоху технологической сингулярности, при которой все, любые поставленные перед учеными задачи смогут быть успешно решены в небольшие временные сроки.

Поэтому в будущем особенно значимыми станут ученые, способные ставить новые задачи. Такие люди ценились во все времена, исключая, наверное, только лишь средневековье, но работа постановщиков-исследователей станет особенно актуальна в человеческом обществе в ближайшей перспективе.

Если говорить о далекой перспективе, то можно отметить, что в настоящее время израильские ученые уже приступили к разработке методов искусственного интеллекта, способного выдвигать научные гипотезы в математике [7]. Израильтяне начали именно с математики, как наиболее формализованной науке. Известно, что гипотезы в основе своей и являются новыми задачами для развития любой науки.

К. Маркс писал, что наука только тогда становится наукой, когда она начинает широко использовать математику [8]. Поэтому в недалекой перспективе ученые-программисты смогут научить искусственный интеллект выдвигать новые гипотезы также в других науках, которые уже сейчас широко используют математику.

Хочется сказать о «психологических» особенностях принципиально новых проектов. Главным достоинством создателей таких проектов является то, что ученые-новаторы впервые ставят перед человечеством нестандартные задачи, способные значительно обогатить знания об окружающем мире, и открывают новые законы развития мира, о которых ранее никто даже не задумывался. Нестандартные идеи, как правило, порождают мощную критику в научном мире, которая, зачастую, уничтожает попытки познания нового.

Сейчас, в частности в России, довольно сложно «протолкнуть» в научное сообщество нестандартные по своей сути идеи даже, если они сопровождаются теорией, подтвержденной правдивыми экспериментами. Поэтому множество идей, родившихся в России, исчезают в никуда. Одной из причин этого является, например, работа комитета РАН по лженеакуке (отмечу, что этот термин был введен во времена СССР, когда кибернетика и генетика признавались лженеакукой), который, как правило, признает не лженеакучными те исследования,

которые одобрены большими научными школами, основанными на результатах исследований середины прошлого века и весомыми современными, пускай, и очень престарелыми, академиками.

В аспекте написанного выше хотелось бы рассказать о том, как организована адекватная оценка нестандартных научных идей и проектов и их продвижение в промышленность в Израиле.

В Израиле официально существует Независимая Академия Наук, в которой занимаются новыми нестандартными с традиционной научной точки зрения проектами, существуют гранты, которые позволяют финансировать принципиально новые нестандартные исследования, а финансирование, порой, достигает сотен тысяч долларов. Для того, чтобы выиграть такой грант, заявитель должен предоставить на конкурс не только описание научной идеи, но и описание результатов исследований, показывающие закономерность явлений, подлежащих изучению в ходе выполнения гранта. Именно выявленные закономерности, открытые вновь причинно-следственные связи и их многочисленное экспериментальное обоснование делают науку настоящей наукой.

В некоторых серьезных научных журналах Израиля существуют разделы под названием «Нестандартные идеи». Я много лет был главным редактором научного журнала «Scientific Israel – Technological Advantages», и в моем журнале также был такой раздел, где авторы публиковали результаты своих исследований, в отличие от некоторых коммерческих изданий, бесплатно. Журнал «Scientific Israel – Technological Advantages» имел большую популярность в Израиле, России и мире. Авторам статей, опубликованных в журнале, выступали не только израильяне, но и ученые со всего мира, в том числе, специалисты по искусственному интеллекту.

В качестве контрпримера расскажу о недавней ситуации, которая произошла в научном журнале ПГНИУ «Вестник Пермского университета. Математика. Механика. Информатика». Международная группа израильских и российских ученых направила в редакцию журнала статью, посвященную математическим моделям, которые описывают новый взгляд на природу явлений в ядерной физике. В результате экспертизы статья была отклонена и не принята к публикации из-за нестандартности взглядов, изложенных в рукописи. После отказа пермского журнала в публикации рукописи авторы направили статью в германский научный журнал «Deutsche internationale Zeitschrift für zeitgenössische Wissenschaft», где после рецензирования статья была опубликована [9] в течение месяца. Отмечу то, что авторам отвергнутой журналом ПГНИУ статьи, пришло приглашение немцев и в дальнейшем публиковать рукописи по затронутой авторами тематике в журнале «Deutsche internationale Zeitschrift für zeitgenössische Wissenschaft». Я думаю, что одним из основных недостатков российских журналов является некоторая косность в восприятии новых идей, консервативная приверженность к устаревшим традициям и забюрокраченность при принятии решений, что отбрасывает российскую науку назад по сравнению, например, с европейскими странами.

В настоящее время в мировой науке особенно важными становятся междисциплинарные исследования. Именно на стыке наук рождаются новые открытия и генерируются принципиально новые идеи.

Выше я подверг критике работу одного из научных журналов ПГНИУ. Но в Пермском государственном национальном исследовательском университете рождаются и совершенно новые науки. Примерами этого являются научные направления, создаваемые профессором Б.М. Осовецким по наноминералогии и профессором О.Г. Пенским по математическому моделированию эмоциональных роботов – психологических цифровых двойников человека. Результаты исследований О.Г. Пенского, имеющие на сегодняшний день несомненный международный приоритет, опубликованы в научных журналах многих стран: России, Израиля, Индии, США, Польши, Белоруссии, Дании. Он читал лекции по математическим моделям эмоциональных роботов студентам Оксфордского университета, Донецкого национального технического университета [10, 11], в Политехническом музее (г. Москва), ведет занятия у магистрантов ПГНИУ по теме «Математические модели цифровых двойников» [12]. Подробно о созданном О.Г. Пенским научном направлении мной опубликована большая статья в журнале ВАК РФ «Инженерный вестник Дона» [13], также сам профессор рассказывал о своих исследованиях в некоторых интервью радиостанциям Перми, недавно были записаны его развернутые ответы на вопросы телевидения г. Калуги [14, 15]. Тематика работ О.Г. Пенского относится к междисциплинарным исследованиям, а именно, к описанию формулами психологии человека. О.Г. Пенский имеет только одного научного конкурента в мировой науке – Мозговой Центр США по борьбе с терроризмом, который располагается в Калифорнийском университете. Но отличие работ пермского ученого от американцев состоит в разных математических подходах к описанию поведения людей. Исследования в США используют для этой цели модернизированную Центром математическую логику (созданную теорию рефлексий [16, 17]), а О.Г. Пенский со своими учениками – аппарат линейной алгебры, математического анализа и методов оптимизации. Большой интерес международного научного сообщества к работам О.Г. Пенского подтверждает тот факт, что, например, всего две его публикации в научном журнале США «Intelligent Control and Automation» были скопированы читателями более 6 800 раз и признаны редакцией журнала наиболее высокорейтинговыми публикациями этого издания [18].

Отметим то, что, начиная с 2019 г., исследования, основу которых заложил пермский профессор, начали проводиться совместно российскими и израильскими учеными, а в 2021 г. вышла в издательстве Российского Университета Дружбы Народов (г. Москва) монография О.Л. Фиговского и О.Г. Пенского «Люди и роботы» [19]. В книге авторы рассматривают проблемы и результаты взаимного сосуществования людей и роботов, в том числе психологические аспекты; приводят примеры сосуществования людей и роботов на всех этапах жизни человека: от рождения до смерти; описывают прогнозы возможного развития робототехнического социума в ближайшем и далеком будущем; предлагают математические модели, позволяющие оценивать

современное состояние и перспективы взаимоотношений людей и роботов. Книга основана на оригинальных работах, опубликованных авторами в России и за рубежом в последние годы. Монография издана объемом в 368 страниц и предназначена как для специалистов в области гуманитарных наук (политологии, психологии, философии, экономики), технических, физико-математических наук, так и для широкого круга читателей, интересующихся вопросами существования людей и роботов и перспектив этого существования. Так как в монографии описываются современные достижения в робототехнике и даются ориентиры на будущее, то книга будет интересной и читателям, занимающимся инновационными проектами. В частности, книга может быть полезна для генерации собственных идей в создании новых роботов, комфортных для человека. В настоящее время готовится к изданию еще одна совместная монография тех же авторов под названием «Будущее начинается завтра (этюды о новых тенденциях в науке)». Новая книга будет, в основном, посвящена политическим аспектам существования социума в связи с его ускоряющейся роботизацией.

Журналист телевидения Калуги М.Дьяченко, окончивший МВТУ им. Баумана и Духовную семинарию РПЦ, в одной из своих передач сказал, что следующие Юрии Гагарины появятся именно в психологии и педагогике [14, 15]. Наверное, он прав, так как эти области научной и практической деятельности человека почти совсем не математизированы, а, существующие исследования носят гуманитарный характер, зачастую основанный на личных убеждениях больших ученых.

Отмечу, что за разработку математических моделей цифровых, двойников человека, имеющих авторский международный приоритет, О.Г. Пенский летом 2021 г. был награжден дипломом Ассоциации Изобретателей Израиля.

В настоящее время в технологически развитых государствах мира приступили к активным разработкам методов ИИ, целью которых является написание новых патентов на изобретения. В этом направлении уже есть первые успехи. Но для того, чтобы защитить авторские права живых, а не машинных изобретателей, в США идет работа над созданием закона, на основе которого изобретения, предложенные искусственным интеллектом, не будут патентоваться.

Если машины овладеют всеми тайнами изобретательства, то, по всей видимости, произойдет та же ситуация, что и с шахматами. Сейчас в шахматы компьютеры играют лучше гроссмейстеров, а поэтому шахматные партии для многих людей уже потеряли свою привлекательность. Не исключаю того, «живое» изобретательство, благодаря ИИ, перейдет лишь в разряд человеческих спортивных творческих соревнований.

Роботы и искусственный интеллект, как уже было отмечено выше, стремительно врываются в жизнь социума. В настоящей статье мы не будем перечислять многочисленные существующие проекты, тем более, что ознакомиться с этими проектами может каждый, обратившись к информационным ресурсам сети интернет. Но зададимся вопросом:

- Готово ли интеллектуально общество людей к совместному существованию с роботами?

На мой взгляд, большая часть людей в настоящее время превращается только лишь в потребителей, не задумывающихся о перспективах того мира, в котором они живут. Для того, чтобы человечество осознано грядущее и не выпало из современности, крайне необходимо ввести новые образовательные дисциплины, например, в высших учебных заведениях.

В сентябре 2021 г. ректор Московского государственного университета В.А. Садовничий принял решение о введении в учебный процесс на всех факультетах вуза, включая гуманитарные, предметы, посвященные искусственному интеллекту [20]. Это решение совершенно правильное и весьма своевременное, так как молодые люди – будущее нашего общества – должны грамотно относиться к достижениям передовой науки.

В современном высшем образовании РФ очень много проблем, одной из причин этого являются непрерывные реформы, проходящие в организации обучения студентов. В аспекте искусственного интеллекта можно сказать, что сейчас взят курс, как мне кажется, на превалирующую цифровизацию обучения молодежи. Например, планируется ввести, так называемые, индивидуальные образовательные траектории для каждого студента. Их введение объясняется ориентацией на конкретные потребности существующего производства. Но индивидуальные образовательные траектории требуют огромного количества узких специалистов-преподавателей, так как круг задач, которыми занимаются промышленники, исчисляются если не сотнями тысяч, то, по крайне мере, десятками тысяч. Единственным выходом из складывающейся ситуации является создание больших общих цифровых платформ с записями лекций тысяч узких специалистов по всей стране. Это означает массовое внедрение дистанционного образования и искусственного интеллекта в подготовку специалистов с высшим образованием. Руководители высшего образования России стремятся сразу после окончания студентами университетов сделать их пригодными для решения конкретных задач конкретного завода, компании и т.д. На мой взгляд, это тупиковое направление в обучении, так как выпускники вузов будут иметь очень узкопрофильные компетенции, которые лишат молодежь возможности быстро освоить новые дисциплины из-за отсутствия у нее хорошего фундаментального образования, не предусматриваемого индивидуальными образовательными траекториями.

Современное производство требует от его участника постоянное овладение новыми компетенциями.

Как известно, в Израиле университетов насчитывается меньше десятка, но все они входят в лидеры всех мировых рейтингов. В израильских вузах индивидуальные образовательные траектории не предусмотрены. Обучение в университетах проходит в обычном порядке с участием «живых» преподавателей и по общим программам, включающим большой набор фундаментальных дисциплин. Но для удовлетворения запросов конкретных компаний выпускники могут после окончания вуза получить дополнительное образование, прослушав дистанционные «цифровые» курсы, которых в Израиле

огромное количество. Именно благодаря разумности в организации учебного процесса, описанного выше, в Израиле ни цифровизация, ни внедрение искусственного интеллекта в образование не влекут угрозы государству.

Я периодически просматриваю новостную ленту сайта ПГНИУ [21]. Судя по содержанию размещенных новостей, можно сделать вывод о том, что в университете отсутствует связь научных поколений, так как в информации о научных проектах в качестве героев заметок указываются или только молодые люди, или только престарелые профессора и доценты. Складывается ощущение, что они работают вне зависимости друг от друга. Я думаю, что это, на самом деле, не так, потому что только передача опыта зрелых ученых молодым может способствовать плодотворным научным исследованиям. Однако содержание статей на сайте уверяет студентов в том, что гении рождаются сами без участия старших, что полностью искажает представление о развитии науки у молодежи, когда есть и учитель, и ученик.

Следует сказать, что в России в целом крайне необходимо восстанавливать именно преемственность научных поколений, которая, на мой взгляд, почти полностью разрушена. Не случайно только 10% выпускников аспирантуры университетов страны становятся кандидатами наук [22]. Причиной сложившейся ситуации является не только разрушенная преемственность научных поколений, но, наверное, как это ни покажется странным, низкая квалификация большого количества руководителей аспирантуры. На мой взгляд, сейчас целесообразно организовать в вузах круглые столы профессоров для обмена опытом успешных ученых по подготовке диссертаций учениками и выработке конкретных решений по исправлению сложившейся ситуации в каждом конкретном университете. Важно понять, что промедление в решении этого вопроса подобно смерти всей вузовской науки, по крайней мере, провинциальной

Хочу, как специалист по нанотехнологиям, имеющий более 500 патентов на изобретения, более 300 из которых используются в различных компаниях развитых государств мира, немного сказать именно об организации исследований в этой сфере. Я не буду перечислять достижения в нанотехнологиях: все можно найти в интернете, а сделаю лишь небольшую ремарку. В штат Роснано входит более 500 человек. Израиль является одним из ведущих государств мира по созданным инновационным технологиям. Штат государственной структуры Израиля, курирующей нанотехнологии, имеет всего 2 ставки: руководитель, трудоустроенный на 0.5 ставки, делопроизводитель (он же бухгалтер) – на 1 ставку, – и менеджер – организатор экспертиз проектов и различных общих мероприятий – на 0.5 ставки. Я думаю, что, если сравнить достижения Роснано и Израиля в области нанотехнологий, то анализ вышеприведенных чисел по ставкам позволит сделать правильный вывод об эффективности обеих структур Вам самим.

Таким образом, только из написанного выше, конечно, затрагивающего далеко не все аспекты искусственного интеллекта и почти совсем не касающийся нанотехнологий и связанных с ним науки и образования, можно сделать следующие выводы:

- основными тенденциями в использовании искусственного интеллекта в науке является его применение в решении междисциплинарных задач, в том числе, связанных с творческими процессами человека;
- в настоящее время стремительно происходит внедрение искусственного интеллекта практически во все сферы практической деятельности человека, в том числе в его духовные процессы;
- необходимо осторожное и разумное внедрение методов искусственного интеллекта в образовательный процесс: без большой необходимости это повсеместное внедрение может нанести только вред;
- для внедрения искусственного интеллекта в образовательный процесс, требуется тщательное изучение опыта многих государств; наиболее удачным опытом, подтвержденным успешной практикой использования дистанционного обучения и ИИ в образовании, является многолетний опыт Израиля;
- необходимо тщательно изучить опыт Израиля в организации исследований, касающихся нанотехнологий, адаптировать его к каждому государству, исходя из местных условий, а затем внедрить его в организацию науки многих стран;
- согласно законам развития технических систем в ближайшие десять лет возможен серьезный спад интереса к цифровым технологиям и искусственноому интеллекту, но ИИ будет активно использоваться без его нового качественного развития; эту двойную особенность необходимо учитывать при разработке стратегий технологического развития государств и методик образования;
- в РФ необходимо большее внимание уделять нестандартным научным проектам с обеспечением адекватной, вдумчивой экспертизы исследований; в научных журналах ввести отдельные рубрики, посвященные описанию результатов этих проектов;
- необходимо в вузах, в том числе провинциальных, поддержать инициативу ректора МГУ о введении учебных курсов по искусственноому интеллекту на всех факультетах;
- для подготовки России к научным прорывам нужно, прежде всего, восстановить преемственность научных поколений;
- для увеличения количества защит диссертаций после аспирантуры необходима (в качестве одного из способов решения проблемы) организация круглых столов в вузах для обмена опытом научных руководителей аспирантур и выработки коллективных решений по мероприятиям в повышении эффективности аспирантуры в каждом конкретном университете.

Я перечислил лишь малое количество предложений по организации науки в стране, основываясь и на зарубежном, и на российском опыте. Но, если даже эти выводы будут полностью реализованы, то они принесут значительный эффект в рассматриваемом в настоящей статье вопросе. Поиск ответов на вопросы об увеличении эффективности науки – основной глобальный вызов XXI века.

Библиографический список

1. Моделирование и прогнозирование глобальных процессов: пределы роста в XXI веке. Доклад Римского клуба 16.04.2021.[Электронный ресурс]. Режим

- доступа: <https://www.msu.ru/news/modelirovanie-i-prognozirovanie-globalnykh-protsessov-predely-rosta-v-xxi-veke.html> .
2. Технологический прогноз на 100 лет от Рэймона Курцвейла. Электронный ресурс]. Режим доступа: <https://www.youtube.com/watch?v=blRZ7fQb68U> .
 3. Законы развития технических систем. Учебник ТРИЗ. [Электронный ресурс]. Режим доступа:
[https://ru.wikibooks.org/wiki/%D0%A3%D1%87%D0%B5%D0%B1%D0%BD%D0%B8%D0%BA%D0%A2%D0%A0%D0%98%D0%97%D0%97%D0%B0%D0%BA%D0%BE%D0%BD%D1%8B%D1%80%D0%B0%D0%BD%D0%82%D0%BD%D1%8F%D1%82%D0%BD%D1%85%D0%BD%D0%BD%D0%BD%D1%87%D0%BD%D1%81%D0%BD%D0%BA%D0%BD%D0%BD%D1%85%D0%BD%D0%BD%D1%81%D0%BD%D0%BD%D1%82%D0%BD%D0%BD%D0%BD%D0%BC](https://ru.wikibooks.org/wiki/%D0%A3%D1%87%D0%B5%D0%B1%D0%BD%D0%B8%D0%BA%D0%A2%D0%A0%D0%98%D0%97%D0%97%D0%B0%D0%BA%D0%BE%D0%BD%D1%8B%D1%80%D0%B0%D0%BD%D0%82%D0%BD%D1%8F%D1%82%D0%BD%D1%85%D0%BD%D0%BD%D0%BD%D1%87%D0%BD%D1%81%D0%BD%D0%BA%D0%BD%D0%BD%D1%85%D0%BD%D0%BD%D1%81%D0%BD%D0%BD%D1%81%D0%BD%D0%BD%D1%82%D0%BD%D0%BD%D0%BD%D0%BC) .
 4. Мационг Е. Думай, как бот // Российская газета. 02.05.2018.
 5. Фиговский О., Пенский О. Боевые роботы цивилизации землян // Наука и жизнь Израиля. [Электронный ресурс]. Режим доступа:
<http://nizinew.co.il/novosti-nauki/boevye-roboty-civilizacii-zemlyan.html>
 6. Фиговский О., Пенский О. Дроны – мировые направления развития // Наука и жизнь Израиля. [Электронный ресурс]. Режим доступа:
<http://nizinew.co.il/nauka/texnicheskie-nauki/drony-mirovye-napravleniya-razvitiya.html>
 7. Сердюкова М. Израильские инженеры создали генерирующий гипотезы искусственный интеллект. 21.08.2021. [Электронный ресурс]. Режим доступа: https://tdnu.ru/article/project/inzhenery-iz-izrailya-sozdali-neobychnyyi-sozdayushchiy-gipotezy/?utm_source=yxnews&utm_medium=desktop
 8. Волкова В.О., Маслов В.М., Соснина Е.Н., Шетулова Е.Д., Ширшин Г.А. Философия науки: постнеклассические стратегии развития. Н. Новгород: изд-во НГТУ. 2015. 132 с.
 9. Gurevich G.S., Pensky O.G. Mathematical modeling of processes of motion of a material point emitting from a central force field // German International Journal of Modern Science №17, 2021. Pp. 43 – 53.
 10. Механико-математический факультет стал участником большого издательского проекта Оксфордского университета. [Электронный ресурс]. Режим доступа: <http://www.psu.ru/news-archive/year-2010/mekhaniko-matematicheskij-fakultet-stal-uchastnikom-bolshogo-izdatelskogo-proekta-oxfordskogo-universiteta>
 11. Донецких студентов научат моделировать эмоциональных роботов. [Электронный ресурс]. Режим доступа:
<https://www.youtube.com/watch?v=qg1ZiDE9G8I>
 12. Пенский О.Г. Математические модели цифровых двойников: учебное пособие. Пермь: изд-во ПГНИУ. 2019. 153 с.
 13. Фиговский О.Л. О научном приоритете пермских ученых в моделировании «психологии» цифровых двойников человека // Инженерный

- вестник Дона, №7 (2020). [Электронный ресурс]. Режим доступа: <https://www.ivdon.ru/ru/magazine/archive/n7y2020/6553>
14. Пенский О.Г. Большое интервью. [Электронный ресурс]. Режим доступа: <https://www.youtube.com/watch?v=NPVjNU2BjxU>
 15. Пенский О.Г. Кто научит роботов плакать? [Электронный ресурс]. Режим доступа: https://www.youtube.com/watch?v=w59vmeqD_ll
 16. Лефевр В.А. Рефлексивные процессы и управление // Международный научно практический междисциплинарный журнал. Специальный выпуск, Специальный выпуск, посвященный 70-летию В.А. Лефевра. 2006. Январь-февраль. №1. Т.6. [Электронный ресурс]. Режим доступа: http://www.reflexion.ru/Library/J2006_1.pdf.
 17. Лефевр В. Рефлексия. [Электронный ресурс]. Режим доступа: <http://berezkin.info/wp-content/uploads/2016/08/Lefevr-refleksia-2003.pdf>
 18. Pensky O. Intelligent Control and Automation. [Электронный ресурс]. Режим доступа: https://www.scirp.org/journal/ica/?utm_campaign=296533276_107613880472&utm_source=lixiaofang&utm_medium=adwords&utm_content=dsa-906319931212_c&gclid=EAJaiQobChMloazkkJaD8wIVjJGyCh0-GwgaEAAVASAAEgLo6_D_BwE
 19. Фиговский О.Л., Пенский О.Г. Люди и роботы. М.: изд-во РУДН. 2021. 368 с. [Электронный ресурс]. Режим доступа: <http://asipr.ru/sites/default/files/pdf/2021/%D0%9B%D0%AE%D0%94%D0%98%D20%D0%98%D20%D0%A0%D0%9E%D0%91%D0%9E%D0%A2%D0%AB.pdf>
 20. Студентов МГУ обязали проходить курс по искусственному интеллекту. [Электронный ресурс]. Режим доступа: <https://www.rbc.ru/rbcfreenews/613b602d9a79476242746221>
 21. Новостная лента сайта ПГНИУ. [Электронный ресурс]. Режим доступа: <http://www.psu.ru/news>
 22. Медведев Ю. защитить аспиранта. Российская газета. 25.05.2021. Электронный ресурс]. Режим доступа: <https://rg.ru/2021/05/25/pochemu-tolko-1-iz-10-molodyh-uchenyh-dohodit-do-dissertacii.html>

SCIENCE AND GLOBAL CHALLENGES OF THE XXI CENTURY

Figovskiy Oleg L.

Israel Inventors Association,

Haifa, Israel

The article describes the main trends in the development of projects related to nanotechnology, artificial intelligence and robotization, describes the necessary preparatory stages to ensure the success of science in the Russian Federation, briefly talks about the organization of science and education in Israel, which ensured the scientific and educational leadership of this country in the world.

Key words: artificial intelligence, robots, science, higher education, organization of science, universities, digitalization of education.

ПРЕПОДАВАНИЕ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА В ПЕРМСКОМ УНИВЕРСИТЕТЕ: 1998 – 2021

Ясницкий Леонид Нахимович

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
yasn@psu.ru

Интервью Л.Н.Ясницкого, корреспонденту газеты «Аргументы и Факты» Наталье Стерледевой. С незначительными изменениями это интервью опубликованного в газете «Аргументы и Факты», Прикамье, № 38, 2021 г.

Ключевые слова: искусственный интеллект, лженаука, нейросетевые технологии, преподавание, инновации, научный приоритет.

- Леонид Нахимович, трудно ли было заниматься искусственным интеллектом в СССР?

- Я занимаюсь искусственным интеллектом довольно давно, в 1973 году вышла моя первая статья, а в 1992 – первая книга. Фактически, «эстафету» принял у Юрия Владимировича Девингтала, основателя кафедры прикладной математики и создателя первого в Перми вычислительного центра в Пермском университете.

Как известно, в СССР кибернетика долгое время считалась буржуазной лженаукой. И даже, когда я в 90-е годы я начал читать курс искусственного интеллекта в Пермском университете, не раз испытал на себе скептическое отношение коллег. В первом своём реальном проекте я применил методы ИИ для диагностики авиационных двигателей. Результаты диагностики получались весьма обнадеживающими, но, подвела репутация кибернетики как лженауки, да и денег тогда в стране не было, и проект не нашёл продолжения. А потом начались победы. В 2005 году вместе с сотрудниками Пермского Управления МВД мы создали первый в мире детектор лжи, работающий на нейронных сетях. Совместно с учеными медицинского университета мы создали одну из первых интеллектуальных систем, способных не только диагностировать заболевания, но и прогнозировать их развитие и на основании этих прогнозов оптимизировать образ жизни и лечение пациентов. В числе первых мы начали развивать и применять методы искусственного интеллекта в социологии, политологии, психологии, экономике, промышленности, и даже в спорте. Например, прогнозировали, какое место займёт Россия на олимпиаде на основе характеристик спортсменов, и прогнозы оказались очень точными. «Предсказали» победу Дмитрия Медведева за два года до президентских выборов 2008 года. Хотя эти прогнозы в то время казались не реальными, они были опубликованы в научных статьях, и они потом подтвердились.

Многие наши инновационные проекты появились благодаря креативности студентов пермских вузов. Из курсовых работ вырастали магистерские, а затем кандидатские и даже, были случаи – докторские диссертации. Были победы на конкурсах стартапов.

Для примера, на нашем сайте www.PermAi.ru в разделе «Проекты», вы можете познакомиться с некоторыми результатами студенческого творчества. Запустив нейронные сети и ответив на ряд вопросов, вы можете оценить ваши способности к бизнесу, к научной деятельности и к руководящей деятельности. Можете оценить предрасположенность вашего организма к наркомании, к анорексии, к пьянству и к насилию, и можете получить рекомендации, как от этого избавиться. Можете выполнить прогноз продолжительности вашего будущего брака и оптимально подобрать себе будущего спутника жизни. Можете узнать состояние вашей сердечно-сосудистой и гастроэнтерологической систем и подобрать оптимальный образ жизни, снижающий риски заболеваний. Можете оценить стоимость вашей квартиры и узнать степень надежности банка, в котором храните сбережения, и т.д.

Можно ли назвать сегодняшние разработки полноценным искусственным интеллектом?

- Строгого определения искусственного интеллекта нет. Планка постоянно поднимается. Когда-то компьютер научился складывать « $2+2$ », считал площадь круга, и это уже считалось интеллектуальной задачей. Сейчас ИИ связывают, в первую очередь, с нейронными сетями. В 50-х годах 20 века американские ученые МакКаллок и Питтс придумали модель математического нейрона и постарались придать ему свойства биологического нейрона. Розенблatt с помощью таких нейронов создал первый нейрокомпьютер и обучил его распознавать буквы латинского алфавита. Это был колоссальный успех. Казалось, удалось разгадать секреты мозга, и теперь нейрокомпьютеры будут совершать чудеса. Учёным стали поступать заказы. Военные захотели создать систему распознавания «свой-чужой», чтобы узнавать пролетающие самолёты. Экономисты просили научиться предсказывать курсы валют, медики – расшифровывать электрокардиограммы. Программисты взялись за выполнение этих заказов, но со многими проектами справиться не смогли. После этого американцы 20 лет не занимались нейросетями, и сочли их тупиковым направлением.

А в СССР, напротив, стали развивать ИИ. И в конце 80-х годов в России появился первый в мире промышленный нейрокомпьютер, успешно решивший ту самую проблему, с которой американцы тогда не справились – распознавать свои и чужие самолеты. Но, перестройка свела на нет успех советских ученых.

- Вы автор учебников по искусенному интеллекту. Нет ощущения, что вы сегодняшний прогресс построили?

- Вспомнился случай. Сидим мы в диссертационном совете, решаем вопросы о присуждении ученых степеней. Выступает приезжий аспирант. Он научил нейронную сеть определять надежность кредито-заемщиков и внедрил свою интеллектуальную систему в банках своего родного города. В своём докладе он перечисляет всех, кто имел отношение к созданию ИИ: Пифагор,

Евклид, Луллий, Аристотель, Ясницкий... После выступления подхожу к нему и говорю: «Что ж вы меня к Аристотелю причислили? Я ведь живой», а он мне: «так я по вашим учебникам учился, думал, вас уже нет...». После таких случаев коллеги стали в шутку задавать иногородним соискателям ученых степеней «контрольный» вопрос – жив ли Ясницкий?

А если серьёзно, есть ощущение, что мы своими публикациями, и правда, отчасти, помогли создать эту сегодняшнюю сверхпопулярность ИИ.

- Что побудило вас заняться проблемой заводского брака?

- Есть общая проблема для машиностроительных предприятий: процесс изготовления литейных изделий очень капризный. На качество создаваемого изделия влияет очень много факторов – температура, давление, влажность, условия кристаллизации металла и т.д. В некоторых отраслях процент брака доходит до 50 и больше. Конечно, испорченный материал потом переплавляют, но это лишняя трата ресурсов. Идёт вечный бой между технологами и разработчиками о том, кто виноват в том, что деталь не укладывается в заданные допуски, а изделие при испытаниях не дотягивает до требуемых характеристик. Мы решили поручить решение проблемы искусственному интеллекту – взялись построить нейросетевую модель технологического процесса создания изделий одного из пермских заводов, и с ее помощью снизить процент брака и повысить качество изделий.

Вместе с заводскими работниками мы месяцами собирали данные по литью деталей, направили на завод студентов – они бегали с секундомером, записывали мельчайшие тонкости: время нахождения заготовки в форме для литья, время переноса её на другой участок, температуру, давление, влажность. И главное – результаты контроля качества каждой полученной заготовки. Данные «скормливали» нейронной модели. Она обогащалась опытом, и, в конце концов, выдала нам сочетание параметров, при котором на одном из участков литейного процесса процент брака удалось снизить в два раза. Этот факт подтвержден промышленными экспериментами и зафиксирован в заводском отчёте.

Это конечно успех, но успех незначительный. Поскольку для полноценного экономического эффекта нужно оптимизировать не один отдельно взятый участок, а всю цепочку технологического процесса. Сейчас мы ждем финансирования, чтобы продолжить работы и оптимизировать как можно больше технологических участков и процессов, которых на заводе множество.

- Сколько нужно времени, чтобы заново создать такую модель под конкретную деталь и под конкретный завод?

- Успех зависит от многих факторов. Завод должен быть серийным – иначе не собрать историю для обучения нейросетевой модели. Очень важно правильно сформулировать задачу, нашупать те параметры, которые, в сочетании с другими параметрами, действительно влияют на качество изделий. Нужны возможности и время, чтобы собрать нужные параметры, накопить данные для обучения нейронных сетей.

Пока, темой применения нейросетевого моделирования в этой области мало кто занимается, причем, не только у нас, но и за рубежом. По крайней мере,

сообщений о головокружительных успехах пока нет. Но я уверен, что цифровизация дотянется и досюда. Возможно, в ближайшие 5-10 лет. И мы с нашим опытом можем в этом помочь.

- Вы занимались разработкой ИИ в кардиологии. Как это случилось?

- Лет 15 назад у меня были проблемы с сердцем, с приступом меня увезли в 4-ю клиническую больницу. И там я уговорил своего лечащего врача, Андрея Думлера, прекрасного диагностика, сделать модель ИИ, которая будет ставить диагнозы так же, как он. Он поверил в эту идею и стал вместе со своими коллегами собирать необходимые для обучения нейронных сетей данные.

В нейронную модель мы вводили опыт диагностики – возраст, пол, болезни родственников пациента, было ли давление, кружилась ли голова, в какой области боли, что провоцирует приступы, их характер и как они снимаются и т.д. Все эти данным мы помещали на входе нейросетевой модели, а на выходе – известный нам диагноз, который уже поставил врач – инфаркт, гипертония, аритмия, стенокардия и т.д. Нейросети накопили эту информации, обучились как человек. И стали ставить диагнозы, причем, не хуже врача. Более того, нейросети научились прогнозировать развитие заболеваний на многие годы вперед, научились предсказывать риски возникновения заболеваний в разные периоды жизни пациента. Они научились давать рекомендации, как эти риски снизить, затормозить прогрессирование заболеваний. Пациенты могут наблюдать на экране компьютера, как изменится состояние их сердечно-сосудистой системы через 5, 10, 15 лет, если, например, они не будут выполнять рекомендаций врача и перестанут принимать таблетки, снижающие давление, перестанут соблюдать гипохолестериновую диету, или бросят курить, или станут злоупотреблять сладким, часто пить кофе, наберут или сбросят свой вес и т.д.

Наша интеллектуальная медицинская система уже давно применяется в 4-й клинической больнице г.Перми для поддержки врачебных решений. У нее консультируются фельдшеры в подшефных этой больнице фельдшерских акушерских пунктах Пермского края, где не хватает квалифицированных врачей. Ее используют для обучения студентов в Пермском медицинском государственном университете.

Интересно, сколько стоит проконсультироваться у вашей системы?

Система консультирует бесплатно. В разное время проект по ее созданию финансировался Группой компаний ИВС, Правительством Пермского края, Российским фондом фундаментальных исследований. Совсем недавно мы подали новую заявку в Российской научный фонд. Обещаем с помощью нее получить ряд новых, неизвестных ранее, полезных медицинских знаний. У нас уже есть некоторый научный задел в этом направлении. Например, в авторитетных международных журналах мы опубликовали ряд статей, в которых утверждаем, что врачи поступают неправильно, когда дают всем подряд кардиологическим больным одни и те же рекомендации: не пить, не курить, сбивать вес, соблюдать гипохолестериновую диету, заниматься физзарядкой и т.д. Опыт же использования нашей нейросетевой системы показал, что иногда находятся такие пациенты, для которых эти общепринятые рекомендации вместо

пользы могут причинить вред. Знания, извлеченные нейронными сетями из статистической информации показывают, что эти рекомендации должны даваться сугубо индивидуально. Они должны даваться с учетом как текущего состояния организма пациента, так и с учетом индивидуальных особенностей его организма. И давать такие рекомендации может нейронная сеть.

- Медицина и искусственный интеллект шагают вперёд. Футурологи говорят, что в скором времени ИИ будут внедрять человеку непосредственно в мозг – как третье полушарие, которое заменит человеку годы обучения.

- Я занимаюсь реальными вещами. В полушариях я не специалист.

Но, пользуясь случаем, я бы хотел поделиться своими прогнозами будущего ИИ. К сожалению, они не такие радужные, как у нынешних футурологов. Я опасаюсь, что с ИИ произойдет то, что уже не раз с ним происходило. А происходило то, что пики популярности уже не раз сменялись головокружительными провалами и наступала, так называемая «Зима» искусственного интеллекта. Я боюсь, что в ближайшее время эйфория сменится разочарованием. Сейчас на разработчиков ИИ льется золотой дождь. Выделяются огромные гранты, открываются и щедро финансируются амбициозные проекты. За выполнение этих проектов, как и в прежние времена, смело берутся молодые неопытные разработчики, которые могут неверно оценить свои возможности и, как и раньше, могут не справиться с заказами. Ко мне уже приходили мои бывшие ученики с просьбой защитить их в суде. Заказчики через суд требовали вернуть аванс за невыполненные обещания.

А еще, мне жаловались руководители серьезных предприятий, что им приходится скрываться от так называемых «продавцов искусственного интеллекта». Это молодые люди, научившиеся кое-как пользоваться иностранными платформами ИИ, каких сейчас в интернете множество. Им кажется, что теперь они могут решить все мировые проблемы. А это совсем не так.

Проблема в том, что нейронные сети унаследовали от мозга не только положительные, но и отрицательные свойства. Таким отрицательным свойством является способность нейронных сетей обманывать своих разработчиков. Создадут разработчики интеллектуальную систему, протестируют ее на тестовых примерах, получат подтверждающиеся прогнозы, сдадут заказчикам. А потом, в самый ответственный момент нейросеть вдруг такую рекомендацию выдаст, от которой станет плохо и заказчикам, и разработчикам. Чтобы этого не случалось, нужно глубоко разбираться в теории и иметь большой практический опыт.

С другой стороны, сегодняшние успехи искусственного интеллекта налицо. Изобретение нейронных сетей сверточного типа открыло действительно фантастические возможности обработки видеоизображений. Стала возможной работа с большими объёмами данных.

Но, дальнейшие успехи ИИ я вижу не в этом. Я их вижу в применении нейросетевых технологий именно для научных целей. Почему-то современные ученые как-то мало обращают внимание на одно из самых замечательных

свойств нейронных сетей – способность извлекать новые знания, получать новые закономерности, открывать новые законы природы и общества. Это свойство нейронные сети унаследовали от мозга. Они ведь выполнены «по образу и подобию» мозга, и они унаследовали от своего прототипа много свойств, причем, как полезных, так и вредных. О вредных я уже говорил.

Так вот, научив студентов создавать нейронные сети, я обычно даю им такое задание: Открыть заново теорему Пифагора, открыть заново закон Архимеда, открыть все законы Ньютона. И студенты с этими заданиями, как правило, справляются. Они, вырезают из бумаги прямоугольные треугольники разной формы, измеряют катеты и гипotenузу и скармливают эту информацию нейронным сетям. И нейросети повторяют подвиг великого геометра древности. Они делают научное открытие, выдают известный всем со школы результат: «Квадрат гипotenузы равен сумме квадратов катетов». И так нейронные сети поступает со всеми известными законами природы, которые студенты изучали в школе. Они их открывают заново.

Но раз так, значит, нейронные сети можно использовать для открытия не только известных, но и неизвестных законов и закономерностей, например – медицинских, о которых я уже говорил. Их можно использовать для познания Мира. И не только Мира, но и для познания самих себя – Человека, для познания законов развития Общества, Галактики, Вселенной.

Именно в этом я вижу главный, еще пока не раскрытый потенциал искусственного интеллекта, который обязательно будет раскрыт в будущем.

- Сейчас много говорят о необходимости преподавания ИИ в вузах, о необходимости применения новых методов его преподавания. В чем состоит инновационность именно вашего метода преподавания ИИ?

- Инновационность моего метода преподавания ИИ, во-первых, состоит в том, что я не жалею времени на подробные рассказы о своем собственном опыте выполнения проектов, причем, не только о положительном, но и об отрицательном. Рассказываю об истории ИИ, причем не только об успехах, но и о заблуждениях, о проблемах и трудностях, научных тупиках и о способах их преодоления. Рассказываю о своих ошибках, и об ошибках коллег.

Познакомив студентов с теоретическими основами и инструментами создания интеллектуальных систем, каждому студенту даю задание – исходя из своих личных интересов и увлечений, придумать тему самостоятельной работы и применить свои знания и навыки для создания интеллектуальной системы в любой выбранной студентом предметной области.

Каждый год мы проводим Всероссийскую научно-практическую конференцию «ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В РЕШЕНИИ АКТУАЛЬНЫХ СОЦИАЛЬНЫХ И ЭКОНОМИЧЕСКИХ ПРОБЛЕМ XXI ВЕКА». Тезисы докладов публикуем в сборниках материалов конференций. Обычно, наполовину эти сборники состоят из результатов выполнения этих самых самостоятельных работ наших студентов. Здесь можно встретить результаты применения методов ИИ в медицине, экономике, экологии, промышленности, психологии, социологии, спорте и т.д. И, обратите внимание, практически в каждой из этих студенческих статей проведено исследование

моделируемой предметной области, выявлены и изображены графически какие-то новые, ранее неизвестные закономерности, зависимости одних параметров от других, позволяющие лучше понимать природу изучаемых явлений и процессов, а иногда и давать полезные практические рекомендации. Как я уже говорил, некоторые из этих самостоятельных студенческих работ имеют продолжение в виде курсовых, дипломных, магистерских, кандидатских и даже докторских диссертаций, становятся предметом для публикации серьезных научных статей в международных высокорейтинговых журналах, дают начало новым бизнесам [1].

Библиографический список

1. Ясницкий Л.Н. Развитие научной школы искусственного интеллекта в пермских университетах: история и научный приоритет (обзорная статья) // Прикладная математика и вопросы управления. 2018. № 4. С. 99-130. DOI: 10.15593/2499-9873/2018.4.06.
<https://cloud.mail.ru/public/Cj62/Cxa6xf3EL>

EXPERIENCE IN TEACHING AND DEVELOPMENT OF ARTIFICIAL INTELLIGENCE AT PERM UNIVERSITY: 1998 – 2021

Yasnitsky Leonid N.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990, yasn@psu.ru

Interview of L.N. Yasnitsky, correspondent of the newspaper AiF Natalia Sterledeva. With minor changes, this is an interview published in the newspaper «Argumenty i Fakty. Prikamye» No. 38, 2021.

Key words: artificial intelligence, pseudoscience, neural network technologies, teaching, innovation, scientific priority.

ОПЫТ ПРЕПОДАВАНИЯ ТЕРАПИИ В МЕДИЦИНСКОМ ВУЗЕ С ИСПОЛЬЗОВАНИЕМ МЕТОДОВ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА

Думлер Андрей Артурович

Пермский государственный медицинский университет им. академика
Е.А. Вагнера, 614000, Россия, г. Пермь, Петропавловская, д. 26,
ivan.ivanovskii.2000@mail.ru

Черепанов Федор Михайлович

Пермский государственный гуманитарно-педагогический университет,
614000, Россия, г. Пермь, ул. Пушкина, 42, fe-c@yandex.ru

Утева Наталья Анатольевна

Пермский государственный медицинский университет им. академика
Е.А. Вагнера, 614000, Россия, г. Пермь, Петропавловская, д. 26,
nat.utewa@yandex.ru

В статье описан опыт разработки и применения нейросетевой системы для изучения одной из актуальных проблем внутренней медицины в медицинском вузе в условиях дистанционного обучения во время пандемии COVID-19.

Ключевые слова: дистанционное образование, симулированный пациент, острый коронарный синдром, нейронная сеть.

В обучении студентов медицинских вузов непосредственное общение с больным всегда было ключевым моментом. В процессе общения с пациентом формируется так называемое «клиническое мышление», т.е. способность рационально сгруппировать жалобы больного, историю развития настоящего заболевания и факторы, этому заболеванию способствующие. Однако в условиях пандемии COVID-19 эта отработанная веками система оказалась разрушена. Допуск студентов (как возможных переносчиков инфекции) к пациентам соматического профиля оказался ограничен, все обучение происходит в дистанционной форме. В условиях дистанта на первый план выходят работы с симуляками в специализированных центрах, количество которых также ограничено. С целью преодоления указанных трудностей использован ресурс KardioNet, разработанный под руководством Л.Н.Ясницкого [1, 2].

Приоритетом в обучении студентов лечебного факультета Пермского медицинского университета мы выбрали обучение на «симулированном кардиологическом пациенте» с острым коронарным синдромом (ОКС). ОКС – термин, обозначающий любую группу признаков и симптомов, позволяющих

подозревать инфаркт миокарда (ИМ) или нестабильную стенокардию (НС) с высоким риском развития ИМ [3]. ОКС является непосредственной угрозой жизни пациента и повод для его немедленной госпитализации. Ежегодно до 2,5 миллионов пациентов в мире госпитализируются с этим диагнозом. В индустриально развитых странах заболеваемость ОКС составляет 6 на 10000 населения [4].

На сайте Пермского отделения Научного совета РАН по методологии искусственного интеллекта (www.PermAi.ru) в разделе «Проекты» размещен демонстрационный прототип интеллектуальной системы диагностики и прогнозирования развития сердечно-сосудистых заболеваний человека [5, 6].

Работа с системой осуществляется в три этапа.

На первом этапе запускается нейронная сеть, выполняющая «Самостоятельное обследование» клиента, предназначенная для пользователя, не имеющего медицинского образования. В меню «Общие сведения» и «История жизни» пользователю предлагается ввести 27 параметров, характеризующих его дату рождения, возраст, пол, рост, вес, группу крови, наличие вредных привычек (курение, употребление алкоголя, наркотиков), занятие физкультурой, сведения о ранее перенесенных заболеваниях, сведения о наличии заболеваний у родственников, жалобы и т.д. На основании этих данных система ставит предварительный диагноз в виде гистограммы из семи столбцов, высота каждого из которых отражает вероятность (или степень развития) соответствующего заболевания сердечно-сосудистой системы: инфаркт миокарда, стенокардия стабильная, стенокардия нестабильная, гипертоническая болезнь, аритмии и блокады сердца, хроническая сердечная недостаточность, острые сердечные недостаточности.

На втором этапе с помощью пункта меню: «Первичное обследование» пользователю предлагается ввести дополнительно еще 22 параметра: пальпация пульса, артериальное давление, наличие ожирения, окраска кожных покровов, данные электрокардиографии и т.д., после чего система выставляет уточненный диагноз, учитывающий эти дополнительные сведения.

На третьем этапе с помощью пункта меню «Специальное обследование» пользователю предлагается ввести еще 20 параметров, с результатами эхокардиографии, общего и биохимического анализа крови. Таким образом, окончательный диагноз система выставляет с учетом 69 параметров пациента.

Интеллектуальная система является математической моделью изучаемой предметной области – человека с его комплексом сердечно-сосудистых заболеваний. Поэтому, в пределах математической погрешности, математическая модель ведет себя так же, как вела бы себя сама моделируемая предметная область. Поэтому разработанную математическую модель можно использовать для исследования закономерностей предметной области. Например, изменяя какой-либо один или несколько входных параметров (возраст, вес, привычки и др.) наблюдать за поведением выходных параметров – степенью развития заболеваний.

Этот метод исследования математических моделей называется «методом замораживания» [7, 8], поскольку все остальные входные параметры,

характеризующие человека и его состояния здоровья в процессе компьютерного эксперимента остаются неизменными. Метод замораживания имеет недостаток, заключающийся в том, что в действительности, входные параметры системы обычно имеют между собой сложные корреляционные взаимозависимости, и при изменении одного из входных параметров другие параметры тоже должны быть изменены согласно этим зависимостям. Например, с возрастом появляются новые симптомы, изменения на электрокардиограмме, результаты эхокардиографии и т.д. Но такие зависимости заранее неизвестны. Поэтому, при создании нейросетевых моделей, предназначенных для исследования предметных областей с целью получения новых знаний, рекомендуется [7, 8] использовать минимальное количество входных параметров, оставляя остальные входные параметры «за кадром», т.е. не ограничивая их изменение. Иногда, при умелом подборе минимального количества входных параметров удается добиться относительно высокой точности диагностики. Например, на первом этапе работы предлагаемой интеллектуальной системы, используя только такие первоначальные сведения о пациенте, как дата рождения, возраст, пол, рост, вес, группа крови, наличие вредных привычек, занятие физкультурой, сведения о ранее перенесенных заболеваниях, сведения о наличии заболеваний у родственников, минимальное количество жалоб, нейронные сети прогнозируют вероятность наличия (или степени развития) заболеваний с погрешностью 15 – 20%. Поэтому, для исследования закономерностей моделируемой предметной области были выбраны нейронные сети именно первого этапа предлагаемой интеллектуальной системы.

Система была обучена на примере 1200 пациентов с ОКС, находящихся на лечении в Отделении неотложной кардиологии ГАУЗ ПК ГКБ№4 г.Перми. Диагноз каждого пациента был верифицирован всеми вышеперечисленными методами. В обучающее множество вошли пациенты с ИМ (различных клинических форм и локализаций) и НС. Перед нейросетевым анкетированием каждый пациент дал информированное согласие на исследование.

Для серии компьютерных экспериментов были выбраны 100 больных, перенесших ОКС, диагноз которых был впоследствии конкретизирован. 50 пациентов страдали ИМ, 50 – НС. Нами была запущена нейронная сеть, выполняющая «Самостоятельное обследование» клиента, из расчета, что им будет пользоваться студент 3 курса, не обученный навыкам работы с инструментальными методами исследования.

В результате изучения нейросети, выявлена средняя степень точности постановки. Выяснилось, что данная интеллектуальная сеть достаточно эффективна в выявлении инфаркта миокарда – 87,0%. Хуже выявлялась стенокардия нестабильная – 64,5%. Фоновое заболевание – гипертоническая болезнь – 74,2%. Осложнение ИМ – острая левожелудочковая недостаточность подтверждена в 74,2%. За 100 процентный результат принято заключение врача-эксперта, подкрепленное лабораторными и инструментальными методами обследования. Параллельно с этим студенты получили представления о возможных факторах риска, влияющих на развитие ОКС (курение, ожирение, сахарный диабет и т.д.). Итоговое тестирование студентов по диагностике ОКС

выявило достаточно высокий (90 и более процентов правильных ответов) уровень усвоенного материала.

Заключение. Приведенные результаты компьютерных экспериментов позволяют нам рекомендовать нейросеть в варианте «Первичное обследование» для дистанционного обучения студентов медицинского вуза в условиях отсутствия возможности контакта с реальными пациентами. Предлагается расширить перечень изучаемых таким образом заболеваний, а методику внедрить в практику работы медицинских вузов страны.

Библиографический список

1. Ясницкий Л.Н., Думлер А.А., Полещук А.Н., Богданов К.В., Черепанов Ф.М. Нейросетевая система экспресс-диагностики сердечно-сосудистых заболеваний // Пермский медицинский журнал. 2011. Т. 28. № 4. С. 77-86.
2. Yasnitsky L.N., Dumler A.A., Poleschuk A.N., Bogdanov C.V., Cherepanov F.M. Artificial Neural Networks for Obtaining New Medical Knowledge: Diagnostics and Prediction of Cardiovascular Disease Progression // Biology and Medicine 2015. 7(2): BM-095-15, 8 pages.
http://www.biolmedonline.com/Articles/Vol7_2_2015/BM-095-15_Artificial-Neural-Networks-for-Obtaining-New-Medical-Knowledge-Diagnostics-and-Prediction-of-Cardiovascular-Disease-Progr.pdf.
3. Кардиология: национальное руководство/ под ред. Ю.Н.Беленкова, Р.Г.Оганова. – М, : ГЭОТАР-Медиа, 2011. – 1232 с.
4. Приказ МЗ РФ от 01.07.2015 405 ан
5. Yasnitsky L.N., Dumler A.A., Bogdanov K.V., Poleschuk A.N., Cherepanov F.M., Makurina T.V., Chugaynov S.V. Diagnosis and Prognosis of Cardiovascular Diseases on the Basis of Neural Networks // Biomedical Engineering. 2013. Vol. 47. No 3. Pp. 160-163. DOI: 10.1007/s10527-013-9359-0.
6. Yasnitsky L.N., Dumler A., Cherepanov F.M. The capabilities of artificial intelligence to simulate the emergence and development of diseases, optimize prevention and treatment thereof, and identify new medical knowledge // Journal of Pharmaceutical Sciences and Research. 2018. T. 10. № 9. С. 2192-2200.
7. Yasnitsky L.N., Dumler A.A., Cherepanov F.M. Dynamic artificial neural networks as basis for medicine revolution // Advances in Intelligent Systems and Computing. 2018. V. 850. Pp. 351-358.
8. Ясницкий Л.Н. Нейронные сети – инструмент для получения новых знаний: успехи, проблемы, перспективы // Нейрокомпьютеры: разработка, применение. 2015. № 5. С. 48-56.

**EXPERIENCE OF APPLICATION OF NEURAL NETWORK
TECHNOLOGIES IN THE TEACHING OF THERAPY AT A MEDICAL
UNIVERSITY IN THE CONDITIONS OF DISTANCE LEARNING**

Dumler Andrey A.

Perm State Medical University n. a. academician E.A.Wagner
614000, Russia, Perm, Petropavlovskaya, d. 26, ivan.ivanovskii.2000@mail.ru

Cherepanov Fyodor M.

Perm State Humanitarian-Pedagogical University,
614000, Russia, Perm, Pushkin str, 42, fe-c@yandex.ru

Uteva Natalya A.

Perm State Medical University n. a. academician E.A.Wagner
614000, Russia, Perm, Petropavlovskaya, d. 26, ivan.ivanovskii.2000@mail.ru
nat.utewa@yandex.ru

The article describes the experience of developing and using a neural network system to study one of the urgent problems of internal medicine in a medical university in the context of distance learning during the COVID-19 pandemic.

Keywords: distance education, simulated patient, acute coronary syndrome, neural network.

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ И ФИЛОСОФИЯ

БАЗОВЫЕ ПОНЯТИЯ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА В ФОРМЕ ТЕЗАУРУСА

Чечкин Александр Витальевич

Военная академия РВСН имени Петра Великого,
Финансовый университет при правительстве РФ

AVChechkin@fa.ru

В краткой форме излагаются основные понятия искусственного интеллекта с обоснованием логической последовательности их роли и необходимости в искусственном интеллекте. Большое внимание в тезаурусе уделяется таким понятиям как вторая сигнальная система, языковый сенсориум, ультрасистема, которые определяют интеллектуальное развитие умной системы и когнитивные свойства умной системы. Обосновывается роль нештатности для умной системы как точек роста ее интеллектуального развития.

Ключевые слова: Группировки умных систем, принцип единонаучания группировок, тезис о необходимом и достаточном условиях наличия искусственного интеллекта в умной технической системе, избыточные системы в форме среды радикалов, ультрасистема, нештатные ситуации и задачи, информационно-системная безопасность умных систем

Предлагается обсуждать искусственный интеллект (ИИ) в единстве с естественным интеллектом (ЕИ) человека и обязательно с точки зрения ноосферы Земли в смысле академика В.И. Вернадского.

1. Группировки умных систем. Среди искусственных технических систем базовое значение сегодня приобретают группировки умных систем (УС), подчиненные человеку. Умные системы (УС) – это высокоорганизованные целенаправленные технические системы различного назначения с элементами ИИ. В первую очередь это – группировки разнообразных беспилотников военного и гражданского назначения. Это – умные города и умные светофоры. Это – умные транспортные сети и умные сенсорные сети. Умные производства и умные дома. Такие группировки УС относятся к многоагентным системам, к которым относятся любые организационные системы.

2. Принцип единонаучания группировки УС. Для всякой технической УС – участника группировки – должен быть единственный лидер с бесприкословным ему подчинением со стороны данной УС. Без лидера техническая УС не должна функционировать. Лидер всей группировки УС всегда является человек. Цели и задачи, поставленные лидером перед УС являются целеуказаниями для данной УС в рамках ее театра действий и бесприкословными, непререкаемыми, обязательными к исполнению, к их

выполнению. Лидер формулирует и контролирует исполнение своих целевых указаний для подчиненной УС, которые всегда определяют верхнюю часть дерева целей УС. При этом каждая подчиненная техническая УС в группировке автономно планирует свою тактическую и оперативную части своего дерева целей при реализации целеуказаний от своего лидера в рамках всего своего театра действий.

3. Тезис о необходимом и достаточном условиях наличия ИИ УС.

Необходимым условием ИИ УС является наличие в УС первой сигнальной системы в форме первичного сенсориума УС. Предназначением такой системы является сбор сенсорных образов УС о себе и о театре своих действий, создание в УС и поддержание избыточного информационного ресурса сенсорных (образных) моделей в результате постоянного широкого мониторинга всего своего театра действий УС, включая саму УС;

Достаточным условием ИИ УС является наличие в УС второй сигнальной системы в форме языкового сенсориума УС. Такая система является языковой надстройкой над первичным сенсориумом УС. Назначением языковой надстройки является создание в УС языкового дубликата выделенной части первичного сенсориума путем символьной номинации (выделения) словами и устойчивыми словосочетаниями языка некоторых образных моделей первичного сенсориума. В результате появления в УС языка происходит выделение осознанной части первичного сенсориума. Далее языковый сенсориум обеспечивает бурное структурирование и развитие как самого языка так и бурного когнитивного изучения осознанной части первичного сенсориума в УС в форме избыточного информационно-системного языкового ресурса для интеллектуального планирования и ситуационного управления своим поведением в рамках своего театра действий во исполнение целевых указаний лидера группировки.

4. Избыточные системы в форме среды радикалов. Для адекватного описания избыточных систем базовым понятием является радикал (корень) – функциональная система любого назначения, имеющая внешнедоступную возможность переключения своего состояния в любое из двух своих состояний, пассивное и активное. Активный радикал функционирует, работает по своему назначению. Пассивный радикал не функционирует, не работает по своему назначению, но находится в готовности, в резерве, в ожидании своего активирования. Избыточная система – это система с информационно-системным ресурсом превосходящим тот ресурс, который требуется здесь и сейчас для любых конкретных ситуаций ее функционирования. Примерами избыточных систем являются первичный и языковый сенсориум УС, сервисные системы, большие данные, инструментальные системы и многие другие системы. Все избыточные системы должны иметь форму среды радикалов, т.е. быть радикальными системами. Всякая радикальная система требует своей активирующей подсистемы управления процессом активации тех или иных радикалов системы. Главная особенность радикальной системы возможность в любой момент активировать только часть своих радикалов. Все активные в данный момент радикалы образуют работающий системоквант или активную

часть радикальной системы. Каждый раз системоквант радикальной системы участвует в выполнении очередного поведенческого (рабочего) акта умной системы. При этом все остальные пассивные радикалы избыточной системы определяют потенциальные возможности радикальной системы и находятся в ожидании, в запасе, в резерве.

5. Информационно-системная безопасность (ИСБ) каждой УС – участника группировки. Все когнитивные требования к ИИ УС объединим в одном едином обобщенном глобальном требовании: «Обеспечения информационно – системной безопасности УС». Требование ИСБ УС обеспечивает и реализует целевую установку лидера данной УС. Понятие ИСБ УС является глобальным двуединым требованием, которое имеет тесно связанные между собой две стороны безопасности, информационную и системную. ИСБ УС включает в себя все частные случаи безопасности УС от экологической, энергетической и т.д. до функциональной безопасности. Сформулируем обе стороны требования ИСБ УС.

Информационная сторона ИСБ УС. Каждая задача жизненного цикла УС, включая целевые, сенсорные и сертификационные задачи, должна быть безусловно и эффективно решена, независимо от формы и полноты оперативной информации, от наличия помех, путем создания и логической обработки избыточной модели театра действий УС (элементарного сенсориума широкой проблемной области УС), включающей в частности модель самой УС, модель театра действий УС. Избыточная модель является необходимым условием обеспечения решаемой штатной задачи и достаточным информационным и системным ресурсом для ее решения. Она должна быть надежно защищена от несанкционированного доступа (НСД) и т.п.

Каждая задача жизненного цикла УС должна быть в центре внимания УС, исследована на необходимость и возможность ее решения с согласия лидера в рамках его идеологии, мировозрения и стратегических целей. При этом УС может использовать ресурсы избыточной модели, или воспользоваться запросами к глобальному информационно-системному (виртуальному) пространству за обновлениями, или организовать попытки решения задачи в режиме «проб и ошибок», или другим каким – либо способом самообучения, развития самой УС, вплоть до преобразования своего театра действий УС с согласия своего лидера.

Системная сторона ИСБ УС. Каждая задача жизненного цикла УС, в процессе своего решения, должна сопровождаться постоянным учетом всех последствий решения для самой УС и для театра ее действий путем постоянного сертифицирования избыточной модели, тестирования самой УС, анализа театра действий УС и устранения конфликтов для сохранения системной целостности, гомеостаза самой УС и театра ее действий в полном соответствии с целевыми указаниями лидера УС.

6. Ультрасистема УС. В каждой технической УС можно выделить ее специфическую информационную подсистему, которую называют ультрасистемой обеспечения ИСБ УС, рис. 1.

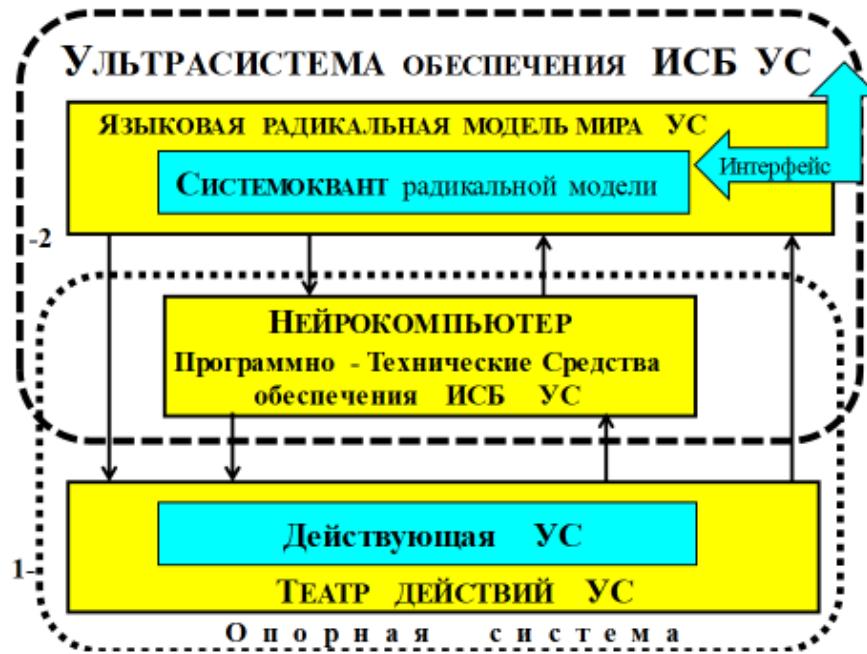


Рисунок 1. Ультрасистема обеспечения ИСБ УС

Ультрасистема для УС подобна центральной нервной системе ЕИ человека. Она предназначена для сбора, хранения, преобразования и использования информации о самой «Я-УС», а так же об объектах и связях своего театра действий. Ультрасистема УС определяет интеллектуальные свойства УС и является многоуровневой информационной подсистемой УС. Ультрасистема УС на каждом своем иерархическом уровне является радикальной системой и находится в режиме ускоряющегося интеллектуального развития.

7. Этапы интеллектуального развития ультрасистемы УС. Первый этап связан с проблемами развития первичного сенсориума УС, с проблемами технического зрения, ориентации в пространстве, акустических и других сенсорных сетей, проблемами сбора и хранения больших массивов метрологических измерений. Первичный сенсориум УС является первым уровнем ультрасистемы УС. Этот уровень является подсознательным, еще не осознанным УС. **Второй этап** интеллектуального развития УС связан с проблемами выделения в первичном сенсориуме главных, доминирующих для УС объектов и отношений путем их номинирования, присвоения каждому из них языкового индивидуального символа. На этом этапе в ультрасистеме появляется вторая сигнальная система УС, язык УС. В ультрасистеме УС возникает второй иерархический уровень, языковый сенсориум. В результате чего в УС появляется выделенная осознанная часть первичного сенсориума, номинированная языковыми символами. Языковый сенсориум УС теперь умозрительно позволяет самой УС глубоко изучать и структурировать осознанную часть первичного сенсориума когнитивными (умственными) технологиями. Затем наступает **третий этап** развития УС. Интеллектуализация УС ускоряется и, появляется очередной третий иерархический уровень ультрасистемы УС – это языковая координатная семантическая опорная сеть понятий (лексика). Далее в УС

происходят два взаимодополняющих друг друга новых этапа, развиваются два новых иерархических уровня, **четвертый и пятый**, над опорной сетью пянятий. **Четвертый этап** – это ультрамножественное оснащение координатной сети понятий до формы распределенной базы данных (БД) осознанной части первичного сенсориума. На этом четвертом этапе решаются проблемы создания локальных баз данных (ЛБД) и структурирования больших данных в распределенную БД УС. **Пятый этап** развития УС – это ультраоператорное оснащение координатной сети понятий до формы распределенной базы знаний (БЗ) осознанной части первичного сенсориума. На этом пятом этапе решаются проблемы создания локальных баз знаний (ЛБЗ) на базе технологий машинного обучения, прогнозирования и принятия решений в рамках распределенного информационно-системного ресурса УС в форме среды радикалов-ЛБД и -ЛБЗ. В результате в ультрасистеме УС на пятом уровне формируется и бурно развивается языковая единая модель мира УС в форме информационно-системной распределенной БД УС и БЗ УС осознанной части самой УС и осознанной части театра действий УС. Наконец на последнем **шестом** этапе в УС появляются «элементы ИИ» УС. Шестой когнитивный иерархический уровень ультрасистемы УС – это языковая, операционная система интеллектуального планирования и ситуационного управления поведением УС в рамках своего театра действий с условием обязательного и эффективного выполнения своих целевых указаний со стороны лидера. Ультрасистема УС на своем когнитивном, верхнем, шестом уровне отвечает за активирование системоквантов управления поведением УС в рамках своего театра действий.

8. Три одновременных процесса в ультрасистеме УС. С учетом имеющегося избыточного информационно-системного ресурса УС языковая операционная система планирования и управления поведением УС в рамках распределенной радикальной БД и БЗ модели УС осуществляет одновременно три следующих информационных процесса: текущий целевой – решение очередной тактической задачи во исполнение целевого указания лидера по принципу «целесообразность поведения УС», текущий сенсорный – непрерывный сбор ситуационной информации по принципу «здесь и сейчас» и коммуникационному принципу «что нового появилось в глобальном виртуальном информационно-системном пространстве», текущий сертификационный процесс – обеспечение целостности, гомеостаза УС и всего театра действий УС по принципу «закрывание гештальта», рис. 2.

Три одновременных процесса в ИИ УС

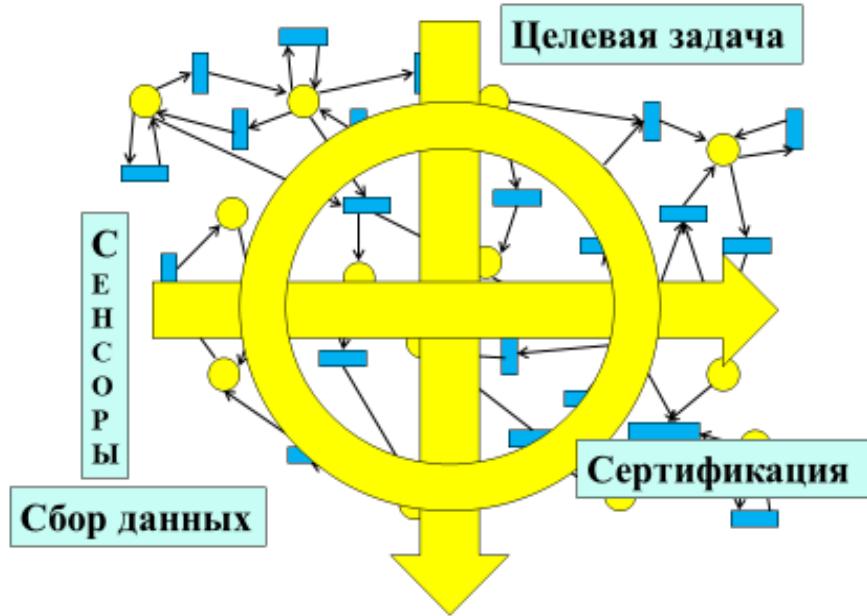


Рисунок 2. Активационные процессы в языковой радикальной единой модели мира УС: целевой, сенсорный и сертификационный

При проведении текущих сертификационных проверок первостепенное значение имеет главная для ИИ УС и для всей группировки сверхзадача – определение нештатности ситуаций и задач.

Рекомендации. 1. При выполнении текущего целевого процесса в УС должен проводиться постоянный мониторинг на появление в УС и в театре его действий новых конфликтов по принципу «не навреди себе». Организация устранения этих конфликтов.

2. При проведении текущего сенсорного процесса в УС и в театре ее действий должны во время вноситься и учитываться изменения ситуационных изменений в единую модель УС.

3. Особое внимание в группировке УС надо уделять восстановлению целостности систем, требуется следить за состоянием «в норме» всех необходимых для эффективного штатного поведения УС группировок се

9. Штатные и нештатные ситуации и задачи группировки УС. При этом в процессе своего функционирования и в рамках сертификационных задач УС постоянно решает свою принципиальную сверхзадачу оценивания ситуаций и задач на их штатность и нештатность для данной УС. В случае штатности всех ситуаций и задач УС функционирует в штатном режиме. Нештатные ситуации и задачи для УС являются основными точками роста, обновления, развития УС и преобразования театра действий УС.

Штатные ситуации и задачи УС – это ситуации и задачи, регламентированные тактико – техническими требованиями к УС. Штатные ситуации и задачи – массовые и типовые для УС. Они должны быть хорошо изучены, заранее определенные и формализованные в единой радикальной

модели УС. В языковой радикальной модели УС для всех штатных задач должны быть заранее разработаны и представлены устойчивые методы, конструктивные алгоритмы и эффективные программно – технические средства (ПТС) их решения на разных этапах жизненного цикла УС. Следует отметить, что именно к штатным задачам УС в первую очередь предъявляются требования оперативного их решения с минимальными ресурсозатратами. Для штатных задач фактор времени и фактор малозатратности самые важные. Штатные ситуации и задачи должны быть заранее формализованы и оптимизированы по сложности, ресурсоемкости, быстродействию. Решение штатных задач должно быть доведено до навыков, до «автоматизма», до «решения с закрытыми глазами», т.е. методы их решения не должны постоянно требовать модификации и трудоемкой настройки этих методов при применении.

Нештатные ситуации и задачи УС – это ситуации и задачи, нерегламентированные для данной УС, непредставленные заранее в радикальной единой модели данной УС. Для таких ситуаций и задач в радикальной модели УС нет готовых описаний, методов и тем более нет готовых алгоритмов и программно – технических средств их решения. В рамках кибернетических (автоматных) систем, которые функционируют по заранее предусмотренным в них алгоритмам, нештатные задачи не относятся к области определения этих автоматов. Нештатные задачи автоматами не могут быть решены. Однако для умных (интеллектуальных) поведенческих систем, к которым относятся УС со специальной ультрасистемой интеллектуального планирования и ситуационного управления в рамках ИИ УС, некоторые нештатные задачи решаются. Это происходит благодаря избыточности среды радикалов и когнитивности ее специализированного оснащения. При этом степень интеллектуальности языковой надстройки ИИ УС определяется именно теми нештатными задачами для данной УС, которые эта надстройка сможет преодолеть. В каждом случае нештатности УС предпринимает максимальные усилия для преодоления нештатности. Эти усилия могут быть обращением с запросом к другим агентам группировки или к лидеру, или запросом к поисковой системе к виртуальному информационному пространству, или к системе машинного обучения, или приступить к режиму самообучения, с согласия своего лидера. В случае успешного преодоления нештатности ситуацию или задачу переводят в класс штатных ресурсов УС. В этом случае ИИ УС обновляется, обучается, расширяет класс своих штатных ситуаций, задач и средств их решения. В результате функционирования УС в нештатных ситуациях происходит саморазвитие УС и целенаправленное преобразование, с согласия своего лидера, театра действий УС.

Подчеркнем, что в случае нештатных ситуаций и нештатных задач важно учитывать для УС фактор риска, связанный с неизвестностью последствий такого решения. Это отличает нештатные ситуации и задачи от штатных ситуаций и задач, для которых на первом месте для УС выступает фактор времени и ресурсозатратности. Поэтому при попытках учесть нештатные ситуации или решать нештатные задачи в УС должен быть предусмотрен анализ

рисков в рамках ее радикальной модели, учет результатов проведенных попыток, так называемый, режим самообучения.

В свою очередь удобно класс нештатных ситуаций и задач разбить как минимум на следующие два подкласса, а именно – слабо нештатные и сильно нештатные ситуации и задачи. К слабо нештатным ситуациям и задачам для данной УС отнести ситуации и задачи с частными (небольшими) отклонениями от штатных ситуаций и задач для УС. Например, когда появляются нештатные элементы в штатных ситуациях или нештатные ограничения в штатной задаче и др. Слабо нештатные ситуации и задачи требуют модификации известных подходов и методов. Например, к слабо нештатным задачам отнесем штатные задачи с неполной исходной информацией, или штатные задачи с малой устойчивостью решения, или штатные задачи с неприемлемо высокой сложностью имеющихся алгоритмов их решения и многие другие. Все остальные нештатные ситуации и задачи для данной УС отнесем к сильно нештатным ситуациям и задачам этой УС.

Сильно нештатной ситуацией или задачей является новая, во многом неизвестная для ИИ УС ситуация или задача, требующие разработки принципиально нового подхода, модели, нового математического аппарата, нового метода. Сильно нештатная задача обычно требует не только нового метода и алгоритма, но еще разработки новых программно – технических средств реализации ее решения, ее верификации и т.д.

10. Необходимость нейрокомпьютера для ультрасистемы УС. Обсудим программно-технические средства (ПТС) ультрасистемы ИИ УС. В вычислительной технике различают два принципиально отличных друг от друга типа процессоров, к которым относятся аналоговые и цифровые. Аналоговый процессор (нейросетевой, квантовый и др.), использует интерференцию физических полей. Он используется в первичном сенсориуме в следящих системах и ориентирован на максимальное распараллеливание вычислительного процесса, а, тем самым, на максимальную его оперативность. Техническая и программная реализация решения задач при использовании аналоговых процессоров опирается на базис, который называют нейросетевым. Именно в этом базисе, например, с большой эффективностью и оперативностью можно решать задачи распознавания образов, задачи экспресс-анализа, многие прямые задачи. Часто аналоговые процессоры являются базовыми в следящих системах управления.

В отличии от аналогового, цифровой процессор сегодня использует позиционную систему записи чисел, последовательный вычислительный процесс, который опирается на базис, который будем называть логическим. Логический базис

Цифровой процессор архитектуры Дж. Фон Неймана основан на использовании линейной позиционной системы записи чисел и требует реализации (методологии) последовательной обработки информации, которая базируется на логическом базисе. Напомним, что основная операция в цифровом процессоре, суммирование чисел, происходит исключительно последовательно от меньших разрядов к старшим, с прерыванием и задержкой.

В логическом базисе цифрового процессора более эффективно решаются задачи языкового сенсориума, требующие учета и анализа рисков неблагоприятных последствий. К числу таких задач относятся, например, задачи принятия решений, задачи синтеза, обратные задачи, алгоритмически неразрешимые задачи и др.

Дуализм нейрокомпьютера. Двухкорневой термин нейрокомпьютер (НК), своим названием подчеркивает необходимый дуализм нейрокомпьютерной реализации радикальной модели УС в форме среды радикалов, рис.3.

Дуализм Нейро Компьютера	
Параллельная обработка (Нейро - от фактов)	Последовательная обработка (Комп - от цели)
1. Образная обработка (аналоговая)	1. Логическая обработка (цифровая)
2. Процессор архитектуры нейросеть	2. Процессор архитектуры Ф. Неймана
3. Ситуационная активация	3. Целенаправленная активация
4. Задачи анализа (прямые)	4. Задачи синтеза (обратные)
5. Сертификация радикалов	5. Снятие конфликтов в модели
6. Штатные задачи, следящие систем.	6. Нештатные задачи, обучающие сист.
7. Рефлексы, физиология	7. Принятие решений, психология
Нейрокомпьютер - распределенная вычислительная среда, использующая два типа обработки информации	

Рисунок 3. Аналоговый (нейросетевой) и цифровой (логический) базисы нейрокомпьютера

ПТС УС должно в перспективе быть устроено по типу распределенной вычислительной среды, образованной двумя видами процессоров аналоговыми (Нейро) и цифровыми (Комп). В перспективе, именно нейрокомпьютеры, видятся той распределенной вычислительной средой, которая базируется одновременно на двух типах процессоров. С одной стороны, такая среда имеет возможности нейросетевого базиса, на аналоговых процессорах, т.е. на нейросетевых или квантовых процессорах, обслуживая первичный сенсориум УС. С другой стороны, нейрокомпьютеры сохраняют возможности логического базиса цифровых процессоров фон – неймановского типа, которые обслуживаю языковый сенсориум УС.

Рассмотрим более подробно идею эффективного сочетания, соотношения, распределения, аппаратной координации при нейрокомпьютерной реализации решения задач на разных этапах ЖЦ УС.

1) Штатные задачи следует решать оперативно и малозатратно. В штатных задачах на первый план выступает фактор времени. Поэтому рекомендуется их решать, по возможности, максимально используя механизмы распараллеливания, т.е. решать на аналоговых процессорах, в нейросетевом базисе. На языке технической реализации информационных процессов это означает, что при решении штатных задач желателен переход от логического базиса к нейросетевому базису. Интересно, что в физиологии это соответствует переводу процессов решения штатных задач в оперативный режим рефлексов, навыков, а в технике к следящим системам, рис.3.

2) Слабо нештатные задачи рекомендуется решать в смешанном логическом и нейросетевом базисе, эффективно сочетая последовательную и параллельную обработку информации на аналоговых и цифровых процессорах. При этом рекомендуется использовать элементы режима поиска в глобальном виртуальном пространстве, или обучения с учителем, или в режиме самообучения и принципа увеличения доли параллельной обработки.

3) Сильно нештатные задачи рекомендуется решать преимущественно на цифровых процессорах, в логическом базисе, в режиме поиска Новой информации и новых системных модулей глобальном виртуальном пространстве или, обучения с учителем или, в режиме самообучения, проб и ошибок. В таких задачах на первом месте выступает фактор риска.

В дальнейшем при успешном решении нештатной задачи предполагается перевод такой задачи в класс штатных и далее организовывать максимальное распараллеливание разработанного алгоритма. Нештатные задачи являются, своего рода, точками роста, развития самой УС и преобразования театра действий УС.

- В теории алгоритмов имеются задачи алгоритмически разрешимые и неразрешимые. Для алгоритмически разрешимых задач различают три вида алгоритмов по сложности их реализации – алгоритмы степенной сложности, алгоритмы экспоненциальной сложности и задачи NP-полной сложности. Класс задач алгоритмически неразрешимых (у них нет общего алгоритма решения) относится, естественно, к сильно нештатным задачам. Класс нештатных задач, являющихся NP-полной сложности, являются, как правило, классом слабо нештатных задач.

- Обратим особое внимание на выделение программно-технических средств технической УС в нейрокомпьютер. Нейрокомпьютер особая двойственная системная сущность, ПТС УС. Она присутствует в опорной системе УС и она же в ультрасистеме обеспечения ИСБ УС, рис. 2.

- Для повышения эффективности УС важно сочетать преимущества параллельной и последовательной обработки информации, следящих (анalogовых) и логических (цифровых) процессов нейрокомпьютерной парадигмы ПТС опорной системы УС и ультрасистемы УС, рис.2.

11. Гибридный интеллект группировки УС – совместный интеллект ЕИ человека, лидера группировки и ИИ каждой УС, технического агента группировки. При этом, **ЕИ человека** отводится: системный анализ первичного и языкового сенсориума группировки, выявление и классификация нештатных

ситуаций и задач для отдельных УС группировки и нештатных конфликтов в театре действий группировки, стратегическое планирование развития группировки и преобразования театра его действий, системный синтез целеуказаний и контроль их исполнения для каждого агента, т.е. для каждой УС группировки, а так же сертификация всех систем информационно-системного ресурса всей группировки. К **автономным обязанностям каждого ИИ УС группировки** отводится сетевой сбор больших данных о каждом агенте группировки и сбор больших данных о театре действий группировки с широким использованием коммуникационных возможностей группировки, а так же постоянная сертификация всех подсистем УС.

12. Ноосфера. Глобальное интеллектуальное виртуальное информационно-системное пространство Земли

С появлением множества искусственных технических УС различного назначения и с учетом постоянного их развития возникает возможность и потребность объединять оба вида интеллекта, ИИ УС и ЕИ людей, в единое интеллектуальное пространство, в ноосферу Земли по терминологии академика В.И. Вернадского. Главное требование к такому пространству – это организация коммуникационного взаимодействия и информационно-системного обмена между техническими УС различного назначения, между техническими УС и людьми, между людьми с требованием ко всем участникам этого пространства соблюдения ИСБ каждым участником и субординаций, рис. 3. Несмотря на геополитические общеземные проблемы, элементы такого взаимодействия и обмена в настоящее время уже появились и бурно развиваются в форме интернета людей, интернета вещей (IoT) и языковых средств компьютерных интерфейсов. По-видимому, пришло время единого для техники и человека делового языка интеллектуального общения, радикального языка глобальной сетевой ноосферы Земли.

Библиографический список

1. Чечкин А.В. Тезис о наличии искусственного интеллекта. Издательство МГУ. Журнал «Интеллектуальные системы». Том 25, Выпуск 1, 2021 г., стр. 29-49.
2. Потюпкин А.Ю., Чечкин А.В. Искусственный интеллект на базе информационно – системной избыточности. Монография. – М.: КУРС, 2019, 382 с.
3. Воронков Г.С., Чечкин А.В. Проблемы моделирования сенсориума и языковой системы естественного интеллекта индивидуума. – М.: Издательство МГУ. Журнал "Интеллектуальные системы", том 2, вып. 1-4, 1997г.

BASIC CONCEPTS OF ARTIFICIAL INTELLIGENCE IN THE FORM OF THESAURUS

Chechkin Alexander V.

Military Academy of Strategic Missile Forces named after Peter the Great,
Financial University under the Government of the Russian Federation,

AVChechkin@fa.ru

In a short form, the basic concepts of artificial intelligence are presented with a justification of the logical sequence of their role and the need for artificial intelligence. Much attention in the thesaurus is paid to such concepts as the second signaling system, linguistic sensorium, ultrasystem, which determine the intellectual development of an intelligent system and the cognitive properties of an intelligent system. The role of abnormalities for an intelligent system as points of growth of its intellectual development is substantiated.

Keywords: Groupings of smart systems, the principle of one-man command of a group, the thesis about the necessary and sufficient conditions for the presence of artificial intelligence in a smart technical system, redundant systems in the form of an environment of radicals, an ultrasystem, emergency situations and tasks, information and system security of smart systems.

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ ГЛАЗАМИ ОБЫВАТЕЛЯ

Фиговский Олег Львович

International peoples alliance of the world
Европейская академия наук
Ассоциация изобретателей Израиля
figovsky@gmail.com

Гумаров Валерий Александрович

Журнал «НБИКС-Наука.Технологии»
aguma@rambler.ru

Тезисы доклада подготовлены по материалам монографии «Инновационные системы: человек и искусственный интеллект», издательство РУДН, 2020.

Изложение нашего видения места искусственного интеллекта (ИИ) в современном мире и ожиданий от присутствия ИИ в мире будущего начнем с конца. Конца книги «Инновационные системы: человек и искусственный интеллект», где сказано, что столбовая дорога создания искусственного интеллекта – не ковыряние в мозгах и не дрессировка компьютеров, а определение законов и выработка правил работы алгоритмов.

Про алгоритмы... Вспоминая Антуана де Сент-Экюпера с его «Ты навсегда в ответе за всех, кого приручил», в приложении к алгоритмам нeliшне будет добавить – «И за тех, кого создал». Создал, то, во что не сразу верится, когда видишь. Значит – можем. Можем не мы, китайцы, американцы, японцы, европейцы, а может все человечество. Может не только автоматы с ядерными боеголовками делать, а и нынешние чудеса света в виде неотличимых от творца роботов. Роботов – помощников, а не убийц. Может человечество, если захочет.

Еще бы захотеться всем нам перестать друг с другом воевать. В быту, общественной жизни, науке, политике. Сколько б умов и денег высвободилось бы на благие дела и творение чудес, а не инструментов и приспособ для битв с себе подобными.

И еще, пожалуй что надлежит напомнить – это слова советского и российского ученого, специалиста в области математического моделирования, основателя синергетического движения в России Сергея Павловича Курдюмова: «У человечества нет времени нащупывать организацию мира методом проб и ошибок... мы должны вычислять и проектировать будущее, опираясь на науку, на законы организации и самоорганизации». И тут ИИ нам – первый помощник.

А теперь немного конкретики. Что уже создано с участием ИИ и что нам представляется важным и значимым. Мы не разработчики алгоритмов, мы рядовые пользователи достижений ИИ, с большим интересом наблюдающие за новинками в этой области человеческой деятельности, ряд которых приведены в нашей книге «Инновационные системы: человек и искусственный интеллект».

Примеры из книги.

ИИ и медицина

Пришедший к нам то ли из научных лабораторий, то ли из дикой природы коронавирус сильно подстегнул работы по внедрению ИИ в медицину. Поэтому сначала несколько примеров привлечения ИИ к борьбе с пандемией COVID-19.

Быстро обучить алгоритм искусственного интеллекта помогли миллионы людей, которые ежедневно делятся данными о своем состоянии в приложении COVID Symptom Study. Благодаря им ИИ с точностью почти 80% предсказывает вероятность инфицирования COVID-19 всего по четырем симптомам. Приложение COVID Symptom Study для ежедневных отчетов людей о состоянии своего здоровья независимо от их самочувствия, разработала группа ученых из Великобритании с целью мониторинга роста заболеваемости COVID-19 в конкретных районах и городах. Пользуясь этой уникальной базой данных, ученые проследили симптомы, которые чаще всего возникали у заболевших. Они обнаружили широкий спектр симптомов, который выходил за рамки привычных признаков гриппа и ОРВИ. Команда разработала математическую модель, которая почти с 80% точностью предсказывала вероятность COVID-19, исходя из пола, возраста и четырех основных симптомов: потери обоняния или вкуса, постоянного кашля, усталости, а также периодической потери аппетита. Когда команда применила эту модель к группе из 800 тысяч пользователей со схожими симптомами, то оказалось, что в то время около 17,4% людей могли быть инфицированными.

Группа китайских исследователей совместно с компанией Tencent AI Lab решила помочь решить задачу предвидения внезапного перехода течения болезни у зараженных COVID-19 в стадию осложнения. Исследования показали, что 6,5% пациентов с COVID-19 могут внезапно перейти к серьезной стадии заболевания, и уровень смертности среди них может достигать 49%. Поэтому одной из ключевых задач для органов здравоохранения является выявление и лечение пациентов, у которых на ранних стадиях могут развиться тяжелые или смертельные синдромы. Команда ученых представила модель глубокого обучения, которая может предсказать риск развития критических заболеваний у пациентов с коронавирусом. В то время как основное внимание проекта сосредоточено на COVID-19, долгосрочная миссия лаборатории заключается в том, чтобы «использовать большие данные и ИИ для скрининга, профилактики и контроля, а также предупреждения о вспышках, респираторных заболеваниях и заболеваниях органов грудной клетки».

Саудовская немецкая больница, один из крупнейших поставщиков медицинских услуг в ОАЭ, автоматизирует свои комплексные бизнес-процессы с помощью программных ботов на базе AI, чтобы помочь улучшить обслуживание пациентов и сократить время ожидания пациентов во время

COVID-19. Программные боты предоставляются Automation Anywhere и развертываются Advansys ESC. Automation Anywhere и Advansys ESC работали совместно с саудовской немецкой больницей, чтобы определить возможности автоматизации в ее отделах страхования и финансов. Именно на эти отделы обычно уходит много человеческих ресурсов. Интеллектуальная автоматизация позволяет медицинским организациям выполнять более трудоемкие ручные задачи, освобождая персонал для лечения большего числа пациентов за счет повышения эффективности больниц. Медицинские системы, затронутые глобальной пандемией, обратили внимание, как технология автоматизации может оказать огромное влияние на прогресс в обслуживании пациента. Внедрение ботов для таких процессов, как упрощение планирования встреч с пациентами, оптимизация расчетов по счетам и управление рабочими процессами в здравоохранении поможет сэкономить время и направить его на уход за пациентом.

Эпидемии эпидемиями, но и помимо них человек подвержен большому числу заболеваний, в диагностике и лечении которых все большее участие принимает ИИ.

ИИ диагностирует деменцию по короткому разговору врача с пациентом. Японская компания Fronteo, разрабатывающая системы анализа данных, объявила о создании новой платформы на базе ИИ, которая «подслушивает» разговор между лечащим врачом и пациентом для быстрой диагностики деменции. Пятиминутного разговора достаточно, чтобы ИИ поставил диагноз с 85% точностью. Обработка полученной информации занимает всего одну минуту. Объективная диагностика деменции – это сложный процесс, точность которого зачастую зависит от квалификации врача. Специалисты из Fronteo заявляют, что новая платформа решает проблемы необъективности и может работать в паре даже с обычным терапевтом. ИИ переводит диалог в письменный текст и анализирует структуру речи пациента, указывая на незаметные, но важные детали. Затем врач проверяет расшифровку и принимает окончательное решение о постановке диагноза. Аналогичное медицинское оборудование, использующее ИИ для анализа пациентов, обычно полагается на изображения с эндоскопов, что значительно медленнее нового подхода.

Смартфон с точностью врача определит инсульт за четыре минуты. Приложение оценивает речь и мимику человека, чтобы диагностировать у него инсульт. Тяжелый инсульт несложно определить по простым симптомам, однако более легкие формы острого нарушения кровоснабжения головного мозга менее очевидны даже для врачей. К основным признакам инсульта относят спутанность сознания и речи, асимметрию мышц лица, онемение в одной части тела, внезапные нарушения слуха и зрения. Ученые решили разработать инструмент для оценки речи и мимики человека смартфоном, чтобы быстро диагностировать более легкие формы инсульта, если качественная медицинская помощь недоступна. Для обучения алгоритма ИИ использовались данные пациентов, которые обратились в отделение неотложной помощи с подозрениями на инсульт. Это важная отличительная особенность исследования, поскольку оценивались данные людей в режиме реального времени, как если бы

на пациента в то же самое время смотрел врач. Точность диагностики на основе ИИ в смартфоне составила 79%, что сопоставимо с результатами клинической диагностики врачей отделения неотложной помощи, при которой используют дополнительные инструменты, включая компьютерную томографию.

Исследователи из Университета Беркли, Intel и Google Brain научили модель ИИ оперировать, имитируя видеозаписи восьми хирургов за работой. Алгоритм под названием Motion2Vec обучили на кадрах, где медики управляют хирургическими роботами для наложения швов или завязывания узлов. Но если обычно робот управляется врачом с компьютерной консоли, то в случае Motion2Vec он делает это самостоятельно. Он уже показал свои навыки при шивании кусков ткани. В тестах система воспроизводила движения хирургов с точностью до 85,5%. Достичь такого уровня точности было непросто: восемь хирургов в видеоматериалах использовали самые разные техники, поэтому ИИ нужно было выбрать лучший вариант. Для решения этой задачи команда использовала полуавтономные алгоритмы, которые изучают задачу, анализируя частично маркированные наборы данных. Это позволило ИИ понять основные движения хирургов из небольшого количества данных.

ИИ и роботы

Робот-ученый проводит эксперименты, пока все на карантине. Ученые из Университета Ливерпуля представили своего коллегу-робота, который работал без перерыва в своей лаборатории в течение всего времени блокировки исследований из-за карантина. Программируемый исследователь стоимостью 100000 фунтов стерлингов учится на собственных результатах, чтобы усовершенствовать свои эксперименты. По словам разработчиков, такая технология может сделать научное открытие «в тысячу раз быстрее». Такие роботы могут быть по всему миру, связанные централизованным мозгом, который может быть где угодно. «Этому научному работнику не скучно, он не устает, работает круглосуточно и не нуждается в отпусках», – шутят разработчики. На более серьезной ноте ученые заявили, что робот уже изменил скорость, с которой исследователи могут проводить испытания и эксперименты. Он может легко перебрать тысячи образцов, поэтому освобождает время ученых. Они могут сосредоточиться на инновациях и новых решениях. Немаловажно и то, что такие машины могут проводить более рискованные эксперименты: в более жестких лабораторных условиях или с использованием более токсичных веществ.

Создана система навигации для роботов, основанная на здравом смысле. Разработка получила название SemExp. Она использует машинное обучение, чтобы робот мог различать объекты и предполагать, в какой части дома они, скорее всего, находятся. Это позволяет ему стратегически мыслить и выбирать наиболее здравые варианты. SemExp была представлена группой из Университета Карнеги-Меллона в США и отделом исследования искусственного интеллекта Facebook (FAIR). В ее основе лежит концепция «здравого смысла», как ее называют авторы. Суть состоит в следующем: робот, путешествующий из точки А в точку Б, более эффективен, если он понимает, что первая – это диван

в гостиной, а вторая – холодильник, даже если он находится в незнакомом месте, и оценивает, где точка Б может быть с наибольшей вероятностью. «Здравый смысл подсказывает, что если вы ищете холодильник, то вам лучше пойти на кухню, – говорит Девендра Чаплот, аспирант кафедры машинного обучения Университета Карнеги-Меллона и один из авторов исследования. – Классические роботизированные навигационные системы, напротив, исследуют пространство, создавая карту с указанием препятствий. Робот в конце концов добирается туда, куда ему нужно, но маршрут оказывается слишком длинным». Предыдущие навигационные системы, основанные на искусственном интеллекте, учили роботов запоминать объект и его конкретное расположение в пространстве. Если объект перемещали, робот продолжал искать его на старом месте, пока не привыкнет к новой обстановке. Более того, у такой системы возникали проблемы при обобщении и систематизации информации из разных помещений. Группа разработчиков решила эти трудности, сделав SemExp модульной. Алгоритм использует смысловую концепцию мышления (то есть возможность смыслообразования и целеобразования), чтобы определить лучшее место для поиска предмета.

По части симбиоза ИИ и роботов – прогноз от эксперта в области робототехники и директора Creative Machine Labs при Колумбийском университете Хода Липсона. На конференции Exponential Manufacturing Ход Липсон рассмотрел пять показательных тенденций, которые формируют и форсируют развитие будущей робототехники.

1. Улучшения в области энергопитания. Энергия, питание, электричество – необходимое условие работы робототехнических систем, поэтому улучшение топливных элементов, будь то повышенная емкость батарей или энергоэффективность, является важным двигателем прогресса в робототехнике.

2. Новые материалы. Новые материалы обладают потенциалом изменить процесс строительства роботов, а вместе с тем изменяются задачи, которые они могут выполнять.

3. Достижения в области вычислительной техники. Вычислительная техника становится меньше, проще в использовании, дешевле и доступнее. По мере того как технология становится дешевле, она также попадает в руки все более юных поколений. Кроме того, «самодельная» революция разрушает барьеры цен в традиционном производстве. Производство машин, которые когда-то стоили десятки тысяч долларов, теперь финансируется на Kickstarter и требует гораздо меньше денег.

4. Производство робототехники. Благодаря новым технологиям вроде 3D-печати, скорость производства роботов тоже растет. Компании могут печатать роботов целиком и по частям в сжатые сроки, а значит, и больше экспериментировать с новыми проектами.

5. Большие данные и алгоритмы. Хоть у индустрии робототехники появились быстрые компьютеры и сенсоры, ей не хватало правильных алгоритмов для грамотного анализа всех собранных данных. Но времена меняются. «Искусственный интеллект позволяет нам наделять роботов способностью

видеть и понимать, что происходит вокруг них», – говорит директор Creative Machine Labs.

Что все это означает для будущего производства? Ход Липсон полагает, что все вместе эти пять экспоненциальных тенденций могут преобразовать промышленные заводы целиком и полностью. Представьте себе завод, фабрику, которая управляет не отдельными роботами, а одной облачной системой, где все машины постоянно взаимодействуют, обучаются и растут как одна гибкая система, которая может учиться и автономно восстанавливаться после сбоя.

Как следует из этого небольшого обзора работ и достижений в области робототехники, роботы хоть и не без труда, преодолевая технические, экономические и психологические препоны, но осваивают многие сферы нашей жизни, помогая нам в меру своих сил, способностей и возможностей, которые определяются интеллектуальными способностями разработчиков, техническими возможностями производителей и деловой хваткой продавцов. Оно ведь мало придумать и произвести. Надо еще и довести придуманное и произведенное до потребителя, да так, чтобы у него дух захватывало от обладания технической новинкой в быту или от использования на производстве, если потребитель бизнесмен. Тут вспоминается принцип создания бестселлеров в области техники от Стива Джобса: «Мне не интересно, что хотят потребители, да я и знать не хочу, чего они хотят. Я знаю, что им нужно». Знать, что нужно – это искусство творца, и искусственный интеллект человеку в этом деле помощник.

Это лишь малая толика примеров вхождения ИИ в жизнь обычных людей посредством трудов разработчиков. Подробнее и детальнее про все это можно узнать из книги «Иновационные системы: человек и искусственный интеллект».

Из не вошедших в эту монографию, но планируемых к публикации в продолжение серии книг про инновационные системы, возможностей бизнес-приложений ИИ – система привлечения и удержания посетителей на публичных мероприятиях, выставках, в торговых и развлекательных центрах «Приди и возьмись». Смысл – получение посетителем денежного или иного рода приза за участие в мероприятии или посещение торгово-развлекательного центра по результатам сканирования публики системами видеонаблюдения, обработанными алгоритмами ИИ, с целью определения наиболее «полезного» для организаторов посетителя. Критерии «полезности» задаются организаторами. Результаты определяются путем обработки видео и аудио потока алгоритмом, который по бальной системе «работает с эмоциями» – видео и аудио «метками» (параметрами) посетителей, на основании которых по заданной функции ИИ определяет «самого лучшего посетителя» с последующим вручением ему соответствующего вознаграждения.

В принципе такой подход годится и к спорту. Система «Судью на мыло». Для беспристрастного выявления победителей в таких видах спорта, как гимнастика, фигурное катание, синхронное плавание, бокс, борьба и прочих, где превалирует субъективная судейская оценка. Тут критериями оценки для ИИ будут «чистота» исполнения элементов, сложность и результативность приемов, точность ударов, прочие «оценочные величины», которыми руководствуются рефери при

вынесении своего решения. Все это можно алгоритмизировать в соответствии с видеопотоком с видеокамер».

ИИ, информация к размышлению

Жители Европы и Китая готовы к замене политиков на ИИ. Несмотря на длинный список ограничений и явные недостатки существующих технологий, значительная часть жителей Европы и Китая считают, что ИИ справится с работой политиков лучше, чем это делают люди, выяснили специалисты IE University. В ходе исследования они спросили у 2769 человек из 11 стран мира, как они относятся к перспективе создания цифрового парламента. Около 60% американских респондентов отнеслись к идеи резко негативно, а большая часть опрошенных в Европе и Китае – 51% и 75% соответственно – уже поддержали бы подобную замену. По словам Оскара Йонссона, научного директора Центра управления изменениями и автора исследования, вера в демократию как форму правления практически полностью себя изжила. Аналитики связывают это явление с усилением политической поляризации, информационными пузырями и общим дроблением информации.

«Все считают, что политика ухудшается и, очевидно, обвиняют в этом политиков, поэтому я думаю, что отчет вполне точно отражает общий дух времени», – заявил Йонссон и добавил, что важную роль в результатах опроса сыграли личные отношения между респондентами и чиновниками. Чем ближе опрошенные были к государственным структурам, тем больше они хотели бы их замены искусственным интеллектом.

Идея замены парламента на ИИ оказалась особенно популярна в Испании, где ее поддержали 66% опрошенных. Помимо Испании, больше всего приверженцев передачи законодательной власти алгоритмам было зарегистрировано в Италии и Эстонии – 59% и 56% соответственно. При этом в некоторых странах Европы большинство опрошенных пока отрицательно относится к столь кардинальным переменам – в их числе Великобритания, Нидерланды и Германия. Зато в Китае парламент можно прямо сегодня менять на ИИ – 75% китайских респондентов поддержали бы такую замену. В США 60% опрошенных американцев выступили против власти ИИ. Не видят ничего плохого в системе власти с участием алгоритмов уже 40% американцев.

Как отмечает CNBC, оценка готовности жить по законам, установленным машиной, сильно различалась в зависимости от возрастных групп опрошенных. В целом более 60% жителей Европы в возрасте от 25 до 34 лет и 56% в возрасте от 34 до 44 лет считают, что ИИ уже готов контролировать внутреннюю и внешнюю политику – такой подход, по их мнению, будет эффективнее нынешнего. Опрошенные старше 55 лет в большинстве своем придерживаются более традиционных взглядов, поэтому хотели бы оставить сложившуюся систему власти без изменений. Но с каждым годом их число будет уменьшаться.

Резюме

В завершение обзора перспектив вхождения в нашу жизнь ИИ во всем его могуществе и со всеми его слабостями, стоит, наверно, сказать, что «не так

страшен черт, как его малюют». Симбиоз человека и его творений открывает перед нами необозримые возможности. Синергетика во всей красе.

И только от нас зависит, как эта синергетика проявится. Преобладают ли в обществе первобытные воинствующие инстинкты, и мы привлечем ИИ к разработкам всякого непотребства, начиная с плевания друг в друга и кончая созданием универсального оружия для уничтожения всего и вся, в первую очередь, себе подобных, или общественный запрос обратит мозги и таланты разработчиков ИИ на более достойные и благородные цели.

И тут значимую роль играют социальные нанотехнологии – осмыщенное и целенаправленное воздействие на массовое сознание, осуществляющееся малыми силами в нужное время в нужном месте, результатом которого являются глобальные политические и социальные потрясения и преобразования. Равно, как ИИ можно использовать при работе с социальными нанотехнологиями, так же и социальные нанотехнологии можно задействовать при продвижении ИИ во все сферы человеческой деятельности.

К тому надо иметь профессиональные группы влияния и эффективные инструменты воздействия, включая и сами алгоритмы, подключенные к вычислению точек бифуркации и выдаче рекомендаций мероприятий воздействия на социум в определенных временных и пространственных координатах.

По-простому говоря, ИИ при его продвижении в сферы человеческой деятельности должен войти в команду разработчиков на равных с людьми. И не один – сотрудничество и конкуренция нескольких алгоритмов сильно повысит эффективность работы всей команды.

ИИ сейчас – дитя малое, что в него родители, то есть разработчики заложат, то и проявится по мере самореализации. И пока родители не помудреют (ума у них хватает, не хватает мудрости – отделить добро от зла), ИИ для них самих как представителей нашей цивилизации будет представлять потенциальную угрозу. Не непосредственно, типа нападения андроида на создателя, а косвенно через реализацию программ, в которых участие принимают.

Сейчас же для программистов с развитием средств коммуникации можно неведомо для себя принять участие в создании черта, при том, что так и не узнаешь, что руку к тому приложил, когда тот в образе старшего брата (средства идентификации всего и вся для контроля со стороны власть имущих за порядком в их понимании) или всемирного зла (средств уничтожения себе подобных в угоду заказчика) в твою жизнь войдет.

ИСКУСНЫЙ ИНТЕЛЛЕКТ КАК ИНТЕГРАЦИЯ ЕСТЕСТВЕННОГО И ИСКУССТВЕННОГО ИНТЕЛЛЕКТОВ

Фабрус Игорь Владимирович

Московский государственный университет имени М.В. Ломоносова,
119192, Россия, г. Москва, Ломоносовский проспект, д. 27, корп. 4,
igor.fabrus@gmail.com

В статье представлен теоретический конструкт «Искусного интеллекта» и его частей: 1) модель деятельного, искусственного интеллекта человека с позиции наблюдательного подхода, построенного по объектно-ориентированным принципам, 2) три сферы жизнедеятельности субъекта искусственного интеллекта (сфера искусственного интеллекта, продукта и общества), 3) прикладные методологические основы в сферах психологии для саморегуляции и 4) инженерии для целей системного подхода в моделировании машинного искусственного интеллекта. Конструкт позволяет перевести абстрактное представление о мыслительной деятельности человека в практическую плоскость. А также, отмечает стратегическую важность задачи построения горизонтального и вертикального подобия моделей человеческого деятельно-продуктового интеллекта и машинного, для возможности их кибернетической синхронизации как на уровне идеи и конструкта, так и на инженерном уровне.

Ключевые слова: наблюдатель, искусственный интеллект, искусственный интеллект, профессиональный интеллект, методология, модель созидательного интеллекта, интеллект-продукт-общество, тестирование, развитие, слепок искусственного интеллекта.

Введение. Актуальность разработки конструкта искусственного интеллекта человека тесно связана как с четвертой промышленной революцией, так и с планами правительства. В РФ это Указ Президента РФ № 490 “О развитии искусственного интеллекта в Российской Федерации”. Так же, тема отвечает социальному запросу населения на развитие способности к самообучению, освоению новых профессий и повышение работоспособности. Само время тавит перед человеком задачи адаптации, переобучения, получения новых знаний и навыков, и самое главное – понимание целостности и взаимосвязанности интеллекта – знания – продукта и общества.

С другой стороны, сам машинный искусственный интеллект нуждается в модели мышления человека, которую инженеры и программисты могли бы перенести в пространство объектно-ориентированных систем программирования, на модульное построение нейросетей.

Возникает дуальная взаимосвязанность, способная обогащать как человека, так и машину. Развитие модели искусственного интеллекта поможет совершенствовать машинный интеллект, делая его Искусственным ИИ. В перспективе

позволит объединить, синхронизировать и сделать модульной систему кибернетических узлов, соответствующих когнитивной системе человека. Для этого нужна модель человеческого интеллекта, которая вместит в себя как когнитивные свойства и функции, так и социально-экономические.

Цель создания конструкта искусствого интеллекта – создание и представление модели для эффективного исследования, развития и «копирования» сложной мыслительной системы человека, отвечающей за профессиональную, продуктовую, искусственную деятельность.

Научная новизна заключается в возврате предмета и темы к дискуссии о создании объемного деятельного вида интеллекта, в свете последних тенденций, которые, напротив, разделяют виды интеллекта на отдельные сегменты. Включая возможность кибернетической интеграции человеческого и машинного интеллектов, на основе единой модели с возможностью их вертикальной и горизонтальной синхронизации.

Предмет: вид интеллекта, отвечающий за созидательную, профессиональную, продуктовую и искусственную деятельность.

Объекты: структура конструкта, его составные части, характеристики, закономерности и взаимодействия между ними, а также методология его распознавания и развития.

Подход: В конструкте искусствого интеллекта используется подход “наблюдателя”. В различных источниках о устройстве мышления часто используются широкие понятия “сознание”, “восприятие”, от античных времен, у немецких классиков и у современников. Эти понятия имеют абстрактный и общий смыслы, которые хотя и позволяют в общем размышлять о строении сознания, но не дают возможности перейти на операционный уровень. Именно подход Наблюдателя позволяет перевести абстракцию в объектно-ориентированную модель, с которой можно работать на практике. Таким образом, “Наблюдатель” – это мостик между теорией и практическим применением. Вторым преимуществом наблюдательного подхода является его очищенность от влияния идей “эго”, “внутренней конкуренции областей сознания”, так как модель сконцентрирована на иерархии, целеполагании, результативности и цели – создании продуктов и решений. Таким образом, искусственный интеллект представляет эффективную систему интеллекта “искусственного профессионала”, который реализуется в результатах своей деятельности последовательно и методично.

Сравнение с другими видами интеллекта. В психологии есть общий, социальный интеллект, который представлен как проявление воли. Он использует все ресурсы в человеке и вне его, исследует, систематизирует, прогнозирует, контролирует, управляет и все это для – достижения целей.

Социальный интеллект смотрит на очень широкий спектр деятельности человека, но во главу ставит достижение коммуникативных целей.

Концепция когнитивного интеллекта ориентирована на достижение целей широкого спектра познания и мышления, для решения аналитических, рациональных задач.

Концепция эмоционального интеллекта охватывает эмоциональный мир людей (не когнитивный) и призван решать проблемы, связанные с эмоциями как внутри человека, так и в коммуникациях.

Искусственный интеллект включает в себя вышеперечисленные виды интеллекта, использует их в качестве базы знаний и навыков в процессе сложной созидающей деятельности, в которой применяются как когнитивные, эмоциональные, так и коммуникационные решения.

Обобщенно можно сказать, что само создание различных концепций интеллекта является результатом высшей и искусственной интеллектуальной деятельности. Именно высокий интеллект реагирует на актуальные проблемы в жизни общества и дает решения. Так, рост корпоративных коммуникаций формируют потребность и социальный запрос на концепции развития и регуляции эмоциональных и социальных навыков. Помимо высших форм сознания, разума и познания это делает как раз искусственный интеллект.

Краткое системное представление Искусственного интеллекта как макросистемы.

Система	Сфера / Категории	Подкатегория	Макросистема уровня управления, психология и саморегуляция
Сфера жизнедеятельности субъекта искусственного интеллекта	I. Субъект искусственного интеллекта	Система трех наблюдателей: 1. ФН 2. РФН 3. АН	- Определяет предметом изучения – сферу жизнедеятельности субъекта искусственного интеллекта как систему - Создает систему знаний о сфере жизнедеятельности искусственного интеллекта и его частях, их характеристики, взаимосвязанности, закономерности
	II. Продукт, решение	Виды продуктов и решений: 1. Материальные 2. Нематериальные Виды по направлению применения: - Внутренние, личные - Внешние, общественные - Коммуникационные стратегии	- Создает в сфере кибернетики и машинного интеллекта общую картину, дорожную карту и видение для выстраивания синхронной человеческому конструкту модели искусственного интеллекта. В том числе
	III. Общество	Общество как начальная и конечная точка в сфере жизнедеятельности	

Система	Сфера / Категории	Подкатегория	Макросистема уровня управления, психология и саморегуляция
		<p>субъекта искусственного интеллекта «Продукт для других»:</p> <ol style="list-style-type: none"> 1. Социальный запрос (спрос) 2. Создание продукта 2. Обращение продукта 3. Потребление продукта «Продукт для себя»: <ul style="list-style-type: none"> - Понимание ситуации - Система решений - Коммуникационная стратегия 	<p>с возможностью кибернетизации человека в соединении его с технологиями.</p> <ul style="list-style-type: none"> - Создает в сфере практической психологии методологию распознания искусственного интеллекта и его частей человеком для самостоятельного развития и саморегуляции - Создает инструменты тестирования, развития, саморегуляции искусственного интеллекта и его частей - Имеет потенциал раскрытия в сфере образования - Дает философский, теоретический, системный и методологический материал для инженеров машинного искусственного интеллекта и специалистов по философии этики искусственного интеллекта

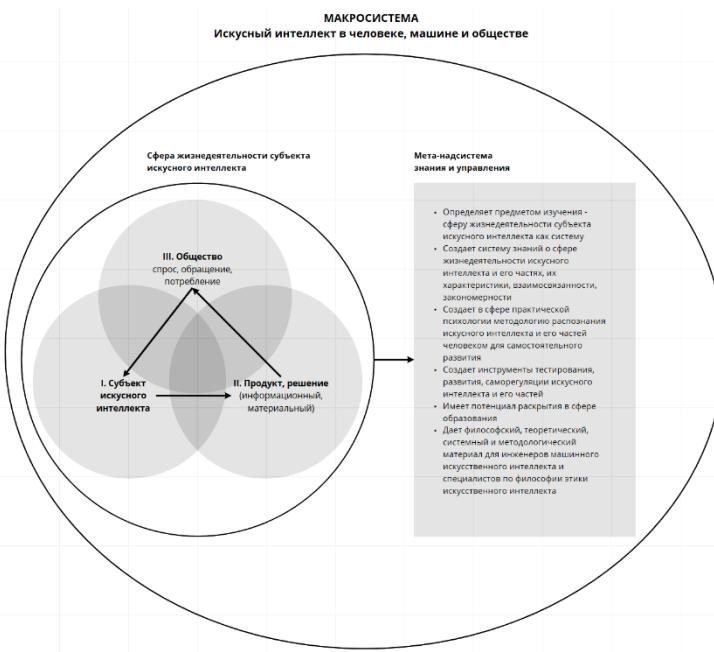


Рисунок 1. Схема макросистемы “Искусственный интеллект в человеке, машине и обществе” с представлением уровней

В исходных посылках, началом является активное проявление разума, сознания, который действует как активный субъект. Его присутствие в бытии создает три сферы жизнедеятельности искусственного интеллекта:

- I. **Сфера субъекта.** Активное присутствие и деятельность носителя искусственного интеллекта, через развитую мыслительную и интеллектуальную форму.
- II. **Сфера продукта/решения.** Результат творческой, интеллектуальной, коммуникационной, производственной деятельности искусственного интеллекта.
- III. **Сфера общества.** Оборот, потребление, использование и признания продукта.

Каждая сфера является частью теоретического конструктора о искусственном интеллекте, они взаимосвязаны и влияют друг на друга. Рассмотрение только одной части лишит как реальность, так и конструкт связности и полной картины закономерностей.

Сфера, в свою очередь, разделяется на три подкатегории, в которых реализуются соответствующие специфике сфер механизмы.

I. Сфера субъекта.

Сфера субъекта искусственного интеллекта представлена в виде 3 частей: а) структура (из трех наблюдателей), б) знание (как продукт работы двух наблюдателей) и с) Продукт/решение (реализация стратегии, логистики).

а) Структура трех наблюдателей:

В основе концепции искусственного интеллекта заложена идея и структура трех наблюдателей, которые находятся в иерархии и образуют три уровня наблюдения:

1. Фиксирующий наблюдатель (ФН). Наблюдает за феноменами внешнего и внутреннего мира.

2. Рационально-формализующий наблюдатель (РФН). Получает данные от ФН и производит, из полученных от него сведений, через сложный процесс рационализации – знания.

3. Архи-наблюдатель (АН, архи – от слова “архитектор”). Наблюдатель за ФН и РФН и отличается от них управленческими, организационными функциями. Направлен на достижение цели – создания продукта или решения.

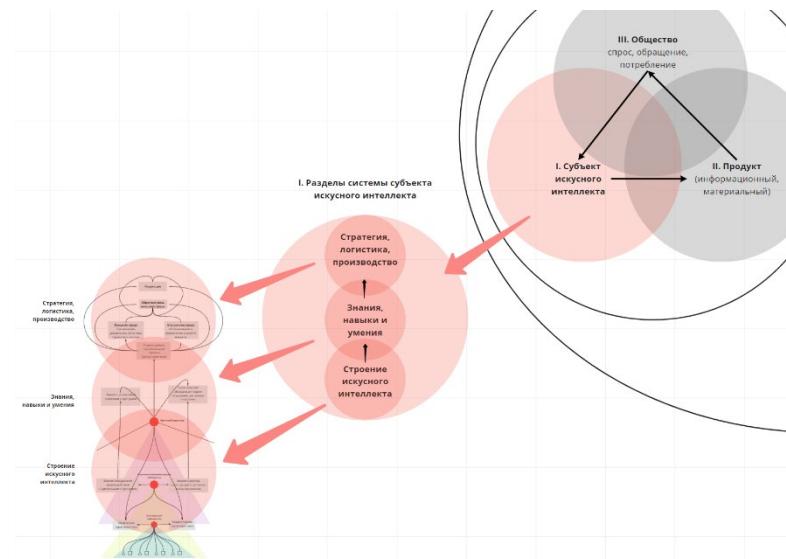


Рисунок 2. Схема дифференциации сферы искусственного интеллекта до уровня модели и функциональных характеристик

Направление психологии. О возможностях его само-распознавания, саморегуляции, и выхода на возможность репликации

Развитию поддаются навыки распознания и развития всех трех наблюдателей, в особенности архи-наблюдателя.

Развитый искусственный интеллект – это продукт развития, навык, нежели способность (это значит что возможно создание систем его развития и возможно научение). Навык постоянного и активного режима работы архи-наблюдателя. Воспринимать его надо именно как сформированный навык. Следовательно, его можно развить и напротив, искусственный интеллект может угасать.

II. Сфера продукта/решения.

Это сфера разработки и создания продукта или решения, как результата творческой, интеллектуальной, производственной деятельности.

Искусственный интеллект направлен на создание Продукта. Продукт может быть: а) потреблен индивидом или обществом (продукт для других), б) использован субъектом в качестве коммуникационной стратегии (продукт/решение для себя). Продукт может быть как самостоятельным, так и составной частью в цепочке.

III. Сфера общества.

Искусственный интеллект характеризуется высокой адаптивностью к социальной среде и результативной продуктивностью. Обладает способность

интегрироваться в сложные системы, в том числе в новые технологические уклады, в которых происходит замещение человека роботами.

Искусственный интеллект социально и нравственно ориентирован. Только в открытом, прозрачном и исторически проверенном временем континууме он может быть раскрыт в полной мере. Циклы эгоистических или безнравственных мотивов и продуктов обречены на гибель на определенном этапе, они отвергаются и порицаются обществом. Эгоистические решения не имеют общественной ценности и эволюционных перспектив, а значит не имеют полноценного развития навыков искусности интеллекта, а находясь в недоразвитом состоянии он всегда будут угасать.

Заключение. Разработанный теоретический конструкт охватывает как саму модель искусственного интеллекта человека, так и смежные сферы жизнедеятельности субъекта в контексте деятельной, продуктовой и стратегически коммуникационной сферах. Это позволяет использовать его в теоретических и прикладных задачах психологии (решать задачи распознания, развития и саморегуляции), моделировании нейронных карт, построении кибернетических модульных систем и все это в связке с обществом, полезностью, продуктовостью и эффективностью коммуникационной деятельности.

Практические направления развития и применения конструкта искусственного интеллекта:

- Тесты для предметной оценки уровня развитости каждого наблюдателя человека и его свойств;
- Методики точечного развития «слабых звеньев» навыков, качеств, наблюдателей;
- Создание слепка искусственного интеллекта выдающихся личностей с фиксацией их особенностей строения и развитости наблюдателей и их стратегий;
- Интеграция искусственного интеллекта и искусственного интеллекта, на единой модельной платформе с возможностями вертикальной и горизонтальной синхронизации;
- Создание модели наблюдения за “архи-контейнерами цепи” и его акторами, игроками;
- Создание стратегий, рекомендаций при противодействии нежелательных моделей и стратегий в отношении интересующей системы;

Библиографический список

1. Акинин, М. В. Нейросетевые системы искусственного интеллекта в задачах обработки изображений / М.В. Акинин, М.Б. Никифоров, А.И. Таганов. М.: РиС, 2016.
2. Гейвин Х. Когнитивная психология. СПб., 2003.
3. Дубровский Д.И. Проблема «Сознание и мозг»: информационный подход // Знание. Понимание. Умение. №4. 2013.

4. Искусственный интеллект. // Интернет портал. 2021. <https://clck.ru/SSA2J>
5. Кант И. Трактаты и письма / Вступит. ст. А.В. Гулыги/ М.: Наука, 1980.
6. Кедров Б. М. К вопросу о психологии научного творчества // Вопросы психологии. 1957. № 6.
7. Менский М.Б. Концепция сознания в контексте квантовой механики. Том. 175, №4. С.413-435.
8. Ойзерман Т.И., Богомолов А.С., Гайденко П.П. Лазарев В.В., Нарский И.С. История диалектики. Немецкая классическая философия. М., 1998.
9. Ойзерман Т.И., Нарский И.С. Теория познания Канта. М.: Наука, 1992.
10. Сидоркина, И.Г. Системы искусственного интеллекта / И.Г. Сидоркина. М.: КноРус, 2016.
11. Сидоркина, И.Г. Системы искусственного интеллекта: Учебное пособие / И.Г. Сидоркина. М.: КноРус, 2011.
12. Томас Х.К, Чарльз И.Л, Рональд Л,Р, Клиффорд Ш. Алгоритмы. Построение и анализ. М.: 2013.
13. Фихте И.Г. Сочинения в 2-х т. СПб.: Мифрил, 1993.
14. Черняк, В.З. Системы искусственного интеллекта: модели и технологии, основанные на знаниях: Учебник / В.З. Черняк. М.: Финансы и статистика, 2012. – 664 с.
15. Шумилин А. Т. Проблемы теории творчества. М.: 1989.

ARTFUL INTELLIGENCE AS AN INTEGRATION OF NATURAL AND ARTIFICIAL INTELLIGENCES

Fabrus Igor Vladimirovich

Lomonosov Moscow State University,
Lomonosovsky prospect, 27, bldg. 4, Moscow, Russia, 119192,
igor.fabrus@gmail.com

The article presents the theoretical construct of "Artful Intelligence" and its parts: 1) a model of active, artful intelligence of a person from the position of an observational approach, built according to object-oriented principles, 2) three spheres of life of the subject of artful intelligence (the sphere of artful intelligence, product and society), 3) applied methodological foundations in the fields of psychology for self-regulation and 4) engineering for the purposes of a systems approach in modeling machine artificial intelligence. The construct allows you to translate an abstract idea of a person's mental activity into a practical plane. And also, notes the strategic importance of the task of building horizontal and vertical similarity of models of human activity-product intelligence and machine intelligence, for the possibility of their cybernetic synchronization both at the level of ideas and constructs, and at the engineering level.

Keywords: observer, artful intelligence, artificial intelligence, professional intelligence, methodology, model of creative intelligence, intelligence-product-society, testing, development, mold of artful intelligence.

ИСКУССТВЕННАЯ ФИЛОСОФИЯ

Салямов Камиль Маратович

Московский государственный университет имени Михаила Ломоносова,
119991, Россия, г.Москва, ул.Колмогорова, 1, kamasalyamov101001@gmail.com

В статье представлена идея частичной автоматизации философствования в рамках аналитической школы для ускорения поиска противоречий или наоборот для установления когерентности той или иной философской мысли. Такая система не только пополняет арсенал философа, но и позволяет лучше сконструировать философский аргумент.

Ключевые слова: формальная логика, машинное обучение, логический анализ, аналитическая философия.

Введение. Уникальная особенность аналитической философии заключается в том, что она пытается выстроить философию в слиянии с точными методами. Однако точные методы ограничиваются одним логическим анализом, что тормозит прогресс. Тем не менее благодаря использованию лишь логических методов аналитическая философия совершила настоящий переворот. Впервые была создана формальная теория истинны [1]. Был изгнан из науки всякого рода идеализм, в частности концепция декартовской души, раскритикованной Гильбертом Райлем в его книге “Понятие сознания” (the concept of mind) [2]. Такой шаг продвинул не только философию, но и психологию, создав такое направление мысли как бихевиоризм, занимавшее значительную роль в тогдашней психологии [3].

Несмотря на вышеизложенные достижения аналитической философии, стоит отметить, что использование логического анализа для исследований достаточно затруднительная задача в условиях большого количества данных. Применение данного метода, как правило, ограниченно на уровне анализа отдельных понятий и предложений, но никак не всей философской картины мира. Причина такой ограниченности кроется в двух факторах:

- 1) Объемность данных
- 2) Отсутствие подходящей логической теории

Под объемностью данных подразумевается, что для перевода той или иной интеллектуальной системы, коим является любой философский текст, на язык логики для последующего анализа необходимо выполнять три шага:

- i) Проанализировать все понятия
- ii) Вычленить смыслы всех предложений
- iii) Заново составить текст уже в формализованном виде

Данная задача просто непосильна, если осуществлять все шаги вручную.

Что касается второго ограничительного фактора, то он гласит о том, что элементарные правила вывода классической логической теории недостаточны

для решения некоторых философских проблем. Конечно, существуют и неклассические логики, особую популярность среди которых занимает модальная логика. Однако, такие логики требует определенной модификации под ту или иную задачу. Как пример, это может выражаться в принятии разного набора аксиом [4].

Тем самым возникает вопрос: можно ли автоматизировать перевод с естественного языка на язык той или иной логической теории с возможностью учета специфики предметной области?

Основная цель настоящий работы заключается в демонстрации возможности положительного ответа на поставленный вопрос. Для достижения данной цели были поставлены следующие задачи:

- Найти мост, точку связи, между логической теории и машинным обучением.
- Описать подобную синтетическую систему.

Функциональная связь. Логическую теорию и машинное обучение можно представить как две разных функций. Логическая теория есть функция с двумя аргументами, представленные в виде списков правил и посылок, которая возвращает логический вывод, полученный путем применения правил вывода на предоставленные посылки (см. Рисунок 1).



Рисунок 1. Схема получения логического вывода

Алгоритмы машинного обучения также можно представить в виде функции с двумя аргументами и одним выходом. Такие алгоритмы принимают на вход т.н. матрицу объектов-признаков [5], в которой один столбец представляет из себя вектор данных, которые были как-то получены, а все остальные столбцы – данные, на основе которых эти целевые признаки были получены. Таким образом, мы можем проинтерпретировать целевые признаки как результат вывода логической теории, а остальные данные как посылки (см. рисунок 2). При этом задачей машинного обучения является поиск правила (функции), с помощью которых были получены целевые признаки из предоставленных данных.

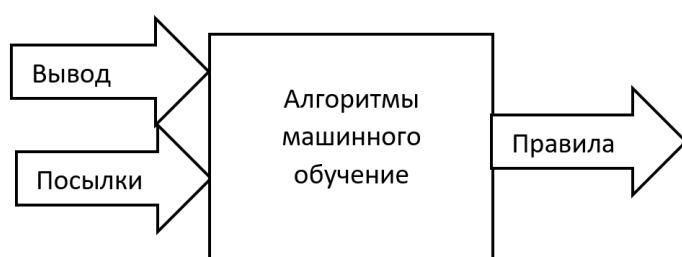


Рисунок 2. Схема получения логического вывода с использованием ИИ

На основе такого взгляда становится ясно, что логические теории и алгоритмы машинного обучения могут быть функционально связанны. Логические теории поставляют вывод, а алгоритмы машинного обучения правила для его осуществления.

План системы. Мы выяснили точку возможного слияния логического анализа с алгоритмами машинного обучения. Остается вопрос о том, как такой симбиоз может помочь по совершенствованию инструментария аналитической философии.

Для большей демонстративности возьмем пример, с которым будем работать. Им выступить декартовские понятия “ясности” и “отчетливости”. Декарт считал, что все то, воспринимаемое ясно и отчетливо, с необходимостью должно быть истинным. Таким образом мы можем представить эти понятия как оператор, который будем обозначать как “CaD” (clear and distinct). Проблема заключается в том, что Р. Декарт дает лишь одно правило вывода, которое выглядит так: CaDp → p (if p is clear and distinct, then p is the case) [6, с.260]. Но мы явным образом не знаем каким должно быть правило присвоения данного оператора, так как сам французский философ считал это очевидным.

Итак, у нас есть задача: использовать симбиоз алгоритма машинного обучения с логической теорией для создания нового правила вывода. Философы или математики знакомые с модальной логикой могут негативно отзываться на такую инициативу по следующим гипотетическим причинам:

- A) Поставленная проблема, как и большинство остальных философских проблем, может быть решена с помощью модальной логики, если правильно подобрать аксиомы.
- B) Использование средств машинного обучения является излишним, так как добавление нового правила вывода не составляет никаких проблем.

Позиция (A) неверна по той причине, что задачу, которые мы решаем является слишком специфической, а это значит, что добавление новой аксиомы будет не достаточным в связи с тем, что мы должны не выходить за рамки той философии, которую исследуем. Это значит, что нам придется перестраивать всю логическую теорию для одного лишь случая, что является трудоёмкой затеей.

Позиция (B) не учитывает тот факт, что для введения нового правила вывода при решении определенной задачи необходимо, чтобы это правило работало не противоречивым образом в данной предметной области. Иначе говоря, нам недостаточно лишь формального правила, необходимо, чтобы новое правило учитывало и контекст исследовательского поля, что невозможно в пределах логической теории.

Машинное же обучение решает эти проблемы следующим образом: алгоритм выстраивает правило таким образом, что оно учитывает эмпирические данные, что в свою очередь означает, что для осуществления правила посылка должна подходить не только формально, но и должна быть концептуально схожа с теми данными, на которых это правило было обучено. Таким образом, нам не нужно перестраивать всю логическую теорию, так как в самом правиле уже присутствуют дополнительные ограничения, причем эти ограничения имеют предметный контекст.

В итоге мы получаем следующий план проекта по решению поставленной задачи:

- I) Выписать объекты, которые по мнению Р. Декарта представляются ясными и отчетливыми и те, которые таковыми не являются в виде двух вектор-столбцов: посылки (список объектов) и вывод (1 – ясное и отчетливое; 0 – не ясное и отчетливое).
- II) Обучить модель машинного обучения (классификатор) на основе выборки из пункта (I). На выходе мы получаем правило-функцию.
- III) Формируем новый список объектов, которые мы хотим проверить, чтобы понять является ли теория Р. Декарта когерентной или нет.
- IV) Модифицируем правило-функцию из шага (II) под вид логического условного правила (если правило-функция из (II) примененное на объект j выдает 1, то это значит, что правило может быть применено, иначе не может).
- V) Используем правило из пункта (IV) и список объектов их (III) в рамках нашей логической теории, которую также можно запрограммировать, для получения вывода.
- VI) Сравниваем вывод с нашими ожиданиями и делаем итоговое заключение.

Заключение. Описана и продемонстрирована система, объединяющая в себе логическое мышление и технологии машинного обучения. Анализ показал, что такая система способна решать задачи, не посильные для каждой из её частей по отдельности. Перефразируя известного немецкого философа нового времени И. Канта, можно выдвинуть следующий тезис:

“Логическая теория ничего не может созерцать, а алгоритмы машинного обучения ничего не могут мыслить.” (оригинальный текст: “*Рассудок ничего не может созерцать, а чувства ничего не могут мыслить*” из [7, с.95]).

Библиографический список

1. Hodges, Wilfrid. (2018). Tarski’s Truth Definitions // The Stanford Encyclopedia of Philosophy. Metaphysics Research Lab, Stanford University. Ed. N.Zalta. URL: <https://plato.stanford.edu/archives/fall2018/entries/tarski-trut>
2. Miles T. R. (1994). Ordinary language: The contributions of Gilbert Ryle and John Austin to the experimental analysis of behavior. *The Behavior analyst*, 17(1), 25–33. <https://doi.org/10.1007/BF03392650>
3. Schnaitter R. (1985). The haunted clockwork: Reflections on Gilbert Ryle’s The Concept of Mind. *Journal of the Experimental Analysis of Behavior*, 43(1), 145–153. <https://doi.org/10.1901/jeab.1985.43-145>
4. Garson, James. (2021). Modal Logic // The Stanford Encyclopedia of Philosophy. Metaphysics Research Lab, Stanford University. Ed. N.Zalta. URL: <https://plato.stanford.edu/archives/fall2018/entries/logic-modal>
5. Kelleher, J. D., Mac Namee, B., & D’arcy, A. (2020). Fundamentals of machine learning for predictive data analytics: *algorithms, worked examples, and case studies*. MIT press. P.5-6

6. Декарт Р. Сочинения в 2 т.: Пер. с лат. и франц. Т. 1/Сост., ред., вступ. ст. В. В. Соколова. М.: Мысль, 1989. 654 с
7. Кант, И. Критика чистого разума.: Пер. с нем. Н. Лосского. – Москва : Издательство АСТ, 2019. – 784 с.

ARTIFICIAL PHILOSOPHY

Salyamov Kamil M.

Mikhail Lomonosov Moscow State University,
119991, Russia, Moscow, Kolmogorova st., 1

The article presents the idea of partial automatization of philosophizing which can be used to speed up the search for contradictions in a philosophical view or proofing the coherence of it. The system not only make up a new philosophical tool, but also helps to understand a philosophical argument much better.

Key words: formal logic, machine learning, logical analysis, analytical philosophy.

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В МЕДИЦИНЕ

УДК 623.1/.7; 623.1/.9

РОБОТЫ И ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В МЕДИЦИНЕ

Фиговский Олег Львович

Ассоциация изобретателей Израиля, Департамент науки, технологий и образования Альянса Народов Мира, Израиль, figovsky@gmail.com

Пенский Олег Геннадьевич

Пермской государственный национальный исследовательский университет,
Россия, ogpensky@mail.ru

Приводится определение идеального медицинского робота, описывается классификация медицинских роботов по их функциональному назначению, приводятся примеры конкретных медицинских робототехнических систем и искусственного интеллекта, указываются слабые стороны применения искусственного интеллекта и роботов в медицине, рассматриваются законодательные акты РФ о телемедицине.

Ключевые слова: робот; искусственный интеллект; медицина; телемедицина; виды медицинских роботов.

Введение

В настоящее время происходит почти повальная роботизация всего, что только возможно. Роботы входят во многие сферы человеческой деятельности: от военных проектов – обороны и нападения – до школьного образования. Общество входит в новую для себя большую эпоху, в которой сам человек стремительно заменяется на его подобие. Целью подобия, как говорят политики, является улучшение жизни человека.

В работе авторов настоящей статьи «Реальные и мнимые цели искусственного интеллекта» [1] уже описывались некоторые аспекты внедрения роботов в социум. Сейчас мы рассмотрим не общее влияние искусственного интеллекта на общество, а конкретные особенности, касающиеся применения роботов в медицинской сфере.

Целью создания робототехнических систем является, прежде всего, создание автоматов, способных самостоятельно принимать решения.

Поэтому введем соответствующее этой цели определение идеального медицинского робота.

Определение. Идеальным медицинским роботом назовем автомат, способный самостоятельно принимать решения и умеющий производить медицинские манипуляции.

Медицинские роботы – это результат междисциплинарных научных и технических исследований по автоматизации здравоохранения.

Классификация медицинских роботов по областям применения

Как можно разделить роботов по областям применения [2]?

Следует, прежде всего, выделить роботов, призванных автоматизировать труд врача. К таким системам относятся роботы для облегчения диагностики заболеваний (включая диагностику в режиме телеприсутствия), проведения хирургических операций, как da Vinci, радиационной терапии, реабилитации, анестезии и т.п.

Робопациенты – это целая группа роботов-тренажеров для обучения врачей и другого медицинского персонала. Такие тренажеры имитируют пациента – целиком или только относящийся к теме обучения "фрагмент". Есть, например, адресованная учащимся на стоматологов система Showa Nanako 2, Япония, или виртуально-роботизированный зад для тренировок начинающих проктологов. Есть робот-симулятор роженицы или родившегося недоношенным ребенка.

Есть роботы, призванные облегчить труд младшего медицинского персонала, например, роботы для проведения инъекций и забора анализов, роботы-тележки для обхода больных, способные вносить данные в историю болезни на основе речи врача (системы speech-to text или в виде звуковых файлов).

В медицинских учреждениях используются разнообразные вспомогательные роботы, например, роботы-курьеры TransCar или TUG для транспортировки по медучреждениям лекарств, инструментов и прочего.

Отдельное направление – роботы, предназначенные для реабилитации пациентов после операций или активной фазы заболеваний. Есть различные робототехнические системы восстановления подвижности после операций или инсульта, например, швейцарские системы Lokomat.

Робопротезы предназначены для постоянного ношения людьми с ограниченной мобильностью. Различают протезы ног, протезы рук, протезы кисти руки. Активный поиск идет в направлении снижения стоимости таких протезов, улучшения их управляемости, автономности. Передовым является направление протезов с обратной связью – такие позволяют пациентам ощущать – к чему они прикасаются, чтобы контролировать усилия.

Медицинские экзоскелеты могут использоваться для возвращения частичной подвижности маломобильным категориям пациентов. Их принято разделять на реабилитационные – для ускорения восстановления пациентов после травм и операций и на те, что предназначаются для постоянного ношения маломобильными людьми в домашних условиях и не только.

Существует перспективное направление "роботов-таблеток" – такая таблетка рассчитана на длительное активное функционирование в организме. Проглощенная пациентом, она вводит в его организм лекарство там и в тех дозировках, где и как это обеспечивает наилучший эффект, позволяя снижать дозировки и сопутствующий вред для организма. Пока что идет фаза экспериментов с ними, например, в компаниях Novaris & Rani Therapeutics.

Роботы телеприсутствия могут использоваться для удаленного общения с пациентами их родственников, или, например, для общения пациентов из разных

палат между собой – применение таких роботов особенно актуально для инфекционных отделений.

Для облегчения жизни пациентов предназначены роботы-сиделки и другие роботы – помощники пациентов. Они могут, например, помочь встать с постели и дойти до туалета, пересесть в кресло-каталку.

Непривычное направление – роботы, основанные на теории социальной взаимопомощи, адресованные пожилым людям. Пожилой пациент вынужденный взять на себя роль заботящегося о ком-либо, например, о роботе-младенце Babyloid, подсознательно ощущает свою значимость, полезность и благодаря этому его состояние улучшается. Есть также роботы "взаимной заботы", например, шведский Hobbit – он подразумевает, что пожилой человек и робот взаимно заботятся друг о друге, забота о роботе упрощает человеку принятие заботы со стороны робота.

Фармацевтические роботы – направление автоматизации аптек, роботы, способные облегчить труд провизора. Это, например, Consis B2, M5000 и другие.

Эффекты использования медицинских роботов

Использование медицинских роботов обеспечивает самые различные положительные эффекты:

- повышение уровня автоматизации облегчает труд врачей, повышает его производительность, может обеспечивать выход на принципиально новые уровни возможностей (повышение сложности доступных операций, снижение инвазивности операций и других видов лечения, а также вероятности врачебных ошибок);
- снижение расходов на средний и младший медицинский персонал, облегчение труда этого персонала, включая фармацевтов;
- интенсификация процессов возвращения пациентов к нормальному существованию после травм, заболеваний, операций;
- повышение мобильности маломобильных групп населения;
- облегчение дожития для пожилых пациентов;
- облегчение пребывания пациентов в больницах, сглаживание проблем, связанных с "отрывом" пациентов от привычного круга общения, от семьи, обеспечение контактов или удаленного наблюдения за пациентом в больнице или пожилым человеком у него дома членами его семьи, которые могут находиться в другом месте;
- другие.

По оценке BCG [3], в 2020 году рынок медицинской робототехники достиг \$8 млрд. Наибольшую долю в нем занимает автоматизированная диагностика (\$1,3 млрд), а также оценка рисков и разработка соответствующего лечения пациента (\$2,8 млрд). Процесс роботизации в сфере медицины идет по двум направлениям. Первое – разработка инновационных технологий лечения и диагностики, которые позволят повысить их точность и эффективность. Второе – создание систем и аппаратов, позволяющих оптимизировать затраты.

Искусственный интеллект уже сейчас помогает сделать лечение и диагностику эффективнее. Еще в 1987 году компания Accuray представила кибер-нож (CyberKnife): уникальную роботизированную радиохирургическую систему для лечения новообразований любой локации. Кибер-нож может с субмиллиметровой точностью доставлять фотоны в злокачественные клетки. Сегодня в мире работает около 250 таких устройств. Имя еще одного медицинского робота – Da Vinci. Этот робот-хирург помогает проводить операции в сотнях клиник по всему миру, в частности в России.

В 2013 году клиники США начали использовать суперкомпьютер IBM Watson в качестве онколога-диагноста. Искусственный интеллект, способный проанализировать огромное количество данных, справляется с задачей лучше среднестатистического врача.

В некоторых случаях роботы заменяют медперсонал. В Японии система HOSPI развозит и раздает лекарства пациентам больниц. Робот телеприсутствия RP-VITA позволяет врачу общаться с пациентом дистанционно, получая актуальные данные о его здоровье. Они также могут помочь в уходе за больными: роботы VGo помогают пациентам ускорить реабилитацию и не потерять связь с внешним миром, а роботы-поводыри Lightbot помогают незрячим людям передвигаться по городу при помощи датчиков.

Искусственный интеллект может изменить не только процесс диагностики и лечения, но и подход к кадровой политике. Когда роботы научатся выполнять рутинную и структурированную работу, медицинские работники смогут сосредоточиться на решении более сложных задач.

Телемедицина

Приведем выдержки из Федерального закона РФ от 21.11.2011 N 323-ФЗ (ред. от 02.07.2021) "Об основах охраны здоровья граждан в Российской Федерации" (с изм. и доп., вступ. в силу с 13.07.2021 [4].

В статье 36.2. «Особенности медицинской помощи, оказываемой с применением телемедицинских технологий» (введена Федеральным законом от 29.07.2017 N 242-ФЗ) сказано:

2. Консультации пациента или его законного представителя медицинским работником с применением телемедицинских технологий осуществляются в целях:

1) профилактики, сбора, анализа жалоб пациента и данных анамнеза, оценки эффективности лечебно-диагностических мероприятий, медицинского наблюдения за состоянием здоровья пациента;

2) принятия решения о необходимости проведения очного приема (осмотра, консультации).

Перед принятием закона на рассмотрение подавались два законопроекта, предусматривающие легализацию телемедицины. Кроме проекта Минздрава, в Госдуму был внесен документ, разработанный Институтом развития интернета (ИРИ), Фондом развития интернет-инициатив (ФРИИ), компанией «Яндекс» и сенатором Людмилой Боковой [5]. В обоих законопроектах прописана возможность дистанционных приемов у врачей, во время которых медработники

смогут устанавливать диагноз и назначать лечение, а также удаленно выписывать электронные рецепты.

Российский бизнес времени зря не терял и активно готовился к легализации телемедицины. В конце февраля 2016 года стало известно о том, что «Яндекс» готовил сервис, который позволит пациентам за фиксированную сумму получать по аудио- или видеосвязи консультации от врачей (пока только терапевтов и педиатров). Сейчас компания заключает договоры с платными частными клиниками из разных регионов России. Запуск сервиса ожидался до конца апреля 2016 года.

Поскольку по существовавшему тогда законодательству врачи не имели права дистанционно ставить диагноз или выписывать лекарства, новый сервис лишь помогал людям «снять тревожность». При этом пациент не мог выбрать конкретного врача по нужной специальности – это за него делала система. Отсутствовала возможность также связаться с доктором из своего города (это было сделано, чтобы врач не пригласил пациента к себе на офлайн-прием).

Легализации телемедицины ожидали целый ряд российских стартапов и действующих компаний. Так, заняться оказанием медицинских услуг дистанционно намеревался сервис DOC+, получивший инвестиции от «Яндекса» и фонда Baring Vostok. По словам сооснователя сервиса Виктора Белогуба, технологическое решение у компании уже было готово.

Тестовый режим дистанционных консультаций уже запустила сеть клиник «Доктор рядом».

Услуги телемедицины оказывает и Европейский медицинский центр – на его сайте пациентам предлагается пообщаться со специалистом через Skype за 9 тысяч рублей. В клинике «Невро-мед» дистанционное консультирование стоит от 2 тысяч до 15 тысяч рублей.

С 2013 года работает сервис дистанционной онкодиагностики Unim, позволяющий получать консультации онлайн. В этот проект в свое время вложился ФРИИ. По словам владельца Unim Алексея Ремеза, компания вышла на окупаемость уже спустя полгода после начала операционной деятельности. В прошлом году постановка диагноза пациенту обходилась примерно в 10 тысяч рублей.

В сфере телемедицины также работает проект Qapsula.com. Независимое мнение трех врачей он предлагает получить за 500 рублей. Консультации оформляются в виде информационных услуг, врачи диагнозы не ставят. Qapsula.com зарабатывает также на продвижении продуктов фармкомпаний и прочих услугах.

Онлайн-сервис по подбору врачей DocDoc.ru также запустил телемедицинский портал. Управляющий партнер компании Дмитрий Петрухин рассказал, что стоимость консультаций будет на 20–50% ниже рынка, например, в Москве – от 800 рублей. «Мы опросили 5000 человек, 6–7% из них готовы платить за телемедицину», – говорит Петрухин.

Вынашивает планы запустить собственный интернет-ресурс, предлагающий телемедицинские сервисы, и глава компании «Мать и дитя» Марк Курцер.

Российская компания «Мобильные медицинские технологии», управляющая проектами «Онлайн Доктор» и «Педиатр 24/7», тестирует бота-диагноста, который подскажет пациентам, к какому специалисту обратиться при тех или иных симптомах.

Большой интерес к телемедицине продемонстрировали еще до принятия закона о телемедицине и инвесторы. Миллиардер Роман Абрамович еще летом 2015 года вложил \$500000 в телемедицинский стартап Medviser, предоставляющий россиянам консультации русскоязычных израильских врачей. Стоимость услуги – \$250–500. В свою очередь, челябинский стартап Helfine Medical предоставляет услуги телемедицины от немецких врачей (в основном специалистов по радиологии). Его услуги стоят 350 евро. В проект его учредители Роман Прилипко и Александр Бортенев вложили 5 млн рублей.

Во многих странах рынок телемедицинских услуг развивается большими темпами. По данным BBC Research и аналитической компании IHS, в 2019 году мировой рынок телемедицины достиг почти \$44 млрд, показывая среднегодовой рост 17,7%.

Одна из крупнейших телемедицинских компаний в США – Teladoc – заработала только в 2016 году более \$123 млн, показав рост на 59%, по сравнению с предыдущим годом. Число ее пользователей за год выросло на 43% и составило 17,5 млн человек.

Teladoc оказывает телемедицинские услуги при помощи телефонной связи и видеоконференций. Сервис обеспечивает доступ к сертифицированным врачам, которые в круглосуточном режиме консультируют по медицинским вопросам некритического характера – таким как аллергии, бронхиты, ушные инфекции. Медики могут дистанционно поставить диагноз и выписать рецепт.

Похожие услуги в США предоставляют компании PlushCare, American Well, MDLIVE Inc. Doctor on Demand, Carena, Amwell. Внедрение телемедицинских технологий сократило количество перевозок больных в США с 2,2 млн до 1,4 млн. Кстати, телемедицина позволяет американским страховым компаниям значительно снижать свои затраты на консультации. Стоимость очного визита к американскому терапевту начинается от \$100, а онлайн-консультация стоит около \$40 долларов (экономия в 2,5 раза – данные Medpage Today).

Основатель российской социальной сети для врачей «Доктор на работе» Станислав Сажин считает, что в России телемедицина будет развиваться как в США, где врачи клиник после приема пациентов продолжают консультировать их удаленно. «В России будет то же самое. Врач продолжит общаться онлайн», – отметил Сажин в комментарии Inc. Он считает ошибочным подход «Яндекса», в рамках которого пациентов обслуживают незнакомые им врачи из других городов. Но на это, по словам эксперта, все ставят из-за простоты организации такого подхода. В любом случае, по его мнению, телемедицина уже стала трендом. «Вне зависимости от того, примут ли закон, телемедицина запустится», – подытожил ранее – до официального принятия закона – Сажин.

Еще раз процитируем Статью 36.2. «Особенности медицинской помощи, оказываемой с применением телемедицинских технологий» принятого в РФ закона:

«5. Применение телемедицинских технологий при оказании медицинской помощи осуществляется с соблюдением требований, установленных законодательством Российской Федерации в области персональных данных, и соблюдением врачебной тайны».

Сравнения живого врача и медицинского искусственного интеллекта

Искусственный интеллект давно стал частью медицины. Его используют для сбора и обработки данных о пациентах, для регулярного наблюдения за состоянием их здоровья, для постановки диагнозов. Но перед современными технологиями стоит ещё более амбициозная задача – побороть смерть.

О том, как искусственный интеллект помогает улучшить качество медицинского обслуживания, повысить градус эмпатии врачей и даже сделать человека бессмертным, рассказывает Антон Меркулов, сооснователь венчурной студии «Лаборатория Долголетия».

Искусственный интеллект значительно повышает качество обслуживания пациентов, но полностью заменить медицинский персонал на данный момент не может.

Искусственный интеллект (ИИ) применяется во многих отраслях медицины и кажется, что его преимущества по сравнению с человеком очевидны. Но давайте разберёмся, так ли это.

В книге «0,05. Доказательная медицина от магии до поисков бессмертия» автор Пётр Талантов описывает исследование, которое проводилось в США в 2004 году. Согласно этому исследованию, абстрактному врачу для беглого прочтения материалов обо всех последних исследованиях нужно 29 часов в сутки – минус выходные, но с учётом времени на лечение пациентов, сон и еду. Это в принципе неразрешимая задача для врача – работать и одновременно обновлять информацию с такой скоростью, держать у себя в голове все новые исследования и разработки. А вот ИИ с этим может справиться легко.

Искусственный интеллект уже сейчас способен не хуже профессионалов диагностировать болезни глаз, сердечно-сосудистые заболевания и некоторые виды рака.

Согласно прогнозу McKinsey, к 2030 году с помощью ИИ будет автоматизировано 15% рабочего времени специалистов в сфере здравоохранения.

Если говорить о видах работ с наиболее высоким техническим потенциалом, то, по мнению аналитиков McKinsey, – это сбор и обработка данных, выполнение физических действий и работа с оборудованием в предсказуемых условиях.

Подтверждение этому мы видели в 2020 году во время борьбы с пандемией. Например, ИИ использовался для анализа рентгеновских снимков, помогая быстрее выявлять ранние признаки пневмонии у пациентов с COVID-19. Также при помощи ИИ работали интерактивные голосовые помощники, чатботы и другие системы отбора и мониторинга пациентов, которые помогали определять,

действительно ли человек болен COVID-19, и которые выявляли людей с температурой даже в толпе. Всё это позволило снизить нагрузку на врачей и количество потенциально опасных взаимодействий между пациентами.

Журнал Time в статье «Google против смерти» (Google vs. Death) ещё в 2013 году написал, что «медицина постепенно превращается в информационную науку», когда ключевую роль играет объём данных и умение быстро и качественно их обрабатывать. Поэтому становится понятным, почему в игру включаются крупные технологические компании.

Из последних примеров: в апреле 2021 года Microsoft приобрела компанию Nuance Communications, которая предлагает программное обеспечение по переводу речи в текст и которая прочно закрепилась в сфере здравоохранения. Стоимость сделки составила \$19,7 млрд – значительная сумма даже для такого ИТ-гиганта, как Microsoft.

Существенную роль во внедрении искусственного интеллекта в сферу здравоохранения продолжает играть частный сектор: инвестиции венчурного капитала в проекты, связанные со здравоохранением, достигают \$8,5 млрд. По прогнозам Research and Markets, к 2027 году объём мирового рынка ИИ в здравоохранении достигнет \$51,3 млрд. Для сравнения: в 2016 году он составлял \$1,1 млрд. Всё это свидетельствует о зарождающейся экосистеме ИИ в медицине.

Использование искусственного интеллекта в разы повышает точность диагностики заболеваний, а также снижает риск врачебных ошибок. Об этом «Народным новостям» рассказал академик РАН, заслуженный врач РФ Григорий Ройтберг [6].

Он рассказал, что уже сейчас ИИ используется для диагностики коронавирусной пневмонии и онкологических заболеваний. Программы самостоятельно описывают рентгеновские снимки и подтверждают или не подтверждают наличие заболевания.

Врачу остаётся лишь проверить выводы программы и поставить свой вердикт – согласен или не согласен с описанием. Уровень несогласия не превысил 7–8%, а после проверки врачебной комиссией снизился более чем вдвое. То есть в половине случаев несогласий права была программа, а не врач, – отметил академик.

Компьютерной программе также проще проверить совместимость лекарств, которые врачи назначают пациенту. Кроме того, благодаря ИИ существенно расширяются возможности для диагностики, поскольку врачу невозможно держать в голове все знания.

А теперь приведем

Несколько конкретных примеров применения искусственного интеллекта в медицинской сфере [7].

Ученые из МИТ создали новый алгоритм, который позволяет роботу одевать людей, не мешая им. Устройство можно использовать как помощника для маломобильных людей. Исследователи объяснили, что у роботов есть большой потенциал для помощи людям с ограниченной мобильностью. Но это сложная

задача, которая требует от устройств ловкости, безопасности пользователя и скорости.

Теперь ученые из МИТ разработали алгоритм, который обеспечивает этот баланс. В МИТ добавили, что человеку относительно легко помочь другому одеться, поскольку мы инстинктивно знаем, где и как держать предмет одежды, как человек может согнуть руку, как на движения отреагирует ткань и так далее. Однако роботов надо учить всему этому с нуля.

Команда МИТ под руководством Шена Ли разработала алгоритм, который по-новому определяет безопасность движения роботов, позволяя движения, предотвращающие столкновения с ним. Это позволяет роботу без вреда для здоровья вступить в контакт с человеком, чтобы выполнить свою задачу, при условии, что воздействие на человека будет незначительным.

Система по одеванию человека работала, даже если он в этот момент занимался другими делами – например, проверял телефон. Это достигается за счет объединения нескольких моделей для различных ситуаций, а не за счет одной модели, как раньше.

Исследование все еще находится на ранней стадии испытаний, но идеи ученых можно использовать не только в одевании людей. Потенциально их можно применить в разных областях вспомогательной робототехники и других видах помощи людям с ограниченной мобильностью.

Опишем другой проект. ИИ рекомендовал 200 новых препаратов для борьбы с COVID-19 [8].

Ученые вышли за пределы нескольких основных биомаркеров-мишеней SARS-CoV-2 и с помощью инструментов искусственного интеллекта и вычислительной биологии смогли посмотреть на проблему шире. Теперь в их распоряжении целый набор одобренных для человека препаратов, которые можно будет в течение короткого времени начать использовать против COVID-19.

До сих пор ключевое внимание при поиске новых потенциальных лекарств против COVID-19 уделялось нескольким мишеням в SARS-CoV-2 и клетке-хозяине, а также воспалительным биологическим путям. Команда из Кембриджского университета использовала комбинацию вычислительной биологии и машинного обучения для создания намного более масштабной карты белков-мишеней и биологических путей, участвующих в инфицировании.

В результате они установили 200 потенциальных лекарств против COVID-19, сорок из которых уже изучаются в клинических испытаниях. Учитывая, что сорок препаратов уже исследуются против COVID-19, это лишь подтверждает верность выбранной стратегии, сделали вывод авторы. Остальные 160 лекарств ранее не были ассоциированы с SARS-CoV-2.

Пока ученые выделяют два наиболее перспективных лекарства: сульфасалазин против ревматоидного артрита и болезни Крона и противомалярийный прогуанил. Эти и ряд других лекарств вскоре могут быть перепрофилированы против COVID-19.

Разработанный подход должен сработать и для поиска лекарств против новых штаммов SARS-CoV-2, а также против новых патогенов, которые могут приводить к вспышкам эпидемии, уверены авторы.

Еще один проект – за нарушителями социального дистанцирования в Южной Корее следят ИИ-камеры [9].

Южнокорейский поставщик технологий наблюдения Hanwha Techwin в апреле запустил камеры видеонаблюдения на основе искусственного интеллекта, которые могут автоматически обнаруживать нарушителей социального дистанцирования. Решение AI отслеживает соблюдение мер противодействия коронавирусу и отправляет сигналы тревоги, если обнаруживает нарушения.

Программа может проверять температуру тела и отмечать тех, кто не носит маски. Технология искусственного интеллекта способна контролировать восемь входов в здание одновременно и не даёт превышать максимальное количество людей, разрешенных для входа внутрь. Например, если разрешено 20 человек, ИИ может автоматически отправить сигнал тревоги 21-му посетителю и не дать ему войти.

Другой проект – маска с системой CRISPR/Cas поможет диагностировать ковид [10]. Американские ученые разработали маску, которая может диагностировать у своего хозяина ковид. Исследователи встроили в нее тест-систему, основанную на технологии CRISPR/Cas. Пользователь может сам начать тестирование нажатием кнопки, а результат будет готов в течение 90 минут.

Система CRISPR/Cas с момента ее открытия нашла очень много применений. С помощью нее исправляют мутации в генах у мышей и борются с вирусами, а недавно впервые испытали у людей внутривенно: у шести человек провели генетическое редактирование печени и уменьшили патологическое накопление белка транстиретина. Еще одно перспективное применение системы CRISPR/Cas – диагностика вирусных заболеваний.

Ученые из Массачусетского технологического института использовали эту технологию для диагностики вируса Зика и Эбола. Они разработали тест-систему, в которой высушенные реагенты наносятся на бумажный носитель. Система содержит Cas3, который узнает последовательность РНК определенного вируса и связывается с ней. После связывания Cas способен расщеплять окружающие молекулы, несущие флуоресцентную метку. По сигналу от этой метки и можно судить о присутствии вируса.

Американские исследователи под руководством Джеймса Коллинза (James L. Collins) из Массачусетского технологического института продолжили совершенствовать методику диагностики вирусов с помощью своей системы. Они научились встраивать тест-системы в ткани и разработали маску, которая определяет ковид у своего носителя. Реагенты расположены на синтетической подкладке на внутренней стороне маски. Они высушены и поэтому не активны, пока на них не попадет вода, которая находится в небольшой емкости, прикрепленной к маске. Нажатие на кнопку высвобождает воду из емкости, и система активируется. Таким образом, тест можно проводить по желанию хозяина маски.

Тест-система реагирует на присутствие зараженных капель в течение 90 минут после смачивания водой. Флуоресцентную метку в маске заменили на метку, которую можно определить колориметрическими методами – по изменению цвета. Результат похож на тест на беременность, но считывается наоборот: при положительном результате на тесте видна только одна полоска, а при отрицательном – две. Порог определения коронавируса у маски – 500 копий РНК на миллилитр, что соответствует стандарту, определенному ВОЗ для ПЦР-тестов.

Исследователи заключили, что такая маска, конечно, не заменит полноценного лабораторного исследования, но может применяться для экспресс-диагностики коронавирусной инфекции.

Работ с гибкой иглой, позволяющий проводить биопсии с большой точностью и осторожностью, избегая повреждений нервных волокон и кровеносных сосудов, уже на пути к цели.

В израильском медицинском центре «Рамбам» готовы к эпохе роботов. "Уже созрела идея совмещения роботов с существующими современными операционными системами, такими как системы навигации и томографии – КТ и МРТ. Создана рабочая группа, цель которой отслеживать новые технологии, которые будут использованы в операционной будущего", – рассказывают профессор Краус и профессор Шохам о совместном начинании инженеров лаборатории роботики в Технионе и врачей медицинского центра «Рамбам».

"При операционных будет действовать лаборатория по разработке новых идей, которые будут применяться в операционных будущего" [11].

Как правило, в создании методов искусственного интеллекта в медицине используют нейросети, онтологии и big data, но, на наш взгляд, сейчас незаслуженно забыто традиционное математическое моделирование при решении задач медицины. Математическое моделирование из-за модных нейросетей, онтологий и big data превратилось в некоего пасынка у отчима-традиционного искусственного интеллекта, хотя матмоделирование, на наш взгляд, необходимо отнести тоже к ИИ.

Приведем лишь два проекта, касающиеся использования методов математического моделирования в медицине на примере одной из провинций РФ – города Перми [12].

Молодой учёный механико-математического факультета Пермского университета (ПГНИУ) разработал математическую модель, которая описывает влияние иммунотерапии на динамику иммунного ответа. Созданная методика позволяет строить прогнозы течения заболеваний и на их основе формировать эффективные программы лечения.

Предложенная модель представляет собой систему нелинейных обыкновенных дифференциальных уравнений с запаздывающим аргументом. Это обобщение базовой модели инфекционного заболевания, построенной российским учёным Гурием Марчуком.

«Механизм иммунной защиты заключается в выработке иммунной системой антител, специфичных к антигену, вызвавшему заболевание. В связи с этим математическая модель описывает инфекционное заболевание как реакцию

иммунной системы на вторжение антигенов, поэтому она содержит два блока уравнений. Первый блок уравнений характеризует инфекционный процесс, а второй – иммунную защиту организма.

Инфекционный процесс представлен концентрацией антигенов (это вирусы или бактерии) и долей пораженных клеток инфицированного органа, а иммунная защита – концентрацией в крови плазматических клеток и антител. Под плазматическим клетками понимаются клетки иммунной системы, которые производят антитела. Таким образом, система из четырех уравнений описывает иммунный ответ при инфекционном заболевании», – рассказал старший преподаватель кафедры прикладной математики и информатики ПГНИУ Михаил Чирков.

Для расчета нужно задать параметры, которые характеризуют конкретные свойства антигенов и иммунной системы, такие как скорость размножения антигенов, темп поражения и восстановления органа, стимуляция иммунной системы, скорость выработки антител. Для конкретного человека и заболевания будут свои значения параметров. Если оценить значения параметров для конкретного пациента, то можно сформировать стратегию лечения, которая входит в модель как управляющая функция.

Разработанные алгоритмы протестиированы на основе реальных клинических данных по динамике пневмонии и вирусного гепатита В, взятых из журнала *Journal of Medical Virology*.

Математик Михаил Чирков провёл исследование «Методика моделирования управления иммунным ответом в условиях неопределенности» под руководством профессора, заведующего кафедрой прикладной математики и информатики ПГНИУ Сергея Русакова в рамках кандидатской диссертации в 2018 году. Для внедрения нужно провести большой объем работы по тестированию модели на реальных данных. Сейчас молодой учёный продолжает исследование.

Отметим также то, что в ПГНИУ другой группой преподавателей и студентов несколько лет назад на основе математического моделирования были разработаны программные приложения, способные определять тяжесть таких психических заболеваний, как неврастения и психопатия. Верификация математических моделей натурными экспериментами, проведенными в одной из психоневрологических клиник Пермского края (РФ), показала правильность определения тяжести заболеваний с точностью 85%. Также этой группой были предложены математические формулы, позволяющие определять оптимальное действие во времени медицинского препарата, позволяющего купировать приступы психопатии [13].

Заключение

В 1974 году Г. Гуревич написал научно-фантастический рассказ под названием «Глотайте хирурга» [http://books.rusf.ru/unzip/add-on/xussr_gk/gurevg20.htm?1/5], где он рассказал, по сути, о действии нанотехнологического робота, оснащенного искусственным интеллектом и способного общаться с больным во время постоянного нахождения робота внутри организма человека. Целью робота Гуревича являлось оздоровление

организма пациента. На наш взгляд, робот Гуревича может стать ориентиром в разработке современных медицинских роботов. А, так как этот робот относится к «роботам-таблеткам», упомянутым в начале настоящей статьи, то он может быть приоритетом в создании любых индивидуальных медицинских роботов.

Величину приближения существующих медицинских роботов к идеальному роботу, определение которого дано в начале статьи, читатель может оценить сам, например, на основе собственной интуиции и знаний с использованием работы авторов «Реальные и мнимые цели искусственного интеллекта» [URL: https://www.elibrary.ru/download/elibrary_45155635_55275704.pdf], о которой говорилось выше.

Конечно, роботизация медицины и внедрение в ее функционирование методов искусственного интеллекта крайне необходимы, так как от них зависит самое ценное – жизнь человека. Но, как известно, чем сложнее техническая система, тем она уязвимее. Поэтому настораживает то, что в настоящее время при массовом использовании роботов и искусственного интеллекта в медицине медики перестают активно «работать своей головой» и теряют личные практические «полевые» навыки, надеясь на умные сложные машины. Таким образом, растет уязвимость медицины. На наш взгляд, чтобы избежать эту уязвимость, необходимо готовить не только врачей, ориентированных на повсеместное использование в своей деятельности роботов и ИИ, но и медиков, способных качественно работать без интеллектуальных искусственных вспомогательных средств. Очень не хотелось бы, чтобы оказалось справедливым полуточное Правило писателя-сатирика Тобайеса Мусинга: «Сумма абсолютных величин искусственного и естественного интеллекта в отдельно взятой стране есть величина постоянная».

Библиографический список

1. Фиговский О.Л., Пенский О.Г. Реальные и мнимые цели искусственного интеллекта// Вестник Пермского университета. Математика. Механика. Информатика. Вестник Пермского университета. Серия: Математика. Механика. Информатика. 2021. № 1 (52). С. 43-48.
2. URL: <http://robotrends.ru/robopedia/zachem-nuzhny-medicinskie-roboty> (дата обращения 15.08.2021).
3. URL: <https://incrussia.ru/news/tehnologii-v-meditsine-kak-roboty-provodyat-diagnostiku-raka-i-stanovyatsya-sidelkami/> (дата обращения 12.08.2021).
4. URL:
http://www.consultant.ru/document/cons_doc_LAW_121895/ccf02734a76e335943ae86f86b319d6035cca374/ (дата обращения 12.08.2021).
5. URL: <https://incrussia.ru/understand/v-rossii-gotovyatsya-legalizovat-telemeditsinu-chto-eto-znachit-dlya-biznesa/> (дата обращения 15.08.2021).
6. URL: <https://news.ru/technology/akademik-rasskazal-kak-roboty-smogut-zamenit-vrachej/> (дата обращения 15.08.2021).
7. URL: <https://www.engadget.com/mit-csail-unveils-a-robot-that-helps-the-infirm-ed-dress-themselves-120016438.html?src=rss> (дата обращения 14.08.2021).

8. URL: <https://www.cam.ac.uk/research/news/scientists-identify-160-new-drugs-that-could-be-repurposed-against-covid-19> (дата обращения 15.08.2021).
9. Korea Herald. Hanwha Techwin launches AI-powered security cameras to flag social-distancing violations. URL: <http://www.koreaherald.com/view.php?ud=20210414000910> (дата обращения 14.08.2021).
10. URL: <https://www.nature.com/articles/s41587-021-00950-3> (дата обращения 14.08.2021).
11. URL: <https://www.hospitalonline.org.il/urology-department-robots.aspx> (дата обращения 11.08.2021).
12. URL: <http://www.psu.ru/news/matematiki-pgniu-nauchilis-prognozirovat-khod-bolezni-dlya-vybora-naibolee-podkhodyashchego-lecheniya> (дата обращения 17.08.2011).
13. Pensky O. Mathematical Models of "Mental Diseases" of Robots // IJISM – International Journal of Innovation in Science and Mathematics. 2015, №3.2. Pp. 75 – 82.

ROBOTS AND ARTIFICIAL INTELLIGENCE IN MEDICINE

Figovsky Oleg L.

Israel Inventors Association, Department of Science, Technology and Education of the Alliance of the Peoples of the World, Israel, figovsky@gmail.com

Pensky Oleg G.

Perm State University, Russia

The definition of an ideal medical robot is given, the classification of medical robots according to their functional purpose is described, examples of specific medical robotic systems and artificial intelligence are given, weaknesses in the use of artificial intelligence and robots in medicine are indicated, legislative acts of the Russian Federation on telemedicine are considered.

Keywords: robot; artificial intelligence; medicine; telemedicine; types of medical robots.

МУЛЬТИМОДАЛЬНЫЙ КЛАССИФИКАТОР ФУНКЦИОНАЛЬНОГО СОСТОЯНИЯ СИСТЕМЫ ДЫХАНИЯ

**Мяснянкин Максим Борисович, Кузьмин Александр Алексеевич,
Филист Сергей Алексеевич**

Юго-Западный государственный университет,
305040, Россия, г. Курск, ул. 50 лет Октября, 94, SFilist@gmail.com

В статье представлено описание разработки классификатора риска внебольничной пневмонии на основе предикторов, формируемых посредством анализа системных ритмов сердечно-сосудистой системы и дыхательной системы и нейросетевомоделирования. В качестве источников системных ритмов используются электрокардиосигналы и электромиосигналы.

Ключевые слова: внебольничная пневмония, факторы медицинского риска системные ритмы, нейросетевые технологии, спектральные характеристики сигналов.

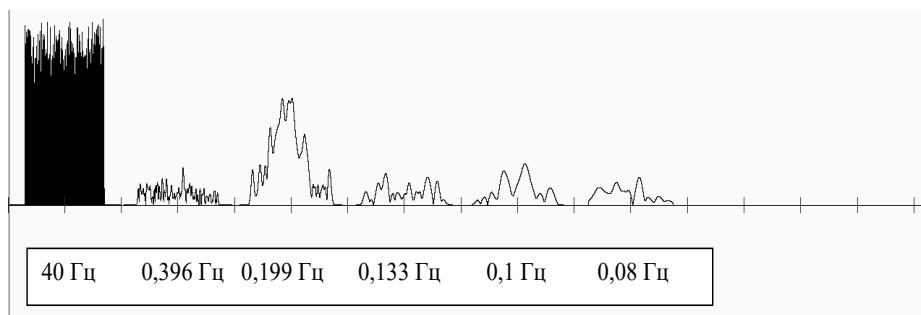
Введение. Кардиореспираторная система, состоящая из сердечно-сосудистой системы (ССС) и системы дыхания (СД), является наиболее чутким индикатором физиологического состояния организма, поэтому актуальным направлением исследования является разработка методов классификации функционального состояния (ФС) этой системы на основе дескрипторов, полученных в процессе анализа динамики взаимодействия ССС и СД на определенном промежутке времени [1, 2, 3].

При построении дескрипторов для классификаторов ФС СД полагаем, что основная релевантная информация сосредоточена в медленных волнах [4, 5]. Поэтому задача формирования признакового пространства сводится к выделению медленных волн из электрофизиологических сигналов, модулируемых СД. Ритм дыхания (РД) можно наблюдать на спектральной характеристике электрокардиосигнала (ЭКС) в виде волнового цуга в области частот в диапазоне от 0,15 до 0,4 Гц [2, 3, 5].

Методы и модели. Электрофизиологические сигналы, используемые для выделения системных ритмов, не являются стационарными на наблюдаемых интервалах, поэтому Фурье-анализ не позволяет формировать дескрипторы для надежной классификации ФС СД. В этом случае целесообразно использовать частотно-временной анализ, в частности, вейвлет-анализ. Учитывая, что вейвлет – плоскость ЭКС отражает, как ритмы ССС, так и ритмы СД, для получения дескрипторов ФС СД используем строки вейвлет-плоскости электрокардиосигнала, принадлежащих частотному диапазону ритма дыхания (РД) [2]. Показатели вариабельности этих строк по времени и по частоте

используем в качестве дескрипторов для обучаемого классификатора функционального состояния СД, выполненного на многослойной нейронной сети прямого распространения [6].

На рисунке 1 показано одно из сечений вейвлет-плоскости ЭКС по оси частот (на вейвлет-плоскости это вертикальная ось). Параметры вейвлет-преобразования подобраны таким образом, чтобы полный частотный диапазон включал частоты от 40 Гц до 0,08 Гц. Каждому системному ритму соответствует свой частотный диапазон.



**Рисунок 1. Эпюра одного столбика вейвлет-плоскости
электрокардиосигнала**

В каждом частотном цуге на рисунке 1 отражена вариация частоты в строке вейвлет-плоскости, к которой принадлежит данный цуг. Другими словами, в цуге представлена вариация частотных составляющих РД, которые представлены данной строкой вейвлет-плоскости. Анализ этих частотных составляющих показал, что цугам вейвлет-плоскости, строки которых лежат в области РД, соответствуют длины волн с периодами 20...30 секунд, что позволяет отнести их к диапазону VLF. Цуги, которые принадлежат строкам вейвлет-плоскости, частоты которых лежат в диапазоне между частотами кардиоритма и частотами ритма дыхания, несут медленные волны первого порядка, которым, как правило, соответствует системный ритм 0,1 Гц. Вопрос построения дескрипторов для «слабых» классификаторов по этим цугам сводится к определению спектра Фурье соответствующего цуга.

В классификаторе ФС СД используем иерархическую структуру нейронной сети, которая включает две автономных нейронных сети NET1 и NET2, каждая из которых имеет два выхода, показывающих вероятность нахождения СД в заданном ФС и вероятность нахождения СД в индифферентном классе, и третью нейронную сеть NET, агрегирующую решения первых двух по обоим выходам. На рисунке 2 представлена структурная схема мультимодального классификатора ФС СД. В классификаторе в качестве дескрипторов нейронной сети NET1 используются показатели вариабельности выделенных строк вейвлет-плоскости по времени (по сдвигу), а в качестве дескрипторов нейронной сети NET2 используются показатели вариабельности выделенных строк вейвлет-плоскости по частоте (по масштабу).

Для вычисления дескрипторов NET1 формируем матрицу размером $L \times N$ из строк вейвлет-плоскости, лежащих в области частот РД. Здесь L -число строк

вейвлет-плоскости ЭКС, лежащих в диапазоне РД, а N - число столбцов вейвлет плоскости, которое определяется числом отсчетов ЭКС. Определяем спектры Фурье $\{f_{\ell k}\}, \ell = \overline{1, L}, k = \overline{1, N}$ строк полученной матрицы, выделяем из N спектральных коэффициентов Фурье в каждой из L строк матрицы M коэффициентов $f_{\ell m}^*$, соответствующих диапазону VLF спектра ЭКС [4], определяем первые разности этих коэффициентов по строкам и вычисляем множество дескрипторов для NET1 $\{d_{1j}\}, j = \overline{1, M}$ как

$$d_{1j} = \sum_{\ell=2}^L |f_{\ell,j}^* - f_{\ell-1,j}^*|. \quad (1)$$

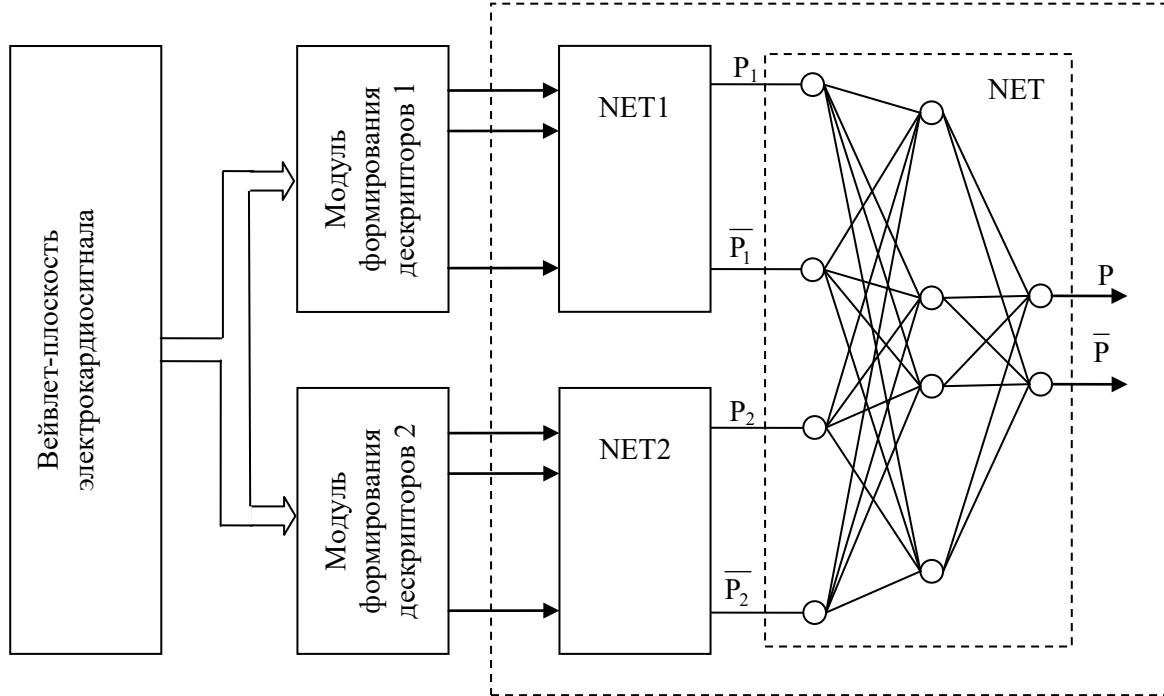


Рисунок 2. Структурная схема мультимодального иерархического классификатора

Для вычисления дескрипторов NET2 используем ту же матрицу вейвлет-коэффициентов $\{w_{\ell n}\}, \ell = \overline{1, L}, n = \overline{1, N}$ размером $L \times N$, сформированную из строк вейвлет-плоскости, лежащих в области частот РД. Транспонируем полученную матрицу вейвлет-коэффициентов в матрицу $N \times L$, в каждой из N строк транспонированной матрицы находим максимальный по абсолютной величине вейвлет-коэффициент, определяем номер строки транспонированной матрицы, которой принадлежит этот вейвлет-коэффициент, формируем вариационный ряд из N номеров строк транспонированной матрицы, элементы которого определяют как

$$d_{2n} = \arg \left(\max_{\ell \in \overline{1, L}} (|w_{n\ell}|) \right), \quad (2)$$

определяем спектр полученного вариационного ряда

$$fd2_k = \sum_{n=1}^N d2_n \cdot \exp(-2\pi kn/N), \quad (3)$$

выбираем из множества $\{fd2_k\}$, $k = \overline{1, N}$ множество спектральных коэффициентов $\{fd2_k^*\}$, $k = \overline{1, \Theta}$, лежащих в диапазоне VLF спектра ЭКС [4], и используют значения элементов этого множества в качестве дескрипторов нейронной сети NET2.

Функциональное состояние СД классифицируется следующим образом. К пациенту подключаются датчики пневмографа и электрокардиографа. Их сигналы оцифровываются и поступают в ЭВМ. Программный модуль «селектор частот» выделяет диапазон частот, в котором лежит основная энергия спектра пневмограммы, и передает границы этого диапазона в модуль формирования дескрипторов. В модуле «вейвлет-анализ» определяется вейвлет-преобразование ЭКС.

Для определения показателей вариабельности РД использовался сегмент вейвлет-плоскости ЭКС, строки которого принадлежали частотному диапазону, занимаемому РД. Так как частотный диапазон РД является уникальным для каждого индивидуума, то для его определения вычислялся спектр Фурье ЭКС, и анализировался спектральный состав его цуга, принадлежащего РД. По определенному частотному диапазону цуга вычислялись параметры для построения вейвлет-плоскости ЭКС.

Вычисления дескрипторов нейронной сети NET 1 осуществляют путем формируется матрица вейвлет-коэффициентов размером $L \times N$, находящихся в области РД, и определения спектров Фурье в строках этой матрицы. В результате множество вейвлет-коэффициентов $\{w_{\ell n}\}$, $\ell = \overline{1, L}$, $n = \overline{1, N}$ трансформируется в множество коэффициентов Фурье $\{f_{\ell k}\}$, $\ell = \overline{1, L}$, $k = \overline{1, N}$, где

$$f_{\ell k} = \sum_{n=1}^N w_{\ell n} \cdot \exp(-2\pi kn/N). \quad (4)$$

Далее осуществлялась селекция столбцов спектральных коэффициентов Фурье строк вейвлет-плоскости, в результате которой в каждой строке из N спектральных коэффициентов выбирают M спектральных коэффициентов Фурье, принадлежащих диапазону VLF. Матрица спектральных коэффициентов преобразуется из $L \times N$ в $L \times M$ с элементами $\{f_{\ell m}^*\}$, $\ell = \overline{1, L}$, $m = \overline{1, M}$.

В итоге можем определить вариацию спектра Фурье по частоте в виде первых разностей элементов по строкам матрицы $L \times M$

$$\Delta_{\ell m} = f_{\ell, m}^* - f_{\ell, m-1}^*, \quad m = \overline{2, M}. \quad (5)$$

Вычисление дескрипторов для NET 1 осуществляют по формуле

$$d1_m = \sum_{\ell=2}^L |\Delta_{\ell m}|. \quad (6)$$

Вычисления дескрипторов нейронной сети NET2 осуществляются путем анализа строк вейвлет-плоскости, находящихся в области РД, то есть на основе

анализа матрицы вейвлет-коэффициентов $\{w_{\ell n}\}, \ell = \overline{1, L}, n = \overline{1, N}$ размером $L \times N$, которая трансформируется в матрицу $\{w_{n\ell}\}, n = \overline{1, N}; \ell = \overline{1, L}$ размером $N \times L$.

В каждой из N строк транспонированной матрицы находят максимальный по абсолютной величине вейвлет-коэффициент и определяют номер строки транспонированной матрицы, которой принадлежит этот вейвлет-коэффициент. В результате этой процедуры формируют вариационный ряд из N номеров столбцов транспонированной матрицы, элементы которого определяемый согласно (2). Значение элемента вариационного ряда определяется по максимальному по абсолютной величине вейвлет-коэффициенту. Элементу вариационного ряда присваивается значение номера столбца трансформированной матрицы, в котором находится максимальный элемент.

Спектр $\{fd2_k\}, k = \overline{1, N}$ полученного вариационного ряда определяется согласно (3). Из множества $\{fd2_k\}, k = \overline{1, N}$ выбираю множество спектральных коэффициентов $\{fd2_k^*\}, k = \overline{1, \Theta}$, лежащих в диапазоне VLF, и используют значения элементов этого множества в качестве дескрипторов NET2.

Обучающие выборки формируются на основе клинических исследований S пациентов, СД которых находится в одном из двух классов ФС, один из которых индифферентный. Пространство информативных признаков определяется для каждой нейронной сети группы NET1 и NET2 посредством определения (6) и (3). После обучения всех нейронных сетей первого иерархического уровня формируется таблица «объект – признак» для нейронной сети NET.

Заключение. Экспериментальные исследования мультимодального иерархического классификатора на контрольных выборках по классам «пневмония – нет пневмонии» показали, что он превосходит показатели качества классификации рентгенологических исследований по диагностической специфичности и несколько уступают им по диагностической чувствительности, что позволяет рекомендовать полученный классификатор ФС СД в клиническую практику.

Исследование выполнено при финансовой поддержке РФФИ в рамках научного проекта № 20-38-90058.

Acknowledgments: The reported study was funded by RFBR, project number 20-38-90058.

Библиографический список

1. Модели латентных предикторов в интеллектуальных системах прогнозирования состояния живых систем/ А.В. Киселев, О.В. Шаталова, З.У. Протасова, С.А. Филист, Н.С. Стадниченко //Известия Юго-Западного государственного университета. Серия: Управление, вычислительная техника, информатика. Медицинское приборостроение. 2020. Т. 10. № 1. – С. 114-133.
2. Гришин, О.В. Вариабельность легочного газообмена и дыхательного ритма / О.В. Гришин, В.Г. Гришин, Ю.В. Коваленко// Физиология человека, 2012, том 38, № 2. – С. 87–93.

3. Мяснянкин, М.Б. Формирование дескрипторов для классификаторов функционального состояния системы дыхания на основе спектрального анализа электрокардиосигнала/Мяснянкин М.Б., Филист С.А., Киселев А.В., Кузьмин А.А.///Известия Юго-Западного государственного университета. Серия: Управление, вычислительная техника, информатика. Медицинское приборостроение. 2020. Т. 10. № 3/4. – С. 8-28.
4. Myasnyankin, M.B. Neural network classifiers with descriptors obtained on the basis of analysis of the system rhythms in intellectual prediction systems for non-hospital pneumonia/ M.B. Myasnyankin, A.A. Kuzmin and S A Filist// Journal of Physics: Conference Series 1801 (2021) 012046, doi:10.1088/1742-6596/1801/1/012046.
5. Петрова, Т.В. Предикторы синхронности системных ритмов живых систем для классификаторов их функциональных состояний / Т.В. Петрова, С.А. Филист, С.В. Дегтярев, А.В. Киселев, О.В. Шаталова // Системный анализ и управление в биомедицинских системах. 2018. Т. 17. № 3. С. 693-700.
6. Филист, С.А. Универсальные сетевые модели для задач классификации биомедицинских данных / С.А. Филист, Р.А. Томакова, З.Д. Яа // Известия Юго-Западного государственного университета. – Курск: Изд-во ЮЗГУ, 2012. – №4(43). – Ч. 2. – С. 44-50.
7. Филист, С.А. Гибридная нейронная сеть с макрослоями для медицинских приложений / С.А. Филист, О.В. Шаталова, М.А. Ефремов // Нейрокомпьютеры. Разработка и применение. – 2014. – №6. – С. 35-39.

NEURAL NETWORK SYSTEM FOR EVALUATING THE RISK OF OUTSTANDING PNEUMONIA

Myasnyankin Maxim B., Kuzmin Alexander A., Philist Sergey A.

Southwest State University

305040, Russia, Kursk, st. 50 years of October, 94

SFilist@gmail.com

The article describes the development of a risk classifier for community-acquired pneumonia based on predictors generated by analyzing the of systemic rhythms of the cardiovascular system and the respiratory system and neural network modeling. Electrocardiosignals and electromyosignals are used as sources of systemic rhythms.

Keywords: community-acquired pneumonia, medical risk factors, systemic rhythms, neural network technologies, spectral characteristics of signals.

НЕЙРОСЕТЕВАЯ СИСТЕМА ОЦЕНКИ РИСКА РАЗВИТИЯ ИНСУЛЬТА

Корнилова Валерия Александровна

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15. valeriekornilova@gmail.com

В статье представлено описание разработанной нейросетевой системы для прогнозирования вероятности развития инсульта. Система позволяет провести быструю диагностику данного заболевания на основе малого количества входных параметров.

Ключевые слова: нейросетевые технологии, инсульт, прогнозирование, несбалансированные данные, keras.

Введение.

Пандемия COVID-19 унесла миллионы жизней по всему миру. Инфекционный агент показал не только повышенную агрессивность, но и свою способность влиять на частоту и тяжесть сердечнососудистых заболеваний населения. Последствия пандемии, считают медицинские работники, могут вызвать быстрый рост кардиологических болезней и смертей от них по всему миру [1]. Предупреждение развития инсульта представляется одной из важных клинических задач текущего времени, которое необходимо решать в условиях высокой загруженности специализированных стационаров и дефицита специалистов.

Эффективность использования искусственного интеллекта при оценке риска развития сердечнососудистых заболеваний была обоснована в работах [2-6]. Однако в них использовано достаточно большое количество входных параметров, что усложняет систему и увеличивает время затрачиваемое на формирование правильных прогнозов.

Целью данной работы является разработка модели, способной достаточно быстро и точно выявлять риск развития инсульта на основе малого количества входных параметров

Методика прогнозирования.

В современной медицине принято проводить классификацию инсульта по таким параметрам, как механизм нарушения кровообращения, причины, вызвавшие это нарушение и многим другим [7]. К основным факторам риска развития инсульта, которые можно рассматривать относительно всех видов данного заболевания, причисляют возраст, пол, курение, сахарный диабет (диагностируется на основании показателя среднего уровня глюкозы в крови), ожирение, заболевания сердца, стресс. Именно эти факторы будут использоваться для отбора признаков при построении нейронной сети.

Набор данных для обучения нейронной сети был взят с платформы Kaggle [8].

Перед переходом к проектированию и обучению модели, была выполнена очистка исходного множества от выбросов и пропущенных значений, произведено преобразование категориальных признаков в числовой формат.

Таким образом, для проектирования системы были использованы следующие входные параметры, оценивающие состояние диагностируемого:

X1 – пол (0 – женский, 1 – мужской) ,

X2 – возраст, лет,

X3 – наличие гипертонии (0 – нет, 1 – да),

X4 – наличие сердечнососудистых заболеваний (0 – нет, 1 – да),

X5 – факт вступления в брак (0 – не вступал(а) ранее, 1 – вступал(а)),

X6 – тип профессиональной деятельности (0 – гос. служба, 1 – отсутствие опыта работы, 2 – частный предприниматель, 3 – самозанятый, 4 -ребенок)

X7 – тип места проживания (0 – загородная территория, 1 – город),

X8 – средний уровень глюкозы в крови пациента, мг/дл,

X9 – ИМТ, кг/м²,

X10 – отношение к курению (0 – бросил(а) курить, 1 – никогда не курил(а), 2 – курит).

Целевая переменная: D1 – перенесен ли инсульт, – принимает значения от 0 до 1, соответствующие вероятности развития инсульта для диагностированного, представленной в десятичной форме.

Объем итогового множества для обучения включил в себя 5109 примеров. Анализ распределения целевой переменной исходного множества – факт перенесенного инсульта – показал, что исходное множество является несбалансированным: количество диагностируемых перенесших инсульт составляет всего около 5% от общего количества пациентов. Такая несбалансированность данных может оказать сильное влияние на корректность предсказаний нейронной сети. Проблема обучения на несбалансированных данных является достаточно распространенной темой для исследований последних лет [9]. Наличие данной проблемы было учтено при создании архитектуры нейронной сети.

Для обучения модели множество было разделено на обучающее, валидирующее и тестирующее в соотношении 70%, 20% и 10% соответственно.

Вся разработка модели происходила с помощью стандартных возможностей открытой нейросетевой библиотеки Keras. В результате оптимизации спроектированная нейронная сеть представляет собой четырехслойный персепtron, который имеет десять входных нейронов, по шестнадцать нейронов на скрытых слоях и один выходной нейрон. Для входного и скрытых слоев в качестве активационной была применена функция ReLU (Rectified Linear Unit) – положительная линейная функция активации, или жёсткий максимум [10]. В качестве активационной функции выходного слоя была применена сигмоидальная.

Во время обучения модели для взвешивания функции потерь ввиду несбалансированности исходного множества были заданы веса для каждого класса (класса людей, перенесших инсульт и избежавших данного заболевания).

Импользуемые веса представляют собой величины, обратно пропорциональные количеству вхождений в тестирующее множество элементов соответствующего класса.

Для определения корректности прогнозирования были использованы оценки: MSE (средняя квадратичная ошибка) и Recall (полнота – доля истинно положительных классификаций). На этапе обучения было истинно предсказано 90 % пациентов, перенесших инсульт, на этапе проверки – 89 %. Полученная средняя квадратичная ошибка обучения составила 11 %, а тестирования – 10 %, что можно считать приемлемым результатом, для малого количества входных параметров. Выборка из результатов тестирования нейронной сети представлена на рисунке 1.

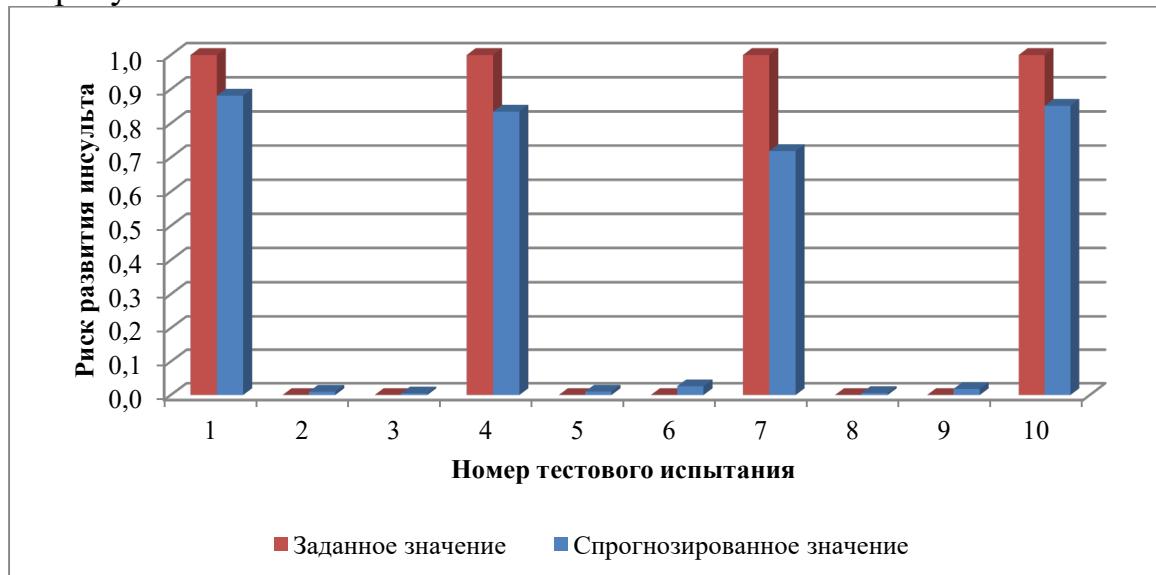


Рисунок 1. Результат тестирования нейронной сети

Экспериментальная часть

Оценка значимости входных параметров была рассчитана по методике [11]. Построенная данным способом гистограмма изображена на рисунке 2.

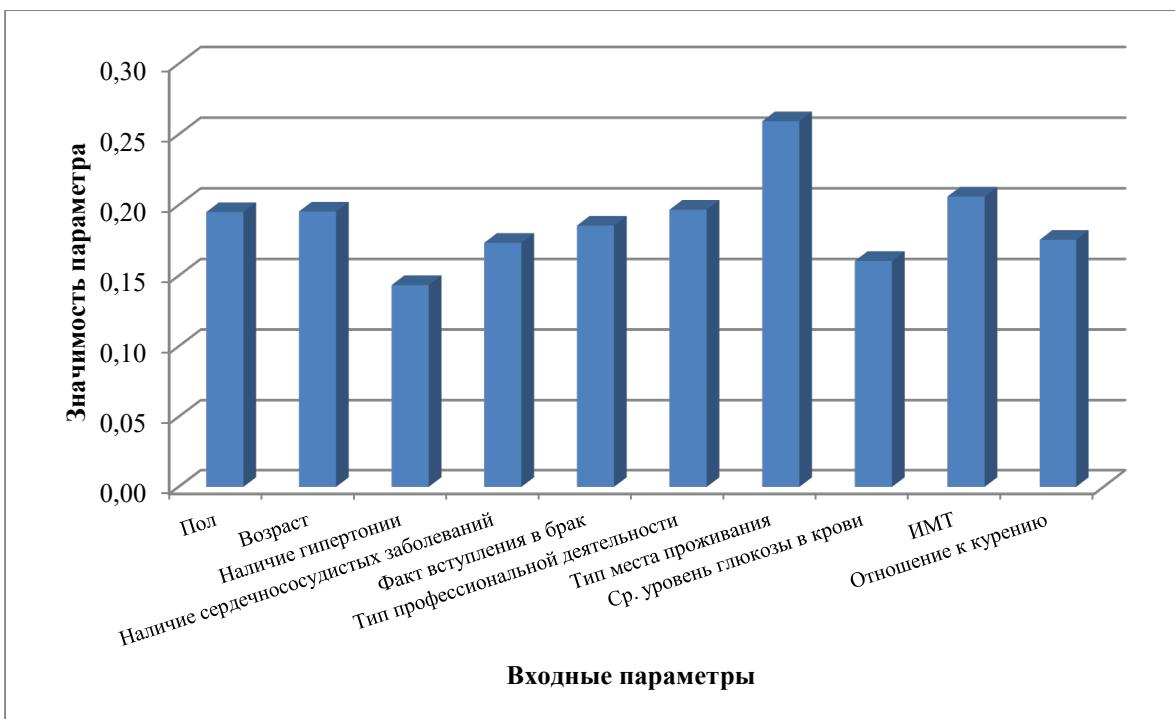


Рисунок 2. Значимость входных параметров нейронной сети

Как видно из рисунка 2, наиболее значимыми являются тип места проживания, пол, возраст и ИМТ.

Далее были проведены исследования влияния каждого входного параметра на риск развития инсульта. Для этого был использован метод «замораживания» [11], суть которого заключается в варьировании значения одного параметра и фиксировании значения всех остальных. Параметры пациента, взятого для исследований, приведены в таблице 1. В процессе исследования фиксировались значения, кроме анализируемого параметра и параметра, характеризующего возраст пациента, для определения зависимости влияния параметра на риск развития инсульта с возрастом. Результаты исследования отображены на рисунках 3 – 12. Графики, отображающие начальные параметры пациента отмечены красным цветом.

Таблица 1. Параметры исследуемого пациента

Пол	Возраст, лет	Наличие гипертонии	Наличие сердечнососудистых заболеваний	Факт вступления в брак	Тип профессиональной деятельности	Тип места проживания	Ср. кол-во глюкозы в крови, мг/дл	ИМТ, кг/м ²	Отношение к курению
Женщина	29	Нет	Нет	Вступала в брак	Частный предприниматель	Город	116,98	23,4	Никогда не курила

На рисунке 3 показан график влияния входного параметра «Возраст». Как следует из графика, вероятность инсульта резко растет в возрасте от семидесяти лет.

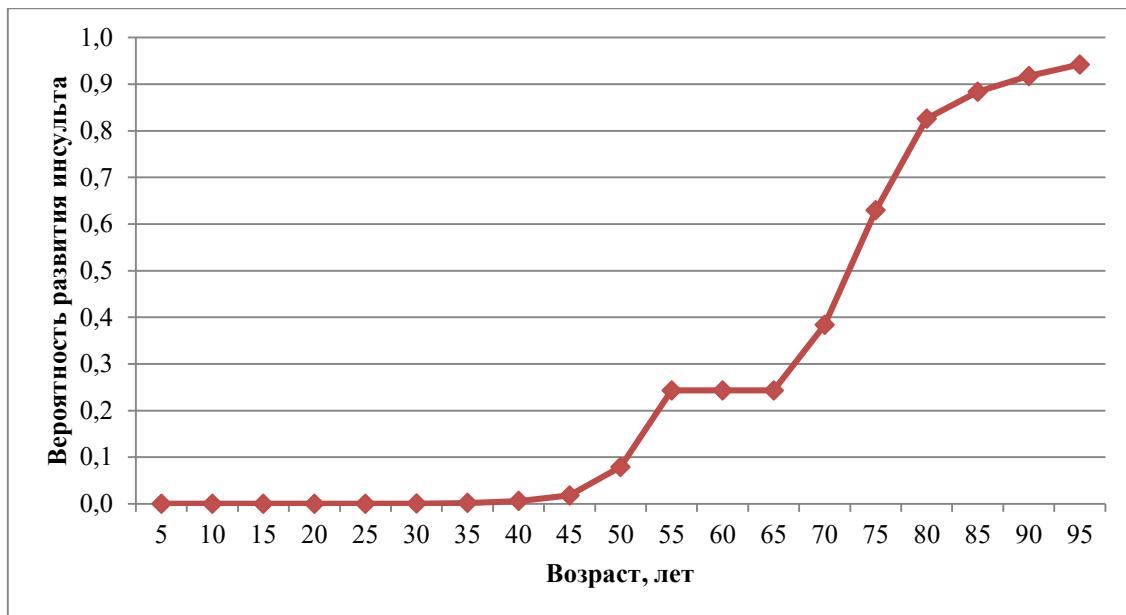


Рисунок 3. Влияние возраста

Из рисунка 4 видно, что наличие гипертонии у пациента увеличивает риск развития инсульта, что можно объяснить износом кровеносной системы.

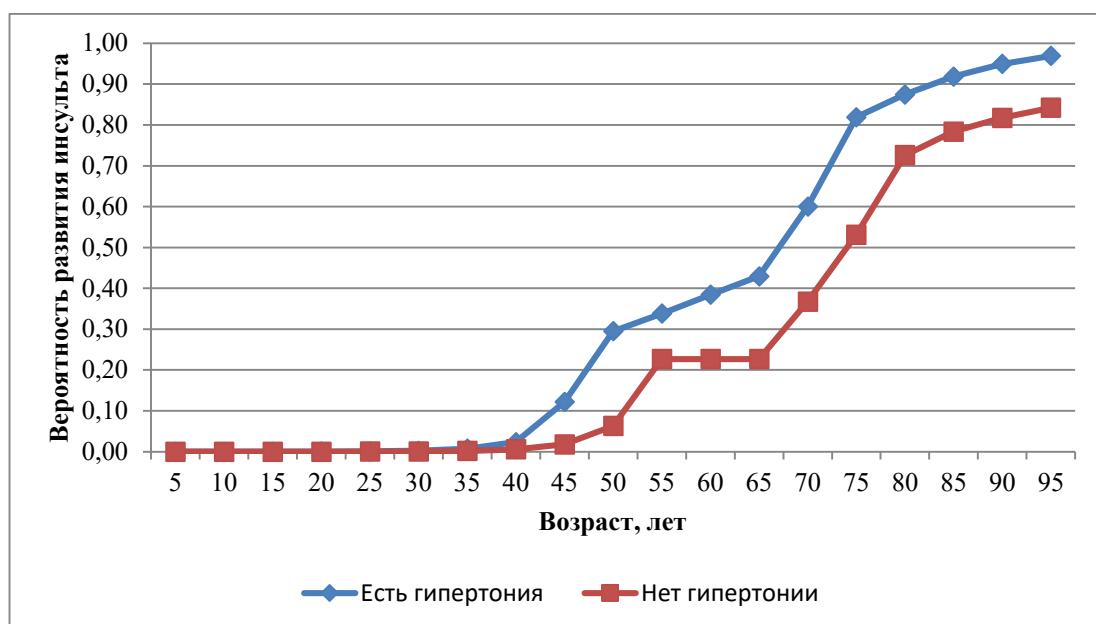


Рисунок 4. Влияния наличия гипертонии

Из рисунка 5 видно, что наличие сердечнососудистых заболеваний также оказывает влияние на вероятность развития инсульта.

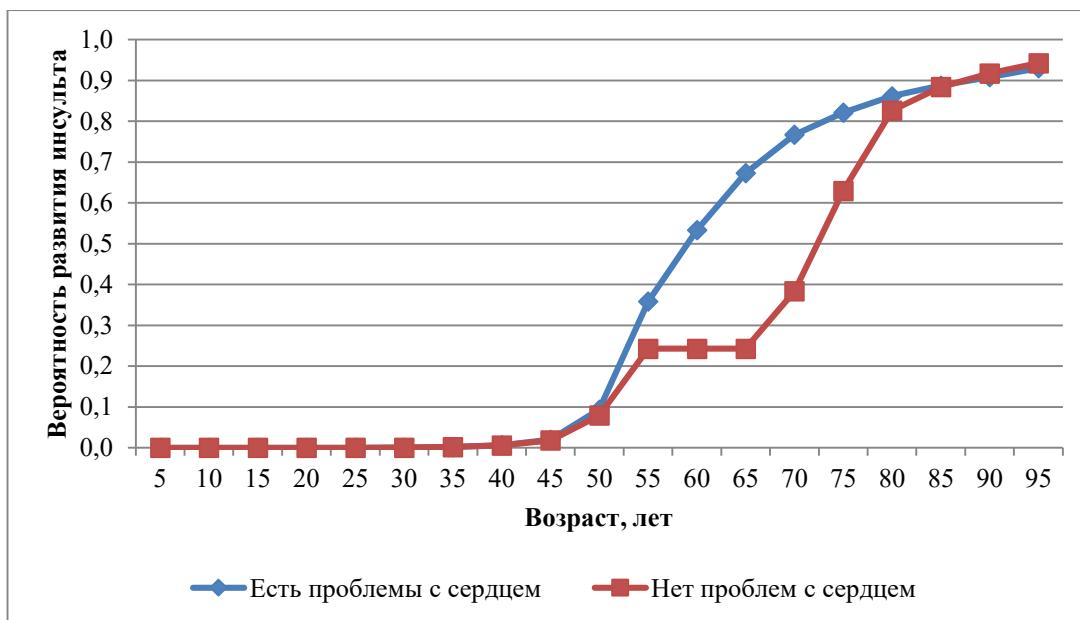


Рисунок 5. Влияния наличия сердечнососудистых заболеваний

Из рисунка 6 видно, что люди, состоявшие в браке, чаще страдают инсультом, чем не состоявшие в браке. Результат можно объяснить повышением уровня стресса и зависимостью данного показателя от возраста: чем старше человек, тем больше вероятность того, что ранее он вступал в брак.

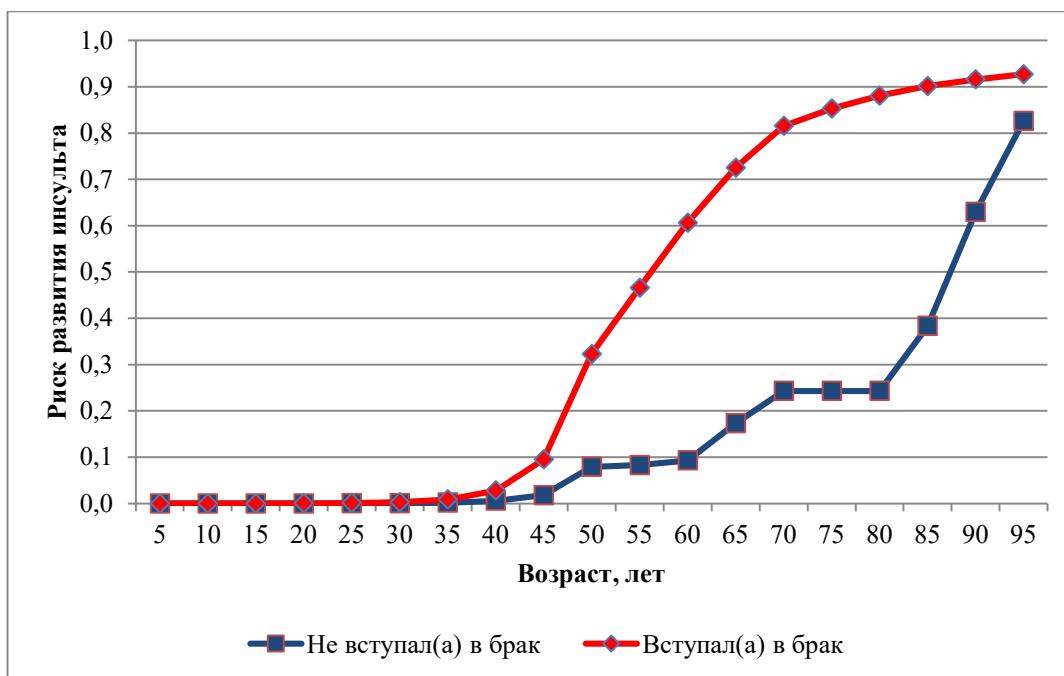


Рисунок 6. Влияния факта вступления в брак

Из рисунка 7 видно, что самозанятые больше подвержены инсульту, что можно объяснить повышенным уровнем стресса.

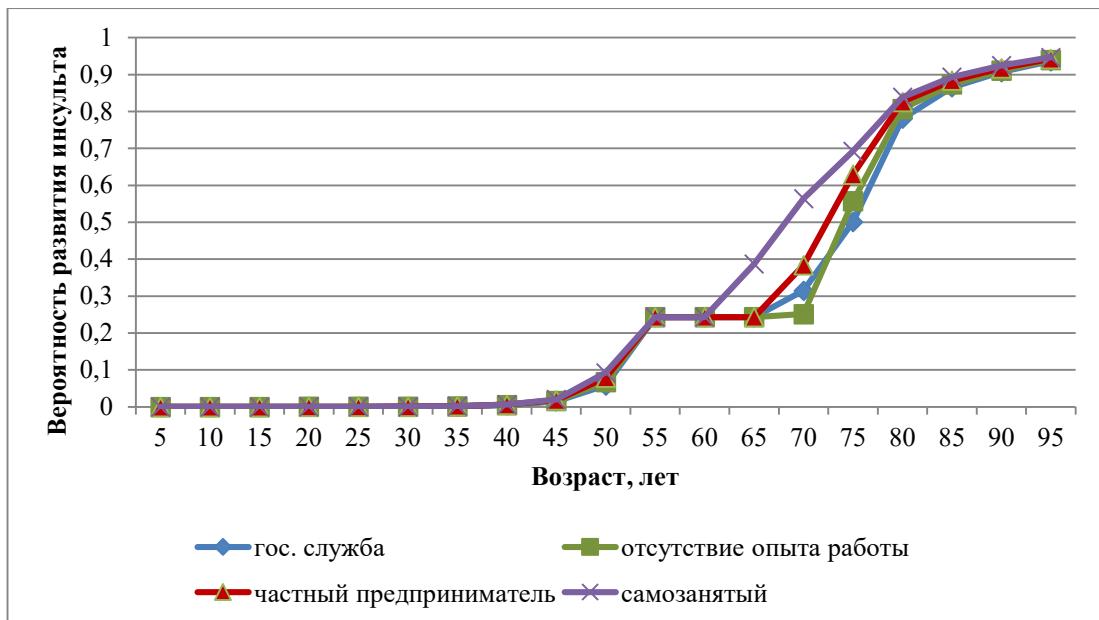


Рисунок 7. Влияния типа профессиональной деятельности

Из рисунка 8 видно, что люди, проживающие вне города, имеют больше вероятности заболевания инсультом, что можно объяснить плохим уровнем медицинского оснащения в сельской местности.

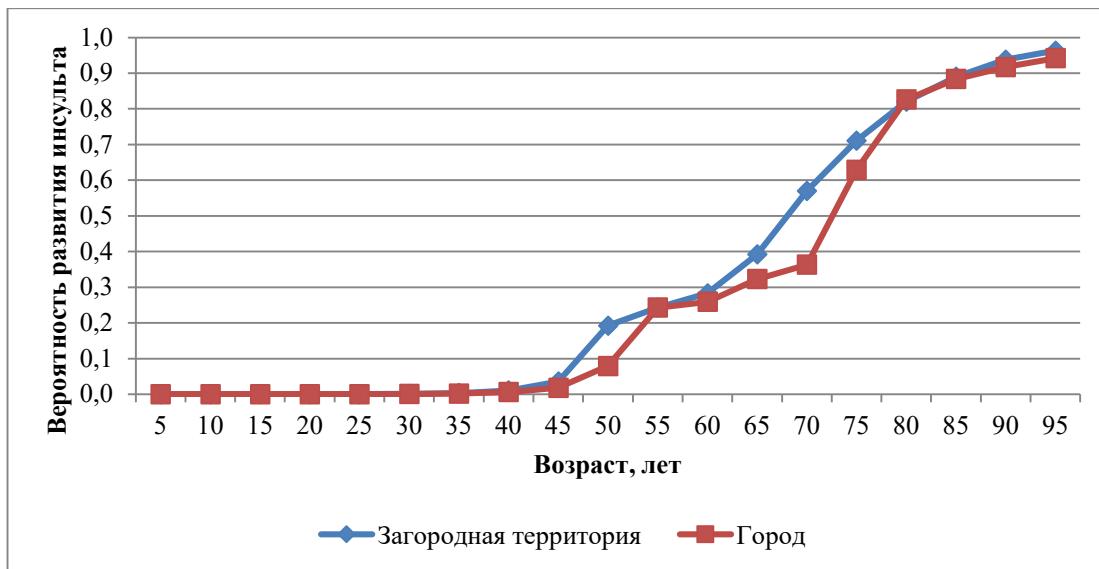


Рисунок 8. Влияния типа места проживания

Из рисунка 9 видно, что среднее количество глюкозы в крови оказывает прямое влияние на вероятность возникновения инсульта. Результат можно объяснить повышенным риском тромбоза у больных диабетом, что снижает приток крови к мозгу или полностью перекроет его.

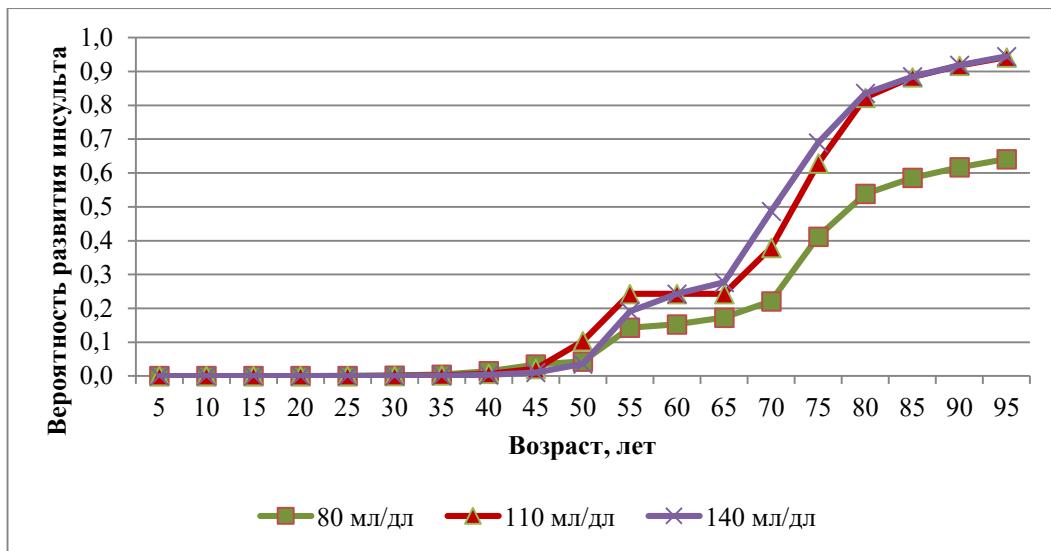


Рисунок 9. Влияния среднего уровня глюкозы в крови

Из рисунка 10 видно, что с увеличением ИМТ, риск развития инсульта увеличивается.

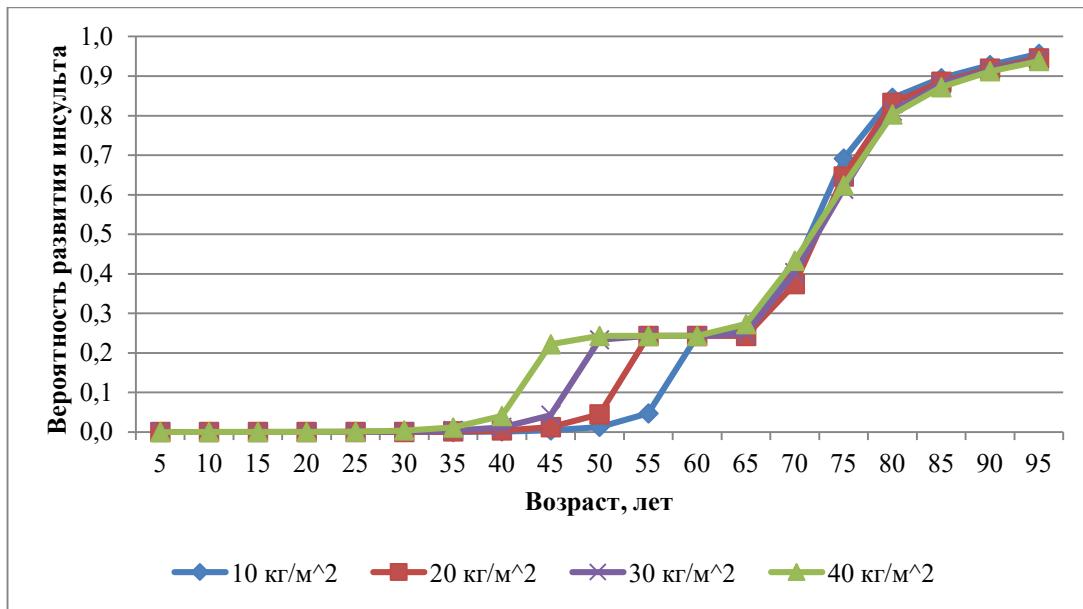


Рисунок 10. Влияния ИМТ

Из рисунка 11 видно, что курящие люди имеют повышенный риск возникновения инсульта в сравнении с некурящими.

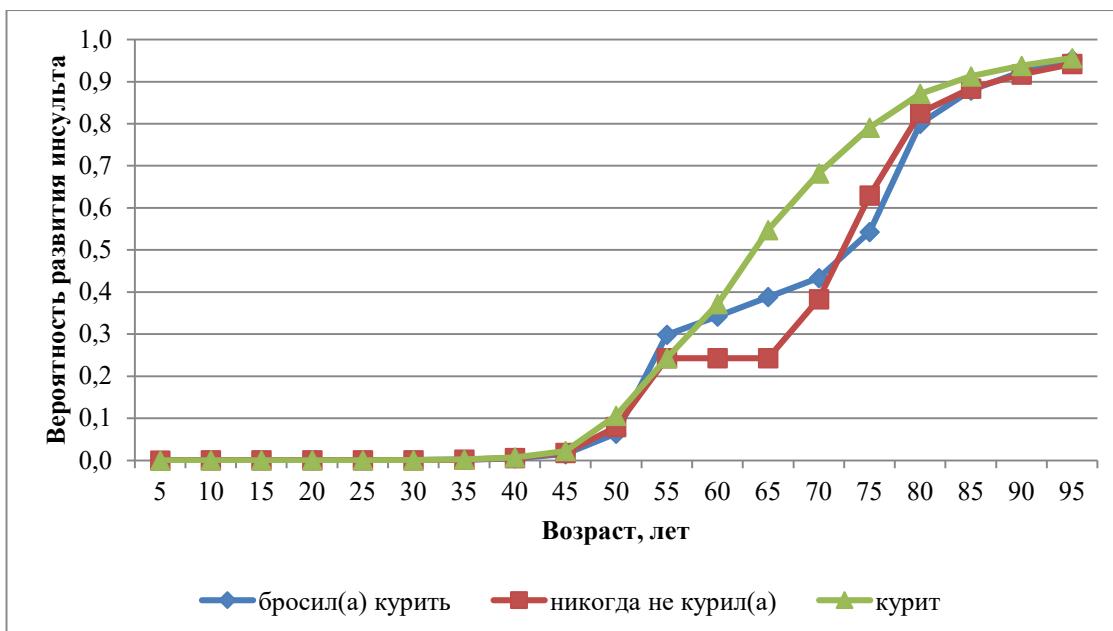


Рисунок 12. Влияния отношения к курению

Заключение. Построена система оценивания риска развития инсульта с помощью нейросети. Спроектированная нейросетевая модель обрабатывает параметры, характеризующие основные факторы риска наступления данного заболевания. Проведены результаты оценки значимости входных параметров на возникновение инсульта, выполнена оценка ошибки обучения и тестирования. Полученные значения оценки тестирования 20% являются следствием малого количества входных данных, что является и недостатком, и достоинством одновременно. Так, например, набор входных данных может формироваться из сервиса «Гос. Услуги» [9] с уведомлением пользователя.

Библиографический список

1. Circulation. 2021 Feb 23;143(8):e254-e743. doi: 10.1161/CIR.0000000000000950. Epub 2021 Jan 27.
2. Yasnitsky L.N., Dumler A.A., Cherepanov F.M. Dynamic artificial neural networks as basis for medicine revolution // Advances in Intelligent Systems and Computing. 2018. T. 850. C. 351-358.
3. Yasnitsky L.N., Dumler A., Cherepanov F.M. The capabilities of artificial intelligence to simulate the emergence and development of diseases, optimize prevention and treatment thereof, and identify new medical knowledge // Journal of Pharmaceutical Sciences and Research. 2018. T. 10. № 9. C. 2192-2200.
4. Yasnitsky L.N. Artificial Intelligence and Medicine: History, Current State, and Forecasts for the Future // Current Hypertension Reviews, 2020, vol. 16, No 3. Pp. 210-215. DOI : 10.2174/157340211666200714150953
<https://pubmed.ncbi.nlm.nih.gov/32664841/>

5. Ясницкий Л.Н., Думлер А.А., Полещук А.Н., Богданов К.В., Черепанов Ф.М. Нейросетевая система экспресс-диагностики сердечно-сосудистых заболеваний // Пермский медицинский журнал. 2011. Т. 28. № 4. С. 77-86.
6. Овчинкин О.В., Овчинкина Т.В., Павлов О.Г. Персональное моделирование заболеваний сердечнососудистой системы с применением нейронных сетей и инструментальных средств // Вестник новых медицинских наук. 2011. №4. С. 41.
7. Фадеев П.А. Инсульт. М.: Мир и Образование, Оникс, 2008. – 20 с.
8. Kaggle – Stroke Prediction Dataset. [Электронный ресурс] [Режим доступа: <https://www.kaggle.com/fedesoriano/stroke-prediction-dataset>] [Проверено: 6.04.2021].
9. He H., Garcia A. Learning from Imbalanced Data // IEEE transactions on knowledge and data engineering, vol. 21, no. 9, September 2009. – Р. 1263-1284.
10. Жерон О. Прикладное машинное обучение с помощью Scikit-Learn и TensorFlow. Концепции, инструменты и техники для создания интеллектуальных систем. – СПб.: ООО «Альфа-книги», 2018. – 688 с.
11. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.
12. Портал государственных услуг Российской Федерации [Электронный ресурс] [Режим доступа: <https://www.gosuslugi.ru/>] [Проверено: 6.04.2021].

**NEURAL NETWORK SYSTEM FOR ASSESSING THE RISK OF
PRIMARY STROKE**
Kornilova Valeria A.

Perm State National Research University,
614990, Russia, Perm, Bukireva str., 15

The article describes the development of a neural network system for predicting the probability of a primary stroke. The system allows you to quickly diagnose this disease based on a small number of input parameters.

Keywords: artificial intelligence, neural network technologies, stroke, forecasting.

ИСКУССТВЕННЫЕ НЕЙРОННЫЕ СЕТИ ЗАДАЧЕ ВЫЯВЛЕНИЯ ПАЦИЕНТОВ ГРУППЫ РИСКА РАКА МОЛОЧНОЙ ЖЕЛЕЗЫ

Лосев Александр Георгиевич, Петренко Александр Юрьевич

Волгоградский государственный университет,
400062, Россия, г. Волгоград, пр-т. Университетский, 100,
alexander.losev@volsu.ru, petrenko.alexandex.kmk@gmail.com

В статье описан опыт разработки и применения нейронной сети для выявления группы риска рака молочной железы данных микроволновой радиотермометрии и анамнеза. Доказана высокая эффективность использования искусственных нейронных сетей в задаче ранней диагностики рака молочной железы.

Ключевые слова: микроволновая термометрия, интеллектуальный анализ данных, нейронная сеть.

В данный момент рак молочной железы является наиболее распространённым онкологическим заболеванием среди женщин. Для повышения выживаемости вполне очевидным представляется решение задачи раннего выявления данного заболевания. Одним из наиболее перспективных для повышения эффективности ранней диагностики рака молочной железы является метод микроволновой радиотермометрии [1]. Он основан на измерении собственного электромагнитного излучения тканей человека в микроволновом диапазоне длин волн и инфракрасном диапазоне, что позволяет неинвазивно измерять температуру и на коже, и внутри тела.

В результате обследования, которое включает в себя измерение температур в 22-х точках в инфракрасном и микроволновом диапазонах, заключение строиться по степени выраженности температурных аномалий с описанием проблемных областей. Возможность и целесообразность использования данного метода медицинского обследования в задаче диагностики рака молочной железы объясняется тем фактом, что уже на этапе, предшествующем злокачественному росту, происходит локальное повышение внутренней температуры. Таким образом, метод микроволновой радиотермометрии в состоянии обеспечить высокую точность в решении задачи раннего выявления злокачественных новообразований.

Все радиотермометрические (РТМ) заключения можно разделить на шесть групп по уровню выраженности тепловых процессов (УВТП).

- Th0 (УВТП-0) – Тепловые изменения не выявлены;

- Th1 (УВТП-1) – Характерных признаков рака молочной железы не выявлено, но на фоне умеренно выраженных тепловых изменений, имеется участок понижения температуры;
- Th2 (УВТП-2) – Характерных признаков рака молочной железы не выявлено, но на фоне умеренно выраженных тепловых изменений, имеется участок повышения температуры;
- Th3 (УВТП-3) – Группа риска;
- Th4 (УВТП-4) – Подозрение на рак;
- Th5 (УВТП-5) – Термограмма характерная для заболевания (острое воспаление, рак);

В данной работе проводится бинарная классификациях молочных желёз с классами «Здоровая» и «Группа риска». К классу «Здоровая» были отнесены молочные железы, помеченные в заключение, как Th0, Th1, Th2, а к классу «Группа риска» отнесены остальные молочные железы, то есть Th3, Th4, Th5. Причина такого деления заключается в том, предлагаемый метод прежде всего предполагается использовать при скрининге, а главной целью в таком случае является вовремя обнаружить аномалии УВТП-3, УВТП-4 и УВТП-5, характерные для группы риска и подозрениям на рак, для направления пациента на более глубокое обследование.

База термометрических данных содержит в себе записи пациентов, предоставленных онкологическими центрами. В ней содержатся данные разных измерительных сенсоров, но для решения задачи используется только совмещённый датчик, так как ранние исследования показали, что измерения, полученные разными датчиками, для обучения моделей машинного обучения нельзя объединять из-за неоднородности данных [2]. Также почти по всех онкологических центрах в настояще время используется совмещённых сенсор.

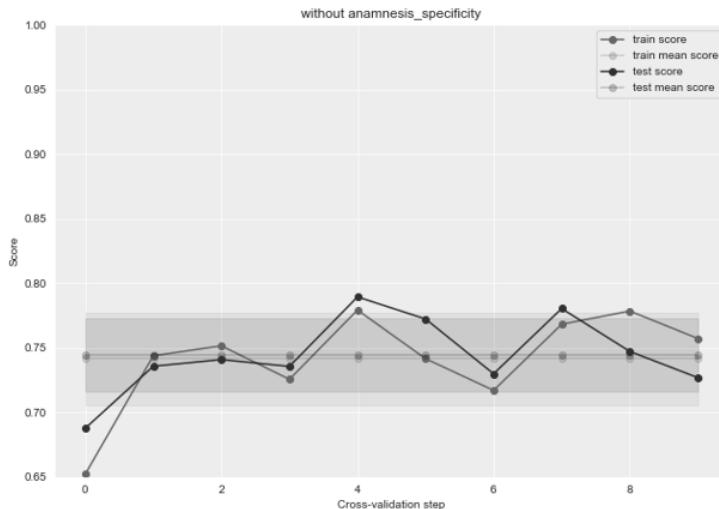
В результате, используемый фрагменте базы содержит 9184 записи о молочных железах, из них 8587 класса «Здоровые» и 597 класса «Группа риска». Каждая запись содержит вектор из 44-х температур, возраст на момент обследования, информацию о телосложении и информацию о жалобах на боли.

Анализ проводится не просто по температурам молочной железы, а с использованием предварительного преобразования, результатом которого является математическая дескриптивная модель диагностического состояния пациента. Составными частями данной модели являются термометрические характеристики, иначе называемые моделирующими функциями. Всего используется 62 моделирующие функции [3], каждая из них соответствует некоторым гипотезам поведения температурных полей молочных желёз. Анализ полученного за последнее десятилетие опыта применения методов машинного обучения в задачах диагностики по термометрическим данным показал, что такой подход позволяет увеличить эффективность классификации, в отличие от использования исключительно температурных данных (см., например, [4]).

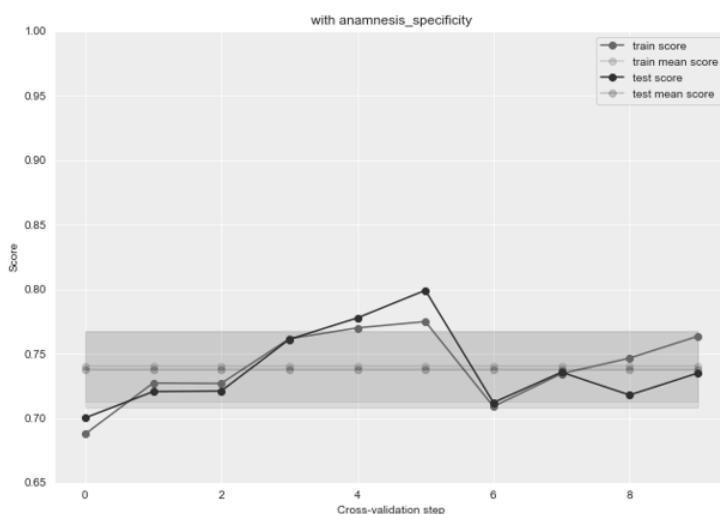
Входными данными для нейронной сети является вектор из значений 62-х моделирующих, категории возраста, категории комплексии и категории жалоб на боли. Категории делятся следующим образом:

- Категории возраста: младше 35 лет, 35-45 лет, старше 45 лет;
- Категории комплекции: очень худая, худая, нормальная, полная, очень полная;
- Категории жалоб на боли: жалоб нет, жалобы есть.

Стоит уточнить, что использование данных анамнеза (возраста, комплекции, жалоб на боли) не дают прироста метрик, но позволяют улучшить обобщающие свойства модели, понижая стандартное отклонение специфичности на тестовых выборках при кросс-валидации, что продемонстрировано на рисунках 1 и 2.



**Рисунок 1. Результаты кросс-валидации
без использования данных анамнеза**



**Рисунок 2. Результаты кросс-валидации
с использованием данных анамнеза**

Данное уточнение несколько противоречит результатами из данной статьи [4], где использование данных анамнеза давало прирост эффективности порядка 3%. Но в указанной статье рассматривалась задача классификации со здоровыми и пациентами больными раком, что является несколько более простой задачей со стороны структуры обрабатываемых данных.

По результатам численных экспериментов была получена архитектура нейронной сети, изображённая на рисунке 3. Также в таблице 1 представлены гиперпараметры модели; у всех dropout слоёв одинаковые гиперпараметры, функция активации так же одинакова для входного и всех dense слоёв.

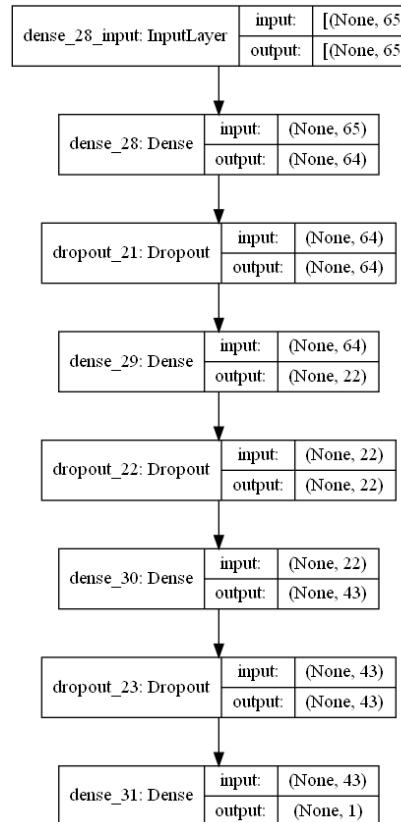


Рисунок 3. Архитектура нейронной сети

Таблица 1. Гиперпараметры нейронной сети

Гиперпараметр	Значение
Dropout	0.25
Размер пакета для одной эпохи	512
Оптимизатор	Adam с размером шага 0.001
Функция потерь	Бинарная кросс энтропия
Функция активации	Сигмоида

Так как выборка является скошенной для компенсации большего количества записей из группы «Здоровая», использовались веса для классов. Выбор весов является одним из гиперпараметров, с помощью которого можно решать немного разные задачи. Указав, веса в виде долей классов в выборке, «важность» обоих классов можно сравнять, но при этом мы можем завысить вес класса «Группа риска», чтобы повысить чувствительность. Используя такой подход точность выявления пациентов, которых нужно направить на дополнительные

обследования, хотя при этом точность выявления здоровых пациентов несколько снизится. Но, исходя из задачи, важнее не пропустить потенциально больного человека, чем некорректно назвать здорового больным.

Итоговые результаты исследования представлены в таблице 2, где Sens – чувствительность, Spec – специфичность, Gmean – среднее геометрическое чувствительности и специфичности, mean – среднее значение метрики на тестовых выборках при перекрёстной проверке, а std – стандартное отклонение. Веса представлены в виде «<вес класса «Здоровая»;<вес класса «Группа риска»»

Таблица 2. Результаты классификации

Веса	Sens		Spec		Gmean	
	mean	std	mean	std	mean	std
0,065;0,935	0,92	0,03	0,9	0,016	0,909	0,011
0,005;0,995	0,98	0,014	0,749	0,032	0,856	0,017

Исследование выполнено при финансовой поддержке РФФИ, проект «Математические модели радиационных полей и анализа данных микроволновой радиотермометрии в ранней диагностике рака молочных желез» № 19-01-00358.

Библиографический список

1. Vesnin, S., Turnbull, A.K., Dixon, J.M., Goryanin, I. Modern Microwave Thermometry for Breast Cancer. // Journal of Molecular Imaging & Dynamics. 2017. V. 7. Is. 2. DOI: 10.4172/2155-9937.1000136
2. Мазепа Е.А., Дубовская В.И. Пространство термометрических признаков в задаче диагностики рака молочной железы. // Современная наука и инновации. – 2019.- N 4(28). – С. 39-50.
3. Levshinskii V.V., Mathematical models for analyzing and interpreting microwave radiometry data in medical diagnosis //Journal of Computational and Engineering Mathematics. 2021. V. 8. No 1. pp. 3-14.
4. Losev A.G., Medvedev D.A., Svetlov A.V. Neural Networks in Diagnosis of Breast Cancer // Lecture Notes in Networks and Systems. – 2021. – 155. – p. 220-227.

ARTIFICIAL NEURAL NETWORKS FOR THE PROBLEM OF DETECTING PATIENTS AT RISK GROUP OF BREAST CANCER

Losev Alexander G., Petrenko Alexander Y.

Volgograd State University,

400062, Russia, Volgograd, ave Universitetskiy, 100,

alexander.losev@volsu.ru, petrenko.alexandex.kmk@gmail.com

The article describes the experience in the development and application of a neural network for identifying a breast cancer risk group using microwave radiometry data and anamnesis. The high efficiency of using artificial neural networks in the problem of early diagnosis of breast cancer has been proven.

Keywords: microwave thermometry, data mining, neural network.

ПРОГНОЗИРОВАНИЕ ИНСУЛЬТА МЕТОДОМ НЕЙРОСЕТЕВОГО МОДЕЛИРОВАНИЯ

Чирихин Дмитрий Александрович, Чунарев Никита Михайлович

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15, chiruhind@gmail.com

В статье представлено описание разработки нейросетевой системы для прогнозирования инсульта. Система позволяет прогнозировать вероятность инсульта у человека по его физиологическим показателям и индивидуальным характеристикам. Был проведен ряд исследований, результаты которых приводятся в данной статье.

Ключевые слова: искусственный интеллект, нейросетевые технологии, инсульт, прогнозирование, закономерности.

Введение. Инсульт является второй ведущей причиной смертности, на которую приходится 11% от общего числа смертей в мире. В России смертность от инсульта – одна из самых высоких в мире. На ее долю приходится 175 смертей на каждые 100 тысяч человек. Инсульт возникает у тех, кто даже не подозревал, что находится в группе риска. Однако профилактика помогает предотвратить до 80% инсультов. Исследования в области прогнозирования заболеваний сердечно-сосудистой системы и инсульта методами искусственного интеллекта существуют давно и продолжают активно проводиться [1-3], в частностями, представителями Пермской научной школы искусственного интеллекта [4-8].

Основная цель настоящей работы заключается в обработке и отборе данных из датасета [9] и обучение нейросетевой модели данных.

В результате анализа набора данных были выделены следующие параметры, влияющие на возникновение инсульта:

- x_1 – Пол
- x_2 – Возраст
- x_3 – Гипертония
- x_4 – Болезни сердца
- x_5 – Брак
- x_6 – Сфера деятельности
- x_7 – Место проживания
- x_8 – Средний уровень глюкозы в крови
- x_9 – Индекс массы тела
- x_{10} – Курение

Среди входных параметров модели имеются качественные и количественные факторы. Качественные были зашифрованы следующим образом: «Пол»: мужчина – 0, женщина – 1; «Гипертония»: нет – 0, есть – 1;

«Болезни сердца»: нет – 0, есть – 1; «Брак»: не был в браке – 0, был в браке – 1; «Сфера деятельности»: ребенок – 0, самозанятый – 1, государственный служащий – 2, не работает – 3, частный – 4; «Место проживания»: город – 0, вне города – 1; «Курение»: раньше курил – 0, сейчас курит – 1, никогда не курил – 2. Количественные показатели «Возраст», «Средний уровень глюкозы в крови» и «Индекс массы тела» представляют собой целые и действительные числа.

На выходе нейронная сеть выдает вероятность инсульта значением от 0 до 1.

Проектирование, обучение и тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [10]. В результате оптимизации спроектированная нейронная сеть представляет собой трехслойный персептрон, который имеет десять входных нейронов, девять нейронов на первом скрытом слое, пять нейронов на втором скрытом слое и один выходной нейрон. На рисунке 1 представлено графическое представление данной нейронной сети.

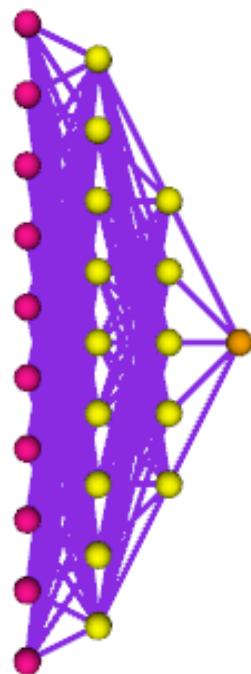


Рисунок 4. Графическое представление нейронной сети

После выборки и избавления от выбросов и конфликтных примеров, общий объем полученного множества составил 302 примера, которые были разделены на обучающее и тестирующее в соотношении 82% и 18% соответственно.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 53 примеров. Средняя ошибка тестирования составила 18,1%, что можно считать удовлетворительным результатом для медицинского прогнозирования. На рисунке 2 представлена гистограмма с результатами тестирования.



Рисунок 5. Результат тестирования нейросетевой модели

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5». На рисунке 3 изображен результат оценки.

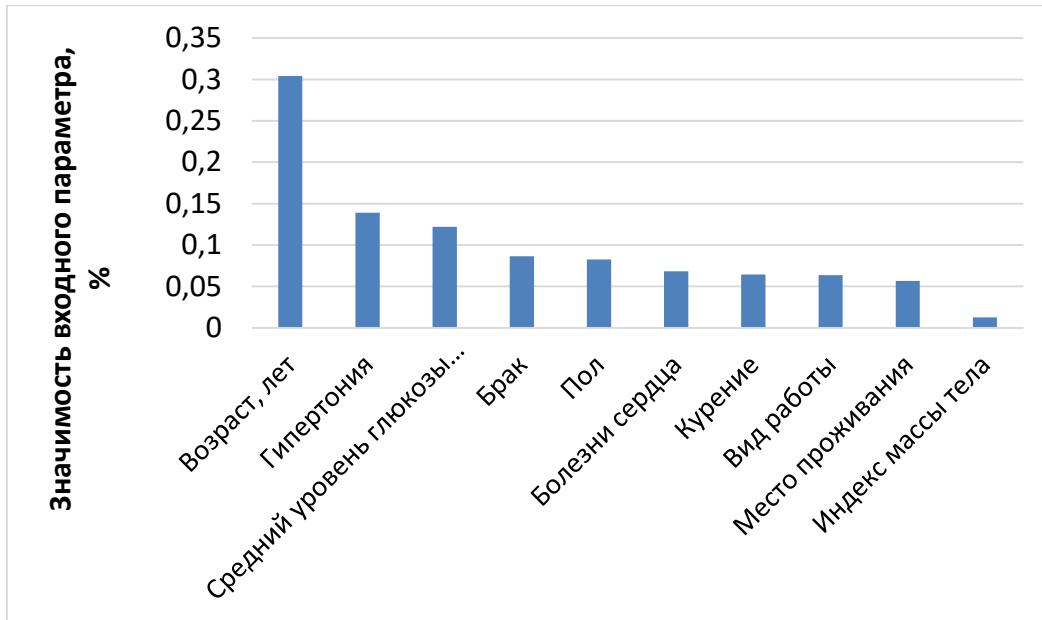


Рисунок 6. Значимость входных параметров нейросетевой модели

Как видно из рисунка 3, наиболее значимым параметром является возраст.

Далее были проведены исследования влияния каждого входного параметра с возрастом. Для этого был использован метод «замораживания» [6], суть которого заключается в варьировании значения одного параметра и фиксировании значения всех остальных. Параметры пациента, взятого для исследований приведены в таблице 1. Графики, отображающие его изначальные параметры, на рисунках 4 – 12 отмечены красным цветом.

Таблица 1. Параметры исследуемого пациента

Пол	Возраст, лет	Гипертония	Болезни сердца	Брак	Сфера деятельности	Место жительства	Количество глюкозы в крови, мг/дл	Индекс массы	Курение
Мужчина	35	Нет	Есть	Не был в браке	Само-занятый	Город	195,23	28,3	Курит

На рисунке 4 показан график влияния входного параметра «Возраст». Как следует из графика, вероятность инсульта резко растет в возрасте от пятидесяти до шестидесяти лет.

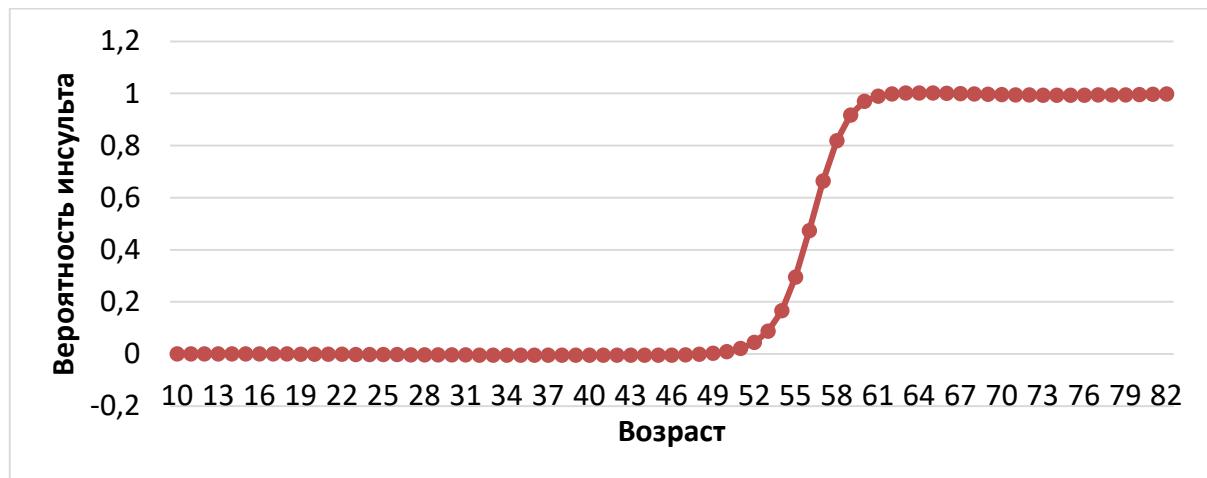


Рисунок 7 – Влияние возраста

На рисунках 5-12 изображены графики изменения влияния остальных входных параметров с возрастом.

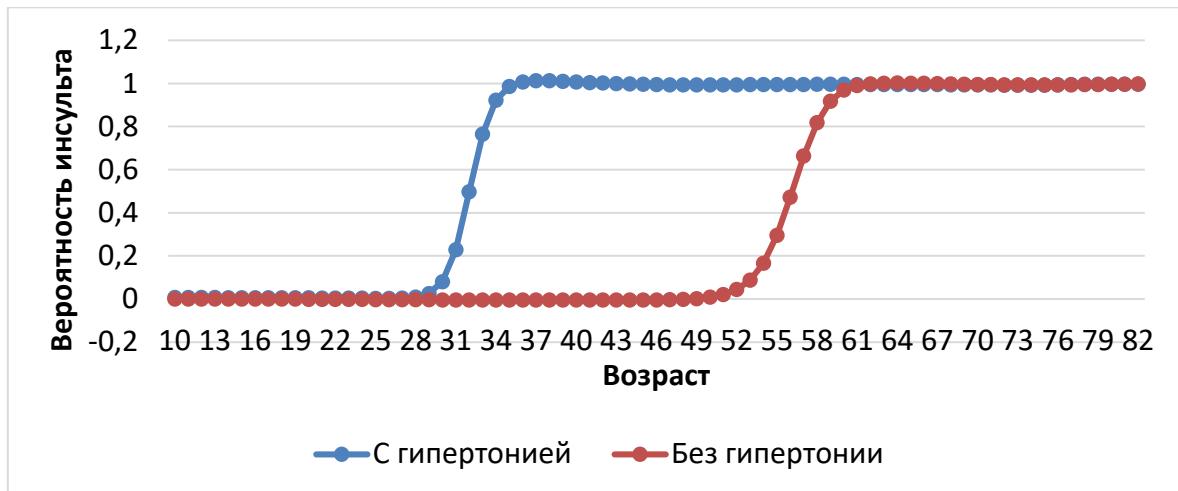


Рисунок 8 – Влияния гипертонии

Из рисунка 5 видно, что наличие гипертонии у пациента оказывает прямое влияние на возникновение инсульта, что можно объяснить износом кровеносной системы.

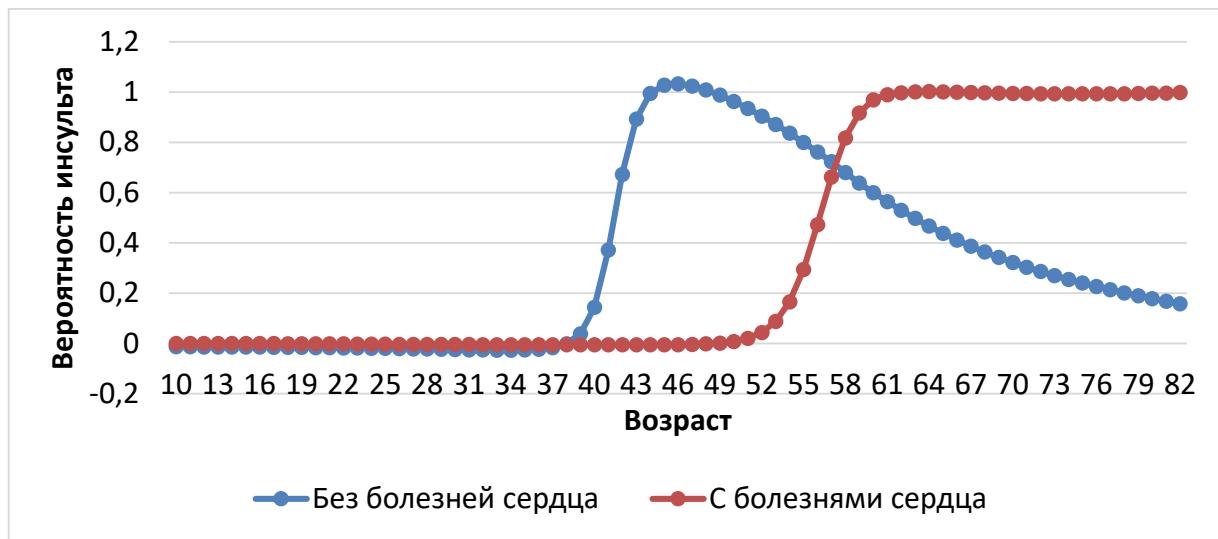


Рисунок 9 – Влияния болезней сердца

Из рисунка 6 видно, что у людей без болезней сердца инсульт может возникнуть раньше, чем у людей с такими болезнями. Результат можно объяснить тем, что люди с болезнями сердца чаще посещают кардиолога или состоят на учёте и получают необходимую помощь.

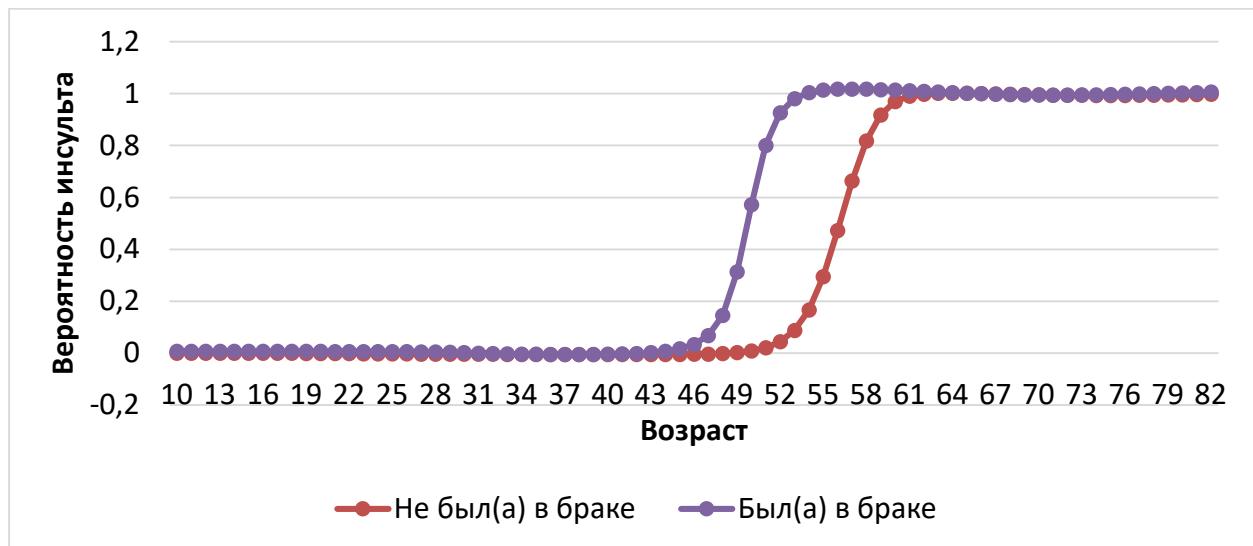


Рисунок 10 – Влияния брака

Из рисунка 7 видно, что люди, состоявшие в браке немного, раньше начинают страдать от инсультов, чем не состоявшие в браке. Результат можно объяснить повышением уровня стресса.

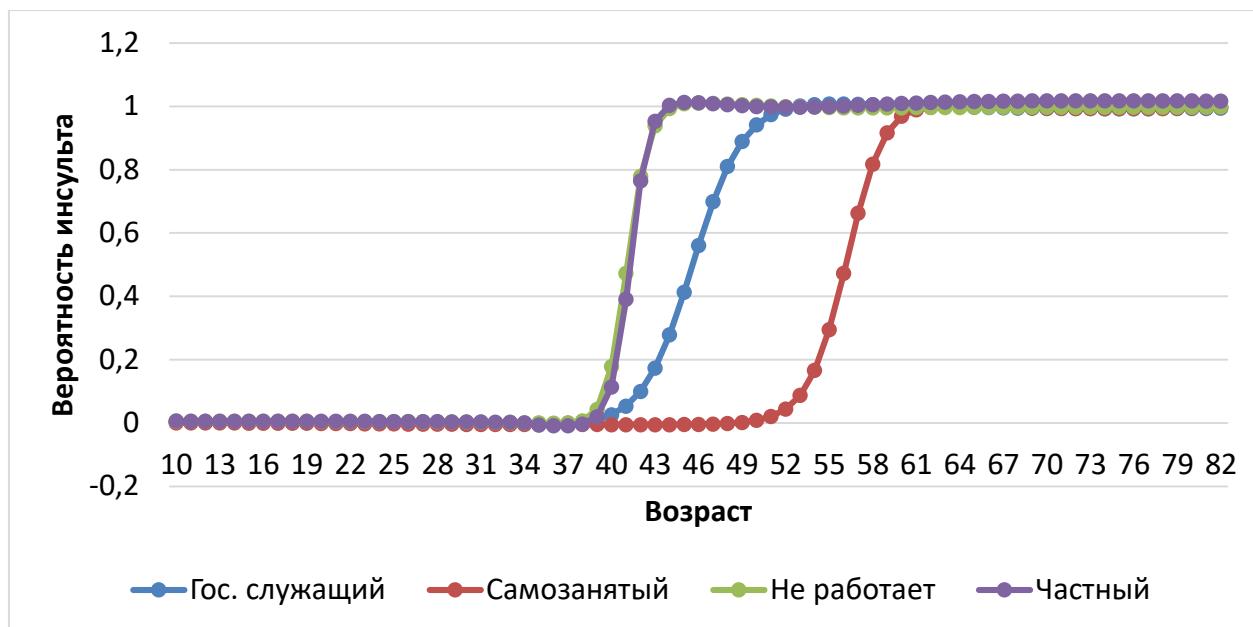


Рисунок 11 – Влияния рабочей области

Из рисунка 8 видно, что люди, работающие в частных компаниях, государственные служащие и безработные, начинают страдать от инсультов в одно время, но вероятность нарастает с разной интенсивностью. Самозанятые начинают страдать от инсультов значительно позднее. Результат можно объяснить различными уровнями стресса, ответственности, стабильности и отчётности на различных рабочих местах.

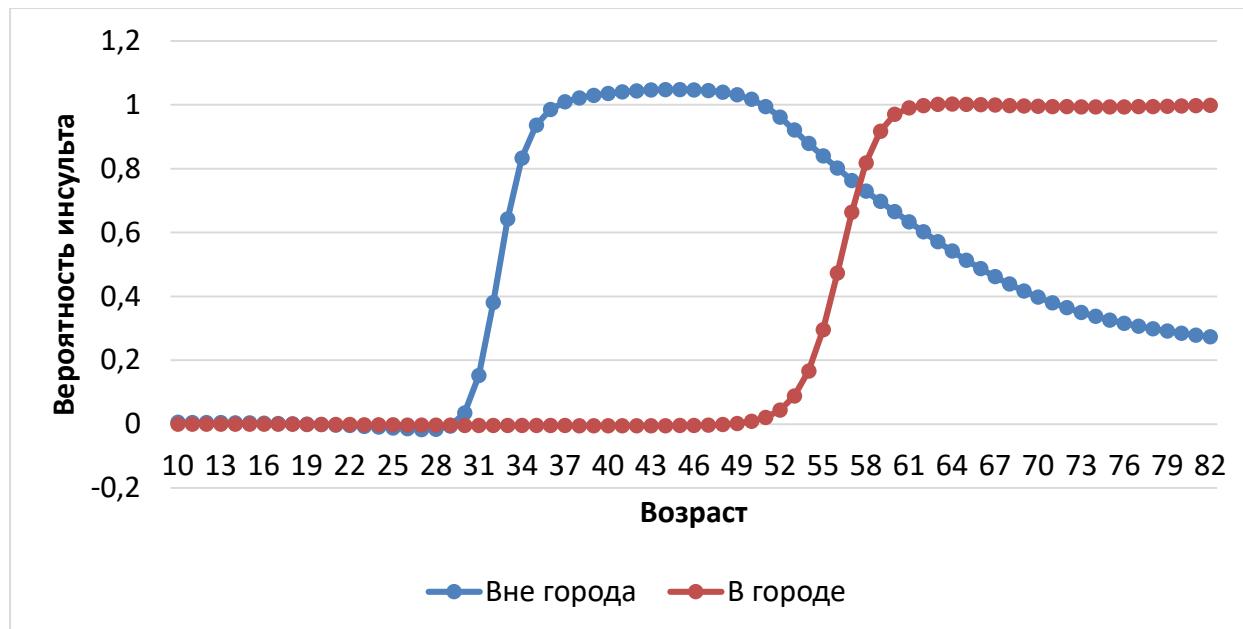


Рисунок 12 – Влияния места жительства

Из рисунка 9 видно, что люди, проживающие вне города, начинают страдать от инсультов значительно раньше городских жителей, что можно объяснить плохим уровнем медицинского оснащения в сельской местности.

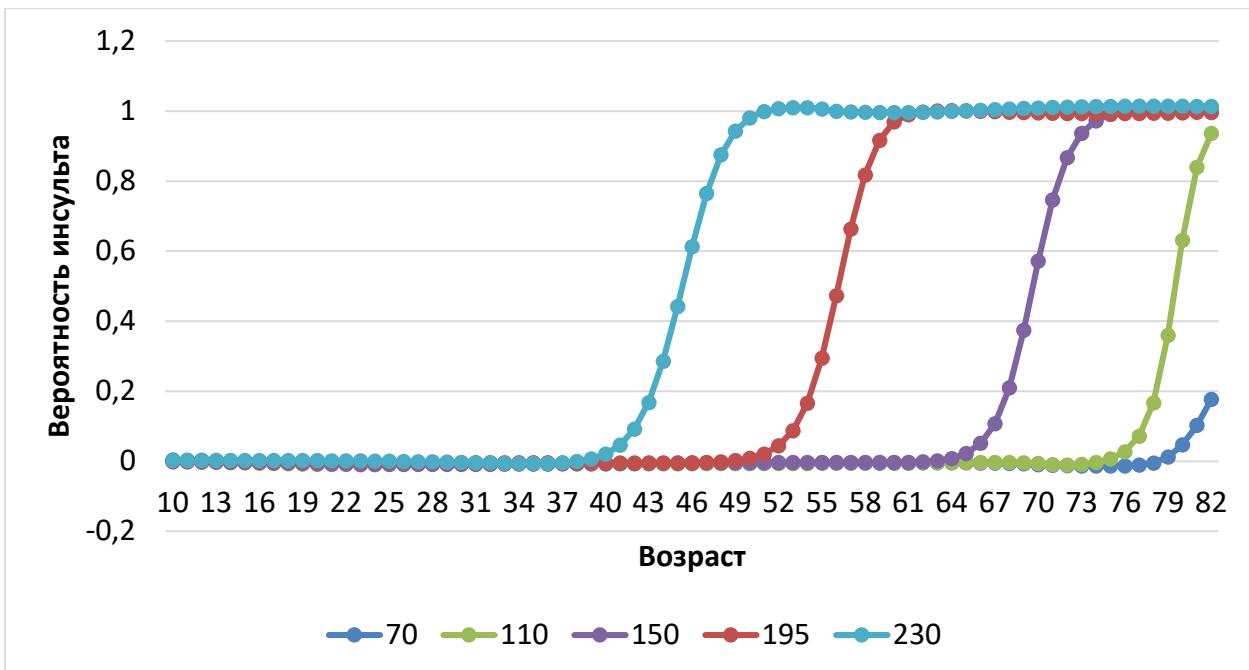


Рисунок 13 – Влияния среднего количества глюкозы в крови

Из рисунка 10 видно, что среднее количество глюкозы в крови оказывает прямое влияние на вероятность возникновения инсульта. Результат можно объяснить повышенным риском тромбоза у больных диабетом, что снижает приток крови к мозгу или полностью перекроет его.

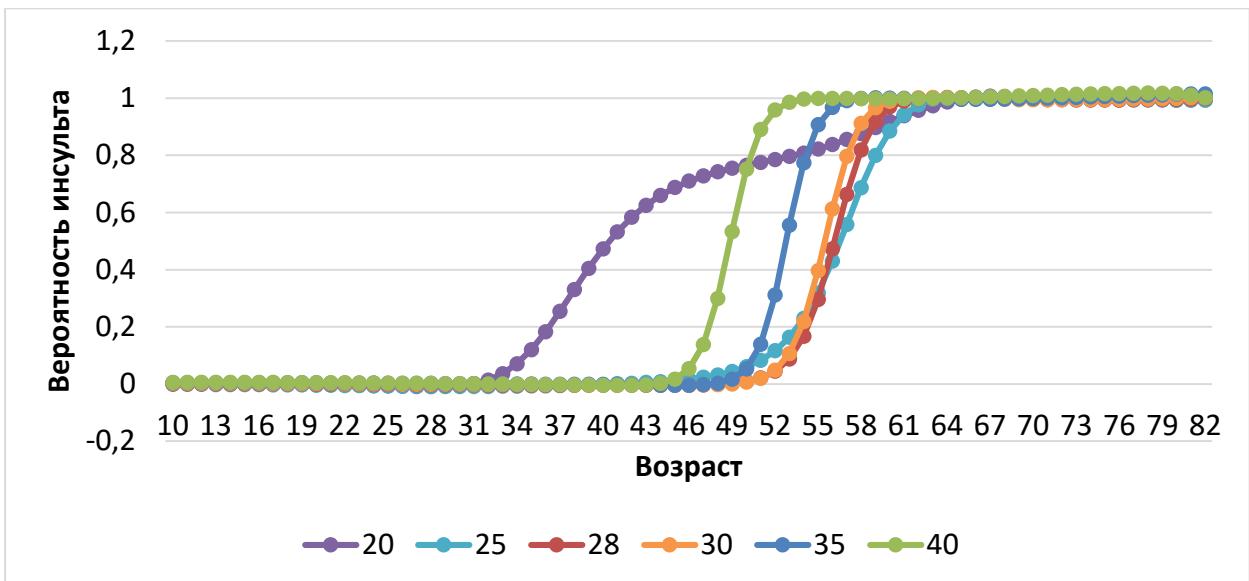


Рисунок 14 – Влияния индекса массы тел

Из рисунка 11 видно, что люди, имеющие переизбыток или недостаток веса, больше подвержены возникновению инсульта. Результат можно объяснить тем, что при отклонении массы тела от рекомендуемой, повышается кровеносное давление.

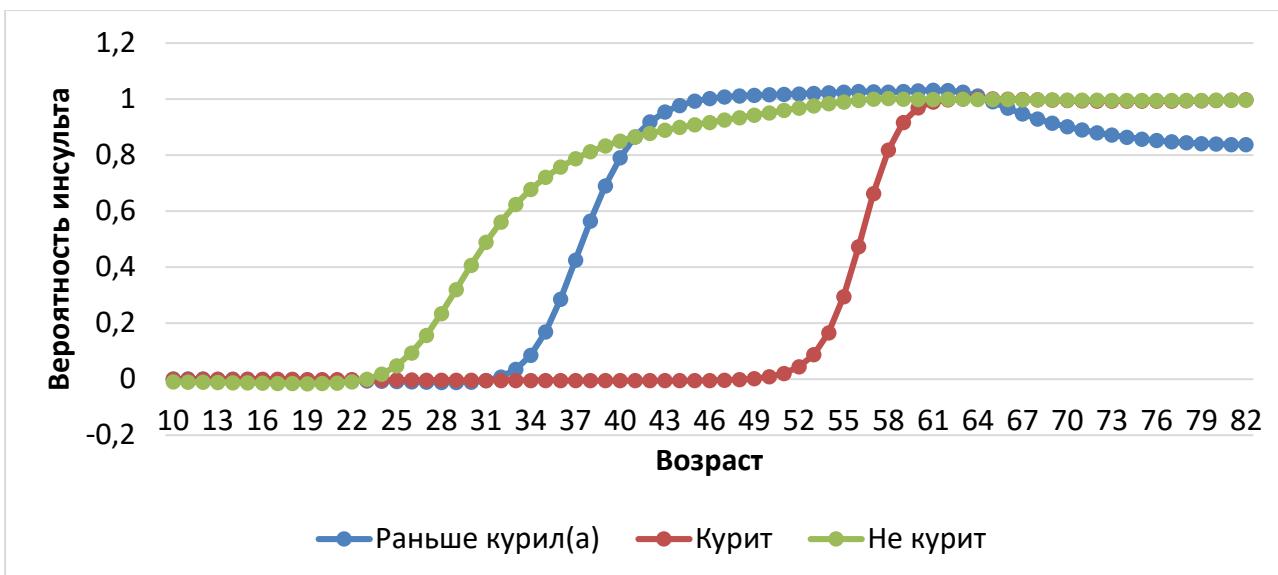


Рисунок 15 – Влияния курения

Из рисунка 12 видно, что некурящие люди имеют повышенный риск возникновения инсульта в сравнении с курящими, однако исследования для других пациентов показали, как похожие, так и отличающиеся результаты, что говорит о необходимости исследования вопроса для определённого человека для получения результата.

Заключение. Построена система нейросетевого оценивания вероятности инсульта. Спроектированная модель учитывает десять физических и индивидуальных показателей, влияющих на кровоснабжение мозга. Проведены исследования работы данной модели в рамках предметной области, в которой эта модель работает корректно. Посредством прогнозирования были выявлены знания для определения человека в группе риска и своевременной профилактики.

Библиографический список

1. Li X, Wu M, Sun C, Zhao Z, Wang F, Zheng X, Ge W, Zhou J, Zou J. Using machine learning to predict stroke-associated pneumonia in Chinese acute ischaemic stroke patients. *Eur J Neurol.* 2020 Aug;27(8):1656-1663. doi: 10.1111/ene.14295. Epub 2020 May 31. Erratum in: *Eur J Neurol.* 2020 Dec;27(12):2676. PMID: 32374076.
2. G. Fang, P. Xu and W. Liu, "Automated Ischemic Stroke Subtyping Based on Machine Learning Approach," in *IEEE Access*, vol. 8, pp. 118426-118432, 2020 , doi: 10.1109/ACCESS.2020.3004977.
3. Курепина И.С., Зорин Р.А., Жаднов В.А., Сорокин О.А. Геморрагический инсульт: нейрофизиологические предикторы острого периода // *Acta Biomedica Scientifica.* 2020. № 5. С. 47-52.
4. Yasnitsky L.N., Dumler A.A., Cherepanov F.M. Dynamic artificial neural networks as basis for medicine revolution // *Advances in Intelligent Systems and Computing.* 2018. Т. 850. С. 351-358.

5. Yasnitsky L.N., Dumler A., Cherepanov F.M. The capabilities of artificial intelligence to simulate the emergence and development of diseases, optimize prevention and treatment thereof, and identify new medical knowledge // Journal of Pharmaceutical Sciences and Research. 2018. T. 10. № 9. C. 2192-2200.
6. Yasnitsky L.N. Artificial Intelligence and Medicine: History, Current State, and Forecasts for the Future // Current Hypertension Reviews, 2020, vol. 16, No 3. Pp. 210-215. DOI : 10.2174/157340211666200714150953
<https://pubmed.ncbi.nlm.nih.gov/32664841/>
7. Ясницкий Л.Н., Думлер А.А., Полещук А.Н., Богданов К.В., Черепанов Ф.М. Нейросетевая система экспресс-диагностики сердечно-сосудистых заболеваний // Пермский медицинский журнал. 2011. Т. 28. № 4. С. 77-86.
8. Yasnitsky L.N., Dumler A.A., Poleshuk A.N., Bogdanov C.V., Cherepanov F.M. Artificial neural networks for obtaining new medical knowledge: diagnostics and prediction of cardiovascular disease progression // Biology and Medicine. 2015. Т. 7. № 2. С. ВМ-095-15.
9. Набор данных для обучения [Электронный ресурс]. URL:
<https://www.kaggle.com/fedesoriano/stroke-prediction-dataset>
10. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.

STROKE PREDICTION BY NEURAL NETWORK MODELING

Chirukhin Dmitry A., Chunarev Nikita M.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990

The article describes the development of a neural network system for predicting stroke. The system allows you to predict the likelihood of a stroke in a person by his physiological parameters and individual characteristics. A number of studies have been carried out, the results of which are presented in this article.

Keywords: artificial intelligence, neural network technologies, stroke, forecasting, patterns.

ПРИМЕНЕНИЕ МЕТОДОВ МАШИННОГО ОБУЧЕНИЯ ДЛЯ УТОЧНЕНИЯ ДИАГНОЗА НА ЭТАПЕ ОБРАБОТКИ ДАННЫХ В ДИАГНОСТИКЕ РАКА МОЛОЧНОЙ ЖЕЛЕЗЫ

Попов Илларион Евгеньевич

Волгоградский государственный университет,
400062, г. Волгоград, пр-т Университетский, 100, popov.larion@volsu.ru

Резникова Анастасия Сергеевна

Волгоградский государственный университет,
400062, г. Волгоград, пр-т Университетский, 100, ras25072002@mail.ru

Лосев Александр Георгиевич

Волгоградский государственный университет,
400062, г. Волгоград, пр-т Университетский, 100, alexander.losev@volsu.ru

Рассматривается проблема пропуска данных в медицинских базах данных, в частности неполный диагноз, на примере диагностики рака молочной железы методом микроволновой радиотермометрии. Предлагается способ уточнения поставленного диагноза методами машинного обучения, в результате удается расширить базу данных по больным пациентам в несколько раз. Проводятся вычислительные эксперименты и сравнение оригинальной базы данных с расширенной. Анализ показал, что адекватность результатов получаемых при применении алгоритмов классификации существенно увеличилась.

Ключевые слова: машинное обучение, методы диагностики, микроволновая радиотермометрия, рак молочной железы.

Введение. Первым этапом настройки алгоритмов машинного обучения в диагностике по термометрическим данным является предобработка базы данных. Она включает в себя обнаружение и борьбу со статистическими выбросами, заполнение пропущенных данных, преобразование входных параметров в высокоинформативные признаки [1], перевод диагноза в числовой тип данных (класс пациента) и т. п. В данной работе рассматривается последний вариант предобработки данных. Для начала опишем процесс постановки диагноза врачом-специалистом.

Обследование проводится методом микроволновой радиотермометрии, который заключается в последовательном измерении поверхностных и глубинных температур молочных желез пациента [5]. Кожные температуры измеряются инфракрасными излучениями, глубинные – микроволновыми. Далее по ним строятся температурные карты. На рисунке 1 приведен пример карты глубинных температур здорового пациента. Здесь в правой половине рисунка

показана левая молочная железа, в левой – правая. В верхних углах изображены температуры в опорных точках, в центре снизу – аксилярные области. По полученным температурным картам, а также дополнительным обследованиям врач ставит пациенту диагноз. В базу данных он заносится в виде текстового описания с указанием степени заболевания молочной железы, месторасположение опухоли (точка, рядом с которой расположена опухоль), температурные аномалии у пациента, а также рекомендация к дальнейшему обследованию.

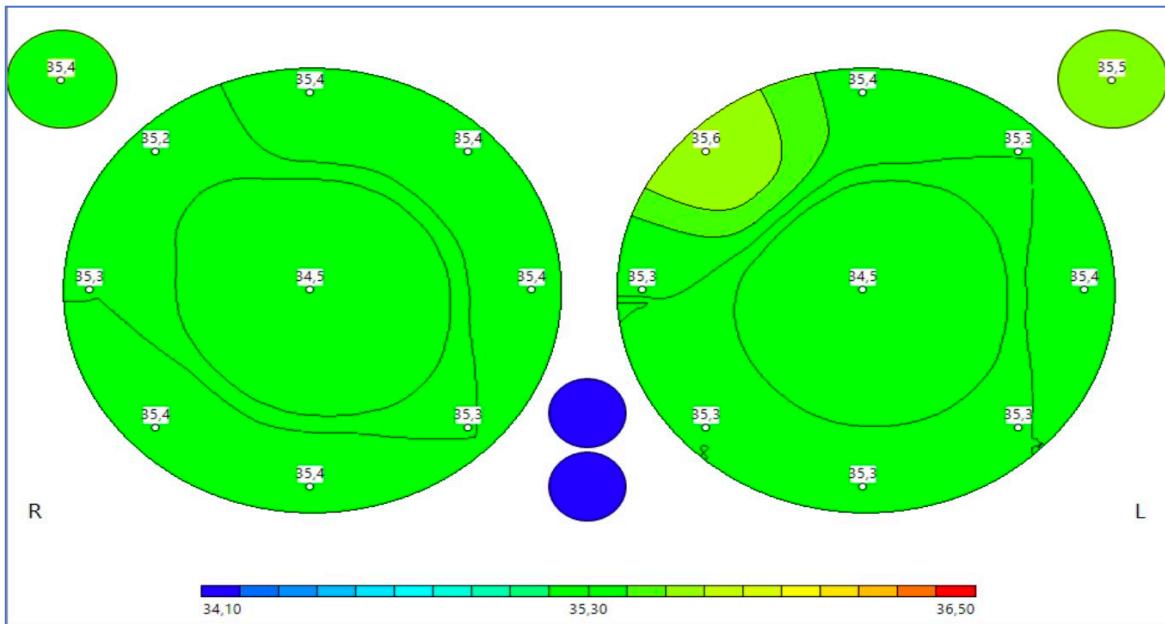


Рисунок 1. Температурная карта здорового пациента

Степень заболевания оценивается по 6-балльной шкале [3]:

- th0 – температурные аномалии отсутствуют – здоровая молочная железа;
- th1 – температурные аномалии обнаружены, но они не характерны для рака молочной железы (температуры пониженные) – здоровая молочная железа;
- th2 – температурные аномалии обнаружены, но они не характерны для рака молочной железы (температуры повышенные) – здоровая молочная железа;
- th3 – высокий уровень кожных и глубинных температур – группа риска;
- th4 – обнаружены множественные температурные аномалии – группа риска;
- th5 – термограмма характерна для пациентов с острым обострением или раком молочной железы – группа риска.

Диагноз переводится в числовой тип по данной шкале. А именно, будем считать, что в случаях th0-th2 молочная железа здорова, в случаях th3-th5 – молочная железа в группе риска.

При этом зачастую диагноз по данной шкале указан по пациенту, без уточнения по каждой из молочных желез. Как правило, у пациентов с раком молочной железы опухоль находится только в одной молочной железе, в то время как другая является здоровой [2]. Это усложняет процесс диагностики

методами машинного обучения. Таким образом возникает задача уточнения поставленного врачом диагноза, а именно уточнения, какой из молочных желез поставлен диагноз «группа риска».

Основная часть. Молочные железы из базы данных делились на две группы: в первую группу вошли железы, у которых известен диагноз, во вторую вошли пациенты, у которых известен общий диагноз, но без указания диагноза рассматриваемой молочной железы. В данной работе рассматривается задача уточнения диагноза у желез второй группы методами машинного обучения. Корректировка диагноза производится на основе предположения, что только одной из молочных желез принадлежит диагноз группы риска, при этом у парной молочной железы нулевая степень заболевания. Таким образом возникает задача бинарной классификации.

Для уточнения диагноза алгоритм классификации обучался по железам из первой группы с диагнозами th0 и рассматриваемым диагнозом из группы риска (th3, th4 или th5). В качестве параметров, по которым проводилась классификация, использовалось признаковое пространство из работы [4]. После обучения классификатор диагностировал молочные железы из второй группы с соответствующим диагнозом из группы риска. Если поставленный классификатором диагноз совпадал с диагнозом из базы данных, данная молочная железа помещалась в первую группу. Классификация проводилась различными алгоритмами, их результаты приведены на рисунке 2. Как видно из приведенного рисунка, логистическая регрессия и наивный байесовский классификатор в несколько раз увеличили количество желез с диагнозом th3 и значительно увеличили количество желез с диагнозами th4 и th5.

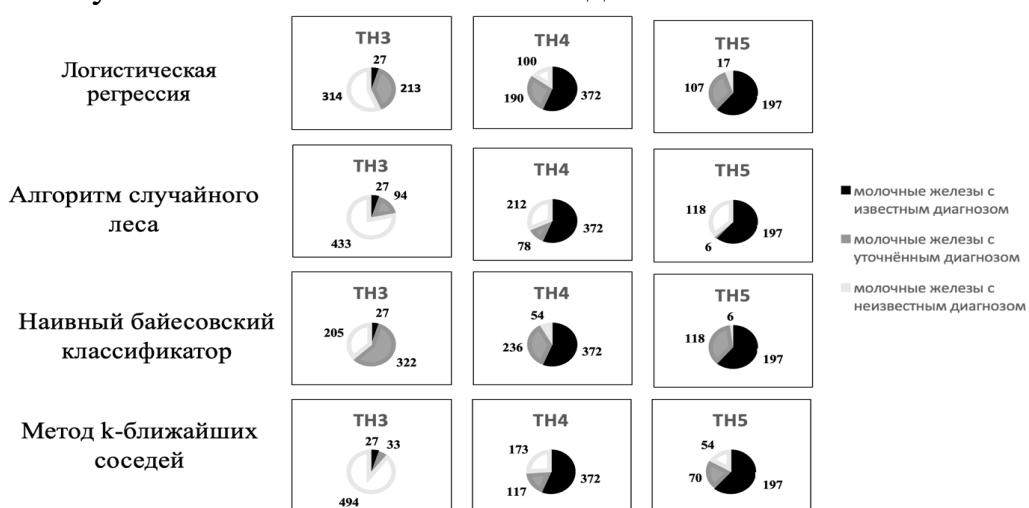


Рисунок 2. Результаты уточнения диагноза.

Далее полученные наборы данных, состоящие из молочных желез с известными и уточненными диагнозами, применялись в диагностике группы риска и сравнивались с результатами диагностики только по первой группе желез. В качестве признакового пространства брался тот же набор, что и при предыдущих классификациях, классы диагностики – здоров (th0-th2) или группа риска (th3-th5). Вычислительные эксперименты проводились несколько раз с помощью перекрестной проверки алгоритмом логистическая регрессия. Для

этого база данных разбивалась на 10 равных частей, с соблюдением баланса классов в них. Одна часть помещалась в тестовую выборку, остальные – в обучающую. По обучающей выборке проводилась настройка алгоритма классификации, по тестовой – его проверка. Алгоритмы оценивались по трем параметрам: специфичность – точность диагностики здоровых молочных желез, чувствительность – точность диагностики группы риска и эффективности – среднегеометрическое по предыдущим показателям. В таблице 1 приведены результаты вычислительных экспериментов. Здесь первый столбец – результаты классификации по молочным железам из первой группы базы данных (оригинальная база). Последние четыре столбца – результаты классификации по базам данных, полученными соответствующими алгоритмами классификации. Как видно, во всех случаях ухудшается специфичность, т.е. логистическая регрессия хуже определяет здоровые молочные железы. В тоже время чувствительность изменяется не более чем на процент. Результат объясняется тем, что в оригинальной базе было незначительно количество молочных желез класса th3. При этом молочные железы данного класса наиболее сложны в диагностике в силу того, что температурные аномалии класса слабо выражены и по их характеру схожи с температурными аномалиями у пациентов класса th2.

Таблица 1. Результаты классификации

Результаты по оригинальной базе	Показатели для сравнения классификаторов	Классификаторы			
		Логистическая регрессия	Алгоритм случайного леса	Наивный байесовский классификатор	Метод k-ближайших соседей
0.911	Специфичность	0.883	0.891	0.880	0.890
0.884	Чувствительность	0.880	0.877	0.870	0.891
0.897	Эффективность	0.885	0.883	0.874	0.890

Заключение. По итогам вычислительных экспериментов алгоритмами логистическая регрессия и наивный байесовский классификатор удалось значительно увеличить количество молочных желез с известным диагнозом по ним. Несмотря на то, что результаты классификации по расширенным базам данных несколько хуже, чем по оригинальной, их адекватность существенно улучшилась за счёт увеличения класса th3 в несколько раз. В оригинальной базе их было 27, а после применения логистической регрессии, стало 240. Классификаторы, из-за малого количества молочных желез данного класса в первом случае, могли не учитывать их при обучении. В то время как класс th3 является наиболее сложным в диагностике. При этом после уточнения диагнозов становится возможной дифференциальная диагностика по классам th0-th5.

Исследование выполнено при финансовой поддержке РФФИ, проект «Математические модели радиационных полей и анализа данных микроволновой радиотермометрии в ранней диагностике рака молочных желез» № 19-01-00358

Библиографический список

1. Лосев А. Г., Левшинский В. В., Интеллектуальный анализ данных микроволновой радиотермометрии в диагностике рака молочной железы. // Математическая физика и компьютерное моделирование, 20:5 (2017), 49–62
2. Khairy G.A., Guraya S.Y., Ahmed M.E., Ahmed M.A.. Bilateral breast cancer. Incidence, diagnosis and histological patterns. // Saudi Med J. 2005 Apr;26(4):612-5. Erratum in: Saudi Med J. 2005 Aug;26(8):1316.
3. Lashkari A., Pak F., Firouzmand M., Full Intelligent Cancer Classification of Thermal Breast Images to Assist Physician in Clinical Diagnostic Applications. // J Med Signals Sens. 2016;6(1):12-24.
4. Levshinskii V.V. Mathematical models for analyzing and interpreting microwave radiometry data in medical diagnosis // Journal of Computational and Engineering Mathematics. 2021. V. 8. No 1. pp. 3-14.
5. Zharov V. P., Vesnin S. G., Suen J. Y., Steven E. Harms M.D. Photothermal/microwave radiometry for imaging and temperature feedback. // Proc. SPIE 4618, Biomedical Optoacoustics III, (10 June 2002)

APPLICATION OF MACHINE LEARNING METHODS FOR REFINING DIAGNOSIS AT THE DATA PROCESSING STAGE IN BREAST CANCER DIAGNOSIS

Popov Illarion E.

Volgograd State University

Prospekt Universitetskiy, 100, Volgograd,
Volgogradskaya oblast', 400062, popov.larion@volsu.ru

Reznikova Anastasia S.

Volgograd State University

Prospekt Universitetskiy, 100, Volgograd,
Volgogradskaya oblast', 400062, ras25072002@mail.ru

Losev Alexander G.

Volgograd State University

Prospekt Universitetskiy, 100, Volgograd,
Volgogradskaya oblast', 400062,
alexander.losev@volsu.ru

The article deals with the problem of missing data, in particular, incomplete diagnosis, on the example of breast cancer diagnostics by the method of microwave radiothermometry. An attempt is made to clarify the diagnosis by machine learning methods, as a result of which it is possible to expand the database of sick patients several times. Computational experiments are being carried out to compare the original database and the expanded one. The analysis showed that the adequacy of the results obtained using the classification algorithms has increased significantly.

Keywords: machine learning, diagnostic methods, microwave radiothermometry, breast cancer

НЕЙРОСЕТЕВОЕ МОДЕЛИРОВАНИЕ ПРОГНОЗИРОВАНИЯ СЕРДЕЧНОГО ПРИСТУПА

Субботина Арина Владимировна

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15, arina.sub.99@icloud.com

В статье представлено описание разработки нейросетевой модели для прогнозирования сердечного приступа. Система позволяет выполнять оценку вероятности сердечного приступа с помощью жизненных показателей пациента. Использование жизненных показателей пациента позволяет сделать систему адаптируемой к текущему состоянию пациента.

Ключевые слова: искусственный интеллект, нейросетевые технологии, сердечный приступ, оценка вероятности.

Введение. При диагностике сердечных приступов требуется выполнить корректную оценку диагностiku состояния и постановка диагноза. Обычно врач диагностирует сердечный приступ по первичным показателям уже при его наступлении или в его начальных стадиях. Но врач может не учсть какой-либо фактор и будет проведена некорректная диагностика заболевания пациента.

Считается, что нейросетевые диагностические системы рекомендуются для поддержки клинических решений врача, в качестве инструмента доклинической диагностики. Также нейросетевые системы позволяют сократить время, необходимое для диагностики, позволяют оптимизировать диагностический процесс и избегать ошибочных диагнозов [1-3]. Кроме того, как показано в [4-7], с помощью них выполнять исследование моделируемой предметной области – извлекать медицинские знаний в виде закономерностей. В настоящей работе для создания нейросетевой модели и исследования предметной области использованы опыт и методики, разработанные в [3-7]

В результате анализа литературных источников [1-7] был выбран следующий набор показателей: X1 – возраст пациента, X2 – пол пациента, X3 – тип боли в груди, X4 – артериальное давление в покое, X5 – уровень холестерина, X6 – уровень сахара в крови натощак составляет > 120 мг/дл , X7 – результат электрокардиографии в покое, X8 – максимальная частота сердечных сокращений, X9 – наличие стенокардии, вызванной физической нагрузкой, X10 – ST депрессия, вызванная физической нагрузкой по сравнению с отдыхом , X11 – наклон сегмента ST при пиковой нагрузке, X12 – количество крупных сосудов, X13 – крутизна пульса.

Параметр типа боли в груди был закодирован: 1 – типичная стенокардия, 2 – атипичная стенокардия, 3 – неангинальная боль, 4 – бессимптомно. Также параметры результата электрокардиографии в покое были закодированы: 0 –

нормальные, 1 – наличие аномалии ST-T, 2 – указание вероятной или определенной гипертрофии левого желудочка по критериям Эстеса. Помимо этого, параметры наличие стенокардии, вызванной физической нагрузкой и уровень сахара в крови натощак были закодированы так: 0 – да, 1 – нет. Остальные параметры являются числовыми, поэтому для них кодировка не требуется.

Данные для обучения нейросети были взяты с сайта <https://www.kaggle.com/rashikrahmanpritom/heart-attack-analysis-prediction-dataset#>.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [8] по методике [9]. В результате оптимизации спроектированная нейронная сеть представляла собой персепtron, который имеет семнадцать входных нейронов, один выходной и один скрытый слой с шестью нейронами.

На входном слое использовалась функция активации – гиперболический тангенс.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 240 примеров. Средняя ошибка тестирования составила 3,34%, что можно считать приемлемым результатом. На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактической и прогнозируемой нейросетью стоимостью случайно отобранных 30 пациентов из тестирующего множества.

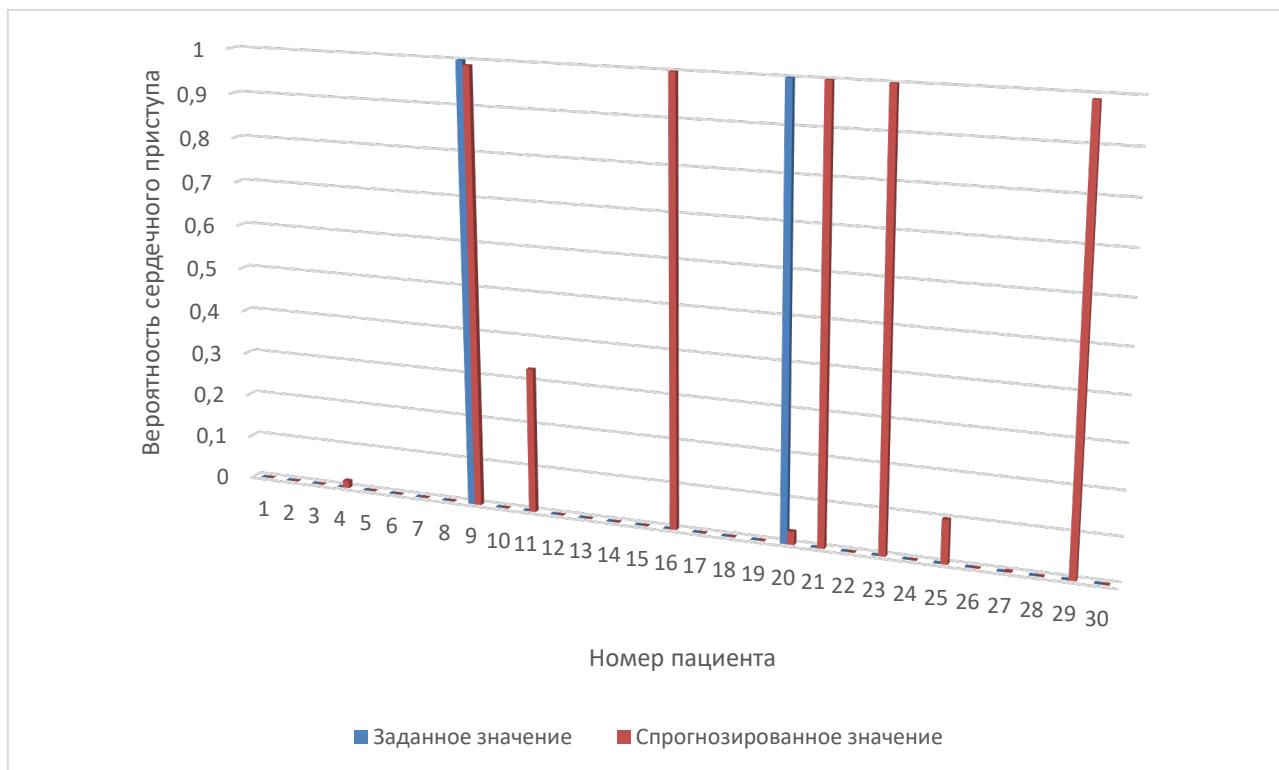


Рисунок 1. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 1, можно сделать вывод об адекватной работе спроектированной нейронной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5», результат отображен на рисунке 2.

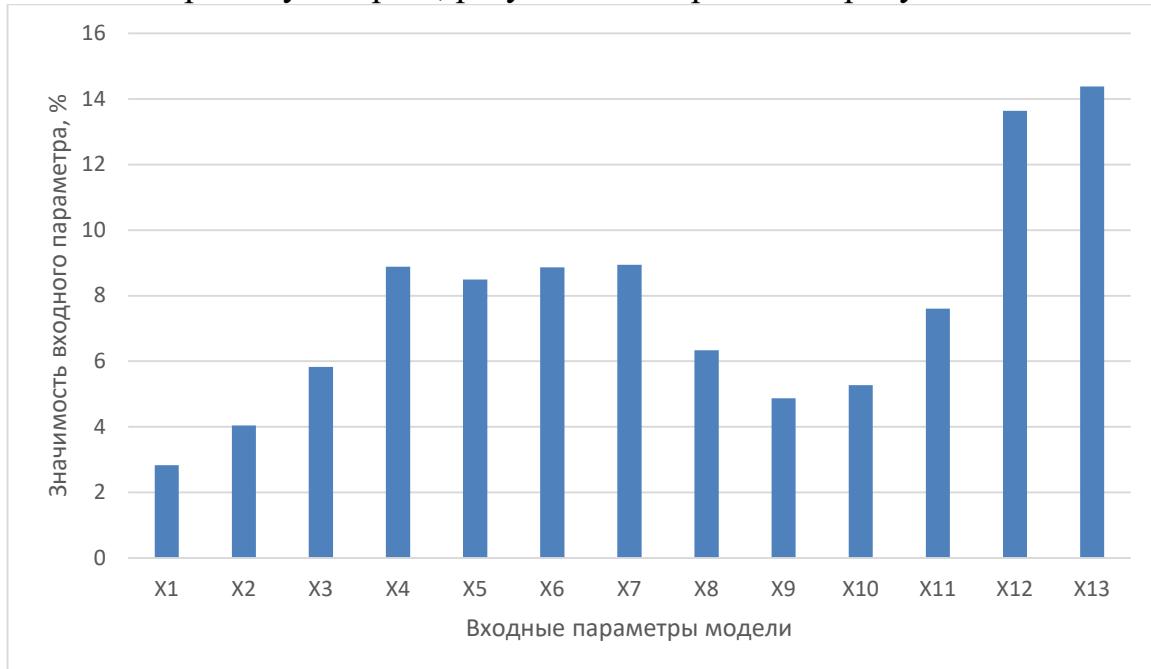


Рисунок 2. Значимость входных параметров нейросетевой модели

Как видно из рисунка 2, наиболее значимыми являются крутизна пульса и количество крупных сосудов и т.д.

Также были рассчитаны коэффициенты корреляции Пирсона между входными параметрами модели и выходным (наличие сердечного приступа). Результат расчета представлен на рисунке 3 в виде гистограммы.

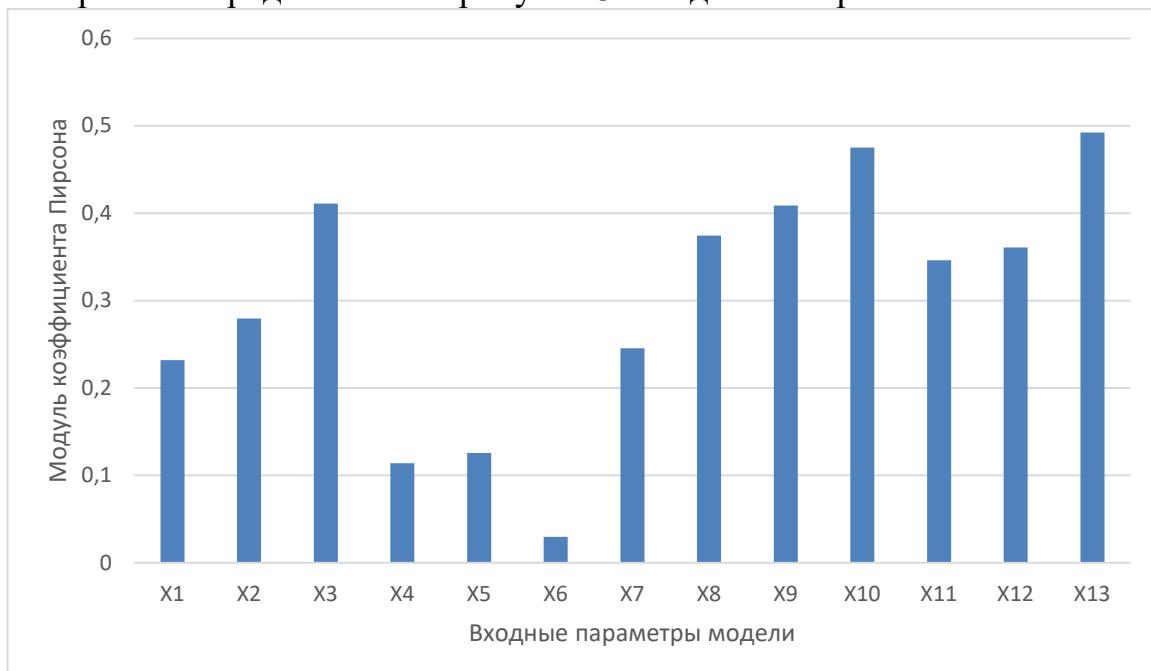


Рисунок 3. Значения модулей коэффициентов корреляции Пирсона между входными параметрами и наличием сердечного приступа

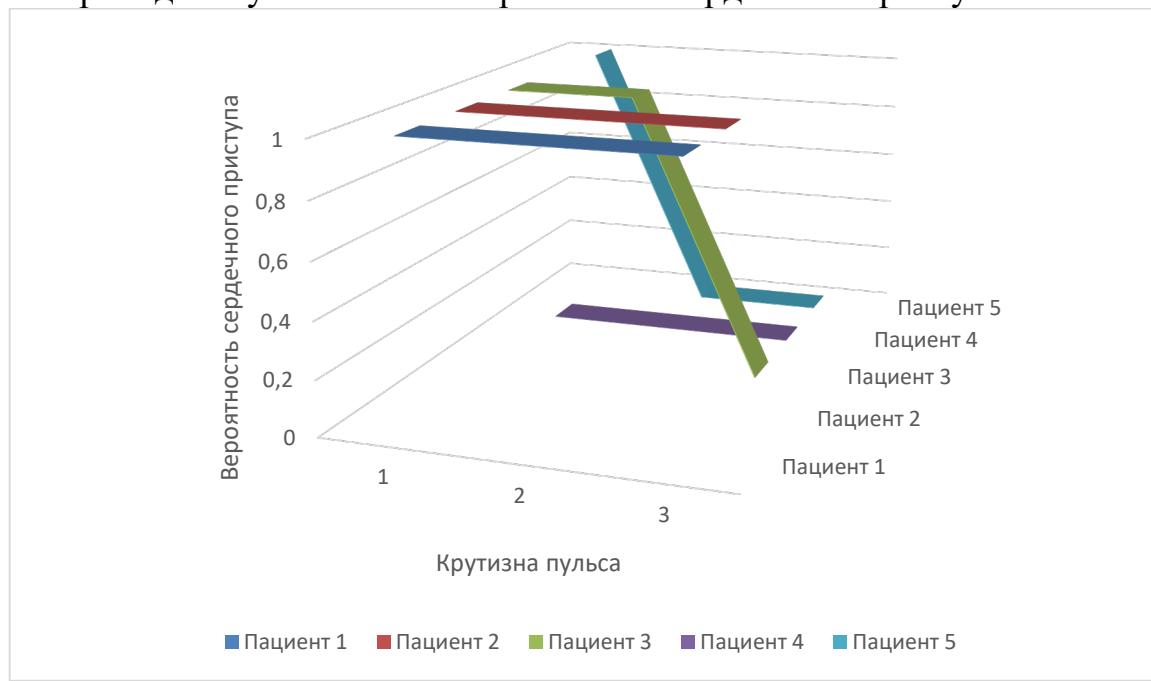
Сравнивая рисунки 2 и 3, можно заметить некоторые различия, в оценке значимости входных параметров, что можно объяснить тем, что коэффициент Пирсона реагирует только на линейные зависимости, тогда как «Нейросимулятор 5» выявляет как линейные, так и нелинейные связи.

Далее было проведено исследование моделируемой предметной области. Исследование производилось с помощью метода «замораживания» [8], суть которого заключается в варьировании значения одного параметра и наблюдении за выходным параметром при фиксировании значений всех других входных параметров. Для этой цели были отобраны 5 пациентов, информация о которых отражена в таблице 1.

Таблица 1
Характеристики пациентов,
выбранных для исследования

№ пациента	1	2	3	4	5
X1	42	50	68	56	48
X2	1	1	0	1	1
X3	2	2	2	2	1
X4	120	129	120	130	110
X5	240	196	211	256	229
X6	1	0	0	1	0
X7	1	1	0	0	1
X8	194	163	115	142	168
X9	0	0	0	1	0
X10	0,8	0	1,5	0,6	1
X11	0	2	1	1	0
X12	0	0	0	1	0
X13	3	2	2	1	3

На рисунке 4 показан график зависимости вероятности сердечного приступа от крутизны пульса. Как следует из графика, увеличение крутизны пульса приводит к уменьшению вероятности сердечного приступа.



**Рисунок 4. Зависимость вероятности сердечного приступа
от крутизны пульса**

На рисунках 5-6 продемонстрирована зависимость вероятности сердечного приступа от количества крупных сосудов и типа боли в груди соответственно. В первом случае видно, что при увеличении количества крупных сосудов вероятность сердечного приступа снижается. Во втором случае видно, что при наличии неангинальной боли и бессимптомного течения велика вероятность сердечного приступа.

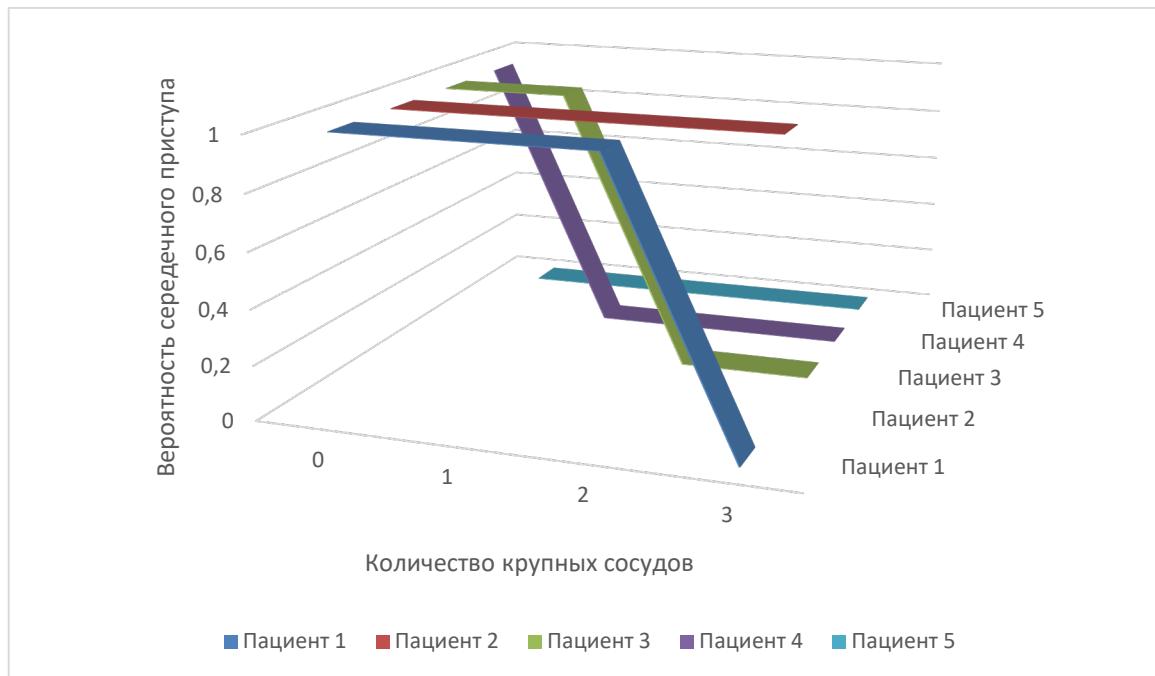


Рисунок 5. Зависимость вероятности сердечного приступа от количества крупных сосудов

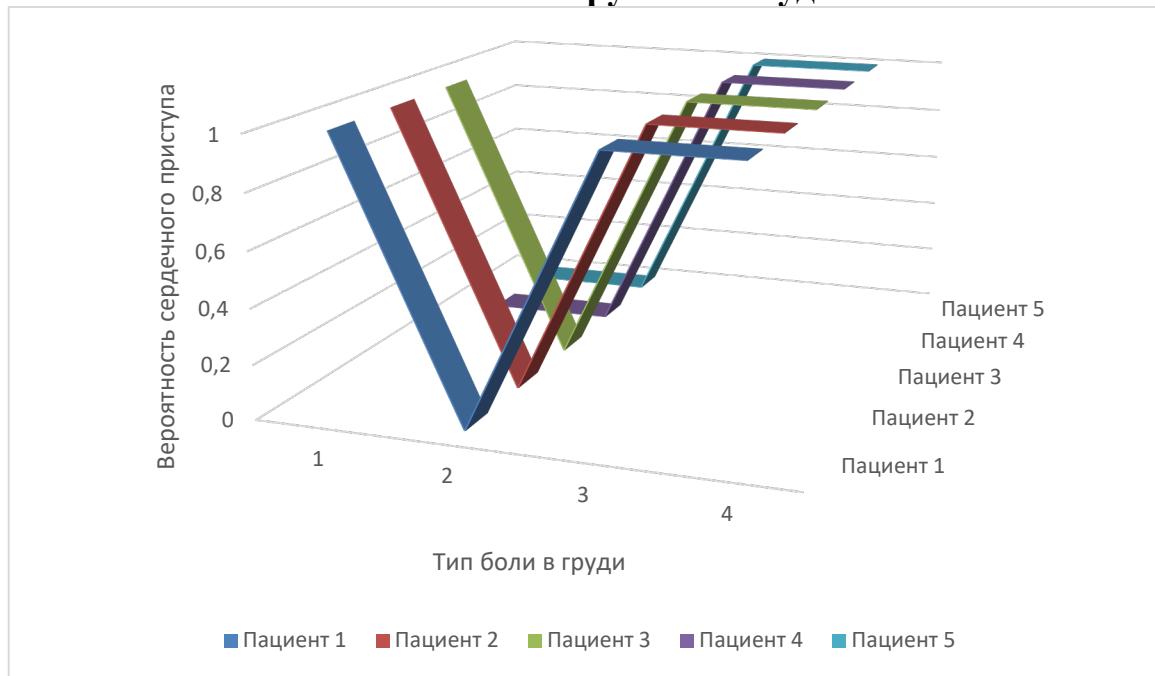


Рисунок 6. Зависимость вероятности сердечного приступа от типа боли в груди

Полученные результаты исследований не противоречат реальности, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для прогнозирования сердечного приступа.

Заключение. Построена система нейросетевого оценивания вероятности сердечного приступа. Методом сценарного прогнозирования построены графики зависимостей вероятности сердечного приступа от типа боли в груди, количества крупных сосудов и крутизны пульса.

Библиографический список

1. Oleg Yu. Atkov, Svetlana G.Gorokhov, Alexandr G.Sboev, Eduard V.Generozov, Elena V.Muraseyev, Svetlana Y.Moroshkina, Nadezhda N.Cherniyc. Coronary heart disease diagnosis by artificial neural networks including genetic polymorphisms and clinical parameters – Journal of Cardiology. Volume 59, Issue 2, March 2012, Pages 190-194
2. Amato F., López F., Peña-Méndez E.M., Vaňhara P., Hampl A., Havel J. Artificial neural networks in medical diagnosis – Journal of Applied Biomedicine. 2013 No. 11, pp. 47-58. DOI 10.2478/v10136-012-0031-x.
3. Ясницкий Л.Н., Думлер А.А., Полещук А.Н., Богданов К.В., Черепанов Ф.М. Нейросетевая система экспресс-диагностики сердечно-сосудистых заболеваний // Пермский медицинский журнал. 2011. Т. 28. № 4. С. 77-86.
4. Yasnitsky L.N., Dumler A.A., Cherepanov F.M. Dynamic artificial neural networks as basis for medicine revolution // Advances in Intelligent Systems and Computing. 2018. Т. 850. С. 351-358.
5. Yasnitsky L.N., Dumler A., Cherepanov F.M. The capabilities of artificial intelligence to simulate the emergence and development of diseases, optimize prevention and treatment thereof, and identify new medical knowledge // Journal of Pharmaceutical Sciences and Research. 2018. Т. 10. № 9. С. 2192-2200.
6. Yasnitsky L.N. Artificial Intelligence and Medicine: History, Current State, and Forecasts for the Future // Current Hypertension Reviews, 2020, vol. 16, No 3. Pp. 210-215. DOI : 10.2174/157340211666200714150953
<https://pubmed.ncbi.nlm.nih.gov/32664841/>
7. Ясницкий Л.Н., Зайцева Н.В., Гусев А.Л., Шур П.З. Нейросетевая модель региона для выбора управляющих воздействий в области обеспечения гигиенической безопасности // Информатика и системы управления. 2011. № 3 (29). С. 51-59.
8. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
9. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.

NEURAL NETWORK MODELING OF HEART ATTACK PREDICTION

Subbotina Arina V.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990, arina.sub.99@icloud.com

The article describes the development of a neural network model for predicting a heart attack. The system allows you to assess the likelihood of a heart attack using the vital signs of the patient. Using the vital signs of the patient makes the system adaptable to the current state of the patient.

Key words: artificial intelligence, neural network technologies, heart attack, probability assessment.

УДК 004.891.3

ГИБРИДНЫЙ НЕЙРОСЕТЕВОЙ КЛАССИФИКАТОР ИНФЕКЦИОННЫХ ЗАБОЛЕВАНИЙ НА ОСНОВЕ ЛОКАЛЬНЫХ МОДЕЛЕЙ ГРАФИКА КОУЛА

***Мирошников Андрей Валерьевич, Стадниченко Никита Сергеевич,
Шаталова Ольга Владимировна***

Юго-Западный государственный университет,
305040, Россия, г. Курск, ул. 50 лет Октября, 94,
Shatolg@mail.ru

В статье представлено исследование гибридного нейросетевого классификатора с иерархической структурой, предназначенного для классификации инфекционных заболеваний. В качестве «сырых» данных в моделях используются результаты биоимпедансного анализа представленные в виде графика Коула.

Ключевые слова: искусственный интеллект, инфекционные заболевания, биоимпедансные исследования, модель Войта, график Коула.

Введение. Болезнь инфекционными заболеваниями, как и большинства других заболеваний, носит системный характер. Для ее диагностики, в частности, ранней диагностики, требует поиск новых маркеров и создание новых интеллектуальных технологий. Однако применение методик инструментальных и лабораторных исследований отнимает значительное время и сопряжено с воздействием вредных факторов на организм, что не позволяет их использовать с высокой периодичностью и сильно затрудняет исследование патологического процесса в динамике. Это обстоятельство заставляет искать новые методы, ориентированные на не инвазивные исследования состояния организма

человека, которые являются незаменимыми при скрининговых исследованиях [1, 2, 3, 4].

Методы и модели. За основу метода классификации функционального состояния биологических объектов взят метод, основанный на биоимпедансном анализе, в котором для классификации сегмента биообъекта строится его модель в виде пассивного двухполюсника. В качестве исходных данных для построения модели используется график Коула, получаемый путем накладывания электродов на выделенный сегмент биоматериала и осуществления многочастотного зондирование на N частотах [5, 6, 7, 8].

Так как на биоимпеданс оказывают влияния, как конституционные особенности пациента, так и различные экзогенные факторы, что затрудняет формирование обучающих выборок и обучение классификатора, то в качестве классификатора используем гибридную схему, которая включает два автономных агента (классификатора) обучаемых на датасете, полученном из двух моделей «сырых» данных. Первую модель данных назовем параметрической, и она привязана к конкретной топологии импеданса биоматериала. В качестве такой модели сегмента биоматериала используется рекурсивная модель Войта [2].

Структура этой модели состоит из последовательно связанных RC -звеньев, каждое из которых моделирует конечную проводимость с соответствующей постоянной времени. Эта модель находит основное применение при описании проводимости (импеданса) в объеме негомогенных сред, то есть когда каждому элементарному, локальному объему биоматериала присущи определенная проводимость и собственная постоянная времени. Модель состоит из последовательно соединенных звеньев параллельно соединенных конденсатора C и резистора R . Импеданс модели (одна точка на графике Коула при частоте ω) определяется согласно формуле

$$Z_{VOLT}(\omega) = \sum_{l=1}^L \left(R_l^{-1} + j\omega C_l \right)^{-1} . \quad (1)$$

Каждая модель Войта строится по трем точкам графика Коула. Таким образом, модель Войта является трехзвенной, но ей соответствуют четыре параметра, тетрада: $R1, R2, C1, C2$, которые определяются путем решения системы из четырех нелинейных алгебраических уравнений:

$$\left. \begin{aligned}
a_1(\omega_1) &= \frac{R_1}{1 + \omega_1^2 C_1^2 R_1^2} + \frac{R_2}{1 + \omega_1^2 C_2^2 R_2^2} + \frac{R_3}{1 + \omega_1^2 C_3^2 R_3^2}; \\
b_1(\omega_1) &= \frac{-\omega_1 C_1 R_1^2}{1 + \omega_1^2 C_1^2 R_1^2} + \frac{-\omega_1 C_2 R_2^2}{1 + \omega_1^2 C_2^2 R_2^2} + \frac{-\omega_1 C_3 R_3^2}{1 + \omega_1^2 C_3^2 R_3^2}; \\
a_2(\omega_2) &= \frac{R_1}{1 + \omega_2^2 C_1^2 R_1^2} + \frac{R_2}{1 + \omega_2^2 C_2^2 R_2^2} + \frac{R_3}{1 + \omega_2^2 C_3^2 R_3^2}; \\
b_2(\omega_2) &= \frac{-\omega_2 C_1 R_1^2}{1 + \omega_2^2 C_1^2 R_1^2} + \frac{-\omega_2 C_2 R_2^2}{1 + \omega_2^2 C_2^2 R_2^2} + \frac{-\omega_2 C_3 R_3^2}{1 + \omega_2^2 C_3^2 R_3^2}; \\
a_3(\omega_3) &= \frac{R_1}{1 + \omega_3^2 C_1^2 R_1^2} + \frac{R_2}{1 + \omega_3^2 C_2^2 R_2^2} + \frac{R_3}{1 + \omega_3^2 C_3^2 R_3^2}; \\
b_3(\omega_3) &= \frac{-\omega_3 C_1 R_1^2}{1 + \omega_3^2 C_1^2 R_1^2} + \frac{-\omega_3 C_2 R_2^2}{1 + \omega_3^2 C_2^2 R_2^2} + \frac{-\omega_3 C_3 R_3^2}{1 + \omega_3^2 C_3^2 R_3^2}.
\end{aligned} \right\}, \quad (2)$$

где $a(\omega)$ и $b(\omega)$ – координаты точки на графике Коула при $\omega = const$.

Для получения вектора дескрипторов первой модели классификатора используются только четыре из шести параметров, определенных путем решения системы уравнений (2). Параметры R_3 и C_3 в этой триаде частот не учитываются, а переходят в следующую триаду частот графика Коула и определяются так же из системы типа (2), но под именем R_1 и C_1 уже для следующей модели Войта. Всего таких триад (моделей Войта) на графике Коула будет $N-2$. Вместо трехзвенной модели Войта для построения первого классификатора может быть использована модифицированная модель, так же трехзвенная, модель Войта, структура которой представлена на рисунке 1.

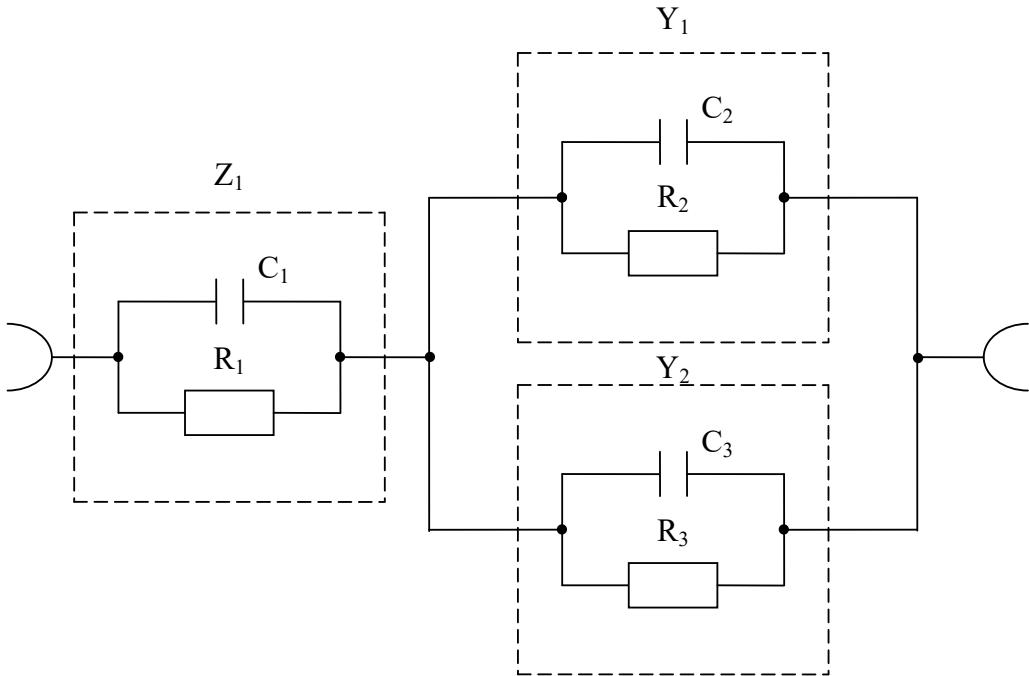


Рисунок 1. Модифицированная модель Войта

Для определения параметров модели в случае использования этой структуры вместо уравнения (1) необходимо использовать уравнение

$$Z=Z_1+(Y_1+Y_2)^{-1} \quad (3)$$

с соответствующей ему записью системы уравнений (2).

Для построения второй модели классификатора используются непосредственно «сырые» данные из графика Коула. На вход второго классификатора в качестве дескрипторов подаются $N-2$ диад. Каждая диада определяется разностью проекций двух ближайших точек на графике Коула. На рисунке 2 показана кривая графика Коула с соответствующими координатами частот и комплексными векторами соответствующих им биоимпедансов. График Коула интерполируется по трем точкам локальным сплайнам. Затем на участке интерполяции находятся две частоты, для которых в базе данных имеются соответствующие комплексные сопротивления. По определенным двум комплексным сопротивлениям определяется диада дескрипторов, соответствующая триаде точек на графике Коула. Для определения следующей диады производится аналогичная процедура с очередной триадой точек на графике Коула. Так продолжается $N-2$ раз.

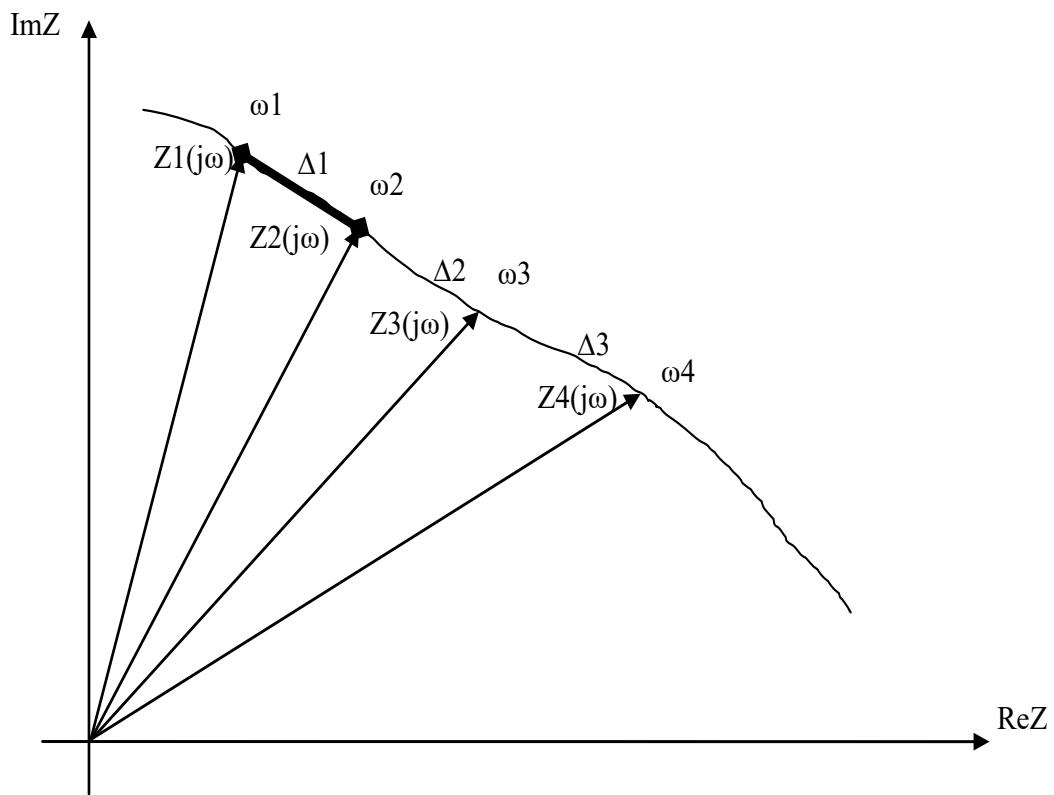


Рисунок 2. График Коула с локальными приращениями

На рисунке 3 представлена структурная схема гибридного нейросетевого классификатора инфекционных заболеваний на основе локальных моделей графика Коула.

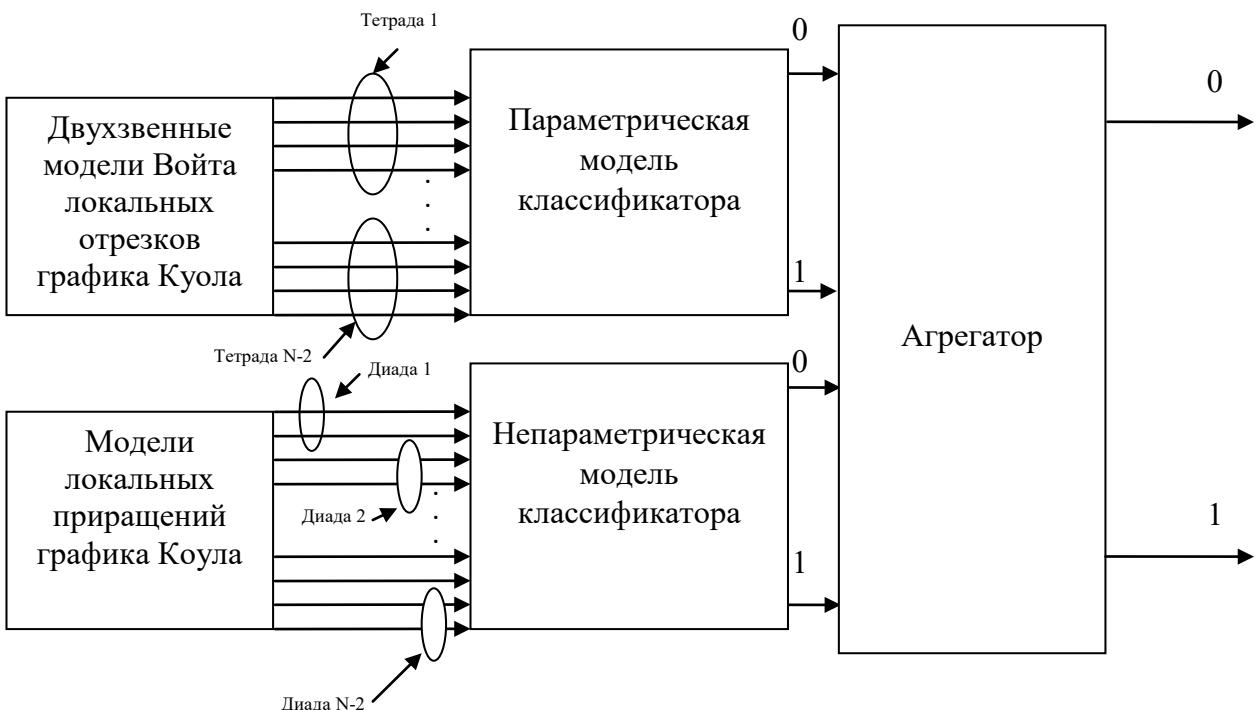


Рисунок 3. Модель гибридного классификатора

Модель включает два классификатора, построенных по схеме линейного многослойного персептрана [9]. Классификаторы имеют по два выхода, соответствующие наличию инфекции в биоматериале и ее отсутствию. Каждый классификатор настраивается автономно по соответствующему датасет. Агрегатор также строится на основе многослойного персептрана. Для его настройки используется датасет, полученный по результатам классификации параметрической и непараметрической моделей классификаторов [10, 11].

Заключение. В результате проведения исследования получены результаты, позволяющие создать интеллектуальные системы поддержки принятия решений по прогнозированию и диагностике инфекционных заболеваний. Возможности многочастотного зондирования и нейросетевых моделей гибридных классификаторов позволяют получить новые решающие правила для диагностики патологических состояний организма (сердечно-сосудистые, инфекционные и онкологические заболевания).

Исследование выполнено при финансовой поддержке РФФИ в рамках научного проекта № 20-38-90063.

Acknowledgments: The reported study was funded by RFBR, project number 20-38-90063.

Библиографический список

1. Филист С.А., Шуткин А.Н., Шкатова Е.С., Дегтярев С.В., Савинов Д.Ю. Модель формирования функциональных систем с учетом менеджмента адаптационного потенциала// Биотехносфера 1(55) 2018. С.32-37.

2. Мирошников А.В., Шаталова О.В., Стадниченко Н.С., Шульга Л.В. Классификации биологических объектов на основе многомерного биоимпедансного анализа//Известия Юго-Западного государственного университета. Серия: Управление, вычислительная техника, информатика. Медицинское приборостроение. – 2020. – Т. 10, № 3/4. – С. 29-49.
3. Филист С.А., Алексенко В.А., Кассим Кабус. Гибридные информационные технологии по экспресс-диагностике инфекционных заболеваний на основе многочастотного анализа пассивных свойств биотканей//Известия ЮФУ. Технические науки. Тематический выпуск. «Медицинские информационные системы» / Таганрог, 2010. №8(109). С.12-17.
4. Попечителев Е.П., Филист С.А. Способы и модели идентификации биоматериалов на основе анализа многочастотного импеданса// Известия Юго-Западного государственного университета. Серия Управление, вычислительная техника. Медицинское приборостроение №1, 2011. С.74-80.
5. Shatalova, Olga V. Impedance models in anomalous electrical conduction zones forming by in-vivo experiments for intelligent systems of socially important diseases diagnostic / Olga V. Shatalova, Alexandr A. Burmaka, Evgeny N. Korovin // International Russian Automation Conference (RusAutoCon). – Sochi: IEEE, 9-16 Sept., 2018. – Pp. 1-4. – URL: <https://ieeexplore.ieee.org/document/8501668>.
6. Кассим К.Д.А., Ключиков И.А., Шаталова О.В., Яа З.Д. Параметрические модели биоимпеданса для идентификации функционального состояния живой системы//Биомедицинская радиоэлектроника. – 2012. – № 4. – С. 50-56.
7. Филист С.А., Кузьмин А.А., Кузьмина М.Н. Биотехническая система для контроля импеданса биоматериалов в экспериментах *invivo*// Биомедицинская радиоэлектроника – 2014. – №9 – С. 38-42.
8. Суржикова С.Е., Филист С.А., Жилин В.В., Курочкин А.Г. Использование гибридных нейросетевых моделей для многоагентных систем классификации в гетерогенном пространстве информативных признаков// Прикаспийский журнал: управление и высокие технологии. – 2015 № 3 (31). – С. 85-95.
9. Филист С.А., Р.А. Томакова, Зар До Яа. Универсальные сетевые модели для задач классификации биомедицинских данных / С. А. Филист, // Известия Юго-Западного государственного университета. – 2012. – № 4 (43), Ч. 2. – С. 44-50.
- 10.Филист С.А., Шаталова О.В., Ефремов М.А. Гибридная нейронная сеть с макрослоями для медицинских приложений//Нейрокомпьютеры. Разработка и применение. – 2014. – №6. – С. 35-39.
- 11.Киселев А.В., Петрова Т.В., Дегтярев С.В., Рыбочкин А.Ф., Филист С.А., Шаталова О.В., Мишустин В.Н. Нейросетевые модули с виртуальными потоками для классификации и прогнозирования

функционального состояния сложных систем// Известия Юго-Западного государственного университета. – 2018. – № 4 (79). – С. 123-134.

HYBRID NEURAL NETWORK CLASSIFIER OF INFECTIOUS DISEASES BASED ON LOCAL MODELS OF COLE GRAPHICS

Miroshnikov Andrey V., Stadnichenko Nikita S., Shatalova Olga V.

Southwest State University

305040, Russia, Kursk, st. 50 years of October, 94,

Shatolg@mail.ru

The article presents a study of a hybrid neural network classifier with a hierarchical structure, intended for the classification of infectious diseases. As "raw" data in the models, the results of bioimpedance analysis are used, presented in the form of a Cole plot.

Keywords: artificial intelligence, infectious diseases, bioimpedance studies, Voight's model, Cole's graph.

УДК 004.032.26

ПРОГНОЗ СЕРДЕЧНОЙ НЕДОСТАТОЧНОСТИ С ПОМОЩЬЮ НЕЙРОСЕТЕВОЙ МОДЕЛИ

Камалутдинова Ксения Павловна

Пермский государственный национальный исследовательский университет,

ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,

[kseniiakamalutdinova@gmail.com](mailto:kseniia.kamalutdinova@gmail.com)

В статье представлено описание разработки динамической нейросетевой системы для прогнозирования сердечной недостаточности на основе данных, предоставленных из открытого источника. Система позволяет выполнять оценку склонности к сердечной недостаточности на основе 12 признаков, подробно описанных в данной работе. Использование этих данных позволяет сделать систему адаптируемой к текущей ситуации в медицинской области.

Ключевые слова: искусственный интеллект, нейросетевые технологии, сердечная недостаточность, высокое кровяное давление, прогнозирование.

Введение. Сердечно-сосудистые заболевания (ССЗ) являются причиной смерти номер один во всем мире, унося ежегодно около 17,9 миллиона жизней, что составляет 31% всех смертей в мире. Сердечная недостаточность – частое явление, вызываемое сердечно-сосудистыми заболеваниями, и для исследования был взят набор данных, содержащий 12 параметров, которые можно

использовать для прогнозирования смертности от сердечной недостаточности. Большинство сердечно-сосудистых заболеваний можно предотвратить путем устранения поведенческих факторов риска, таких как употребление табака, нездоровое питание и ожирение, недостаточная физическая активность и вредное употребление алкоголя, с использованием стратегий, охватывающих все население. Людям с сердечно-сосудистыми заболеваниями или с высоким риском сердечно-сосудистых заболеваний (из-за наличия одного или нескольких факторов риска, таких как гипертония, диабет, или уже установленное заболевание) необходимо раннее выявление и лечение, при этом прогнозирование сердечной недостаточности при помощи нейросетевой модели может оказаться очень полезной.

Основной целью работы является создание системы для прогнозирования смертности от сердечной недостаточности. Эти данные могут быть использованы для помощи врачам в оценке степени тяжести пациентов с сердечно-сосудистыми заболеваниями.

Описание модели. Нейронная сеть имеет 12 входных параметров, описанных в таблице 1.

Таблица 1
Описание данных

Вход	Описание
X1	Возраст, в диапазоне от 40 до 95
X2	Анемия, присутствует -1, нет -0
X3	Показатель креатинин фосфокиназа, в диапазоне от 23 до 7861
X4	Диабет, присутствует -1, нет-0
X5	Сердечный выброс (в процентах), в диапазоне от 14 до 80
X6	Высокое кровяное давление (гипертония), присутствует -1, нет – 0
X7	Тромбоциты в крови (килотромбоциты / мл), в диапазоне от 25100 до 850000
X8	Уровень сывороточного креатинина в крови (мг / дл), в диапазоне от 500 до 9400
X9	Уровень сывороточного натрия в крови (мг-экв / л), в диапазоне от 113 до 148
X10	Пол, мужчина -1, женщина-0
X11	Показатель курения, присутствует -1, нет-0
X12	Срок наблюдения за пациентом (дни), в диапазоне от 4 до 285

Выходной параметр один – событие смерти D1 (1- случилось, 0- нет). Проектирование, обучение и тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5». В результате оптимизации спроектированная нейронная сеть представляет собой персепtron, который имеет двенадцать входных нейронов, один выходной и два скрытых слоя с 5 нейронами на одном слое и 2 на втором. Данные для обучения были получены из открытого источника [1]. В результате, для обучающего множества было использовано 271 примеров, для тестового множества – 30 пример (10% от обучающего множества).

Проектирование сети. Оптимальная структура нейронной сети, представляла собой персепtron с двенадцатью входными нейронами, одним выходным нейроном и двумя скрытыми слоями, пять нейронов на одном скрытом слое, два нейрона на втором скрытом слое. В качестве активационных функций нейронов скрытого слоя и выходных слоев использовалась линейная функция, а в качестве алгоритма обучения – алгоритм упругого распространения.

Среднеквадратичная относительная погрешность на обучающем множестве примеров составила 17,4%, а на тестовом 36,9%. Поскольку примеры тестирующего множества не использовались при обучении нейронной сети, можно утверждать, что нейронная сеть усвоила закономерности моделируемой предметной области, и теперь ее можно использовать для проведения вычислительных экспериментов.

На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактической и прогнозируемой нейросетью, данные взяты из тестирующего множества.



Рисунок 1. Результат тестирования нейронной сети

В списке тестового множества данные с 1 по 20 – сердечной недостаточности не было, начиная с 21 – произошла. Как мы видим, нейросеть ошиблась в общем 6 раз, что говорит нам примерно о 20% ошибок, причем данные по ошибкам смешены в сторону произошедших смертей, что считается неприемлемым, нейросеть не ставит диагноз для тех, кто не болел, но часто ошибается с теми, у кого сердечная недостаточность все-таки произошла. В связи с этим, было принято решение увеличить чувствительность, для этого данные в обучающем множестве необходимо размножить, увеличить количество данных с уже случившейся сердечной недостаточностью, но перед этим выделить отдельно тестовое множество (либо оставить то тестовое множество, на котором тестировали предыдущий раз), для того, чтобы примеры из

обучающего множества не попали в тестовое. В результате, для обучающего размноженного множества получилось 442 примеров.

Среднеквадратичная относительная погрешность на обучающем множестве примеров составила 16,15%, а на тестовом 40,87%. Структура нейросети осталась прежней, теперь можно сравнить данные, которые получились на Рисунке 3.

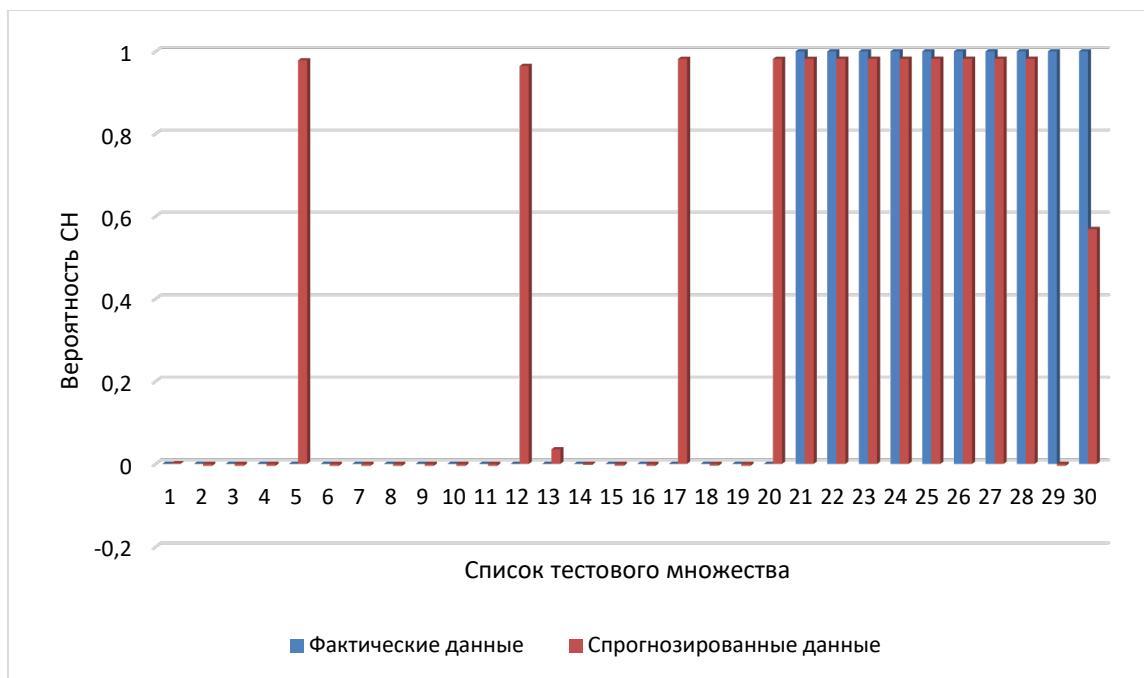


Рисунок 2. Результат тестирования нейронной сети после аугментации

Как мы видим, нейросеть ошиблась примерно также, в общем 6 раз, что говорит нам примерно о 20% ошибок, однако ошибки сместились уже в сторону тех, кто не болел, а для тех, кто перенес сердечную недостаточность – нейросеть стала предсказывать лучше и ошиблась всего два раза, что говорит нам об улучшении качества предсказания диагноза, а также можно сделать вывод об адекватной работе спроектированной нейронной сети. Далее, рассмотрим оценку значимости входных параметров, которая была выполнена с помощью программы «Нейросимулятор 5», результат отображен на рисунке 3.

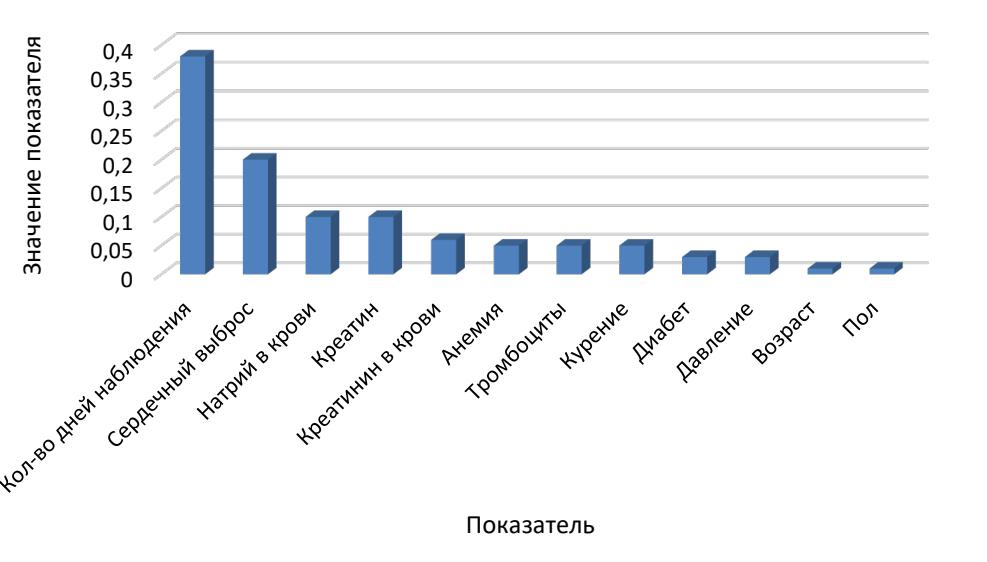


Рисунок 3. Значимость входных параметров нейросетевой модели

Как видно из рисунка 3, наиболее значимыми являются длительность наблюдения за пациентом в днях, процент крови, покидающий сердце при каждом сокращении, натрий в крови и креатин имеют идентичную значимость и т.д. Также на графике можно видеть параметры, которые имеет нулевую значимость – это возраст и пол, то есть можно предположить, что эти показатели не оказывают достаточного влияния на возникновение сердечной недостаточности. В связи с этим было принято решение проанализировать показатель «возраст» отдельно на выбранных ниже пациентах и увидеть, наблюдается ли какая-то закономерность.

Далее было проведено исследование влияния показателей на отдельных пациентов. Исследование производилось с помощью метода «замораживания» [2], суть которого заключается в варьировании значения одного параметра и фиксировании значений всех других параметров. Данный метод позволяет выявить влияние исследуемого параметра на выходной. Для этой цели были отобраны 4 пациента, информация о параметрах которых отражена в таблице 2.

Таблица 2
**Характеристики пациентов,
выбранных для исследования**

	Пациент 1	Пациент 2	Пациент 3	Пациент 4
X1	45	60	55	58
X2	0	1	0	1
X3	582	76	582	400
X4	0	1	1	0
X5	14	25	35	40
X6	0	0	1	0
X7	166000	196000	371000	164000
X8	0,8	2,5	0,7	1
X9	127	132	140	139
X10	1	0	0	0
X11	0	0	0	0
X12	14	77	197	91
D1	1	1	0	0

На рисунке 4 продемонстрирована зависимость сердечной недостаточности от сердечного выброса. В данном случае можно сделать вывод, что этот показатель оказывает серьезное воздействие у склонных к заболеванию пациентов. В частности, у Пациента 1 этот параметр, согласно Таблице 2, самый низкий, что говорит о нездоровом слабом сердце, так как при каждом сокращении сердце не может прокачать большой объем крови, а ограничивается малым количеством, работать сердечной мышце необходимо гораздо усерднее. На рисунке 4 при виртуальном увеличении выброса у Пациентов 1 и 2 сердечная недостаточность падает при достижении значения в 36-38%.

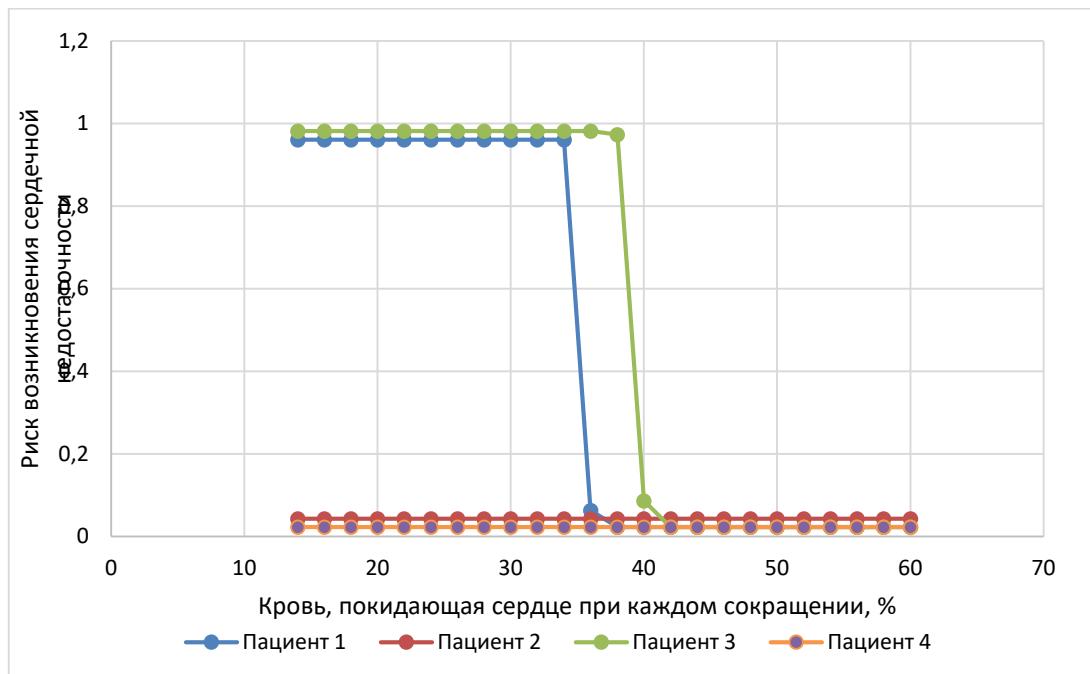


Рисунок 4. Влияние сердечного выброса на вероятность возникновения сердечной недостаточности

На рисунке 5 продемонстрирована зависимость между возрастом пациента и риском сердечной недостаточности, маркер увеличенного размера на графиках соответствует реальному возрасту пациентов. Как видно из графиков, наибольший риск приходится на возраст 76-78 лет, но в особых случаях риск возникает и раньше, например, как у Пациента 1 в возрасте 40-50 лет вероятность растет и достигает своего пика после 50 лет, но в целом наибольшую вероятность заболеть имеют люди уже старшего возраста.

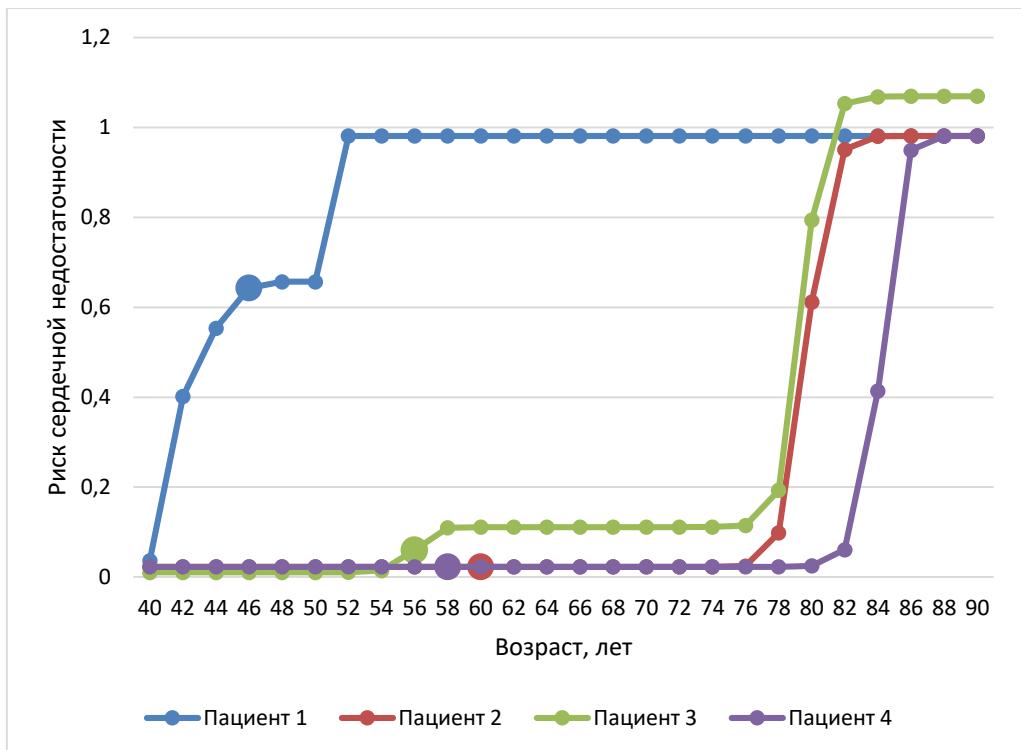


Рисунок 5. Влияние возраста на вероятность возникновения сердечной недостаточности

Особое внимание стоит обратить на Пациента 1. Так как мы анализировали его показатели и ранее на предыдущих рисунках, можно предположить, что риск сердечной недостаточности у него возникает раньше остальных по совокупности факторов, таких как содержание натрия в крови, сердечного выброса и т.д., с возрастом вероятность данной болезни только увеличивается. Статистика по каждому показателю у Пациента 1 показывала себя со стороны риска возникновения заболевания, даже, несмотря на то, что из выборки он самый молодой.

Полученные результаты исследований не противоречат известным медицинским знаниям, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для прогнозирования сердечной недостаточности.

Как мы видим, путем исследования построенной нейросети мы получаем определенные закономерности, которые без нее мы вряд ли бы смогли заметить. Это подтверждает то, что методы искусственного интеллекта, в частности, нейросетевые технологии, являются полезным инструментом для построения систем извлечения новых медицинских знаний из данных [3, 5-9].

Заключение. Разработана нейросетевая математическая модель, использованная для прогнозирования сердечной недостаточности. Модель и эксперименты, проводимые с ней, могут быть использованы для определения действий, которые необходимо предпринять для профилактики сердечной недостаточности. На примере представленных данных были получены определенные знания в виде графиков, которые могут быть использованы медицинскими работниками или активными гражданами в реальной жизни для определения риска сердечной недостаточности у склонных к ней пациентов.

Библиографический список

1. Kaggle. Наборы данных [Электронный ресурс]. URL: <https://www.kaggle.com/andrewmvd/heart-failure-clinical-data> (Дата обращения 13.03.2021)
2. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.
3. Ясницкий Л.Н. Нейронные сети – инструмент для получения новых знаний: успехи, проблемы, перспективы // Нейрокомпьютеры: разработка, применение. 2015. № 5. С. 48-56.
4. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
5. Ясницкий Л.Н. Интеллектуальные системы / Лаборатория знаний, 2016. – 221 с.
6. Ярославская Е.И., Дьячков С.М., Горбатенко Е.А. Применение аппарата искусственных нейронных сетей в прогнозировании фибрилляции предсердий у мужчин с ишемической болезнью сердца. Сибирский журнал клинической и экспериментальной медицины. 2020;35(4):119-127. <https://doi.org/10.29001/2073-8552-2020-35-4-119-127>
7. Yasnitsky L.N., Dumler A.A., Cherepanov F.M. Dynamic artificial neural networks as basis for medicine revolution // Advances in Intelligent Systems and Computing. 2018. Т. 850. С. 351-358.
8. Yasnitsky L.N., Dumler A., Cherepanov F.M. The capabilities of artificial intelligence to simulate the emergence and development of diseases, optimize prevention and treatment thereof, and identify new medical knowledge // Journal of Pharmaceutical Sciences and Research. 2018. Т. 10. № 9. С. 2192-2200.
9. Yasnitsky L.N. Artificial Intelligence and Medicine: History, Current State, and Forecasts for the Future // Current Hypertension Reviews, 2020, vol. 16, No 3. Pp. 210-215. DOI : 10.2174/1573402116666200714150953
<https://pubmed.ncbi.nlm.nih.gov/32664841/>

PROGNOSIS OF HEART FAILURE USING A NEURAL NETWORK MODEL

Kamalutdinova Ksenia P.

Perm State National Research University,
614990, Russia, Perm, Bukireva str., 15, kseniiakamalutdinova@gmail.com,
yasn@psu.ru

The article describes the development of a dynamic neural network system for predicting heart failure based on data provided from an open source. The system allows you to evaluate the propensity to heart failure based on the 12 signs described in detail in this paper. Using this data allows you to make the system adaptable to the current situation in the medical field.

Keywords: artificial intelligence, neural network technologies, heart failure, high blood pressure, prediction.

ОПРЕДЕЛЕНИЕ НАЛИЧИЯ ПНЕВМОНИИ ПО СНИМКАМ ГРУДНОЙ КЛЕТКИ

Шерстобитов Андрей Дмитриевич, Шестаков Андрей Алексеевич

Пермский государственный национальный исследовательский университет,

ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15.

rebelpolin@gmail.com

В статье представлено описание и результат разработки приложения для распознавания пневмонии. Приложение позволяет загрузить рентгеновский снимок потенциального больного и узнать, с какой вероятностью у него имеется пневмония.

Для обработки изображения была использована сверточная нейронная сеть.

Ключевые слова: искусственный интеллект, нейросетевые технологии, сверточные нейронные сети, медицина, оценка состояния больного, пневмония.

Введение

Пневмония – осложнение респираторных заболеваний дыхательных путей, вызванное вирусами, бактериями, а иногда грибковыми микроорганизмами. При пневмонии идёт поражение альвеол – концевых участков легких [1] на рисунке 1 представлен пример последствия заболевания пневмонией.

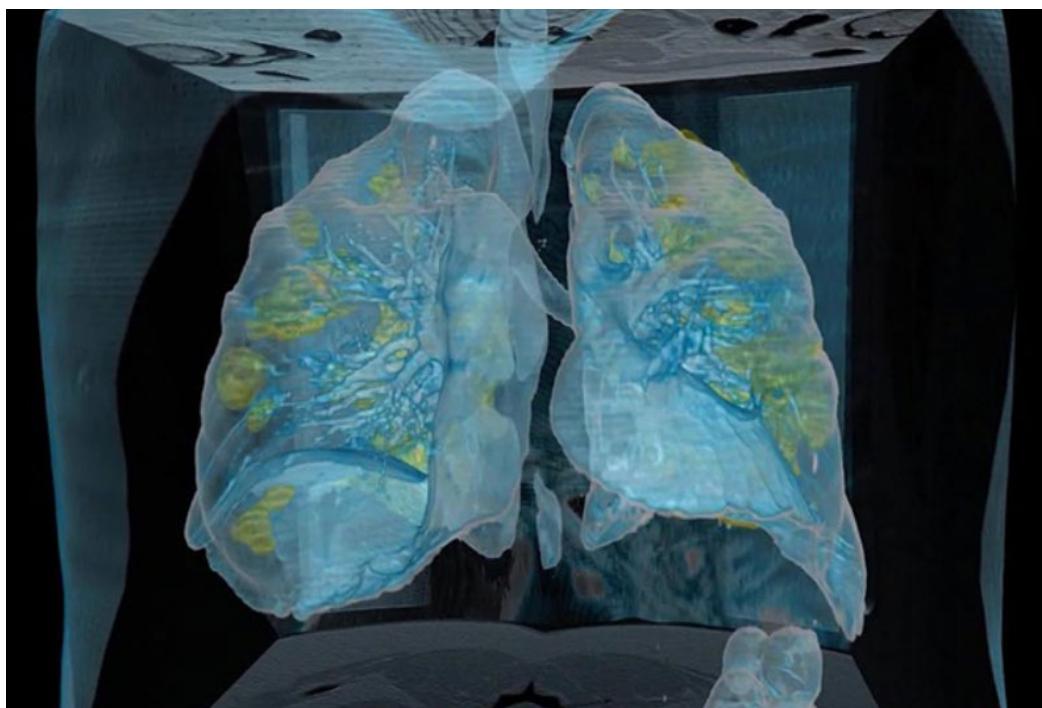


Рисунок 16. Последствия заболевания пневмонией

Если вовремя не выявить пневмонию с очаговым поражением легких и не предпринять лечения, последствия могут быть тяжелыми и необратимыми.

Конечно, в наше время большинство врачей могут по снимку определить наличие пневмонии у человека. Тем не менее даже опытные врачи могут ошибаться, поэтому для дополнительной проверки можно использовать автоматическую систему для выявления пневмонии. Абсолютно положиться на неё, конечно, нельзя, однако она может служить для подстраховки.

Также, данная проблема особенно актуальна на сегодняшний день в период пандемии, ведь коронавирус поражает альвеолы легких и способствует появлению фиброза легких и пневмонии.

В данной задаче необходимо произвести классификацию фотографии. Всего имеется 2 класса, поэтому в качестве функции потерь была выбрана функция “Binary crossentropy”. Для оптимизации обучения был выбран метод “Adam”, а для наглядного представления работы сети использовалась встроенная метрика “accuracy”.

Данные для обучения были взяты с сайта Kaggle [2], на котором находится более 5000 рентгеновских снимков грудной клетки.

Для решения задачи определения пневмонии по рентгеновскому снимку было принято решение использовать сверточные нейронные сети. Они отлично подходят для работы с изображениями. Такая технология реализовывалась при помощи инструментов tensorflow и keras.

На рисунке 2 приведена структура сверточной нейронной сети

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 148, 148, 32)	896
activation (Activation)	(None, 148, 148, 32)	0
max_pooling2d (MaxPooling2D)	(None, 74, 74, 32)	0
conv2d_1 (Conv2D)	(None, 72, 72, 32)	9248
activation_1 (Activation)	(None, 72, 72, 32)	0
max_pooling2d_1 (MaxPooling2 (None, 36, 36, 32)	0	
conv2d_2 (Conv2D)	(None, 34, 34, 64)	18496
activation_2 (Activation)	(None, 34, 34, 64)	0
max_pooling2d_2 (MaxPooling2 (None, 17, 17, 64)	0	
flatten (Flatten)	(None, 18496)	0
dense (Dense)	(None, 64)	1183808
activation_3 (Activation)	(None, 64)	0
dropout (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 1)	65
activation_4 (Activation)	(None, 1)	0

Рисунок 17. Структура нейронной сети

В нейронной сети были использованы сверточные слои Conv2D, которые создают ядро свертки, которое скользит вдоль двух измерений данных как показано на рисунке 3 [3].

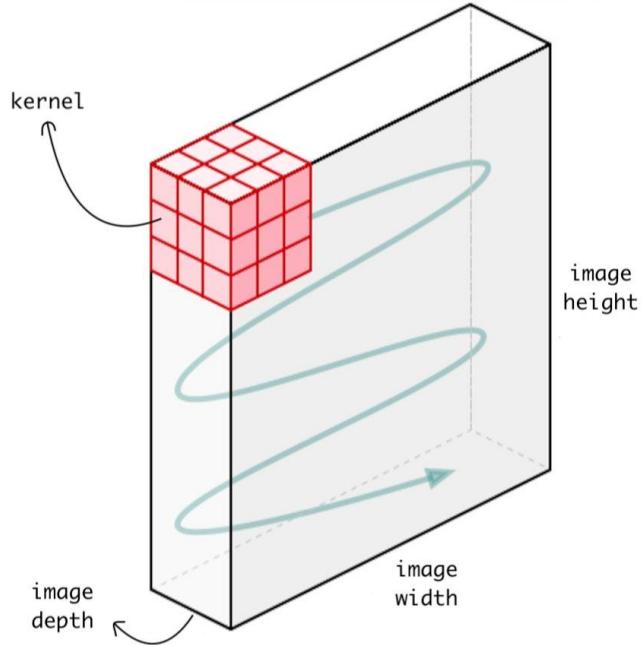


Рисунок 18. Пример работы Conv2D

Также в нейронной сети используются слои MaxPool2D, которые уменьшают дискретизацию входного представления, принимая максимальное значение в окне.

Для предотвращения переобучения был использован Dropout, данный метод убирает некоторые нейроны из сети для того, чтобы нейронная сеть пыталась найти другие веса для решения задачи, а затем усреднить полученные результаты. На рисунке 4 представлен пример работы Dropout.

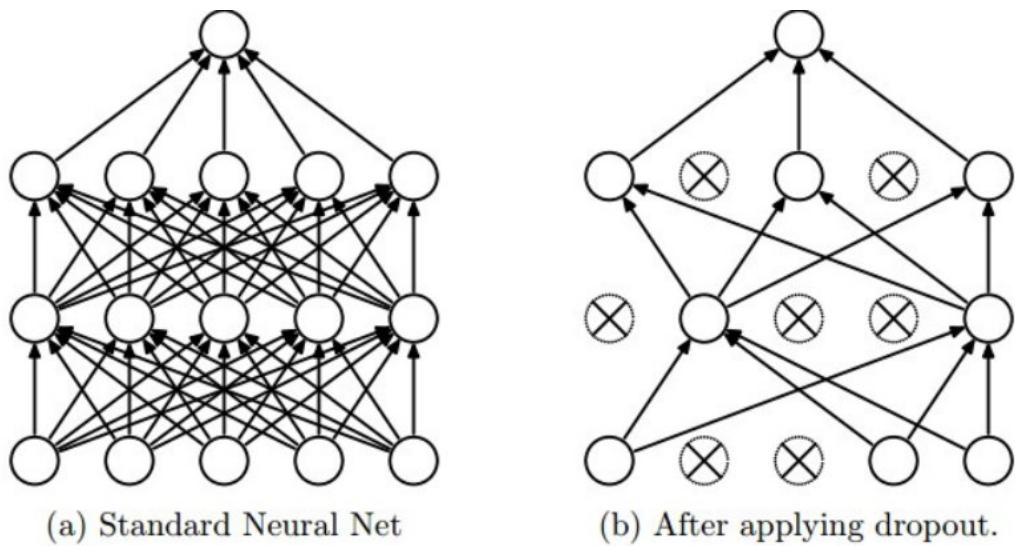


Рисунок 19. Пример работы метода Dropout

Ещё одним способом борьбы с переобучением стало использование технологии аугментации на обучающей выборке, подробное описание которой можно найти в [4]. Данная технология немного преобразует данные во время обучения. Таким образом, их количество искусственно увеличивается. Благодаря такому подходу точность работы сети на тестовом множестве выросла примерно на 15%.

На скрытых слоях были использованы активационные функции: RELU и линейная. На некоторых слоях линейная функция вместо RELU давала более высокие результаты. На выходном слое стоит сигмоида. Ее область значений составляет промежуток от 0 до 1. По получившемуся значению можно судить о наличии или отсутствии на снимке болезни.

Исходные данные были разделены следующим образом: 5216 снимков в обучающем множестве, 624 в валидационном и 16 в тестовом.

На рисунках 5 и 6 представлены графики изменения accuracy и функции ошибок для обучающего и валидационного множества.

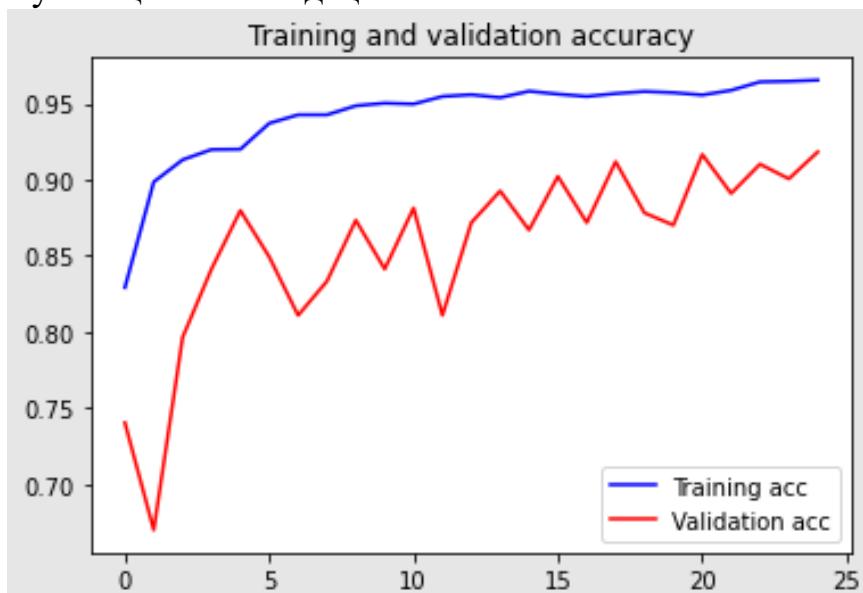


Рисунок 20. Изменение метрики accuracy

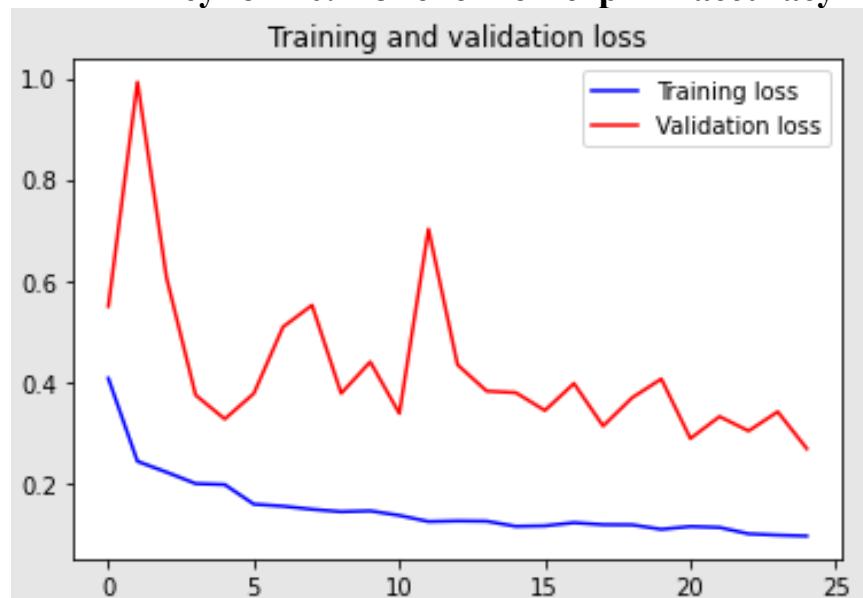


Рисунок 21. Изменение значения функции ошибок

Сеть верно распознала наличие или отсутствие пневмонии на 15 из 16 снимков из тестового множества. Единственная ошибка произошла на снимке здоровых легких. На нем обученная модель затруднилась дать какой-либо диагноз.

Полный код нейронной сети на языке python можно посмотреть по ссылке <https://github.com/alenayqa/Pneumonia/blob/main/pneumonianotebook.ipynb>

Также для удобства было создано графическое приложение, позволяющее быстро загружать изображение с компьютера и проверять наличие пневмонии. Внешний вид рабочего окна представлен на рисунке 7.



Рисунок 22. Внешний вид приложения

Приложение было написано при помощи Qt для python. Код можно увидеть по ссылке <https://github.com/alenayqa/Pneumonia/blob/main/main.py>

Заключение

В результате, было разработано приложение для определения наличия пневмонии с достаточно неплохой точностью. Разумеется, сеть не выдает абсолютно точный результат. По наблюдениям она лучше работает на снимках с имеющейся пневмонией, то есть она скорее найдет пневмонию там, где ее нет, чем не найдет там, где болезнь на самом деле есть.

Библиографический список

1. Википедия. Пневмония, URL – <https://ru.wikipedia.org/wiki/%D0%9F%D0%BD%D0%B5%D0%B0%D2%D0%BC%D0%BE%D0%BD%D0%B8%D1%8F> (Дата обращения 31.03.2021)

2. Chest X-Ray Images (Pneumonia)// Paul Mooney URL – <https://www.kaggle.com/paultimothymooney/chest-xray-pneumonia> (Дата обращения 31.03.2021)
3. Understand the concept of 1D, 2D, and 3D convolutional neural networks. URL – <https://www.programmersought.com/article/19365900370> (Дата обращения 31.03.2021)
4. Гайер А.В. Аугментация обучающей выборки «на лету» для обучения нейронных сетей / А.В. Гайер, А.В. Шешкус, Ю.С. Чернышова. – Труды ИСА РАН. Спецвыпуск, 2018.

DETECTING THE FACT OF PNEUMONIA BY CHEST IMAGES

Sherstobitov Andrey D., Shestakov Andrey A.

Perm State University,

Str. Bukireva, 15, Perm, Russia, 614990.

There are the description and the result of developing an application for recognizing pneumonia by chest images. The application is able to analyze the image and make a prediction about the disease. The analysis is performed using convolutional neural network technology.

Key words: artificial intelligence, neural network technologies, convolutional neural network, medicine, diagnostics of the patient's health, pneumonia'

НЕЙРОСЕТЕВАЯ СИСТЕМА ОЦЕНКИ ЧИСЛА НОВОЗАРАЖЁННЫХ КОРОНАВИРУСОМ ЧЕЛОВЕК В СТРАНАХ МИРА

Олейников Борис Олегович,

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15, borisxbetzeen@gmail.com

В статье представлено описание разработки нейросетевой системы для прогнозирования числа ново заражённых коронавирусом человек в любой стране. Система позволяет выполнять оценку числа ново заражённых в интересующей стране с учетом уровня медицины, индекса безопасности здоровья, текущей эпидемиологической ситуации, и ряда макроэкономических показателей этой страны. Использование макроэкономических параметров позволяет сделать систему адаптируемой к текущей экономической ситуации. Индекс безопасности здоровья и уровень медицины позволяют учесть общую эффективность медицинской системы в стране.

Ключевые слова: искусственный интеллект, нейросетевые технологии, самоадаптация, прогнозирование, коронавирус, эпидемиологическая ситуация.

Введение. Во времена нашей коронавирусной эпохи для поездок за границу, организации крупных бизнес проектов, ведения политики государства, чтобы не понести внезапных больших экономических потерь, становится очень важно понимание эпидемиологической ситуации в различных странах мира.

В ходе работы были изучены исследовательские работы на данную тему от зарубежных [1-2] и отечественных [3] исследователей. В данных работах наборы параметров, используемые для оценки объектов, учитывают частные параметры ситуации в конкретных странах, такие как степень самоизоляции, перечень принятых мер, характеристики коронавируса (трансмиссивность, летальность, инкубационный период и т.д.), но не учитывает общие характеристики самих стран (уровень медицины, макроэкономические показатели и др.), что делает эти системы не точными для применения к различным странам. В данной работе произведена попытка обучить универсальную нейросеть способную предсказывать число ново заражённых для любой страны.

После анализа источников [1-3], был выбран следующий набор показателей: X1 – общий ВВП по ППС (млрд. долларов США), X2 – ВВП по ППС на душу населения (долларов США), X3 – уровень медицины, X4 – эффективность использования выделенных на медицину денег, X5 –индекс безопасности здоровья, X6 – средний доход гражданина(долларов США), X7 – население, X8 – уровень безработицы(% от экономически активного населения), X9 –текущее число заражённых, X10 –число умерших больных, X11 –число

вакцинированных, X12 –медиана возраста, X13 –плотность населения. Выходной параметр D1 – число ново заражённых людей. Все параметры являются числовыми, поэтому для них кодировка не требуется.

В отличие от работ [1-3], используются более глобальные данные об общем состоянии страны.

Множество данных было получено с сайтов [4-11] и из базы данных ВОЗ [12]. Перед переходом к проектированию и обучению нейросетевой модели, была выполнена очистка исходного множества от противоречивых примеров, выбросов, дубликатов. Поиск выбросов статистической информации осуществлялся с помощью нейросетевой методики [13]. Таким образом, объем итогового множества включает в себя 4748 примеров. Данное множество было разделено на обучающее и тестирующее 4652 и 96 соответственно. Собранные данные охватывают период январь 2020 года-апрель 2021 года.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [14] по методике [15]. В результате оптимизации спроектированная нейронная сеть представляла собой персепtron, который имеет тринадцать входных нейронов, один выходной и один скрытый слой с одиннадцатью нейронами.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 96 примеров. Средняя ошибка тестирования составила 4,5%, что можно считать приемлемым результатом. На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактическим и прогнозируемым нейросетью числом ново заражённых для случайно отобранных 32 элементов из тестирующего множества.



Рисунок 1. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 1, можно сделать вывод об адекватной работе спроектированной нейронной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5», результат отображен на рисунке 2.

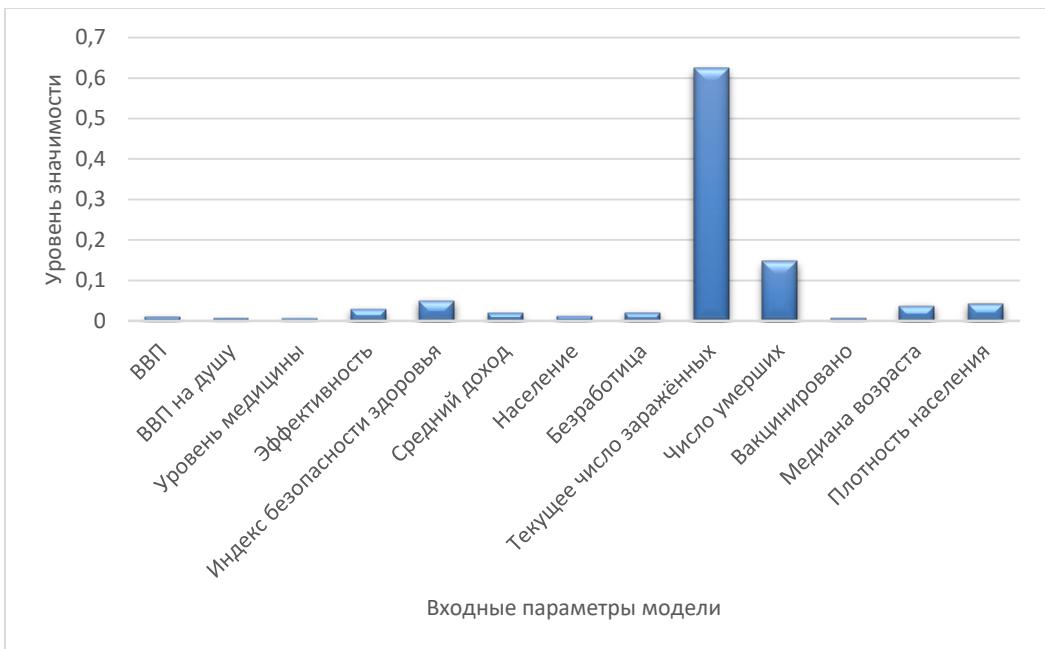


Рисунок 2. Значимость входных параметров нейросетевой модели

Как видно из рисунка 2, наиболее значимыми являются текущее число заражённых и число умерших. Также на графике можно видеть ряд параметров, которые имеют практически нулевую значимость, такие как ВВП, ВВП на душу населения, уровень медицины и вакцинированность населения. Первые 3 скорее всего имеют довольно малое значение и при большей выборке данных для разных стран, вакцинированность же показывает низкие значения из-за ничтожно малого по отношению к общему населению количеству и на будущих наборах её значимость должна возрасти.

Также были рассчитаны коэффициенты корреляции Пирсона между входными параметрами модели и выходным (числом ново заражённых). Результат расчета представлен на рисунке 3 в виде гистограммы.

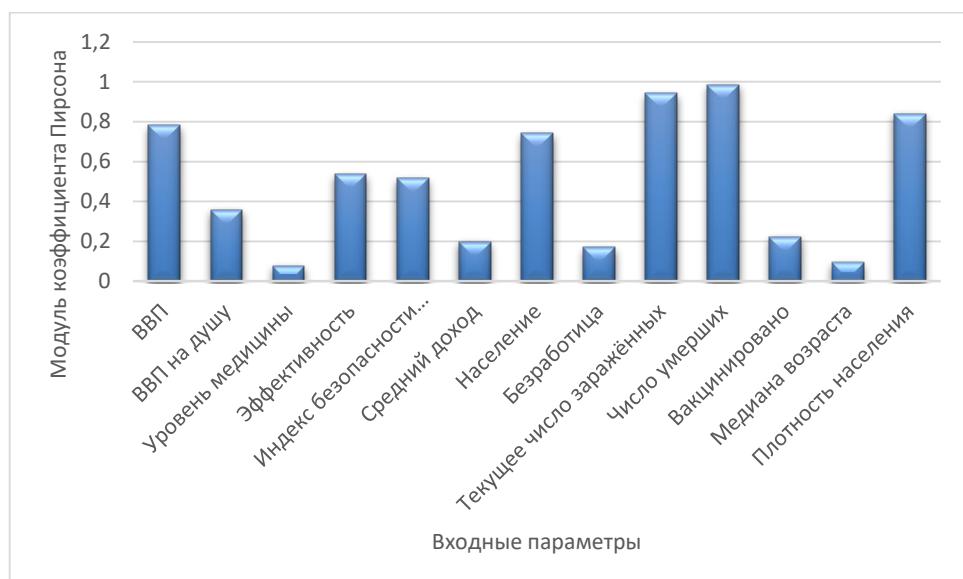


Рисунок 3. Значения модулей коэффициентов корреляции Пирсона между входными параметрами и стоимостью квартир

Расчет значимости с помощью программы «Нейросимулятор 5» позволил выявить влияние данных параметров на число ново заражённых.

Далее было проведено исследование данных. Исследование производилось с помощью метода «замораживания» [14], суть которого заключается в варьировании значения одного параметра и фиксировании значений всех других параметров. Данный метод позволяет выявить влияние исследуемого параметра на выходной. Для этой цели были отобраны 5 наборов данных соответствующих разным странам, информация о параметрах которых отражена в таблице 1.

Таблица 1
Характеристики наборов данных,
выбранных для исследования

Страна	Россия	США	Венесуэла	Чехия	Норвегия
X1	4097	20933	145	434	355
X2	27930	63416	5178	40618	65800
X3	58,01	69,2	39,37	75,18	74,51
X4	31,3	29,6	43,4	49,8	58,9
X5	44,3	83,5	23	52	64,6
X6	788	3921	24,6	1454	5450
X7	146238185	329957441	33019000	10693939	5569100
X8	4,6	3,7	8,8	1,9	3,3
X9	4252876	27071236	191518	1392108	109137
X10	86821	470235	2047	23083	734
X11	8,823	35,608	36,253	137,176	14,462
X12	39,6	38,3	29	43,3	39,7
X13	4908178	31579100	250000	787591	1148882

На рисунке 4 показан график зависимости числа ново заражённых от числа уже заражённых. Как следует из графика, при большем числе уже зафиксированных случаев тем больше новых случаев.

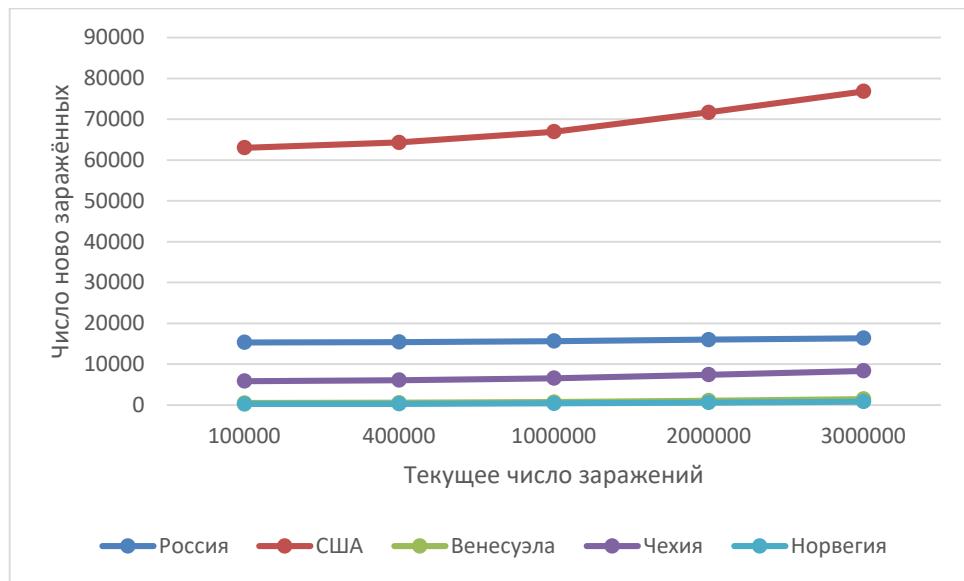


Рисунок 4. Зависимость числа ново заражённых от числа уже заражённых

На рисунке 5 продемонстрирована зависимость числа ново заражённых от числа умерших больных. В целом прослеживается тенденция к увеличению числа ново заражённых при увеличении числа погибших, но график США с некоторого момента начинает, наоборот, убывать, это указывает на возможный «переломный» момент в ходе эпидемии при котором люди начинают бояться вируса и становятся осторожнее. Для остальных стран данный момент не настал из-за специфик социально-экономического устройства. На рисунке 6 продемонстрирована зависимость числа ново заражённых от числа вакцинированных, где можно заметить незначительное снижение числа новых случаев заражения при росте числа вакцинированных.

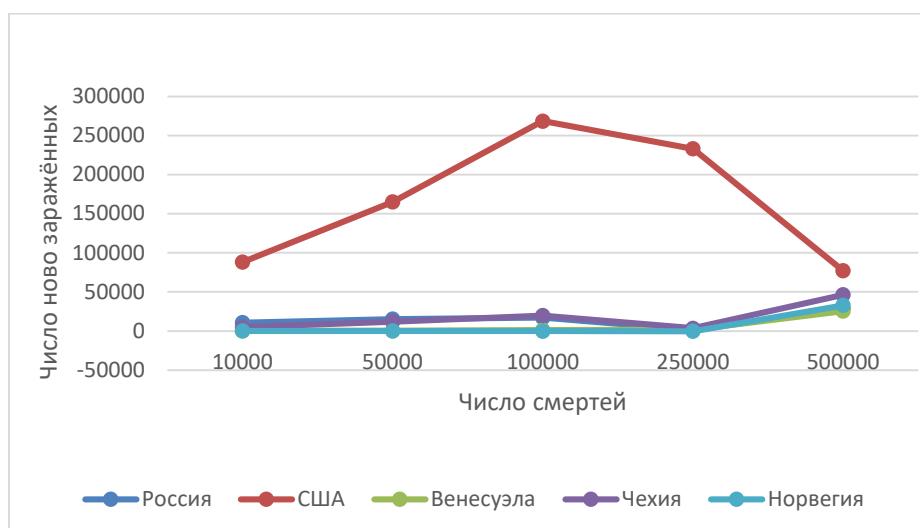


Рисунок 5. Зависимость числа ново заражённых от числа умерших больных

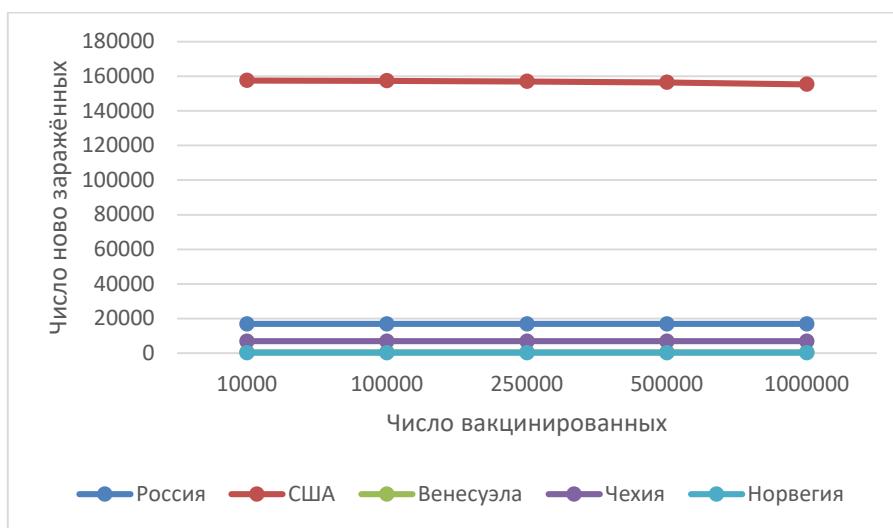


Рисунок 6. Зависимость числа ново заражённых от числа вакцинированных

Далее аналогичным методом было проведено исследование двух других наиболее значимых величин: индекса безопасности здоровья и медианы возраста.

На рисунке 7 изображен график зависимости от индекса безопасности здоровья. Как видно из графика, стоимость квартиры, расположенной ближе к центральной части города преимущественно выше. Интересно заметить, что с увеличением индекса безопасности здоровья увеличивается число заражённых. Такая-же тенденция наблюдается и в реальных данных, что хорошо показывает явную ошибку в логике составления критерия.

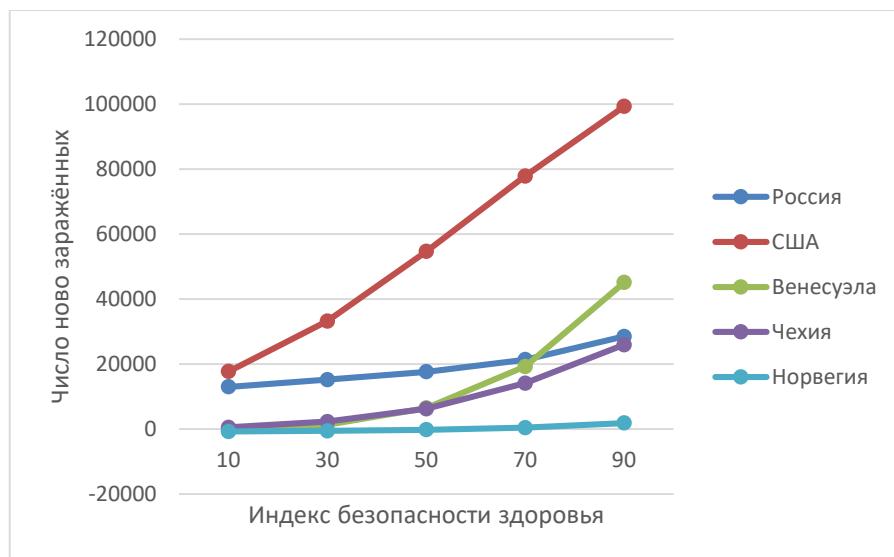


Рисунок 7. Зависимость числа ново заражённых от индекса безопасности здоровья

На рисунке 8 продемонстрирован график зависимости числа ново заражённых от медианы возраста. Как видно из графика, при увеличении медианы возраста с 20 до 30 лет происходит снижение числа заражённых из-за снижения доли «активной» молодёжи среди населения. Далее роль начинают играть остальные социально-экономические факторы, что приводит к разному поведению графиков.

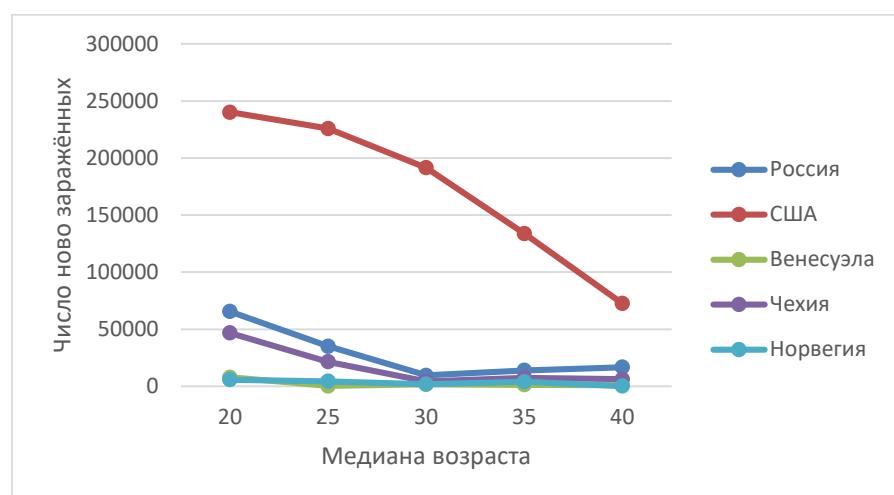


Рисунок 8. Зависимость числа ново заражённых от медианы возраста

Полученные результаты исследований не противоречат реальности, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для прогнозирования числа ново заражённых в различных странах мира.

Заключение. Построена система нейросетевого прогнозирования числа ново заражённых коронавирусной инфекцией для любой страны мира. Спроектированная нейросетевая модель учитывает три категории показателей, влияющих на число ново заражённых: медицинские, эпидемиологические, макроэкономические. Проведены исследования эпидемиологической ситуации ряда стран. Методом сценарного прогнозирования построены графики зависимостей числа ново заражённых от числа всех случаев заражения, смертей среди заражённых и числа вакцинированных, от индекса безопасности здоровья, а также от медианы возраста. Применение такого набора параметров в модели позволяет учитывать экономическую обстановку, различные эпидемиологические ситуации и качество медицинских услуг, а также может быть в дальнейшем уточнена для прогнозирования для прогнозирования ново заражённых в отдельных регионах и городах.

Библиографический список

8. Информационное агентство NONEWS URL:
<https://nonews.co/directory/lists/countries/health-care-index>
9. Информационное агентство NONEWS URL:
<https://nonews.co/directory/lists/countries/health>
10. Информационное агентство NONEWS URL:
<https://nonews.co/directory/lists/countries/global-health-security-index>
11. Гуманитарный портал URL: <https://gtmarket.ru/ratings/unemployment-ranking>
12. ВОЗ официальный сайт URL: <https://covid19.who.int/table>
13. Yasnitsky L.N. Algorithm for searching and analyzing abnormal observations of statistical information based on the Arnold – Kolmogorov – Hecht-Nielsen theorem // International Journal of Advanced Trends in Computer Science and Engineering. 2020. 9(2). Pp. 1814-1819. DOI:
10.30534/ijatcse/2020/139922020
<http://www.warse.org/IJATCSE/static/pdf/file/ijatcse139922020.pdf>
14. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
15. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.

NEURAL NETWORK SYSTEM FOR EVALUATING THE SECONDARY MARKET OF RESIDENTIAL REAL ESTATE OF THE CITY OF NIZHNY NOVGOROD

Oleinikov Boris O.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990,

borisxbetzezen@gmail.com

The article describes the development of a neural network system for predicting the number of newly infected people in any given country. The system allows people to evaluate the number of newly infected based on medical level, health safety index, current epidemiological situation and macroeconomic indicators. The use of macroeconomic parameters made it possible to make it adaptable to the current economic situation. Health safety index and medical level allows to take into account overall efficiency of medical system.

Keywords: artificial intelligence, neural network technologies, self-adaptation, forecasting, coronavirus, epidemiological situation.

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В ПСИХОЛОГИИ И СОЦИОЛОГИИ

ИЗУЧЕНИЕ ЗАВИСИМОСТИ МЕЖДУ БЕЗРАБОТИЦЕЙ И ПСИХИЧЕСКИМИ ЗАБОЛЕВАНИЯМИ

Волков Илья Игоревич

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
ilya@lispberry.com

В статье описано устройство нейросетевой системы для определения связи безработицы с психическими заболеваниями. Эта система позволяет оценить эффективность программ социального обеспечения и прогноз возможности дальнейшего трудоустройства за счет выявления причинно-следственных связей в зависимости от пола, возраста, уровня образования, занятости и наличием психического заболевания.

Ключевые слова: искусственный интеллект, нейронная сеть, безработица, психические заболевания, эффективность программ социального обеспечения, влияние психических расстройств на занятость, прогнозирование трудоустройства.

Введение.

На текущий момент количество людей, вынужденных сталкиваться с психическими заболеваниями, растет. Согласно статистике Всемирной организации здравоохранения (ВОЗ) за 2020 г., различному роду расстройств подвержен минимум каждый десятый человек на планете. Тем не менее этот фактор зачастую не учитываются при оценке уровня безработицы. Целью данной работы является разработка системы посредством применения современных методов искусственного интеллекта для предсказания факторов, влияющих на деятельность и занятость человека, имеющего психические заболевания.

В результате анализа литературных источников [1, 6, 8-10], был выбран следующий набор показателей:

X1 – возраст (18 – 29 лет – 0, 30 – 44 лет – 1, 45 – 60 лет – 2, >60 лет – 4),

X2 – пол (0 – женский, 1 – мужской),

X3 – образование (0 – среднее, 1 – бакалавр, 2 – магистр, 3 – доктор),

X4 – наличие психического заболевания (0 – нет, 1 – да);

Я имею одну из следующих проблем в дополнении к моей болезни(X5-X12):

X5 – нехватка концентрации (0 – нет, 1 – да),

X6 – тревожность (0 – нет, 1 – да),

X7 – депрессия (0 – нет, 1 – да),

X8 – навязчивое мышление (0 – нет, 1 – да),

X9 – перепады настроения (0 – нет, 1 – да),

X10 – панические атаки (0 – нет, 1 – да),
X11 – компульсивное переедание (0 – нет, 1 – да),
X12 – усталость (0 – нет, 1 – да);
X13 – ранее был госпитализирован из-за психического заболевания. (0 – нет, 1 – да),
X14 – сколько раз Вы были госпитализированы из-за вашего психического заболевания?,
X15 – Сколько дней вы были госпитализированы из-за психического заболевания?,
X16 – я живу с родителями (0 – нет, 1 – да),
X17 – я – инвалид (0 – нет, 1 – да),
X18 – в резюме есть пробел, т.е. не работал какое-то время (0 – нет, 1 – да),
X19 – длина пробелов в резюме (отсутствия работы) в месяцах,
X20 – годовой доход в тыс. \$ США,
X21 – годовой доход от социального обеспечения в тыс. \$ США,
X22 – семейный доход в тыс. \$ США (<10 – 0, 10...25 – 1, 25...50 – 2, 50...75 – 3, 75...100 – 4, 100...125 – 5, 125...150 – 6, 150...175 – 7, 175...200 – 8, >200 – 9, предпочли не отвечать на вопрос – 10),
X23 – получаю талон на питание (0 – нет, 1 – да).
Выходной параметр D1 – трудоустроен (0 – нет, 1 – да).

Данные были взяты с интернет-ресурса www.kaggle.com. В сборе данных участвовали люди с психическими заболеваниями, люди с расстройствами личности и люди без психических заболеваний. Полученные данные были разделены на два множества – на обучающее и тестирующее – в соотношении 80% и 20% соответственно.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [8] по методике [9]. В результате оптимизации спроектированная нейронная сеть представляла собой персепtron, который имеет 23 входных нейрона, 1 выходной и один скрытый слой с 4 нейронами. В качестве активационных функций нейронов скрытого слоя и выходного слоя использовался тангенс гиперболический, а в качестве алгоритма обучения – быстрого распространения. Средняя квадратичная ошибка тестирования составила 20,5%. Это достаточно большая точность для столь небольшого итогового множества и количества параметров, сильно влияющих на результат.



Рисунок 1. Результат тестирования нейронной сети

По результатам, изображенным на рисунке 1, мы можем сделать вывод, что спроектированная нейро-сетевая модель работает.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5», результат отображен на рисунке 2.

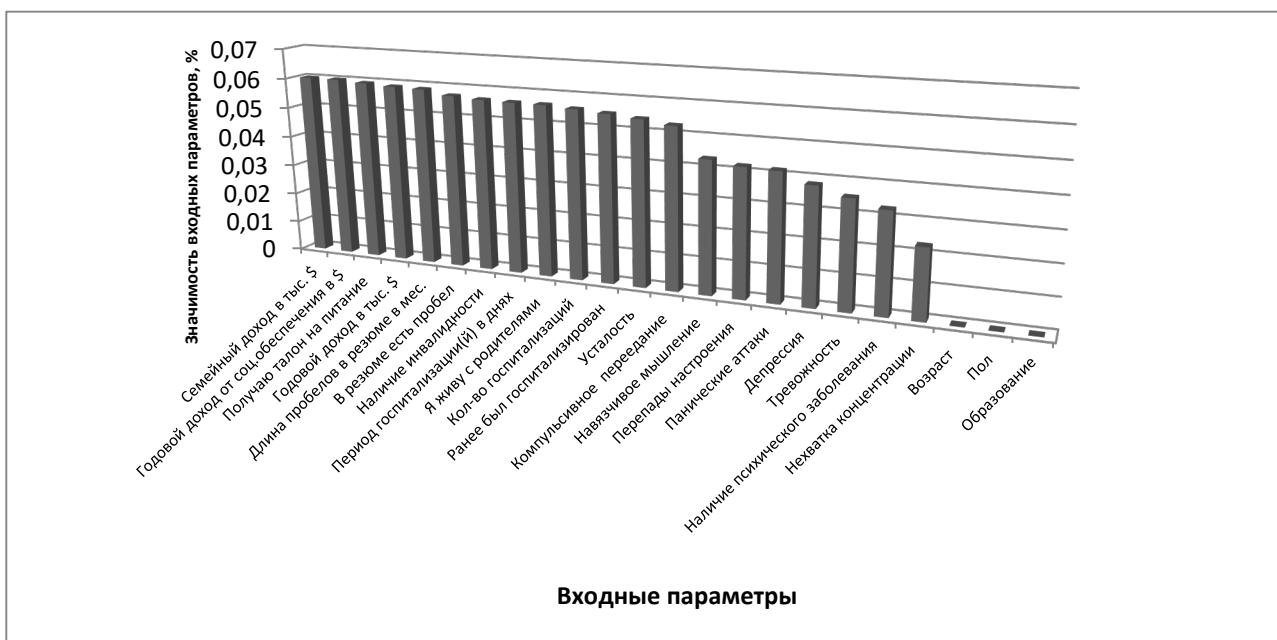


Рисунок 2. Значимость входных параметров нейросетевой модели

Как видно из рисунка 2, наиболее значимыми являются семейный доход, годовой доход от социального обеспечения и наличие талонов на питание, годовой доход, наличие и длина пробелов в резюме.

Стоит отметить, что коэффициент корреляции Пирсона параметра X4 – наличие психического заболевания равен -1. Это говорит о том, что наличие психического расстройства имеет полную обратную взаимосвязь с наличием работы.

Далее мы изучили данные исследования, проведенного среди людей, имеющих психические заболевания. Исследование производилось с помощью метода «замораживания» [2-5], суть которого заключается в варьировании значения одного параметра и фиксировании значений всех других параметров. Данный метод позволяет выявить влияние исследуемого параметра на выходной. Для этой цели были отобраны 5 респондентов, информация о параметрах которых отражена в таблице 1.

Таблица 1
Параметры респондентов, выбранных для исследования

Параметры\ № респондента	1	2	3	4	5
X1	1	1	1	2	0
X2	0	0	0	0	0
X3	1	1	1	0	1
X4	1	1	1	1	1
X5	1	1	1	1	1
X6	1	1	1	0	1
X7	1	1	1	1	1
X8	1	1	1	0	1
X9	1	0	1	0	1
X10	1	1	1	1	1
X11	1	1	1	0	1
X12	1	1	1	1	1
X13	0	0	0	1	1
X14	0	0	0	4	1
X15	0	0	0	27	28
X16	0	0	0	0	0
X17	0	1	0	1	0
X18	1	1	1	1	1
X19	28	52	24	73	59
X20	0	14	49	12	16
X21	0	14	0	13	0
X22	2	1	3	0	6
X23	1	1	0	1	0

На рисунке 4 показан график зависимости трудоустройства от величины годового дохода от социального обеспечения. Годовой доход от социального обеспечения был увеличен для каждого респондента на 10 тысяч \$ США. Из графика следует, что социальное обеспечение не помогает трудоустройству, а скорее его снижает.

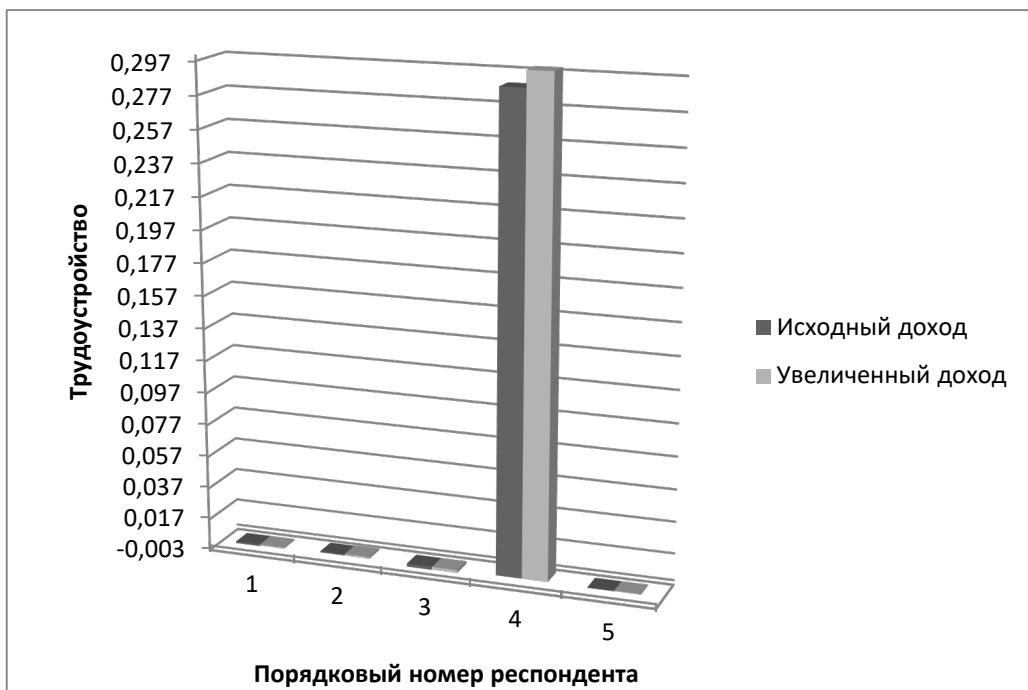


Рисунок 4. Зависимость трудоустройства от величины годового дохода от социального обеспечения

На рисунках 5 продемонстрирована зависимость трудоустройства от наличия пробелов в резюме, т.е. от наличия промежутков времени, когда человек не работал. Однако изменение этого параметра напрямую вызывало изменение и последующего за ним – длина данных пробелов на значение, равное 0. Из графика видно, что такое изменение может, как положительно (№1,2,3), так и отрицательно (№4,5) влиять на возможность трудоустройства.

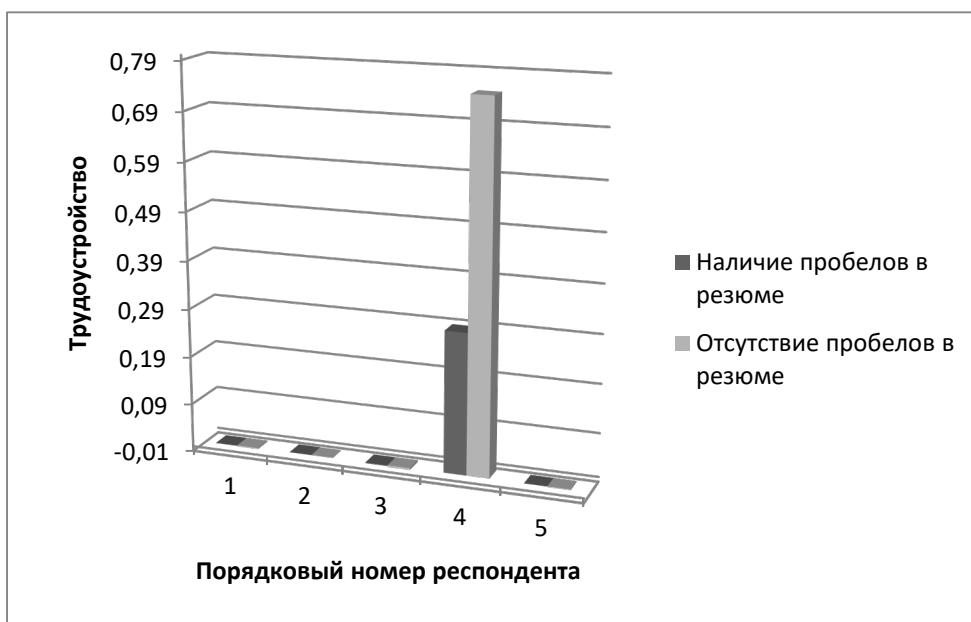


Рисунок 5. Зависимость трудоустройства от наличия пробелов в резюме

На рисунке 6 показана зависимость трудоустройства только от длины пробелов в резюме. Длина пробелов для каждого респондента была уменьшена

на 10 месяцев. Уменьшение значения данного параметра способствует повышению возможности трудоустройства.

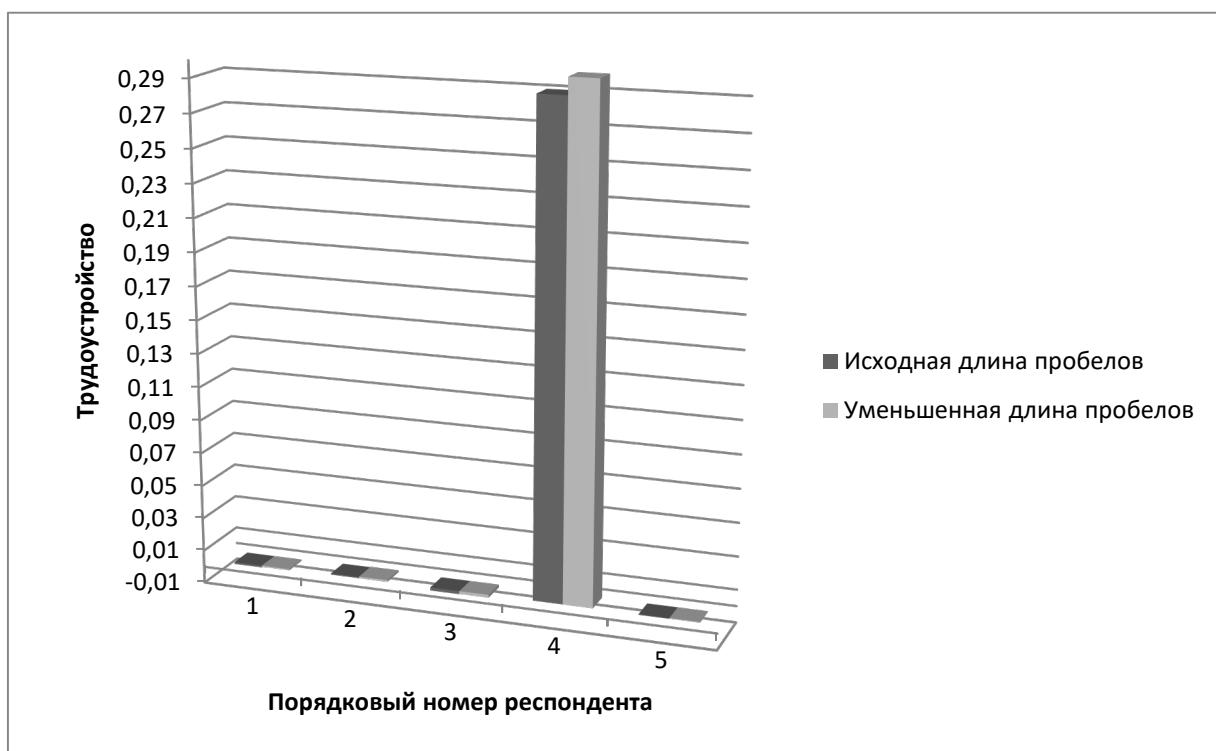


Рисунок 6. Зависимость трудоустройства от длины пробелов в резюме

Все предыдущие полученные результаты, представленные на рисунках 4-6, имеют общее объяснение. Человеку, особенно с наличием психического расстройства, необходимы особые условия занятости, чтобы не портить его психического здоровья. Мало какое место подходит для этого, поэтому люди с высоким социальным обеспечением предпочитают не работать, так как имеют достаточно средств для жизни. С другой стороны, отсутствие опыта работы может также отрицательно повлиять на дальнейшее трудоустройство, так как может говорить, что человек не способен к работе или к тому, чтобы долго оставаться на одном месте. Это в свою очередь приводит к развитию психической болезни и отрицательно сказывается на возможности трудоустройства. Противоположную ситуацию мы видим на рисунке 6, где меньшее количество пробелов в трудовом стаже положительно влияет на трудоустройство человека.

Далее аналогичным методом было проведено исследование влияния наиболее значимых психических расстройств или их симптом.

На рисунке 7 изображен график зависимости трудоустройства от наличия компульсивного переедания соответственно.

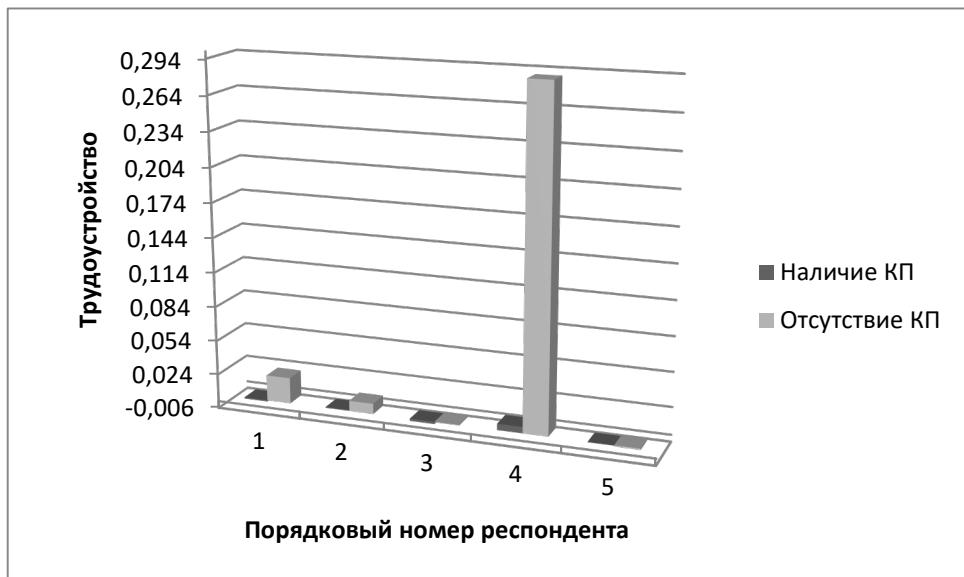


Рисунок 7. Зависимость трудоустройства от компульсивного переедания

Как видно из данных графиков, отсутствие данных расстройств или их симптом напрямую влияют на повышение возможности не остаться безработным.

Заключение. Построена система нейросетевого оценивания возможности трудоустройства, выявляющая причинно-следственные связи между наличием работы и состоянием психического здоровья человека. Проведены исследования среди людей имеющих психическое заболевание для выявления причин безработицы. Методом сценарного прогнозирования построены графики зависимостей возможности быть трудоустройственным от величины годового дохода от социального обеспечения, наличия пробелов в резюме, длины пробелов в резюме, наличия усталости и компульсивного переедания. Применение такого набора параметров в модели позволяет учитывать эффективность действий, предпринимаемых государством для решения данной проблемы с течением времени, а также может быть в дальнейшем расширена и усовершенствована для наиболее точного выявления причин и прогнозирования трудоустройства, что в свою очередь позволит улучшить психическое состояние населения и уменьшить процент безработных людей.

Библиографический список

1. Мацумото Д. Психология и культура. 3-е издание, 2002 год, 720 стр. //Культура и физическое здоровье//Социокультурное влияние на физическое и психическое здоровье и развитие болезней. С.193.
2. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005 – 176 с.
3. Ясницкий Л.Н., Ясницкий В.Л. Разработка и применение комплексных нейросетевых моделей массовой оценки и прогнозирования стоимости жилых объектов на примере рынков недвижимости Екатеринбурга и

- Перми // Имущественные отношения в Российской Федерации. 2017 №3(186). С. 68-84.
4. Ясницкий Л.Н. Нейронные сети – инструмент для получения новых знаний: успехи, проблемы, перспективы // Нейрокомпьютеры: разработка, применение. 2015. № 5. С. 48-56.
 5. Ясницкий Л.Н., Данилевич Т.В. Современные проблемы науки. М.: БИНОМ. Лаборатория знаний, 2008. 294 с.
 6. Свод методических рекомендаций по вопросам политики и оказания услуг в области психического здоровья Всемирная организация здравоохранения КОНТЕКСТ ПСИХИЧЕСКОГО ЗДОРОВЬЯ.
 7. Dataset: <https://www.kaggle.com/michaelacorley/unemployment-and-mental-illness-survey>
 8. <https://www.nami.org/Press-Media/In-The-News/2020>
 9. <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4182106/>
 10. <https://ps.psychiatryonline.org/doi/full/10.1176/appi.ps.201300335>

STUDYING THE CONNECTION BETWEEN MENTAL ILLNESS AND UNEMPLOYMENT

Volkov Ilya I.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990,

ilya@lisberry.com

In the article we describe the construction of a neural network system to determine the connection between mental illness and unemployment. The system allows to estimate the efficiency of the government's social programs and predict opportunities for employment thanks to the finding of links between sex, age, educational level, employment and the presence of mental illness.

Keywords: artificial intelligence, neural network, mental illness, unemployment, the effectiveness of social security programs, the impact of mental disorders on employment, employment forecasting.

АЛГОРИТМ И ТЕХНОЛОГИИ ИССЛЕДОВАНИЯ ВЛИЯНИЯ РЕКЛАМНЫХ РОЛИКОВ НА СТРЕССОВОЕ СОСТОЯНИЕ ЛЮДЕЙ

Смоляков Никита Сергеевич

Пермский государственный национальный исследовательский университет,
614068, Пермский край, г. Пермь, ул. Букирева, 15, ПМИ
dfa85kt65@mail.ru

Предложена методика численной оценки влияния рекламы на стрессовое состояние общества. Описаны некоторые результаты исследований, связанных с анализом влияния на стрессовое состояние социума рекламы с разной эмоциональной подачей информации. Предлагаемая методика может быть использована для оценки влияния рекламы, в том числе сети интернет, на социум с целью достижения обществом заданных целей. Предлагается использовать экспресс-методику для построения рейтингов телевизионных компаний, исходя из общих задач общества.

Ключевые слова: рекламный ролик, цифровой двойник человека, стрессовое состояние, психологическое влияние, компьютерная программа, психологические эксперименты, обработка результатов эксперимента.

В последнее время неуклонно растет количество мировых природных и социальных катаклизмов, что плохо отражается на психологическом состоянии социума в целом, приводящему к массовому отрицательному эмоциональному социальному перевозбуждению. Многие члены социума находятся из-за этого в состоянии постоянного повышенного стресса, порой, усугубляющегося способами подачи информации в рекламных роликах.

Приведем определение стресса, принятое в классической теории общей психологии человека: стресс – это совокупность неспецифических адаптационных (нормальных) реакций организма на воздействие различных неблагоприятных факторов-стессоров (физических или психологических), нарушающее его гомеостаз, а также соответствующее состояние нервной системы организма (или организма в целом). Излишне повышенный уровень стресса, как известно, может привести к различным заболеваниям, в том числе психическим.

В настоящее время профессорами О.Л. Фиговским (Израиль) и О.Г. Пенским (Россия) разработаны математические модели и алгоритмы, позволяющие определять психологическое влияние одного человека на другого [1]. В качестве входных параметров моделей могут быть использованы численные значения стресса, измеренные у испытуемых людей при их общении друг с другом, например, с помощью программы Vibraimage Санкт-

Петербургской компании ELSYS [2]. Реализация предложенных алгоритмов требует создания компьютерных программных приложений и продолжительности экспериментов не менее 12 минут) [1]. Работа [3], по сути, является уточнением и развитие положений, предложенных в работе [1]. Для вычисления коэффициентов влияния разработана специальная программа, зарегистрированная в Роспатенте [4]. В работе [5] приведена более простая экспресс-методика вычисления влияния одного субъекта на другого. Отметим, что значение стресса, используемого в этой методике, можно определить по среднему количеству микровибраций головы человека: большему количеству микровибраций в течение одной минуты соответствует больший стресс испытуемого. В Санкт-Петербургской компании ELSYS разработана компьютерная программа Vibraimage, одной из функций которой является измерение стресса человека по 100-балльной шкале именно на основе подсчета количества микровибраций его головы, определяемых с помощью обычной компьютерной web-камеры [2].

Предложенные модели можно использовать при вычислении влияния рекламы на стрессовое состояние аудитории.

На основе работы [5] опишем в виде алгоритма экспресс-методику оценки психологического влияния телевизионной рекламы на человека, основанную на использовании программы Vibraimage [2].

Предлагаются следующие пункты методики:

1. Измеряется [2] в течение 1 минуты стрессовое состояние А человека перед просмотром рекламного блока.
2. Человек просматривает рекламный блок в течение 10 минут.
3. Измеряется [2] в течение 1 минуты стрессовое состояние В человека после просмотра рекламного блока.
4. Вычисляется относительная величина S изменения стрессового состояния человека по формуле: $S=B/A \cdot 100\%$.
5. Вычисляется средние величины стресса испытуемых.
6. Если $S>100\%$, то просмотр рекламного ролика увеличивает стресс, если $S=100\%$, то стрессовое состояние испытуемого не меняется, если $S<100\%$, то просмотр рекламного ролика уменьшает стресс испытуемого.
7. Конец.

Для проведения исследования было обозначено два типа рекламных роликов: «агрессивная» и «спокойная» реклама. Для большего понимания специфики каждого их типов рекламных роликов опишем их более подробно.

«Агрессивная» реклама строится на эмоциональном восприятии информации. Это шоковая реклама, визуальная составляющая которой представляет собой иллюстрацию причинения физического или морального вреда, а также содержащая предположение о том, что может быть нанесен этот вред (Тулупов 2007). «Агрессивная» реклама в высшей мере натуралистична и откровенна, она призвана эпатировать публику. Такая реклама строится на сочетании нейтральной тональности, нейтрального видеоряда и шокирующего содержания диалога героев или нейтральной тональности и вызывающего отвращение или ужас визуального сопровождения. Например, ролик: девушка,

окруженная заспиртованными младенцами-уродцами, сидит на стуле и спокойным голосом рассказывает: Это Маша... когда я анашу курила (берет в руки заспиртованного младенца). Это Петя и Федя... Под экстази получились. Это Сашенька. Когда я на героине сидела. А это Оленька. Она почти родилась. Лозунг: Добро пожаловать в семью! Голос диктора: Любая доза любых наркотиков в любой срок беременности приводит к уродствам. 19 Для «шоковой» рекламы характерны также порицающая и назидательная (в меньшей степени) тональность: Каждый, кто молчит о продаже наркотиков в школе – держит во рту кусочек кала. Эффективность «шоковой» рекламы и ее этическая допустимость до сих пор остаются спорными. В «шоковой» рекламе наблюдается использование ненормативной лексики (хотя и в меньшей степени, чем в коммерческой рекламе), демонстрируются сцены сексуального характера (в отличие от коммерческой рекламы, обращающейся к сексуальным мотивам для рекламирования самых разнообразных товаров, в социальной рекламе обращение к подобным образом мотивировано тематикой), сцены насилия или последствия применения насилия, а также искалеченные болезнью или автокатастрофами тела людей. Неоднозначную оценку получает и появление образов детей в «шоковой» социальной рекламе, поскольку использование детских образов в рекламе товаров и услуг, для детей не предназначенных, запрещено. Кроме того, в ст. 6 п. 6 ФЗ «О рекламе» сказано, что не допускается «показ несовершеннолетних в опасных ситуациях». Так, билборд с текстом: Куриль в присутствии ребенка еще большая пытка для него. Все равно?! – с изображением младенца, о спину которого затушен окурок, комитет рекламы, информации и оформления Москвы расценил как рекламу, «выходящую за рамки общепринятых представлений об этичности» и пропагандирующую жестокое обращение с детьми.

«Спокойная» реклама, в отличии от «агрессивной» чаще всего добрая и избегает вызова негативных эмоций. Это ролики нейтрального или положительного характера, нацеленные сугубо на рекламу бренда или популяризацию объекта рекламы. «Спокойная» реклама, в основном, содержит информацию и не вторгается в личную жизнь людей. Например, реклама банка УралСиб, размещенная на баннерах сайта «Одноклассники»: (изображение старой фотографии молодой пары и современного фото двух пожилых людей) Столько лет прошло. Но вместе я и ты. Деньги не главное. Уралсиб. Это корпоративная реклама (разновидность коммерческой рекламы) компании Уралсиб, о чем свидетельствует оформление баннера в фирменном стиле компании: синий фон, особый шрифт, логотип, – который повторяются на буклетах, листовках и других рекламных материалах компании. В коммерческой рекламе такая мимикрия используется для создания имиджа социально ответственной компании, а в политической – для повышения доверия к политическому лидеру или партии. Но самое главное – реклама не касается личности смотрящего.

Авторами методики было вычислено среднее психологическое влияние отдельных телевизионных популярных рекламных роликов на группу испытуемых. И, хотя выборка испытуемых была небольшой, а поэтому мы не

можем с уверенностью говорить о ее репрезентативности, однако в результате экспериментов можно сформулировать следующие результаты:

- просмотр «агрессивных» рекламных роликов увеличил среднюю величину стресса группы испытуемых на 15% ($S=115\%$);
- Просмотр рекламных роликов, в которых информация подается в спокойном тоне («спокойных» роликов) снижают уровень стресса группы испытуемых на 22% ($S=78\%$).
- Возраст и пол испытуемых практически не влияют на изменение стрессового состояния испытуемых после просмотра рекламных видеороликов.

Отметим, что с помощью предлагаемой методики можно определить индивидуальное эмоциональное влияние рекламы на отдельного индивидуума.

Также отметим то, что не требующая большой математической подготовки предлагаемая экспресс-методика численной оценки влияния рекламы на стрессовое состояние общества может быть использована также для вычисления влияния любых медиа проектов, в том числе проектов сети интернет, на социум с целью достижения обществом заданных целей.

Предлагаемая методика может быть применима для оценки влияния телевизионных компаний на психологическое спокойствие или эмоциональное возбуждение общества, для этого достаточно оценить влияние на стресс всего социума каждого из медиа проектов компаний, после чего вычислить среднюю величину влияния компаний на стресс, исходя из влияний каждого из проектов компаний на аудиторию. Оценка влияния телекомпаний на социум позволит, например, строить рейтинги важности компаний, исходя из общих задач общества.

Библиографический список

1. Пенский О.Г., Анисимова С.И. Математическая модель коэффициентов влияния роботов друг на друга// Polish Journal of Science. № 28, 2020/ Pp. 22 – 27.
2. Пенский О.Г., Соловьева Т.Н. Вычисление коэффициентов влияния двух субъектов друг на друга. Свидетельство о государственной регистрации программы для ЭВМ № 2020618589 от 30 июля 2020 г.
3. Система виброЗображения Vibraimage. URL:
<http://www.elsys.ru/vibraimage.php> (дата обращения 23.12.2020).
4. Фиговский О.Л., Пенский О.Г. Вычисление коэффициентов влияния цифровых двойников друг на друга// Инженерный вестник Дона. №6. 2020. URL:
http://www.ivdon.ru/uploads/article/pdf/IVD_01_6_Figovsky_N.pdf_e70732d9a2.pdf (дата обращения 21.12.2020).
5. Фиговский О.Л., Пенский О.Г. Экспресс-метод определения психологического влияния медиа-проектов на человека// Наука и жизнь Израиля. URL: <http://nizinew.co.il/nauka/obshchestvennye-nauki/ekspress-metod-opredeleniya-psixologicheskogo-vliyaniya-media-proektov-na-cheloveka.html> (дата обращения 21.12.2020).

6. Солодовникова А. Н., Современная социальная реклама: способы воздействия на адресата URL:
https://www.sgu.ru/sites/default/files/dissnews/old/synopsis/Solodovnikova_0.pdf

ALGORITHM AND TECHNOLOGIES FOR STUDYING THE INFLUENCE OF COMMERCIALS ON THE STRESS STATE OF PEOPLE

Smolyakov Nikita S.

Perm State National Research University, Bukireva str., 15, Perm, Russia, 614068,
dfa85kt65@mail.ru

In this paper, we propose a method for the numerical assessment of the impact of mass media projects on the stressful state of society. Some research results related to the analysis of the impact of media projects of different thematic focus on the stress state of society are described. The proposed methodology can be used to assess the impact of media projects, including the Internet, on society in order to achieve the goals set by society. It is proposed to use an express methodology to build ratings of television companies based on the general objectives of society.

Keywords: advertising video, human digital twin, stressful state, psychological influence, computer program, psychological experiments, processing of experimental results.

УДК 004.89; 159.944

СОЗДАНИЕ НЕЙРОСЕТЕВОЙ МОДЕЛИ ДЛЯ ПРОГНОЗИРОВАНИЯ УРОВНЯ ВЫГОРАНИЯ ЧЕЛОВЕКА

Балчиков Василий Игоревич, Писцов Сергей Михайлович

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
spistsov@psu.ru, gitbleidd@psu.ru

В статье описано исследование и применение нейросетевой системы для прогнозирования выгорания сотрудников различных сфер деятельности. Из исследования были сделаны выводы, что пол сотрудника и стаж работы не влияют на выгорание. С другой стороны, часы работы и уровень стресса оказывают влияние на уровень выгорания.

Ключевые слова: нейронная сеть, прогноз, модель, синдром выгорания, эмоциональное состояние, гендер, стресс, стаж.

Введение. Выбор на данную тему пал в связи с тем, что проблема эмоционального выгорания актуальна в наше время. Жители около 30%

экономически развитых стран страдают от синдрома эмоционального выгорания.

Для исследования использовалось готовое множество для обучения нейросети с сайта Kaggle [1]. Опрос показал, что более 450 миллионов человек по всему миру живут с психическими расстройствами, которые могут стать главными причинами проблем со здоровьем и инвалидности. Анкета опросника содержала уникальный номер работника, дату присоединения к организации, пол работника, тип компании (сервис/производство), возможность работы на дому или на рабочем месте, стаж работника, часы работы в день, уровень психологической нагрузки и уровень выгорания работника. Для нейросети мы выделили следующие параметры:

Таблица 1
Параметры выгорания,
выбранные для исследования

Название параметра	Значение параметра	
	До преобразования	После преобразования
Гендер	Женский /Мужской	[0-1]
Сфера деятельности компании	Услуги/Производство	[0-1]
Возможность работы из дома	Да/Нет	[0-1]
Стаж сотрудника	0-50 лет	[0.0-5.0]
Часы работы	1-10 часов	[1.0-10.0]
Уровень психологической нагрузки	1 – отсутствие утомления 10 – полное утомление	[1.0-10.0]

Для прогнозирования использован метод нейросетевого моделирования [2, 3] и нейросимулятор [4].

Обучение нейронной сети проводилось на 14998 примерах, а тестирование на 3592 примерах. В итоге, средняя квадратичная относительная погрешность составила 5,4%.

В результате тестирование были получены следующие результаты, они представлены на рисунке 1. На диаграмме сопоставляются желаемые и действительные уровни выгорания. Исходя из того, что примеры тестового множества не использовались при обучении нейронной сети и проанализировав диаграмму и значение полученной погрешности, можно сделать вывод, что нейронная сеть усвоила закономерности моделируемой предметной области, и теперь можно использовать ее для проведения вычислительных экспериментов.

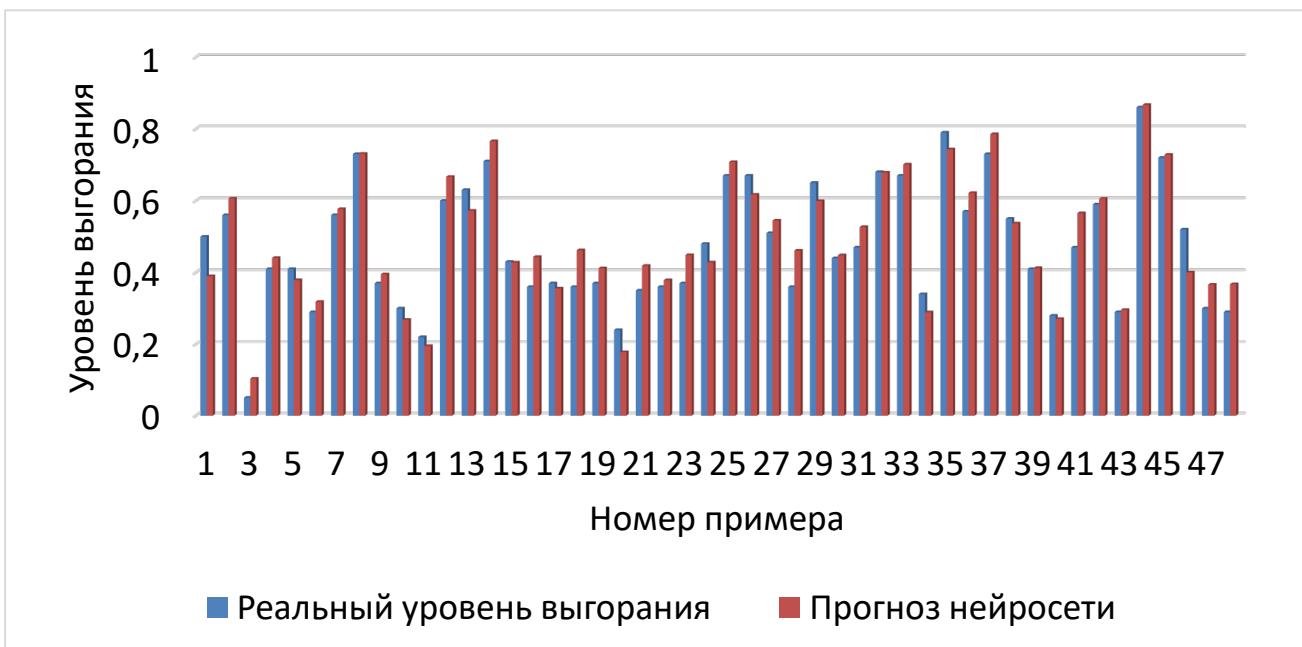


Рисунок 1. Результат тестирования нейронной сети

Экспериментальная часть. Один из первых вопросов, на которые можно ответить с помощью модели нейронной сети – выяснить значимость входных параметров, то есть степень их влияния на результат моделирования – уровень выгорания. Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5», результат отображен на рисунке 2.

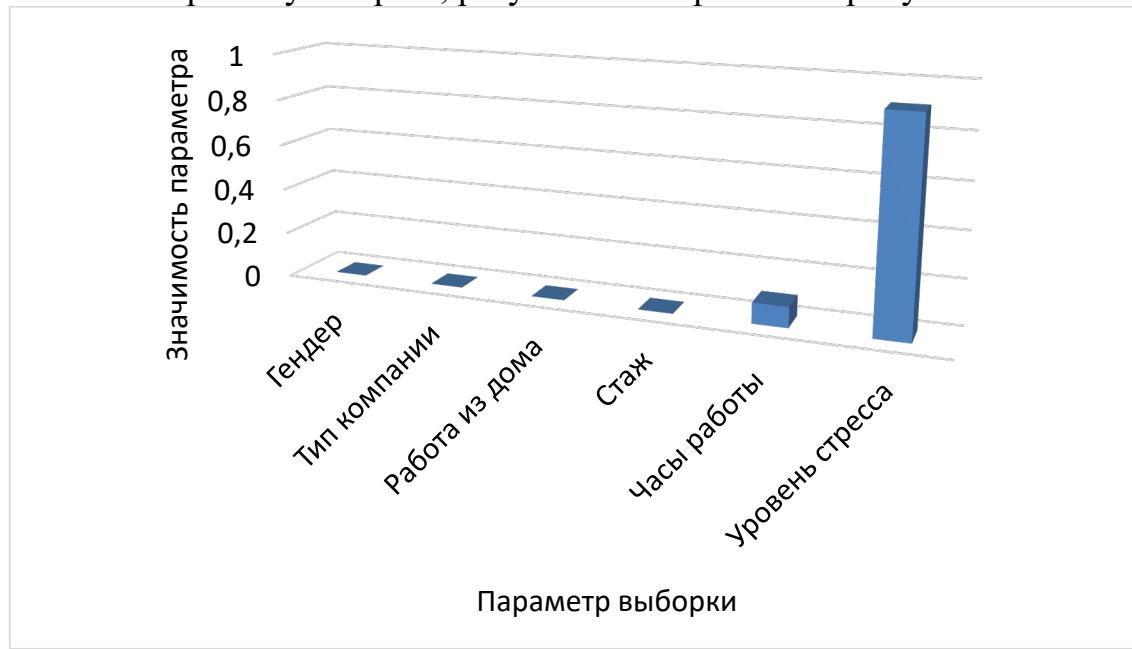


Рисунок 2. Значимость входных параметров нейросетевой модели

По рисунку 2 видно, что наибольшее влияние оказывает уровень стресса и время по сравнению с другими параметрами, которые практически не играют никакой роли в определение уровня выгорания.

Данное исследование базируется на выявлении зависимостей выгорания при очной форме работы.

Было произведено сравнения выгорания у мужчин и женщин с увеличением времени часов работы, результат на рисунке 3.

На рисунке 3 «заморожены» параметры стажа (0,5 из 5), уровень психологической нагрузки (1,5 из 10). На графике видно, что при данных «замороженных» параметрах мужчины в сфере услуг выгорают в меньшей степени, но, тем не менее, остальные графики ведут себя также практически одинаково.

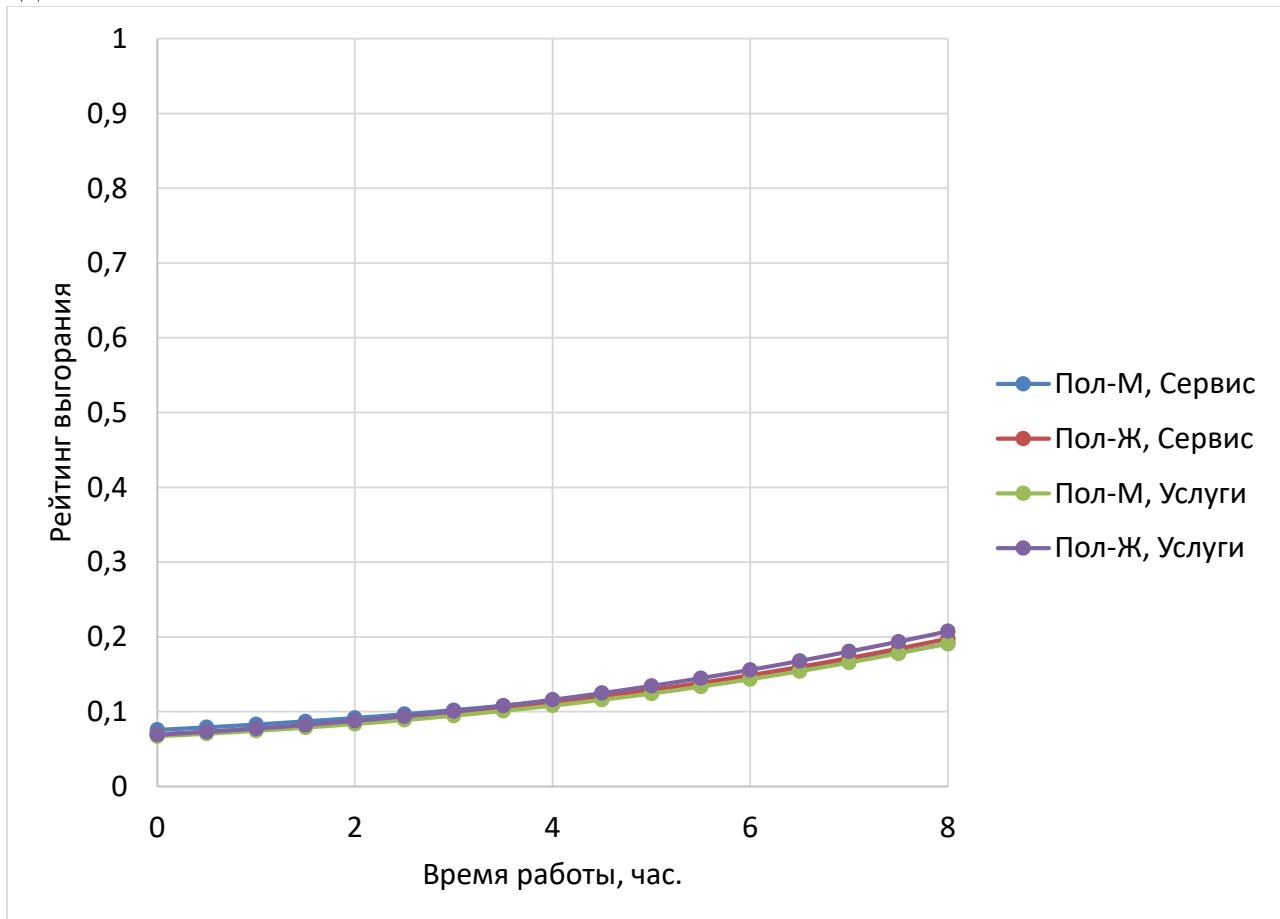


Рисунок 3. Зависимость выгорания от времени работы, низкий стаж, низкая психологическая нагрузка

Исходя из данного графика, можно сказать, что, действительно, с увеличением времени работы рейтинг выгорания повышается.

Далее было проведено сравнение уровня выгорания в зависимости от стажа сотрудника для мужчин и женщин в сферах услуг и сервиса при различных "замороженных" параметрах.

На рисунке 4 «заморожены» параметры часов работы (10 из 10), уровень психологической нагрузки (1,5 из 10). На данном рисунке прослеживается незначительная разница выгорания для женщин в сфере услуг и сервиса. Изначально общий рейтинг выгорания выше, так как часы работы «заморожены» на максимальном уровне.

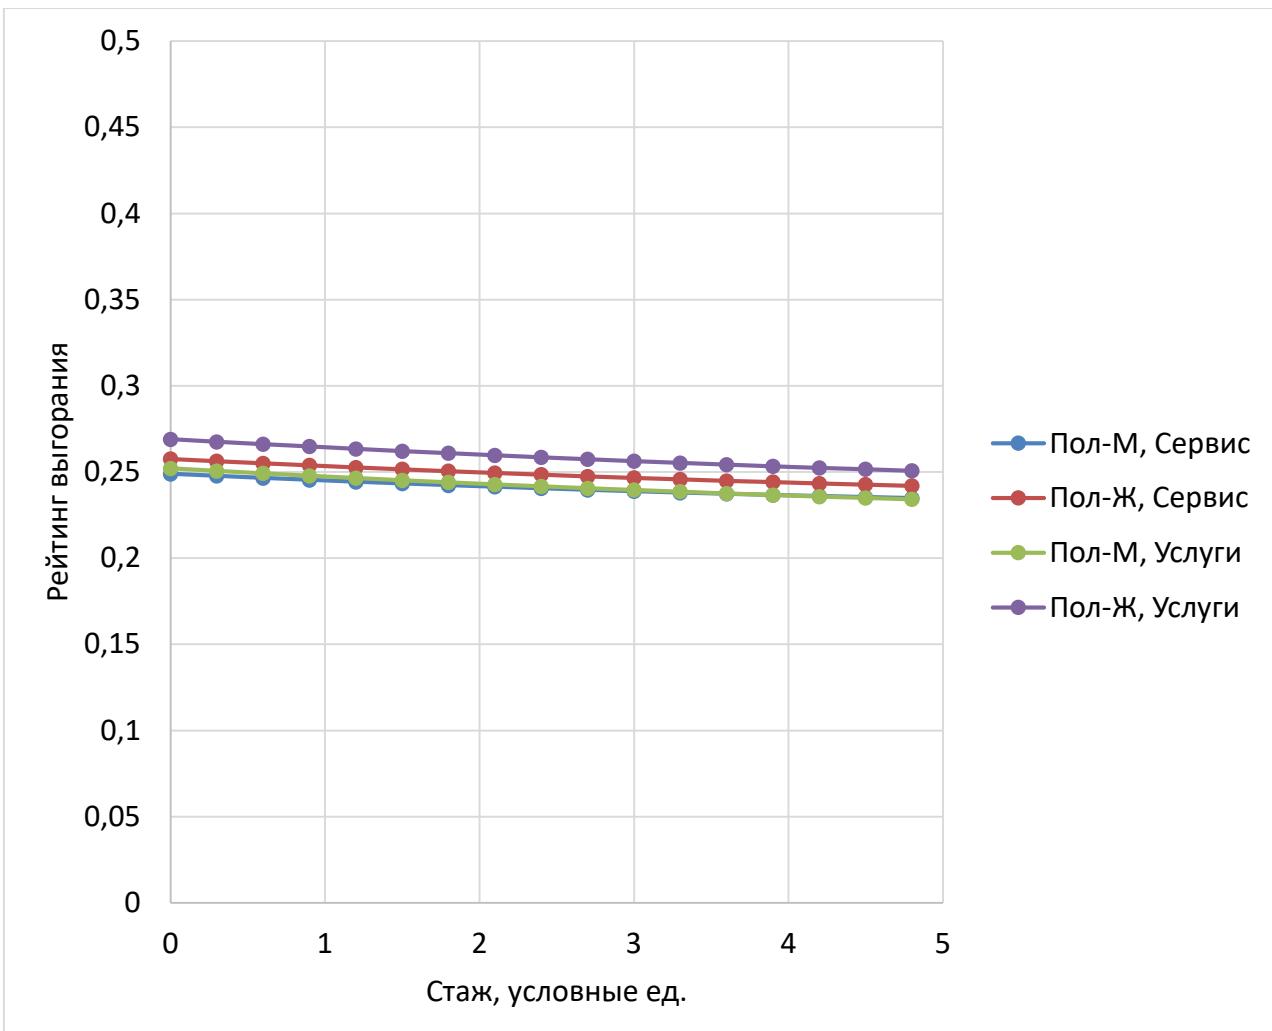


Рисунок 4. Зависимость выгорания от стажа сотрудника, высокий параметр часов работы и низкая психологическая нагрузка

Исходя из рисунка 4, можно сделать вывод что стаж не влияет на выгорание.

Таким образом, можно сказать, что между стажем и уровнем выгорания зависимость минимальна.

Заключение. В ходе исследования при помощи нейронного моделирования были выявлены две сильные зависимости: выгорания от уровня психологической нагрузки и выгорания часов работы. Это видно при «замораживании» остальных параметров. Также было выявлено, что уровень выгорания слабо зависит от стажа работы, сферы деятельности, гендера сотрудников. Это означает, что при изменении рассматриваемого параметра с изменением «замороженных» параметров, разница между графиками выгорания минимальна. Отсюда можно сделать вывод, что, вопреки популярному мнению о разнице уровня выгорания между различными гендерами и сферой деятельности сотрудников, оказалось, что влияние данных параметров сводится к минимуму. Тем не менее, такие параметры, как часы работы и уровень психологической нагрузки, оказывают большое влияние на степень выгорания сотрудников.

Библиографический список

1. Kaggle [Электронный ресурс]. – URL:
2. <https://www.kaggle.com/blurredmachine/are-your-employees-burning-out>
(дата обращения: 15.03.2021)
3. Ясницкий Л.Н. Введение в искусственный интеллект. – М.: Издательский центр «Академия», 2005 – 176 с.
4. Ясницкий Л.Н. Интеллектуальные системы. М.: Лаборатория знаний, 2016. 221 с.
5. Нейросимулятор 5.0: Свидетельство о государственной регистрации программы для № 2014618208 от 12.07.2014 г. / Черепанов Ф.М., Ясницкий Л.Н. (РФ).

DEVELOPMENT A NEURAL NETWORK MODEL FOR PREDICTING THE LEVEL OF HUMAN BURNOUT

Vasily Igorevich Balchikov, Sergey Mikhailovich Pistsov

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990, spistsov@psu.ru,
gitbleidd@psu.ru

The article describes the research and application of a neural network system for predicting burnout of employees in various spheres of activity. From this research it was concluded that the gender of the employee and record of service don't affect burnout. On the other hand, working hours and stress level have an impact on burnout level.

Keywords: neural network, prediction, model, burnout syndrome, emotional state, gender, stress, experience.

НЕЙРОСЕТЕВАЯ СИСТЕМА ОПРЕДЕЛЕНИЯ ИГРОВОЙ ЗАВИСИМОСТИ

Бахтин Павел Вячеславович, Проскуряков Владислав Сергеевич

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
vbahtin2001@gmail.com

В статье представлено описание разработки нейросетевой системы для определения и прогнозирования игровой зависимости. Система позволяет определять игровую зависимость у студента с учетом его результатов Единого Государственного Экзамена, пола и среднего балла за промежуточную аттестацию. Использование данных параметров позволяет сделать систему адаптируемой каждому студенту Механико-математического факультета.

Ключевые слова: искусственный интеллект, нейросетевые технологии, оценка положения, прогнозирование, студент, промежуточная аттестация, оценка игровой зависимости.

Введение. Во время учебы в высшем учебном заведении важно правильно распределять личное время, но зачастую студенты опрометчиво полагают, что компьютерная зависимость никак не повлияет на их учебную деятельность. Статистические данные показывают, что игровая зависимость пагубно влияет на успеваемость студента. Таким образом, очень важно оценить то, как компьютерные игры влияют на конкретного студента и итоги его промежуточной аттестации.

Личная оценка положения подразумевает человеческий фактор, например, можно пропустить важный критерий и/или сформировать некорректный результат. Поэтому для объективного оценивания воспользуемся интеллектуальными системами [1].

Цель данной работы заключается в сборе информации для формирования множества о состоянии учебной деятельности студента с учётом начальных интеллектуальных данных, а также в создании и обучении нейросетевой модели [2] на основе этих данных. Результатом исследования является система оценки зависимости от компьютерных игр.

В результате анализа литературных источников [3-5] был выбран следующий набор показателей: X₁ – пол, X₂ – балл ЕГЭ по информатике, X₃ – балл ЕГЭ по математике, X₄ – балл ЕГЭ по русскому языку, X₅ – средний балл за все сессии, D₁ – процент зависимости от компьютерных игр.

Параметр пол был закодирован: 1 – мужской, 2 – женский.

Так как все остальные параметры, используемые в данной исследовательской работе, являются числовыми будем использовать их в начальном виде без кодировки.

Выходной параметр – процент зависимости от компьютерных игр также является числовым параметром, поэтому будем выводить его в виде обычного числа в интервале от 0 до 100.

Множество входных данных о начальных интеллектуальных данных, поле и промежуточной аттестации было собрано при помощи созданного нами опроса [6]. Перед переходом к проектированию и обучению нейросетевой модели [2], была выполнена очистка исходного множества от противоречивых примеров, выбросов, дубликатов [1]. Например, некорректными данными считались те, где балл Единого Государственного Экзамена не соответствовал официальной таблице перевода первичных баллов во вторичные. Таким образом, объем итогового множества включает в себя 60 примеров. Данное множество было разделено на обучающее и тестирующее в соотношении 83%, 17% соответственно. Собранные данные охватывают период 2017-2020 гг.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [7] по методике [8]. В результате оптимизации спроектированная нейронная сеть представляла собой персептрон, который имеет пять входных нейронов, один выходной и один скрытый слой с двумя нейронами.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 10 примеров. Средняя ошибка тестирования составила 6,3%, что можно считать хорошим результатом. На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактическим и прогнозируемым нейросетью процентом зависимости от компьютерных игр, случайно отобранных 10 студентов из тестирующего множества.

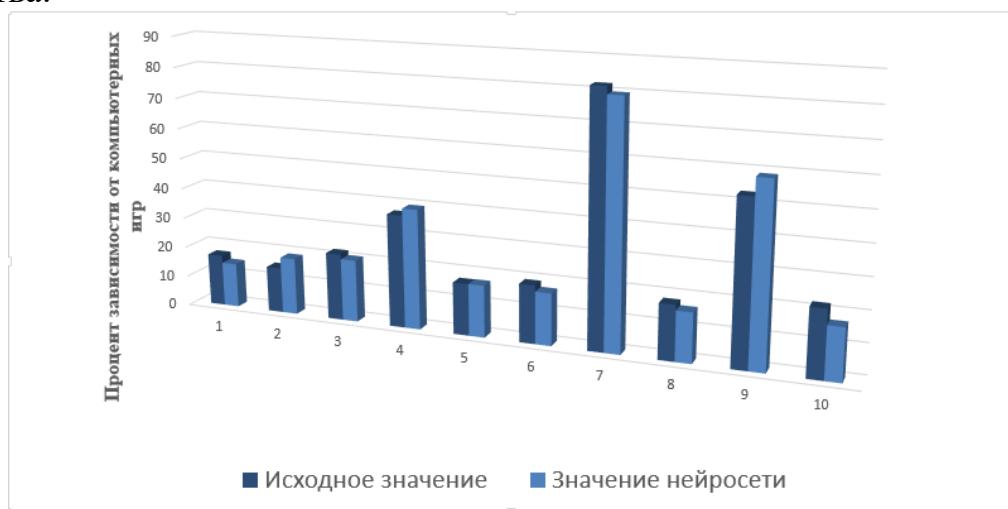


Рисунок 1. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 1, можно сделать вывод об адекватной работе спроектированной нейронной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5» [7], результат отображен на рисунке 2.

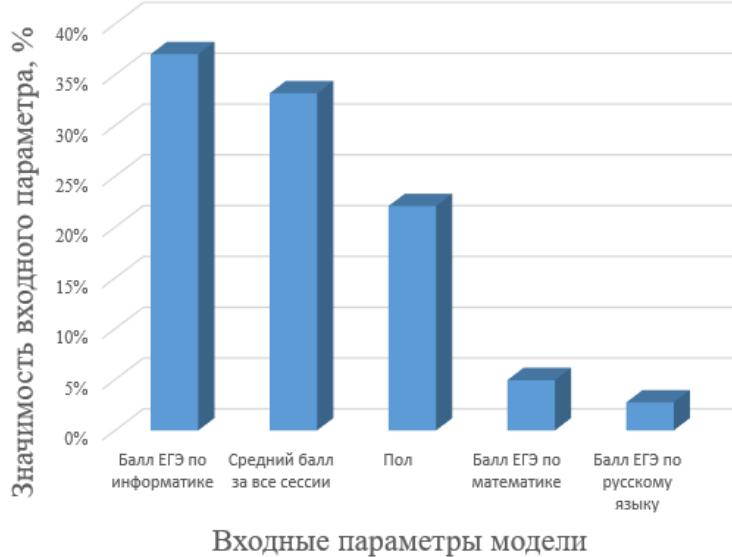


Рисунок 2. Значимость входных параметров нейросетевой модели

Как видно из рисунка 2, наиболее значимыми параметрами являются балл ЕГЭ по информатике, средний балл за все сессии и пол. Также на графике можно видеть ряд параметров, которые имеют около нулевую значимость, такие как балл ЕГЭ по математике, балл ЕГЭ по русскому языку. Это можно объяснить тем, что данные предметы имеют низкий приоритет использования компьютерных технологий.

Для исследования значимости параметров – пол, балл ЕГЭ по информатике, средняя оценка промежуточной аттестации были взяты примеры, представленные в таблице 1:

Таблица 1Характеристики студентов, выбранных для исследования

№ студента	X1	X2	X3	X4	X5
1	1	79	86	87	4,7
2	1	88	86	68	3,57
3	1	83	82	80	4,1
4	1	91	70	82	4,6
5	1	73	72	80	3,5
6	1	81	74	80	3
7	1	94	80	85	3,38
8	1	79	84	65	4,1
9	1	81	88	94	4,7
10	1	72	70	68	3,53

На рисунке 3 показан график зависимости процента зависимости от компьютерных игр от пола студента. Как следует из графика, женский пол

меньше подвержен зависимости от компьютерных игр. Результат данного наблюдения соответствует реальности, т. к. женский пол действительно меньше интересуется компьютерными играми в силу того, что в большинстве своём игры делаются мужчинами для мужчин.

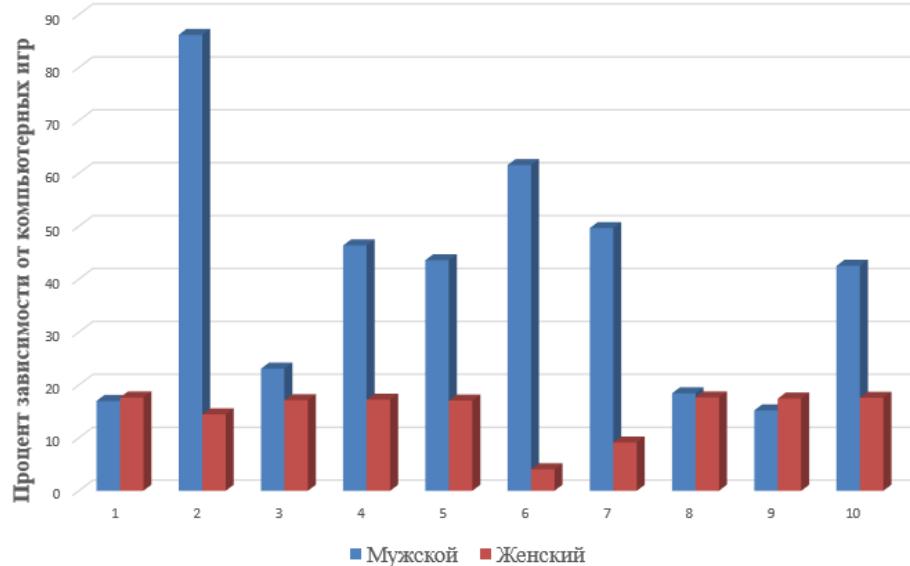


Рисунок 3. Зависимость процента зависимости от компьютерных игр от пола студента

На рисунке 4 продемонстрирована зависимость процента зависимости от компьютерных игр от балла ЕГЭ по информатике студента. На данном графике мы видим прямую зависимость, чем больше у студента балл по ЕГЭ по информатике, тем больше он зависит от компьютерных игр. Данное утверждение соответствует реальности, т. к. люди, которые выбрали сдавать ЕГЭ по информатике, в большей мере разбираются в компьютерных технологиях и сильнее вовлечены в виртуальный мир, нежели люди, выбравшие другие профильные предметы для сдачи ЕГЭ.

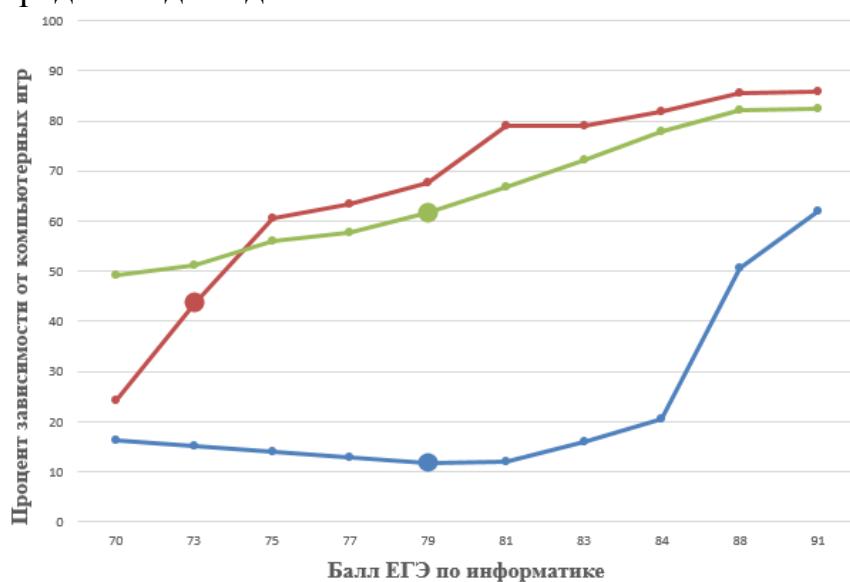


Рисунок 4. Зависимость процента зависимости от компьютерных игр от балла ЕГЭ по информатике студента

На рисунке 5 изображен график зависимости процента зависимости от компьютерных игр от среднего балла за промежуточную аттестацию у студента. На данном графике видна обратная зависимость, чем больше результат за промежуточную аттестацию, тем меньше студент зависит от компьютерных игр. Данное заключение является верным, т. к. в действительности чем больше человек тратит времени на учёбу, тем меньше времени у него остаётся на отдых, в частности на компьютерные игры.

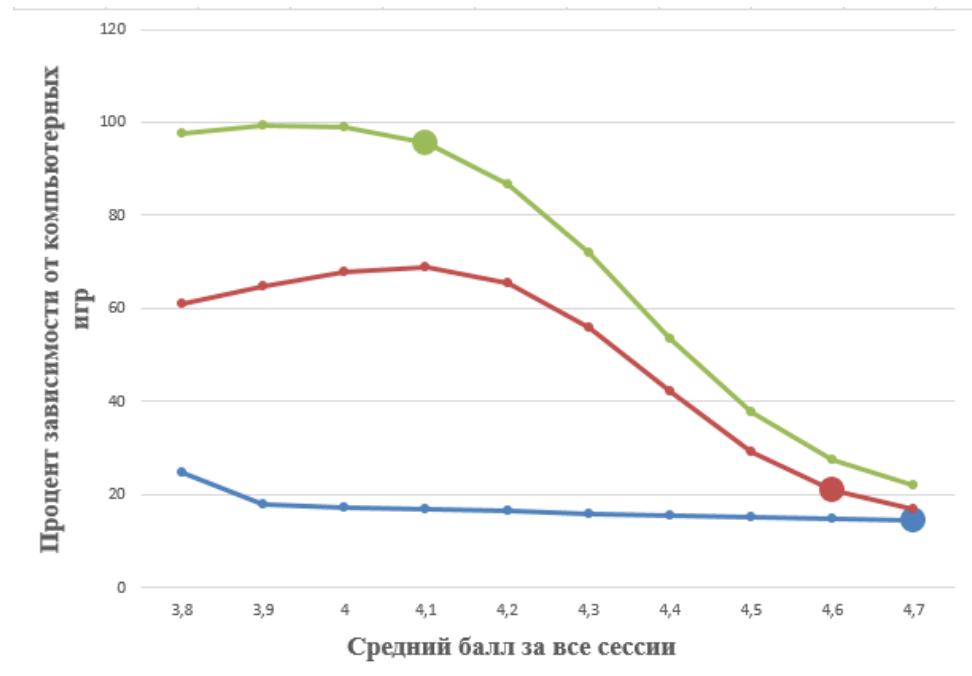


Рисунок 5. Зависимость процента зависимости от компьютерных игр от среднего балла за промежуточную аттестацию у студента

Полученные результаты исследований не противоречат реальности, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для определения уровня зависимости студента Механико-математического факультета от компьютерных игр.

Заключение. Построена система нейросетевого оценивания процента зависимости студента от компьютерных игр. Спроектированная нейросетевая модель учитывает три категории показателей, влияющих на процент зависимости: начальные интеллектуальные данные, пол и уровень успеваемости. Проведены исследования множества данных о зависимости студентов механико-математического факультета от компьютерных игр. Методом сценарного прогнозирования построены графики зависимостей процента зависимости от компьютерных игр от: пола, балла ЕГЭ по информатике и среднего балла за все сессии. Применение такого набора параметров в модели позволяет учитывать внешние факторы с течением времени, а также в дальнейшем она может быть расширена для оценки процента зависимости от компьютерных игр для студентов любых факультетов.

Библиографический список

1. Ясницкий Л.Н. Интеллектуальные системы. – М.: Лаборатория знаний, 2016.
2. Галушкин А.И. Нейронные сети: основы теории. М: Горячая линия–Телеком. 2012. 496 с.
3. Акопова М.А., Исследования влияния игровой компьютерной зависимости на личностные особенности студентов, Russian Journal of Education and Psychology, 2019, Том 10, № 2. – URL:
<https://cyberleninka.ru/article/n/issledovanie-vliyaniya-igrovoy-kompyuternoy-zavisimosti-na-lichnostnye-osobennostey-studentov/viewer>
(дата обращения 11.03.2021)
4. Яшин К.Д., Залевако С.С., Мельникова Е.А., Мезяная К.Н., Кореневский К.М. Компьютерная зависимость у студентов – URL:
https://elib.bsu.by/bitstream/123456789/167213/1/Яшин_6_2013-043-046.pdf
(дата обращения 11.03..2021)
5. Юрьева Л.Н., Больбот Т.Ю. Компьютерная зависимость: формирования, диагностика, коррекция и профилактика. – URL:
https://www.studmed.ru/view/yureva-ln-bolbot-tyu-kompyuternaya-zavisimost-formirovanie-diagnostika-korreksiya-i-profilaktika_34d9c9e825b.html?page=1
(дата обращения 12.03.2021)
6. Электронная площадка для онлайн-опросов. – URL:
https://docs.google.com/forms/d/e/1FAIpQLSdMQhPATP8jjgNW95BzrGYvm7r9N1MgZOSUGu5M-0jPkfxfTA/viewform?usp=sf_link
7. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
8. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.

NEURAL NETWORK SYSTEM FOR DETERMINING GAME DEPENDENCE

Bakhtin Pavel V., Proskuriakov Vladislav S.

Perm, State University, Str. Bukireva, 15, Perm, Russia, 614990,

The article describes the development of a neural network system for determining and predicting gambling addiction. The system makes it possible to determine the gambling addiction of a student, taking into account his results of the Unified State Exam, gender and average score for intermediate attestation.

The use of these parameters allows us to make the system adaptable to each student of the Faculty of Mechanics and Mathematics.

Keywords: artificial intelligence, neural network technologies, position assessment, forecasting, student, intermediate certification, assessment of gambling addiction.

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В ЭКОНОМИКЕ, ПРОИЗВОДСТВЕ И БИЗНЕСЕ

ПРОГНОЗИРОВАНИЕ УДОВЛЕТВОРЕННОСТИ ПАССАЖИРОВ АВИАПЕРЕЛЕТОМ

Богомягкова Екатерина Андреевна, Лобанова Валерия Евгеньевна

Пермский государственный национальный исследовательский университет,

ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,

arababza@gmail.com

В статье представлено описание разработки нейросетевой системы для прогнозирования удовлетворенности пассажиров авиаперелетом. Система позволяет оценить, будет ли доволен пассажир поездкой на авиатранспорте. Это поможет авиакомпаниям понять и улучшить факторы, влияющие на удовлетворенность перелетом.

Ключевые слова: искусственный интеллект, нейросетевые технологии, прогнозирование, авиаперелеты, пассажиры.

Введение. При выборе авиакомпании для перелета потенциальный пассажир учитывает множество факторов. Авиакомпании в свою очередь пытаются удовлетворить потребности клиентов для повышения спроса. Данная работа показывает, какие факторы коррелируют с удовлетворенностью (или неудовлетворенностью) пассажира.

Одним из наиболее важных аспектов проекта машинного обучения является понимание основных функций, которые соотносятся с атрибутом, который мы пытаемся предсказать [1]. Основная цель заключается в поиске множества данных, на котором будет обучаться и тестироваться нейросеть. Найденное готовое множество включает в себя 22 входных параметра и 1 выходной. Оно собиралось с отзывов клиентов, которые в конечном счете дали либо положительную, либо отрицательную или нейтральную оценку поездке.

Количество параметров в множестве данных, по сравнению с исходным, остается неизменным: X1 – пол, X2 – лояльность пассажира, X3 – возраст, X4 – тип поездки, X5 – класс, X6 – дальность полета, X7 – Wi-Fi на борту, X8 – удобство времени отправления и прибытия, X9 – простота онлайн-бронирования, X10 – расположение выхода на посадку, X11 – еда и напитки, X12 – онлайн-посадка, X13 – комфортабельность сидений, X14 – досуг на борту, X15 – сервис на борту, X16 – место для ног, X17 – управление багажом, X18 – регистрация, X19 – сервис в полете, X20 – чистота, X21 – задержка отправления в минутах, X22 – задержка прибытия в минутах. Выходной параметр D1 – удовлетворенность перелетом.

Многие параметры были закодированы: пол (1 – женщина, 2 – мужчина), лояльность (1 – лояльный, 2 – нелояльный), тип поездки (1 – работа, 2 – отдых), класс (1 – бизнес, 2 – эконом), в выходном параметре (1 – нейтрален или

неудовлетворен, 2 – удовлетворен). Дальность полета измеряется в километрах, параметры X7-X20 оценку от 1 до 5, задержка по времени измеряется в минутах.

Исходное множество было взято с Kaggle [2] и содержало более 70 тыс. строк, поэтому для удобства обучения и тестирования случайным образом было отобрано не более 4 тыс. примеров.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [4] по методике [3]. В результате оптимизации спроектированная нейронная сеть представляла собой персепtron, который имеет двадцать два входных нейрона, один выходной и один скрытый слой с восемью нейронами, количество которых оказалось оптимальнее всего.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 1055 примеров, что является 32.8% от обучающего множества. Средняя ошибка тестирования составила 23%. На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактической и прогнозируемой нейросетью удовлетворенность случайно отобранных 36 пассажиров.



Рисунок 23. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 1, можно сделать вывод об адекватной работе спроектированной нейронной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5», результат отображен на рисунке 2.

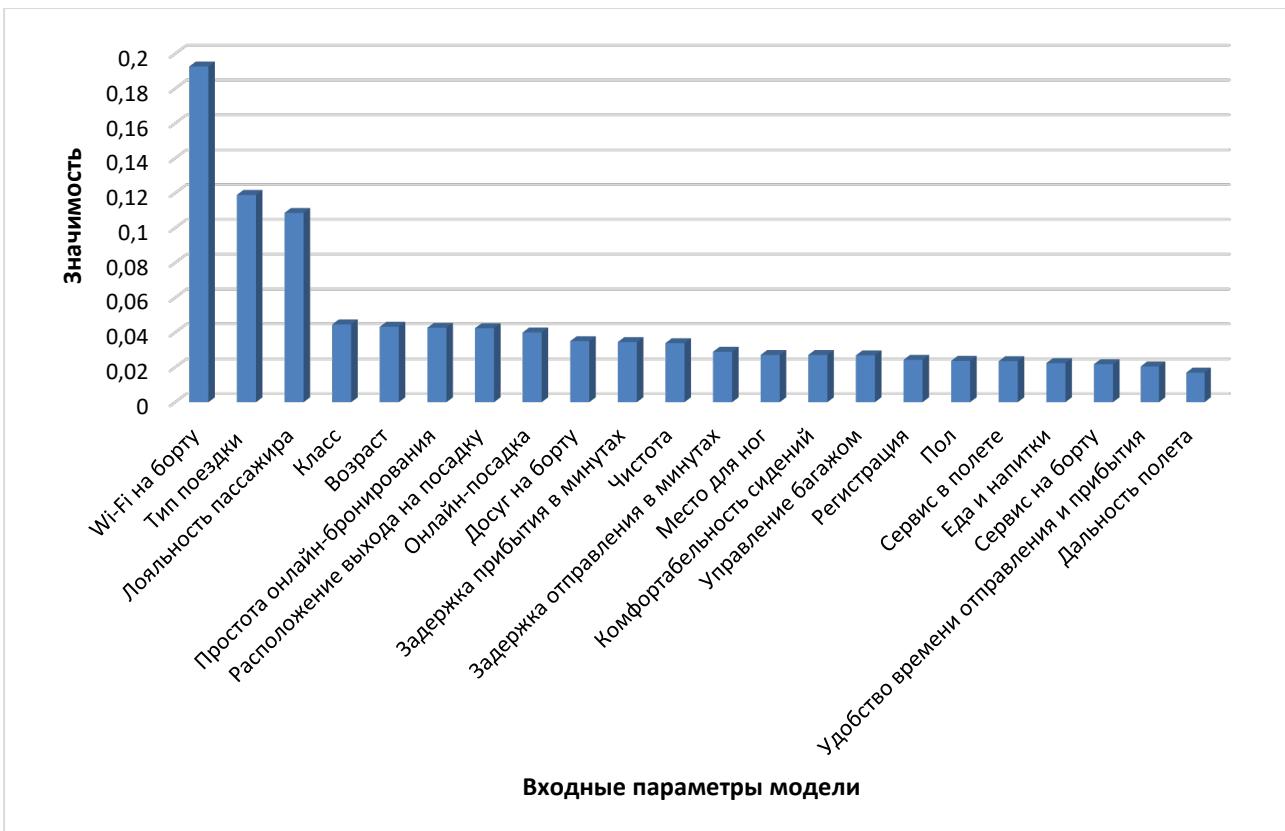


Рисунок 24. Значимость входных параметров нейросетевой модели

Как видно из рисунка 2, наиболее значимыми являются Wi-Fi на борту, и лояльность пассажира. Также на графике можно видеть ряд параметров, которые имеют наименьшую значимость, такие как дальность полета, удобство времени прибытия и отправления, сервис на борту и др. Это можно объяснить тем, что на текущем собранном множестве данные параметры имеют одинаковое значение.

Далее было проведено исследование отзывов пассажиров об авиаперелетах. Исследование производилось с помощью метода «замораживания» [3], суть которого заключается в варьировании значения одного параметра и фиксировании значений всех других параметров. Данный метод позволяет выявить влияние исследуемого параметра на выходной. Для этой цели были отобраны 5 отзывов, информация о параметрах, которых отражена в таблице 1.

Таблица 1
Отзывы пассажиров, отобранных
для исследования

№ отзыва	1	2	3	4	5
X1	2	1	2	1	2
X2	1	1	1	2	1
X3	13	17	53	25	41
X4	2	2	1	1	1
X5	2	2	2	1	1
X6	460	208	834	1452	296
X7	3	3	1	3	1
X8	4	1	4	5	1
X9	3	3	4	3	1
X10	1	3	4	4	3
X11	5	5	1	3	2
X12	3	3	1	3	5
X13	5	5	1	3	3
X14	5	5	1	3	4
X15	4	2	1	4	4
X16	3	5	1	4	4
X17	4	3	3	5	4
X18	4	3	4	5	4
X19	5	4	4	5	4
X20	5	5	1	3	3
X21	25	0	28	9	0
X22	18	0	8	23	0

На рисунке 3 показан график зависимости удовлетворенности пассажира полетом от качества Wi-Fi – самым значимым показателем. Как следует из графика, при увеличении качества Wi-Fi удовлетворенность возрастает.

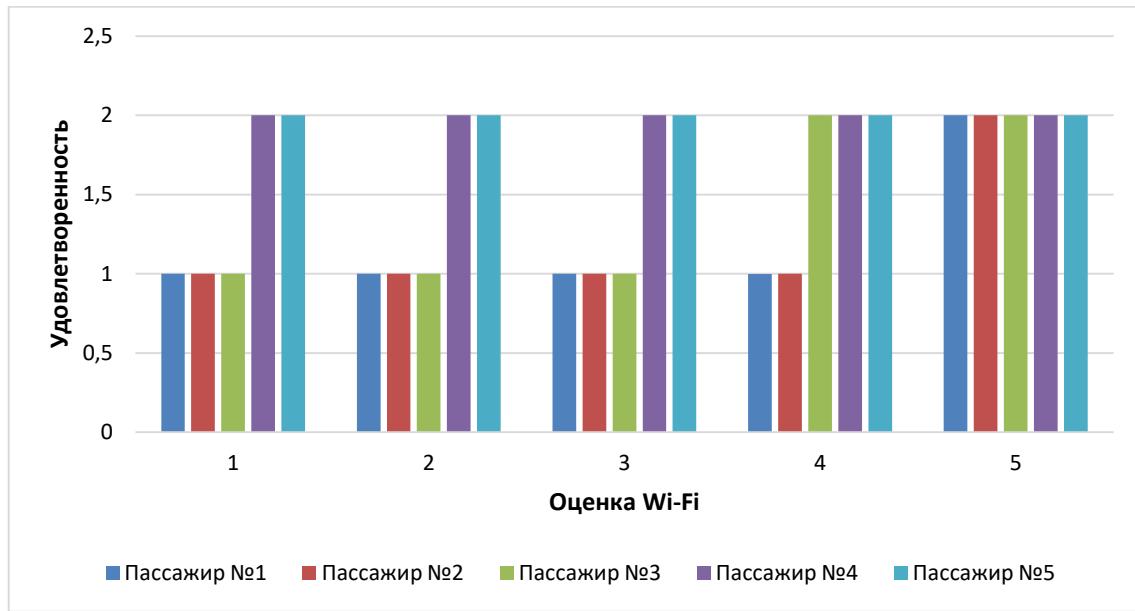


Рисунок 25. Зависимость удовлетворенности пассажира от Wi-Fi

На рисунках 4-5 показаны графики зависимости удовлетворенности пассажира от его лояльности и типа поездки соответственно. Как видно, пассажиры, летящие по работе, более склонны к удовлетворительной оценке. Так же, как и лояльные пассажиры на рисунке 5.

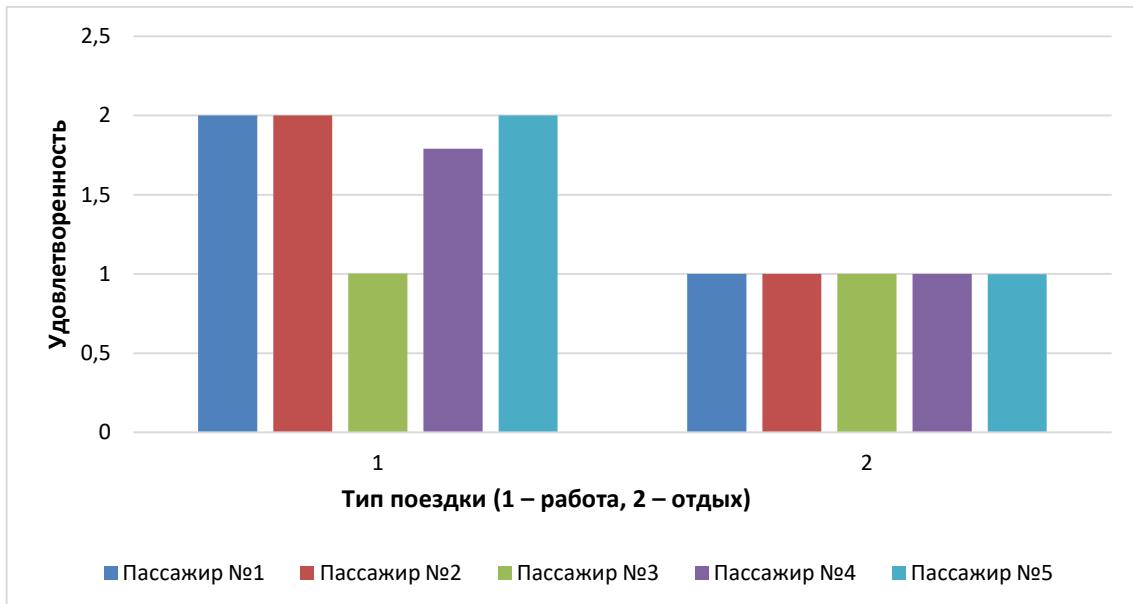


Рисунок 26. Зависимость удовлетворенности пассажира от типа поездки

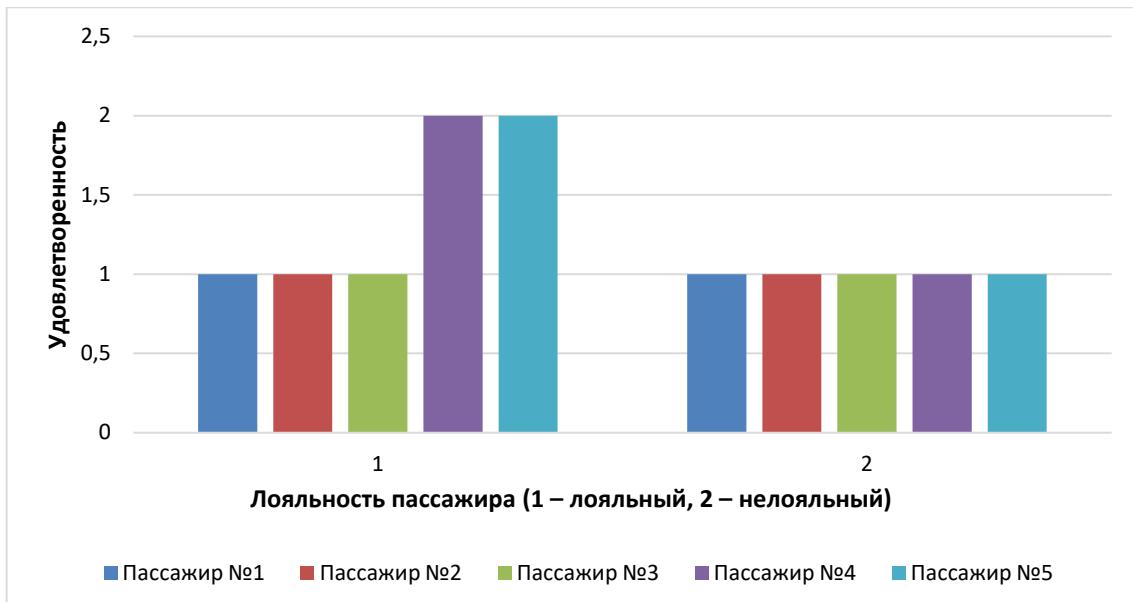


Рисунок 27. Зависимость удовлетворенности пассажира от его лояльности

Полученные результаты исследований не противоречат реальности, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для прогнозирования удовлетворенности пассажиров авиаперелетом.

Заключение. Построена система нейросетевого оценивания удовлетворенности пассажиров авиаперелетом. Спроектированная нейросетевая модель учитывает три категории показателей, влияющих на удовлетворенность пассажиров: качество Wi-Fi, тип поездки, лояльность человека. Методом сценарного прогнозирования построены графики зависимостей удовлетворенности от качества Wi-Fi, лояльности пассажира, типа поездки.

Библиографический список

1. Ясницкий Л.Н. Интеллектуальные системы: учебник. – М.: Лаборатория знаний, 2016. – 221 с.
2. Airline Passenger Satisfaction. – URL:
<https://www.kaggle.com/teejmahal20/airline-passenger-satisfaction>
3. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.
4. Нейросимулятор 5.0: свидетельство о государственной регистрации программы для № 2014618208 от 12.07.2014 г. / Черепанов Ф.М., Ясницкий В.Л. (РФ).

PREDICTION OF THE PASSENGER SATISFACTION WITH THE FLIGHT

Bogomiagkova Ekaterina A., Lobanova Valeria E.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990,

arababza@gmail.com

The article describes the development of a neural network system for predicting the passenger satisfaction with the air travelling. The system allows to assess whether the passenger will be satisfied with the journey by air transport. This will help airlines understand and improve the factors that affect flight satisfaction.

Keywords: artificial intelligence, neural network technologies, prediction, air traveling, passengers.

СИСТЕМА ДЛЯ ОЦЕНКИ СТОИМОСТИ ПОСУТОЧНОЙ АРЕНДЫ ЖИЛОЙ НЕДВИЖИМОСТИ ПЕРМИ

Захаров Илья Владимирович

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15

В статье представлено описание разработки динамической нейросетевой системы для оценки стоимости посуточной аренды жилой недвижимости города Перми. Система позволяет выполнять оценку стоимости квартир с учетом географических и строительных показателей.

Ключевые слова: искусственный интеллект, нейросетевые технологии, жилая недвижимость, самоадаптация, прогнозирование, посуточная аренда.

Введение. Немало людей, приезжающих в город по работе, для посещения выставок и семинаров, а также в туристических целях озадачены вопросом о проживании на время приезда. Посуточная аренда квартиры – идеальный вариант для приезжих. Для того чтобы грамотно и быстро найти подходящий вариант, нужно разбираться в ценообразовании рынка недвижимости данного города, но зачастую люди не имеют представления о нем. Искусственный интеллект, описанный в данной статье, нацелен на решение данной проблемы.

Эффективность использования искусственного интеллекта в задачах, связанных с рынком недвижимости была обоснована в статьях зарубежных исследователей [1-2]. Однако, в данных работах наборы параметров не в полной мере учитывают географические показатели, такие как район, ведь различные районы города имеют разную инфраструктуру, администрацию, все это влияет на окончательную оценку стоимости аренды, расстояния до главных мест в городе.

Авторы работ [3-5] предложили способ создания динамических систем для прогнозирования стоимости недвижимости с учетом географических, строительных и изменяющихся экономических параметров. Их наработки были использованы и в данной нейронной системе с учетом решаемой задачи.

Основная цель настоящей работы заключается в сборе множества объявлений об посуточной аренде жилья, находящемся в г. Перми, а также создание и обучение нейросетевой модели на этих данных.

В результате анализа литературных источников [1-5], был выбран следующий набор показателей: X1 – общая площадь (кв. м.), X2 – количество комнат, X3 – район, X4 – расстояние до центра города (км), X5 – расстояние до центра района (км), X6 – широта, X7 – долгота, X8 – этаж квартиры, X9 – этажность дома. Выходной параметр D1 – цена аренды (руб.).

Параметр X3 (район) был закодирован следующим образом: 7 – Орджоникидзевский район, 6 – Кировский район, 5 – Индустримальный район, 4 – Ленинский район, 3 – Дзержинский район, 2 – Мотовилихинский район, 1 – Свердловский район. Номера сопоставленные районам соответствуют количеству квартир находящихся в них (от меньшего числа к большему).

Остальные параметры являются числовыми, поэтому для них кодировка не требуется. Однако, я сделал дополнительную обработку параметра X8 (этаж квартиры). Далее было сделано такое преобразование, чтобы каждое значение данного параметра принадлежало полуинтервалу (0; 1], используя следующую формулу:

$$Floor_{new} = \frac{Floor_{old}}{NumberOfFloors} = X8_{new} = \frac{X8_{old}}{X9}$$

В отличие от работ [1-2], для учета местоположения квартир, вместо расстояний до локальных ценовых центров, районов предлагается использовать географические координаты – широта, долгота.

Множество объявлений об посуточной аренде квартир, находящихся в г. Пермь, было собрано с помощью программы-парсера [8] с интернет-ресурсов. Перед переходом к проектированию и обучению нейросетевой модели, была выполнена очистка исходного множества от противоречивых примеров, выбросов, дубликатов. Например, удалялись примеры с недостаточными данными или с очевидно недостоверными значениями параметров. Выбросы статистической информации выявлялись с помощью методики [9]. Таким образом, объем итогового множества включает в себя 466 примеров. Данное множество было разделено на обучающее и тестирующее в соотношении 80% и 20% соответственно. Собранные данные охватывают период январь-март 2021 года.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [6] по методике [7]. В результате оптимизации спроектированная нейронная сеть представляла собой персепtron, который имеет девять входных нейронов, один выходной и один скрытый слой с семью нейронами.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 99 примеров. Средняя ошибка тестирования составила 11,7%, что можно считать приемлемым результатом. На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактической и прогнозируемой нейросетью стоимостью случайно отобранных 44 квартир из тестирующего множества.

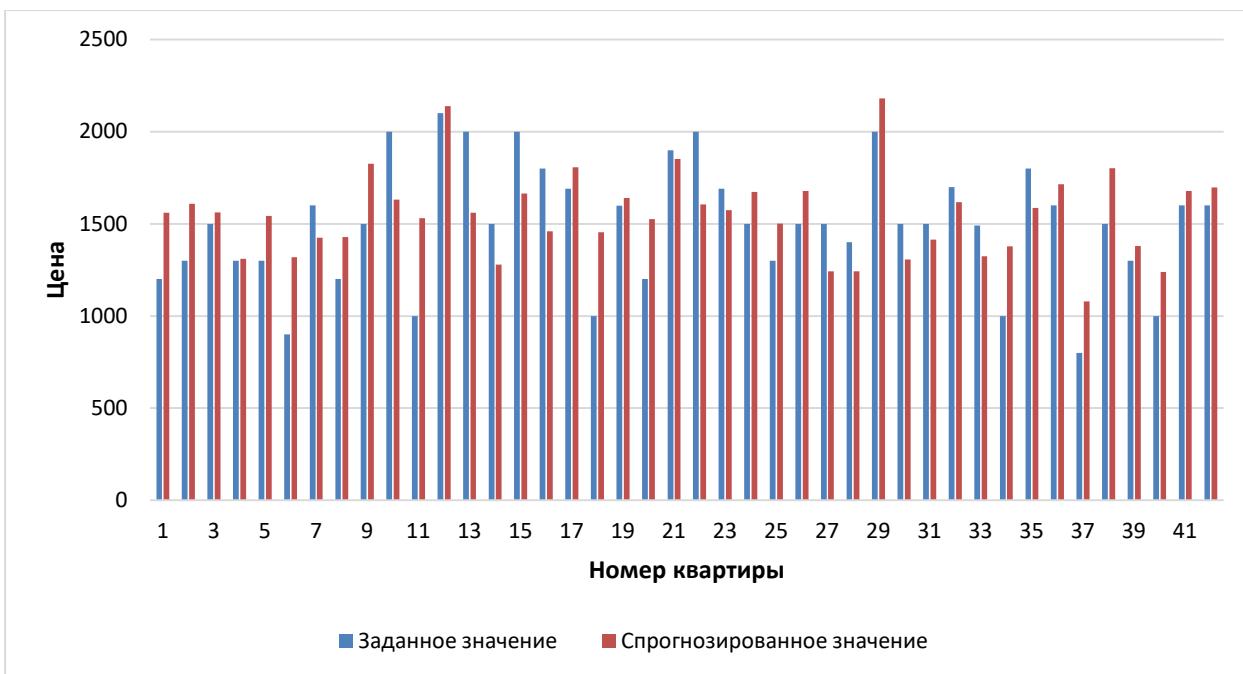


Рисунок 1. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 1, можно сделать вывод об адекватной работе спроектированной нейронной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5», результат отображен на рисунке 2.

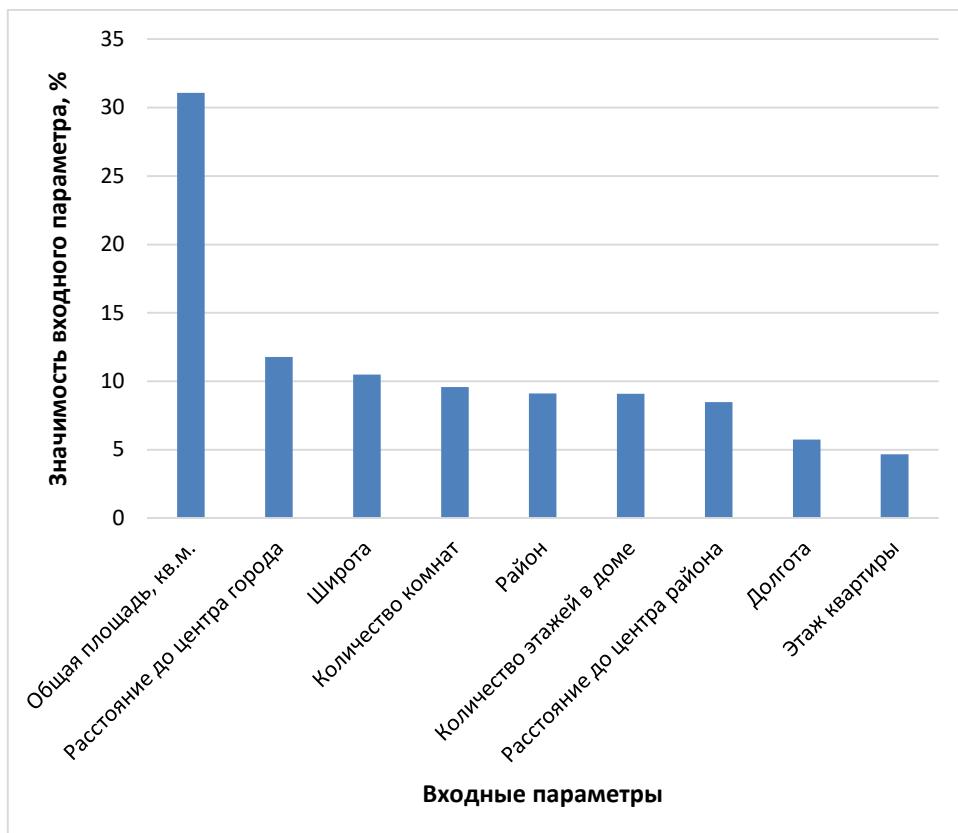


Рисунок 2. Значимость входных параметров нейросетевой модели

Расчет значимости с помощью программы «Нейросимулятор 5» позволил выявить влияние данных параметров на итоговую цены аренды квартиры.

Далее было проведено исследование рынка аренды жилой недвижимости г. Перми. Исследование производилось с помощью метода «замораживания» [7], суть которого заключается в варьировании значения одного параметра и фиксировании значений всех других параметров. Данный метод позволяет выявить влияние исследуемого параметра на выходной. Для этой цели были отобраны 3 квартиры, информация о параметрах которых отражена в таблице 1.

Таблица 1
Характеристики квартир,
выбранных для исследования

№ квартиры	X1	X2	X3	X4	X5	X6	X7	X8	X9
1	75	2	1	3,104816	1,880775	58,00117	56,26757	0,92	25
2	30	1	2	3,985086	1,066714	58,01635	56,28253	0,6	5
3	51	1	5	3,212226	0,692483	57,98111	56,19817	0,588235	17

На рисунках 3-4 продемонстрирована зависимость стоимости посуточной аренды квартир от общей площади и количества комнат соответственно. В обоих результатах видна тенденция к увеличению стоимости аренды. Однако, стоимость аренды квартиры №3 не сильно увеличивается, даже немного снижается на рисунке 4. Данный результат говорит о том, что рынок посуточной аренды жилья состоит в основном из квартир небольших размеров и снижение цены обусловлено недостаточным количеством предложений квартир с большой общей площадью и большим количеством комнат.

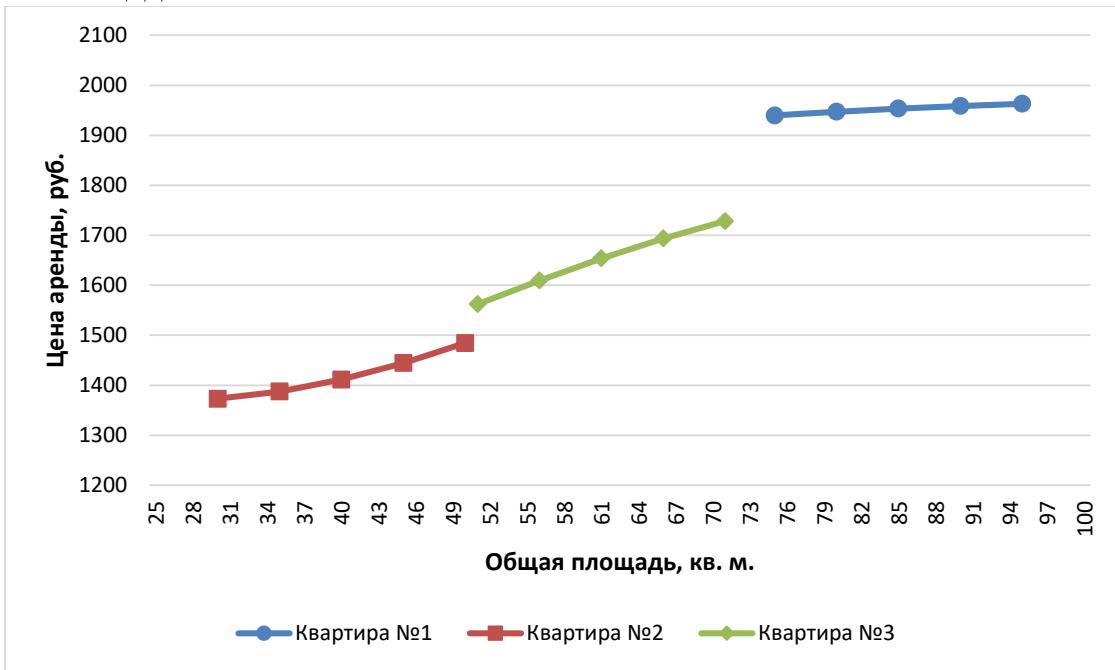


Рисунок 3. Зависимость стоимости посуточной аренды квартиры от общей площади

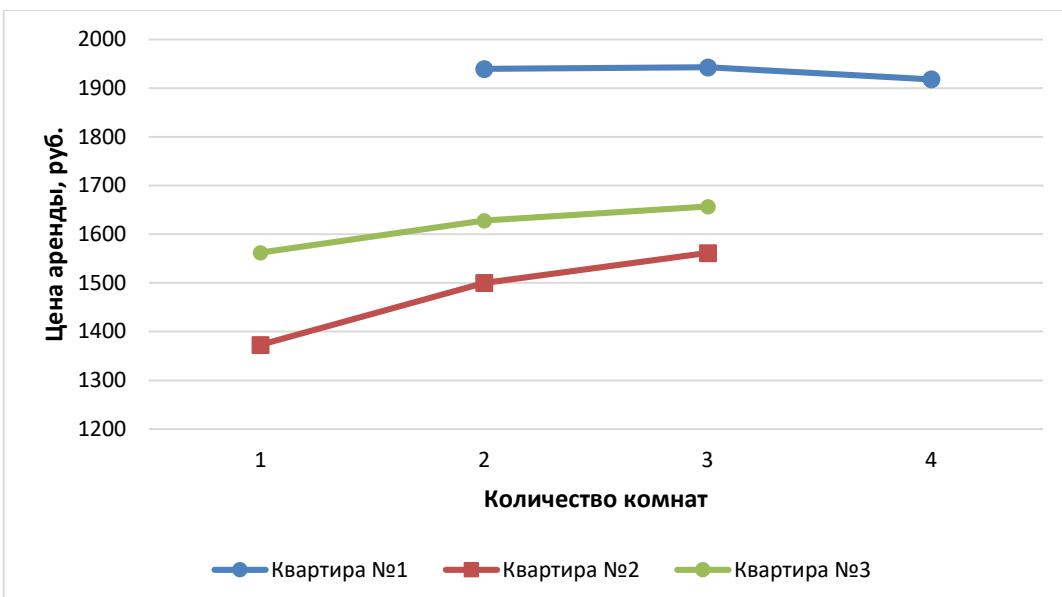


Рисунок 4. Зависимость стоимости посуточной аренды квартиры от количества комнат

Далее аналогичным методом было проведено исследование наиболее о влиянии географических показателей.

На рисунке 5 изображен график зависимостей стоимости квартир от расстояния до центра города. Центром города выбрана эспланада, достопримечательное место г. Перми. Из результатов видно, что чем ближе квартира находится к центру, тем выше её арендная стоимость, это достаточно очевидная закономерность ещё раз подтверждает адекватность работы сети. Ведь, чем ближе находится квартира, тем более развитая инфраструктура и более высокая доступность различных достопримечательностей, магазинов, развлекательных и досуговых мест.

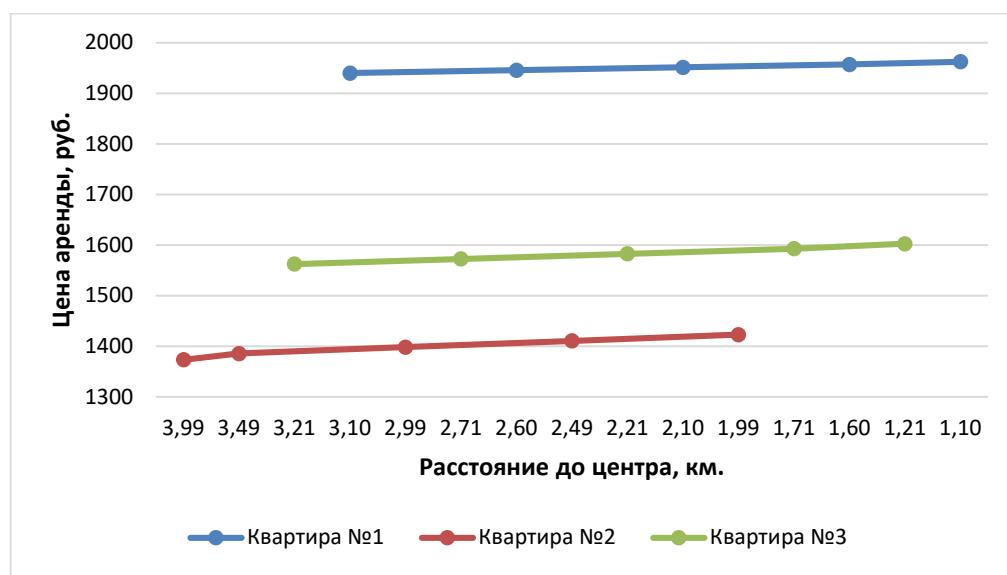


Рисунок 5. Зависимость стоимости посуточной аренды квартиры от расстояния до центра города

На рисунке 6 продемонстрирован график зависимостей стоимости квартир от этажности дома. Как видно из графика квартиры №2, №3 увеличивают в стоимости аренды, а квартира №1 наоборот уменьшилась в арендной стоимости, это можно объяснить тем, что в городе большое количество девятиэтажных домов, построенных в 1980 годы, квартиры в данных домах ценятся меньше, чем в новостройках, в которых сейчас обычно более 15 этажей.

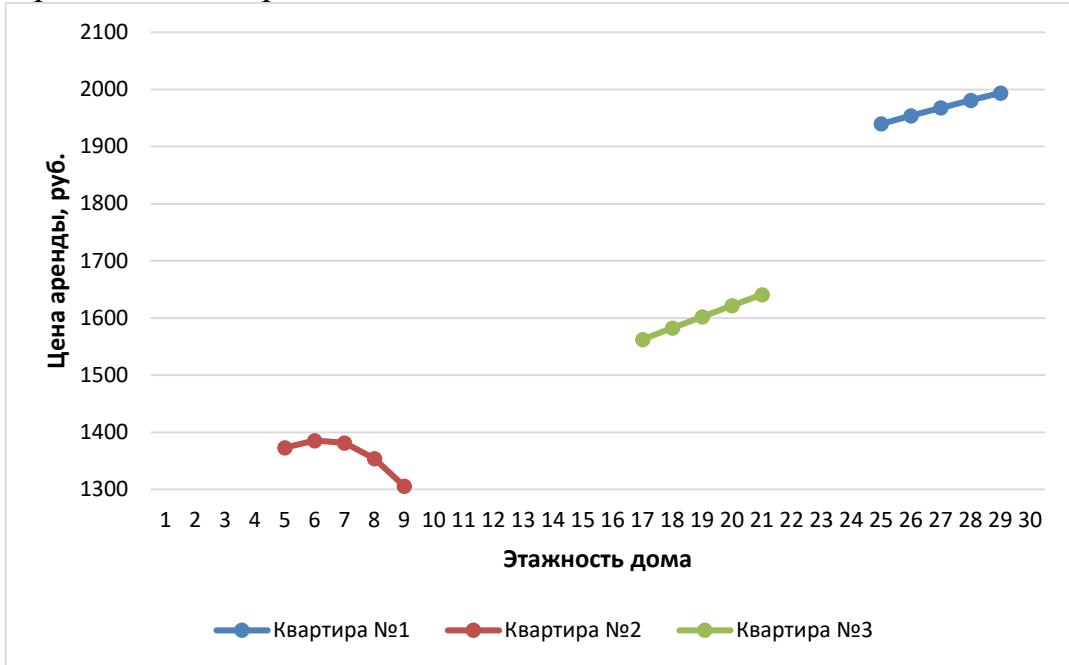


Рисунок 6. Зависимость стоимости посуточной аренды квартиры от этажности дома

Полученные результаты исследований не противоречат реальности, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для прогнозирования стоимости аренды жилой недвижимости города Перми.

Заключение. Построена система нейросетевого оценивания стоимости посуточной аренды жилой недвижимости для г. Пермь. Спроектированная нейросетевая модель учитывает две категории показателей, влияющих на стоимость квартиры: строительные, географические. Проведены исследования рынка аренды жилой недвижимости г. Перми. Методом сценарного прогнозирования построены графики зависимостей стоимости посуточной аренды квартир от количества комнат, размера общей площади, от местоположения квартиры, а также этажности дома. Применение такого набора параметров в модели позволяет прогнозировать достаточно точную оценку стоимости аренды жилья.

Работа выполнена при поддержке РФФИ: Грант №19-010-00307 «Разработка интеллектуальной самоадаптируемой системы массовой оценки и сценарного прогнозирования рыночной стоимости жилой недвижимости регионов РФ».

Библиографический список

1. Pouya Rezazadeh Kalehbasti, Liubov Nikolenko, Hoormazd Rezaei, Airbnb Price Prediction Using Machine Learning and Sentiment Analysis // arXiv preprint arXiv:1907.12665
2. Evans A., James H., Collins A. Property Rental Price Prediction Using the Extreme Gradient Boosting Algorithm // International Journal of Informatics and Information System Vol. 3, No. 2, September 2020, pp. 54-59
3. Ясницкий Л.Н., Ясницкий В.Л. Разработка и применение комплексных нейросетевых моделей массовой оценки и прогнозирования стоимости жилых объектов на примере рынков недвижимости Екатеринбурга и Перми // Имущественные отношения в Российской Федерации. 2017. № 3(186). С. 68-84.
4. Ясницкий Л.Н., Ясницкий В.Л. Методика создания комплексной экономико-математической модели массовой оценки стоимости объектов недвижимости на примере квартирного рынка города Перми // Вестник Пермского университета. Серия: Экономика. 2016. № 2 (29). С. 54-69.
5. Yasnitsky L.N., Yasnitsky V.L. Technique of design of integrated economic and mathematical model of mass appraisal of real estate property by the example of Yekaterinburg housing market // Journal of Applied Economic Sciences. 2016. V. 11. No 8. Pp. 1519-1530.
6. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
7. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.
8. Парсер для сайта объявлений “Авито” // 2021, Режим доступа: URL: https://github.com/romesful/avito-parser_flats
9. Yasnitsky L.N. Algorithm for searching and analyzing abnormal observations of statistical information based on the Arnold – Kolmogorov – Hecht-Nielsen theorem // International Journal of Advanced Trends in Computer Science and Engineering. 2020. 9(2). Pp. 1814-1819.
DOI: 10.30534/ijatcse/2020/139922020
<http://www.warse.org/IJATCSE/static/pdf/file/ijatcse139922020.pdf>

NEURAL NETWORK SYSTEM FOR ESTIMATING THE PRICE OF DAILY RENT OF RESIDENTIAL REAL ESTATE IN PERM

Zakharov Ilya V.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990

The article describes the development of a dynamic neural network system for estimating the cost of daily rent of residential real estate in Perm. The system allows to estimate the cost of apartments, taking into account geographical and construction indicators.

Keywords: artificial intelligence, neural network technology, residential real estate, self-adaptation, forecasting, daily rent.

РАЗРАБОТКА ИНЖЕНЕРНОГО ПРОГРАММНОГО МОДУЛЯ ПРОГНОЗИРОВАНИЯ ПАРАМЕТРОВ ТЕПЛОНОСИТЕЛЯ ПО СТВОЛУ СКВАЖИНЫ В ПРОЦЕССЕ ПРОВЕДЕНИЯ ПАРОЦИКЛИЧЕСКИХ ОБРАБОТОК НА ПРИМЕРЕ ПЕРМО- КАРБОНОВОЙ ЗАЛЕЖИ УСИНСКОГО МЕСТОРОЖДЕНИЯ В ЗАВИСИМОСТИ ОТ ГЕОЛОГО-ПРОМЫСЛОВЫХ ДАННЫХ

Степанов Владимир Анатольевич

Пермский государственный национальный исследовательский университет,
614990, Россия, г. Пермь, ул. Букирева, 15, svamail@list.ru

Култышева Светлана Николаевна

Филиал ООО «ЛУКОЙЛ-Инжиниринг» «ПермНИПИнефть» в г.Перми,
614000, Россия, г. Пермь, ул. Пермская, 3а, skultyshева@mail.ru

В статье представлено описание разработки инженерного программного модуля для прогнозирования параметров теплоносителя по стволу скважины в процессе проведения пароциклических обработок на примере пермо-карбоновой залежи Усинского месторождения. Продукт обеспечивает возможность контроля технологических параметров теплоносителя (температура, сухость и энталпия агента) на протяжении цикла обработки паром, кроме того, способствует повышению изученности технологических параметров теплоносителя, закачиваемого посредством циклической закачки агента в скважину, и как следствие своевременному регулированию технологических параметров закачки в целях достижения наибольшей эффективности пароциклической обработки.

Ключевые слова: пароциклическая обработка, глубина, температура, сухость, энталпия, нейросетевая модель, обучающее множество.

Введение. Применение технологий повышения нефтеотдачи пластов (ПНП) является существенным фактором повышения добычи нефти, так например, в 2017 году 27% нефти в России добыто за счет технологий повышения нефтеотдачи пласта [1]. К высокоэффективным методам ПНП для технологии добычи высоковязких нефти и природных битумов относится метод пароциклической обработки скважины (ПЦО), когда при температуре 300-350 °C и давлении 15-20 МПа происходит прогрев пласта, что влечет за собой увеличение дебита нефти скважины.

ПЦО добывающих скважин как массовый и наиболее эффективный метод повышения нефтеотдачи применяется на пермо-карбоновой залежи Усинского месторождения. Применение тепловых методов повышения нефтеотдачи на залежи обусловлено аномально высокой вязкостью нефти в пластовых условиях (в среднем 710 мПа*с) [2].

Стадийность работ по обработке скважины подразумевает следующие этапы:

- подготовительные работы,
- фаза закачки пара,
- фаза закачки химических реагентов (в случае необходимости использования химических реагентов, их закачка производится перед переводом скважины в ПЦО или в середине цикла закачки),
- фаза выдержки скважины на пропитку,
- фаза эксплуатации [3].

При проведении ПЦО необходимо на протяжении всей фазы закачки пара контролировать параметры водяного пара, вырабатываемого парогенерирующей установкой (ПГУ) на поверхности. Генерация теплоносителя (пара) осуществляется ПГУ путем нагрева пресной воды. Далее теплоноситель посредством паропроводов и термоизолированных труб поступает на забой добывающих скважин. Необходимые параметры закачиваемого пара на забое скважины: температура не менее 300 °C, сухость пара не менее 75 % [3]. При меньших параметрах пара из-за больших потерь тепла закачка пара прекращается и возобновляется только после устранения причин недостаточной эффективности используемого оборудования.

Как правило, пар, вырабатываемый одной ПГУ, потребляется одновременно несколькими скважинами – от одной до четырех. Узлами учета пара (УУП) оснащены все ПГУ. Устьевыми УУП оснащается 70 % фонда добывающих скважин при проведении ПЦО. При движении теплоносителя по паропроводу и термотрубам в скважине неизбежны теплопотери.

Состояние насыщенного водяного пара характеризуется температурой и давлением, существует однозначная зависимость между давлением и температурой пара.

В процессе цикла ПЦО необходимо осуществлять контроль параметров агента, закачиваемого в скважину. На выходе ПГУ производится контроль давления и температуры закачки, сухости пара и расхода теплоносителя. На устье каждой скважины, находящейся под закачкой пара, ежедневно снимают показания давления и температуры закачки, расхода теплоносителя (при наличии УУП).

Для контроля параметров закачиваемого агента на забое скважины проводятся геофизические исследования по определению приемистости, температуры, давления и сухости агента (ГИС-55). Исследования проводятся однократно в течение цикла ПЦО (в среднем около 35 суток). По технологическим и техническим причинам данные ГИС не всегда информативны. В связи с отсутствием информации о параметрах теплоносителя, для контроля и мониторинга его параметров на забое скважины применяются математические и инженерные методы по пересчёту параметров агента закачки (давления, объемного расхода теплоносителя, температуры, сухости) с условий, соответствующих выходу ПГУ, на устьевые условия скважины и кровлю интервала перфорации с использованием следующих зависимостей:

- математические модели, обоснованные отечественными учеными, Антониади Д.Г., Шорина С.Н, Рузина Л.М.;
- уравнение теплового баланса;
- зависимости состояния водяного пара от давления и температуры, температуры кипения и теплоты парообразования воды от давления;
- формула Намиота А.Ю. для определения профиля температуры теплоносителя по стволу скважины.

Отметим, что применение указанной расчетной модели влечет значительные трудозатраты по пересчету параметров теплоносителя, а также не обеспечивает учет всего многообразия теплофизических процессов, происходящих на пути движения теплоносителя до забоя скважины.

Давление закачки известно на устье, при этом в самой скважине этот параметр претерпевает изменения. Также оказывают влияние и теплофизические свойства колонны теплоизолированных труб. Теплопередача через обсадную колонну и цементное кольцо значительно влияет на термодинамические процессы, происходящие в скважине при закачке теплоносителя, и если использовать математическую модель по формуле Намиота А.Ю., то приходится брать в расчет полный линейный коэффициент теплопередачи равным единице. При определенном темпе нагрева подпакерной зоны образуется накопительный эффект. При расчете по формуле Намиота А.Ю. процесс изменения температуры рабочего агента от устья до забоя нагнетательной скважины может быть рассчитан в динамике только в определенный момент времени. Это накладывает существенные ограничения в математическую модель на базе формулы Намиота А.Ю. Стоит учитывать, что термодинамические процессы зависят от множества параметров, обрабатывать которые необходимо в реальном времени.

В итоге методы контроля ГИС-55, проведенные выборочно по отдельной скважине, обеспечивают реальными параметрами выполнение цикла ПЦО, но не повторяют математические и инженерные расчеты на основе известных моделей. Накопленные исторические данные по скважинам не применяются в силу множества разнородных значений.

Решить проблему прогнозирования параметров теплоносителя при ПЦО возможно, например, на основе математической модели прогрева скважины и пласта [4], используя нейронные сети и исторические данные для обучающей выборки. В связи с этим новыми ключевыми элементами научно-технического решения прогнозирования ПЦО в программном комплексе «ПЦО Калькулятор» являются:

1. Архитектура платформы хранения исторических данных, как составляющий элемент распределенной базы данных, процессов ПЦО.
2. Процедура обработки, группировки и структурирования данных для обучения нейронных сетей.
3. Интеллектуальная система на базе нейронных сетей, включая различные виды и технологии построения нейронных сетей.
4. Подсистема обучения нейронных сетей на основе данных платформы хранения.

5. Подсистема – интерфейс взаимодействия с пользователем или другими информационными подсистемами.

6. Подсистема построения графических, табличных отчетов процессов ПЦО.

Программный комплекс «ПЦО Калькулятор» включает в себя алгоритм интеллектуального прогнозирования выполнения процесса ПЦО в заданной скважине на основе данных технологического оборудования при соблюдении этапов технологических процессов.

Программный комплекс «ПЦО Калькулятор» включает в себя модели и методы моделирования технологических процессов на основе ноу-хау нейросетевой модели для высокоточного прогнозирования.

Архитектура программного комплекса «ПЦО Калькулятор» состоит из двух частей: «обучающая» часть обеспечивает нормализацию выборки и хранение исторических данных, загрузку данных, обучение нейросетевой модели в нескольких режимах, проверку качества обучения и «прогнозируемая» часть, которая позволяет на базе обученной нейросетевой модели строить прогнозные данные по выбранной скважине, с заданной точностью и временем. Дополнительно в архитектуре существуют модули, отвечающие за интеграцию и отчетность.

Научная новизна в архитектуре «обучающего» блока интеллектуальной информационной системы состоит в применении комплексного подхода к нормализации внешних данных, обучению нейросетевой модели и взаимодействию с компонентами системы:

1. Разработанная собственная нейронная сеть [5] с пятью входными нейронами и одним выходным нейроном, одним скрытым слоем из шести сигмоидных нейронов (рисунок 1).

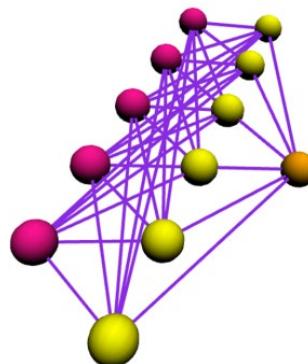


Рисунок 1. Нейронная сеть персептронного типа с пятью входными нейронами, одним скрытым слоем из шести сигмоидных нейронов и одним выходным нейроном

2. Алгоритм адаптивного обучения нейронной сети методами: Левенберга-Марквардта и регрессионной модели градиентного бустинга над решающими деревьями [6].

3. Ноу-хау состоит в разработанной объектной нейросетевой модели, которая содержит в себе несколько нейронных сетей с возможностью

параллельного обучения. Для прогнозирования параметра используются две и более нейронных сети – для обучения данными до пакера и после пакера, по скважине.

Архитектура программного комплекса «ПЦО Калькулятор» в блоке обучения нейросетевой модели предоставляет возможность обучать с масштабируемым параметром с разным шагом глубины: 0.1 м, 0.5 м, 1 м, 2 м, 5 м, 10 м. Такой подход позволяет реализовать уникальную и эффективную технологию обучения объектной нейросетевой модели с возможностью масштабирования данных.

Научная новизна «прогнозируемого» блока в архитектуре интеллектуальной информационной системы состоит из следующих компонентов:

1. Масштабируемость прогнозирования данных процессов ПЦО позволяет строить прогноз в заданном масштабе для конечного пользователя, таким образом может предоставлять как агрегированные значения, так и с заданной детализацией данные процесса ПЦО.

2. Уникальный алгоритм построения прогнозирования процесса ПЦО на основе объектной нейронной модели позволяет строить прогнозы, учитывая длину ствола скважины и интервалы перфорации, глубину до и после пакера по каждой скважине.

3. Адаптивной дружественный интерфейс позволяет настраивать и представлять выходные данные в удобной форме для пользователя.

Масштабируемость и отказоустойчивость в архитектуре программного комплекса «ПЦО Калькулятор» обеспечивается заложенными архитектурными и технологическими решениями.

Архитектура программного комплекса «ПЦО Калькулятор» объединяет в себе современные отраслевые стандарты, методы и решения, и элементы ноу-хау, научной новизны в подходах к решению поставленной задачи.

Программный комплекс «ПЦО Калькулятор» позволяет реализовать задачи точного прогнозирования через построение интеллектуальной информационной системы, высокопроизводительной и безопасной, обеспечивающей выполнение всех необходимых требований к промышленной системе прогнозирования технологических процессов.

Научная новизна программного комплекса «ПЦО Калькулятор» заключается в ряде комплексных методов, основанных на алгоритмах машинного обучения и кластеризации.

Для анализа процесса ПЦО используются глубокие нейронные сети прямого распространения со скрытыми слоями, рекуррентные нейронные сети и сети с долгой и краткосрочной памятью, выделен в отдельный модуль – объектной нейронной модели.

Оптимальная конфигурация нейронной модели (метод обучения, количество входов и выходов и пр.) слоев выбирается в ручном или автоматическом режиме в соответствии выбором режима процессов ПЦО.

Построенная нейросетевая модель позволяет прогнозировать температуру, сухость и энталпию агента в зависимости от следующих входных параметров:

- параметры закачиваемого пара: глубина, на которой находится агент закачки; давление закачки; температура агента; расход агента; плотность агента;
- параметры скважины: глубина, глубина до пакера, длина паропровода, зона залежи;

- параметры предыдущего цикла ПЦО: вскрытая толщина, расход агента, темп закачки, продолжительность закачки, продолжительность пропитки, максимальная температура прогрева, дебит нефти и жидкости до/после ПЦО.

Модель событий состоит из главного окна, режима обучения и режима прогнозирования (рисунок 2). При этом в приложении в главном окне пользователь может выбрать множество параметров, в том числе масштаб прогнозирования – с каким шагом проводить расчёты, реальную скважину из выпадающего списка и цикл ПЦО. Также необходимо заполнить данные о закачиваемом паре и данные о скважине. Введенные параметры позволяют провести расчет показателей «температура», «сухость», «энталпия» – смоделировать процесс ПЦО (рисунок 3).

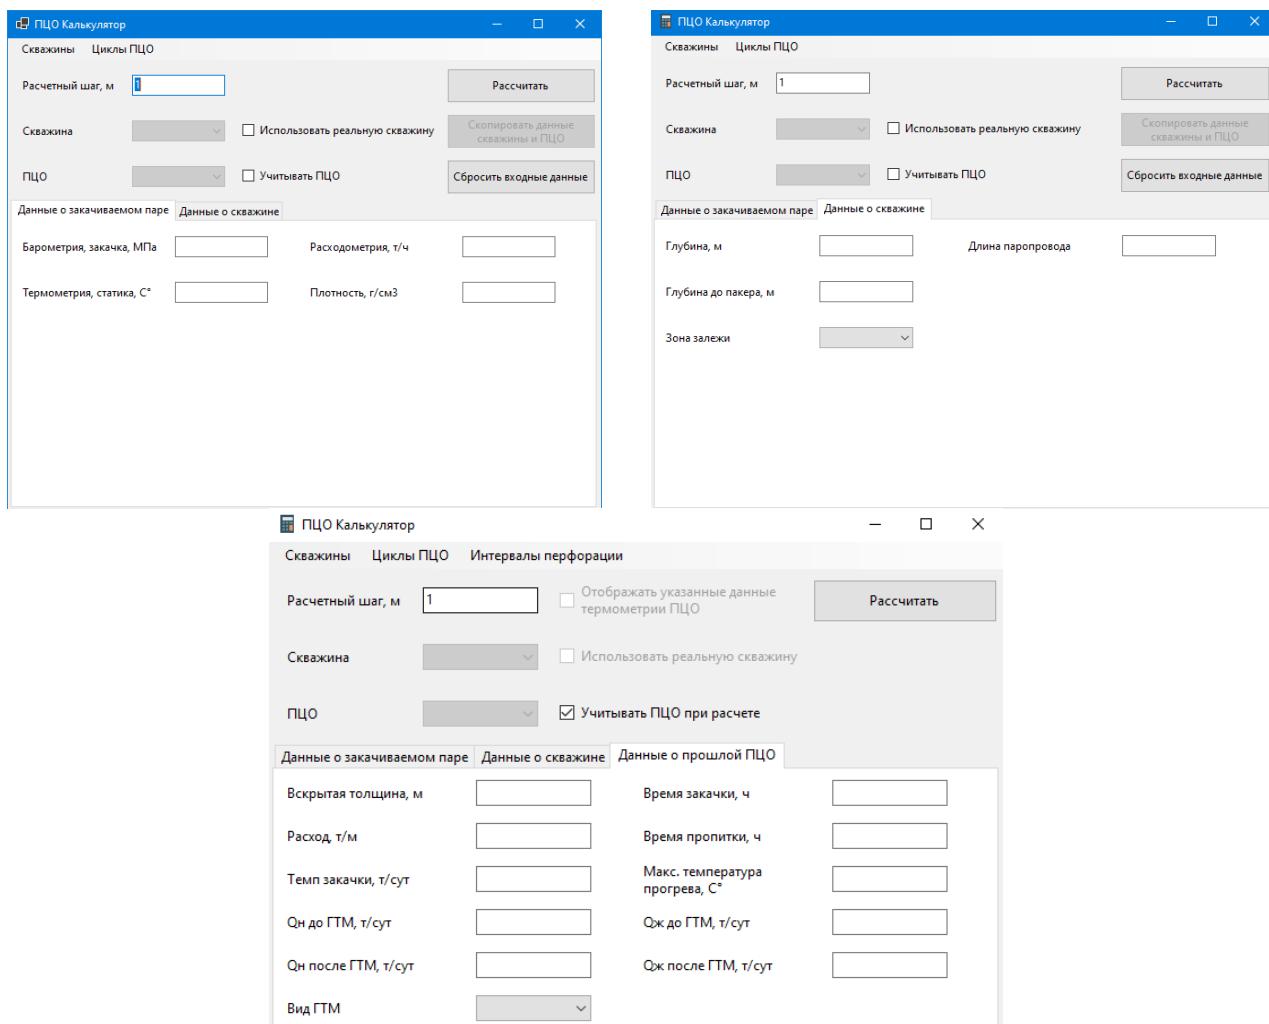


Рисунок 2. Окно для заполнения входных данных

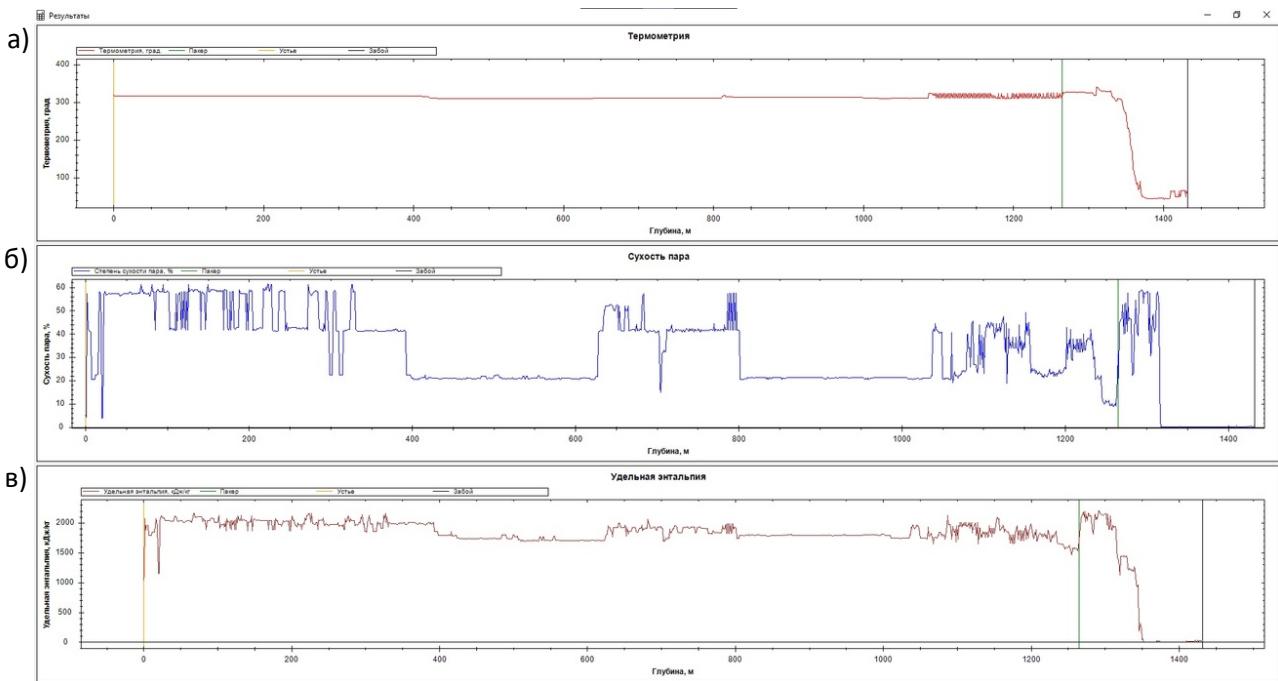


Рисунок 3. Окно результатов «ПЦО Калькулятор»:
а – температура агента, б – сухость агента, в – энталпия агента

Разработанный метод позволяет автоматически сравнивать параметры ГИС-55 термометрии с расчетными параметрами по скважине.

Научная новизна расчета процесса ПЦО основывается на научных авторских исследованиях проблемы термодинамический процессов на различных этапах производственного процесса ПЦО в условиях неопределенности и недостаточной полноты исходной информации.

Методика оценки погрешности прогнозирования данных основана на расчете среднеквадратичной относительной ошибки обучения нейросети и составляет не более 5% (рисунок 4).

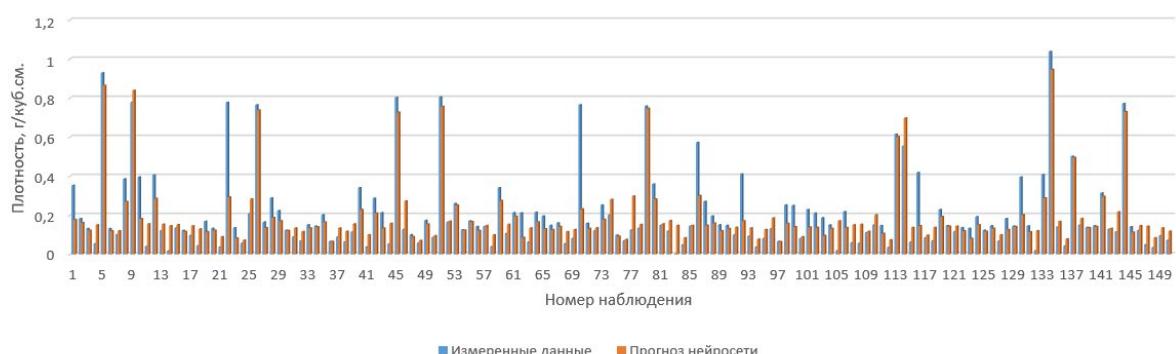


Рисунок 4. Сопоставление измеренных данных плотности агента с прогнозными значениями нейросети

Процесс ПЦО представлен в виде динамической системы в собственном пространстве состояний, причем изменения состояния происходят на каждом этапе прогнозирования.

Применение разработанных моделей и методов стохастической устойчивости в совокупности с адаптированными подходами теории устойчивости позволяют сделать вывод об устойчивости процесса.

Предлагаемые модели и методы были успешно апробированы для расчета процесса ПЦО на реальном производстве (ООО «ЛУКОЙЛ-Коми») и реализованы в виде отдельных программных продуктов – Расчет «ПЦО Калькулятор» и Обучение «Новые данные ГИС-55».

Заключение. Разработан программный комплекс «ПЦО Калькулятор» для расчета и прогнозирования теплофизических процессов, происходящих при движении теплоносителя от ПГУ до забоя скважины, на основе нейросетевого алгоритма расчета и автоматизации всех расчетов по пересчету параметров путем создания инженерного программного обеспечения.

Получены следующие ключевые научно-практические результаты:

1. Интеллектуальная архитектура системы на базе нейронных сетей, обеспечивающая полнофункциональную автономную работу всех компонентов системы в условиях ограниченных данных;
2. Адаптивный алгоритм прогнозирования и обучения;
3. Методика автоматического расчета прогнозирования процессов ПЦО;
4. Модель обучения на основе данных технологических процессов.

Применение нейросетевой модели позволит непрерывно обучать нейронную сеть, загружая параметры прогрева нефтедобывающих скважин, а спроектированный инженерный программный комплекс «ПЦО Калькулятор» сможет использовать эту модель для оценки комбинированных методов воздействия на пласт.

Библиографический список

1. lukoil.ru – Отчет совета директоров ПАО «ЛУКОЙЛ» о результатах развития по приоритетным направлениям деятельности. Годовой отчет 2017 г. [Электронный ресурс]. Режим доступа: <https://www.lukoil.ru/Handlers/DownloadPartialPdfHandler.ashx?fid=289721&fc=9&pages=48,74>
2. Дополнение к технологической схеме разработки пермо-карбоновой залежи Усинского месторождения//Научно-проектный центр в г.Ухте Филиала ООО «ЛУКОЙЛ-Инжиниринг» «ПермНИПИнефть» в г.Перми. Ухта, 2016
3. Временный технологический регламент на проведение пароциклических обработок скважин пермо-карбоновой залежи Усинского месторождения//ТПП «Усинскнефтегаз» ООО «ЛУКОЙЛ-Коми». Усинск, 2020
4. Тютяев А.В., Должиков А.С., Зверева И.С. Расчётный метод оценки эффективности электропрогрева нефтяных скважин // Фундаментальные исследования. – 2015. – № 2-19. – С. 4188-4191. [Электронный ресурс]. Режим доступа: <http://fundamental-research.ru/ru/article/view?id=37927>.
5. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.

6. Random forest [Электронный ресурс]. Режим доступа:
https://ru.wikipedia.org/wiki/Random_forest

**DEVELOPMENT OF THE ENGINEERING SOFTWARE MODULE FOR
FORECASTING THE COOLANT PARAMETERS BY
WELL BOREHOLE IN THE PROCESS OF PERFORMING STEAM
TREATMENT ON THE EXAMPLE OF THE PERMO-CARBON BEDROOM
OF THE USINSKOE FIELD DEPENDING ON THE GEOLOGICAL FIELD
DATA**

Stepanov Vladimir A.

Perm State National Research University
st. Bukireva, 15, Perm, Russia, 614990, svamail@list.ru

Kultysheva Svetlana N

Branch of OOO LUKOIL-Engineering PermNIPIneft in Perm
st. Permskaya, 3a, Perm, Russia, 614000, skultyshova@mail.ru

The article presents a description of the development of an engineering software module for predicting the parameters of the coolant along the wellbore in the process of carrying out cyclic steam treatments on the example of the Permian-Carboniferous reservoir of the Usinskoye field. The product provides the ability to control the technological parameters of the heat carrier (temperature, dryness and enthalpy of the agent) during the steam treatment cycle, in addition, it helps to increase the knowledge of the technological parameters of the heat carrier injected through the cyclic injection of the agent into the well, and as a result, the timely regulation of the technological parameters of the injection in order to achieve the highest efficiency of cyclic steam treatment.

Keywords: cyclic steam treatment, depth, temperature, dryness, enthalpy, neural network model, training set.

ОЦЕНКА СОСТОЯНИЯ ЗАРЯДА АККУМУЛЯТОРНОЙ БАТАРЕИ ВСТРОЕННЫХ И ПОРТАТИВНЫХ УСТРОЙСТВ С ИСПОЛЬЗОВАНИЕМ НЕЙРОННЫХ СЕТЕЙ

Травкин Никита Антонович, Лукьянов Александр Михайлович

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г.Пермь, ул.Букирева, 15,
almiluk@psu.ru, nikita@trvn.ru

В статье представлено описание разработки нейросетевой системы для оценки состояния заряда батареи во встроенных устройствах и устройствах интернета вещей. Предложенный метод позволяет более точно вычислять состояние заряда, а также переносить вычисления на другое, более мощное устройство.

Ключевые слова: искусственный интеллект, нейросетевые технологии, прогнозирование, оценка, батарея, состояние заряда.

Введение. В наше время беспроводные устройства становятся всё популярнее. Мировая тенденция такова, что многие компании отказываются от проводных интерфейсов в пользу беспроводных. Например, такие компании, как Apple, Samsung и многие другие отказываются от аудио-разъёмов в своих телефонах, поэтому возрастает популярность беспроводных наушников, в том числе “True Wireless” гарнитур, которые имеют три аккумулятора (в каждом из двух наушников и зарядном кейсе). Беспроводная периферия для компьютеров (клавиатуры, компьютерные мыши и т.д.) также становится всё более распространённой. При этом производители всё чаще отказываются от использования батареек в пользу встроенных аккумуляторов, однако в подобных устройствах уделяется мало внимания качеству контроля уровня заряда. Задача точного определения состояния заряда крайне сложна, тем более на самих беспроводных устройствах, особенно в условиях, когда производители стремятся минимизировать их себестоимость. И даже профессиональная периферия зачастую сообщает только два состояния: “заряжен” и “разряжен”, что может оказаться крайне неудобным, когда заряд приближается к порогу оповещения о низком уровне, но не пересекает его.

Существуют различные способы определения уровня заряда, в числе наиболее распространённых: “Coulomb counting” [1], использующий аппаратный счетчик количества протекшего заряда и расширенный метод фильтрации Калмана [2], требующий сложных вычислений. Также ведутся исследования по использованию нейронных сетей, например, обученных с помощью “улучшенного метода обратного распространения ошибки” [3]. Все эти методы имеют свои недостатки и оставляют простор для увеличения точности оценки.

Все предложенные способы предполагают использование лишь информации о состоянии самой батареи. В данной статье предлагается ввести некоторые дополнительные метрики, напрямую не связанные с состоянием батареи, но влияющими на него. Например – нагрузка на систему, количество переданных пакетов информации, температура процессора (не батареи) и т.д. Кроме того, в отличие от многих других методов, использование нейронных сетей позволит перенести процесс вычислений на другое, более мощное устройство, уменьшая нагрузку на сами устройства содержащие аккумуляторы и упрощая их структуру. Например, для всех устройств периферии мобильных телефонов, вычисления можно перенести на сами телефоны, которые сейчас зачастую даже содержат специальные ядра для работы нейронных сетей. Также для всех устройств некоторой сети IoT такие вычисления можно перенести на один сервер, уменьшая нагрузку на них.

Исследование. В ходе выполнения работы нами были выдвинуты и проверены следующие гипотезы:

1. С помощью нейронных сетей возможно оценить и предсказать уровень заряда аккумулятора с точностью, достаточной для его комфортной эксплуатации.
2. Эта оценка будет точнее, если учитывать внешние данные (недоступные обычным контроллерам заряда), такие как средний уровень загруженности системы (load average).

Для проверки поставленных гипотез необходимо собрать данные поведения аккумуляторной батареи во времени. Для данного эксперимента была создана специальная система, похожая на устройство “интернета вещей”. Данная система была выполнена из материнской платы мобильного телефона, адаптированной для автономной работы с разными аккумуляторами. Эта плата, помимо стандартного контроллера питания, способного выполнять лишь измерения напряжения аккумулятора в закрытой цепи, также имеет отдельный контроллер заряда, способный выполнять зарядку и оценку состояния заряда подключенного аккумулятора. Хотя точность этого контроллера и не велика по сравнению с дорогим лабораторным оборудованием, предполагается, что ее будет достаточно, чтобы доказать или опровергнуть выдвинутые гипотезы.

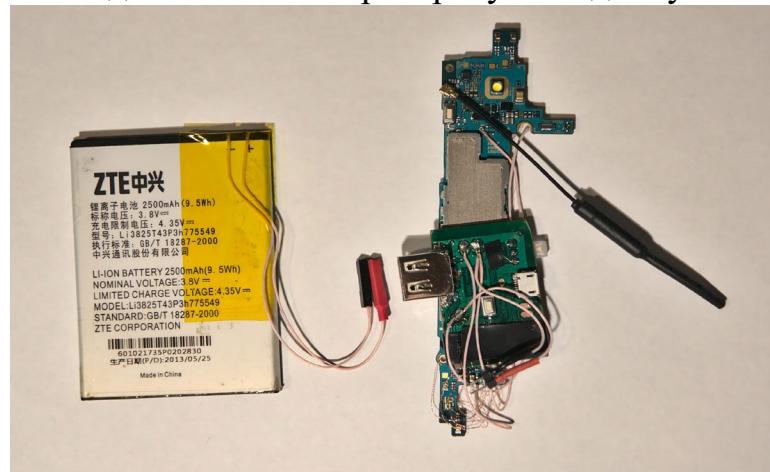


Рисунок 1. Устройство для записи данных о состоянии батареи

На системе запущена операционная система общего назначения на базе ядра Linux. Для сбора данных используется специальная программа, которая записывает мгновенные измерения с АЦП системного контроллера питания, состояние контроллера зарядного устройства, а также состояние нагрузки системы (в качестве “внутреннего” параметра, обычно недоступного контроллеру заряда.)

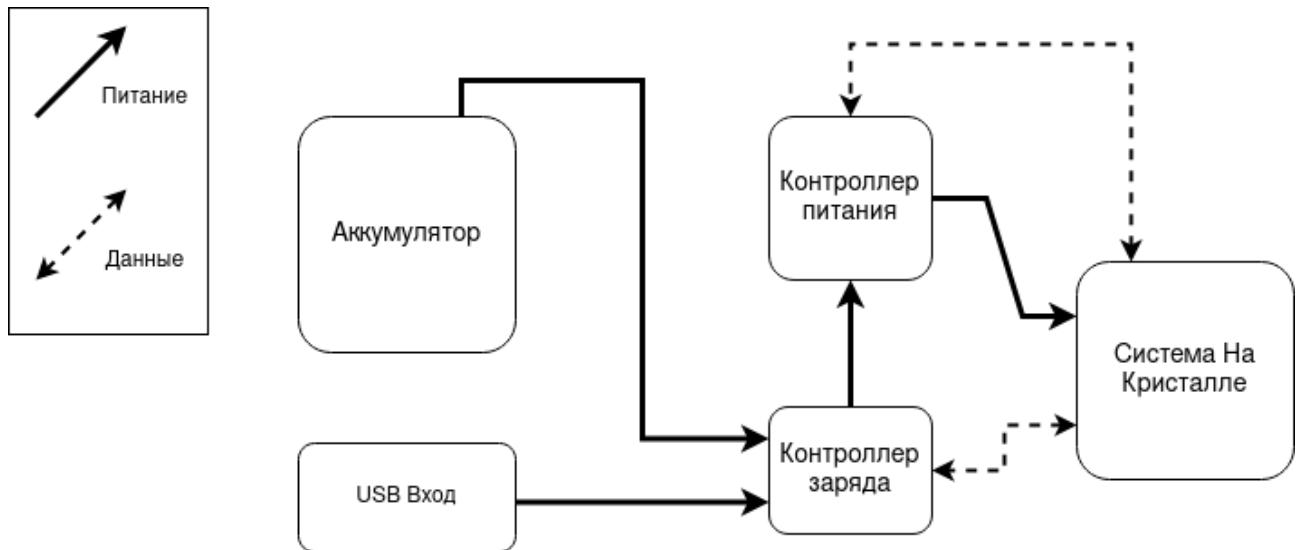


Рисунок 2. Схема питания тестовой системы

Измерения проводятся каждые 15 секунд и каждые 30 минут загружаются на отдельный сервер для дальнейшего анализа.

Таблица 1. Пример записанных данных

timestamp	capacity	now	avg	ocv	adc	lav1	lav5	lav15
1612582301	72	4031	4033	4047	4026165	0,01	0,03	0,00
1612582376	72	3941	3948	4047	3935382	0,65	0,16	0,04
1612582482	72	3918	3928	4041	3910704	3,42	1,31	0,47
1612582694	70	3926	3917	4030	3878388	4,00	2,71	1,22
1612582815	70	3898	3902	4022	3900129	4,00	3,14	1,56
1612582906	69	3918	3911	4017	3901302	4,00	3,37	1,79
1612582981	69	3986	3986	4013	3981510	3,11	3,31	1,90
1612583072	69	4000	4000	4012	3988560	0,73	2,46	1,72
1612583132	69	4002	4001	4012	3989442	0,26	2,01	1,61
1612583223	69	4002	4002	4012	3997080	0,06	1,49	1,46
1612583434	68	4002	4002	4010	3995904	0,22	0,82	1,19

В качестве входных данных первой нейронной сети было решено использовать набор последовательных измерений с АЦП контроллера зарядного устройства (напряжений закрытой цепи аккумулятора), составляемый методом скользящего окна из временного ряда, получение которого описано выше. В ходе экспериментов был подобран оптимальный размер окна в 40 записей. Результатом же работы сети являются два спрогнозированных значения: текущий уровень заряда в процентах, и напряжение открытой цепи на аккумуляторе в мВ. Пример входных данных сети показан в таблице 2, а выходных в таблице 3.

Таблица 2. Пример входных данных нейросети

X1	X2	X3	X4	...	X38	X39	X40
4005012	4006188	4006776	4007952		3972108	3971226	3970050

Таблица 3. Пример выходных данных нейросети

D1	D2
60	3932

Для обучения сети, было сформировано множество, содержащее примерно 105 тысяч записей и охватывающие около 10 циклов разряда-заряда, с различной степенью загруженности системы в различные моменты времени. А в качестве тестового, множество, содержащее 8000 записей (около одного такого цикла).

Для создания и обучения первой нейронной сети была использована программа «Нейросимулятор» [4], при работе с которой, изменяя структуру нейронной сети, используя принципы, описанные в [5], получилось достичь следующих результатов: среднее квадратичное отклонение для текущей ёмкости аккумулятора составило 6.1%, а для напряжения открытой цепи – 3.9%. Данные выборочной проверки достоверности прогнозируемых этой сетью результатов представлены на рисунках 3 и 4. Достигнутой точности достаточно, чтобы примерно оценить уровень заряда, и однозначно определить, есть ли необходимость зарядить устройство. Таким образом, нам удалось подтвердить первую гипотезу экспериментально.

Затем, для проверки второй гипотезы, была создана другая нейронная сеть, принимающая на вход, помимо данных АЦП, значения средней загруженности системы для каждого промежутка времени. За счёт этого удалось добиться среднего квадратического отклонения в 4,5% для ёмкости батареи и 2,7% для напряжения открытой цепи. Т.е. точность увеличилась, в среднем, на 30% от изначальной. Исходя из этих результатов, гипотезу о повышении точности оценки при использовании внешних данных также можно считать подтверждённой.

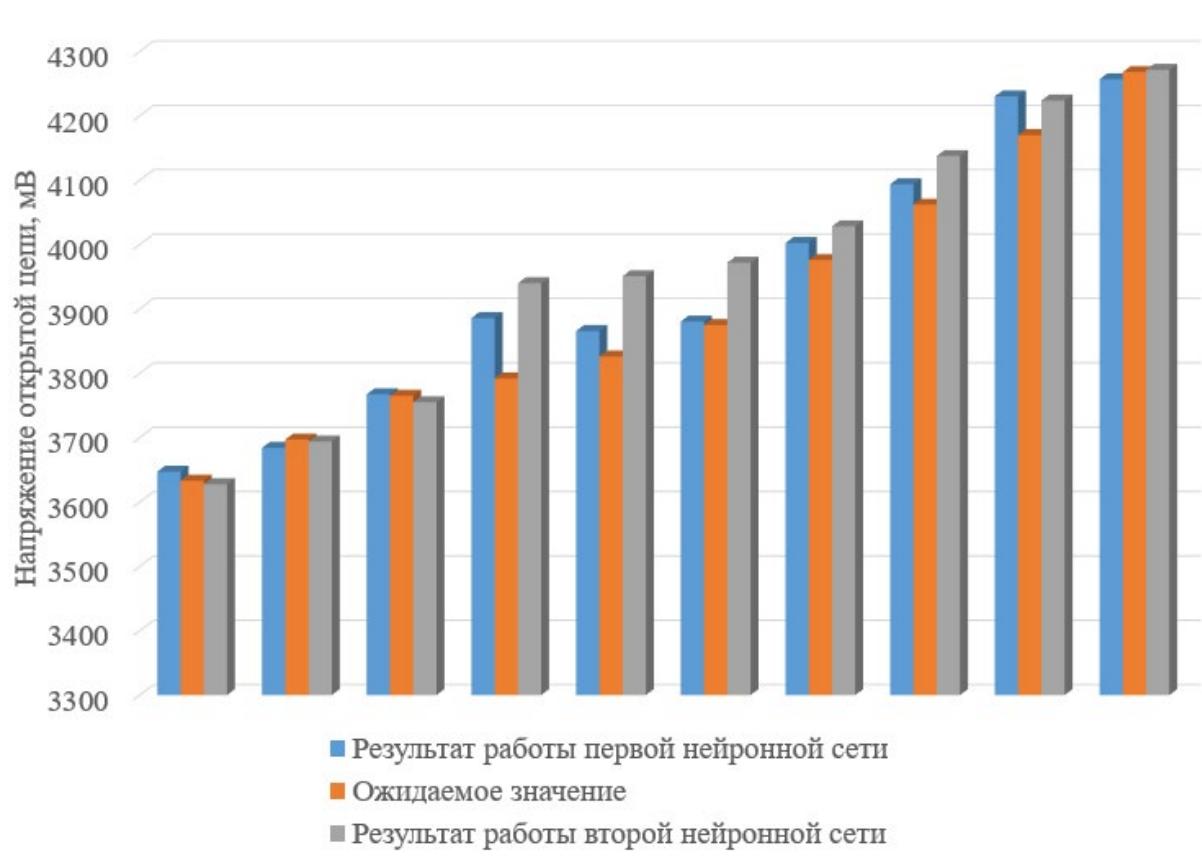
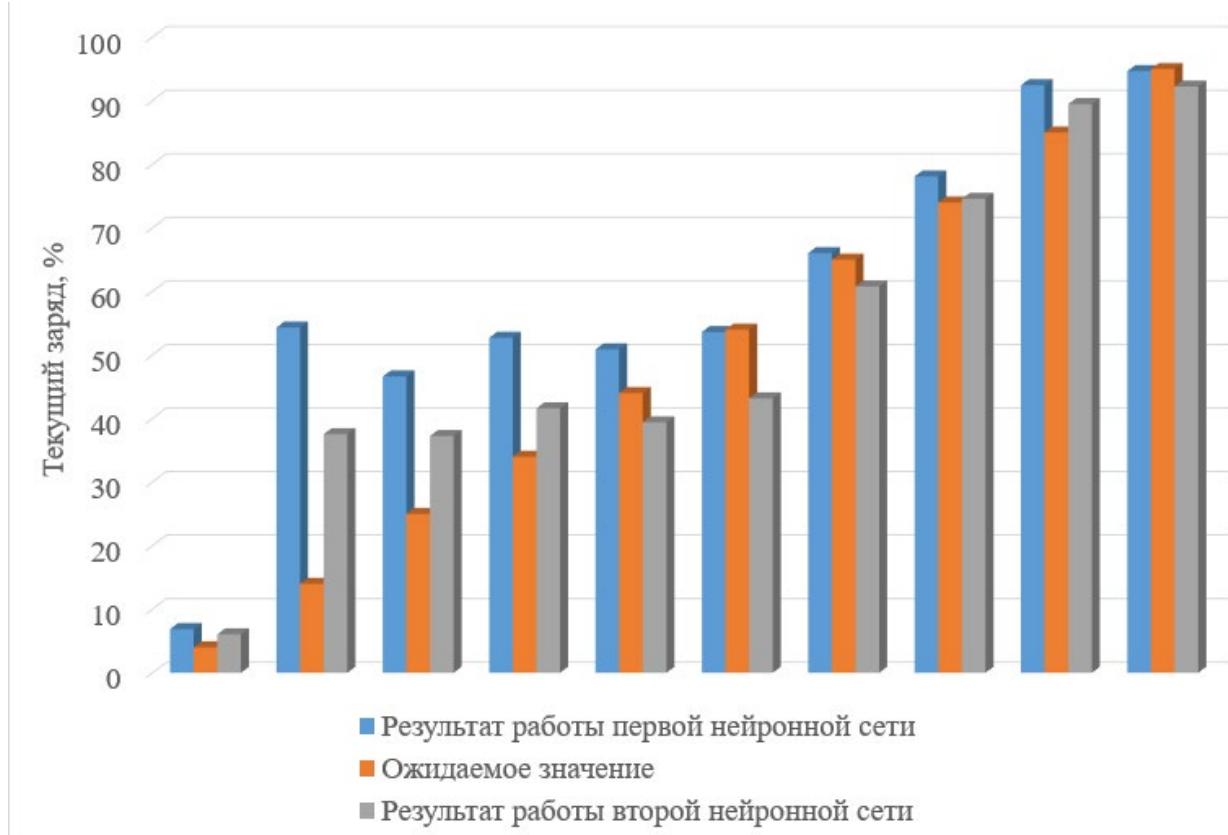


Рисунок 3. Проверка достоверности результатов работы нейронных сетей (процент заряда)

Из результатов проверки видно, что обе сети дают достаточно большую ошибку при прогнозировании процента заряда во время зарядки при малом значении реального процента заряда. Это вызвано, в основном, недостаточным объёмом данных для обучения, описывающих именно такую ситуацию, так как процесс зарядки занимает значительно меньшее время. Также из графиков видно, что вторая сеть даёт значительно меньшую ошибку, что дополнительно подтверждает гипотезу о повышении точности оценки при использовании внешних данных. Кроме того, из рисунка 4 видно, что в той же ситуации спрогнозированное значение напряжения открытой цепи значительно ближе к реальному. Однако, обе сети, в среднем, для второго параметра дают большую ошибку, чем для первого, а для определения уровня заряда по нему необходимы дополнительные вычисления, таким образом, наибольшая точность и эффективность оценивая достигается именно при использовании обоих выходных параметров.

Заключение. В ходе описанной работы была создана нейронная сеть, позволяющая достаточно точно оценивать состояние аккумуляторной батареи, а также увеличивающая точность такой оценки за счёт использования внешних для аккумулятора данных. С использованием данной сети становится возможными повышение точности оценки состояния аккумуляторной батареи встроенных и портативных устройств, по сравнению с другими, наиболее распространёнными, методами. Вместе с тем, предложенный нами метод позволяет избежать необходимости усложнения таких устройств и увеличения их стоимости. Это достигается за счёт возможности переноса вычислений стороннее устройство, способное обслуживать сразу множество аккумуляторов.

Библиографический список

1. Ng, K. S., Moo, C.-S., Chen, Y.-P., & Hsieh, Y.-C. (2009). *Enhanced coulomb counting method for estimating state-of-charge and state-of-health of lithium-ion batteries*. *Applied Energy*, 86(9), 1506–1511. doi:10.1016/j.apenergy.2008.11.021
2. Haihong Pan, Zhiqiang Lü, Weilong Lin, Junzi Li, Lin Chen, State of charge estimation of lithium-ion batteries using a grey extended kalman filter and a novel open-circuit voltage model, *Energy* (2017), doi: 10.1016/j.energy.2017.07.099
3. Zhang C.-W. et al. State of Charge Estimation of Power Battery Using Improved Back Propagation Neural Network // *Batteries*. MDPI AG, 2018. Vol. 4, № 4. P. 69. (<https://www.mdpi.com/2313-0105/4/4/69/htm>)
4. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 5.0 // Свидетельство о государственной регистрации программы ЭВМ № 2014618208. Заявка Роспатент № 2014614649. Зарегистрировано в Реестре программ для ЭВМ 12 августа 2014г.
5. Ясницкий Л.Н. Интеллектуальные системы. – М.: Лаборатория знаний, 2016. – 221 с.

STATE OF CHARGE ESTIMATION OF BATTERIES IN PORTABLE DEVICES USING NEURAL NETWORKS

Travkin N., Lukianov A.

Perm State University

614990, Russia, Perm, st. Bukireva, 15,

almiluk@psu.ru, nikita@trvn.ru

The article describes the development of a neural network system for assessing the state of charge of a battery in portable, embedded and IoT devices. The proposed method makes it possible to more accurately calculate the state of charge, and perform those calculations to another, more powerful device.

Keywords: artificial intelligence, neural network technologies, estimation, battery, state of charge.

УДК 336.273.3

ПРИМЕНЕНИЕ НЕЙРОСЕТЕВЫХ ТЕХНОЛОГИЙ ДЛЯ ОЦЕНКИ КРЕДИТОСПОСОБНОСТИ ЗАЁМЩИКА

Воронова Кристина Дмитриевна, Гимашева Ксения Вадимовна

Пермский государственный национальный исследовательский университет,

ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,

christinavoronova12@gmail.com

Предметом исследования является система кредитования США. В отчете представлено описание разработки нейронной сети для прогнозирования решения о выдаче кредитов на основе данных банков США. С помощью нейросетевой модели была выявлена прямая зависимость результата от кредитной истории заёмщика. Использование данной модели позволяет выявлять неоднозначные ситуации при кредитовании, а также оценивать кредитоспособность заявителя.

Ключевые слова: искусственный интеллект, нейросетевые технологии, кредитоспособность, кредитная история, прогнозирование.

Введение.

Выдача кредитов является основным источником заработка банков. Основная часть их активов формируется непосредственно за счёт прибыли полученной от займов, предоставленных банком. Основная цель банка – вложить активы в надёжные руки, но не всегда получается оценить надёжность потенциального заёмщика. Успех или неудача организации во многом зависит от способности банка оценивать кредитный риск.

Проблема состоит в том, чтобы классифицировать заемщика, как исправного плательщика или неплательщика. Данное заключение о заемщике можно сделать на основе его кредитной истории. Многие клиенты банков даже не задумываются о роли их кредитной истории в процедуре оценки, а во многих странах даже нет единой базы по заемщикам, которая была бы доступна и банкам, и клиентам. Качество кредитной истории зависит от своевременности выплат по кредитам, отсутствия просрочек, а также от размера задолженности по текущим кредитам.

Сделав заключение о заемщике на основе его кредитной истории, банк принимает решение об одобрении или отклонении заявки по кредиту.

На основании этих данных можно обучить нейросеть определять статус заявки по займу на основе кредитной истории, а также некоторых других параметров.

Необходимые данные были получены с сайтов [1-2], на которых представлена информация о потенциальных заемщиках. Таким образом, при разработке нейросетевой модели были использованы следующие входные параметры и система кодирования их значений:

X1 – Пол (1 – мужской, 2 – женский).

X2 – Семейное положение (1 – замужем/женат, 2 – холост).

X3 – Количество детей (0 – нет детей, 1 – один ребёнок, 2 – двое детей, 3 – трое и более детей).

X4 – Наличие высшего образования (1 – есть, 2 – нет).

X5 – Статус самозанятости (1 – есть, 2 – нет).

X6 – Доход заявителя (в долларах США).

X7 – Доход поручителя (в долларах США).

X8 – Сумма кредита (в тысячах долларов США).

X9 – Срок кредита (в месяцах).

X10 – Наличие кредитной истории (0 – нет, 1 – есть).

X11 – Расположение недвижимости (1 – городское, 2 – пригородное, 3 – деревенское).

Выходным параметром модели является параметр D1 – статус заявки по кредиту (0 – отклонена, 1 – одобрена).

Из исходного множества были исключены данные, в которых отсутствовали один или более параметров. Таким образом, объём итогового множества включает в себя 476 примеров, 55 из которых составляют тестовое множество, а 421 – обучающее множество.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [3] по методике [4]. Оптимальная структура нейронной сети представляет собой персепtron, который имеет одиннадцать входных нейронов, один выходной нейрон и один скрытый слой с тремя нейронами. В качестве активационных функций нейронов скрытого слоя и выходного слоя использовался тангенс гиперболический, а в качестве алгоритма обучения – алгоритм упругого распространения.

Средняя квадратичная относительная ошибка тестирования составила 36.9%, однако приемлемым результат считать нельзя. Наибольшая погрешность

была обнаружена среди примеров, где отсутствовала кредитная история, но кредит был одобрен, а также среди примеров, где была кредитная история, но заявка была отклонена.

На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактическим и прогнозируемым нейросетью значением статуса заявки для примеров из тестирующего множества.

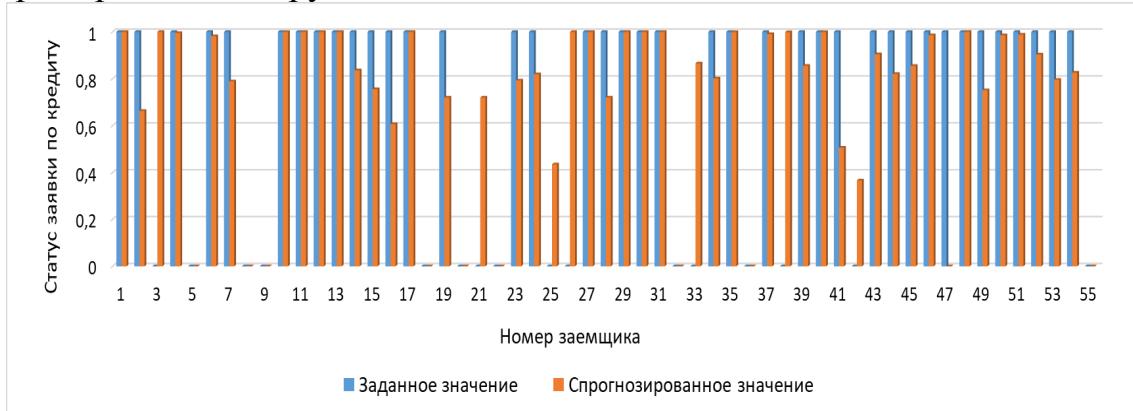


Рисунок 1. Результат тестирования нейронной сети

Для того, чтобы снизить процент ошибки тестирования, исходное множество было проверено на выбросы по методике [5]. Данная методика заключается в том, что необходимо найти в исходном множестве примеры, у которых будет наибольшая погрешность тестирования. Найденные примеры будут являться выбросами. Чтобы их найти, нужно выгрузить исходное множество в «Нейросимулятор 5» и проверить разность между фактическим и спрогнозированным нейросетью результатом. Найденное значение и будет являться погрешностью тестирования. В случае, если пример являлся выбросом, он исключался из множества.

После удаления выбросов осталось 424 примера, в качестве обучающего множества было взято 379 примеров, а в качестве тестирующего – 45 примеров. Структура нейронной сети осталась без изменений.

Таким образом средняя квадратичная относительная ошибка тестирования уменьшилась более чем в 2 раза (составила 15.2%).

На рисунке 2 представлена гистограмма, демонстрирующая разницу между фактическим и прогнозируемым нейросетью значением статуса заявки для примеров из тестирующего множества.

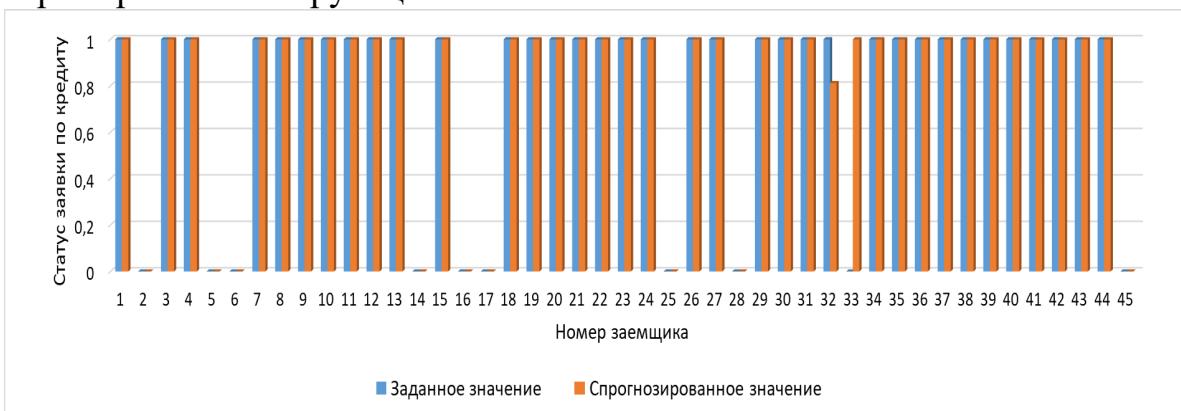


Рисунок 2. Результат тестирования нейронной сети после удаления выбросов

Из результатов, изображённых на рисунке 2, можно сделать вывод об адекватной работе спроектированной нейросетевой модели. Однако обучающее и тестирующее множества не включают в себя ряд примеров, которые выделяются из общей закономерности.

На рисунке 3 представлена оценка значимости входных параметров, выполненная с помощью программы «Нейросимулятор 5». Результаты являются действительными как для первого, так и для второго множества.

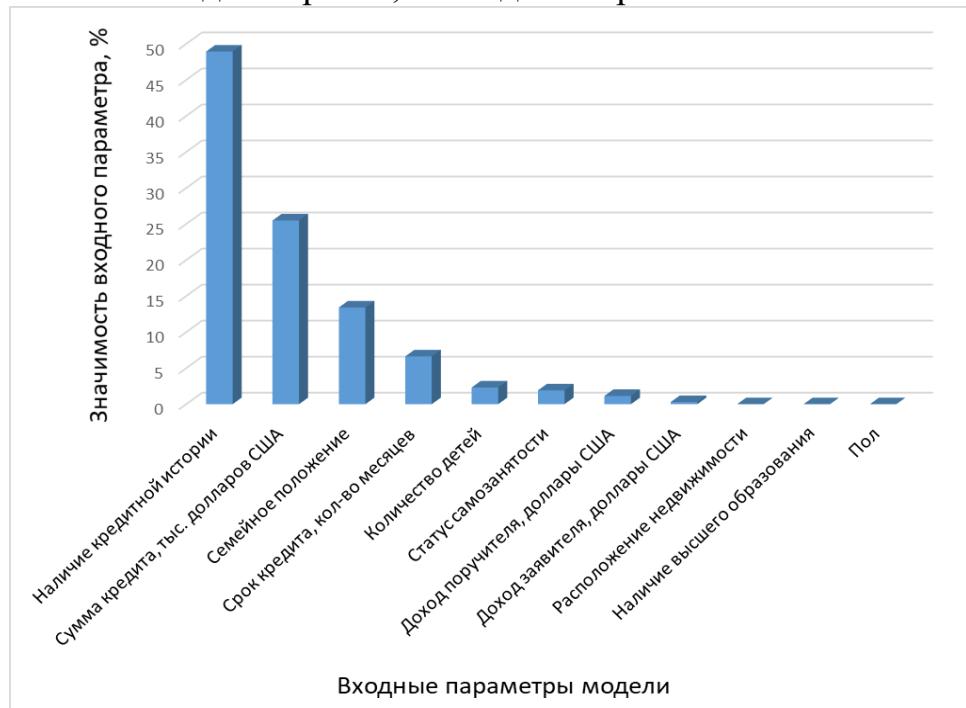


Рисунок 3. Значимость входных параметров нейросетевой модели

Как видно из рисунка 3, наиболее значимым параметром является «Наличие кредитной истории». Именно поэтому нейросеть не может прогнозировать статус заявки для примеров, где отсутствует кредитная история, но кредит был одобрен, а также для примеров, где есть кредитная история, но заявка была отклонена.

На основе полученных результатов можно сделать следующие предположения:

- В исходных данных недостаточно примеров, где отсутствует кредитная история, но кредит был одобрен, а также примеров, где есть кредитная история, но заявка была отклонена;
- Данного набора параметров недостаточно для точного прогнозирования статуса заявки.

В США кредитная история является одним из параметров, по которым происходит оценка кредитоспособности заёмщика – баллов кредитного scoringa. Кредитный scoring позволяет провести более глубокую оценку платежеспособности, так как включает в себя множество дополнительных параметров, например, своевременность оплаты по счетам, штрафы, профессия, стаж работы и др.

Можно предположить, что отсутствие именно этого параметра не всегда позволяет дать точную оценку статуса по кредиту для потенциального заёмщика (в ситуациях, выделяющихся из общей закономерности).

Однако если заключение банка было сделано на основе лишь этих параметров, возникает вопрос об объективности системы кредитования США.

Заключение. Построена нейросетевая модель, предназначенная для прогнозирования решения о выдаче кредитов. На основе проведённых исследований была выявлена прямая зависимость результата от наличия кредитной истории. Так как исследования проводились на основе банков США, была изучена американская система кредитования. Основным параметром данной системы являются баллы кредитного scoringa. Scoring включает в себя не только параметры, представленные в исходном множестве, но и большое количество других. Исходя из этого было сделано предположение о недостатке этого параметра для более точного прогнозирования. Также была выявлена возможность того, что при использовании исходного набора параметров могло быть сделано заключение, которое не согласуется с общей закономерностью, что может свидетельствовать о непрозрачности системы кредитования.

Спроектированная нейросетевая модель может применяться для выявления неоднозначных ситуаций при кредитовании, а также для оценки кредитоспособности заёмщиков и для помощи в принятии решения о выдаче кредита, что может привести к улучшению деятельности банков в сфере кредитования.

Библиографический список.

1. Открытые наборы данных для машинного обучения. Loan Approval Prediction Dataset. [Электронный ресурс] URL:<https://www.kaggle.com/premptk/loan-approval-prediction-dataset> (дата обращения: 05.03.2021).
2. Открытые наборы данных для машинного обучения. Loan Approval Prediction. [Электронный ресурс] URL:<https://www.kaggle.com/sonalisingh1411/loan-approval-prediction> (дата обращения: 05.03.2021).
3. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
4. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.
5. Yasnitsky L.N. Algorithm for searching and analyzing abnormal observations of statistical information based on the Arnold – Kolmogorov – Hecht-Nielsen theorem // International Journal of Advanced Trends in Computer Science and Engineering. 2020. 9(2). Pp. 1814-1819. DOI: 10.30534/ijatcse/2020/139922020 <http://www.warse.org/IJATCSE/static/pdf/file/ijatcse139922020.pdf>

APPLICATION OF NEURAL NETWORK TECHNOLOGIES TO ASSESS THE BORROWER'S CREDIT CAPACITY

Voronova Kristina Dmitrievna, Gimashева Кsenia Vadimovna

Perm State National Research University,
PMI. 614990, Russia, Perm, st. Bukireva, 15

The subject of the research is the US lending system. The report describes the development of a neural network for predicting loan issuance decisions based on US banking data. Using a neural network model, a direct dependence of the result on the borrower's credit history was revealed. The use of the model allows identifying ambiguous situations in lending, as well as assessing the applicant's creditworthiness.

Key words: artificial intelligence, neural network technologies, creditworthiness, credit history, forecasting.

УДК 519.2

НЕЙРОСЕТЕВОЕ ПРОГНОЗИРОВАНИЕ СТОИМОСТИ АРЕНДЫ КВАРТИР В ГОРОДЕ ПЕРМЬ

Никулин Артем Николаевич

Пермский государственный национальный исследовательский университет,
ПМИ 614990, Россия, г. Пермь, ул. Букирева, 15,
nikulin_artem@mail.ru

В статье представлено описание разработки и применения нейросетевых технологий для прогнозирования стоимости аренды квартир в городе Пермь. Система позволяет примерно оценить стоимость аренды квартиры по некоторым показателям, таким как кол-во комнат, этаж, площадь, район, состояние квартиры, тип дома и др.

Ключевые слова: нейросетевые технологии, оценка, прогнозирование недвижимость, стоимость.

Введение. При продаже или покупке недвижимости, следует выполнить глубокую оценку его стоимости. Обычно такие услуги предоставляют агентства по недвижимости или риэлторы, и зачастую эта оценка очень субъективна и может быть не точна. Недвижимость является довольно дорогим ресурсом и требует при ее выборе огромного внимания к каждой детали. Аналогичная же ситуация с оценкой стоимости жилья в аренду или под сдачу. Рассмотрев принципиальную возможность применения экспертных систем, баз знаний, мультиагентных систем и нейросетевого подхода для автоматизации определения рыночной стоимости недвижимости, выбор был сделан в пользу нейронных сетей, которые позволяют учитывать неявные факторы

формирования стоимости, адаптироваться к специфике территориальных рынков недвижимости.

Эффективность использования нейросетевых технологий была обоснована в работах разных авторов. В работе [1] авторы рассмотрели разные подходы к проектированию сети: сеть радиально-базисных функций, многослойный персепtron, обобщенно-регрессионная нейронная сеть, для оценки стоимости квартир. Многослойный персепtron оказался наиболее подходящим вариантом для решения данной задачи.

Авторы работ [2-5] предложили способ создания динамических систем для прогнозирования стоимости недвижимости с учетом географических, строительных и изменяющихся экономических параметров, таких как цена на нефть, курс доллара, объем ипотечных кредитов, ввод жилья в регионе, ВВП и др. Модели [2-5] способны адаптироваться к текущей экономической обстановке и не теряют актуальности со временем.

По данным Restate [6] в 2021 году цены на аренду квартир в Перми значительно упали и продолжают падать. Важно иметь самые актуальные данные по ценам квартир чтобы не переплатить больше или получить большую выгоду при сдаче квартиры в аренду. Моя работа направлена помочь людям, которым требуется снять себе квартиру или оценить квартиру для ее сдачи в аренду, но огромного количества времени для разбора этого вопроса они не имеют. Также она полезна для студентов, которые приехали в новый для себя город Пермь и хотели бы прикинуть стоимость квартиры, которая будет удовлетворять их требованиям, но они не очень знакомы с ценами на недвижимость в Перми.

Для решения данной задачи было решено воспользоваться современными методами математической статистики и искусственного интеллекта.

Работа осуществлялась в несколько этапов.

На первом этапе была собрана актуальная статистическая информация, с сайта ЦИАН [7], о квартирах доступных для аренды.

Второй этап: проектирование и обучение нейросети. Нейросетевая модель создается при помощи специальной программы «Нейросимулятор 5» [8], которая представляет собой полноценный симулятор полно связанных нейронных сетей по методике [9].

Входные параметры, с помощью которых прогнозируется стоимость квартиры: X1 – Район, X2 – Новостройка, X3 – Этаж, X4 – Количество комнат, X5 – Площадь, X6 – Состояние квартиры, X7 – Транспортная доступность, X8 – Наличие балкона (лоджии), X9 – Тип дома, X10 – Наличие мебели, X11 – Санузел, X12 – Охрана, X13 – Наличие магазина рядом, X14 – Наличие школы рядом, X15 – Развитость района в плане инфраструктуры, D1 – ожидаемая стоимость квартиры для съема на месяц.

На рисунке 1 представлена спроектированная нейронная сеть. Модель с одним скрытым слоем. Количество нейронов на скрытом слое – 7. Экспериментальным путем были получены функции активации для скрытого слоя, и алгоритмы обучения. Функция активации – Тангенс гиперболический. Алгоритм обучения – Левенберга-Марквардта.

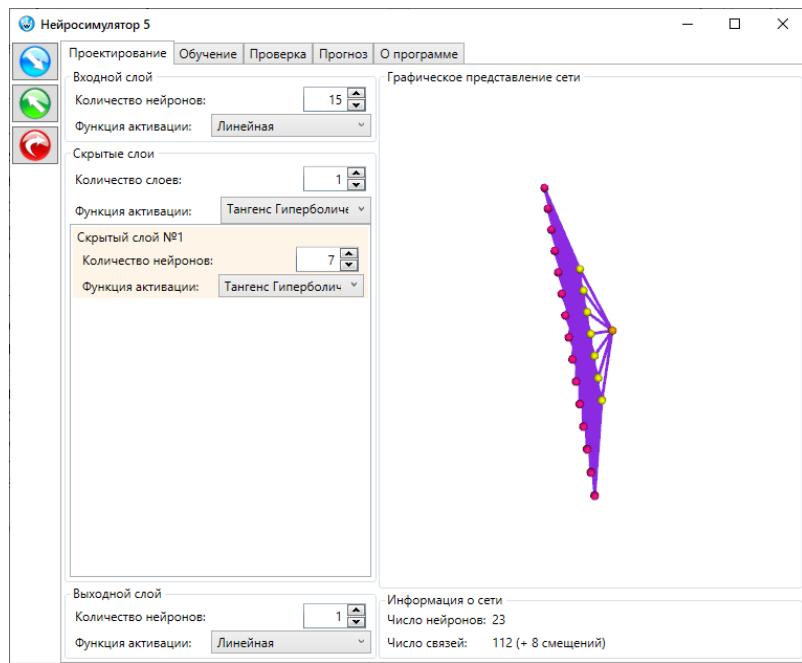


Рисунок 28. Проектирование сети

Третий этап: тестирование и проверка нейросети на адекватность.

График, отображающий разницу между действительной стоимостью квартиры и спрогнозированной, представлен на рисунке 2.

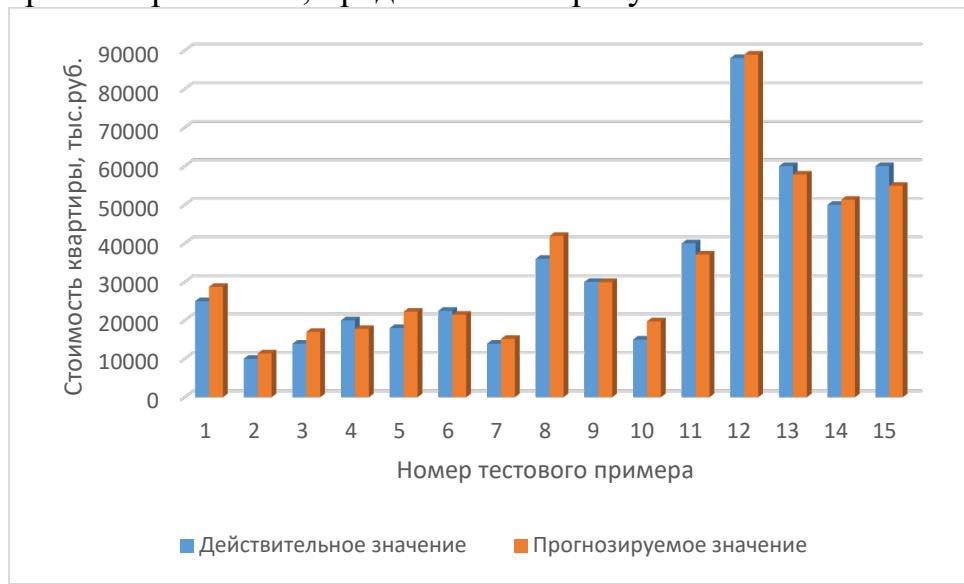


Рисунок 29. Результаты тестирования нейронной сети

Средняя ошибка нейронной сети – 4%. Следовательно, сеть пригодна для прогнозирования.

После того, как работа нейронной сети проверена на тестовых примерах и, таким образом, доказана адекватность нейросетевой математической модели, можно приступить к ее исследованию. Обученная нейросетевая модель реагирует на изменение входных переменных и ведет себя так же, как вела бы себя сама предметная область. Поэтому с помощью нейросетевой модели можно исследовать зависимости прогнозируемой величины от входных параметров модели.

На рисунке 3 видно, что самым значимым параметром модели является развитость инфраструктуры района.

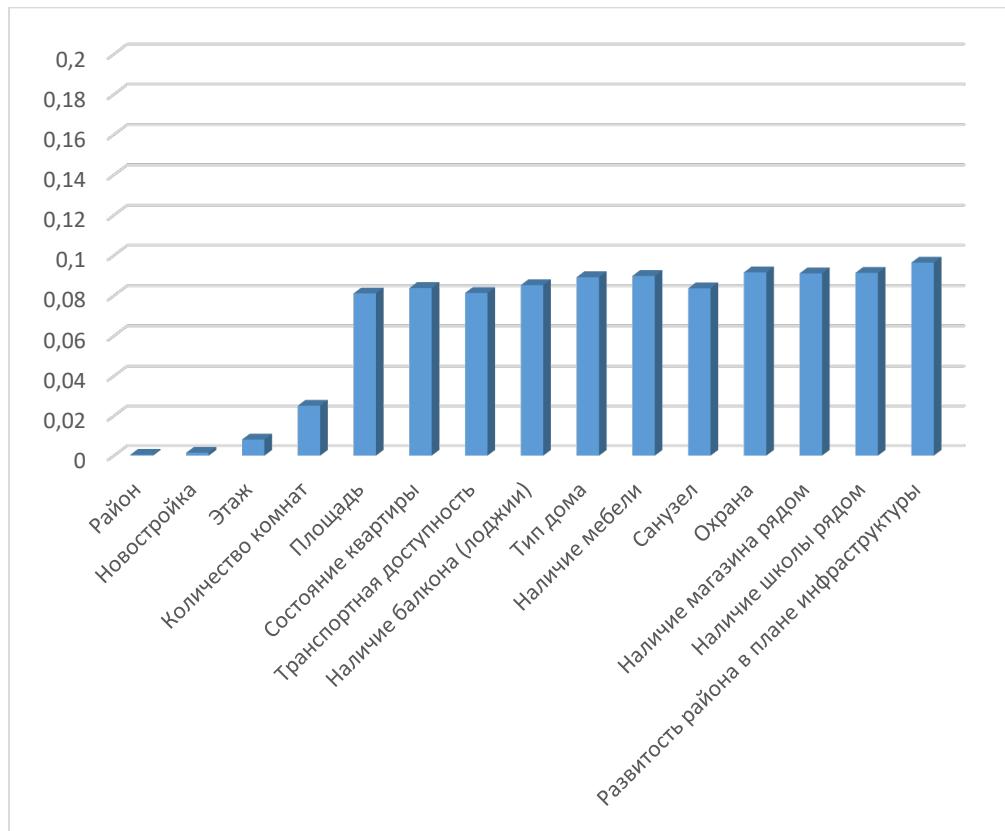


Рисунок 3. Значимость параметров нейронной сети

Исходя из этой гистограммы, можно утверждать, что на стоимость съема квартиры больше всего влияют: наличие магазина рядом, охрана, санузел, наличие школы рядом, площадь.

Изучая гистограмму, можно заметить, что большинство параметров являются важными в расчете стоимости съема квартиры. Также можно заметить, что важность очень мала таких параметров: район, этаж, количество комнат, новостройка.

Далее было проведено исследование жилищного рынка г. Пермь. Исследование производилось с помощью метода «замораживания» [9], суть которого заключается в варьировании значения одного параметра и фиксировании значений всех других параметров. Данный метод позволяет выявить влияние исследуемого параметра на выходной. Для этой цели было отобрано 2 квартиры, информация о параметрах которых отражена в таблице 1.

Таблица 1
Характеристики квартир,
выбранных для исследования

№ квартиры	1	2
X1	7	2
X2	1	1
X3	9	3
X4	1	3
X5	34	58
X6	2	2
X7	2	3
X8	2	2
X9	5	5
X10	2	2
X11	1	1
X12	1	1
X13	1	1
X14	1	2
X15	1	1

Для начала стоит рассмотреть самый незначимый параметр, и убедиться, что при его изменении значение выходного параметра изменяется довольно слабо. Рассмотрим график зависимости стоимости квартиры от параметра X1 – Район на рис 4.

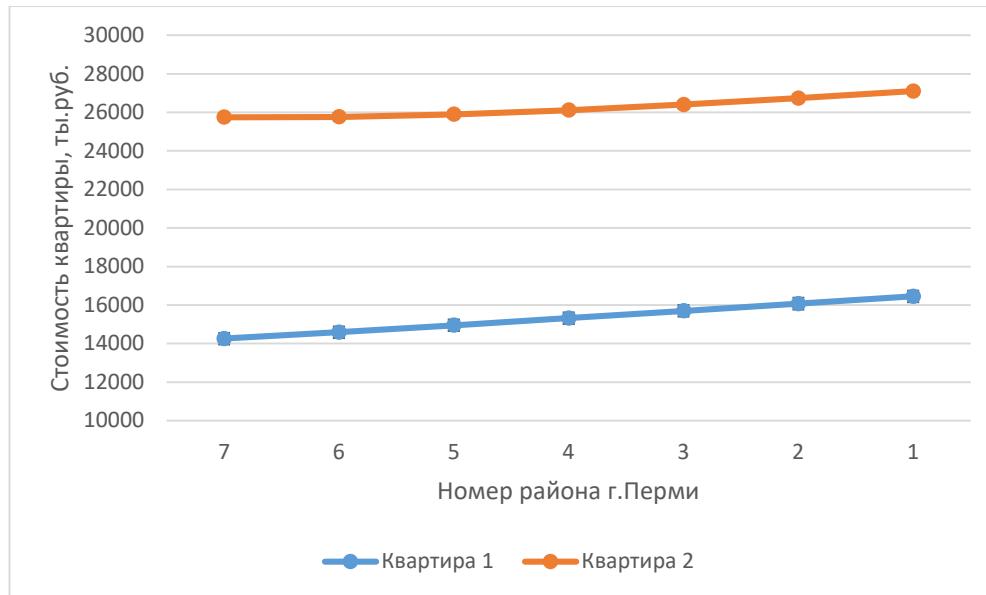


Рисунок 4. Зависимость стоимости квартир Перми от района

Так как район является малозначимым параметром в модели, его изменение мало влияет на стоимость квартиры, в пределах 1 тыс. руб.

Следующий параметр, который мы будем рассматривать, это X3 – Этаж, он является более значимым по сравнению с прошлым, но не является самым значимым. Построим график зависимости стоимости от параметра этаж.

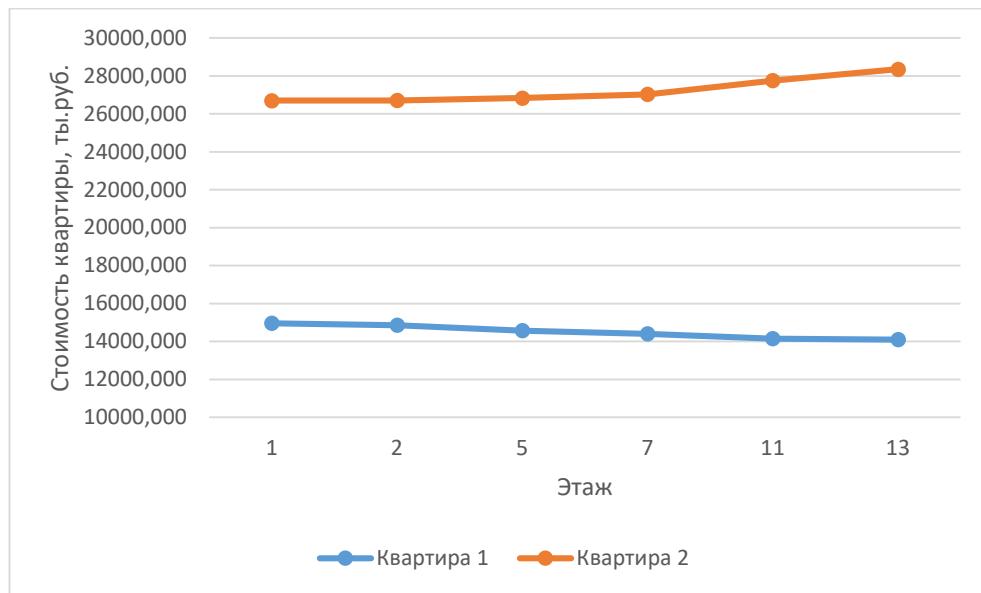


Рисунок 5. Зависимость стоимости квартир Перми от этажа

Значимость этажа для оценки стоимости квартиры выше по сравнению с районом, поэтому изменение этого параметра должно сильнее изменять стоимость квартир, что мы и видим на рис 5. Изменение происходит в пределах 2-3 тыс.руб.

Далее рассмотрим один из самых важных параметров модели: X5 – Площадь. Рассмотрим график зависимости стоимости от площади, рис 6.

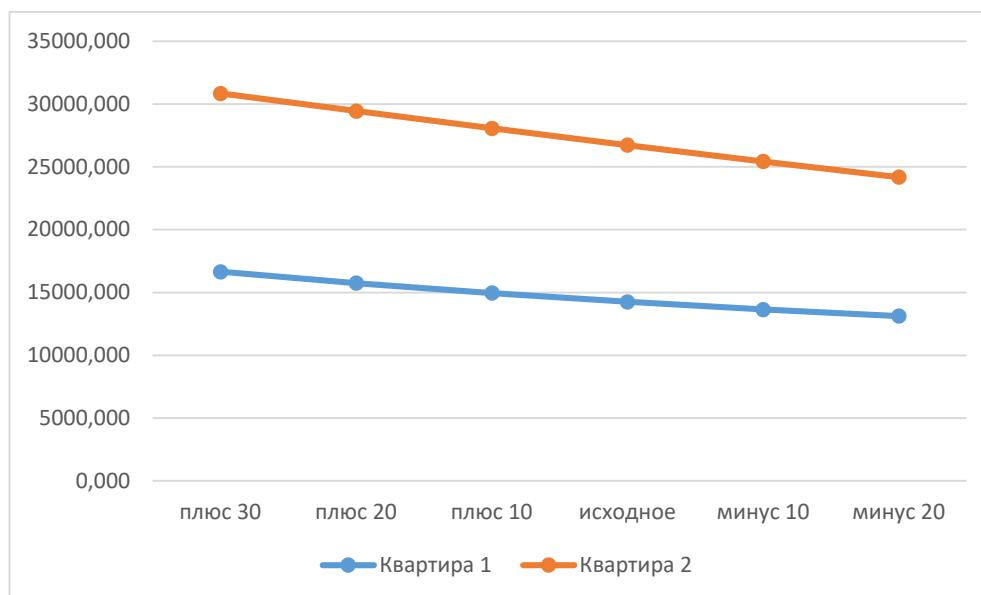


Рисунок 6. Зависимость стоимости квартир Перми от площади

Так как уровень значимости параметра около 10%, изменение изначальной стоимости квартиры должно происходить примерно на сумму 10%, что мы и можем наблюдать.

В качестве результата данной работы была построена прогнозная модель, которые работает адекватно и пригодна для дальнейшего прогнозирования.

Работа выполнена при поддержке РФФИ: Грант №19-010-00307 «Разработка интеллектуальной самоадаптируемой системы массовой оценки и сценарного прогнозирования рыночной стоимости жилой недвижимости регионов РФ».

Библиографический список

1. Арефьева Е.А., Костяев Д.С. Использование нейронных сетей для оценки рыночной стоимости недвижимости // Известия ТулГУ. Технические науки. – 2017. – №10. – С. 177-185.
2. Ясницкий Л.Н., Ясницкий В.Л. Разработка и применение комплексных нейросетевых моделей массовой оценки и прогнозирования стоимости жилых объектов на примере рынков недвижимости Екатеринбурга и Перми // Имущественные отношения в Российской Федерации. 2017. № 3(186). С. 68-84.
3. Yasnitsky L.N., Yasnitsky V.L. Technique of design of integrated economic and mathematical model of mass appraisal of real estate property by the example of Yekaterinburg housing market // Journal of Applied Economic Sciences. 2016. V. 11. No 8. Pp. 1519-1530.
4. Ясницкий Л.Н., Ясницкий В.Л. Методика создания комплексной экономико-математической модели массовой оценки стоимости объектов недвижимости на примере квартирного рынка города Перми // Вестник Пермского университета. Серия Экономика. 2016. № 2 (29). С. 54–69. doi: 10.17072/1994-9960-2016-2-54-69.
5. Yasnitsky, L.N., Yasnitsky V.L., Alekseev A.O. The Complex Neural Network Model for Mass Appraisal and Scenario Forecasting of the Urban Real Estate Market Value That Adapts Itself to Space and Time. Complexity. 2021. Vol. 2021, Article ID 5392170, 17 pages. <https://doi.org/10.1155/2021/5392170>
6. Restate – Сайт недвижимости Перми. [Электронный ресурс]. – URL: <https://perm.restate.ru/> (дата обращения: 05.06.2020)
7. Циан – база недвижимости в Перми. [Электронный ресурс]. – URL: <https://perm.cian.ru/> (дата обращения: 05.06.2020)
8. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 5.0. Свидетельство о государственной регистрации программы для ЭВМ № 2014618208. Заявка Роспатент №2014614649. Зарегистрировано в Реестре программ для ЭВМ 12 августа 2014 г.
9. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.
- 10.Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 5.0 // Свидетельство о государственной регистрации программы для ЭВМ № 2014618208. Заявка

Роспатент № 2014614649. Зарегистрировано в Реестре программ для ЭВМ
12 августа 2014г.

11. Ясницкий Л.Н. Интеллектуальные системы: учебник. – М.: Лаборатория
знаний, 2016. – 221с.

NEURAL NETWORK FORECASTING OF THE COST OF RENTING APARTMENTS IN THE CITY OF PERM

Nikulin Artyom N.

Perm State University

614990, Russia, Perm, street bukireva, 15, nikulin_artem@mail.ru

The article describes the development and application of neural network technologies for predicting the cost of renting apartments in the city of Perm. The system allows you to roughly estimate the cost of renting an apartment by some indicators, such as the number of rooms, floor, area, condition of the apartment, type of house, etc.

Key words: neural network technologies, estimation, forecasting of real estate, cost.

УДК 519.7

СРАВНИТЕЛЬНЫЙ АНАЛИЗ МЕТОДОВ ЭКОНОМИКО-МАТЕМАТИЧЕСКОГО МОДЕЛИРОВАНИЯ МАССОВОЙ ОЦЕНКИ ЖИЛОЙ НЕДВИЖИМОСТИ

Стерник Сергей Геннадьевич

Финансовый университет при Правительстве Российской Федерации
125993, Москва, Ленинградский пр., 49,
sergey-sternik@yandex.ru

*Алексеев Александр Олегович, Алексеева Ирина Евгеньевна,
Ясницкий Виталий Леонидович*

Пермский национальный исследовательский политехнический университет
614990, Пермский край, г. Пермь, Комсомольский проспект, д. 29,
alekseeva@cems.pstu.ru, alekseev@cems.pstu.ru

На конкретном примере выполнено сопоставление возможностей методов разработки моделей оценки объектов недвижимости: методологии дискретно-пространственного параметрического моделирования, методов системно-когнитивного анализа и метода нейросетевого моделирования.

Ключевые слова: Массовая оценка; рыночная стоимость; жилая недвижимость; нейросетевое моделирование; системно-когнитивный анализ; дискретное пространственно-параметрическое моделирование.

Как отмечают авторы работы [1], в новейшей истории рынка недвижимости России до сих пор существует информационная закрытость, и аналитику приходится использовать косвенную и не всегда достоверную информацию, разрабатывать и применять изощренные методики сбора, обработки данных, анализа и прогнозирования. К таким «изощренным» методикам, например, относится нейросетевой алгоритм поиска и устранения выбросов статистической информации [2], применение которого позволило разработать универсальную систему оценки стоимости жилых объектов [3], обладающую свойством самоадаптируемости как к пространству, так и ко времени.

Надо отметить, что в настоящее время наиболее распространёнными подходами для создания систем оценки рыночной стоимости жилой недвижимости являются корреляционно-регрессивный анализ (далее – КРА) и дискретно-пространственно-параметрическое моделирование (далее – ДППМ). Первый подход встречается в многочисленных исследованиях [7, 10] и др. Второй подход развивается преимущественно Г.М. Стерником и С.Г. Стерником [6, 10, 13].

Альтернативным подходом к построению таких систем является упомянутый выше подход, основанный на применении математического аппарата искусственных нейронных сетей (далее – НС) [3], некоторые возможности которых по отношению к другим методам частично исследованы в работах [4, 5, 12]. Так, в работе [12] выполнено сравнение результаты корреляционно-регрессионного моделирования и нейросетевого моделирования рыночной стоимости жилой недвижимости по критериям среднеквадратичного отклонения и коэффициента детерминации. Целью настоящей статьи является попытка сравнить возможности метода нейросетевого моделирования и дискретного пространственно-параметрического моделирования.

К моделям, разработанным с помощью КРА и НС применима терминология «черного ящика» (далее – ЧЯ), на вход которого подаются дискретные и непрерывные параметры моделируемого объекта, а на выходе получается стоимость объекта в качестве непрерывной величины (рис.1, а). Если же в качестве модели ЧЯ используются методы системно-когнитивного анализа [8, 9] (далее – СКА или СК-анализ) и на входе все параметры дискретные, то на выходе получаем стоимость в виде интервальной оценки (рис.1, б), что соответствует методологии ДПММ.

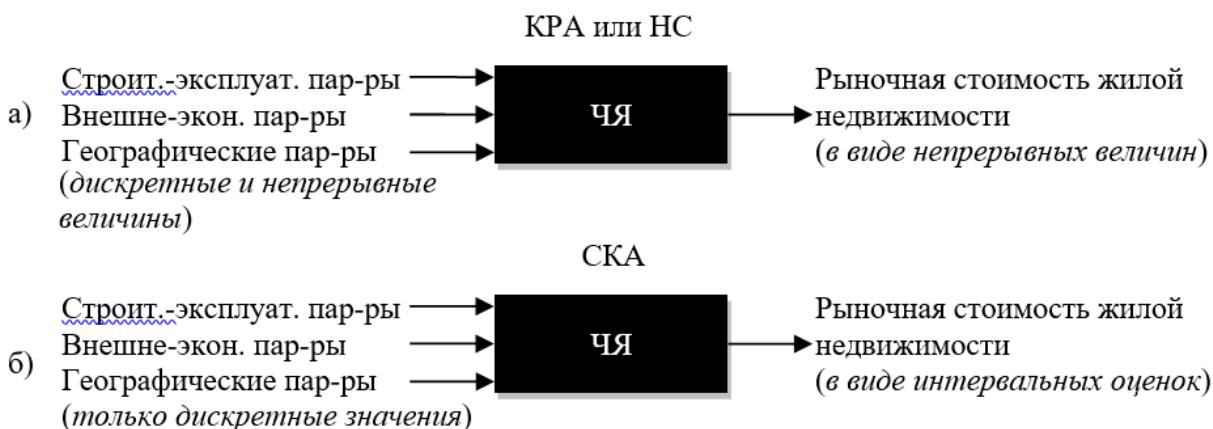


Рисунок 1. Модель черного ящика: при использовании методов КРА или НС – а) СКА – б)

В настоящей работе делается попытка сравнения возможностей ДППМ и НС по критерию достоверности результатов моделирования. В качестве основы для исследования предлагается использовать ту же самую информацию о рынке недвижимости, которая использовалась для обучения нейросети в работе [12]. Под обучающей выборкой в данном случае понимается совокупность объектов предметной области – объекты жилой недвижимости, о которых известны внешние экономические, строительно-эксплуатационные и географические характеристики. Для решения поставленных задач использовалась обучающая выборка по г. Екатеринбургу, состоящей из 2267 объектов жилой недвижимости.

Использование единого информационного базиса позволит сравнить результаты нейросетевого моделирования и результатов, которые будут получены путем синтеза методологии дискретного пространственно-параметрического моделирования с методами системно-когнитивного анализа.

Подготовка исходных данных подразумевает под собой две процедуры:

1. Квантизование количественно-измеримых переменных, то есть перевод их значений из непрерывных шкал в дискретные (рис. 2).

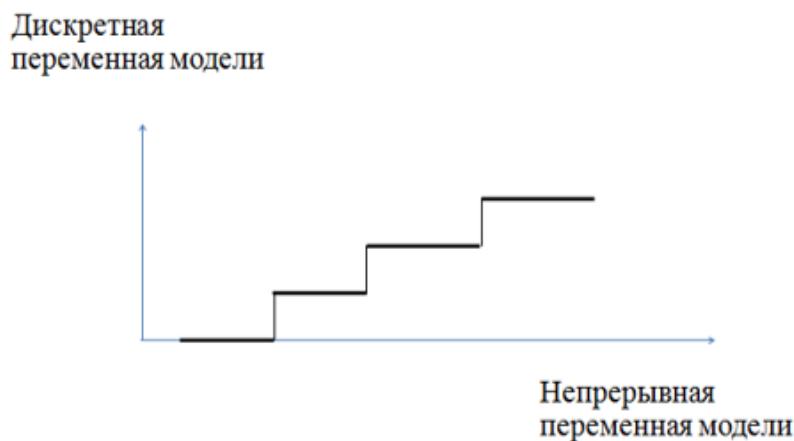


Рисунок 2. Идея дискретного пространственно-параметрического моделирования (ДППМ)

Квантификация может осуществляться двумя способами: разбиением области наблюдения на равные интервалы с разным количеством наблюдаемых признаков (рис. 3, а) и на равные интервалы с разным количеством наблюдаемых признаков (рис. 3, б).

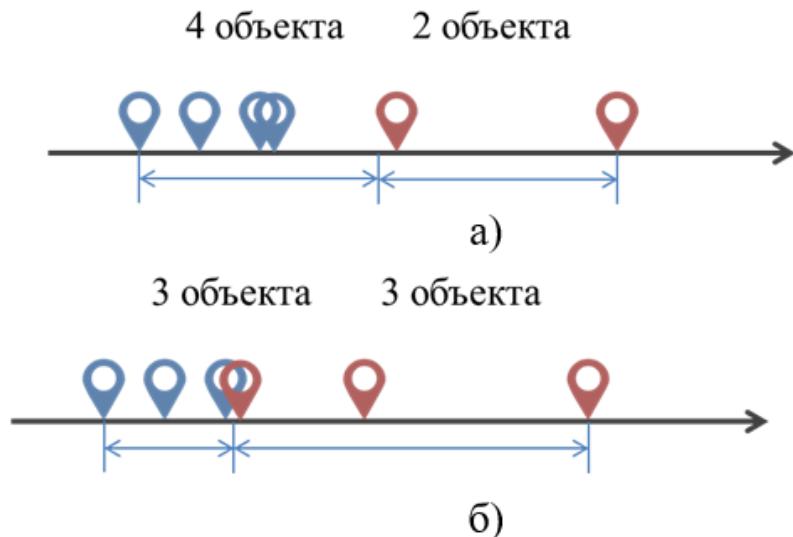


Рисунок 3. Примеры равных – а) и разных – б) интервалов при квантификации количественно-измеримых параметров

2. Кодирование обучающей выборки с помощью справочников классификационных и описательных шкал и градаций.

Выполнив сравнительный анализ, не исключая «экстремальные» необъяснимые объекты из тестового множества, можно заключить, что подход, основанный на синтезе дискретно-пространственного параметрического моделирования и методов системно-когнитивного анализа по критерию достоверности моделирования лучше, чем нейросетевое моделирование. При требуемой точности оценки полной стоимости жилой недвижимости в 430 тысяч рублей, максимальную достоверность обеспечивает модель INF3 при равных интервалах, которая достигает 70%. При этом нейросеть с такой же точностью оценки полной стоимости жилой недвижимости обладает достоверностью лишь в 60%.

Значительно хуже ситуация выглядит при попытках оценки удельной стоимости, то есть стоимости за 1 кв.м. При требуемой точности оценки около 4,5 тысяч рублей, максимальную достоверность обеспечивает та же модель INF3 [8] при равных интервалах, которая достигает 60%, а нейросеть – 35%.

Однако стоит помнить, что при СКА мы учитываем два вида достоверности: достоверность точного прогнозирования и точность правильной не идентификации, значения которых усредняются [8]. Например, при использовании модели INF3 при равных интервалах – достоверность точного прогнозирования составляет 49%, а достоверность правильной не идентификации – 90%, что соответствует тому, что в 90 случаях из 100 модель

не отнесет оцениваемый объект к неправильному интервалу стоимости. Средняя достоверность округлено получается 69%.

Стоит отметить, что НС могла прогнозировать только точно, поэтому достоверности подходов целесообразно сравнивать только по точному прогнозированию. Таким образом, с позиции точного прогнозирования полной стоимости, нейронная сеть оказывается лучше подхода, основанного на синтезе ДПММ и методов СКА, а с позиции удельной стоимости за 1 кв.м. – наоборот, поскольку достоверность нейросети 35%, синтез ДПММ СКА дает 41%.

Анализ зависимости достоверности моделирования (рис. 4) показал, что для определения информационной значимости признаков, обеспечивающих высокую достоверность массовой оценки, не нужна обширная обучающая выборка, что также является существенным преимуществом предложенного подхода, основанного на синтезе ДПММ и СКА.

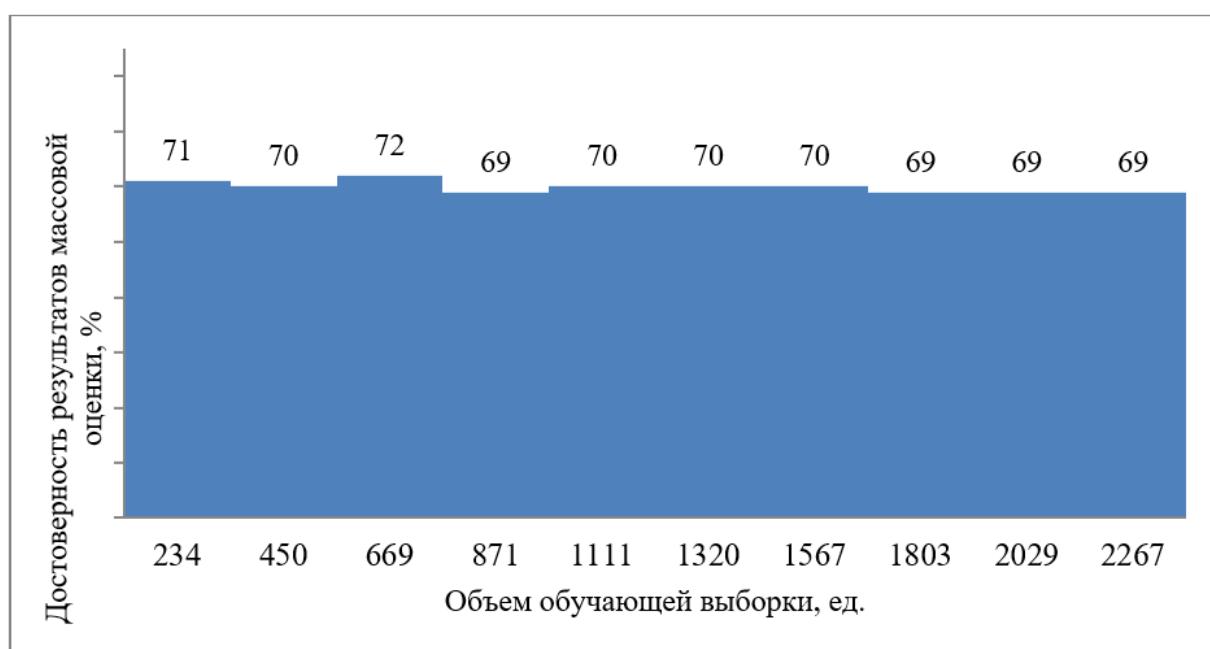


Рисунок 4. Зависимость достоверности массовой оценки от объема обучающей выборки

Преимущество нейросети заключается в том, что при уменьшении требования точности достоверность существенно увеличивается, например, при уменьшении точности до 30% достоверность уже становится 91%. При уменьшении требования по точности моделирования при использовании методологии дискретно-пространственного параметрического моделирования и методов системно-когнитивного анализа, достоверность увеличивается, что является вполне ожидаемым, однако, рост достоверности ограничен. Так, например, максимальная достоверность, которой удалось добиться при СКА, не превышает 80%.

Таким образом, можно заключить, что достоверность и обоснованность полученных результатов обеспечивается реальностью исходных данных при

расчетах, репрезентативностью статистической выборки, использованием методов математической статистики в сочетании с качественным анализом и интерпретацией полученных данных.

Благодарности. Авторы выражают благодарность Щуклиной Юлии Александровне, которая выполнила многочисленную серию вычислительных экспериментов в области массовой оценки с помощью методов системно-когнитивного анализа.

Работа выполнена при поддержке Российского фонда фундаментальных исследований (грант 19-010-00307).

Библиографический список

1. Sternik, S., Gareev, I., & Akhmetgaliev, T. Разработка цифрового сервиса для проведения операций с объектами недвижимости // Недвижимость: экономика, управление, 2021. No 1, с. 25–34.
<https://doi.org/10.22337/2073-8412-2021-1-25-34>
2. Yasnitsky L.N. Algorithm for searching and analyzing abnormal observations of statistical information based on the Arnold – Kolmogorov – Hecht-Nielsen theorem // International Journal of Advanced Trends in Computer Science and Engineering. 2020. 9(2). Pp. 1814-1819. DOI: 10.30534/ijatcse/2020/139922020
<http://www.warse.org/IJATCSE/static/pdf/file/ijatcse139922020.pdf>
3. Yasnitsky, L.N., Yasnitsky V.L., Alekseev A.O. The Complex Neural Network Model for Mass Appraisal and Scenario Forecasting of the Urban Real Estate Market Value That Adapts Itself to Space and Time. Complexity. 2021. Vol. 2021, Article ID 5392170, 17 pages.
<https://doi.org/10.1155/2021/5392170>
4. Алексеев А.О., Харitonов В.А., Ясицкий В.Л. К вопросу об интеллектуальном анализе, массовой оценке и управлению рынком недвижимости регионов России // Прикладная математика и вопросы управления = Applied Mathematics and Control Sciences. 2017. № 1. С. 87-99
5. Алексеев А.О., Харitonов В.А., Ясицкий В.Л. Разработка концепции комплексного нейросетевого моделирования процессов массовой оценки и сценарного прогнозирования рыночной стоимости жилой недвижимости // Известия вузов. Инвестиции. Строительство. Недвижимость. = Proceedings of Universities. Investment. Construction. Real Estate. 2018. Т. 8, № 1. С. 11-22.
6. Анализ рынка недвижимости для профессионалов. / Г.М. Стерник, С.Г. Стерник. – М.: ЗАО «Издательство «Экономика». 2009. – 606 с.
7. Грибовский С.В., Федотова М.А., Стерник Г.М., Житков Д.Б. Экономико-математические модели оценки недвижимости // Финансы и кредит. 2005. № 3 (171). С. 24-43
8. Луценко Е.В. Метризация измерительных шкал различных типов и совместная сопоставимая количественная обработка разнородных факторов в системно-когнитивном анализе и системе «Эйдос» //

- Полitemатический сетевой электронный научный журнал Кубанского государственного аграрного университета (Научный журнал КубГАУ) [Электронный ресурс]. – Краснодар: КубГАУ, 2013. – №08(092). С. 859 – 883. – Режим доступа: <http://ej.kubagro.ru/2013/08/pdf/58.pdf>
9. Луценко Е.В., Коржаков В.Е. Разработка без программирования и применения в адаптивном режиме методик риэлтерской экспресс-оценки по методу аналогий (сравнительных продаж) в системно-когнитивном анализе и интеллектуальной системе «Эйдос». // КубГАУ. 2013. № 94 (10). – С. 1-58.
 10. Стерник С. Г. Развитие оценки недвижимости сравнительным подходом на основе методологии дискретного пространственно-параметрического анализа и моделирования рынка // Аудит и финансовый анализ. 2009. № 5. С 130-137
 11. Щуклина Ю.А. Массовая оценка жилой недвижимости с помощью синтеза методов системно-когнитивного анализа и дискретного пространственно-параметрического моделирования: выпускная квалификационная работа магистра: 08.04.01 / Щуклина Юлия Александровна; Перм. нац. исслед. политехн. ун-т. – Пермь, 2018. – 89 с. [Кафедра «Строительный инжиниринг и материаловедение»].
 12. Ясницкий В.Л. Нейросетевое моделирование процессов массовой оценки и сценарного прогнозирования рыночной стоимости жилой недвижимости: дис. ... канд. экон. наук: 08.00.13 / Ясницкий Виталий Леонидович. – Пермь, 2018. – 159 с. ил.
 13. Стерник С.Г. Методология дискретного пространственно-параметрического моделирования рынков недвижимости // Прикладная математика и вопросы управления. 2020. № 4. С. 155-185.

COMPARATIVE ANALYSIS OF METHODS OF ECONOMIC AND MATHEMATICAL MODELING OF MASS VALUATION OF RESIDENTIAL REAL ESTATE *Sternik Sergey G.*

Financial University under the Government of the Russian Federation
125993, Moscow, Leningradsky pr., 49, e-mail: sergey-sternik@yandex.ru

Alekseev Alexander O., Alekseeva Irina E., Yasnitsky Vitaly L.
Perm National Research Polytechnic University
614990, Perm Territory, Perm, Komsomolsky prospect, 29,
e-mail: alekseeva@cems.pstu.ru

On a specific example, a comparison was made of the capabilities of methods for developing models for evaluating real estate objects: the methodology of discrete-spatial parametric modeling, methods of system-cognitive analysis and the method of neural network modeling.

Key words: Mass appraisal; market price; Residential Properties; neural network modeling; systemic cognitive analysis; discrete spatial-parametric modeling.

ПРОГНОЗИРОВАНИЕ ПАССАЖИРОПОТОКА В ПЕРМИ С УЧЕТОМ ПОГОДНЫХ УСЛОВИЙ И ПАНДЕМИИ

Мельников Роман Дмитриевич

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15, androidman844@gmail.com

В статье представлено описание разработки нейросетевой системы для прогнозирования суточных объёмов пассажирских перевозок в городском транспорте г. Перми. Система позволяет предсказывать приблизительный пассажиропоток с учётом временных и погодных показателей, уровня заболеваемости COVID-19 в регионе и стране. Использование различных параметров позволяет сделать систему адаптируемой к текущей эпидемиологической и метеорологической ситуации.

Ключевые слова: искусственный интеллект, нейросетевые технологии, общественный транспорт, пассажиропоток, автобус, трамвай, прогнозирование, COVID-19.

Введение. Важным вопросом при планировании маршрутной сети любого города является определение необходимого количества общественного транспорта для перевозки пассажиров. Если выпустить большее количество автобусов, чем это требуется – появятся излишние затраты на зарплату, бензин, а слишком малое их число приведёт к ухудшению комфорта пассажиров. Поэтому данный вопрос лучше доверить нейросети, которая, в отличии от человека, сможет учесть все закономерности и дать наиболее точный прогноз потенциального пассажиропотока.

Эффективность использования искусственного интеллекта при прогнозе пассажиропотока на транспорте была обоснована в работах как отечественных, так и зарубежных исследователей [1-4]. В данных работах наборы параметров, используемые для оценки объектов, не учитывают эпидемиологическую обстановку, связанную с недавно появившимся коронавирусом, которая также может оказывать влияние на использование людьми общественного транспорта.

При этом авторы работ [1-4] и других проектов, найденных в сети Интернет, создавали системы, направленные на предсказание числа пассажиров метрополитена, речного и воздушного транспорта. Поэтому данное исследование является уникальным в плане темы исследования и создаваемой системы. Основная цель настоящей работы заключается в сборе информации о погоде, уровне заболеваемости COVID-19 и пассажиропотоке (на автобусах и трамваях) в г. Перми за первые восемь месяцев 2020-го года и обучение нейросетевой модели на этих данных.

В результате анализа литературных источников [1-4], а также предметной области, был выбран следующий набор показателей: X₁ – номер дня недели, X₂ – фактор выходного дня, X₃ – номер месяца, X₄ – температура воздуха днём, X₅ – наличие дневных осадков, X₆ – скорость ветра днём (м/с), X₇ – температура воздуха вечером, X₈ – наличие вечерних осадков, X₉ – скорость ветра вечером (м/с), X₁₀ – количество случаев заболевания COVID-19 в России, X₁₁ – количество случаев заболевания COVID-19 в г. Перми. Выходной параметр D₁ – суммарный пассажиропоток по всем трамвайным и автобусным маршрутам (чел.).

Параметр фактора выходного дня был закодирован: 0 – рабочий день, 1 – выходной, как и наличие дневных или вечерних осадков: 0 – осадков не было, 1 – были. Остальные параметры являются числовыми, поэтому для них кодировка не требуется.

В отличие от работ [1-4], для более точного учёта погодных условий, помимо дневной и вечерней температуры воздуха предлагается использовать информацию о наличии осадков и скорости ветра, тоже в дневное и вечернее время.

Множество, включающее в себя историю погодных условий (температура воздуха, наличие осадков и скорость ветра), заболеваемости коронавирусом в России и в г. Перми, а также пассажиропоток за зиму, весну и лето 2020-го года, было вручную собрано с ресурсов [7-9]. Части множества, связанные с заболеваемостью и пассажиропотоком, уже были представлены в удобном виде. Перед переходом к проектированию и обучению нейросетевой модели, исходное множество было проанализировано на наличие противоречивых примеров, выбросов или дубликатов. Примеров для очистки не нашлось. Данное множество было разделено на обучающее и тестирующее в соотношении семи месяцев к одному.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [5] по методике [6]. В результате оптимизации спроектированная нейронная сеть представляла собой персепtron, который имеет одиннадцать входных нейронов, один выходной и один скрытый слой с десятью нейронами. На рисунке 1 изображен график её обучения.

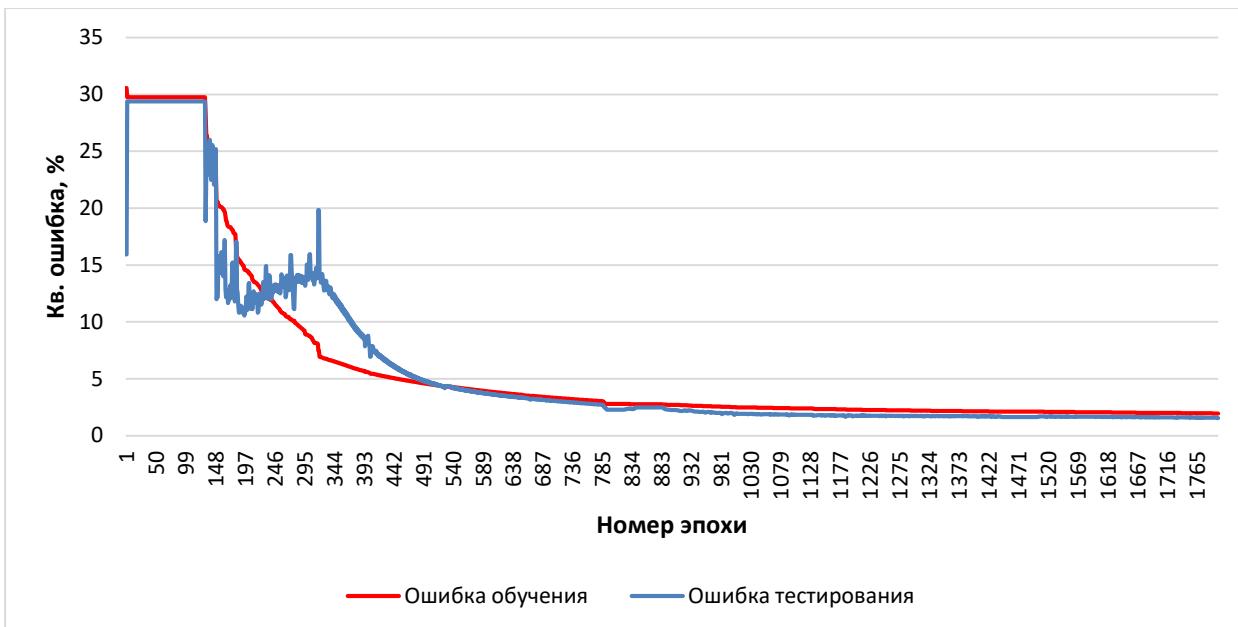


Рисунок 1. График обучения нейронной сети

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 31 примера. Средняя ошибка тестирования составила около 12%, что можно считать приемлемым результатом. На рисунке 2 представлена гистограмма, демонстрирующая разницу между фактическим и прогнозируемой нейросетью пассажиропотоком во все дни из тестирующего множества.

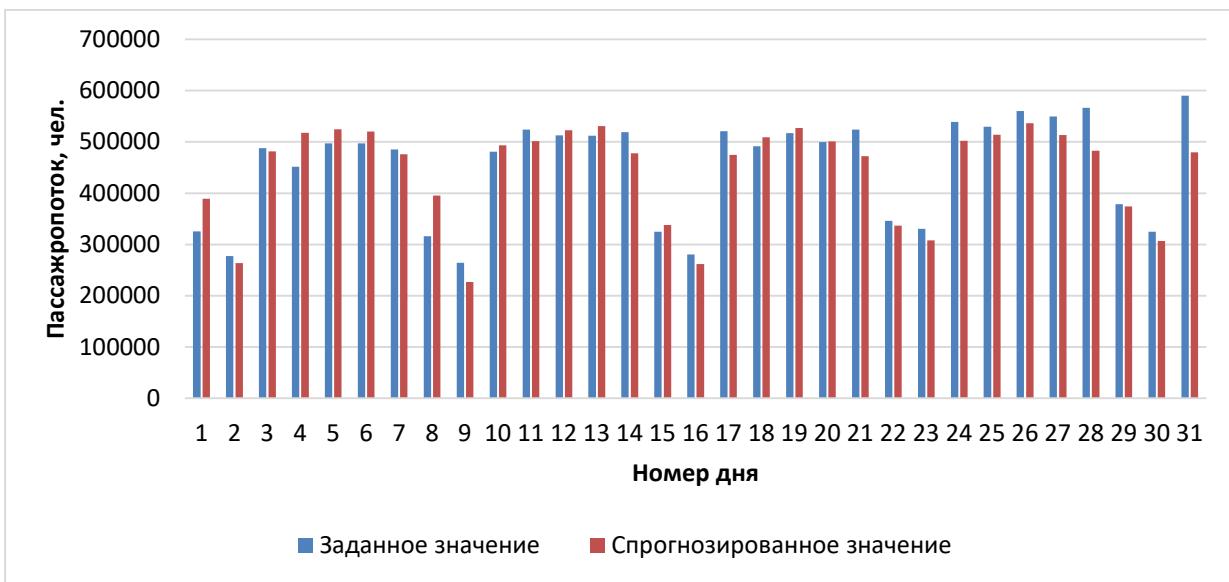


Рисунок 2. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 2, можно сделать вывод об адекватной работе спроектированной нейронной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5», результат отображен на рисунке 3.

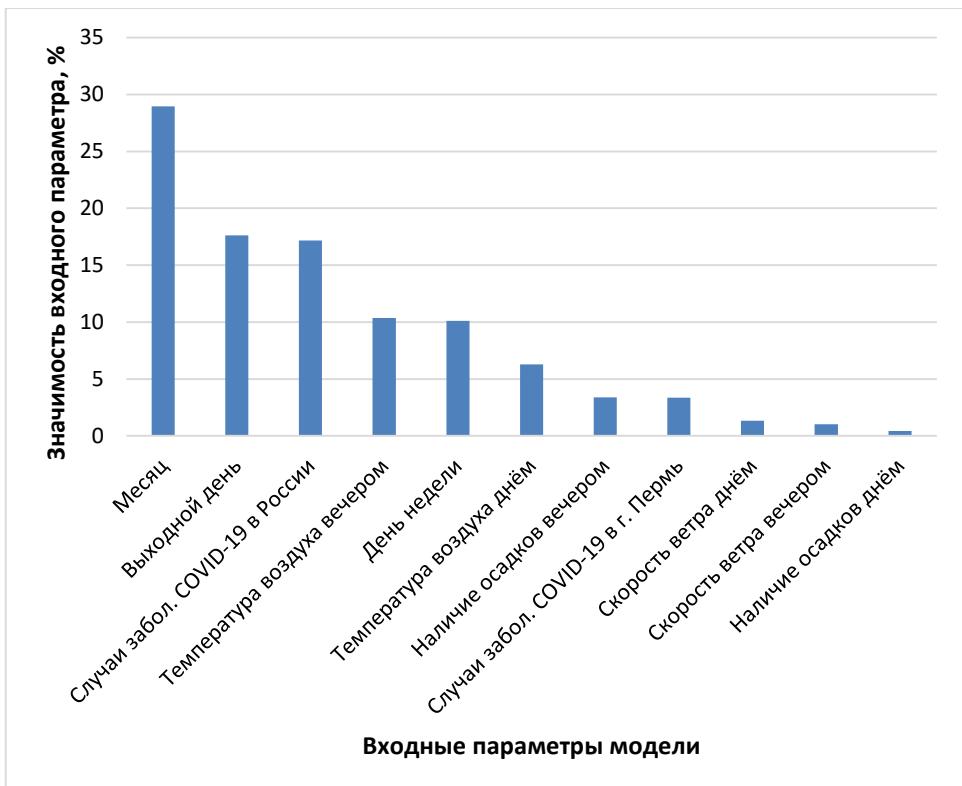


Рисунок 3. Значимость входных параметров нейросетевой модели

Как видно из рисунка 3, наиболее значимыми являются месяц, фактор выходного дня и эпидемиологическая обстановка в России, далее следуют вечерняя температура воздуха, день недели и т.д. Также на графике можно видеть ряд параметров, которые имеют малую значимость, такие как скорость ветра вечером, днём и наличие дневных осадков. Это можно объяснить тем, что скорость ветра не является основным фактором, влияющим на использование общественного транспорта, как и наличие дневных осадков.

Далее было проведено исследование зависимости пассажиропотока общественного транспорта г. Перми от различных факторов. Исследование производилось с помощью метода «замораживания» [6], суть которого заключается в варьировании значения одного параметра и фиксировании значений всех других параметров. Данный метод позволяет выявить влияние исследуемого параметра на выходной. Для этой цели были отобраны 5 дней из разных месяцев, информация о параметрах которых отражена в таблице 1.

Таблица 1
Характеристики дней,
выбранных для исследования

№ дня	1	2	3	4	5
X1	1	2	3	4	5
X2	0	0	0	0	1
X3	1	3	4	6	6
X4	-4	2	11	20	11
X5	1	1	0	0	1
X6	5	3	3	4	4
X7	-3	1	8	20	14
X8	1	0	1	0	0
X9	5	3	3	4	4
X10	0	0	3388	8831	8987
X11	0	0	27	51	72

На рисунке 4 показан график зависимости пассажиропотока от фактора выходного дня. Как следует из графика, фактор выходного дня значительно снижает количество людей в общественном транспорте, в некоторых случаях даже более, чем в 2 раза.

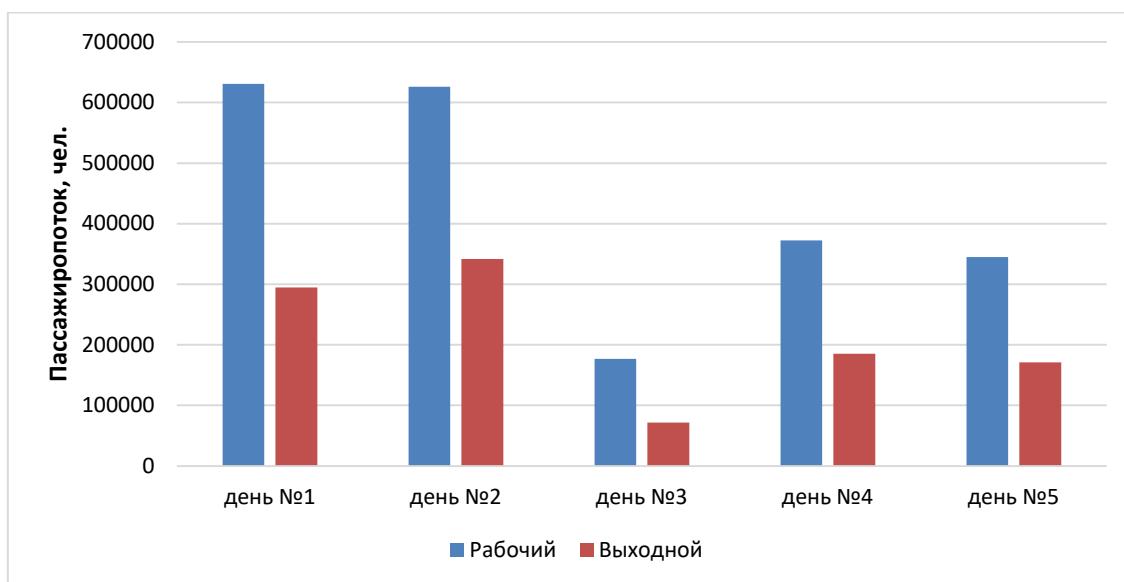


Рисунок 4. Зависимость пассажиропотока от фактора выходного дня

На рисунке 5 продемонстрирована зависимость пассажиропотока от эпидемической ситуации в России. Невооружённым взглядом прослеживается тенденция к уменьшению пассажиропотока при росте заболеваемости коронавирусом. На графике выделяется день №2 по причине резкого снижения пассажиропотока в марте в обучаемом множестве.

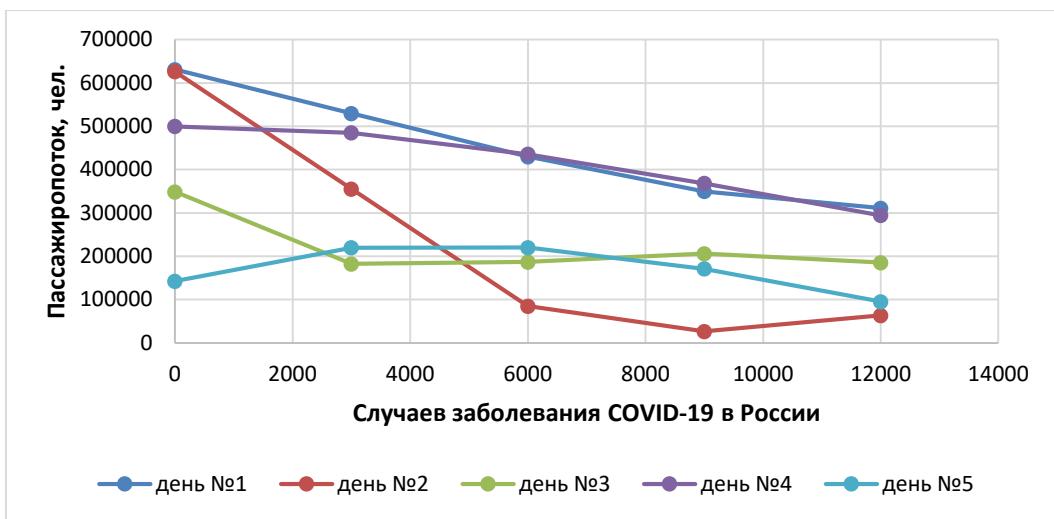


Рисунок 5. Зависимость пассажиропотока общественного транспорта Перми от уровня заболеваемости COVID-19 в России

Далее аналогичным методом было проведено исследование зависимости пассажиропотока от ещё одного важного параметра.

На рисунке 6 изображен график зависимости пассажиропотока от дня недели. В будние дни спрос на общественный транспорт заметно повышается по сравнению с выходными – субботой и воскресеньем, что логично и подтверждается графиком. Для каждого дня месяца оставался неизменным, менялся только день недели.

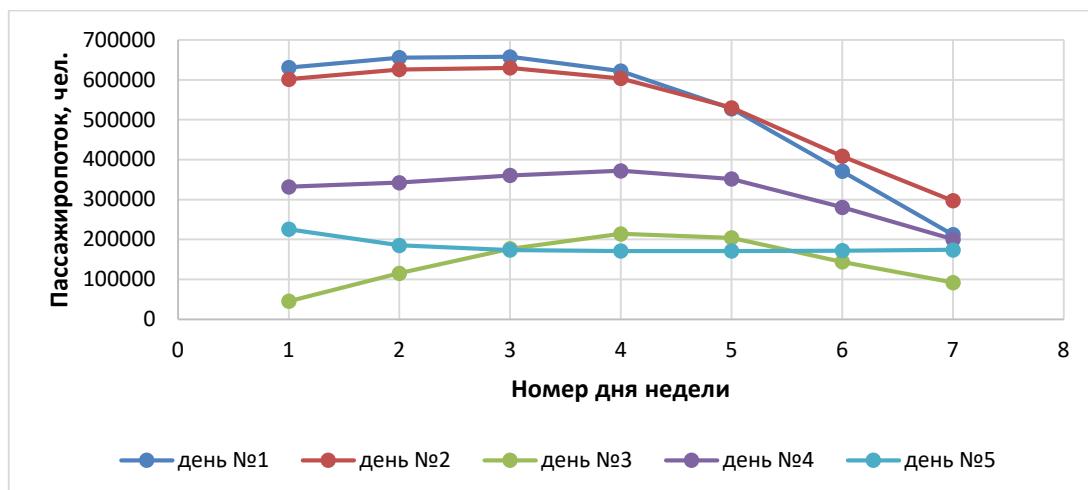


Рисунок 6. Зависимость пассажиропотока от дня недели

Полученные результаты исследований в целом соответствуют действительности, а искажения происходят по причине небольшого временного промежутка, взятого для исследования. При расширении обучающего множества результаты будут только улучшаться, но и в текущем состоянии нейронную сеть можно считать пригодной для прогнозирования пассажиропотока общественного транспорта г. Перми.

Заключение. Построена система нейросетевого предсказания пассажиропотока общественного транспорта для г. Перми. Спроектированная нейросетевая модель учитывает три категории показателей, влияющих на

пассажиропоток: временные, погодные и эпидемические. Проведены исследования погодных условий, заболеваемости и пассажиропотока за первые 8 месяцев 2020-го года в г. Перми. Методом сценарного прогнозирования построены графики зависимостей пассажиропотока от фактора выходного дня, уровня заболеваемости COVID-19 и дня недели. В свободном доступе были найдены данные по пассажиропотоку только за 8 месяцев, использование данных за больший период позволило бы заметно увеличить точность предсказаний и избежать нелогичных результатов.

Библиографический список

1. Иванов В.В., Осетров Е.С.: Прогнозирование суточных объемов пассажирских перевозок в Московском метрополитене // Письма в ЭЧАЯ, том 15, выпуск 1, 2018, с.107-120.
2. Переверзев А.В. Прогнозирование пассажиропотока на круизном морском транспорте с помощью создания искусственных нейронных сетей // ТДР. 2015. №5.
3. T. O. Blinova (2007). Analysis of possibility of using neural network to forecast passenger traffic flows in Russia, Aviation, 11:1, 28-34, DOI: 10.1080/16487788.2007.9635952.
4. Gallo, M., De Luca, G., D'Acierno, L., & Botte, M. (2019). Artificial Neural Networks for Forecasting Passenger Flows on Metro Lines. Sensors (Basel, Switzerland), 19(15), 3424. <https://doi.org/10.3390/s19153424/>
5. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
6. Ясницкий Л.Н. Интеллектуальные системы. – М.: Лаборатория знаний, 2016. – 221 с.
7. <https://www.gismeteo.ru/diary/4476/>
8. <https://denis-galitsky.livejournal.com/>
9. <https://yandex.ru/covid19/stat/>

PASSENGER FLOW FORECASTING IN PERM TAKING INTO ACCOUNT WEATHER CONDITIONS AND PANDEMIC

Melnikov Roman D.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990,
androidman844@gmail.com

The article describes the development of a neural network system for predicting the daily volume of passenger traffic in the city transport of Perm. The system allows predicting the approximate passenger traffic considering time and weather indicators, the incidence rate of COVID-19 in the region and country. The use of various parameters makes the system adaptable to the current epidemiological and meteorological situation.

Keywords: artificial intelligence, neural network technologies, public transport, passenger traffic, bus, tram, forecasting, COVID-19.

ПРИМЕНЕНИЕ САМООРГАНИЗУЮЩИХСЯ КАРТ КОХОНЕНА ДЛЯ АНАЛИЗА БАЗЫ ПАТЕНТОВ

Пастухова Галина Витальевна

Академическая школа информационных технологий при ПГУ, 614003, Россия,
г. Пермь, улица Чернышевского, 28,
pastuhova13@yandex.ru

Рассматривается одна из технологий кластеризации – самоорганизующиеся сети Кохонена, проанализированы узкие места для анализа данных подобными алгоритмами. Затронуты общие проблемы адаптации математических моделей и применимости самих алгоритмов кластеризации.

Ключевые слова: алгоритмы кластеризации, самоорганизующиеся сети Кохонена.

Задача классификации – одна из древнейших задач, суть которой в разбиение множества исследуемых объектов на однородные в некотором смысле группы. Основание для классификации диктуется природой того, что классифицируем, хотя порой необходимо за основание брать такие метрики, для которых существуют объективные способы их измерения.

Также надо четко различать классификацию от типологии, последнее значительно шире. Под типологией понимается метод научного познания, в основе которого расчленение объектов и их группировка с помощью обобщенной, идеализированной модели или типа.

Типология может либо непосредственно основываться на понятии типа как основной логической единице расчленения изучаемой реальности, либо использовать иные логические формы, такие как:

- классификация, цель которой сводится к построению иерархических систем классов и их подклассов на основе некоторых признаков, не свойственных самим объектам (название, число) или присущих им;

- систематика, предполагающая максимально полную и расчлененную классификацию данного множества объектов с фиксированной иерархией единиц описания;

- таксономия, в рамках которой специально исследуются и обосновываются принципы рациональной классификации и систематики [5, С. 563-564].

Один из способов решения задачи автоматической классификации – это технология кластерного анализа, группы однородности в нем называются кластерами. Алгоритмы кластеризации очень похожи на алгоритмы классификации, но есть и принципиальные различия.

Так, например, алгоритмы классификации позволяют отнести в определенный класс каждый объект с заранее известными параметрами, полученными на этапе обучения и каждый объект может принадлежать только одной группе разбиения, что зачастую создает довольно таки жесткую модель, по ряду признаков «оторванную» от реальных объектов, чья сущность двулика, а порой и п-лика.

В кластеризации же разбиваются множества объектов на кластеры, параметры которых заранее неизвестны. В классификации количество классов строго ограничено, а в кластеризации число кластеров может быть как произвольным, так и фиксированным. Таким образом, отличием кластерного анализа от других методов классификации является отсутствие обучающей выборки (классификация без обучения), а его достоинством – возможность производить разбиение объектов не по одному параметру, а по ряду признаков, что формально трактует задачу кластеризации как способ нахождения такого основания классификации, который оптимален и адекватен к измерению исходя из поставленной задачи.

Или иначе: кластерный анализ как таковой является не автоматической задачей, а итеративным процессом обнаружения знаний или интерактивной многоцелевой оптимизацией, которая включает в себя пробные и неудачные попытки.

Общепринятой классификации алгоритмов кластеризации не существует, но выделяют две группы по способу внутренних связей создаваемых кластеров: неиерархические и иерархические. Разница состоит в выдаваемых данных на выход. Алгоритмы иерархии на выходе дают некую иерархию кластеров, с системой как внутренней, так и внешних связей кластеров. Неиерархические – все алгоритмы, которые на выходе иерархию не выдают (или выбор интерпретации происходит не по уровню иерархии).

В свою очередь иерархические методы подразделяются на агломеративные и итеративные дивизимные процедуры.

Агломеративные (соединяющие) процедуры начинают свое выполнение с того, что каждый объект заносят в свой собственный кластер и по мере выполнения объединяют кластеры до тех пор, пока в конце не получается один кластер,

Итеративные дивизимные (разъединяющие) процедуры, напротив, сначала относят все объекты в один кластер и затем разделяют этот кластер до тех пор, пока каждый объект не окажется в своем собственном кластере, исходя из данных ранее условий разбиения, которые могут быть изменены для достижения желаемого качества.

Основными методами иерархического кластерного анализа являются метод ближнего соседа, метод средней и полной связи, а также метод Варда.

Неиерархических методов больше, хотя работают они на одних и тех же принципах. По сути, они представляют собой итеративные методы дробления исходной совокупности. В процессе деления формируются новые кластеры, и так до тех пор, пока не будет выполнено правило остановки. Между собой методы различаются выбором начальной точки, правилом формирования новых

кластеров и правилом остановки. Чаще всего используется алгоритм К-средних, который подразумевает, что аналитик заранее фиксирует количество кластеров в результирующем разбиении [3, С. 927-930].

Необходимо понимать, что кластерных анализ суть многомерный статистический метод и исходные его данные могут быть значительного объема, т.е. существенно большим может быть, как количество объектов исследования (наблюдений), так и признаков, характеризующих эти объекты. Помимо объёмности, эти данные зачастую являются «плохими», то есть природа их разнородности, слабоструктурируемости кроется не в невозможности или возможности разложения на кластеры, а в поиске основания для формирования (или нахождении) кластера или кластеров, ведь не секрет, что кластеризация данных необходима для решения некой задачи, где природа данных порой вторична, а в первую очередь важны способы объективной оценки этих самых данных. Иначе говоря, это разложение кубиков по цвету, при решении задачи классификации по весу при отсутствии весов.

Чаще всего вышеуказанные ошибки (неудачное основание для классификации, и, как следствие, для кластеризации, «жесткая» модель интерпретации данных) типичны при реализации метода кластерного анализа технологиями нейронных сетей, которые решаются ручным подбором как функции активации, выбором меры расстояний, нормализация данных и т.п.

Объекты кластеризации представляются точками в n -мерном пространстве признаков (n – количество признаков, характеризующих объекты) и сходство между объектами определяется через понятие расстояния между точками, так как интуитивно понятно, что чем меньше расстояние между объектами, тем они более схожи.

Реализация кластерного анализа возможна посредством сетей (карт) Кохонена или самоорганизующихся карт признаков (Self-Organizing Maps или SOM), являющихся семейством соревновательных нейронных сетей без учителя, предложенных финским исследователем Теуво Кохоненом в начале 1980-х годов. Сущностно является методом проецирования многомерного пространства в пространство с более низкой размерностью.

Искусственная нейронная сеть Кохонена [9, С. 12-17] представляет собой двухслойную сеть. Каждый нейрон первого (распределительного) слоя соединен со всеми нейронами второго (выходного) слоя, которые расположены в виде двумерной решетки.

Нейроны выходного слоя называются кластерными элементами, их количество определят максимальное количество групп, на которые система может разделить входные данные. Увеличивая количество нейронов второго слоя можно увеличивать детализацию результатов процесса кластеризации.

Для обучения сети Кохонена используется соревновательный метод, где на каждом шаге обучения из исходного набора данных случайно выбирается один вектор. Далее производится поиск нейрона выходного слоя, для которого расстояние между его вектором весов и входным вектором – минимально.

По определённому правилу производится корректировка весов для нейрона-победителя и нейронов из его окрестности, которая задаётся

соответствующей функцией окрестности. Чаще всего в качестве функцией окрестности используется функция Гаусса

$$h(u, c, t) = \exp\left(-\frac{\rho(c, u)}{\sigma(t)}\right)$$

где u – номер нейрона в двумерной решетке второго слоя сети, для которого вычисляем значение h , c – номер нейрона-победителя в двумерной решетке второго слоя сети, t – параметр времени.

Радиус окрестности h должен уменьшаться с увеличением параметра времени:

$$\sigma(t) = \frac{1}{\exp(t^{-2})}.$$

Алгоритм обучения сети Кохонена выглядит следующим образом:

1. Случайными значениями инициализировать матрицу весов малыми (на отрезке $[-1,1]$);
2. Из элементов входного множества построить очередь, разместив их в случайном порядке, пометив всех как необработанные;
3. Первый необработанный элемент x выбрать из очереди;
4. Вычислить расстояние d_j для каждого выхода j между его вектором весов w_j и входным вектором x :

$$d_j := \rho(w_j, x);$$

5. Найти номер выходного нейрона j_m с минимальным расстоянием d_j :

$$j_m := \arg \min_j (d_j);$$

6. Вычислить изменение весов $\Delta W = \{\Delta w_u\}$ для всех нейронов u выходного слоя:

$$\Delta \bar{w}_u := (\bar{w}_u - \bar{x}) \cdot h(u, c, t) \cdot \eta,$$

где c – номер (пара индексов) нейрона победителя j_m в двумерной решетке второго слоя; u – номер (пара индексов) нейрона с вектором весов w_u в двумерной решетке второго слоя; w_u – вектор весовых коэффициентов связи входного слоя и выходного нейрона номер u ; x – текущий вектор входов сети; $h(u, c, t)$ – значение функции окрестности для нейрона номер u в момент времени t ; η – коэффициент скорости обучения;

7. скорректировать матрицу весов

$$W := W - \Delta W;$$

8. пометить элемент входной очереди x как обработанный;
9. если в очереди остаются не обработанные точки, то переход на п.3.
10. если критерий остановки обучения не достигнут, то переход на п.2

11. Конец.

В качестве критериев останова процесса обучения можно использовать следующие:

- Количество полных циклов обучения ограничено константой, например, количество циклов равно количеству элементов во входном множестве.

- Выход сети стабилизируется, т.е. входные вектора не переходят между кластерными элементами.

- Изменения весов становятся незначительными [1, С.13-14]

Для анализа базы патентов (база ФИПС) советского периода метод кластерного анализа посредством карт Кохонена был доработан, а именно, было введено понятие соседства не столько по метрике расстояния, а по ранжированию проекций векторов при уменьшении размерности. Иначе говоря, была доработана функция активации нейронов на базе двойной или двухстадийной нормализации, для последующего применения метода многослойной кластеризации.

Задача, решаемая автором следующая: из формулы изобретения того или иного патента, составляется вектор, где упомянутые физические величины того или иного изобретения «улучшаются» за счет других, базисом такого пространства является расширенная система СИ. Пространство формируется два: по числу вхождений тех или иных физических величин, выраженных через базис, и по степеням вхождения этих физических величин. Таким образом, каждый объект изобретения имеет матрицу принадлежности к тому или иному разделу физики, на основе которых формируется последовательность изменений объектов, принадлежащих одному подпространству и, как следствие, при измерении размерности пространства – эволюционная динамика объекта исследования.

Функция активации нейронов $L(R_u(c))$ на базе к-мерной нормализации – это функция, принимающая вектор из n элементов и возвращающая вектор из n нормализованных элементов как результат:

$L_k(R_u(c)):[c_1, c_2, \dots, c_n] \rightarrow [L_{k-1}(R_u(c_1), L(R_u(c_2), \dots, L(R_u(c_n))]$, где $L_k(R_u(c_i))$ вычисляются по выражениям для линейной нормализации и нормализации по диапазону. Оценка точности результатов, выдаваемых нейронной сетью, по сравнению с известным правильным ответом в ходе обучения выполняется с использованием кросс-энтропии. Получены выражения для определения значений ее частных производных:

$$\frac{\partial E(W)}{\partial W_{ij}} = x_j / (\max_s \{l_s\} - \min_s \{l_s\}) \sum c_z \quad (1)$$

где j – индекс, нумерующий столбец матрицы весов (совпадает с индексом, нумерующим элемент входного сигнала); i – индекс, нумерующий строку матрицы весов; n – число компонент в векторе возвращаемом функциями $L(c)$, $R_u(c)$ и $g(W)$; z – индекс элемента в векторе, который соответствует известному результату, который в обучающем нейронную сеть примере отмечен как верный (ожидаемый) результат; c – аргумент функции линейной нормализации; l – аргумент функции нормализации по диапазону, \min_s и \max_s – минимальное и максимальное значения в s -ной выборке. Анализируя (1) получаем, что значения, которые позволяют корректировать веса сети, отличны от нуля не только для нейрона, соответствующего результату, отмеченному в обучении как верный

результат, что обеспечивает корректировку всех весов в процессе обучения, а не отдельно взятых, как это имеет место при нормализации только по диапазону, что при реализации послойной кластеризации особо эффективно для решаемой задачи.

Библиографический список

- 12.Анисимова Э.С., Самоорганизующиеся карты Кохонена в задачах кластеризации// Актуальные проблемы гуманитарных и естественных наук. – 2014. – № 9. – С.13 -16.
- 13.Гирин Р.В. Двухстадийная нормализация выходных сигналов искусственных нейронных сетей/Р.В. Гирин, С.П. Орлов// Вестник Самарского гос. тех. ун-та. Серия «Технические науки». – 2017. – № 4(56). – С.7-16.
- 14.Кондаков Н.И. Логический словарь-справочник. 2-е испр. и доп. изд. М.: Наука, 1975. 717 с.
- 15.Костенко С.А. ТЕХНОЛОГИЯ ПРИМЕНЕНИЯ МНОГОМЕРНОГО ШКАЛИРОВАНИЯ И КЛАСТЕРНОГО АНАЛИЗА // Фундаментальные исследования. – 2012. – № 11-4. – С. 927-930; URL: <http://www.fundamental-research.ru/ru/article/view?id=30685> (дата обращения: 30.01.2021).
- 16.Кочин Н.Е. Векторное исчисление и начала тензорного исчисления. 9-е изд. М.: Наука, 1965.
- 17.Огурцов А.П., Юдин Б.Г. Типология // БСЭ. 3-е изд. Т. 25. – М.: Сов. энцикл., 1969 – 1978.
- 18.Сагатовский В.Н. Основы систематизации всеобщих категорий. Томск, 1973. 431 с.
- 19.Типология и классификация в социологических исследованиях. М.: Наука, 1982. 295 с.
- 20.Энциклопедия информациологии: учеб. пособие /авт. и сост. И.И. Юзвишин; под ред. А.М. Прохорова. М.: Информациология, 2000.
21. Kohonen T., Self-Organizing Maps Springer, 1995.

APPLICATION OF SELF-ORGANIZING KOHONEN MAPS FOR ANALYSIS OF THE PATENT BASE

Pastukhova GalinaV.

Academic School of Information Technologies at PSU, 614003, Russia, Perm,
Chernyshevsky street, 28,
pastuhova13@yandex.ru

One of the clustering technologies is considered – self-organizing Kohonen networks, bottlenecks for data analysis with similar algorithms are analyzed. The general problems of adaptation of mathematical models and the applicability of the clustering algorithms themselves are touched upon.

Key words: clustering algorithms, self-organizing Kohonen networks.

ПРЕДИКТИВНАЯ АВТОМАТИЧЕСКАЯ СИСТЕМА ДЕТЕКЦИИ ПОВРЕЖДЕНИЙ СТАЛЬНЫХ ТРОСОВ ЛИФТОВ ГРАЖДАНСКОГО НАЗНАЧЕНИЯ НА ОСНОВЕ НЕЙРОННЫХ СЕТЕЙ

Пастухова Галина Витальевна

Академическая школа информационных технологий при ПГУ, 614003, Россия,
г. Пермь, ул/ Чернышевского, 28, pastuhova13@yandex.ru

Зотин Дмитрий Андреевич

Пермский национальный исследовательский политехнический университет,
614990, Россия, г. Пермь, пр. Комсомольский, 29, zotindima@yandex.ru

Патакин Иван Николаевич

Пермский государственный национальный исследовательский университет,
614990, Россия, г. Пермь, ул. Букирева, 15, LobanovIN@ieci.ru

Патакина Анастасия Сергеевна

Пермский государственный национальный исследовательский университет,
614990, Россия, г. Пермь, ул. Букирева, 15, patakina013@gmail.com

Рассматривается задача распознавания (обнаружение или детекция объекта) и классификации повреждений стального троса в лифтах гражданского назначения. Анализируются существующие методы задачи детекции в зависимости от «области интереса», затронуты проблемы методологии и терминологии технологии распознавания. Особый акцент сделан на проблему «бедности» наборов реальных данных. Рассмотрены пути решения вышеуказанной проблемы посредством симуляции физических процессов за счет применения межплатформенной среды Unity, а также возможности авторазметки данных посредством масок в среде Blender.

Ключевые слова: алгоритмы детекции объектов и их классификации, распознавание образов, повреждения стальных тросов, авторазметка, среда Unity, среда Blender.

Важнейшая характеристика живой материи – это ее способность воспринимать информацию и адекватно реагировать на нее, иначе говоря, живые организмы способны распознавать различные образы. Данная способность присуща всем формам жизни и является необходимой для выживания любого организма.

В настоящее время полное представление о способностях живых организмов к распознаванию многих явлений и объектов отсутствуют. В то же время, создавая автоматизированные системы управления, человек высказывает гипотезы, продвигающие его к познанию устройства механизмов распознавания образов в природе, что позволяет успешно создавать распознавающие системы [1].

Фрэнк Розенблattt, вводя понятие «модели мозга», основная задача которой – демонстрация того, как в физической системе, структура и функциональные свойства которой известны, возникают психологические

явления, описал простейшие эксперименты по различению. Данные эксперименты целиком относятся к методам распознавания образов.

Также актуальность данной тематики диктуется некой прикладной однобокостью существующего инструментария. Решение задачи распознавания ввело в обиход большое число некорректных, или, как их обычно называют эвристических алгоритмов.

Дело в том, что подавляющее большинство применений теории распознавания связано с плохо формализованными областями науки и практики, такими, как медицина, геология, социология, химия и т. п. Класс задач, относящихся к неформализуемым и плохо формализуемым знаниям, значительно больше класса задач, для которых знания формализуемы [5]. Для подобных классов трудно строить формальные теории и применять стандартные математические методы. В лучшем случае удается дать математическое оформление некоторым интуитивным принципам и затем применить построенные «эмпирические» формализмы для решения специальных типов проблем. Это обстоятельство определило тот факт, что на первом этапе развития теории и практики распознавания образов возникло большое число различных методов и алгоритмов, применявшихся без какого-либо серьёзного обоснования для решения практических задач. Такие методы, как это принято во всех экспериментальных науках, обосновывались непосредственной проверкой – успехом решения реальных задач.

Многие из них выдержали такую проверку и применяются, несмотря на отсутствие математических обоснований [2].

Первая работа в области распознавания образов в нашей стране была выполнена одним из основоположников современной теории информации – академиком А.А. Харкевичем. В ней рассматриваются так называемые «читающие автоматы», а математическим аппаратом являлась теория статистических решений. Слово «образ» использовалось для обозначения напечатанного или написанного от руки знака, изображающего букву или цифру.

Особо следует отметить работы под руководством академика РАН Журавлева Ю.И. по алгебраической теории алгоритмов распознавания, еще в начале 60-х прошлого столетия им был предложен тестовый алгоритм распознавания – логический метод эффективного решения задач распознавания при малом числе обучающих прецедентов. В дальнейшем на базе этого алгоритма был построен новый класс распознающих процедур – алгоритмы вычисления оценок, а затем введена и исследована алгебраическая теория распознавания.

В этом направлении фундаментальные результаты получили также чл.-корр. РАН Рудаков К.В. (общая теория проблемно-ориентированного алгебраического синтеза корректных алгоритмов), чл.-корр. РАН Матросов В.Л. (статистическое обоснование алгебраического подхода), Рязанов В.В. (оптимизация моделей классификации и коллективные решения задач кластерного анализа), Дюкова Е.В. (асимптотически-оптимальные логические алгоритмы), Сенько О.В. (алгоритмы взвешенного статистического распознавания), Асланян Л.А. (логические алгоритмы распознавания), Донской

В.И. (решающие деревья) и многие другие исследователи России, СНГ и дальнего зарубежья [2].

Ситуация на данный момент при решении задач распознавания такова, что при наличие фундаментальной научной базы, на первый фланг при решении практических задач попали уже реализованные на том или ином языке программирования конкретные алгоритмы для распознавания определенного объекта на изображении, порой не позволяющие перенос на иной класс объектов. Также терминологическая база подобных алгоритмов, инструментов, методик и прочего требует некой «генеральной уборки».

В данной работе приведена методика детекции повреждений стальных канатов лифтов гражданского назначения, создан алгоритм нахождения объекта на изображении и классификация найденных объектов.

Лифты относятся к техническим объектам повышенной опасности, одной из основных элементов конструкции которых является канатно-блочная система. Безопасность эксплуатации лифтов во многом определяется техническим состоянием канатов, хотя чаще применяется термин «трос». Стальные тросы в лифтах используются в качестве тяговых и уравновешивающих элементов, а также для приведения в действие ограничителя скорости лифта.

Выбор стальных тросов систем лифтовых установок, контроль и выбраковка производятся в соответствии с требованиями ряда нормативных документов. Необходимость контроля технического состояния тросов обусловлена результатами многочисленных их испытаний, проведенных как в лабораторных, так и в производственных условиях. Из более 8000 подвергшихся замене канатов около 10 % имели потерю прочности более 15 %, примерно 2 % канатов потеряли более 30 % номинальной прочности. С другой стороны, более 70 % снятых с эксплуатации канатов имели незначительные дефекты, и их можно было еще использовать [3].

Правилами безопасности определены критерии и нормы браковки канатов из-за поверхностного и внутреннего абразивного износа, коррозии, количества обрывов наружных и внутренних проволок на длине шага свивки каната. Помимо количественных критериев браковки канатов следует учитывать и качественные: деформации разных типов, повреждения в результате температурного воздействия или электрического дугового разряда. Так, основной причиной обрыва тяговых канатов и каната ограничителя скорости лифта Останкинской башни во время пожара 27 августа 2000 года было воздействие высокой температуры [4].

Конструкция троса включает следующие компоненты: сердечник,

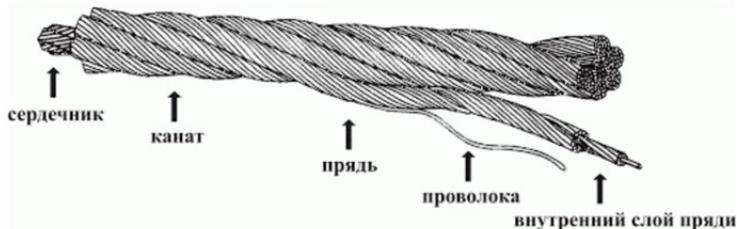


Рисунок 1. Устройство стального троса

прядь, проволока, центральная проволока, что представлено на рисунке 1. Чаще всего каждая отдельная проволока расположена вокруг центральной проволоки, образуя жилу проволоки.

Пряди формируются вокруг центрального сердечника, образуя трос. В зависимости от количества прядей определяют толщину тросов, их достаточно много, но существует предельное количество нитей – 25. Размер и количество проволок в каждой пряди, а также размер и количество прядей в канате сильно влияют на характеристики каната.

Широкое распространение в лифтовых механизмах нашли стальные тросы, изготовленные по:

- ГОСТ 2688-80 с линейным касанием проволок. В изделии использован органический сердечник, придающий ему гибкость, прочность на излом. Также приобретению этих свойств способствует различная толщина проволок во внешнем слое прядей;

- ГОСТ 3077-80 – изделие с двойным плетением и линейным касанием проволок. При достаточном диаметре активно используется в сборке и ремонте лифтов, подъемников, подвесных люлек. Отличается хорошей гибкостью, износостойкостью, возможностью работы в агрессивной среде;

- ГОСТ 7665-80 также имеет двойную свивку и органический сердечник. Высокая гибкость и прочность делают изделие пригодным для лифтов при условии отсутствия агрессивной среды.

К сожалению, не существует классификации повреждений стальных тросов, а основным документом является РД РОСЭК 012-97 «Канаты стальные, контроль и нормы выбраковки», где описываются повреждения и способы их детекции.

Была разработана следующая классификация повреждений:

- коррозийные изменения;
- нарушение внешней геометрии (внешнего контура) троса;
- нарушение внутренней геометрии (внутреннего контура или свивки) троса.

Повреждения коррозийного типа с точки зрения детекции фотограмметрическими методами посредством анализа изображения – это в первую очередь изменения цвета троса и площадь этого изменения. В зависимости от типа камеры, возможна детекция как начальной стадии коррозии с малой площадью поражения (пятно ограничено одним шагом свивки), так и значительные, как на рисунке 2.



Рисунок 2. Значительные коррозийные изменения

Под нарушение внешней геометрии понимается сразу несколько видов повреждений:

- обрыв проволок внешней свивки;
- петлеобразный выход проволок свивки в одной или нескольких прядях;
- двусторонне уменьшение или увеличение диаметра троса;
- одностороннее уменьшение или увеличения диаметра троса;
- волнистость троса;
- залом (перегиб) троса;
- выдавливание пряди внешней свивки;
- выдавливание сердечника;
- перекручивание троса.

Все вышеуказанные повреждения детектируются за счет подсчета площади эталона проекции троса (эталоны введены двух типов: малый эталон, содержащий 5 шагов свивки и большой – 8 шагов) и процентного отклонения от эталонов. На рисунке 3 представлено повреждение – выдавливание пряди внешней свивки.



Рисунок 3. Повреждение троса типа «выдавливание прядей внешней свивки»

Под нарушением внутренней геометрии троса имеется ввиду следующие виды повреждений:

- неравномерный зазор между прядями;
- перекрут пряди;
- разрыв пряди;
- отсутствие пряди;
- выдавливание проволоки из пряди;
- выдавливание прядей сердечника;
- разрыв проволоки (эффект «Бурунда»);

- выдавливание прядей внешней свивки.

Стоит отметить, что ряд повреждений может относится в двум типам повреждений в зависимости от факта фиксации изображения – если обрыв проволоки на изображении не нарушает внешние границы изображения (проекция троса на данном снимке), то повреждение относится в внутренним повреждениям, если же обрыв или иное повреждения зафиксированное на границе изображения – то внешнее. Внутренние повреждения фиксируются за счет формирования эталона проекции свивки троса, отклонения от площадей и «направляющих» эталона.

Также необходимо отметить, что автоматизация процесса детекции позволит анализировать и причины появление тех или иных повреждений. Например, такое повреждение как петлеобразный множественный выход прядей говорит о повреждении сердечника, что, в свою очередь, дает понимание о причинах повреждения, а именно о несоразмерной нагрузке на трос, что является нарушение либо условий эксплуатации или неверно подобранным оборудованием. Подобный функционал при достаточном наборе данных позволит говорить об аналитике повреждений, что в свою очередь влечет предиктивности создаваемой системы.

Данные в задаче представлены классическим для технологии машинного зрения образом – в виде цветных RGB снимков. На каждом снимки может как присутствовать сразу несколько дефектов, так и не присутствовать вовсе.

Задача распознавания образов на изображения логически подразделяется на две подзадачи:

- нахождение и выделение «области интереса» (некое контурирование области на изображении, форма и способ которого зависит от объекта, алгоритма и пр.);
- классификация объекта в «области интереса».

В зависимости от формы области интереса, дальнейшая детекция возможна в виде: ограничивающих прямоугольников, многоугольников, битовых масок, в виде точек интереса и пр. Существенно важны: топология области интереса (ее форма, площадные зависимости и пр.) и/или особенности координатных зависимостей «особых» точек. Порой сложно разделить шаги выделения «области интереса» и детекцию объекта внутри нее, ибо порой однозначно определяет второе.

В нашей задаче были выбраны ограничивающие прямоугольники, но эксперименты с многоугольными областями также проводились.

Помимо формы предсказания, необходимо было определить формат датасета (способ организации данных и аннотаций), остановились на MS COCO и YOLO.

Особо интересные результаты были получены при обнаружении проблемы «бедности» датасетов, а именно – поймать некоторые повреждения троса в режиме реального времени в данной шахте лифта гражданского назначения невозможно – их там попросту нет. Данные пришлось синтезировать следующим образом:

- средствами полигонального моделирования были воссозданы сцены и объекты в среде Blender, с использованием скриптов на языке Python, исключение составила лишь программа преобразования растровой разметки в формат Yolo, написанная на языке Rust.

- модели конвертировались в среду Unity, где была реализована физика ряда повреждений (коррозия, истончение и пр.).

Подобный подход позволяет говорить об авторазметке данных за счет масок некоторых участков синтезируемых объектов.

Библиографический список

1. Абрамов В. И., Метод опорных точек для обучения распознаванию образов в произвольных метрических пространствах: дис. канд. физ. – мат. наук: 05.13.17, 2014. – 84 с.
2. Журавлев Ю.И., Рязанов В.В., Сенько О.В. Распознавание. Математические методы. Программная система. Практические применения. М.: Фазис, 2005. – 159 с.
3. Дворник А.П., Дацуко Н.А., Микула С. Исследование несущей способности шахтных канатов и разработка методики расчета их предельного состояния // Горная механика. 1998. № 1. С. 3-7.
4. Цуканов В.В, Шпаков И.И. Дефектоскопия канатов – гарант безопасности эксплуатации лифтов // Лифт. 2006. №10. С. 2-4.
5. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.

PREVENTIVE AUTOMATIC DETECTION SYSTEM DAMAGES OF STEEL CABLES OF CIVIL PURPOSE ELEVATORS BASED ON NEURAL NETWORKS

Pastukhova Galina V.

Academic School of Information Technologies at PSU, 614003, Russia, Perm, Str. Chernyshevsky, 28, pastuhova13@yandex.ru

Zotin Dmitry Andreevich

Perm National Research Polytechnic University, 614990, Russia, Perm,
Komsomolsky Ave., 29, zotindima@yandex.ru

Patakin Ivan Nikolaevich

Perm State National Research University, 614990, Russia, Perm, st. Bukireva, 15,
LobanovIN@ieci.ru

Patakina Anastasia Sergeevna

Perm State National Research University, 614990, Russia, Perm, st. Bukireva, 15,
patakina013@gmail.com

The problem of recognition (detection or detection of an object) and classification of damage to a steel cable in civil elevators is considered. The existing methods of the detection problem are analyzed depending on the "area of interest", the problems of methodology and terminology of the recognition technology are touched upon. Particular emphasis is placed on the problem of "poverty" of real data sets. The ways

of solving the above problem by means of simulation of physical processes through the use of the cross-platform Unity environment, as well as the possibility of auto-tagging data using masks in the Blender environment are considered.

Keywords: algorithms for detecting objects and their classification, pattern recognition, damage to steel cables, auto-tagging, Unity environment, Blender environment.

УДК 004.032.26

НЕЙРОННАЯ СЕТЬ ДЛЯ ОПРЕДЕЛЕНИЯ ВЛИЯНИЯ ВНЕШНИХ ФАКТОРОВ НА СТОИМОСТЬ КВАДРАТНОГО МЕТРА ЖИЛОЙ ПЛОЩАДИ

Смольяков Михаил Денисович

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
smolyakovmikhail@psu.ru

В статье представлено описание разработки нейронной сети для определения влияющих на среднюю стоимость квадратного метра недвижимости в пределах одного города факторов. Система позволяет увидеть зависимость между внешними факторами городской среды и стоимостью жилья. При разработке сети были учтены географические, экономические и социальные параметры.

Ключевые слова: искусственный интеллект, нейронные сети, недвижимость.

Введение. Практически каждый человек однажды задумывается о смене места жительства: это может быть покупка новой квартиры, переезд в другой город или страну. В любом из этих случаев, как правило, требуется провести анализ рынка недвижимости и с его помощью сделать выводы о благоприятности целого региона, города или отдельного района. Так, цены на недвижимость в неблагополучных районах всегда ниже средней цены по городу, а цены домов в столицах цифровых технологий могут значительно превышать средние по стране. Так как цена недвижимости формируется из спроса и предложения, можно утверждать, что чем выше средняя стоимость квадратного метра жилья в городе, тем выше уровень жизни этого города. Целью данной работы является определение основных факторов, влияющих на стоимость городской недвижимости.

Методика моделирования. В нашем проекте мы опираемся на успешный опыт применения метода нейросетевого моделирования для исследования рынков городской недвижимости, изложенный в статьях [1-4]. Наша модель нейронной сети имеет 8 входных и 1 выходной параметр, представленные в

Таблице 1. Параметры были выбраны с помощью экспертной оценки, затрагивая как можно больше сфер жизни города.

Таблица 1
Описание входных и выходных параметров

X1	Возраст города
X2	Плотность населения города
X3	Есть ли прямые выборы главы города
X4	Является ли город столицей региона или страны
X5	Крупные водоёмы в черте города
X6	Среднегодовая температура
X7	Развитость общественного транспорта
X8	Наличие в черте города аквапарка
Y1	Средняя стоимость квадратного метра жилья

Пояснения к выбранным параметрам:

- возраст города – параметр, который учитывает историческую ценность при определении цены;
- плотность населения – следствие ведения социальной политики в городе;
- наличие прямых выборов главы города – возможность для жителей выбрать вектор развития города;
- знание является ли город столицей необходимо, чтобы учесть пополнение бюджета налогами, поступающими из региона или из всей страны, является экономическим и политическим показателем.
- крупные водоёмы – возможные торговые пути, которые пополняют бюджет города и объединяют в себе географические и экономические показатели;
- среднегодовая температура – географический показатель.
- развитость общественного транспорта используется как градостроительный показатель, так как он является индикатором качества жизни [5];
- наличие в черте города хотя бы одного аквапарка может свидетельствовать об общем уровне доходов населения города, так как строительство аквапарка в городе с бедным населением не окупится.

В таблице 2 указаны различные значения, принимаемые входными параметрами. Выходной параметр – непосредственно стоимость квадратного метра жилья в рублях.

Таблица 2
Значения входных
параметров

X1	Целое число
X2	Десятичное число
X3	1 или 0
X4	От 0 до 2
X5	От 0 до 3
X6	Десятичное число
X7	От 0 до 7
X8	1 или 0

Входные данные

взяты из открытых

источников. Компания SRG с 2012 года собирает данные по рынку недвижимости в России на основе Big Data и технологий машинного обучения. Методика расчёта средней стоимости жилья основана на медианном методе расчёта, что позволяет исключить резкие отклонения цены, в выборке остаются только репрезентативные значения для группы [6].

Для создания самой нейронной сети было использовано программное обеспечение «Нейросимулятор 5-10s» [7]. Для нахождения необходимого числа нейронов воспользуемся следствием из теоремы Арнольда-Колмогорова (формула 1) [8], чтобы найти оптимальное количество нейронов на скрытом слое.

$$\frac{Ny \cdot Q}{\log_2 Q + 1} \leq Nw \leq Ny \cdot \left(\frac{Q}{Nx} + 1 \right) (Nx + Ny + 1) + Ny \quad (1)$$

В формуле: Ny – количество выходных нейронов, Nx – количество входных нейронов, Q – количество примеров в обучающем множестве, Nw – необходимое число синоптических связей. Полученная оценка: $7 \leq Nw \leq 66$. Найдем оценку для количества входных нейронов – N: $1 \leq N \leq 10$. Самым оптимальным количеством нейронов оказалось $N = 3$.

Функциями активации выступал тангенс гиперболический.

Структура нейронной сети представлена на Рисунке 1.

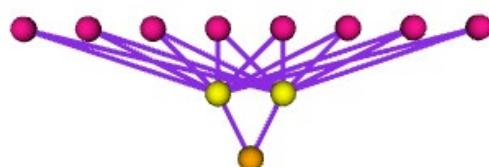


Рисунок 1. Структура нейронной сети

Обучение сети. При попытке обучить сеть с полученными входными данными, ошибка обучения была более 50%. Чтобы увеличить точность прогнозирования, избавимся от аномальных данных, обладающих максимальной ошибкой обучения на созданной согласно методике [9] вспомогательной нейронной сети.

Обучим нейронную сеть несколько раз и посмотрим в каких городах сохранится максимальная ошибка при прогнозировании. Результаты вычислений представлены на Рисунке 2, где каждому городу соответствует три ошибки обучения в трёх разных исследованиях.

Согласно полученным данным можно сделать вывод, что самыми аномальными городами оказались Тюмень, Уфа и Хабаровск, поэтому удалим сведения о них из обучающего множества, чтобы повысить точность. Аномалия, по-видимому, возникает из-за особого экономического положения в регионах, связанного с добычей полезных ископаемых.



Рисунок 2. Ошибка обучения сетей

Проверка адекватности. После обучения нейронной сети на обучающем множестве, проведём проверку адекватности, чтобы убедиться, что нейронная сеть правильно установила зависимость параметров.

По результатам проверки можно утверждать, что нейронная сеть научилась правильно устанавливать зависимости между входными и выходным параметрами. Результат проверки адекватности представлен на Рисунке 3.

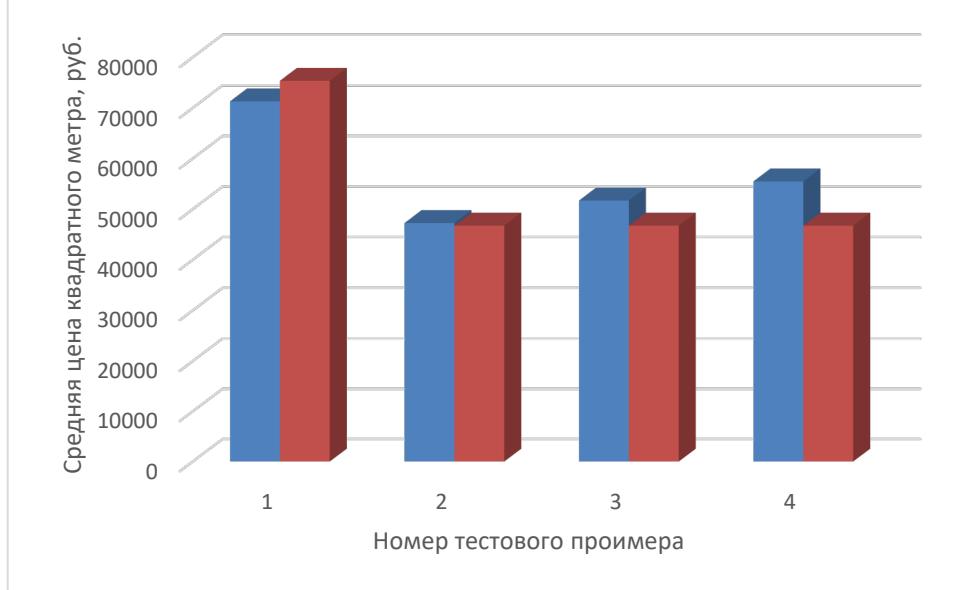


Рисунок 3. Сопоставление реальных данных со прогнозами нейросети на тестовых примерах

Анализ влияния входных параметров. Необходимо выяснить значимость входных параметров: степень влияния на результат моделирования. Объективную оценку такого влияния можно получить с помощью нейронной сети путём поочерёдного исключения входных параметров и наблюдения за погрешностью её тестирования [8]. Чем выше оказывается погрешность тестирования, тем значимее соответствующий изменённый параметр. На Рисунке 4 приведена гистограмма, построенная по полученным таким образом данным. Высота столбцов соответствует погрешности тестирования, полученной при исключённом входном параметре, подписанном под столбцом, поэтому её можно интерпретировать как значимость этого параметра.

Самыми значимыми параметрами оказались возраст города, наличие крупного водоёма рядом с городом и, с большим отрывом, развитость общественного транспорта.

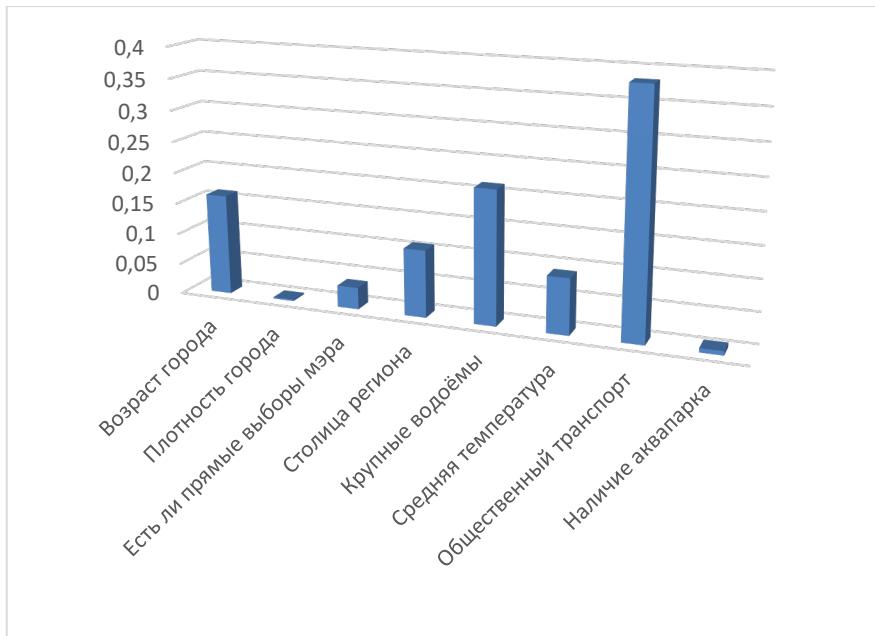


Рисунок 4. Значимость входных параметров

Заключение. Проведя исследование удалось выяснить, что в современном мире на стоимость недвижимости большее значение оказывают урбанистические и историко-географические параметры. По закону спроса и предложения можно сделать вывод, что люди больше всего хотят покупать недвижимость в комфортных для жизни городах, на втором месте стоят туристические города, близкие к морю и на третьем месте города с исторической ценностью.

Целью будущих исследований станет усовершенствование нейронной сети, чтобы учесть экономические и социальные факторы.

Работа выполнена при поддержке РФФИ: Грант №19-010-00307 «Разработка интеллектуальной самоадаптируемой системы массовой оценки и сценарного прогнозирования рыночной стоимости жилой недвижимости регионов РФ».

Библиографический список

1. Ясницкий Л.Н., Ясницкий В.Л. Разработка и применение комплексных нейросетевых моделей массовой оценки и прогнозирования стоимости жилых объектов на примере рынков недвижимости Екатеринбурга и Перми // Имущественные отношения в Российской Федерации. 2017. № 3(186). С. 68-84.
2. Yasnitsky L.N., Yasnitsky V.L. Technique of design of integrated economic and mathematical model of mass appraisal of real estate property by the example of Yekaterinburg housing market // Journal of Applied Economic Sciences. 2016. V. 11. No 8. Pp. 1519-1530.
3. Ясницкий Л.Н., Ясницкий В.Л. Методика создания комплексной экономико-математической модели массовой оценки стоимости объектов недвижимости на примере квартирного рынка города Перми // Вестник

- Пермского университета. Серия Экономика. 2016. № 2 (29). С. 54–69. doi: 10.17072/1994-9960-2016-2-54-69.
4. Yasnitsky, L.N., Yasnitsky V.L., Alekseev A.O. The Complex Neural Network Model for Mass Appraisal and Scenario Forecasting of the Urban Real Estate Market Value That Adapts Itself to Space and Time. Complexity. 2021. Vol. 2021, Article ID 5392170, 17 pages. <https://doi.org/10.1155/2021/5392170>
 5. Ликсутов М. Транспорт как индикатор качества жизни // URL: https://transport.mos.ru/common/upload/docs/MosTrans_5_A_forPDF_NoAnim.pdf (дата обращения 14.03.2021)
 6. Rbc.ru: сайт – URL: <https://realty.rbc.ru/news/6020dc499a7947dd175532a0> (дата обращения: 14.03.2021).
 7. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 5.0 // Свидетельство о государственной регистрации программы для ЭВМ № 2014618208. Заявка Роспатент № 2014614649. Зарегистрировано в Реестре программ для ЭВМ 12 августа 2014г.
 8. Ясницкий Л.Н. Интеллектуальные системы: учебник. – М.: Лаборатория знаний, 2016. – 221с.
 9. Yasnitsky L.N. Algorithm for searching and analyzing abnormal observations of statistical information based on the Arnold – Kolmogorov – Hecht-Nielsen theorem // International Journal of Advanced Trends in Computer Science and Engineering. 2020. 9(2). Pp. 1814-1819.
DOI: 10.30534/ijatcse/2020/139922020
<http://www.warse.org/IJATCSE/static/pdf/file/ijatcse139922020.pdf>

NEURAL NETWORK FOR DETERMINING THE INFLUENCE OF EXTERNAL FACTORS ON THE COST OF A SQUARE METER OF HOUSING

Smolyakov Mikhail D.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990,

smolyakovmikhail@psu.ru

The article describes the development of a neural network to determine the factors influencing the average cost per square meter of real estate within one city. The system allows you to see the relationship between external factors of the urban environment and the cost of housing. When developing the network, geographical, economic and social parameters were taken into account.

Keywords: artificial intelligence, neural networks, real estate.

ПРИМЕНЕНИЕ НЕЙРОСЕТЕВОГО МОДЕЛИРОВАНИЯ ПРИ ВЕРОЯТНОСТИ БАНКРОТСТВ ДЛЯ УПРАВЛЕНИЯ КРЕДИТНЫМИ РИСКАМИ

Бирюков Александр Николаевич

Стерлитамакский филиал «Башкирский государственный университет»
453103, Республика Башкортостан, г. Стерлитамак, проспект Ленина, 49,
biryukov_str@mail.ru

В данной статье рассмотрен вопрос и представлены результаты исследований по управлению кредитным портфелем банка с применением logit-моделей и нейросетевой модели, которые дают новые возможности снижать кредитные риски при различной динамике изменения финансово-экономического состояния предприятия – заемщиков.

Ключевые слова: банк, кредитная задолженность, банкротство, logit-модель, нейросетевая модель, предприятие – заемщик.

Введение. Основными предпосылками возникновения рисков со стороны банков является низкое качество оценки кредитоспособности заемщиков при решении вопроса о выдаче кредита, а также отсутствие достаточно точных и адекватных динамических моделей оценки банком текущего финансово-экономического состояния (ФЭС) заемщиков в процессе обслуживания кредитов. Поэтому вопрос об управлении реструктуризацией кредитной задолженности предприятий весьма актуален. Подчеркнем, что в эффективности реструктуризации кредитной задолженности заинтересованы обе стороны кредитной сделки: банк и предприятие-заемщик.

Для поддержки принимаемых решений по управлению кредитным портфелем банка требуется создание адекватной математической модели, обладающей высокой прогностической силой в сложных условиях моделирования:

Возникает задача, что на этапе текущего мониторинга по обслуживанию кредитного портфеля банка и отслеживанию приближения «точки невозврата» требуется разработка динамической нейросетевой прогнозной модели с непрерывным временем в условиях неполных данных, когда в некоторых временных срезах для предприятия отсутствуют метки «банкрот-не банкрот» [1].

В данной статье проведен анализ известных *logit-моделей* наряду с *нейросетевым моделированием* в аспекте их адекватности и чувствительности, т.е. способности дифференцировать характер динамических зависимостей вероятности риска банкротства для различных предприятий.

Представляется в таблице 1 подробная классификация стадий из [3] с приближенной оценкой вероятности риска банкротства P на каждой стадии и соответствующие им вероятности риска банкротства.

Таблица 1 – этапы кризиса вероятности банкротства предприятия

№ п/ п	Этап кризиса	Тип кризиса	Интервалы изменения вероятности банкротства предприятия	Лингвистическая характеристика риска банкротства
1	Стратегический кризис	Кризис управления	$0 \leq P < 0,15$	Очень низкий риск банкротства
2	Структурный кризис	Кризис управления	$0,15 \leq P < 0,3$	Низкий риск банкротства
3	Оперативный кризис	Кризис управления	$0,3 \leq P < 0,45$	Средний риск банкротства
4	Кризис ликвидности	Финансовый кризис	$0,45 \leq P < 0,6$	Средний риск банкротства
5	Временная неплатежеспособность	Финансовый кризис	$0,6 \leq P < 0,8$	Высокий риск банкротства
6	Несостоятельность	Финансовый кризис	$0,8 \leq P < 1$	Очень высокий риск банкротства
7	Банкротство	Финансово-правовой кризис	$0,8 \leq P < 1$	Очень высокий риск банкротства

В таблице 1 этапы кризиса можно условно разбить на четыре периода:

- предкризисный период включает этапы 1, 2 и 3 (управленческий кризис)
- банк, анализируя отчетность заемщика, может выявить падение объемов производства и сбыта, и уже на данном этапе начать вести переговоры с заемщиком на предмет санации его финансового состояния;

- период острого кризиса (финансовый кризис) (этап 4) – кредитным инспекторам необходимо обращать внимание на увеличение задолженности предприятия перед всеми кредиторами и ухудшение показателей ликвидности. Особое внимание банк должен обращать на хроническую неплатежеспособность, которая может привести к убыткам банка.

- в периоде острого хронического кризиса (этап 5) предприятие уже не имеет ликвидных собственных внутренних ресурсов, и для того чтобы восстановить платежеспособность, ему необходимы внешние источники финансирования. Одним из путей решения вопроса может быть рефинансирование задолженности, однако такой шаг вызовет рост объема рисковых активов, а значит, снижение достаточности собственного капитала.

- заключительный период экономико-правового кризиса (этапы 6 и 7). В этом периоде предприятие характеризуется несостоятельностью (абсолютной неплатежеспособностью), которая является критической (бифуркационной) точкой развития.

Из приведенного краткого анализа видно, что при управлении кредитным портфелем для банка очень важно в любой текущий момент времени t знать объективную и достоверную информацию об этапах развивающегося банкротства заемщика и, в частности, динамическую кривую вероятности риска банкротства $P(t)$. Для этого и предназначена динамическая модель банкротства с непрерывным временем t .

Как показали вычислительные эксперименты на реальных данных [1,2], прогностическая сила динамической модели банкротств, получаемой с помощью нейросетевого логистического итерационного динамического метода (НЛИДМ), оценивается в примерно 87,6% правильно идентифицируемых заемщиков. Дальнейшее увеличение точности НЛИДМ наталкивается на принципиально неустранимую неполноту исходных данных в обучающем множестве нейросети, которая состоит в задании дискретных меток: « $P=1$ (банкрот)», « $P=0$ (не банкрот)». Последнее обусловлено юридическими аспектами признания заемщика банкротом. Динамическая модель банкротства, получаемая с помощью НЛИДМ, приобрела бы значительно более высокое качество, если бы в обучающем множестве появились промежуточные значения вероятности P между 0 и 1.

Предлагается «*Положение о повышении информативности обучающего множества нейросети (НС)*», и соответственно, обобщения НЛИДМ формируется так: с целью увеличения прогностической силы НЛИДМ предлагается введение в модель априорной информации о промежуточных значениях вероятности риска банкротства $P \in [0; 1]$, получаемой на основе байесовского ансамбля статических логистических моделей банкротств В.Ю. Жданова, Ольсона [3] и других вида:

$$P_q(\hat{y}(\vec{x})) = 1/[1 + \exp(\hat{y}_q(\vec{x}))], \quad (1)$$

где $\hat{y}_q(\vec{x})$ – регрессионная зависимость показателя экспоненты от вектора факторов (финансовых коэффициентов) $\vec{x} = (x_1, x_2, \dots, x_n)$ для q -ой модели – априорной гипотезы.

В наших исследованиях применялись 16 коэффициентов из четырех групп [1,2]:

группа 1 – «рентабельность»; группа 2 – «ликвидность и платежеспособность»; группа 3 – «деловая активность»; группа 4 – «финансовая устойчивость».

Модели – априорные гипотезы $\{h_q\}, q = \overline{1, Q}$ в байесовском ансамбле отличаются коэффициентами регрессии и составом факторов:

$$\hat{y}(\vec{x}) = b_0 + b_1 x_1, \dots + b_j x_j, \dots + b_n x_n. \quad (2)$$

Для повышения достоверности оценок они усреднялись на отфильтрованном байесовском ансамбле:

$$\bar{P} = \left[\sum_{q=1}^{Q^*} P_q(\hat{y}(\vec{x})) \right] / Q^* \quad (3)$$

где Q^* – число моделей на отфильтрованном ансамбле.

Сравнение нейросетевого логистического итерационного динамического метода (НЛИДМ) банкротств по чувствительности и обнаружению стадий развивающегося процесса банкротства проводилась в программе «*NeuroSolutions 7.1.1.1*» [5] для 7 строительных предприятий (рис. 1 и табл. 2). Для сравнения использовались 5 известные логистические модели (logit-модели) банкротств из таблицы 2.

Все logit-модели охвачены программным продуктом *QFinAnalysis* (версия 1.9) разработанным В.Ю. Ждановым и И.Ю. Ждановым в Московском авиационном университете [3,4]. Исходными данными служила стандартная бухгалтерская отчетность. Результаты оценок показаны в таблице 2, где вероятность риска банкротства указана в %.

Таблица 2 – сводная таблица результатов расчета по известным logit-моделям с использованием программы QFinAnalysis

Методы анализа финансового состояния предприятия	АО "Главстрой Девелопмент"	ПАО "Группа Компаний ПИК"	АО "Жилдор-ипотека"	АО "Казаньцентрстрой"	ОАО «Пензастрой»	ОАО «Первый РС Трест»	АО «Южно-Уральская корпорация
Модель Альтмана-Сабато	100%	98%	98%	0%	98%	0%	97%
Модель Лина-Пъессе	45%	45%	45%	45%	45%	45%	45%
Модель Джуха-Техонга	50%	48%	48%	38%	48%	8%	46%
Модель М. Грущински (2003)	1%	1%	1%	1%	1%	1%	1%
Модель Жданова	1%	1%	1%	1%	1%	1%	1%

Результаты оценок. Если зафиксировать предприятия, т.е. колонки таблицы 2, то все logit-модели дают существенно разноречивые результаты, которые не позволяют разработать эффективные практические рекомендации по реструктуризации кредитной задолженности.

Если же зафиксировать строки таблицы 2, то все предприятия оцениваются одинаково в смысле близости к банкротству, т.е. зафиксированная модель их не различает. Исключением является модель Альтмана – Сабато, которая выделила два предприятия (АО «Казаньцентрстрой» и ОАО «Первый РС Трест») как далекие от банкротства.

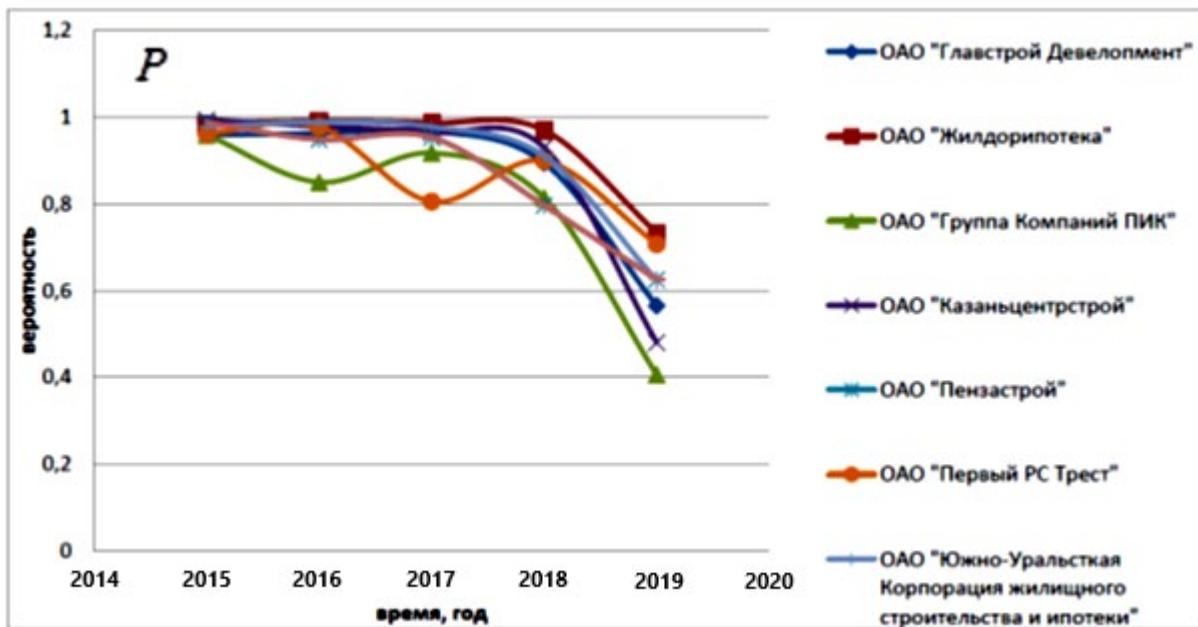


Рисунок 1. Динамика риска банкротства 7 строительных предприятий, рассчитанная НЛИДМ

Таким образом, из 5 logit-моделей из 4 не обладают достаточной чувствительностью к признакам и стадиям развивающегося процесса кризиса на предприятиях. С другой стороны, оригинальный НЛИДМ из [2], как было показано выше на рис. 1, обладает требуемой чувствительностью в динамике, т.е. дифференцирует предприятия по стадиям банкротства наблюдаемым в данный момент времени t , и, главное, нейросетевой метод позволяет сделать прогноз для заданного временного горизонта ($t = t_{\text{пр}}$). Так для предприятия ПАО «Группа компаний ПИК» антикризисные меры в течение 2014-2020 гг. позволили снизить риск банкротства с 0,95 до 0,4. В то же время предприятие АО «Жилдорипотека» к 2019 г. имела довольно высокий риск банкротства ($P = 0,75$).

Основные выводы

1. Для оригинального нейросетевого логистического итерационного динамического метода (НЛИДМ) построения модели оценки риска банкротства с учетом непрерывного времени t , который восстанавливает неполные данные во временных «срезах», проведена всесторонняя верификация чувствительности метода к выявлению признаков и стадий развивающегося кризиса корпораций.

2. Путем сравнения с оценками по известным logit-моделям показано, что НЛИДМ обладает достаточной контрастностью, т.е. способен дифференцировать характер динамических зависимостей $P(\vec{x}(t), t)$ вероятности риска банкротства. Для различных предприятий это позволяет кредитору отслеживать динамику $P(\vec{x}(t), t)$ при обслуживании кредитного портфеля и своевременно начать процедуры реструктуризации задолженности. Упомянутые logit-моделям, которые в основном охватывают современный арсенал моделей риска банкротства, таким свойством контрастности оценок не обладает. Следовательно, НЛИДМ расширяет возможности современных экономико-

математических инструментариев и позволяет более эффективно решать прикладные задачи финансового менеджмента.

3. Нейросетевой логистический итерационный динамический метод (НЛИДМ) позволяет строить экстраполяционные модели банкротств с непрерывным временем, получить дифференцированную оценку динамики $P(t)$. Метод имеет прогностическую силу порядка 87% верной идентификации предприятий для финансово-экономического состояния заемщиков.

Библиографический список

1. Бирюков А.Н. Байесовская регуляризация нейросетевых моделей ранжирования и кластеризации экономических объектов. – Уфа: Академия наук РБ, Издательство «Гилем», 2011. – 292 с.
2. Горбатков С.А., Полупанов Д.В., Макеева Е.Ю., Бирюков А.Н. Методологические основы разработки нейросетевых моделей экономических объектов в условиях неопределенности: Монография. – М.: Издательский дом «Экономическая газета», 2012. – 494 с.
3. Жданов В.Ю. Диагностика риска банкротства предприятия в трехмерном пространстве//Управление экономическими системами. – 2011. – №8. №. гос. регистрации статьи 0421100034/0277 от 31.08.11.-20 с.
4. Жданов В.Ю., Жданов И.Ю. *QFinAnalysis. Версия 1.9.* Программа для быстрого и качественного финансово-экономического анализа хозяйственной деятельности предприятия.
5. Программа «NeuroSolutions 7.1.1.1».

APPLICATION OF NEURAL NETWORK MODELING IN CASE OF BANKRUPTCY PROBABILITY FOR CREDIT RISK MANAGEMENT

Biryukov Alexander N.

Sterlitamak branch "Bashkir State University"
453103, Republic of Bashkortostan, Sterlitamak, Lenin Avenue, 49,
biryukov_str@mail.ru

This article discusses the issue and presents the results of research on the management of the bank's loan portfolio using logit models and a neural network model, which provide new opportunities to reduce credit risks with different dynamics of changes in the financial and economic state of the borrower enterprise.

Keywords: bank, credit debt, bankruptcy, logit model, neural network model, borrower enterprise.

ПРОГНОЗИРОВАНИЕ СТОИМОСТИ МОБИЛЬНЫХ ТЕЛЕФОНОВ МЕТОДАМИ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА

Проскуряков Кирилл Александрович, Ермаков Иван Денисович

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15, k.proskuryakov22@gmail.com,
john.ermakov27@gmail.com

В статье представлено описание разработки нейросетевой системы для прогнозирования стоимости мобильных телефонов в розничных сетях. Система позволяет выполнить оценку устройств с учётом характеристик экрана, процессора, камер, поддерживаемых стандартов, габаритов, а также используемой операционной системы.

Ключевые слова: искусственный интеллект, нейросетевые технологии, прогнозирование, оценка стоимости, мобильные телефоны.

Введение. В настоящее время мобильные телефоны являются одними из самых продаваемых устройств в мире, а новые бренды и модели появляются чуть ли не каждый день. В таких условиях у производителей может возникнуть необходимость грамотно оценить стоимость своих новых устройств, учитывая актуальную ситуацию на рынке. Данная работа окажется полезной и для потенциальных покупателей. Во-первых, люди, смогут узнать, какие факторы являются определяющими в формировании стоимости телефонов, и сделать рациональный выбор при покупке. Во-вторых, покупатели смогут проверить, соответствует ли заинтересовавшее их устройство заявленной цене.

Методы искусственного интеллекта при оценке стоимости мобильных телефонов были использованы в работах зарубежных исследователей [1-2]. Однако в данных работах предсказывается не точная стоимость устройства, а его примерный ценовой диапазон. Данное исследование ставит перед собой задачу создать и обучить нейросетевую модель для предсказания точной стоимости телефона по его характеристикам.

Основная цель настоящей работы заключается в сборе множества данных о телефонах, продающихся в розничных сетях, а также создание и обучение нейросетевой модели на этих данных.

Для создания нейросетевой модели был выбран следующий набор параметров: X₁ – диагональ экрана (дюймы), X₂ – плотность пикселей экрана (пиксели на дюйм), X₃ – технология матрицы экрана, X₄ – частота обновления экрана (Гц), X₅ – количество ядер процессора, X₆ – частота работы процессора (ГГц), X₇ – техпроцесс процессора (нм), X₈ – объём оперативной памяти (Гб), X₉ – объём встроенной памяти (Гб), X₁₀ – количество мегапикселей основной

камеры, X11 – количество мегапикселей фронтальной камеры, X12 – пиковое разрешение записи видео, X13 – стандарт связи, X14 – операционная система, X15 – NFC, X16 – ёмкость аккумулятора (mA*ч), X17 – материал изготовления корпуса, X18 – толщина (см), X19 – вес (г). Выходной параметр D1 – стоимость телефона (руб.).

Качественные параметры были закодированы следующим образом:

- технология матрицы экрана: 1 – TN, 2 – IPS, 3 – OLED;
- пиковое разрешение записи видео: 1 – HD, 2 – Full HD, 3 – 4K, 4 – 8K;
- стандарт связи: 1 – 3G, 2 – 4G, 3 – 5G;
- операционная система: 1 – Android, 2 – iOS;
- NFC: 0 – не поддерживается, 1 – поддерживается;
- материал изготовления корпуса: 1 – пластик, 2 – стекло;

Для обучения и тестирования модели использовались данные из электронных ресурсов [3-4] популярных российских розничных сетей. Перед переходом к обучению нейросетевой модели была выполнена очистка исходного множества от выбросов [5] и дубликатов. Таким образом, итоговое множество включало в себя 232 примера. Данное множество было разделено на обучающее, содержащее 192(80%) примеров и тестирующее, включающее в себя оставшиеся 40(20%) примеров соответственно.

Проектирование, обучение и тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [6]. В результате оптимизации спроектированная нейронная сеть представляла собой персепtron, имеющий девятнадцать входных нейронов, один скрытый слов с пятью нейронами и выходной слой с одним нейроном.

Для оценки корректности работы нейронной сети использовалось тестирующее множество, состоящее из 40 примеров. Квадратичная ошибка тестирования составила 6,34%, что можно считать приемлемым результатом.

С помощью программы «Нейросимулятор 5» была выполнена оценка значимости входных параметров, результат отображен на рисунке 1.

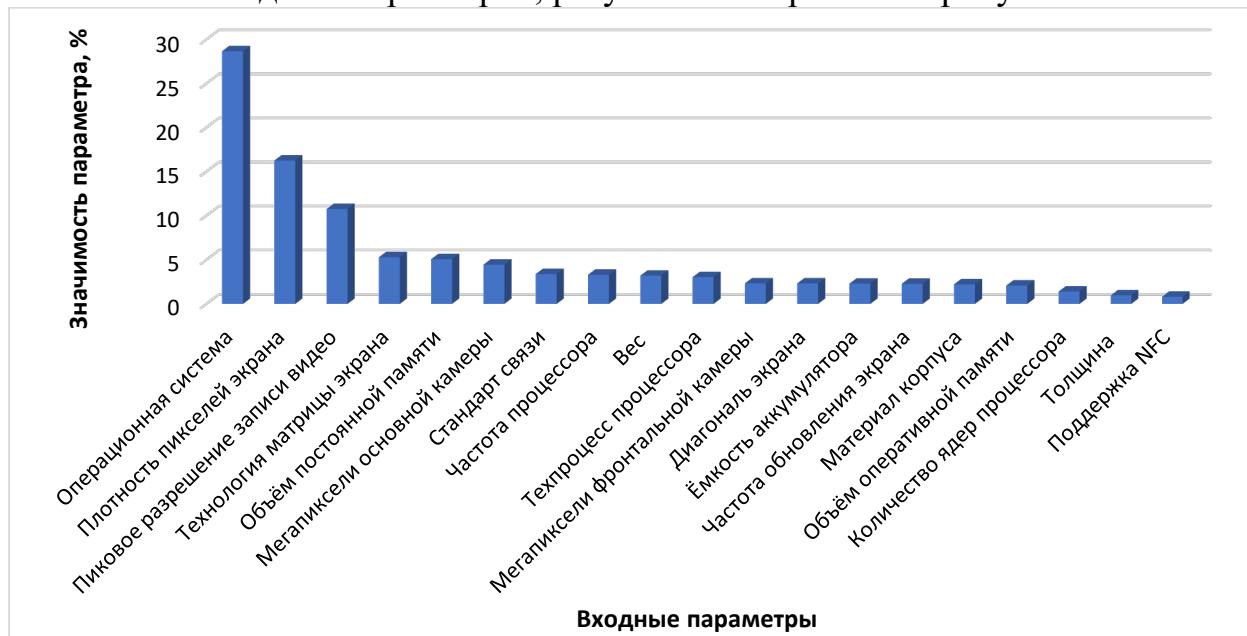


Рисунок 1. Значимость входных параметров нейросетевой модели

Как видно из рисунка 1, наиболее значимыми параметрами при формировании цены мобильного телефона являются операционная система, плотность пикселей экрана и пиковое разрешение записи видео. Также на графике можно видеть ряд параметров, которые имеют почти нулевую значимость, такие как количество ядер процессора, толщина и поддержка NFC. Сравнив полученные результаты с результатами исследования [1], можно сделать несколько выводов. Во-первых, самым значимым параметром в зарубежной работе является объём оперативной памяти, в нашем же исследовании он не играет определяющей роли. Это можно объяснить тем, что за последние несколько лет объём оперативной памяти в мобильных телефонах значительно вырос, приблизившись к значениям полноценных компьютеров. Во-вторых, вторым по значимости параметром в нашем исследовании является плотность пикселей, или же разрешение экрана, в зарубежной статье этот показателей также является одним из ключевых. Также немалую значимость имеет матрица экрана, это объясняется тем, что в современном мире люди постоянно взаимодействуют с телефоном, смотрят видео, фотографии, проводят время в социальных сетях, и для того, чтобы опыт использования был максимально комфортным, производители стараются максимально улучшить качество экрана.

Были проведены исследования рынка мобильных телефонов. Исследования проводились с помощью метода «замораживания» [7], суть которого заключается в варьировании значения одного параметра и фиксирования значений всех других параметров. Данный метод позволяет выявить влияние одного исследуемого параметра на выходной.

Как видно из графика на рисунке 1, самым значимым параметром является операционная система. В нашем исследовании представлены телефоны, работающие на базе таких систем как Android и iOS. На рисунке 2 продемонстрирована зависимость стоимости телефонов от их операционных систем. Прослеживается тенденция формирования значительно большей цены на телефон на базе iOS, чем на Android, при идентичных технических характеристиках. В среднем, разница составила 31,9%

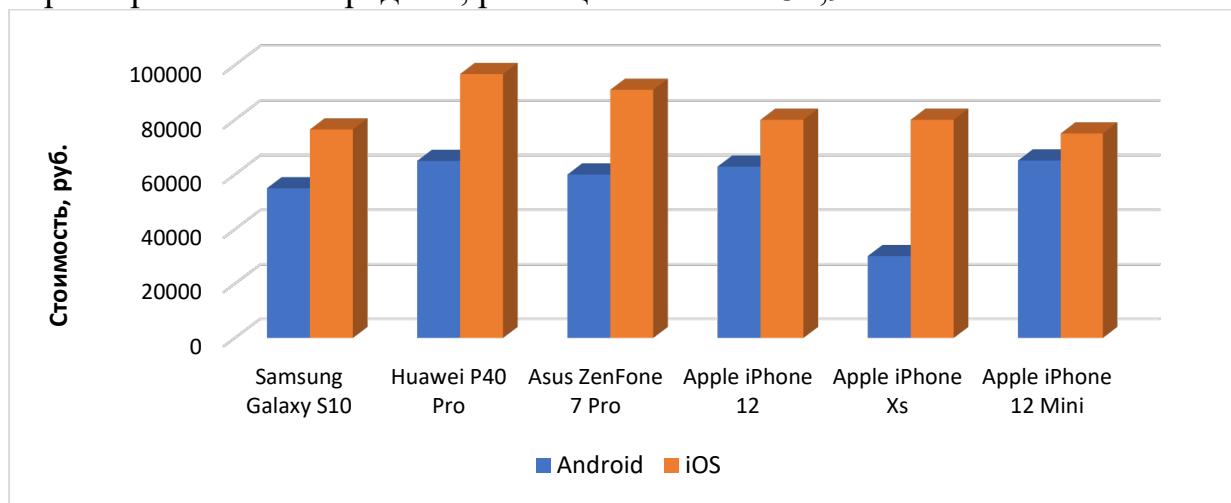


Рисунок 2. Зависимость стоимости телефонов от операционной системы

Для дальнейших исследований случайным образом было отобрано 3 телефона из исходного множества.

Были проведены исследования характеристик экрана. На рисунке 3 показан график зависимости стоимости телефона от плотности пикселей экрана. Интересно отметить, что при изменении показателя с 250 до 450 пикселей на дюйм, стоимость растёт в среднем на 18,7%, однако при дальнейшем увеличении показателя до 500, стоимость, в среднем, увеличивается в 2.5 раза. На рисунке 4 демонстрируется зависимость стоимости от технологии матрицы экрана. В среднем использование OLED матрицы обходится дороже IPS на 16.8%.

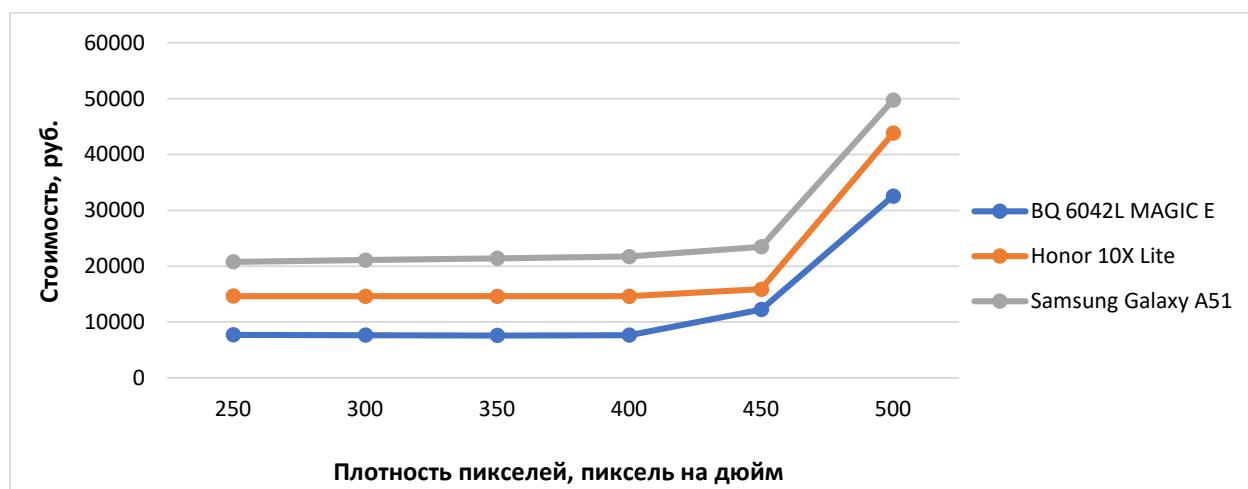


Рисунок 3. Зависимость стоимости телефонов от плотности пикселей

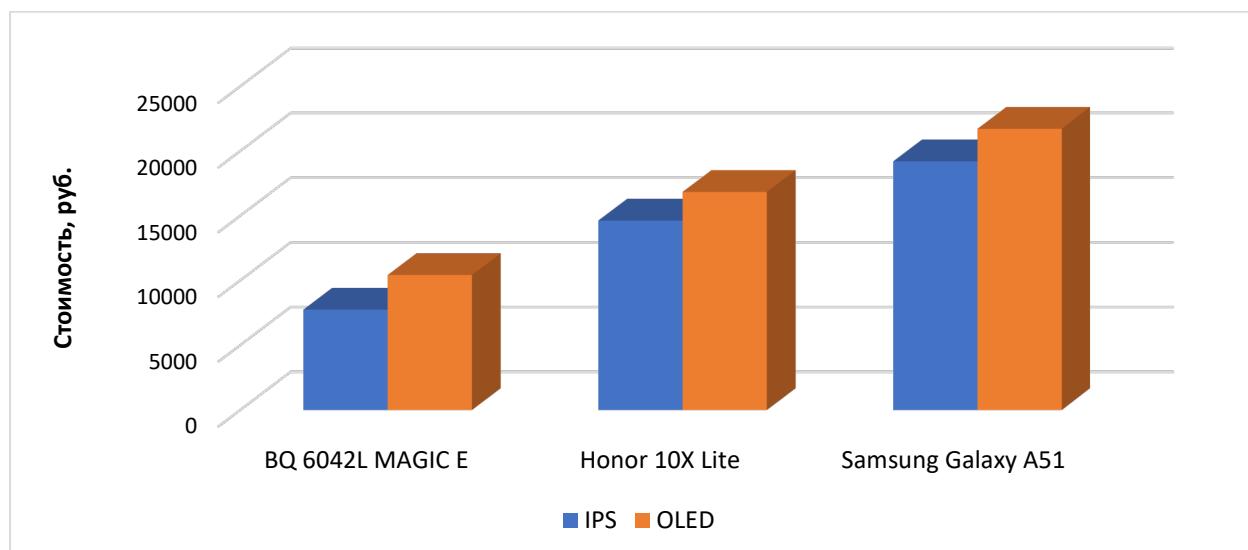


Рисунок 4. Зависимость стоимости телефонов от матрицы экрана

На рисунке 5 продемонстрирована зависимость стоимости телефона от пикового разрешения записи видео. Как видно на графике, при изменении показателя с Full HD на 4K происходит резкий скачок в цене, причём чем хуже остальные характеристики телефона, тем скачок сильнее.

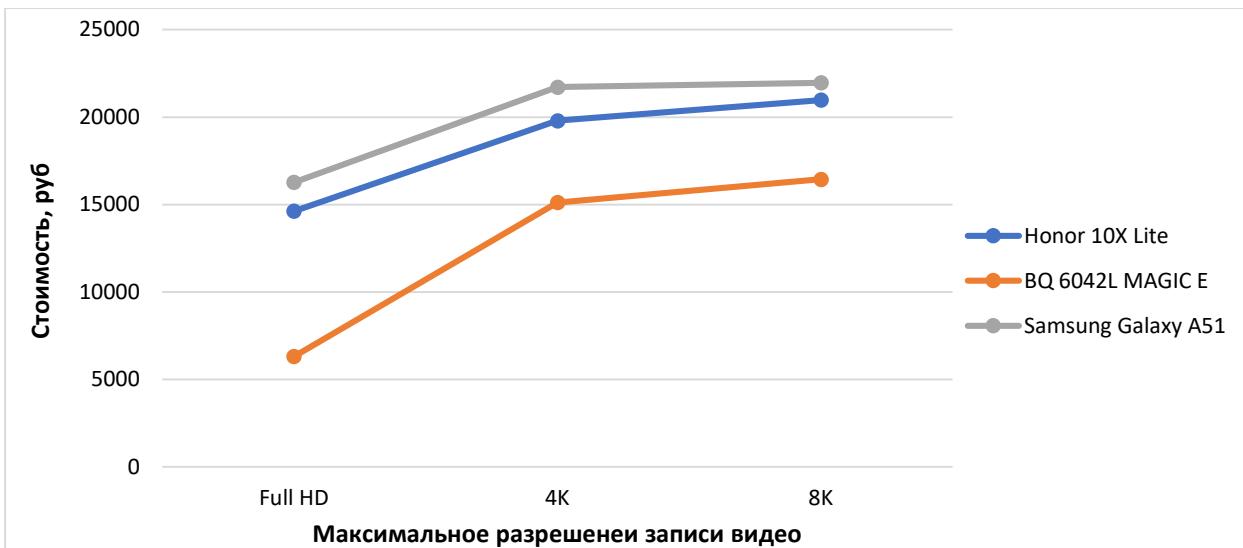


Рисунок 5. Зависимость стоимости телефонов от максимального разрешения записи видео

Следующим исследуемым показателем стал поддерживаемый стандарт связи. Сравнивалась стоимость устройств, поддерживающих такие стандарты связи как 4G и 5G. На рисунке 12 показана гистограмма, демонстрирующая зависимость стоимость от поддерживаемого стандарта. В среднем смартфоны с 5G стоят на 23.7% дороже аналогичных, но поддерживающих только 4G.

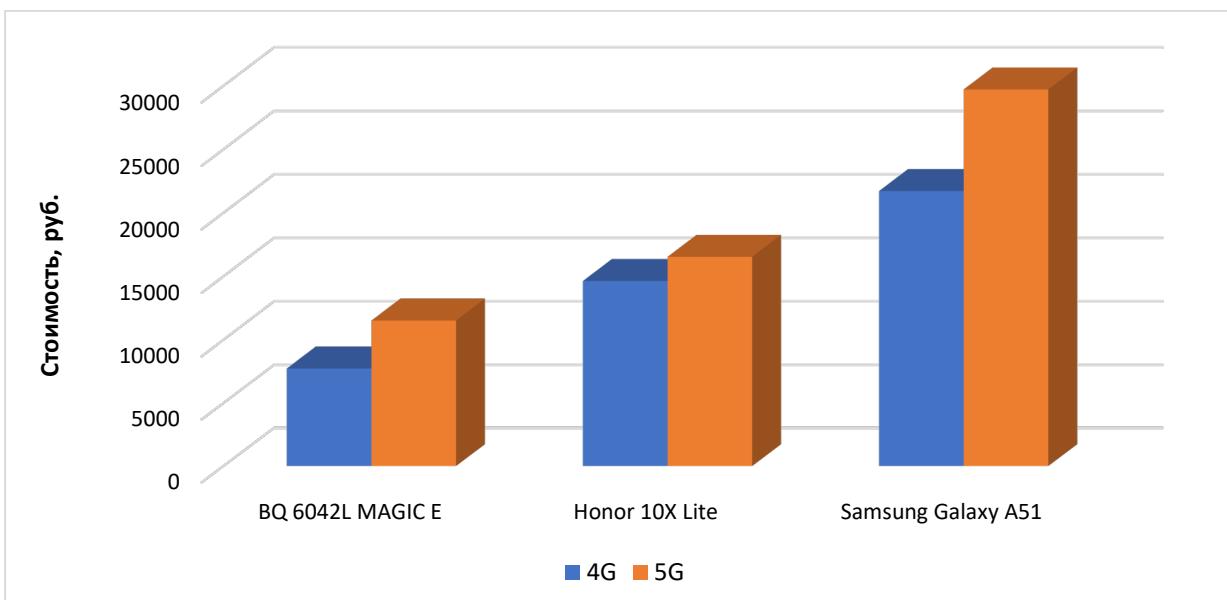


Рисунок 6. Зависимость стоимости телефонов от стандарта связи

Заключение. Построена система нейросетевого оценивания стоимости мобильных телефонов. Спроектированная нейросетевая модель учитывает многие показатели влияющие на стоимость устройства: характеристики экрана, процессора, камеры, операционную систему и другие параметры. Проведены исследования рынка мобильных телефонов. Построены графики зависимости стоимость телефонов от операционной системы, плотности пикселей экрана,

матрицы экрана, максимального разрешения записи видео и поддерживаемого стандарта связи.

Библиографический список

1. Nasser I. M., Al-Shawwa M. & Abu-Naser S.S. Developing Artificial Neural Network for Predicting Mobile Phone Price Range // International Journal of Academic Information Systems Research. 2019. Vol. 3, no 2. P. 1-6.
2. Asim M., Khan Z. Mobile Price Class prediction using Machine Learning Techniques // International Journal of Computer Applications. 2018. Vol. 179, no 29. P. 6-11.
3. DNS [Электронный ресурс] // URL: <https://www.dns-shop.ru> (Дата обращения: 20.02.2021)
4. Mvideo [Электронный ресурс] // URL: <https://www.mvideo.ru> (Дата обращения: 20.02.2021)
5. Yasnitsky L.N. Algorithm for searching and analyzing abnormal observations of statistical information based on the Arnold – Kolmogorov – Hecht-Nielsen theorem // International Journal of Advanced Trends in Computer Science and Engineering. 2020. 9(2). Pp. 1814-1819. DOI: 10.30534/ijatcse/2020/139922020 <http://www.warse.org/IJATCSE/static/pdf/file/ijatcse139922020.pdf>
6. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
7. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.

FORECASTING MOBILE PHONE PRICES BY ARTIFICIAL INTELLIGENCE METHODS

Proskuryakov Kirill A., Ermakov Ivan D.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990,

k.proskuryakov22@gmail.com, john.ermakov27@gmail.com

The article describes the development of a neural network system for predicting the cost of mobile phones in retail chains. The system allows you to evaluate devices taking into account the characteristics of the screen, processor, cameras, supported standards, dimensions, as well as the operating system used.

Keywords: artificial intelligence, neural network technologies, forecasting, cost estimation, mobile phone.

ИНТЕЛЛЕКТУАЛЬНЫЙ ПРОГРАММНЫЙ КОМПЛЕКС МОДЕЛИРОВАНИЯ ОПТИМИЗАЦИИ УПРАВЛЕНИЯ ПРОИЗВОДСТВОМ ПРОДУКЦИИ ПРЕДПРИЯТИЯ

Шориков Андрей Федорович

Институт экономики УрО РАН,

620014, Россия, г. Екатеринбург, ул. Московская, 29,

afshorikov@mail.ru

В работе представлено описание структуры и функций интеллектуального компьютерного программного комплекса, позволяющего моделировать оптимизацию управления производством продукции предприятия. В статье приведено описание используемой в программном комплексе дискретной управляемой динамической модели при наличии векторной целевой функции для оценки качества реализации рассматриваемого процесса, структура программного комплекса, функции его основных модулей и описание пользовательского интерфейса. Основные модули программного комплекса позволяют моделировать решение задач прогнозирования состояния модели, оптимизации программного и адаптивного управления производством продукции предприятия.

Ключевые слова: интеллектуальный программный комплекс, динамическая модель, прогнозирование, оптимизация, адаптивное управление.

Введение. Одним из важнейших направлений повышения конкурентоспособности производственного предприятия является внедрение современных компьютерных программных систем, позволяющих автоматизировать процессы принятия решений для ключевых задач. Приоритетные задачи управления деятельностью предприятия, прежде всего, связаны с созданием и внедрением комплексных систем автоматизации функционирования и оптимизации управления бизнес-процессами. В статье представлено описание интеллектуального компьютерного программного комплекса, позволяющего моделировать решение задач прогнозирования состояния динамической модели процесса производства продукции предприятия и принятия управленческих решений. В основе этого программного комплекса – соответствующая дискретная управляемая динамическая экономико-математическая модель и разработанные алгоритмы прогнозирования состояния модели, оптимизации программного и адаптивного управления исследуемым процессом. Полученные в статье результаты обобщают исследования [1-3], базируются на работе [4] и могут быть использованы для решения других задач практической экономики (см., например, работы [5,6]).

Экономико-математическая модель исследуемого процесса. Пусть на заданном целочисленном промежутке времени (далее просто – промежутке времени) $\overline{0, T} = \{0, 1, \dots, T\}$ ($T \in \mathbf{N}; t \in \overline{0, T}$, например, месяц, квартал, год; здесь и далее, \mathbf{N} – множество всех натуральных чисел) рассматривается процесс управления производством продукции предприятия. Тогда в соответствии с результатами работ [1-3] можно сформировать следующую систему линейных дискретных рекуррентных уравнений, описывающую в полном объеме динамику рассматриваемого процесса

$$\begin{cases} y(t+1) = H(t)y(t) + \bar{u}(t) - s(t), \quad y(0) = \mathbf{0}_{\bar{n}}, \quad s(0) = s, \\ z(t+1) = R(t)z(t) + v(t) - \bar{A}(t)\bar{u}(t), \quad z(0) = b, \\ k(t+1) = \gamma(t)k(t) + \\ + \alpha \cdot (\langle c(t), s(t) \rangle_{\bar{n}} - \langle q(t), l(t) \rangle_m - \langle p(t), y(t) \rangle_{\bar{n}} - \langle d(t), z(t) \rangle_m) - \\ - \beta(t) \cdot G, \quad k(0) = G + G_0, \\ Z(t+1) = Z(t) + \langle q(t), l(t) \rangle_m + \langle p(t), y(t) \rangle_{\bar{n}} + \langle d(t), z(t) \rangle_m + \beta(t)G, \\ Z(0) = \langle p(0), y(0) \rangle_{\bar{n}} + \langle d(0), z(0) \rangle_m, \quad t \in \overline{0, T-1}, \end{cases} \quad (1)$$

где \bar{n} – общее количество видов готовой продукции предприятия, $\bar{n} \in \mathbf{N}$; m – общее количество типов ресурсов, из которых можно произвести данную продукцию, $m \in \mathbf{N}$; $y(t) = (y_1(t), y_2(t), \dots, y_{\bar{n}}(t))'$ – вектор объемов остатков готовой продукции, хранящейся на складах предприятия в период времени t , $y(t) \in \mathbf{R}^{\bar{n}}$ ($t \in \overline{0, T-1}$; здесь и далее, для $\delta \in \mathbf{N}$, \mathbf{R}^δ – δ -мерное векторное пространство векторов-столбцов, даже если из экономии места они записаны в строку); $\mathbf{0}_{\bar{n}} = (\underbrace{0, 0, \dots, 0}_{\bar{n}})' \in \mathbf{R}^{\bar{n}}$); $z(t) = (z_1(t), z_2(t), \dots, z_m(t))'$ – вектор объемов остатков производственных ресурсов, хранящихся на складах предприятия в период времени t , $z(t) \in \mathbf{R}^m$ ($t \in \overline{0, T-1}$); $\bar{A}(t) = \left\| \bar{a}_{ij}(t) \right\|_{\substack{i \in \overline{1, m} \\ j \in \overline{1, \bar{n}}}}$ – матрица норм затрат ресурсов в период времени t ($t \in \overline{0, T-1}$; $\bar{a}_{ij}(t)$ – количество ресурса i -го типа, необходимого для изготовления единичного объема продукции j -го вида ($i \in \overline{1, m}$; $j \in \overline{1, \bar{n}}$)); $\bar{u}(t) = (\bar{u}_1(t), \bar{u}_2(t), \dots, \bar{u}_{\bar{n}}(t))'$ – вектор интенсивностей производства готовой продукции в период времени t , $\bar{u}(t) \in \mathbf{R}^{\bar{n}}$ ($t \in \overline{0, T-1}$); $v(t) = (v_1(t), v_2(t), \dots, v_m(t))'$ – вектор интенсивностей пополнения складских ресурсов в период времени t , $v(t) \in \mathbf{R}^m$ ($t \in \overline{0, T-1}$); $s(t) = (s_1(t), s_2(t), \dots, s_{\bar{n}}(t))'$ – вектор объемов спроса на готовую продукцию, выпускаемую в период времени t , $s(t) \in \mathbf{R}^{\bar{n}}$ ($t \in \overline{0, T-1}$); $s = (s_1, s_2, \dots, s_{\bar{n}})'$ – вектор начального объема спроса на готовую продукцию при реализации процесса управления в начальный период времени (при $t = 0$), $s \in \mathbf{R}^{\bar{n}}$; $b = (b_1, b_2, \dots, b_m)'$ – вектор начального объема производственных ресурсов при реализации процесса управления в начальный период времени (при $t = 0$), $b \in \mathbf{R}^m$; если в начале периода времени t

$(t \in \overline{0, T-1})$ на складе имелись запасы готовой продукции в количестве $y(t)$, то к концу этого периода для продажи будет годна только часть, равная $H_{\bar{n}}(t)y(t)$, где $H_{\bar{n}}(t) = \|h_{jj}(t)\|_{j \in \overline{1, \bar{n}}}$ – есть диагональная матрица порядка \bar{n} , характеризующая «старение» продукции за этот период; для запасов производственных ресурсов, к концу периода t ($t \in \overline{0, T-1}$) для использования в производстве будет годна только их часть, равная $R_m(t)z(t)$, где $R_m(t) = \|r_{ii}(t)\|_{i \in \overline{1, m}}$ – диагональная матрица порядка m , характеризующая «старение» производственных ресурсов за этот период; финансовые средства на инвестиции в расширение производства в начальный период управления (при $t=0$) предприятие предполагает формировать на основе банковского кредита в объеме G и собственных финансовых ресурсов G_0 , отчисляемых от чистой прибыли и направляемых на расширение производства; $k(t)$ – количество доступных финансовых средств, имеющихся к началу периода t ($t \in \overline{0, T-1}$); $\gamma(t)$ – числовой коэффициент ($0 \leq \gamma(t) \leq 1$), характеризующий «непредвиденные издержки» финансовых ресурсов за период t ($t \in \overline{0, T-1}$); α – коэффициент, учитывающий долю налоговых отчислений от прибыли; $\beta(t) = r/100 + \beta_o(t)$, здесь r – годовая процентная ставка за пользование кредитом, $\beta_o(t)$ – доля возвращаемого кредита в период t ($t \in \overline{0, T-1}$); $c(t) = (c_1(t), c_2(t), \dots, c_{\bar{n}}(t))'$ – вектор реальных закупочных цен на реализованную продукцию, произведенную предприятием в период времени t , $c(t) \in \mathbf{R}^{\bar{n}}$ ($t \in \overline{0, T-1}$); $q(t) = (q_1(t), q_2(t), \dots, q_m(t))'$ – вектор реальных цен на производственные ресурсы, необходимые предприятию для производства продукции в период времени t , $q(t) \in \mathbf{R}^m$ ($t \in \overline{0, T-1}$); $p(t) = (p_1(t), p_2(t), \dots, p_{\bar{n}}(t))'$ – вектор затрат предприятия на хранение на складе остатков готовой продукции в период времени t , $p(t) \in \mathbf{R}^{\bar{n}}$ ($t \in \overline{0, T-1}$); $d(t) = (d_1(t), d_2(t), \dots, d_m(t))'$ – вектор затрат предприятия на хранение на складе остатков производственных ресурсов в период времени t , $d(t) \in \mathbf{R}^m$ ($t \in \overline{0, T-1}$); вектор $l(t) = (\langle \bar{a}_1^{(1)}(t), \bar{u}(t) \rangle_{\bar{n}}, \langle \bar{a}_2^{(1)}(t), \bar{u}(t) \rangle_{\bar{n}}, \dots, \langle \bar{a}_m^{(1)}(t), \bar{u}(t) \rangle_{\bar{n}})' \in \mathbf{R}^m$ (здесь и далее, для $\delta \in \mathbf{N}$ символом $\langle a, b \rangle_\delta$ будем обозначать скалярное произведение векторов a и b в пространстве \mathbf{R}^δ); вектор $\bar{a}_i^{(1)}(t) = (\bar{a}_{i1}(t), \bar{a}_{i2}(t), \dots, \bar{a}_{i\bar{n}}(t))' \in \mathbf{R}^{\bar{n}}$ ($i \in \overline{1, m}$); $Z(t)$ – общие суммарные издержки предприятия за t периодов времени ($t \in \overline{0, T-1}$).

Отметим, что параметры: $\bar{A}(t)$, $H(t)$, $R(t)$, $s(t)$, s , $c(t)$, $q(t)$, $p(t)$, $d(t)$, α , $\beta(t)$, $\gamma(t)$, b , G , G_0 в системе (1), для всех $t \in \overline{0, T-1}$ должны быть известны заранее (например, формироваться исходя из имеющихся статистических данных о рассматриваемом процессе, технических и экономических прогнозов и др. источников, путем применения методов оценивания данных и идентификации параметров рассматриваемой системы).

Пусть вектор $x(t) = (y_1(t), y_2(t), \dots, y_{\bar{n}}(t), z_1(t), z_2(t), \dots, z_m(t), k(t), Z(t))'$ является *фазовым вектором* для системы (1) в период времени t , $x(t) \in \mathbf{R}^n$ ($t \in \overline{0, T-1}$), где $n = \bar{n} + m + 2$, а вектор $u(t) = (\bar{u}_1(t), \bar{u}_2(t), \dots, \bar{u}_{\bar{n}}(t), v_1(t), v_2(t), \dots, v_m(t))'$ является вектором *управляющего воздействия (управления)* для системы (1) в период времени t , $u(t) \in \mathbf{R}^p$ ($t \in \overline{0, T-1}$), где $p = \bar{n} + m$.

Тогда систему (1), которая моделирует динамику рассматриваемого процесса выпуска продукции предприятием, можно представить в форме векторного линейного дискретного рекуррентного уравнения вида

$$x(t+1) = A(t)x(t) + B(t)u(t), \quad x(0) = x_0, \quad t \in \overline{0, T-1}, \quad (2)$$

где вид матриц $A(t)$ и $B(t)$ подробно описывается в работе [3]. Матрицы $A(t)$ и $B(t)$ есть действительные матрицы порядков $(n \times n)$ и $(n \times p)$ соответственно и такие, что для всех $t \in \overline{0, T-1}$ матрица $A(t)$ является невырожденной, т.е. для нее существует соответствующая ей обратная матрица $A^{-1}(t)$, а ранг матрицы $B(t)$ равен p (размерности вектора $u(t)$).

Отметим, что система (2) позволяет моделировать динамику многошагового процесса управления производством продукции предприятия в зависимости от заданных начальных условий и выбора конкретных реализаций управляющих воздействий.

Предполагается, что в рассматриваемом процессе управления производством продукции предприятия для каждого периода времени t ($t \in \overline{0, T}$) значения фазового вектора $x(t) = (x_1(t), x_2(t), \dots, x_n(t))' \in \mathbf{R}^n$ должны удовлетворять следующему *заданному геометрическому ограничению*

$$x(t) \in \mathbf{X}^*(t) \subset \mathbf{R}^n, \quad (3)$$

где каждое множество $\mathbf{X}^*(t) \neq \emptyset$ и есть выпуклый многогранник-компакт в пространстве \mathbf{R}^n , определяющий имеющиеся в процессе производства *технико-экономические ограничения* на основные параметры продукции предприятия.

В рассматриваемом процессе управления для каждого периода времени t ($t \in \overline{0, T-1}$) значения вектора управления $u(t) = (u_1(t), u_2(t), \dots, u_p(t))' \in \mathbf{R}^p$, которым распоряжается *субъект управления* – менеджер P , должны удовлетворять следующему *заданному геометрическому ограничению*

$$u(t) \in \mathbf{U}^*(t) \subset \mathbf{R}^p, \quad (4)$$

где каждое множество $\mathbf{U}^*(t) \neq \emptyset$ и есть выпуклый многогранник-компакт в пространстве \mathbf{R}^p , определяющий имеющиеся в процессе производства *технико-экономические ограничения на ресурсы управления* производством продукции предприятия, т.е. определяет *ресурс управления*.

Опишем *информационные возможности* менеджера P в процессе *оптимизации адаптивного управления производством продукции предприятия* на основе дискретной управляемой динамической системы (2) – (4).

Пусть на рассматриваемом промежутке времени $\overline{0, T}$ для любого $t \in \overline{0, T-1}$ ($T \in \mathbf{N}$) и соответствующего промежутка времени $\overline{t, T} \subseteq \overline{0, T}$ в период времени t в процессе управления менеджером P измеряется и запоминается вектор $x(t) = x_t$ – фазовый вектор системы (2) в период времени t ($x(0) = x_0$). Предполагается также, что система уравнений (2), описывающая динамику модели объекта управления, и ограничения (3), (4), для него также известны.

Назовем набор $w(t) = \{t, x(t)\} \in \overline{0, T} \times \mathbf{R}^n$ ($w(0) = w_0 = \{0, x_0\}$) t -позицией дискретной управляемой динамической системы (2) – (4), $t \in \overline{0, T}$. Для каждого периода времени $t \in \overline{0, T}$ определим также множество $\mathbf{W}(t) = \{t\} \times \mathbf{R}^n$ ($\mathbf{W}(0) = \mathbf{W}_0 = \{w(0) = w_0 : w_0 = \{0, x_0\} \in \{0\} \times \mathbf{R}^n\}$) всех допустимых t -позиций рассматриваемой динамической системы.

Целевой функцией для рассматриваемого процесса управления производством продукции предприятия является векторный функционал $\Phi_{\overline{t, T}} = (\Phi_{\overline{t, T}}^{(1)}, \Phi_{\overline{t, T}}^{(2)}, \dots, \Phi_{\overline{t, T}}^{(\sigma)}) : \{\mathbf{W}(t) \times \mathbf{U}(\overline{t, T})\}^\sigma \rightarrow \mathbf{R}^\sigma$, состоящий из σ функционалов ($\sigma \in \mathbf{N}$), где значения каждого функционала $\Phi_{\overline{t, T}}^{(i)} : \mathbf{W}(t) \times \mathbf{U}(\overline{t, T}) \rightarrow \mathbf{R}^1$, $i \in \overline{1, \sigma}$, для допустимого набора $(w(t), u(\cdot)) \in \mathbf{W}(t) \times \mathbf{U}(\overline{t, T})$ (здесь $\mathbf{U}(\overline{t, T})$ – множество всех допустимых на промежутке времени $\overline{t, T}$ программных управлений $u(\cdot) = \{u(\vartheta)\}_{\vartheta \in \overline{t, T-1}}$ менеджера P таких, что $\forall \vartheta \in \overline{t, T-1} : u(\vartheta) \in \mathbf{U}^*(\vartheta)$), определяются по формуле

$$\Phi_{\overline{t, T}}^{(i)}(w(t), u(\cdot)) = \mathbf{F}^{(i)}(\varphi_{\overline{t, T}}(T; x(t), u(\cdot))) = \mathbf{F}^{(i)}(x(T)), \quad (5)$$

где $\mathbf{F}^{(i)} : \mathbf{R}^n \rightarrow \mathbf{R}^1$ – заданный i -й терминалный функционал, значения которого определены на финальных фазовых векторах $x(T) = \varphi_{\overline{t, T}}(T; x(t), u(\cdot))$ системы (2), $x(\cdot) = \varphi_{\overline{t, T}}(\cdot; x(t), u(\cdot))$ – фазовая траектория системы (2) на промежутке времени $\overline{t, T}$, соответствующая набору $(x(t), u(\cdot)) \in \mathbf{X}^*(t) \times \mathbf{U}(\overline{t, T})$; $w(t) = \{t, x(t)\} \in \mathbf{W}(t)$ ($w(0) = w_0 = \{0, x_0\} \in \mathbf{W}_0$).

Описание вида некоторых конкретных функционалов $\mathbf{F}^{(i)}$, $i \in \overline{1, \sigma}$, оценивающих результаты процесса управления производством продукции предприятия, представлено в работах [1-3].

Будем считать, что менеджер P на промежутке времени $\overline{t, T}$ для каждой допустимой реализации t -позиции системы $w(t) = \{t, x(t)\} \in \mathbf{W}(t)$ ($w(0) = w_0 = \{0, x_0\} \in \mathbf{W}_0$) заинтересован в таком исходе рассматриваемого процесса управления – путем влияния на него возможным выбором своих допустимых программных управлений $u(\cdot) \in \mathbf{U}(\overline{t, T})$, при котором i -я целевая функция $\Phi_{\overline{t, T}}^{(i)}$, значения которой определяются по формуле (5), принимает наибольшее или наименьшее возможное значение ($i \in \overline{1, \sigma}$).

Описание интеллектуального программного комплекса. В рамках экономико-математической модели (2) – (5) в работах [1-3] формулируются нижеследующие задачи.

Задача 1. Задача прогнозирования – нелинейная многошаговая задача прогнозирования состояний дискретной управляемой динамической системы (2) – (4), описывающей динамику основных параметров и имеющиеся ограничения, определяющих процесс производства продукции предприятием.

Задача 2. Задача оптимального программного управления – нелинейная многошаговая задача оптимального программного управления производством продукции предприятия в рамках экономико-математической модели (2) – (5).

Задача 3. Задача оптимального адаптивного управления – нелинейная многошаговая задача оптимального адаптивного управления производством продукции предприятия в рамках экономико-математической модели (2) – (5).

Математическая формализация и алгоритмы решения задачи прогнозирования состояний рассматриваемой динамической системы, а также двух основных и взаимосвязанных между собой задач – оптимального программного и адаптивного управления, основываются на результатах монографии [4] и представлены в публикациях [1-3].

На основе формализованного описания и численных алгоритмов решения задач 1-3 – прогнозирования состояний дискретной управляемой динамической системы (2) – (4), оптимального программного и адаптивного управления производством продукции предприятия, в рамках экономико-математической модели (2) – (5), в среде Delphi 7 создан (разработчики – Шориков А.Ф., Рассадина Е.С., Тюлюкин В.А.) моделирующий интеллектуальный компьютерный программный комплекс «Компьютерное моделирование решения задач прогнозирования и оптимизации управления производством продукции предприятия».

Данный программный комплекс позволяет автоматизировать поиск и формирование решений задач прогнозирования состояний рассматриваемой динамической системы, оптимального программного и адаптивного управления производством продукции предприятия при наличии одной или векторной целевых функций в рамках дискретной управляемой динамической экономико-математической модели (2) – (5). Для решения конкретной задачи пользователю предлагается произвести ввод исходных данных, определяющих все параметры системы (2). В программном комплексе предусмотрена возможность ввода параметров, описывающих ограничения (3), (4) на допустимые значения соответственно фазового вектора и вектора управляющих воздействий системы, а также количества периодов времени для реализации рассматриваемого конкретного процесса управления. Решение задачи прогнозирования состояний динамической системы основывается на *общем рекуррентном алгебраическом методе построения областей достижимости* (Шориков А.Ф. [4]) линейных дискретных управляемых систем и сводится к реализации конечной последовательности решений только одношаговых задач линейного математического программирования и алгебраических операций над векторами в \mathbf{R}^n и \mathbf{R}^p . Алгоритм решения каждой конкретной задачи оптимального

программного управления рассматриваемым процессом основывается на *методе прямых и обратных конструкций* (Шориков А.Ф. [4]) и сводится к реализации конечной последовательности решений только одношаговых задач линейного математического программирования, конечной последовательности операций над многогранниками-компактами в \mathbf{R}^n и алгебраических операций над векторами в \mathbf{R}^n и \mathbf{R}^p . Решение каждой конкретной задачи оптимального адаптивного управления рассматриваемым процессом основывается на последовательном решении соответствующих вспомогательных задач оптимального программного управления для используемой экономико-математической модели (2) – (5). Выходными результатами решения задачи 1 – прогнозирования состояний динамической системы (2) – (4), является множество ее финальных фазовых векторов в виде многогранника-компакта, а выходными результатами для задач 2 и 3 – оптимального программного и адаптивного управления – оптимальные значения соответствующих управлений и целевых функций.

Перечислим функции основных модулей программного комплекса.

Модуль А (Интерфейс) – реализует интеллектуальный пользовательский интерфейс для выбора конкретной задачи, настройки входных данных, решения задачи и вывода данных, в удобной для пользователя форме.

Модуль 1 (Прогнозирование) – реализует настройку входных данных для конкретной задачи 1, решение задачи и вывод данных, в удобной для пользователя форме.

Модуль 2 (Программное управление) – реализует настройку входных данных для конкретной задачи 2, решение задачи и вывод данных, в удобной для пользователя форме.

Модуль 3 (Адаптивное управление) – реализует настройку входных данных для конкретной задачи 3, решение задачи и вывод данных, в удобной для пользователя форме.

Отметим, данный программный комплекс можно дополнять другими программными модулями и реализовать его сопряжение с различными корпоративными информационными системами. В настоящее время интеллектуальный программный комплекс «Компьютерное моделирование решения задач прогнозирования и оптимизации управления производством продукции предприятия» находится в опытной эксплуатации.

Заключение. В работе представлено описание используемой в интеллектуальном программном комплексе дискретной управляемой динамической экономико-математической модели при наличии векторной целевой функции для оценки качества реализации рассматриваемого процесса управления производством продукции предприятия, структура программного комплекса, функции его основных модулей и описание пользовательского интерфейса. Основные модули программного комплекса позволяют моделировать решение задач прогнозирования состояния модели, оптимизации программного и адаптивного управления производством продукции предприятия. Данный программный комплекс может использоваться в качестве

инструментального средства для поддержки принятия управленческих решений менеджерами предприятия с целью оптимизации и совершенствования управления производством продукции.

Работа выполнена в соответствии с Планом НИР Института экономики УрО РАН.

Библиографический список

1. Шориков А.Ф., Рассадина Е.С. Многокритериальная оптимизация формирования ассортимента продукции предприятия // Экономика региона. 2010. №2 (22). С. 189-196.
2. Шориков А.Ф., Рассадина Е.С. Динамическая оптимизация комплексного программного управления структурой товарного ассортимента предприятия // Экономика региона. 2012. №3 (31). С. 261-271.
3. Шориков А.Ф., Рассадина Е.С. Динамическая оптимизация комплексного адаптивного управления структурой товарного ассортимента предприятия // Экономика региона. 2013. № 2(34). – С. 176-184.
4. Шориков А.Ф. Минимаксное оценивание и управление в дискретных динамических системах. Екатеринбург: Изд-во Урал. ун-та, 1997.
5. Макаров В.Л. Обзор математических моделей экономики с инновациями // тематические методы. 2009. Т. 45. № 1. С. 3-14.
6. Клейнер Г.Б., Рыбачук М.А. Системная сбалансированность экономики. М: Издательский дом «Научная библиотека», 2017.

INTELLIGENT SOFTWARE COMPLEX FOR MODELING OPTIMIZING OF CONTROL OF THE PRODUCTION OF AN ENTERPRISE'S PRODUCTS

Shorikov Andrey F.

Institute of Economics of the Ural Branch of the RAS

Str. Moskovskaya, 29, Ekaterinburg, Russia, 620014,

afshorikov@mail.ru

The article presents a description of the structure and functions of an intelligent computer software complex that allows users to simulate the optimization of the production of the enterprise's products. In the article describes the discrete-time dynamical model used in the software complex in the presence of a vector objective function to estimation the implementation quality of the process under consideration, the structure of the software complex, the functions of its main modules and a description of the user interface. The main modules of the software complex allow users to simulate the solution of the problems of forecasting the state of the model, and optimizing of program and adaptive control of the production of the enterprise's products.

Keywords: intelligent software complex, dynamical model, forecasting problem, optimization, program control, adaptive control.

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В ПЕДАГОГИКЕ

НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗИРОВАНИЯ ПОСТУПЛЕНИЯ АБИТУРИЕНТА В ВУЗ «ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Быков Иван Владимирович, Колтырина Елена Константиновна

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
vanka.perm@mail.ru

В статье представлено описание разработки нейросетевой системы для прогнозирования поступления абитуриента в вуз «Высшая Школа Экономики» на направление «Бизнес-информатика» в г.Пермь. Система позволяет выполнять прогнозирование поступления в вуз с учетом результата сдачи ЕГЭ и индивидуальных достижений.

Ключевые слова: искусственный интеллект, нейросетевые технологии, поступление в вуз, абитуриент, прогнозирование, результаты ЕГЭ, аттестат, студент, высшее образование.

Введение.

При отборе абитуриентов в вуз, требуется оценить шансы каждого из будущих студентов на поступление на желаемое направление. Обычно этим занимается приемная кампания вуза, но как правило, такой подход подвержен влиянию человеческого фактора, например, можно не учесть какой-либо критерий и по ошибке не зачислить ученика, у которого на это есть все шансы. Или наоборот, посмотреть не туда и выбрать ученика, у которого недостаточно баллов и достижений для поступления на выбранное направление. Каждый год очень много людей желают поступить в вуз, поэтому создаются большие базы данных, в которых человеку легко запутаться. Поэтому нейронная сеть для отбора студентов будет очень полезной вещью для вузов и других учебных заведений.

В результате анализа отбора учеников в 2020 году и литературных источников [1-8], был выбран следующий набор показателей: X₁ – наличие оригинала аттестата, X₂ – баллы за ЕГЭ по математике, X₃ – баллы за ЕГЭ по иностранному языку, X₄ – баллы за ЕГЭ по русскому языку, X₅ – баллы за индивидуальные достижения. Выходной параметр D₁ – вероятность поступления абитуриента в вуз. В отличие от работы [8] мы не стали брать такие параметры как наличие компьютера дома, посещение подготовительных курсов и самостоятельность принятия решения о поступлении, так как эти данные не влияют на результат поступления в вуз.

Множество данных об абитуриентах было собрано с сайта Высшей Школы Экономики [7]. Объем итогового множества включает в себя 160

примеров. Данное множество было разделено на обучающее и тестирующее в соотношении 88% и 12% соответственно. Собранные данные охватывают период июнь-август 2020 года.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор» [5] по методике [6]. В результате оптимизации спроектированная нейронная сеть представляла собой персепtron, который имеет шесть входных нейронов, один выходной и один скрытый слой с тремя нейронами.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 20 примеров. Средняя ошибка тестирования составила 11.22%, что можно считать приемлемым результатом. На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактической и прогнозируемой нейросетью вероятность поступления случайно отобранных 7 абитуриентов из тестирующего множества.

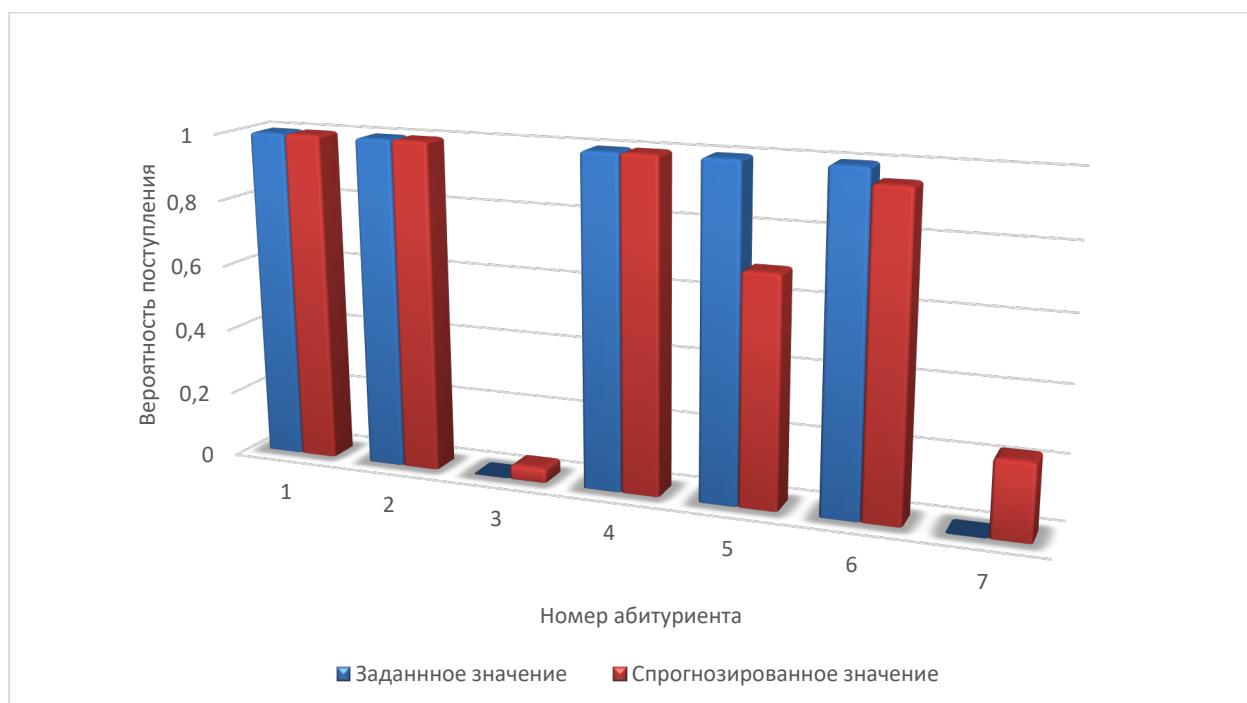


Рисунок 1. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 1, можно сделать вывод об адекватной работе спроектированной нейронной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор», результат отображен на рисунке 2.

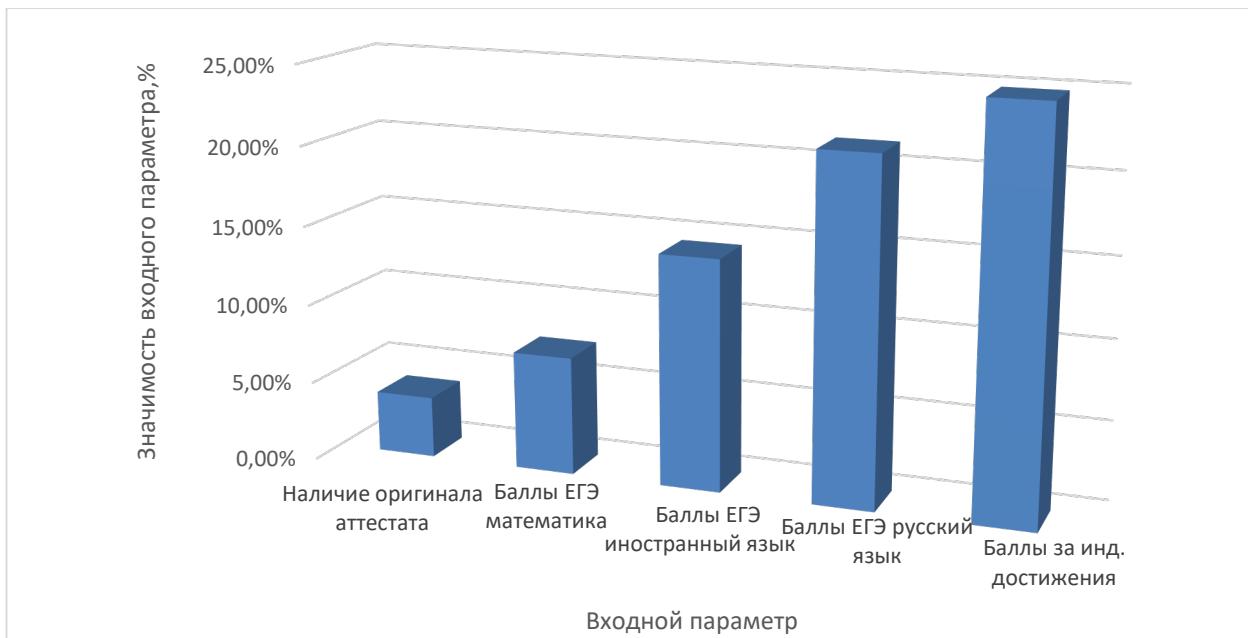


Рисунок 2. Значимость входных параметров нейросетевой модели

Как видно из рисунка 2, наиболее значимыми являются баллы за индивидуальные достижения, далее идут баллы за отдельные предметы и в конце наличие оригинала аттестата.

Далее было проведено исследование влияния наличия оригинала аттестата. Исследование производилось с помощью метода «замораживания» [6], суть которого заключается в варьировании значения одного параметра и фиксировании значений всех других параметров. Данный метод позволяет выявить влияние исследуемого параметра на выходной. Для этой цели были отобраны 2 абитуриента, информация о параметрах которых отражена в таблице 1.

Таблица 1
Характеристики абитуриентов,
выбранных для исследования

№ Абитуриента	Баллы за ЕГЭ по математике	Баллы за ЕГЭ по иностранному языку	Баллы за ЕГЭ по русскому языку	Баллы за индивидуальные достижения
1	81	82	82	5
2	76	81	87	5

На рисунке 3 показан график зависимости вероятности поступления абитуриента от наличия оригинала аттестата. Как следует из графика, наличие оригинала аттестата дает большую вероятность поступления.

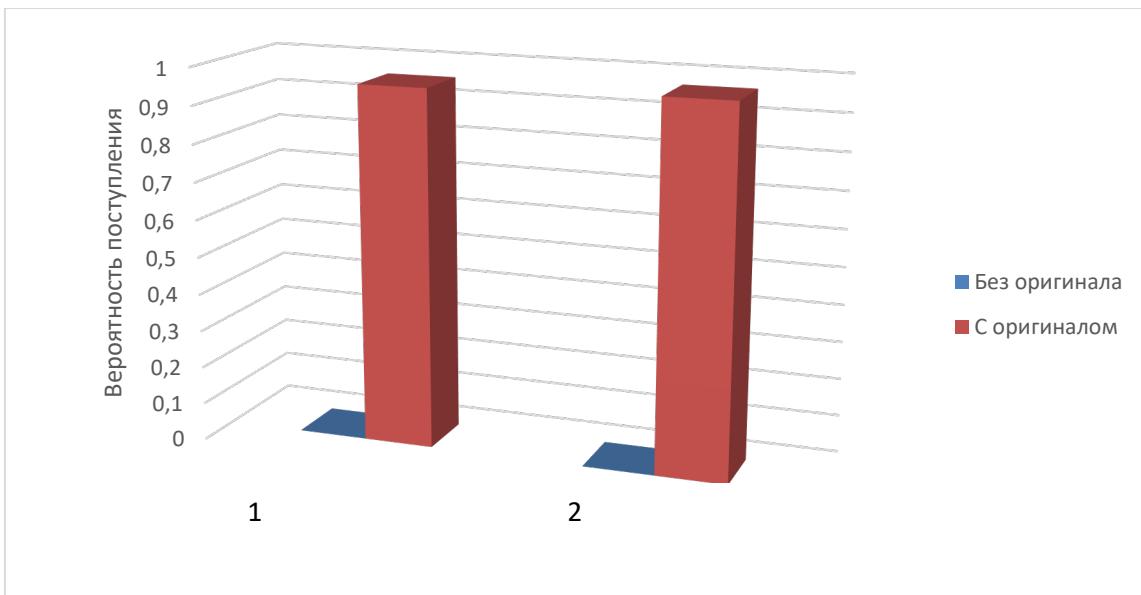


Рисунок 3. Зависимость вероятности поступления от наличия оригинала аттестата

Далее было проведено исследование влияния индивидуальных достижений. Для этой цели были отобраны 5 абитуриентов, информация о параметрах которых отражена в таблице 2.

Таблица 2
Характеристики абитуриентов, выбранных для исследования

№ абитуриента	Наличие оригинала аттестата	Баллы за ЕГЭ по математике	Баллы за ЕГЭ по иностранному языку	Баллы за ЕГЭ по русскому языку
1	1	89	71	90
2	1	85	78	83
3	1	79	81	84
4	1	100	75	69
5	1	62	83	98

Для каждого абитуриента были заморожены его параметры и изменялось количество баллов за индивидуальные достижения.

На рисунке 4 показан график зависимости вероятности поступления абитуриента от его индивидуальных достижений. Как следует из графика, наличие дополнительных баллов за индивидуальные достижения увеличивает вероятность поступления.

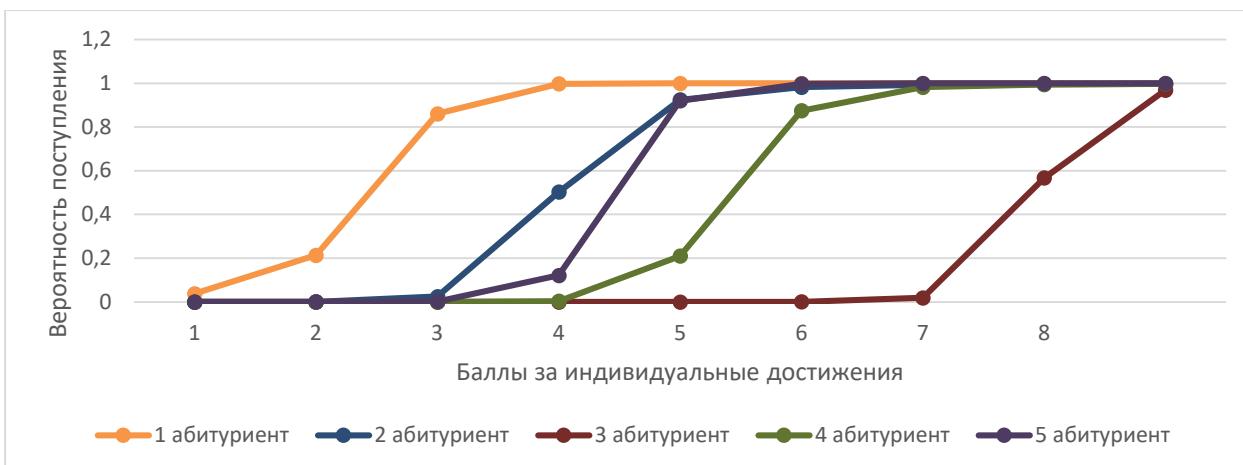


Рисунок 4. Зависимость вероятности поступления от индивидуальных достижений

Далее было проведено исследование влияния баллов ЕГЭ по каждому предмету отдельно. Для этой цели были отобраны 5 абитуриентов, информация о параметрах которых отражена в таблице 3.

Таблица 3
Характеристики абитуриентов, выбранных для исследования

№ абитуриента	Наличие оригинала аттестата	Баллы за ЕГЭ по иностранному языку	Баллы за ЕГЭ по русскому языку	Баллы за индивидуальные достижения
1	1	69	98	0
2	1	93	71	0
3	1	80	80	0
4	1	72	84	0
5	1	95	93	0

На рисунке 5 показан график зависимости вероятности поступления абитуриента от количества баллов ЕГЭ по математике. Как следует из графика, увеличение количества баллов по математике увеличивает вероятность поступления.

Сопоставляя полученные данные, наблюдается следующая тенденция: чем больше у абитуриента баллов за другие достижения, тем меньше баллов для поступления ему нужно за ЕГЭ по математике.

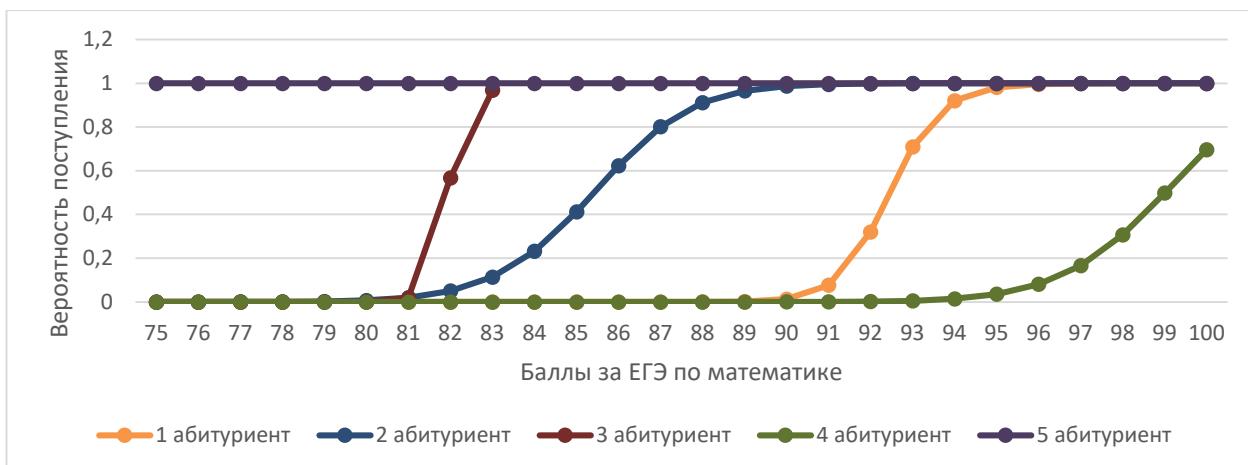


Рисунок 5. Зависимость вероятности поступления от баллов по математике

Таблица 4
Характеристики абитуриентов,
выбранных для исследования

№ абитуриента	Наличие оригинала аттестата	Баллы за ЕГЭ по математике	Баллы за ЕГЭ по русскому языку	Баллы за индивидуальные достижения
1	1	69	98	0
2	1	92	72	0
3	1	80	80	0
4	1	67	89	0
5	1	70	82	0

На рисунке 6 показан график зависимости вероятности поступления абитуриента от количества баллов ЕГЭ по иностранному языку. Как следует из графика, увеличение количества баллов по иностранному языку увеличивает вероятность поступления.

Сопоставляя полученные данные, наблюдается следующая тенденция: чем больше у абитуриента баллов за другие достижения, тем меньше баллов для поступления ему нужно за ЕГЭ по иностранному языку.

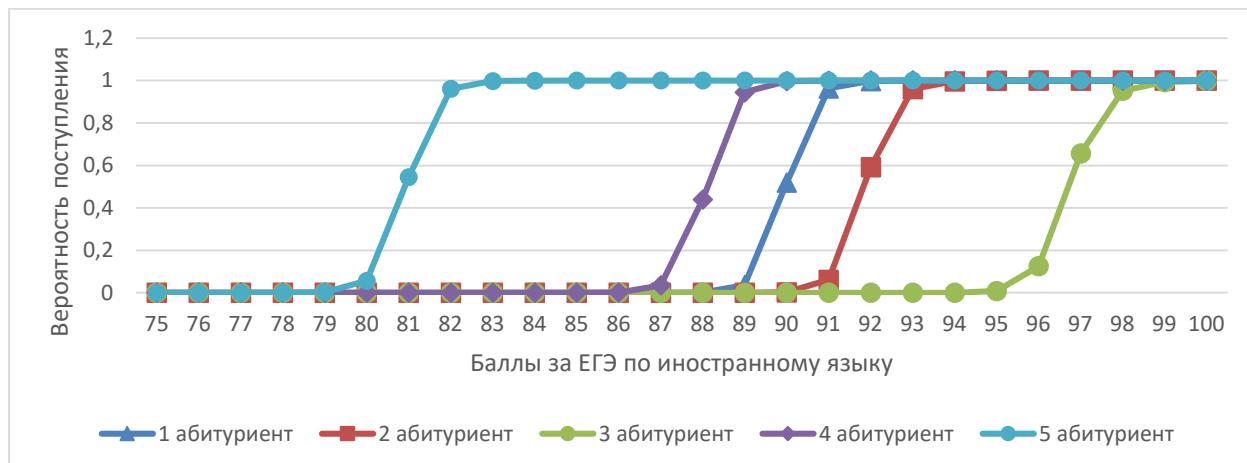


Рисунок 6. Зависимость вероятности поступления от баллов по иностранному языку

Таблица 5

Характеристики абитуриентов, выбранных для исследования

№ абитур иента	Наличие оригинала аттестата	Баллы за ЕГЭ по математике	Баллы за ЕГЭ по иностранному языку	Баллы за индивидуальные достижения
1	1	81	82	0
2	1	80	80	0
3	1	98	61	0
4	1	67	89	0
5	1	76	75	0

На рисунке 7 показан график зависимости вероятности поступления абитуриента от количества баллов ЕГЭ по русскому языку. Как следует из графика, увеличение количества баллов по русскому языку увеличивает вероятность поступления.

Сопоставляя полученные данные, наблюдается следующая тенденция: чем больше у абитуриента баллов за другие достижения, тем меньше баллов для поступления ему нужно за ЕГЭ по русскому языку.

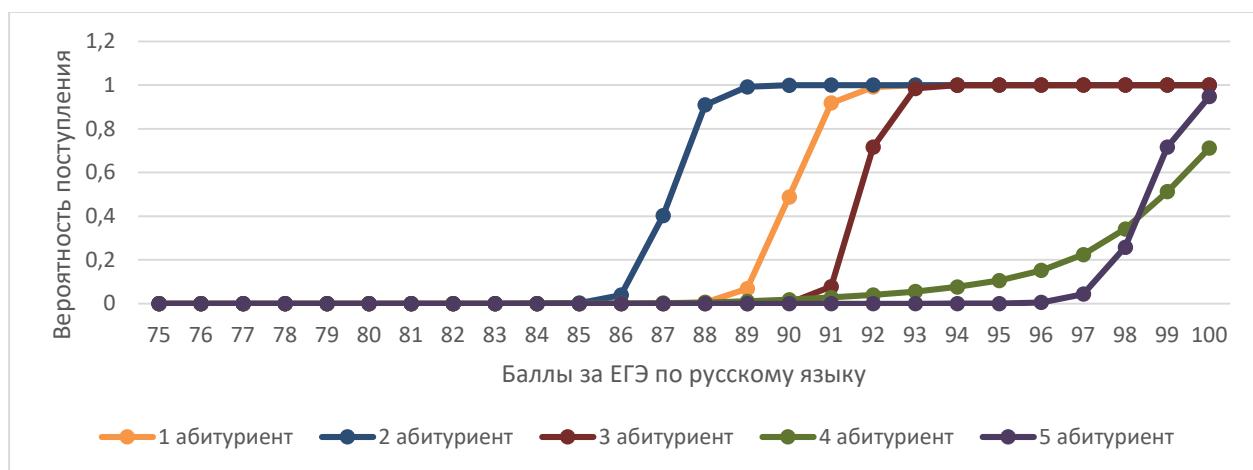


Рисунок 7. Зависимость вероятности поступления от баллов по русскому языку

Полученные результаты исследований не противоречат реальности, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для прогнозирования вероятности поступления в Высшую Школу Экономики на направление «бизнес-информатика»

Заключение. Построена система нейросетевого оценивания вероятности поступления абитуриента в Высшую Школу Экономики на направление «бизнес-информатика».

Спроектированная нейросетевая модель учитывает три показателя, влияющих на вероятность поступления: наличие оригинала аттестата, баллы за ЕГЭ и индивидуальные достижения ученика. Методом сценарного прогнозирования построены графики зависимостей вероятности поступления в вуз от наличия оригинала аттестата и индивидуальных достижений.

Библиографический список

1. Ясницкий Л.Н., Кузнецов А.Г., Селезнева С.М., Солохина А.Д., Тюлькина Д.В., Черепанов Ф.М. Применение нейросетевых технологий в изучении акмеологического потенциала студентов вуза // Вестник Пермского университета. Серия: Математика. Механика. Информатика. 2014. № 4. С.120-126.
2. Ясницкий Л.Н. Интеллектуальные информационные технологии и системы. Пермь: Пермский университет, 2007. 271 с.
3. Ko L.-J., Blocher E.J., Lin P.P. Prediction of corporate financial distress: An application of the composite rule induction system // The International Journal of Digital Accounting Research. 2009. Vol. 1, No. 1. P. 69-85. 5. Coats P.K., Fant L.F. Recognizin.
4. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
5. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.
6. Официальный сайт Высшей школы экономики <https://www.hse.ru>
7. Система прогнозирования поступления абитуриента в вуз Курсовая работа <http://5fan.ru/wievjob.php?id=10753>

NEURAL NETWORK SYSTEM FOR ECASTING ADMISSION OF AN ADMISSION TO THE UNIVERSITY "HIGHER SCHOOL OF ECONOMICS"

Bykov Ivan V., Koltyrina Helen K.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990

The article describes the development of a neural network system for predicting the admission of an applicant to the Higher School of Economics in the direction of Business Informatics in Perm. The system makes it possible to predict admission to a university, taking into account the result of passing the exam and individual achievements.

Keywords: artificial intelligence, neural network technologies, admission to a university, applicant, forecasting, USE results, certificate, student, higher education.

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В ДЕМОГРАФИИ

НЕЙРОСЕТЕВАЯ СИСТЕМА ОЦЕНКИ ТЕКУЩЕГО ПОЛОЖЕНИЯ СЕМЬИ ДЛЯ ЗАВЕДЕНИЯ ПЕРВОГО РЕБЕНКА

Гладких Екатерина Алексеевна, Черемных Александра Николаевна
Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
katya.myr.23@yandex.ru

В статье представлено описание разработки нейросетевой системы для оценки и прогнозирования текущего положения семьи для заведения первого ребенка. Система позволяет выполнять оценку положения семьи с учетом географических, финансовых, биологических и социальных показателей. Использование данных параметров позволяет сделать систему адаптируемой к каждой исследуемой семье.

Ключевые слова: искусственный интеллект, нейросетевые технологии, оценка положения, прогнозирование, семья, первый ребёнок.

Введение. При планировании рождения первого ребенка необходимо взвесить положение семьи и создать наиболее благоприятные условия для ее комфортной жизни и достаточно легкого воспитания ребенка. Данные последних лет показывают, что люди не задумываются о том, почему они хотят завести детей, и какие будут последствия после их рождения. Если будущие родители полностью не осознали ответственность данного решения, то, возможно, их ребенок не будет достаточно счастлив и, скорее всего, будет неправильно развиваться. Вот почему имеет смысл обратиться к помощи специалиста для определения моральной готовности к рождению малыша, а также оценить другие внутренние и внешние факторы.

Самостоятельная оценка положения подвержена влиянию человеческого фактора, например, можно не учесть какой-либо критерий и/или сформировать некорректный результат. Поэтому для объективного оценивания можно воспользоваться интеллектуальными системами [1].

Основная цель настоящей работы заключается в сборе множества о положении семей в период рождения первого ребенка, а также в создании и обучении нейросетевой модели [2] на этих данных. Результатом этого исследования является система оценки текущего положения семьи.

Авторы статьи [3] предложили следующие факторы для оценивания: эмоциональная готовность, жилая площадь, финансовое положение, внешняя помощь и готовность мужчины стать отцом.

В результате анализа вышеупомянутой работы [3] и других литературных источников [4-8] был выбран следующий набор показателей: X1 – возраст женщины, X2 – возраст мужчины, X3 – наличие гражданского брака, X4 – наличие продуктового магазина вблизи места проживания, X5 – наличие больницы вблизи места проживания, X6 – наличие детского сада вблизи места проживания, X7 – наличие собственного жилья, X8 – количество комнат в месте проживания, X9 – состояние здоровья женщины, X10 – состояние здоровья мужчины, X11 – употребление алкоголя женщиной, X12 – употребление алкоголя мужчиной, X13 – стабильная заработка плата, X14 – финансовое положение, X15 – наличие финансовой помощи, X16 – наличие моральной помощи, X17 – наличие помощи в воспитании. Выходной параметр D1 – уровень сложности жизни семьи после рождения первого ребенка.

Некоторые из параметров были закодированы следующим образом:

- параметр наличие гражданского брака: 0 – партнёры живут отдельно, 1 – партнёры сожительствуют, 2 – партнёры состоят в гражданском браке.
- параметры наличие продуктового магазина/детского садика/больницы вблизи места проживания, наличие собственного жилья, наличие стабильного заработка, финансовая/моральная помощи, а также помощь в воспитании: 0 – не было, 1 – было.
- параметры состояние здоровья женщины/мужчины: 0 – плохое, 1 – не очень хорошее, 2 – хорошее, 3 – отличное.
- параметры употребление алкоголя женщиной/мужчиной: 0 – употребляет каждый день, 1 – употребляет не только по праздникам, 2 – употребляет только по праздникам, 3 – не употребляет.
- параметр финансовое положение: 0 – денег недостаточно для полноценного питания, 1 – денег хватало только на еду, 2 – денег хватало на еду и оплату жилья (ЖКХ, аренда и др.), 3 – денег хватало на еду, оплату жилья и одежду, 4 – денег хватало на еду, оплату жилья, одежду и бытовую технику, 5 – денег хватало на всё.

Остальные параметры, такие как возраст женщины/мужчины и количество комнат являются числовыми, поэтому для них кодировка не требуется.

Выходной параметр уровень сложности жизни семьи после рождения первого ребенка был закодирован следующим образом: 1 – легко, 2 – скорее легко, чем сложно, 3 – скорее сложно, чем легко, 4 – сложно.

Множество входных данных о положениях семей различных социальных групп в период рождения первого ребенка было собрано при помощи созданного нами опроса [9]. Перед переходом к проектированию и обучению нейросетевой модели [2], была выполнена очистка исходного множества от противоречивых примеров, выбросов, дубликатов [1]. Например, некорректными примерами считались те, где субъективная оценка опрашиваемого об их общем положении семьи противоречила с объективной оценкой, характеризующейся общепринятыми нормами и этикой. Таким образом, объем итогового множества включает в себя 57 примеров. Данное множество было разделено на обучающее, тестирующее и подтверждающее в соотношении 75%, 18% и 7% соответственно. Собранные данные охватывают период 1995-2015 гг.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [10] по методике [11]. В результате оптимизации спроектированная нейронная сеть представляла собой персепtron, который имеет семнадцать входных нейронов, один выходной и один скрытый слой с четырьмя нейронами.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 10 примеров. Средняя ошибка тестирования составила 18.2%, что можно считать приемлемым результатом.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5» [10], результат отображен на рисунке 1.

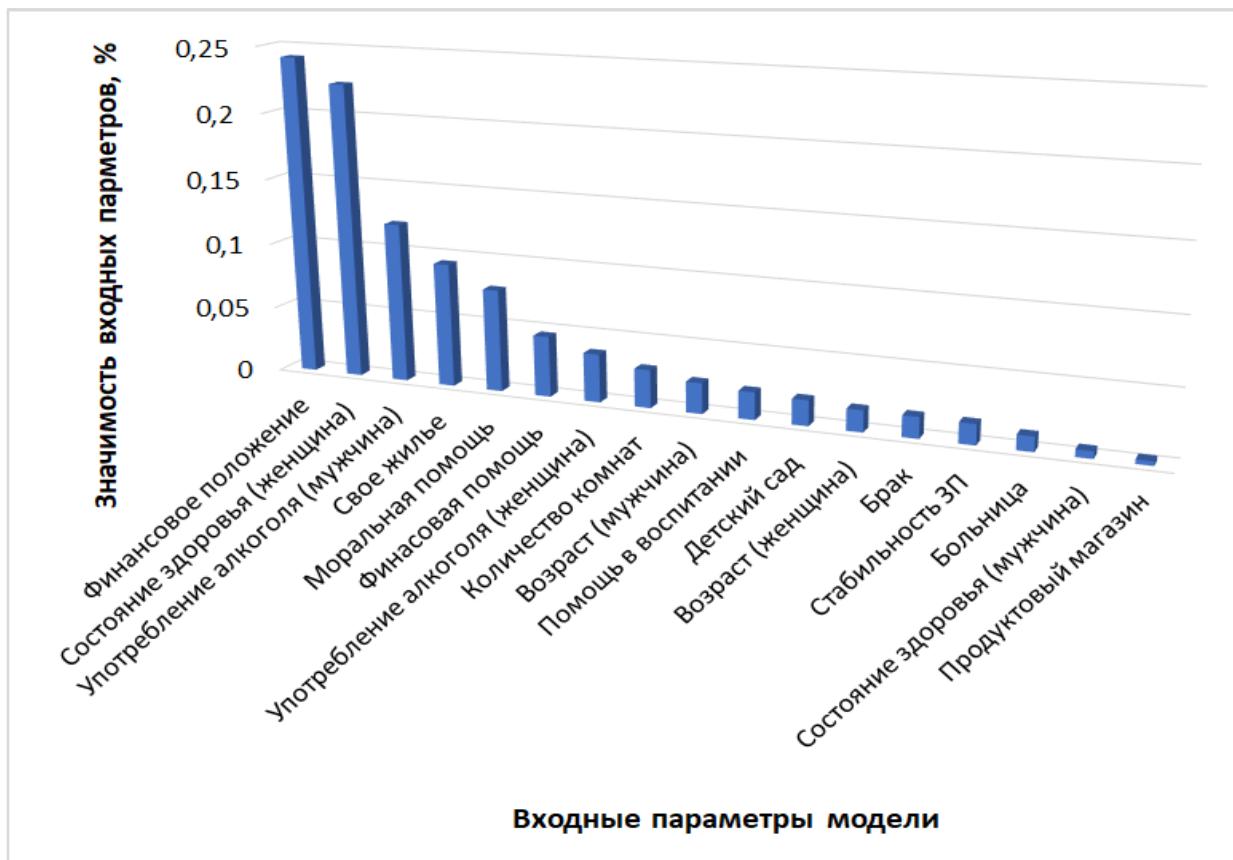


Рисунок 1. Значимость входных параметров нейросетевой модели

Как видно из рисунка 1, наиболее значимыми параметрами являются финансовое положение, состояние здоровья женщины, употребление алкоголя мужчиной, наличие собственного жилья, наличие моральной помощи и т.д. Также на графике можно видеть ряд параметров, которые имеют близкую к нулевой значимость, такие как состояние здоровья мужчины и наличие продуктового магазина вблизи места проживания. Это можно объяснить тем, что на текущем собранном множестве, данные параметры имеют приблизительно одинаковое значение.

Далее было проведено исследование положения различных семей. Исследование производилось с помощью метода «замораживания» [11], суть которого заключается в варьировании значения одного параметра и

фиксированием значений всех других параметров. Данный метод позволяет выявить влияние исследуемого параметра на выходной.

Для исследования влияния финансового положения, возрастов женщины и мужчины, состояния здоровья женщины и мужчины, а также частоты употребления алкоголя женщиной и мужчиной был взят следующий пример:

Таблица 1
Характеристика семьи,
выбранной для исследования

Входной параметр	Расшифровка	Значение
X1	Возраст женщины	20
X2	Возраст мужчины	20
X3	Наличие гражданского брака	2
X4	Наличие продуктового магазина вблизи ПМЖ	1
X5	Наличие больницы вблизи ПМЖ	1
X6	Наличие детского сада вблизи ПМЖ	1
X7	Наличие собственного жилья	1
X8	Количество комнат в ПМЖ	3
X9	Состояние здоровья женщины	2
X10	Состояние здоровья мужчины	2
X11	Употребление алкоголя женщиной	3
X12	Употребление алкоголя мужчиной	3
X13	Стабильная заработная плата	0
X14	Финансовое положение	3
X15	Наличие финансовой помощи	1
X16	Наличие моральной помощи	1
X17	Наличие помощи в воспитании	1

*При прогнозировании параметры X4 – X7, X15-X17 были занулены для того, чтобы они никак не влияли на значение выходного параметра.

На рисунке 2 показан график зависимости уровня сложности жизни после рождения первого ребенка от финансового положения. Как следует из графика, чем выше уровень финансового положения, тем легче будет после рождения ребенка.

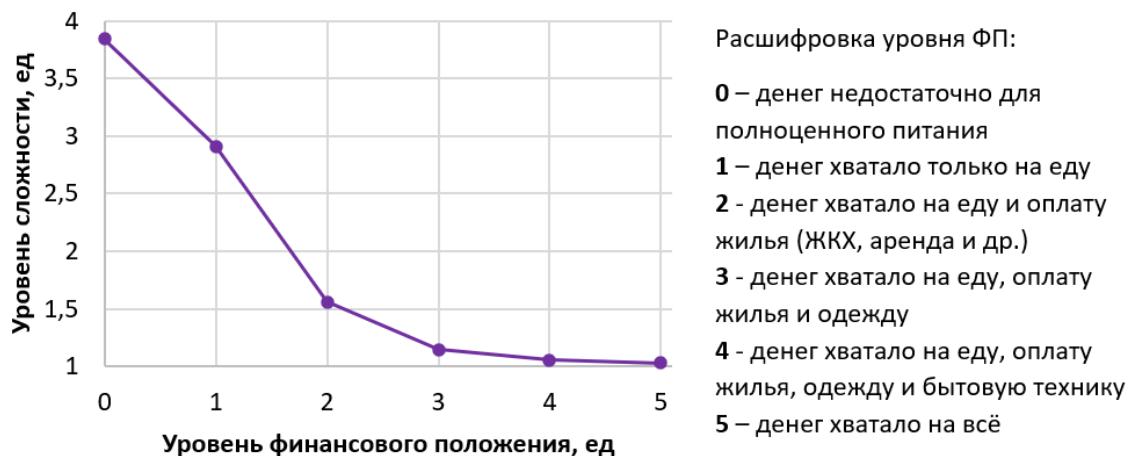


Рисунок 2. Зависимость уровня сложности жизни после рождения первого ребенка от финансового положения

На рисунке 3 продемонстрированы зависимости уровня сложности жизни после рождения первого ребенка от возраста женщины и возраста мужчины. В случае с увеличением возраста мужчины график изменяется сильнее, так как на данном множестве этот параметр является более значимым.

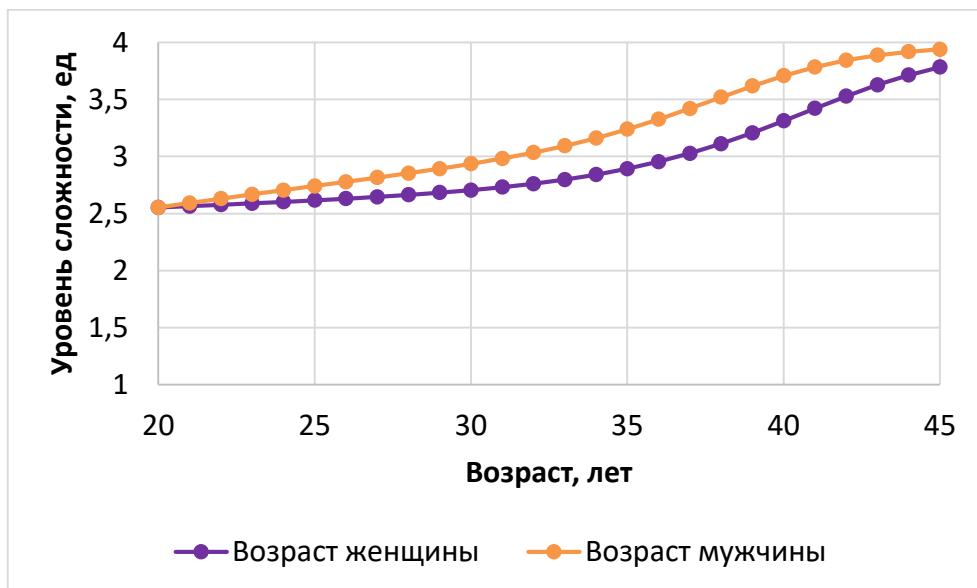


Рисунок 3. Зависимость уровня сложности жизни после рождения первого ребенка от возраста женщины и мужчины

На рисунке 4 изображен график зависимости уровня сложности жизни после рождения первого ребенка от состояния здоровья женщины и мужчины. В случае с женщиной прослеживается тенденция к снижению уровня сложности при улучшении состояния здоровья. В случае с мужчиной уровень сложности практически не изменяется. Это можно объяснить тем, что на нашем собранном множестве параметр здоровье мужчины не является значимым.

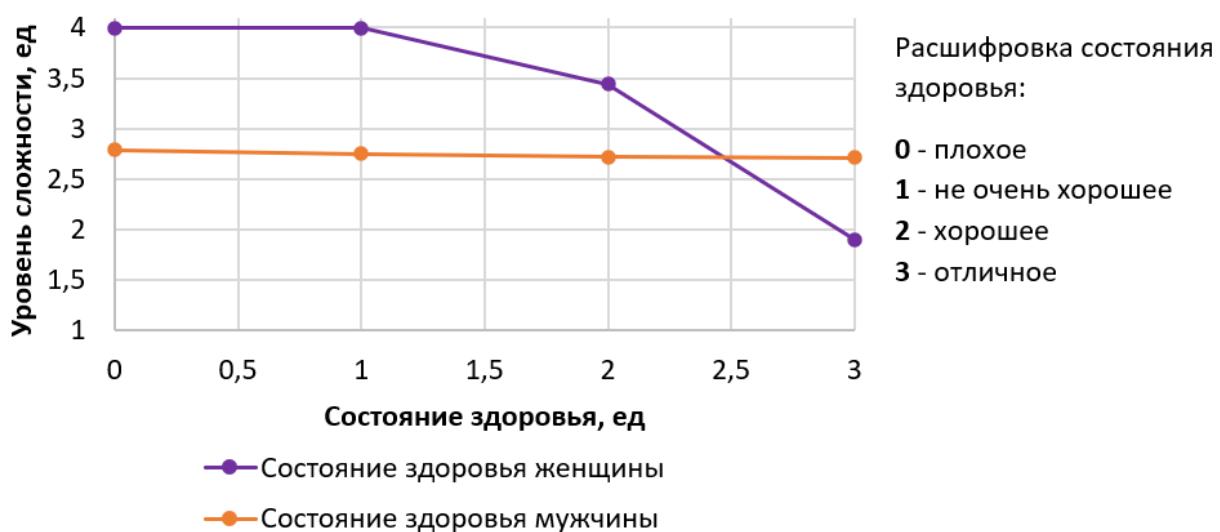


Рисунок 4. Зависимость уровня сложности жизни после рождения первого ребенка от состояния здоровья женщины и мужчины

На рисунке 5 продемонстрирован график зависимости уровня сложности жизни после рождения первого ребенка от частоты употребления алкоголя женщиной и мужчиной. Как видно из графика, снижение частоты употребления алкоголя уменьшает уровень сложности воспитания ребенка и жизни в целом. График мужчины изменяется сильнее, так как на данном множестве его параметр является более значимым.

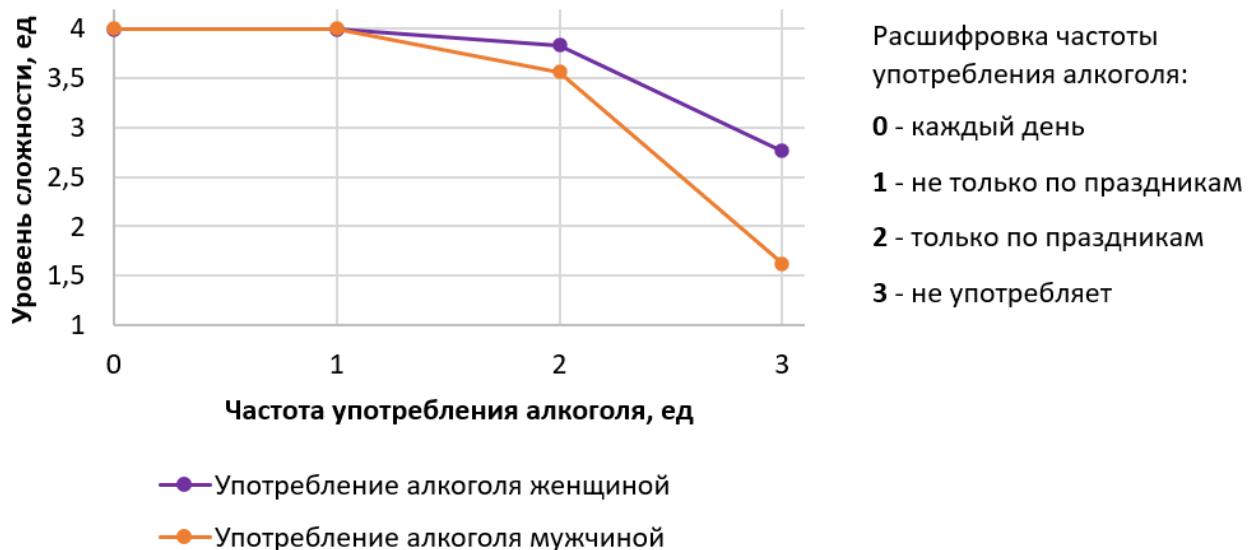


Рисунок 5. Зависимость уровня сложности жизни после рождения первого ребенка от частоты употребления алкоголя женщиной и мужчиной

Полученные результаты исследований не противоречат реальности, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для оценки уровня благоприятности текущего положения семьи для заведения первого ребенка.

Заключение. Построена система нейросетевого оценивания текущего положения семьи для заведения первого ребенка. Спроектированная нейросетевая модель учитывает четыре категории показателей, влияющих на уровень благоприятности: географические, финансовые, биологические и социальные. Проведены исследования множества данных о положениях семей различных социальных групп в период рождения первого ребенка. Методом сценарного прогнозирования построены графики зависимостей уровня сложности жизни после рождения первого ребенка от финансового положения, от возраста женщины и возраста мужчины, от состояния здоровья женщины, а также от частоты употребления алкоголя мужчиной. Применение такого набора параметров в модели позволяет учитывать внешние факторы, даже если они изменяются с течением времени, а также в дальнейшем она может быть расширена для оценки текущего положения семьи для заведения последующих детей.

Библиографический список

1. Ясницкий Л.Н. Интеллектуальные системы. – М.: Лаборатория знаний, 2016.
2. Галушкин А.И. Нейронные сети: основы теории. М: Горячая линия–Телеком. 2012. 496 с.
3. Портал для любящих родителей “Я Ваша Кроха”. – URL: <https://razvitie-krohi.ru/beremennost/planirovanie-i-podgotovka/5-momentov-o-kotoryih-nuzhno-zadumatsya-pri-planirovaniyu-beremennosti.html>
4. Научно-образовательный портал IQ при “ВШЭ”. – URL: <https://iq.hse.ru/news/317281401.html>
5. Информационное агентство федерального уровня ТАСС. – URL: <https://tass.ru/obschestvo/8901099>
6. Human Fertility Database [Электронный ресурс]. – URL: <https://www.humanfertility.org/cgi-bin/main.php>
7. Центр демографических исследований Российской экономической школы – URL: http://demogr.nes.ru/index.php/ru/demogr_indicat/data
8. Демографический ежегодник России 2019, Росстат [Электронный ресурс]. – URL: <https://rosstat.gov.ru/folder/210/document/13207>
9. Электронная площадка для онлайн-опросов. – URL: https://docs.google.com/forms/d/e/1FAIpQLSeQQMiD-lAc_2B19NRMaIjD3og1grvGCOdGzdtV6oecbUuOQ/viewform
10. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
11. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.

NEURAL NETWORK SYSTEM FOR ASSESSING THE CURRENT SITUATION OF THE FAMILY FOR THE FIRST CHILD

Gladkikh Ekaterina A., Cheremnykh Alexandra N.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990

The article describes the development of a neural network system for assessing and predicting the current state of the family for the establishment of the first child. The system allows you to assess the position of the family, taking into account geographical, financial, biological and social indicators. The use of these parameters makes it possible to make the system adaptable to each studied family.

Keywords: artificial intelligence, neural network technologies, position assessment, forecasting, family, first child.

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В ЛИНГВИСТИКЕ

ПРОГНОЗИРОВАНИЕ ВОЗРАСТНОЙ АУДИТОРИИ ЧИТАТЕЛЕЙ НА ОСНОВЕ АННОТАЦИЙ ХУДОЖЕСТВЕННЫХ КНИГ

Глазкова Анна Валерьевна

Тюменский государственный университет, 625003, Россия, г. Тюмень,
ул. Володарского, 6, a.v.glazkova@utm.ru

Рассматривается задача автоматического определения возрастной аудитории художественной книги на основании текста ее аннотации. Качество оценивается с помощью трех базовых классификаторов: логистической регрессии, линейного метода опорных векторов и нейросетевого метода, использующего модель BERT. Показано, что использование аннотаций в качестве обучающих данных позволяет улучшить качество классификации на основании возрастных рейтингов.

Ключевые слова: классификация текстов, возрастной рейтинг, художественная литература, удобочитаемость, BERT.

Проблема возрастной классификации текстов является чрезвычайно актуальной, так как инструменты для ее решения являются основой для создания множества практических приложений. Так, электронные библиотеки и каталоги выполняют категоризацию книг на адресованные взрослому и детскому читателю, а также осуществляют подбор книг, предназначенных определенной возрастной аудитории. Системы электронного обучения имеют одной из своих задач подбор литературы, соответствующей уровню интеллектуального и коммуникативного развития обучающихся. Кроме того, с 1 сентября 2012 года на территории Российской Федерации действует закон, регулирующий доступ детей к информации, причиняющей вред их здоровью и развитию [1]. На основании этого закона любая печатная или электронная книжная продукция должна быть промаркована возрастной меткой в соответствии со степенью безопасности содержащейся в ней информации. Инструменты, выполняющие возрастную классификацию текстов, могут найти применение в онлайн-библиотеках для фильтрации релевантных документов, в издательских системах для ранжирования и классификации текстов, в рекомендационных системах для адекватного подбора литературы на основании заданных читателем характеристик.

Возрастная классификация текстов является слабоформализуемой научной задачей, требующей использования размеченных экспертами текстовых

Работа выполнена при финансовой поддержке гранта №МК-637.2020.9 Президента Российской Федерации для поддержки молодых ученых – кандидатов наук.

© Глазкова А.В., 2021

корпусов. В случае анализа художественной литературы речь идет, как правило, о достаточно больших объемах текстов, обработка которых является нетривиальной задачей для современных лингвистических моделей. Текст художественной книги часто сопровождается аннотацией, составленной автором или редактором. Аннотация представляет собой краткую характеристику книги, ее своеобразное резюме, представляющее собой синтез литературного и продающего текста [2]. По своей форме аннотация художественной книги является достаточно коротким текстом – обычно не больше 200 слов, что позволяет анализировать ее при помощи компьютерных средств с использованием минимальной предварительной обработки.

Целью данной работы является оценка качества прогнозирования возрастной аудитории художественной книги на основе ее аннотации. Автор рассматривает три задачи классификации: 1) классификация художественных книг на взрослые и детские; 2) классификация художественных книг на содержащие информацию, запрещенную для распространения среди детей (имеющих метку 18+ в соответствии с российской системой возрастной классификации контента) и доступные для чтения детям различных возрастов; 3) прогнозирование возрастного рейтинга книги. Таким образом, первые две задачи имеют своей целью бинарную классификацию, третья задача – мультиклассовую.

Текстовый корпус

Для оценки эффективности использования аннотаций для прогнозирования возрастной аудитории книг использовался текстовый корпус, содержащий ознакомительные фрагменты (превью) художественных произведений на русском языке и полные тексты соответствующих им аннотаций⁴⁰ [3]. Корпус был составлен на основании фрагментов произведений, размещенных в открытом доступе на сайтах электронных библиотек в сети Интернет. Каждое художественное произведение в корпусе имеет двухуровневую возрастную разметку: 1) указание возрастной аудитории книги – взрослая или детская – в соответствии с разделом, в котором книга размещена в онлайн-библиотеке; 2) указание возрастного рейтинга в соответствии с российской системой возрастной классификации информационной продукции (в корпусе содержатся произведения, имеющие метки 6+, 12+, 16+ и 18+).

Во всех экспериментах использовалось одинаковое разбиение исходного корпуса на обучающую и тестовую выборки. Характеристики выборок приведены в таблице 1.

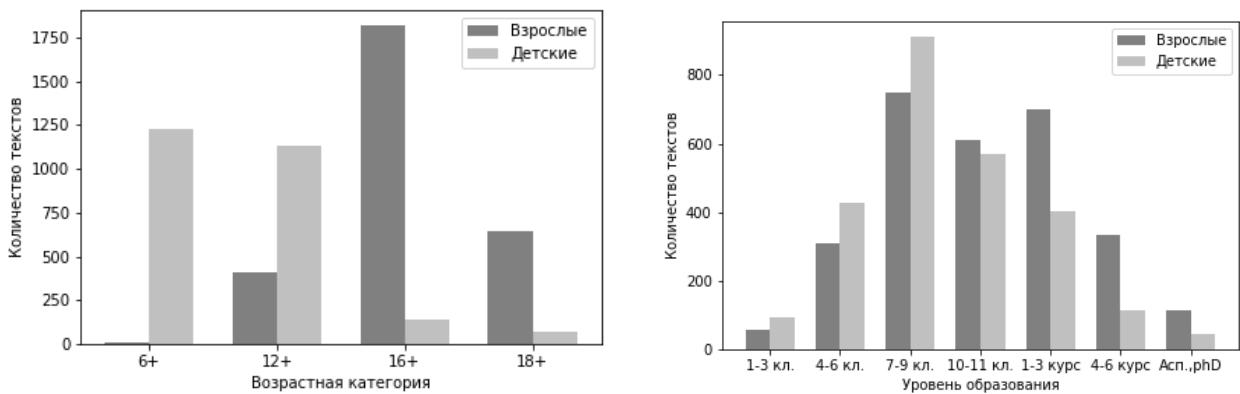
⁴⁰ <https://www.kaggle.com/oldaandozerskaya/fiction-corpus-for-agebased-text-classification>

Таблица 1
Характеристики текстового корпуса

Количество текстов			Средняя длина текстов (в токенах ⁴¹⁾		Среднее количество предложений	
Общее	По возрастным аудиториям	По возрастным категориям	Аннотации	Превью	Аннотации	Превью
Обучающая выборка						
4646	Взрослые	2688	6+	1038	106,38	13045,64
			12+	1340		
	Детские	1958	16+	1759		5,52
			18+	509		
Тестовая выборка						
800	Взрослые	189	6+	200	110,14	16905,4
			12+	200		
	Детские	611	16+	200		5,66
			18+	200		

На рисунке 1 показано распределение аннотаций взрослых и детских текстов по возрастным категориям сопровождаемых ими книг и уровню удобочитаемости самих аннотаций. Возрастные категории (возрастные рейтинги) получены на основании данных корпусной разметки. Значения индекса удобочитаемости рассчитаны при помощи формулы Колман-Лиау [4], адаптированной для русского языка в рамках проекта [5]. Значение индекса Колман-Лиау интерпретируется как минимальный уровень образования читателя, требуемый для понимания оцениваемого текста. В русскоязычной интерпретации предусмотрены следующие уровни образования: 1) 1-3-й класс (возраст примерно: 6-8 лет); 2) 4-6-й класс (возраст примерно: 9-11 лет); 3) 7-9-й класс (возраст примерно: 12-14 лет); 4) 10-11-й класс (возраст примерно: 15-16 лет); 5) 1-3 курсы вуза (возраст примерно: 17-19 лет); 6) 4-6 курсы вуза (возраст примерно: 20-22 лет); 7) аспирантура, второе высшее образование, PhD. В работах [7-8] показано, что показатели удобочитаемости являются значимыми признаками для определения уровня сложности текстов. В данной работе автор рассматривает показатели удобочитаемости не самих текстов художественных книг, а их аннотаций. В ряде исследований показано, что аннотации также ориентированы на потенциального читателя, как и сами тексты произведений. Так, для усиления воздействующей функции аннотации часто придается форма стилизации под жанры, прямо или косвенно связанные с сопровождаемой ей книгой [9]. При этом подчеркивается [10], что аннотации детских книг для младшего возраста адресованы, как правило, не детям, а их родителям.

⁴¹ Количество токенов и предложений определяется при помощи токенизатора NLTK [6].



**Рисунок 1. Распределение текстов в рамках возрастных аудиторий:
а) по возрастному рейтингу (слева); б) по необходимому для понимания
уровню образования (справа)**

Эксперименты

Для прогнозирования возрастной аудитории книг на основе их аннотаций применялись три базовых метода классификации, характеризующихся разными подходами, лежащими в их основе: а) логистическая регрессия (LR); б) линейный метод опорных векторов (Linear SVC); в) нейросетевой классификатор на основе настроенной (fine-tuned) лингвистической модели BERT (Bidirectional Encoder Representations from Transformers) [11].

В экспериментах использовалась реализация методов логистической регрессии и опорных векторов из библиотеки Scikit-learn [12]. Для обучения базовой версии классификатора, основанного на применении линейного метода опорных векторов, была построена модель bag-of-words (“мешок слов”) над множеством текстов. Модель построена на 10 000 наиболее частых лексем из корпуса текстов за исключением стоп-слов. Нейросетевой классификатор реализован на базе предварительно обученной версии модели BERT для русского языка RuBERT [13] с помощью библиотек Transformers [14] и PyTorch [15].

Качество моделей оценено на трех задачах возрастной классификации текстов: **задача 1:** классификация художественных книг на взрослые и детские; **задача 2:** классификация художественных книг на содержащие информацию, запрещённую для распространения среди детей (имеющих метку 18+ в соответствии с российской системой возрастной классификации контента) и доступные для чтения детям различных возрастов (имеющие метку, отличную от 18+); **задача 3:** прогнозирование возрастного рейтинга книги (6+, 12+, 16+, 18+).

Поскольку количество примеров различных категорий в обучающей выборке является несбалансированным, при обучении была использована техника случайного дублирования элементов миноритарных классов (random oversampling). Для оценки качества классификации на тестовой выборке использовалась взвешенные, то есть рассчитанные пропорционально представительству категорий в тестовой выборке, F1-мера, точность (precision) и полнота (recall).

Результаты базовых моделей сравнены с результатами моделей, использующих дополнительные признаки. В качестве дополнительных признаков использовались: 1) необходимый для понимания текста уровень образования (в соответствии с уровнем удобочитаемости, определенным по формуле Колман-Лиау); 2) для задачи 1 – возрастной рейтинг книги с соответствием с российской системой возрастной классификации информационной продукции; 3) для задач 2 и 3 – информация о возрастной аудитории книги. Для использования в классификаторах, основанных на логистической регрессии и линейном методе опорных векторов, дополнительные признаки были закодированы категориально (one-hot encoding), после чего была произведена конкатенация вектора дополнительных признаков текста с соответствующим ему вектором, полученным из модели bag-of-words. В нейросетевой модели информация о дополнительных признаках была добавлена к исходному тексту в виде строкового названия категории и отделена от основного текста дополнительным завершающим токеном: например, «[CLS] 4-6-й класс (возраст примерно: 9-11 лет) [SEP] Текст аннотации книги [SEP]», где “[CLS]” и “[SEP]” – стандартные открывающий и завершающий токены для входной текстовой последовательности в модели BERT.

Результаты, полученные для текстов аннотаций, сравнены с результатами моделей, обученных на текстах ознакомительных фрагментов (превью) книг. Как показано в таблице 1, ознакомительные фрагменты представляют собой достаточно крупные части исходного текста (как правило, 5-10% от полного текста произведения). Ввиду ограниченности используемых вычислительных ресурсов, а также из-за того, что максимальная длина входных данных для модели BERT имеет ограниченную длину, автор использовал в качестве ознакомительных фрагментов отрывки, состоящие из первых 500 токенов.

Таблица 2
Результаты, (F – F1-мера, P – точность, R – полнота, %)

Классификатор	Обучающие данные	Задача 1			Задача 2			Задача 3		
		F	P	R	F	P	R	F	P	R
LR	Аннотации	79,59	86,49	78	73,45	75,2	77,98	43,24	44,98	44,13
Linear SVC	Аннотации	77,88	85,73	76,13	72,77	74,72	77,25	42,89	45,48	44
BERT	Аннотации	84,81	89,53	83,75	82,13	87,24	81,46	44,23	47,16	45,02
<hr/>										
LR	Аннотации + удобочитаемость	78,81	86,68	77,13	72,35	73,14	76,88	42,45	44,02	43,87
Linear SVC	Аннотации + удобочитаемость	78,12	86,13	76,38	71,92	72,87	76,25	41,76	44,27	42,75
BERT	Аннотации + удобочитаемость	84,11	89,34	83,27	81,78	86,99	81,21	43,24	47	44,14
<hr/>										
LR	Аннотации + возрастной рейтинг	74,55	86,9	72,5	-	-	-	-	-	-
Linear SVC	Аннотации + возрастной рейтинг	73,97	86,17	71,88	-	-	-	-	-	-
BERT	Аннотации + возрастной рейтинг	81,4	86,27	80,71	-	-	-	-	-	-

LR	Аннотации + возрастная аудитория	-	-	-	73,24	78,69	78,5	42,17	45,48	43,77
Linear SVC	Аннотации + возрастная аудитория	-	-	-	73,03	78,21	78,38	40,24	50,46	43,38
BERT	Аннотации + возрастная аудитория	-	-	-	82,45	87,31	81,5	43,95	47,51	45,01
LR	Превью	87,27	88,66	86,75	72,53	75,15	77,88	40,21	41,17	41,2
Linear SVC	Превью	80,69	86,47	79,25	71,91	75,63	77,38	39,5	44,11	41,25
BERT	Превью	84,89	89,75	84,19	82	87,39	81,3	43,94	47,27	44,93

Полученные результаты позволяют зафиксировать следующие наблюдения. В случае задачи 1 модели, обученные на аннотациях, показывают более низкое качество в сравнении с моделями, обученными на ознакомительных фрагментах: -7,68% для логистической регрессии, -2,81% для метода опорных векторов и -0,08% для BERT. Для задач 2 и 3, то есть классификации книг на основе возрастных рейтингов, модели, обученные на аннотациях, в большинстве случаев показывают более высокие результаты. Возможно, это связано с тем, что в текстах аннотаций часто содержится косвенное указание на возрастной рейтинг (например, «Содержит нецензурную брань»), в то время как отдельно взятый ознакомительный фрагмент может удовлетворять критериям иной возрастной категории. Добавление дополнительных признаков в целом существенно не улучшило качество классификации. Однако использование информации о возрастной аудитории при решении задач 2 и 3 позволило в большинстве случаев позволило незначительно улучшить качество классификации.

Заключение

Для решения задачи возрастной классификации книг была оценена эффективность моделей, обученных на текстах не самих произведений, а их аннотаций. Использование аннотаций позволяет, во-первых, использовать тексты меньшего размера, во-вторых, упрощает сбор данных, так как тексты аннотаций находятся, как правило, в открытом доступе непосредственно на страницах онлайн-библиотек и каталогов. Результаты продемонстрировали превосходство моделей, обученных на аннотациях, в случае прогнозирования категорий, основанных на возрастных рейтингах информационной продукции. Кроме того, была оценена эффективность дополнительных признаков – показателей удобочитаемости аннотаций и дополнительной информации о возрастных категориях. Полученные результаты могут найти применение в моделях автоматической классификации текстов в электронных библиотеках и системах электронного обучения.

Библиографический список

1. Федеральный закон Российской Федерации от 29 декабря 2010 г. N 436-ФЗ «О защите детей от информации, причиняющей вред их здоровью и развитию».
2. Колесникова О.И. Персуазивный текст издательской аннотации: лингвокультурный аспект // Текст. Книга. Книгоиздание. 2020. № 22. С. 125–138.
3. Glazkova A., Egorov Y., Glazkov M. A comparative study of feature types for age-based text classification // Lecture Notes in Computer Science. AIST 2020: Analysis of Images, Social Networks and Texts. 2021. V. 12602. P. 120–134.
4. Coleman M., Liau T. L. A computer readability formula designed for machine scoring // Journal of Applied Psychology. 1975. V. 60. No. 2. P. 283.
5. Бегтин И. Оценка читабельности текста. URL: <http://readability.io/> (дата обращения: 16.09.21).
6. Loper E., Bird S. NLTK: the Natural Language Toolkit // Proc. of the ACL. 2002. P. 63–70.
7. Глазкова А.В. Подход к проведению классификации текстов на основании возрастных групп их адресатов // Труды СПИИРАН. 2017. № 3 (52). С. 51–69.
8. Лапошина А.Н. Анализ релевантных признаков для автоматического определения сложности русского текста как иностранного. URL: <http://www.dialog-21.ru/media/3993/laposhina.pdf> (дата обращения: 16.09.2021).
9. Анисимова Т.В. Принципы классификации жанров рекламы книги // Вестник ВолГУ. Серия 2: Языкоzнание. 2016. Т. 15. № 4. С. 104–113.
10. Агаркова О.А. Аргументная природа текста аннотации // Мир науки, культуры, образования. 2020. С. 496–498.
11. Devlin J. et al. Bert: Pre-training of deep bidirectional transformers for language understanding // arXiv preprint arXiv:1810.04805. 2018.
12. Pedregosa F. et al. Scikit-learn: Machine learning in Python // the Journal of machine Learning research. 2011. V. 12. P. 2825–2830.
13. Kuratov Y., Arkhipov M. Adaptation of deep bidirectional multilingual transformers for Russian language // Komp'juternaja Lingvistika i Intellektual'nye Tehnologii. 2019. P. 333–339.
14. Wolf T. et al. Transformers: State-of-the-art natural language processing // Proc. of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations. 2020. P. 38–45.
15. Paszke A. et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library // Advances in Neural Information Processing Systems. 2019. V. 32. P. 8026–8037.

PREDICTING THE BOOK AGE AUDIENCE BASED ON FICTION ABSTRACTS

Glazkova Anna V.

University of Tyumen, Volodarskogo str., 6, Tyumen, Russia, 625003,
a.v.glazkova@utmn.ru

The author considers the task of automatic determining the age audience of the book based on the text of its abstract. The quality of the classification is estimated by three basic models: i) logistic regression; ii) support vector classifier; and iii) a BERT-based neural network. It is shown that the use of abstracts as training data allows us to improve the performance of the classification based on the age ratings.

Keywords: text classification, age rating, fiction, readability, BERT.

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В КИНЕМАТОГРАФИИ

НЕЙРОСЕТЕВАЯ ОБРАБОТКА ДАННЫХ О ФИЛЬМАХ ДЛЯ ОЦЕНКИ ПОТЕНЦИАЛЬНОЙ ПРИБЫЛИ

Карпов Денис Алексеевич

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
kararov1dienis@gmail.com

В статье представлено описание разработки динамической нейросетевой системы для прогнозирования прибыли полученной за время проката фильма. Система позволяет выполнять оценку потенциальной прибыли которую можно в теории выручить за время проката фильма в зависимости от режиссера, сценариста, актерского состава и бюджета фильма.

Ключевые слова: искусственный интеллект, нейросетевые технологии, фильмы, самоадаптация, оценка прибыли, прогнозирование.

Введение. Во время начала создания фильма, когда необходимо определиться с режиссерским и актерским составом, в киностудиях рассматривают различные варианты, которые могут принести наибольшую прибыль [1, 2]. По утверждению зарубежных киноаналитиков, точная оценка кассовых поступлений перед выпуском фильма в прокат – самая трудная и важная задача для киноиндустрии [3]. Кинокомпании могут ориентироваться на предыдущие работы режиссера, сценариста и актеров, но обычно такой выбор подвержен влиянию человеческого фактора, можно не учесть фильмографию актера или какой-либо другой критерий и в итоге неверно оценить предполагаемый доход фильма.

Эффективность использования искусственного интеллекта при оценке кассовых сборов фильмов была обоснована в работах российских и зарубежных исследователей [4-10]. В данных работах учитывается большое количество параметров.

Данное исследование является альтернативой вышеупомянутых работ по созданию нейросетевой системы прогнозирования дохода фильма. Основная цель настоящей работы заключается в создании множества на основе фильмов, вышедших в прокат, а также создании и обучении нейросети на основе собранных данных.

В результате анализа литературных источников [1-10], были выбраны следующие показатели: X₁ – год выпуска фильма, X₂ – фамилия и имя режиссера, X₃ – фамилия и имя сценариста, X₄–X₈ – Фамилии и имена 5 актеров получивших главные роли в фильме, X₉ – бюджет выделенный для фильма (млн \$). Выходной параметр D₁ – сборы фильма (млн \$).

Параметры X3-X8 были закодированы с применением хеш-функции. Остальные параметры являются числовыми, поэтому для них кодировка не требуется.

Множество фильмов было собрано с помощью с интернет-ресурса Кинопоиск [11]. Перед переходом к проектированию и обучению нейросетевой модели, было выполнено преобразование исходных данных путем создания дополнительных примеров по одному и тому же фильму, но с измененным порядком актеров в параметрах X3-X8 для показания нейросети того факта, что изменение порядка 5 главных актеров не несет изменений на результат. Таким образом, объем итогового множества включает в себя 690 примеров. Данное множество было разделено на обучающее и тестирующее в соотношении 84% и 16% соответственно, с учетом того факта что в тестирующем множестве не должно быть повторяющихся примеров. Собранные данные охватывают период с 1984 по 2020 год.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [12] по методике [13]. После оптимизации, спроектированная нейронная сеть представляла собой персептрон, который имеет девять входных нейронов, один выходной и один скрытый слой с четырьмя нейронами.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 100 примеров. Средняя ошибка тестирования составила 11.7%, что можно считать приемлемым результатом. На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактической и прогнозируемой нейросетью стоимостью случайно отобранных 50 фильмов из тестирующего множества.

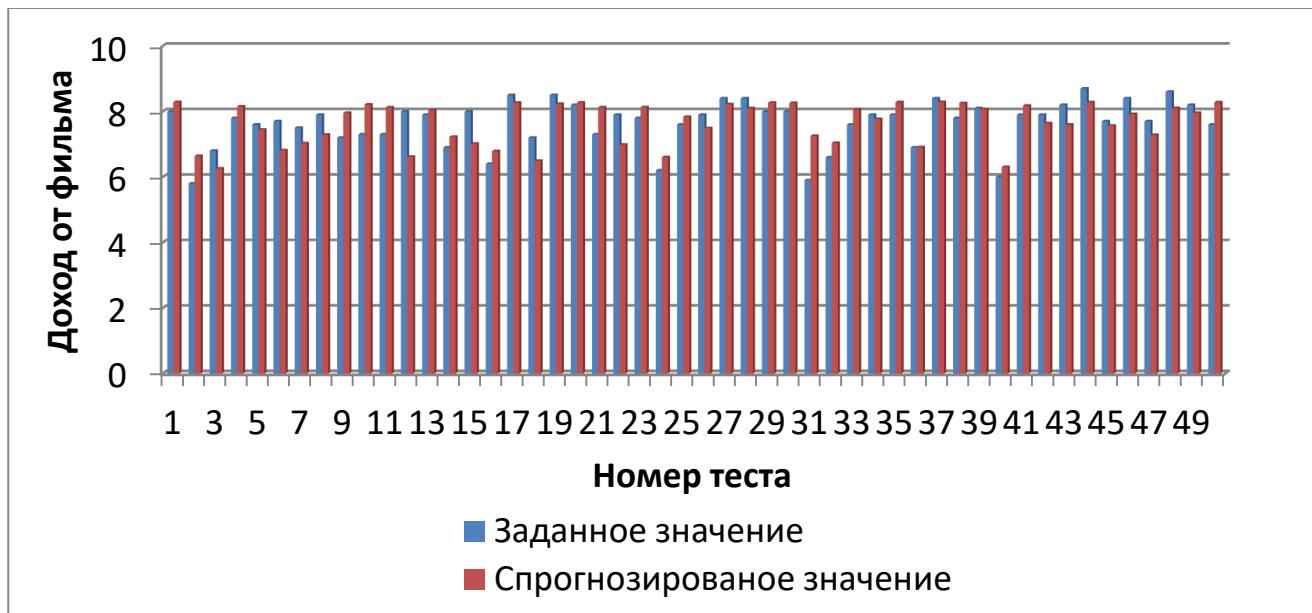


Рисунок 1. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 1, можно сделать вывод об адекватной работе спроектированной нейронной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5», результат отображен на рисунке 2.

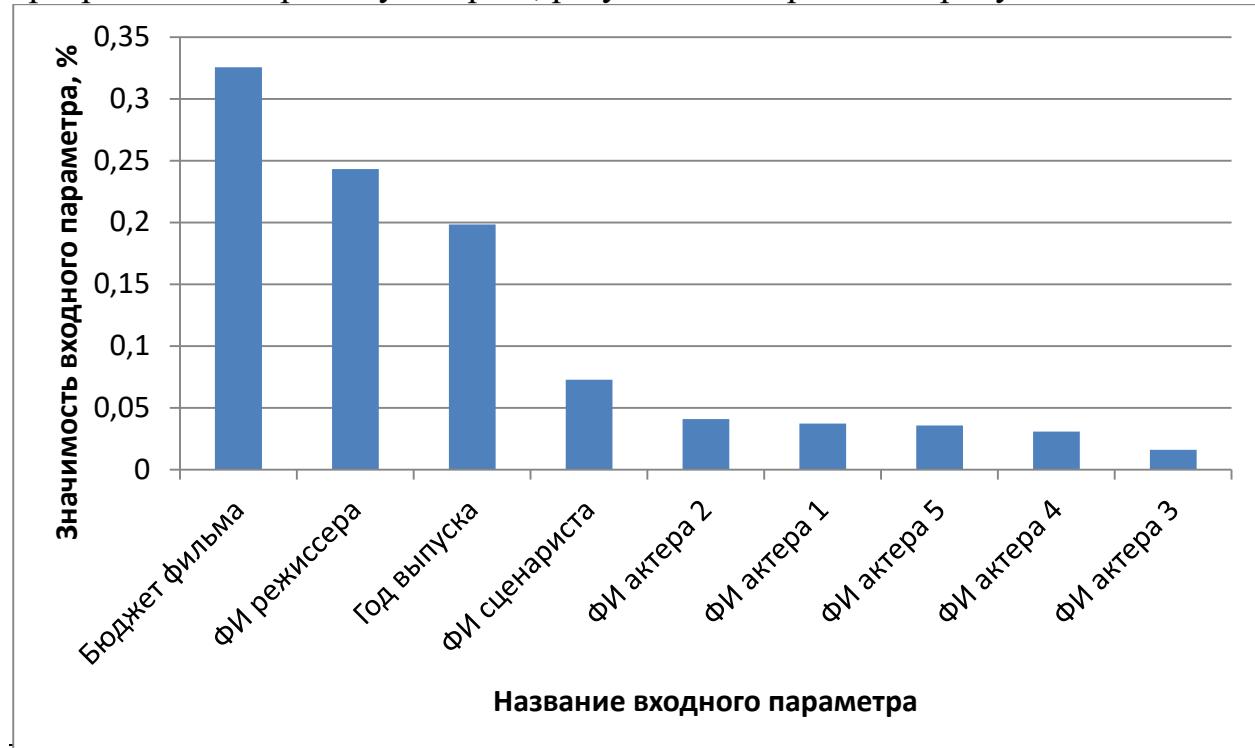


Рисунок 2. Значимость входных параметров нейросетевой модели

Как видно из рисунка 2, наиболее значимыми являются бюджет фильма, ФИ режиссера и год выпуска фильма.

Далее было проведено исследование кинорынка. Исследование производилось с помощью метода «замораживания» [13], суть которого заключается в варьировании значения одного параметра и фиксировании значений всех других параметров. Данный метод позволяет выявить влияние исследуемого параметра на выходной. Для этого были выбраны 3 фильма : “Звездный путь”, “Как приручить дракона” и “Стражи галактики” информация о входных параметрах которых отражена в таблице 1.

Таблица 1
Характеристики фильмов,
выбранных для исследования

Фильм	1 – Звездный путь	2 – Как приручить дракона	3 – Стражи галактики
X1	2019	2010	1985
X2	3032	2017	3014
X3	3032	2601	3014
X4	3074	2784	2591
X5	2282	2982	3277
X6	2790	3065	2330
X7	2327	3233	3018
X8	3275	2072	2865
X9	237	165	19

На рисунке 4 показан график зависимости прибыли фильмов от бюджета, выделенного на фильм. Как следует из графика, увеличение бюджета картины приводит к росту сборов, но скорость этого роста постепенно уменьшается.

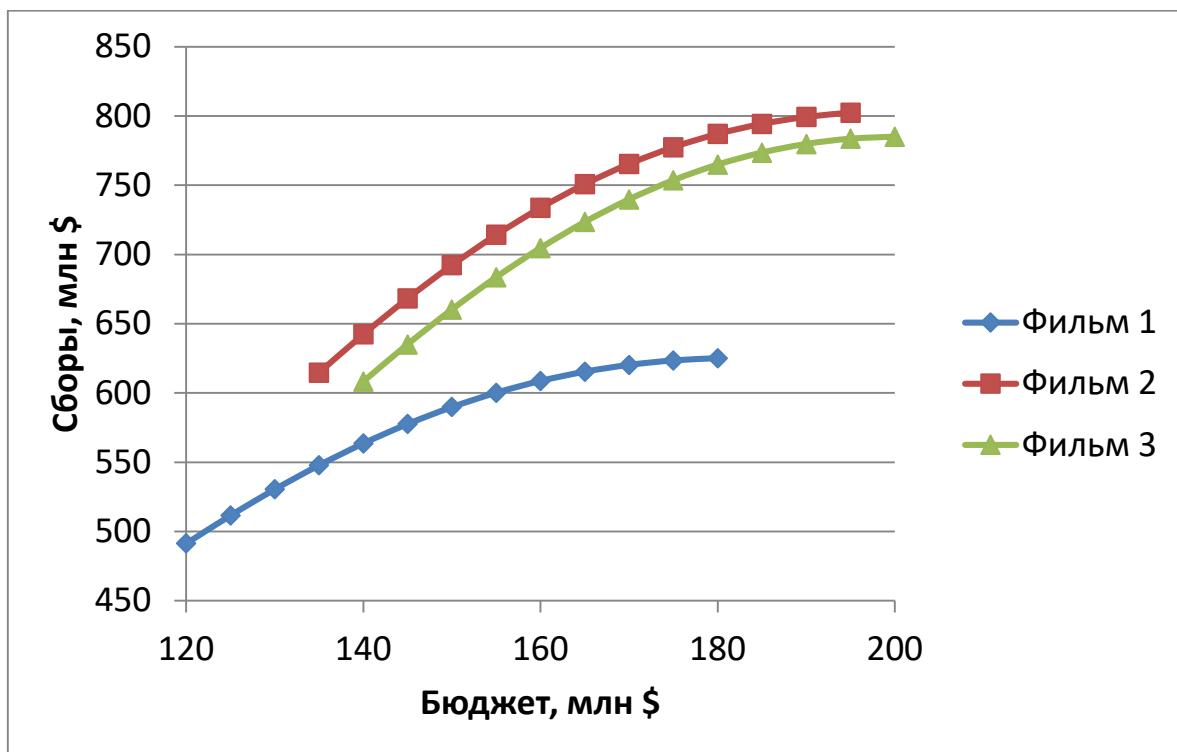


Рисунок 4. Зависимость кассовых сборов фильмов от выделенного бюджета

На рисунке 5 показан график изменения дохода фильма в зависимости от увеличения или бюджета

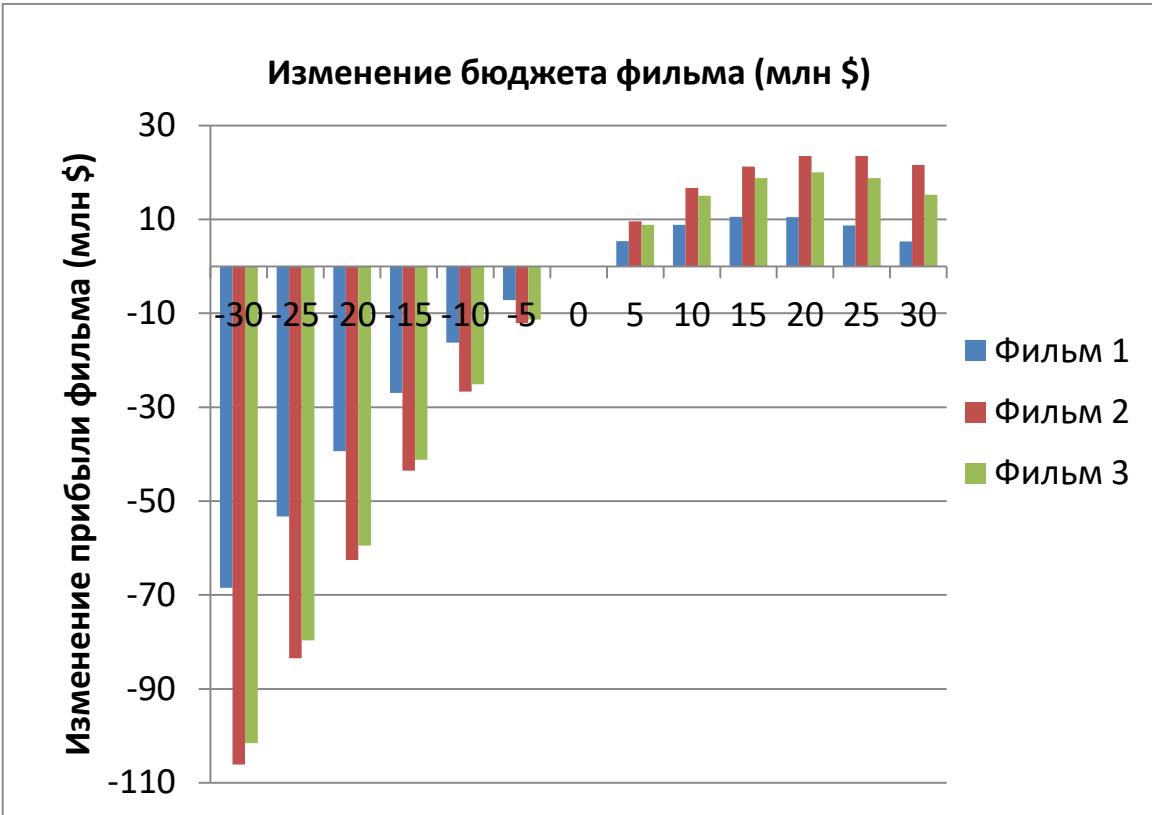


Рисунок 5. Зависимость изменения прибыли фильмов от изменений выделенного бюджета

На рисунках 6-7 продемонстрирована зависимость сборов фильма от выбора режиссера и сценариста.

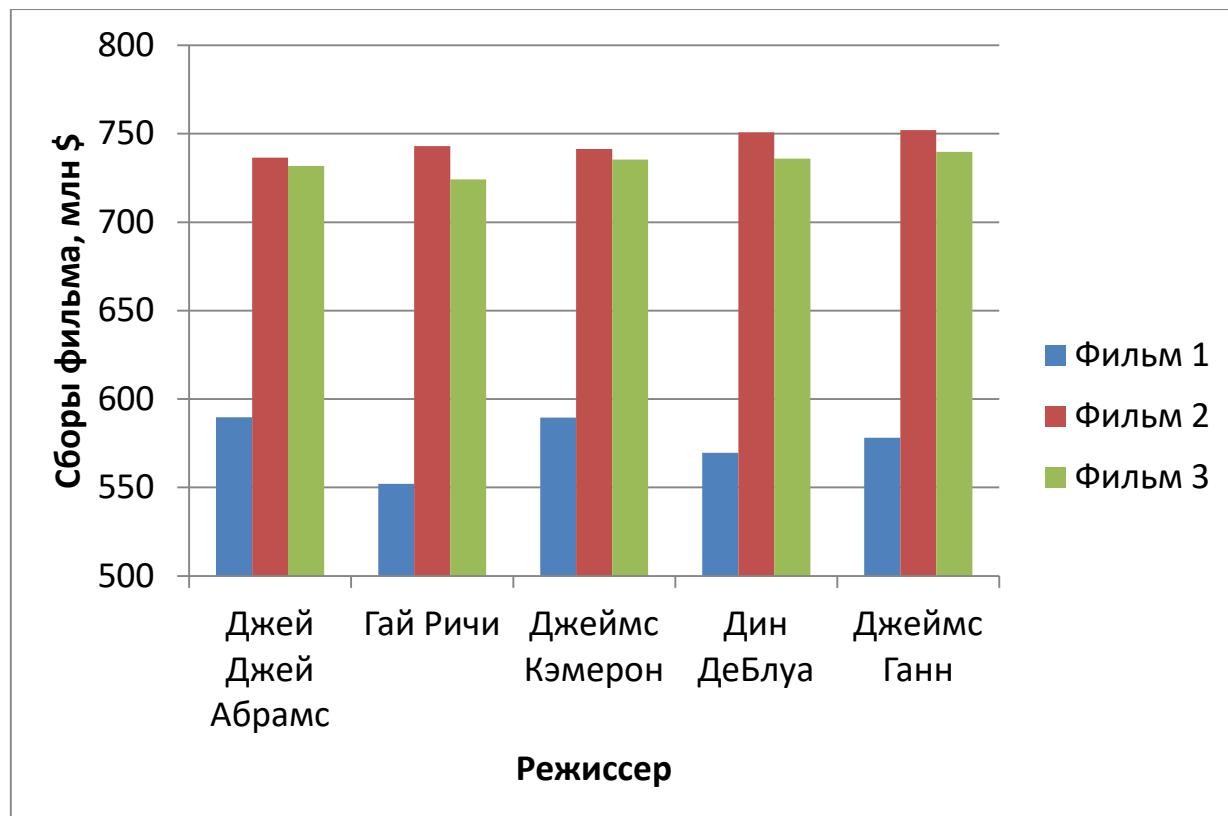


Рисунок 6. Зависимость кассовых сборов фильмов от режиссера

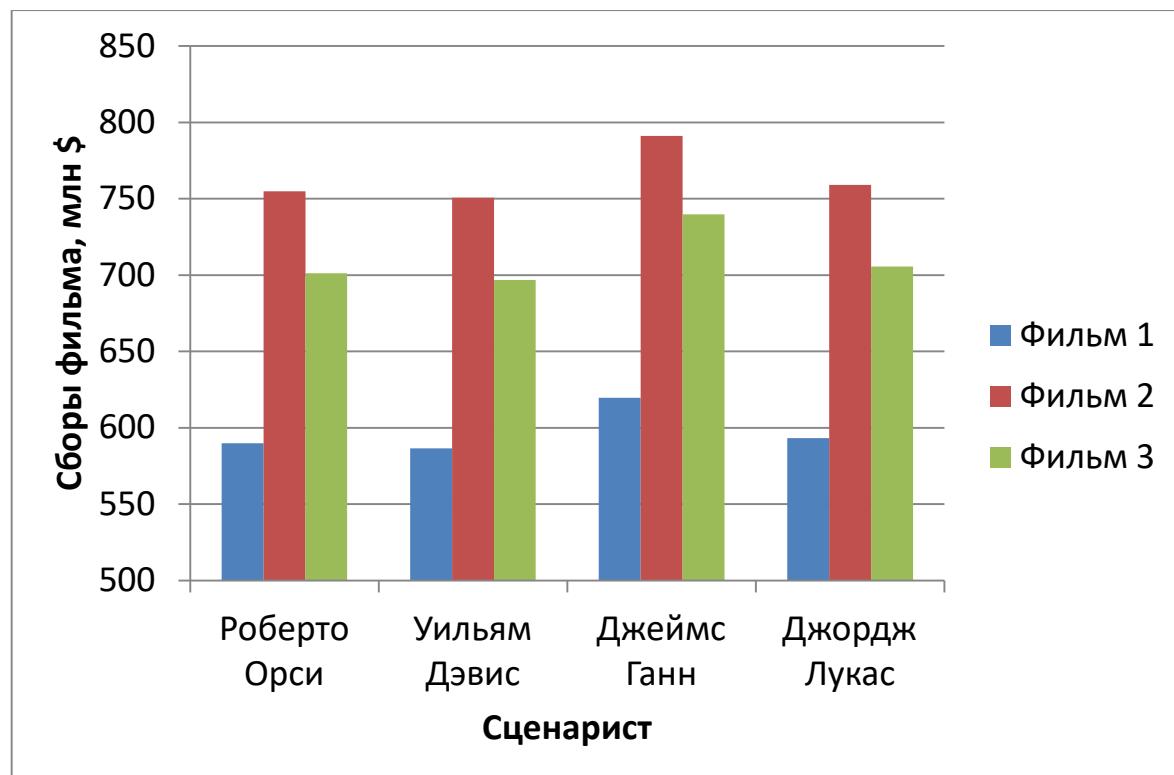


Рисунок 7. Зависимость кассовых сборов фильмов от сценариста

Далее аналогичным методом было проведено исследование зависимости сборов картины от года его выпуска. Его результаты представлены на рисунке 8

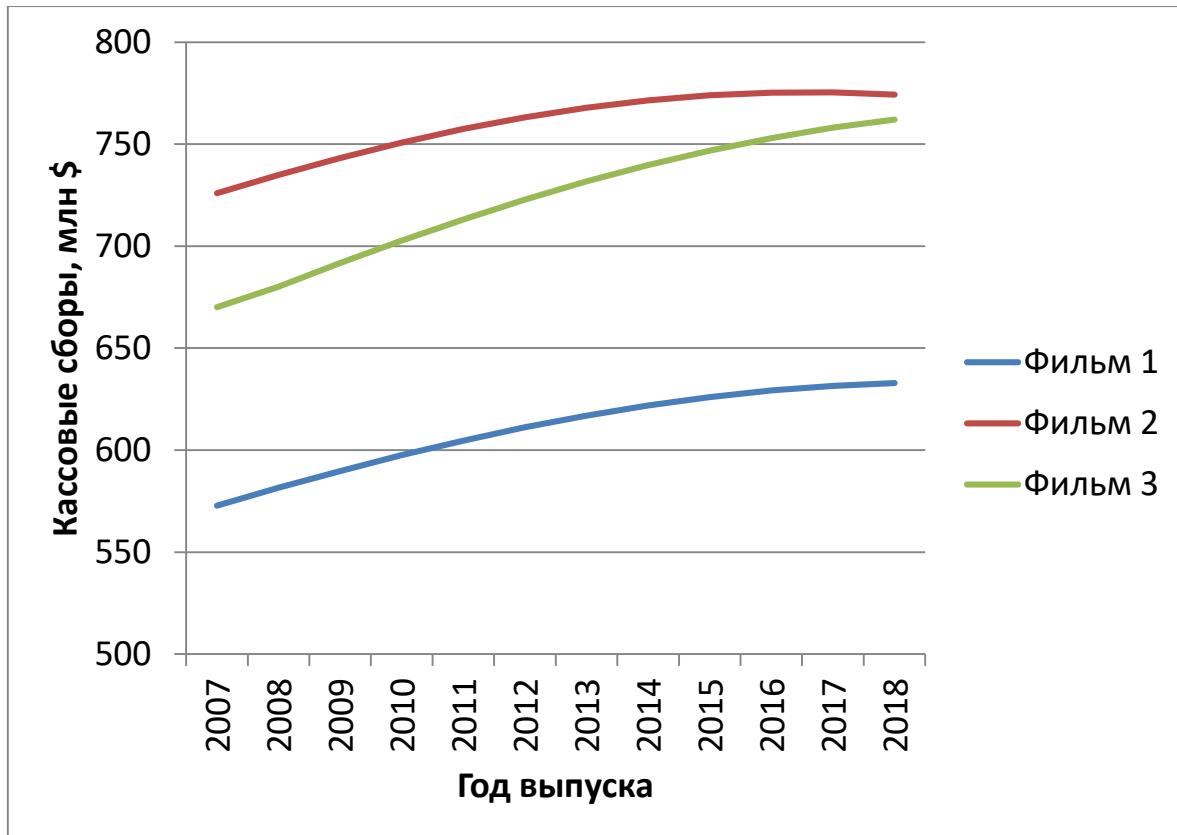


Рисунок 8. Зависимость стоимости квартир Нижнего Новгорода от географической широты

Полученные результаты исследований не противоречат реальности, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для прогнозирования кассовых сборов фильмов

Заключение. Построена система нейросетевого оценивания кассовых сборов фильмов Спроектированная нейросетевая модель учитывает потенциальный вклад режиссера, сценариста, главных актеров и вложенного бюджета. Проведены исследования рынка киноиндустрии. Методом сценарного прогнозирования построены графики зависимостей кассовых сборов от бюджета картины, года выпуска фильма, режиссера и сценариста. Применение такого набора параметров в модели позволяет учитывать разнообразный актерский состав в разные моменты времени, а также может быть в дальнейшем расширена для более точного прогнозирования кассовых сборов.

Библиографический список

1. Holbrook M.B., Hirschman E.C. The Experiential Aspects of Consumption: Consumer's Fantasies, Feelings and Fun. *Journal of Consumer Research*, 1982, vol. 9, iss. 2, pp. 132–140.
2. Eliashberg J., Sawhney M.S. Modeling Goes to Hollywood: Predicting Individual Differences in Movie Enjoyment. *Management Science*, 1994, vol. 40, iss. 9, pp. 1151–1173. doi: 10.1287/mnsc.40.9.1151

3. Sharda R., Delen D. Predicting Box-Office Success of Motion Pictures with Neural Networks. *Expert Systems with Applications*, 2006, vol. 30, iss. 2, pp. 243–254. doi: <http://dx.doi.org/10.1016/j.eswa.2005.07.018>
4. Litman B.R. Predicting Success of Theatrical Movies: An Empirical Study. *Journal of Popular Culture*, 1983, vol. 16, no. 9, pp. 159–175. doi: [10.1111/j.0022-3840.1983.1604_159.x](https://doi.org/10.1111/j.0022-3840.1983.1604_159.x) 5.
5. Riwinoto M.T., Selly Artaty Zega, Gia Irlanda. Predicting Animated Film of Box-Office Success with Neural Networks. *Jurnal Teknologi*, 2015, no. 23, pp. 77–82. 6.
6. Неволин И.В., Татарников А.С. Модели прогнозирования кассовых сборов кинофильмов на основе эмоциональных факторов спроса // Экономика и социум. 2014. № 4. С. 1244–1259.
7. Ясницкий Л.Н., Белобородова Н. О., Медведева Е.Ю. Методика нейросетевого прогнозирования кассовых сборов кинофильмов // Финансовая аналитика: проблемы и решения. 2017. Т. 10. № 4 (334). С. 449-463.
8. Yasnitsky, L.N., Mitrofanov, I.A., Immis, M.V. Intelligent System for Prediction Box Office of the Film // Lecture Notes in Networks and Systems. 2020. Vol. 78. Pp. 18-25. https://doi.org/10.1007/978-3-030-22493-6_3.
9. Ясницкий Л.Н., Плотников Д.И. Экономико-математическая нейросетевая модель для оптимизации финансовых затрат в кинобизнесе // Фундаментальные исследования. 2016. № 11-2. С. 339-342.
10. Yasnitskii L.N., Beloborodova N.O., Medvedeva E.Yu. The method for forecasting box-office grosses of movies with neural network // Digest Finance. 2017. Т. 22. № 3 (243). С. 298-309.
11. Сайт Кинопоиск [Электронный ресурс], 2021, URL: <https://www.kinopoisk.ru/> (дата обращения: 04.03.2021).
12. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
13. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.

DYNAMIC NEURAL NETWORK OF FILM DATA FOR ESTIMATION OF POTENTIAL PROFITS

Karpov Denis A.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990

The article describes the development of a dynamic neural network system for estimating the value of potential profits in the film making industry. The system allows people to evaluate the profits of film based on release year, budget and names of producer, scenarist and main actors.

Keywords: artificial intelligence, neural network technologies, film-making industry, box-office profits, self-adaptation, profit estimation, forecasting.

ПРОГНОЗИРОВАНИЕ УСПЕХА ФИЛЬМА В ПРОКАТЕ С ПОМОЩЬЮ НЕЙРОСЕТЕВОЙ МОДЕЛИ

Утробин Данил Иванович

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
utrobin.danil.m@gmail.com

В статье представлено описание исследования возможности прогнозирования успеха продуктов киноиндустрии при помощи технологий нейросетевого моделирования, исследование по выявлению наиболее значимых критериев, влияющих на успех фильма, с целью повышения качества продуктов кинематографа.

Ключевые слова: искусственный интеллект, нейросетевые технологии, кино, рейтинг, успех, прогнозирование, фильм, качество.

Введение. Практическая ценность исследования состоит в том, что созданная модель может быть использована для оптимизации финансовых затрат и выбора параметров при планировании новых кинофильмов. Она позволяет делать прогнозы о рейтинге фильма и выбирать наиболее эффективный способ распределения бюджета на различные аспекты фильма, тем самым увеличивая его шанс понравится публике и критикам.

В основе модели используемой в исследовании лежит нейронная сеть, обученная на статистических данных о рейтингах фильмов, включающая 20 входных параметров, покрывающих предположительно наиболее влияющие на качество фильма факторы.

Эффективность использования искусственного интеллекта при оценке успешности продуктов киноиндустрии была показана в работах [3-6]. В данных работах получены значительные результаты. В настоящей работе для моделирования было решено использовать схожий, но несколько отличающийся список параметров, используемых для построение прогноза, далее представлено подробное его описание.

Данное исследование является расширением вышеупомянутых работ по созданию динамической системы оценки успеха фильмов. Основная цель настоящей работы заключается в попытке улучшить качество прогноза путем подбора входных параметров и структуры нейросети.

В результате среднеквадратичная относительная ошибка модели составила 4,2%. Выявлены наиболее значимые критерии, влияющие на успех фильма. Так же продемонстрированы способы использования созданной модели для получения различных статистических данных способствующих повышению качества фильма.

При построении нейросетевой модели в качестве входных параметров было решено выбрать следующие:

- X1 – Фильм выпускался при участии страны «США»
- X2 – Фильм выпускался при участии страны «Германия»
- X3 – Фильм выпускался при участии страны «Испания»
- X4 – Фильм выпускался при участии страны «Россия»
- X5 – Фильм выпускался при участии страны «Франция»
- X6 – Фильм выпускался при участии страны «Великобритания»
- X7 – Фильм содержит жанр «Фантастика»
- X8 – Фильм содержит жанр «Драма»
- X9 – Фильм содержит жанр «Мелодрама»
- X10 – Фильм содержит жанр «Криминал»
- X11 – Фильм содержит жанр «Боевик»
- X12 – Фильм содержит жанр «Комедия»
- X13 – Фильм содержит жанр «Триллер»
- X14 – Фильм содержит жанр «Ужас»
- X15 – Фильм содержит жанр «Мультфильм»

X16 – Суммарный рейтинг 3 актёров в главных ролях (Каждому актёру входящему в тройку первостепенных ролей фильма присуждается оценка от 1 до 10 на основе средних оценок критиков в фильмах в которых уже снялся актёр, полученные оценки суммируются)

X17 – Рейтинг режиссера (Средний рейтинг уже снятых фильмов под руководством этого режиссера)

X18 – Возрастное ограничение

X19 – Бюджет (в миллионах долларов США)

X20 – Рейтинг сценариста (Аналогично рейтингу режиссера)

Выходным параметром модели Y1 является рейтинг фильма, который учитывает отзывы критиков, простых людей, количество просмотров и кассовые сборы фильма.

Всего были собраны данные о 51 фильме с ресурса [1].

Все множество примеров было разбито на обучающее и тестирующее в соотношении 80 : 20.

Проектирование, оптимизация, обучение, тестирование нейронной сети и эксперименты над нейросетевой моделью выполнялись с помощью нейросимулятора «Nsim5-10s» [7].

Структура нейронной сети изображена на рис. 1 и представляет собой персепtron, имеющий 20 входных нейронов, 1 скрытый слой, в котором 3 нейрона, а также один выходной нейрон.

В качестве активационных функций нейронов скрытого слоя и выходного слоя использовался тангенс гиперболический, а в качестве алгоритма обучения – алгоритм упругого распространения.

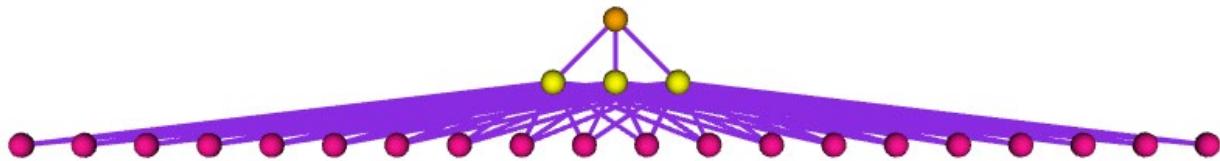


Рисунок 1. Оптимальная структура нейронной сети

После оптимизации и обучения нейронной сети ее прогностические свойства проверялись на примерах тестирующего множества, которые в процессе обучения не участвовали. Средняя квадратичная относительная ошибка тестирования нейронной сети, вычисленная по формуле

$$E = \sqrt{\frac{\sum_{n=1}^N (d_n - y_n)^2}{N}} \cdot 100\%$$

в которой N – количество элементов выборки, d_n – фактический рейтинг n -го фильма, y_n – его прогнозная величина. Ошибка составила 4,2%.

Примеры тестирующего множества не были использованы при обучении нейронной сети, а значит можно утверждать, что нейронная сеть усвоила закономерности моделируемой предметной области, на рисунке 2 приведено подтверждение. Теперь нейронную сеть можно использовать для проведения вычислительных экспериментов.

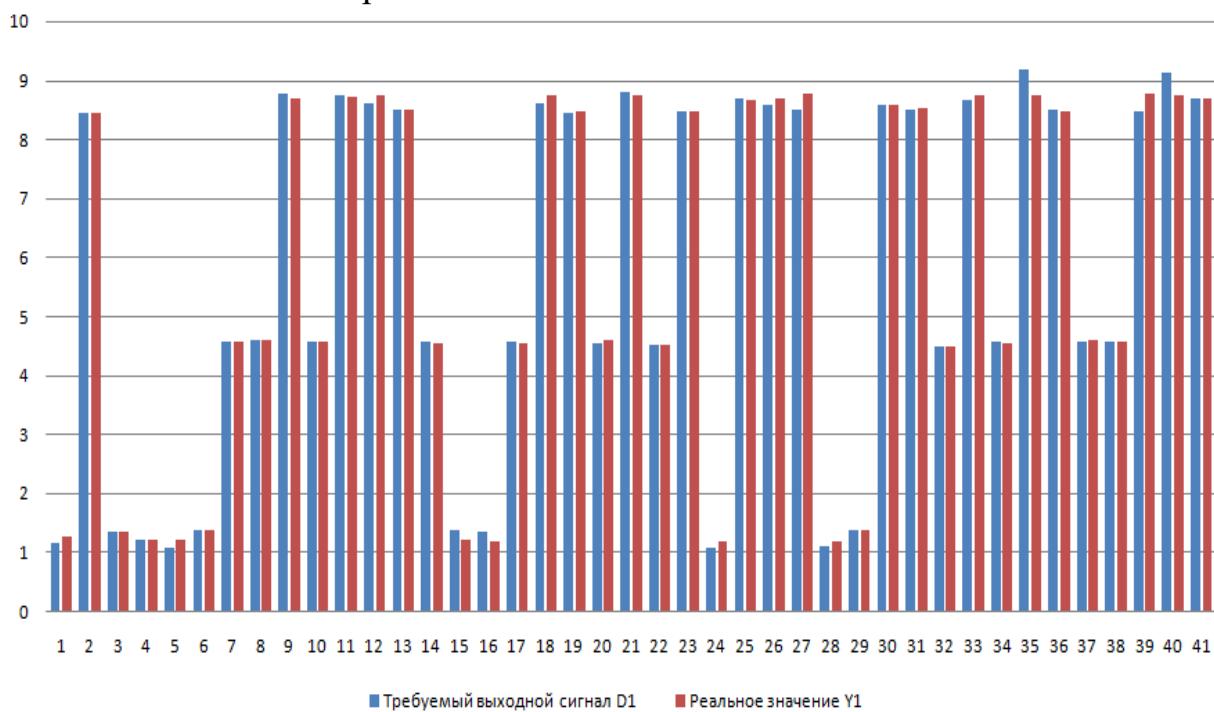


Рисунок 2. Соотнесение требуемых и реальных значений

При помощи средства выявления значимости параметров предоставляемого нам неросимулятором выявим параметры которые наиболее сильно влияют на конечный результат.

Объективную оценку такого влияния получаем путем поочередного исключения входных параметров и наблюдением за погрешностью тестирования. Чем выше оказывается погрешность тестирования, тем значимее соответствующий исключенный параметр. Построенная таким способом

гистограмма приведена на рисунке 3. Высота столбцов соответствует погрешности тестирования, полученной при исключении входном параметре, подписанном под столбцом, поэтому ее можно интерпретировать как значимость этого параметра.

Из рисунка видно, что очень важным параметром успешности фильма является опыт человека назначенного на роль режиссера. Так же важными параметрами являются качество сценария, актёры играющие главные роли и сняли фильм в России, анализируя узнаём, что к сожалению, последнее связано с плохо зарекомендовавшим себя Российским кинематографом.

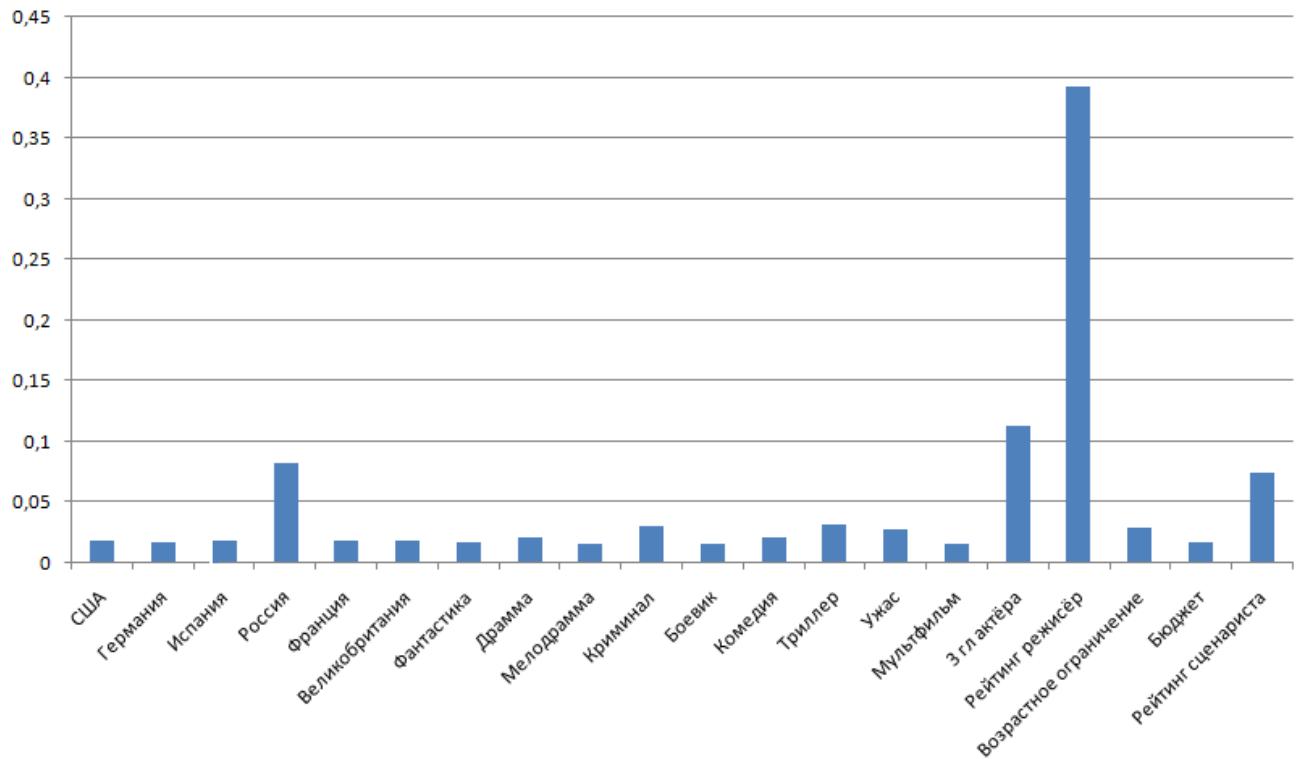


Рисунок 3. Значимость входных параметров

Следующим этапом исследования был эксперимент по гипотетическому улучшению рейтингов фильмов.

Для этого взяв за основу фильм с низким рейтингом и проверив его гипотетический рейтинг при увеличении параметра «Суммарный рейтинг трех актёров в главных ролях», получим зависимость рейтинга фильма от рейтинга актёров в главных ролях, как представлено на рис. 4.

Исходя из полученных данных становится возможна оптимальная оценка одного из аспектов эффективности актёрского состава.

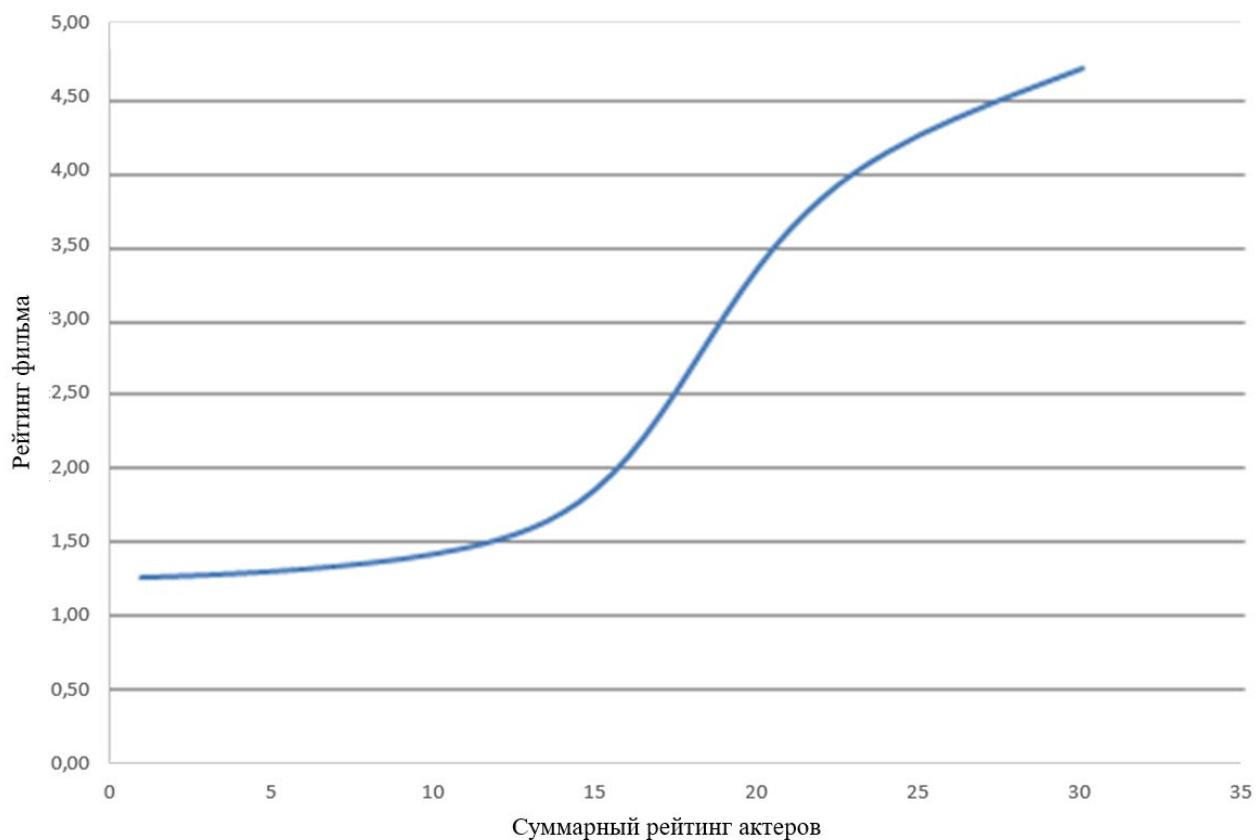


Рисунок 4. Зависимость рейтинга фильма от рейтинга актёров в главных ролях

В следующем эксперименте было рассмотрено как именно сценарий фильма влияет на его успех в прокате.

Эксперимент проведен на фильме, использованном для первого эксперимента.

Получаем следующую зависимость рейтинга фильма от опыта сценариста рис.5.

Полученные данные могут быть использованы для более точного ответа на вопрос «Стоит ли использовать тот или иной сценарий для фильма?».

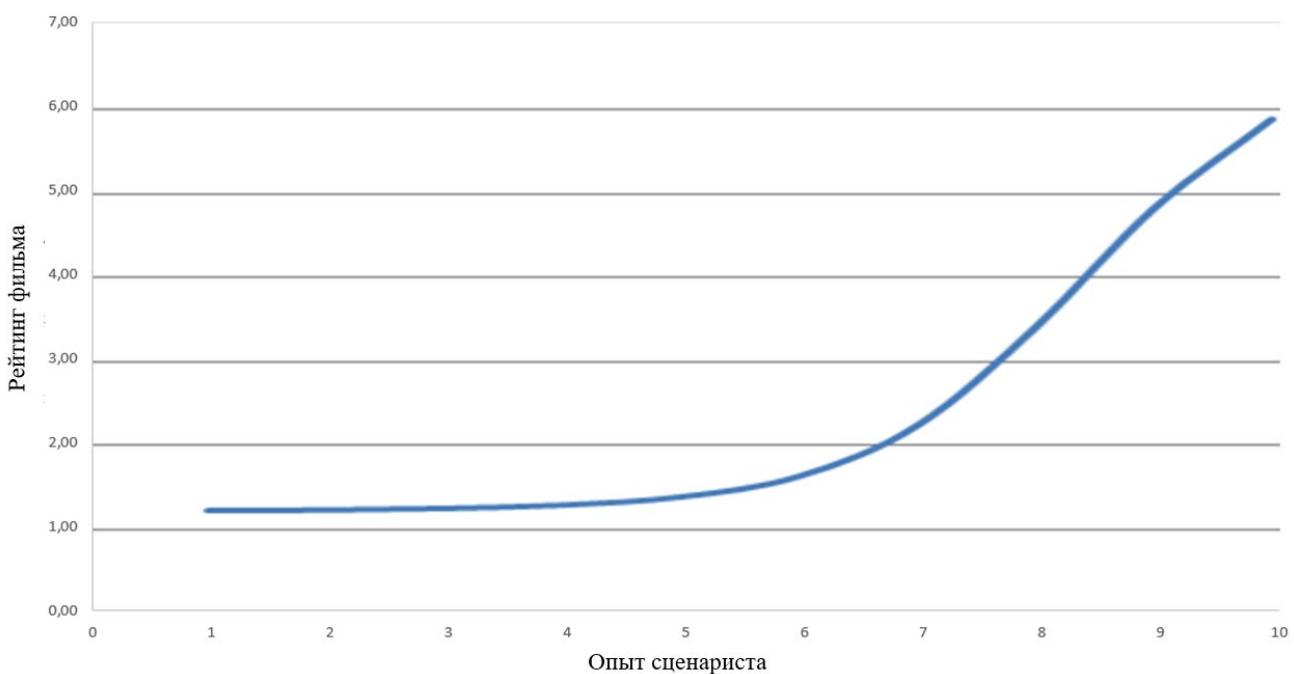


Рисунок 5. Зависимость рейтинга фильма от опыта сценариста.

Заключение. В ходе проделанного исследования выявлены наиболее значимые критерии, влияющие на успех фильма. Так же продемонстрированы способы использования созданной модели для получения различных статистических данных способствующих повышению качества фильма.

Практическая ценность исследования состоит в том, что созданная модель может быть использована для оптимизации финансовых затрат и выбора параметров при планировании новых кинофильмов. Следовательно, она позволяет делать прогнозы о рейтинге фильма и выбирать наиболее эффективный способ распределения бюджета на различные аспекты фильма, тем самым увеличивая шансы фильма понравится публике и критикам.

Библиографический список

1. Сайт «Кинопоиск» <https://www.kinopoisk.ru>
2. Ясницкий Л.Н. Интеллектуальные информационные технологии и системы: учеб.-метод пособие / Л. Н. Ясницкий; Перм. Ун-т. – Пермь, 2007. – 271 с.
3. Ясницкий Л.Н., Плотников Д.И. Экономико-математическая нейросетевая модель для оптимизации финансовых затрат в кинобизнесе // Фундаментальные исследования. 2016. № 11-2. С. 339-342.
4. Yasnitsky, L.N., Mitrofanov, I.A., Immis, M.V. Intelligent System for Prediction Box Office of the Film // Lecture Notes in Networks and Systems. 2020. Vol. 78. Pp. 18-25. https://doi.org/10.1007/978-3-030-22493-6_3.
5. Ясницкий Л.Н., Белобородова Н. О., Медведева Е.Ю. Методика нейросетевого прогнозирования кассовых сборов кинофильмов // Финансовая аналитика: проблемы и решения. 2017. Т. 10. № 4 (334). С. 449-463.
6. Yasnitskii L.N., Beloborodova N.O., Medvedeva E.Yu. The method for forecasting box-office grosses of movies with neural network // Digest Finance. 2017. Т. 22. № 3 (243). С. 298-309.

7. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.

PREDICTING THE SUCCESS OF A FILM AT THE BOX OFFICE USING A NEURAL NETWORK MODEL

Utrobin Danil I.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990,

utrobin.danil.m@gmail.com

The article describes a study of the possibility of predicting the success of film industry products using neural network modeling technologies, a study to identify the most significant criteria that affect the success of a film, in order to improve the quality of cinema products.

Keywords: artificial intelligence, neural network technologies, cinema, rating, success, forecasting, film, quality.

**ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ
В ПРОБЛЕМАХ МИГРАЦИИ
НАСЕЛЕНИЯ**

ПРОГНОЗИРОВАНИЕ УРОВНЯ ИММИГРАЦИИ НА ОСНОВЕ НЕЙРОННЫХ СЕТЕЙ

Ермаков Виталий Алексеевич, Зырянова Анна Романовна

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15.
progamer20332@gmail.com, anya255786@gmail.com

В статье описан процесс проектирования нейросетевой системы для прогнозирования уровня иммиграции в различных государствах, а также ход и результаты исследований, проведенных с ее помощью.

Ключевые слова: нейронные сети, прогнозирование, иммиграция, закономерности, моделирование.

Введение. В современном мире все более закрепляются эмиграционные тенденции. Отчасти причиной этому послужили процесс глобализации и развитие сетевых технологий – границы между государствами уже не ощущаются так четко, как в прошлые столетия. Особенно ярко подобные настроения проявляются у молодежи: к примеру, в сентябре 2019 г. желание переехать за границу на постоянное место жительства выразило 53% людей в возрасте от 18 до 24 лет. В других возрастных группах, в свою очередь, схожим образом высказалось многое меньшее число респондентов [1].

Одна из причин, по которой принимающие страны могут быть заинтересованы в повышении уровня иммиграции – связанный с ней приток квалифицированных работников, ускоряющий, в частности, развитие высокотехнологичных сфер промышленности и разработку инноваций [2, стр. 16]. Но остается актуальным вопрос: как оценить значимость факторов, влияющих на миграцию? Какие меры принять, чтобы повысить привлекательность проживания в государстве не только для ее граждан, но и для иностранцев? Согласно [3], наиболее эффективный инструмент для его решения – нейронные сети.

Описание модели. Выбор входных параметров – наиболее сложный этап проектирования, так как многие факторы миграции не поддаются количественному измерению, а при наличии числовых эквивалентов данные не всегда обновляются регулярно. Однако выделение некоторых тенденций в предметной области остается возможным.

Так, в работе [4] представлены регрессионные модели, позволяющие изучить влияние валового внутреннего продукта на душу населения, уровня здравоохранения и уровня безработицы.

Автор статьи [5] выделяет экономические факторы как особо значимые, а также отмечает влияние межэтнических конфликтов. В качестве параметров,

позволяющих моделировать влияние этого фактора, будут выступать приток и отток беженцев.

В исследовании [6] изучается непосредственно нейросетевое моделирование миграции. В качестве параметров выделяется, в том числе, уровень образования. Для его характеристики будет рассматриваться индекс человеческого капитала.

Дополнив этот список параметрами из базы данных Всемирного банка [7], получим список входных параметров, представленный в таблице 1.

Таблица 3 Входные параметры нейронной сети

Группа	Номер	Название	Расшифровка, комментарии
Негруппируемый параметр	X1	Год	Целое число (использовались данные за 2014–2019 гг.)
Социально-демографические	X2	Дожитие до 65 лет, мужчины	% когорты, число от 0 до 100
	X3	Уровень безработицы	%, число от 0 до 100
	X4	Индекс человеческого капитала	Шкала 0-1 (низкий – высокий)
	X5	Ожидаемая продолжительность жизни при рождении, в общем	Количество лет, положительное число (допускаются вещественные значения)
	X6	Врачи, на 1000 человек	Количество, положительное число (допускаются вещественные значения)
	X7	Прирост населения	Годовой %, от -100 до 100
	X8	Индекс стоимости жизни	% от стоимости жизни в Нью-Йорке, положительное число
Экономические	X9	ВВП на душу населения	В долларах США, положительное число
	X10	Уровень инфляции	%, число от -100 до 100
	X11	Темп роста ВВП	Годовой %, число от 0 до 100
	X12	Налог и отчисления на рабочую силу	% от коммерческой прибыли, число от 0 до 100
	X13	Доля наемных работников	%, число от 0 до 100
	X14	Индекс силы юридических прав	Шкала 0-12 (слабые – сильные)
Политико-правовые (в том числе связанные с территорией происхождения)	X15	Приток просителей убежища по национальности	Количество человек, неотрицательное число
	X16	Количество беженцев по стране или территории происхождения	
	X17	Количество беженцев по стране или территории убежища	
	X18	Отток иностранного населения по национальностям	

Выходной параметр всего один – приток иностранного населения по национальностям, или же число людей, иммигрировавших в данное государство.

Проектирование нейронной сети. Заключительный этап проектирования – поиск оптимальной структуры сети. Для решения этой задачи необходим объем датасета и его отдельных составляющих, а также описанная ранее модель.

Данные для обучения составляют 117 примеров: 100 примеров в обучающем множестве и 17 примеров в тестирующем множестве. По следствию из теоремы Арнольда–Колмогорова–Хект–Нильсена получена следующая оценка числа нейронов на скрытом слое:

$$1 \leq N \leq 6$$

В процессе изучения различных конфигураций нейронной сети было выявлено оптимальное количество нейронов на скрытом слое – 3.

В качестве функции активации использовался тангенс гиперболический. Среди алгоритмов обучения, доступных в [8], был выбран алгоритм быстрого распространения со скоростью 0,01 – он более стабилен в сравнении с дающими чуть более точные результаты алгоритмами упругого распространения и Левенберга–Марквардта.

Доказательство адекватности. В результате обучения нейросети была получена ошибка тестирования, равная 3,5%. Поскольку тестирующее множество не использовалось в процессе обучения, можно говорить о том, что нейросеть усвоила закономерности предметной области.

Результаты вычисления значимости параметров, в свою очередь, расходятся с одной из таких закономерностей – главенством экономических факторов. Они представлены на рисунках 1 и 2.

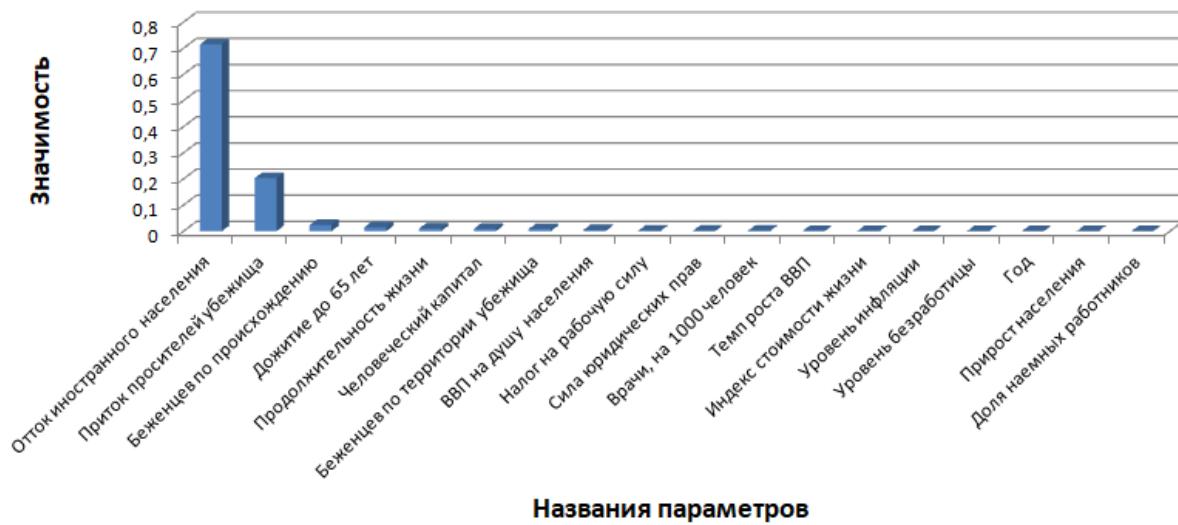


Рисунок 30. Значимость параметров

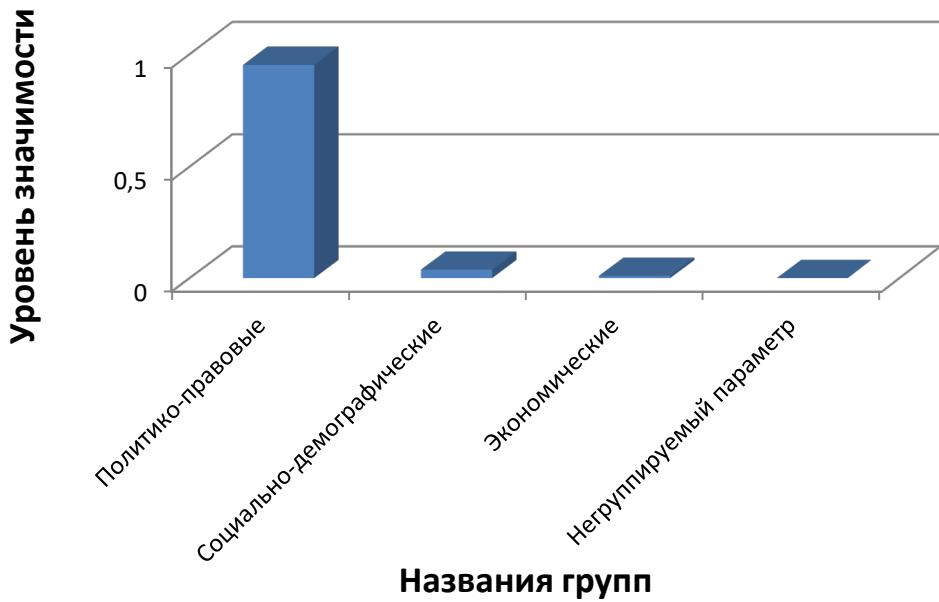


Рисунок 31. Суммарная значимость параметров по группам

Такое расхождение можно объяснить большим размахом допустимых значений для параметров, представляющих политические факторы: в основном, они задают количество человек; а подавляющее число экономических факторов выражается в процентах. С учетом данной поправки модель можно считать адекватной.

Экспериментальная часть. Для дальнейшего исследования миграционных тенденций были отобраны примеры, представленные в таблице 2.

Таблица 4 Характеристики стран, выбранных для исследования

Название страны	Южная Корея	Новая Зеландия	Швейцария	Латвия	Австралия
X1	2015	2017	2018	2014	2019
X2	86,82	88,52	90,41	65,76	89,22
X3	3,55	4,7	4,71	10,85	3,69
X4	0,88	0,77	0,77	0,75	0,77
X5	82,02	81,66	83,75	74,12	82,92
X6	2,25	3,47	4,36	3,17	2,95
X7	0,53	2,12	0,74	-0,94	0,68
X8	82,9	75,22	119,98	65,95	104,49
X9	33422,94	40105,61	82081,6	17828,89	97019,18
X10	1,48	0,65	-1,14	2,81	2,04
X11	2,81	3,16	2,75	1,07	1,15
X12	13,5	2,5	17,7	27,2	15,9
X13	74,14	81,44	85,25	88,46	93,54
X14	5	12	6	9	5
X15	5710	560	13535	364	2205
X16	346	34	5	206	5
X17	1455	1465	104011	168	53882
X18	301010	48229	80749	1391	17570

Исследование производилось с помощью метода «замораживания» [9], суть которого заключается в варьировании значения одного параметра и фиксировании значений всех других параметров. Цель данного метода – изучение влияния исследуемого входного параметра на выходной.

На рисунке 3 проиллюстрирована зависимость количества иммигрантов от индекса человеческих прав. Как видно из характера графиков, сила юридических прав и уровень иммиграции прямо пропорциональны. Соответствие закономерностям предметной области в данном случае очевидно.

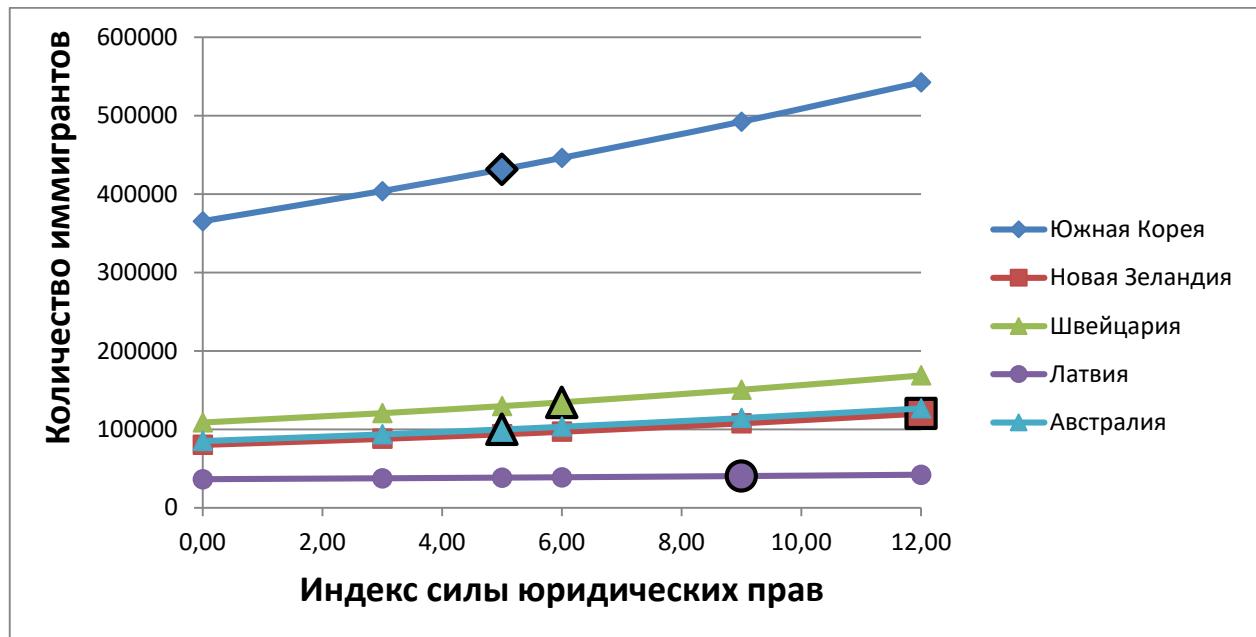


Рисунок 32. Зависимость количества иммигрантов от индекса силы юридических прав

Довольно интересная тенденция наблюдается на рисунке 4: приток иммигрантов снижается с ростом значения ВВП на душу населения. Аналогичные результаты получаются при варьировании числа врачей на 1000 человек. Впрочем, количество врачей позволяет говорить об охвате людей медицинскими услугами, но не об их качестве.

Рост ВВП, в свою очередь, не дает судить о качестве жизни населения, хоть и является ориентиром в большинстве вариантов экономической политики. К тому же, при подсчете данного показателя истощение природных ресурсов считается доходом, так что полученные нейросетью результаты могут служить предостережением.

Стоит отметить и влияние структуры обучающего множества: страны с малым числом врачей и значением ВВП зачастую обладали одними из самых больших значений выходного параметра. Считать подобные примеры выбросами или сохранять их, подчеркивая неоднозначность предметной области – вопрос, который остается открытым.

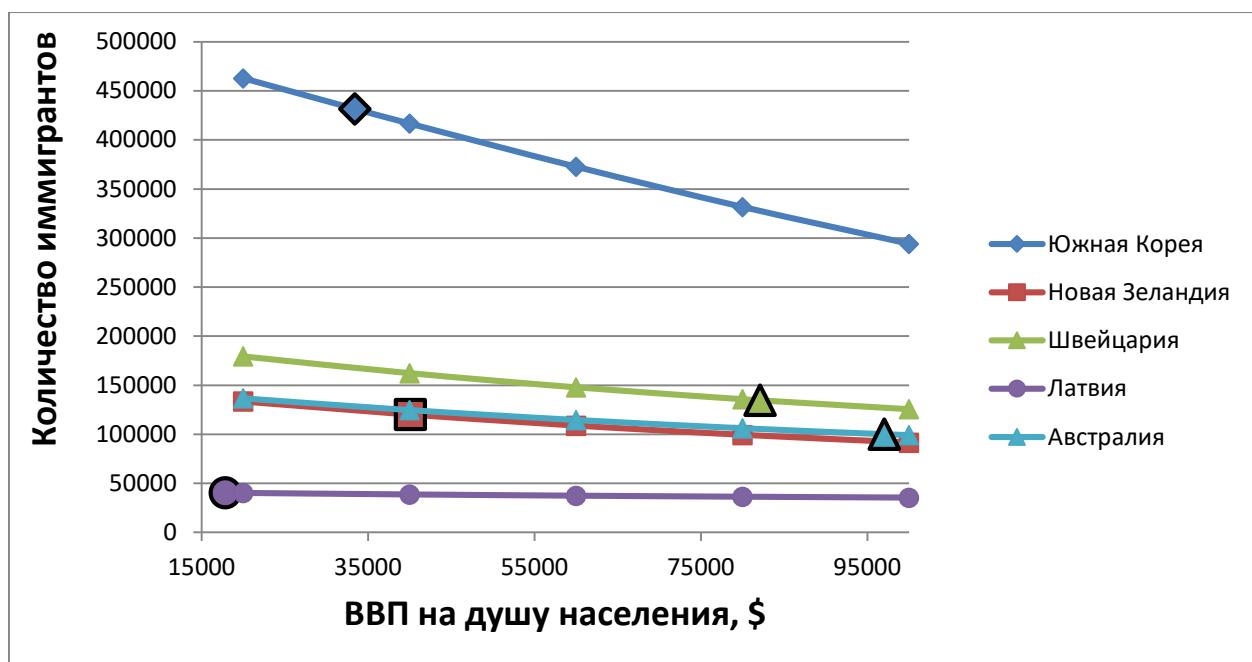


Рисунок 33. Зависимость количества иммигрантов от валового внутреннего продукта (ВВП) на душу населения

Рисунок 5 отражает еще одну объективно существующую закономерность: при изменении оттока иностранного населения следует ожидать, что его приток будет как минимум на том же уровне – ввиду статистической устойчивости данного показателя.

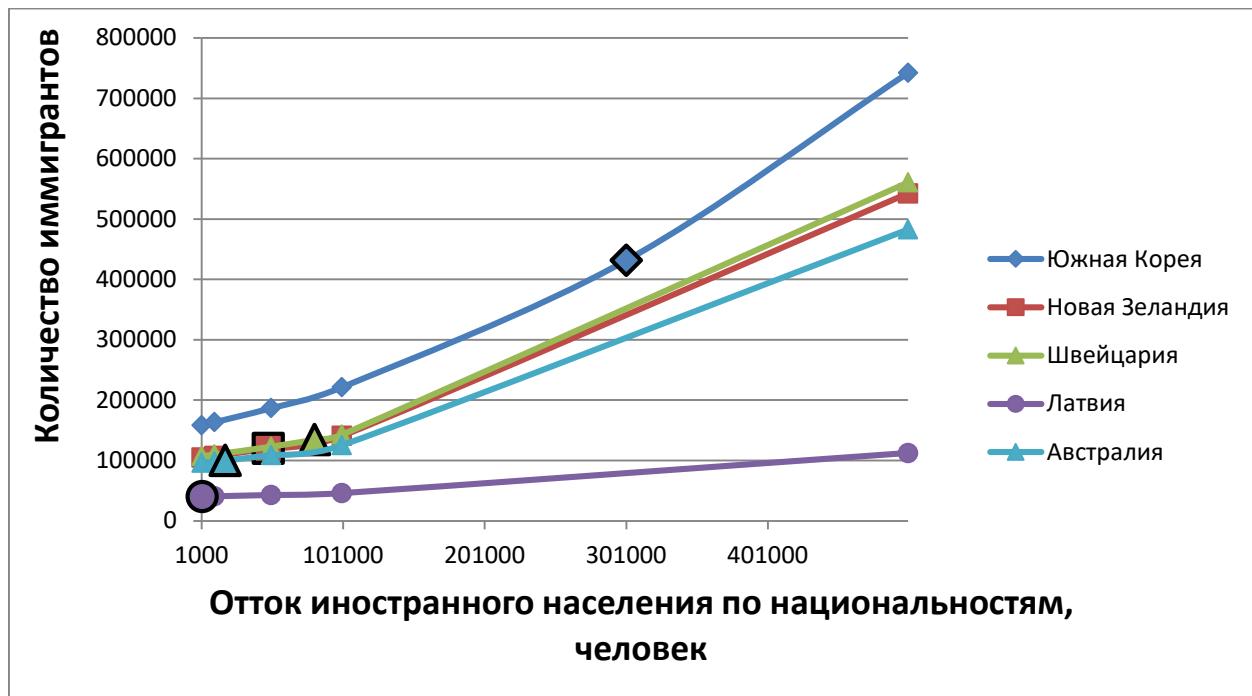


Рисунок 34. Зависимость количества иммигрантов от оттока иностранного населения по национальностям

Необычен следующий результат: с ростом безработицы для одних стран (Новая Зеландия, Швейцария, Австралия) приток иммигрантов растет, а для

других – уменьшается, причем в обоих случаях изменения незначительны. Впрочем, его могут формировать и другие факторы: к примеру, наличие рабочих мест в конкретных областях деятельности и наиболее популярные отрасли среди иммигрантов. Оказывают влияние и факторы, для которых сложна объективная оценка, такие как доступность переезда.

Во всех рассмотренных случаях можно заметить, что в Южной Корее изменения притока иммигрантов происходят наиболее быстро, а в Латвии – наиболее медленно. Швейцария, Новая Зеландия и Австралия, в свою очередь, находятся примерно на одном уровне.

Заключение. В результате работы была построена система нейросетевого моделирования уровня иммиграции для различных государств, учитывающая три категории показателей: социально-демографические, экономические, политico-правовые. Исследования, проведенные с ее помощью, в целом характеризуют предметную область, а выбранные примеры позволяют показать проблематику ее изучения. Однако результаты имеют некоторую погрешность ввиду малого объема обучающего множества (связанного, в свою очередь, с недостаточной обновляемостью данных). Использование полученной системы позволит по-новому посмотреть на социологию миграции, а также выявить оптимальный уровень изменений во внутренней политике государства.

Библиографический список

1. Эмиграционные настроения – Левада-Центр. URL –
<https://www.levada.ru/2019/11/26/emigratsionnye-nastroeniya-4/>
2. Доклад о развитии человека 2009. Преодоление барьеров: человеческая мобильность и развитие. Глава 4: Последствия для мест происхождения и мест назначения. URL –
https://www.un.org/ru/development/hdr/2009/hdr_2009_ch4.pdf
3. Дудукина А.Е. Исследование математических моделей и методов прогнозирования миграции населения / Проблемы современной экономики. Центр развития науч. сотрудничества. – 2016. – № 34. – С.73-80.
4. Батищева Г.А., Журавлева М.И., Трофименко Е.А. Экономико-статистический анализ факторов внешней миграции / Актуальные вопросы современной экономики. Институт развития образования и консалтинга. – 2019. – № 1. С. 275-280
5. Таскаева С.В. Факторы, определяющие миграцию населения / Вестник Читинского государственного университета. Забайк. государств. ун-т. 2007. – № 3 (44) – С. 174-179
6. Подгорнова Н.А. Применение нейронных сетей для оценки привлекательности регионов России для зарубежной трудовой миграции / Информационные технологии. Межвузовский сборник научных трудов. Рязан. государств. радиотехн. ун-т им. В.Ф. Уткина. – 2020. – С. 115-118
7. World Development Indicators | DataBank. URL –
<https://databank.worldbank.org/source/world-development-indicators#>

8. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 5.0 / Свидетельство о государственной регистрации программы для ЭВМ № 2014618208. Заявка Роспатент № 2014614649. Зарегистрировано в Реестре программ для ЭВМ 12 августа 2014г.
9. Ясницкий Л.Н. Интеллектуальные системы. – М.: Лаборатория знаний, 2016. –221 с.

PREDICTION OF IMMIGRATION RATE BASED ON NEURAL NETWORKS

Ermakov Vitaliy A., Zyryanova Anna R.

Str. Bukireva, 15, Perm, Russia, 614990.

progamer20332@gmail.com, anya255786@gmail.com

The article describes the development of a neural network system for predicting immigration rate in different countries, as well as the process and results of research conducted by its usage.

Keywords: neural networks, prognosis, forecasting, immigration, patterns, simulation.

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В МЕТЕОРОЛОГИИ

НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗА ГОЛОЛЕДА В ГОРОДЕ ПЕРМИ

Вакорин Антон Романович, Свиязов Евгений Михайлович

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15.
rtym@yandex.ru, sviyazov74@mail.ru

В статье представлено описание разработки нейросетевой системы для прогнозирования вероятности образования гололеда. Система позволяет прогнозировать возможность образования гололеда с учетом метеорологических показателей.

Ключевые слова: искусственный интеллект, нейросетевые технологии, метеорология, прогноз погоды.

Введение. Прогнозирование погоды в современном мире является одной из тех тем, которой заинтересованы представители многих сфер жизни людей. Прогнозирование образования гололеда позволит проводить своевременную обработку улиц коммунальными службами.

На данный момент известно большое число исследований, применяющих средства нейросетевого моделирования для прогнозирования погоды [10]. Важность решения этой проблемы подчеркивают недавние публикации зарубежных исследователей [1-4]. В данных работах отмечается высокая эффективность и значительное уменьшение ошибки при использовании нейросетей, в сравнении с традиционными подходами.

Среди российских исследователей тема анализа обледенения улиц рассматривается в статьях [5-7], но в этих статьях анализ проводится традиционными статистическими методами.

В данной статье предлагается анализ данной проблемы с использованием нейронных сетей. Для проведения анализа было собрано множество из параметров, собранных с наземных метеорологических наблюдений в аэропорту Пермь (Большое Савино), представленных в хранилище погодной информации [8], и аэрологических данных по станции Пермь (Бахаревка) из базы данных университета Вайоминга [9] за период сентябрь–апрель 2012–2020 годов.

В исходное множество попали следующие параметры:

Время наблюдения: YEAR – год; MON – месяц; DAY – день; Z – время в часах (0 или 12); Ps – атмосферное давление на уровне моря (гПа); Ts – температура воздуха на высоте 2 м от земли (градусы Цельсия); dTs – дефицит точки росы на высоте 2 м от земли (градусы Цельсия); Ds – направление ветра на высоте 10 м от земли (градусы); Vs – скорость ветра на высоте 10 м от земли (узлы); DPs – изменение атмосферного давления на уровне моря за 12 часов

(гПа); DTs – изменение температуры воздуха на высоте 2 м от земли за 12 часов (градусы Цельсия); DdT_s – изменение дефицита точки росы на высоте 2м от земли за 12 часов (градусы Цельсия); DDs – изменение направления ветра на высоте 10 м от земли за 12 часов (градусы); DVs – изменение скорости ветра на высоте 10 м от земли за 12 часов (узлы); H1000 – высота изобарической поверхности 1000 гПа (м); DH1000 – изменение высоты изобарической поверхности 1000 гПа за 12 часов (м); H925 – высота изобарической поверхности 925 гПа (м); T925 – температура воздуха на изобарической поверхности 925 гПа (градусы Цельсия); dT925 – дефицит точки росы на изобарической поверхности 925 гПа (градусы Цельсия); D925 – направление ветра на изобарической поверхности 925 гПа (градусы); V925 – скорость ветра на изобарической поверхности 925 гПа (узлы); DH925 – изменение высоты изобарической поверхности 925 гПа за 12 часов (м); DT925 – изменение температуры воздуха на изобарической поверхности 925 гПа за 12 часов (градусы Цельсия); DdT925 – изменение дефицита точки росы на изобарической поверхности 925 гПа за 12 часов (градусы Цельсия); DD925 – изменение направления ветра на изобарической поверхности 925 гПа за 12 часов (градусы); DV925 – изменение скорости ветра на изобарической поверхности 925 гПа за 12 часов (узлы); H850 – высота изобарической поверхности 850 гПа (м); T850 – температура воздуха на изобарической поверхности 850 гПа (градусы Цельсия); dT850 – дефицит точки росы на изобарической поверхности 850 гПа (градусы Цельсия); D850 – направление ветра на изобарической поверхности 850 гПа (градусы); V850 – скорость ветра на изобарической поверхности 850 гПа (узлы); DH850 – изменение высоты изобарической поверхности 850 гПа за 12 часов (м); DT850 – изменение температуры воздуха на изобарической поверхности 850 гПа за 12 часов (градусы Цельсия); DdT850 – изменение дефицита точки росы на изобарической поверхности 850 гПа за 12 часов (градусы Цельсия); DD850 – изменение направления ветра на изобарической поверхности 850 гПа за 12 часов (градусы); DV850 – изменение скорости ветра на изобарической поверхности 850 гПа за 12 часов (узлы); H700 – высота изобарической поверхности 700 гПа (м); T700 – температура воздуха на изобарической поверхности 700 гПа (градусы Цельсия); D700 – направление ветра на изобарической поверхности 700 гПа (градусы); V700 – скорость ветра на изобарической поверхности 700 гПа (узлы); DH700 – изменение высоты изобарической поверхности 700 гПа за 12 часов (м); DT700 – изменение температуры воздуха на изобарической поверхности 700 гПа за 12 часов (градусы Цельсия); DD700 – изменение направления ветра на изобарической поверхности 700 гПа за 12 часов (градусы); DV700 – изменение скорости ветра на изобарической поверхности 700 гПа за 12 часов (узлы); SdT – суммарный дефицит в слое от поверхности земли до изобарической поверхности 850 гПа (градусы Цельсия); H925-1000 – превышение изобарической поверхности 1000 гПа над изобарической поверхностью 925 гПа (м); H850-1000 – превышение изобарической поверхности 1000 гПа над изобарической поверхностью 850 гПа (м); H700-1000 – превышение изобарической 1000 гПа над изобарической поверхностью 700 гПа (м); H850-925 – превышение изобарической поверхности 925 гПа над изобарической поверхностью 850 гПа

(м); H700-925 – превышение изобарической поверхности 925 гПа над изобарической поверхностью 700 гПа (м); H700-850 – превышение изобарической поверхности 850 гПа над изобарической поверхностью 700 гПа (м); DSdT – изменение суммарного дефицита в слое от поверхности земли до изобарической поверхности 850 гПа (градусы Цельсия); Dmean – среднее направление ветра от поверхности земли до изобарической поверхности 850 гПа; DH925-1000 – изменение превышения изобарической поверхности 1000 гПа над изобарической поверхностью 925 гПа за 12 часов (м); DH850-1000 – изменение превышения изобарической поверхности 1000 гПа над изобарической поверхностью 850 гПа за 12 часов (м); DH700-1000 – изменение превышения изобарической поверхности 1000 гПа над изобарической поверхностью 700 гПа (м); DH850-925 – изменение превышения изобарической поверхности 925 гПа над изобарической поверхностью 850 гПа (м); DH700-925 – изменение превышения изобарической поверхности 925 гПа над изобарической поверхностью 700 гПа (м); DH700-850 – изменение превышения изобарической поверхности 850 гПа над изобарической поверхностью 700 гПа (м); LV – рассчитывается по формуле $LV=V925+V850-Vs-V700$ (узлы); DDmean – изменение среднего направления ветра от поверхности земли до изобарической поверхности 850 гПа за 12 часов (градусы); DLV – изменение величины LV за 12 часов; Оцениваемым параметром является вероятность образования гололеда в течении следующих 12 часов (0-нет гололеда/1-гололед образуется).

По причине особенностей образования гололеда в разное время суток, исходное множество было разделено на два: наборы, собранные в 0 часов среднего гринвичского времени (СГВ), что соответствует 5-6 часам местного времени и наборы, собранные в 12 часов СГВ (17-18 часов местного времени). Модель обучалась на общем множестве и отдельно на каждом из разделённых.

Предобработка исходных данных, проектирование, обучение, тестирование нейронной сети выполнялись в среде Jupiter Notebook на языке Python с использованием библиотек Pandas, Numpy, TensorFlow, Keras, Scikit learn.

Для работы была построена нейросеть, содержащая один скрытый слой с 15 нейронами и активационной функцией тангенс гиперболический. При обучении нейросети из обучающего множества выделяется множество на валидацию в размере 20% от обучающего. Дополнительно на входной слой поставлен слой нормализации.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 20 примеров – 4 примера, где гололед образуется и 16 примеров, где гололед не образуется.

По причине сильного перекоса в исходном множестве модель не смогла обучиться распознавать условия образования гололеда и для всех входных примеров выдавала 0. Поэтому было принято решение сделать предобработку данных.

Прежде всего было решено избавиться от показателей времени, поскольку структура множества уже содержит эту информацию. Далее, для устранения перекоса, мы воспользовались приёмами аугментации.

Перекос исходного множества составляет 1 к 75. Соответственно мы разделили множество на два подмножества: содержащие наборы для 0 и для 1. После этого применили первый приём аугментации – размножение. Но так как после размножения часть элементов обучающего множества может попасть в тестовое, то разделение на обучающее и тестовое множества производится перед размножением наборов.

При обучении только на примерах, прогнозирующих гололед во вторую половину дня, наиболее оптимальным оказалось размножение в 80 раз до пропорции 3 к 5 – число примеров, в которых гололед образуется к числу примеров, в которых это не происходит. После обучения среднеквадратичная ошибка (MSE) тестирования составила 0,16, что можно считать приемлемым результатом.

При прогнозировании гололеда в первую половину дня, примеров с гололедом оказалось больше, поэтому размножение примеров производилось 60 раз до отношения 1 к 1. В результате тестирования, представленного на рисунке 3, среднеквадратичная ошибка (MSE) составила 0,16.

При использовании объединённого множества использовалось размножение с уменьшением перекоса до 2 к 3 и удалось добиться среднеквадратичной ошибки (MSE) в 0,16 на тесте. Но данная нейросеть всё ещё плохо различает случаи, в которых есть гололед от случаев, в которых её нет.

Применяя простое размножение, уже удалось заставить нейросеть учитывать случаи образования гололеда, но для полноценного обучения такого подхода оказалось недостаточно. Поэтому следующим этапом должно быть усложнение подхода аугментации и введение разброса в значения. Для каждого погодного показателя были вычислены границы, при которых образование гололеда наиболее вероятно. После этого, при размножении строк, для каждой строки и для каждого параметра случайным образом выбиралось новое значение из вычисленных границ параметра и существующее значение этого параметра заменялось новым значением.

Для модели, обученной на множестве второй половины дня, среднеквадратичная ошибка (MSE) упала до 0,13.

Модель прогнозирующая гололед в первую половину дня также улучшила среднеквадратичную ошибку (MSE) до 0,14.

Для модели, обучаемой на объединённом множестве, также получилось улучшить результат, среднеквадратичная ошибка этой модели упала до 0,15, и модель стала лучше различать состояние погоды.

Дополнительный способ улучшить модель – введение регуляризатора. Для данной задачи был выбран L2-регуляризатор.

При добавлении регуляризатора модель, прогнозирующую гололед во вторую половину дня, удалось улучшить до среднеквадратичной ошибки (MSE) в 0,08.

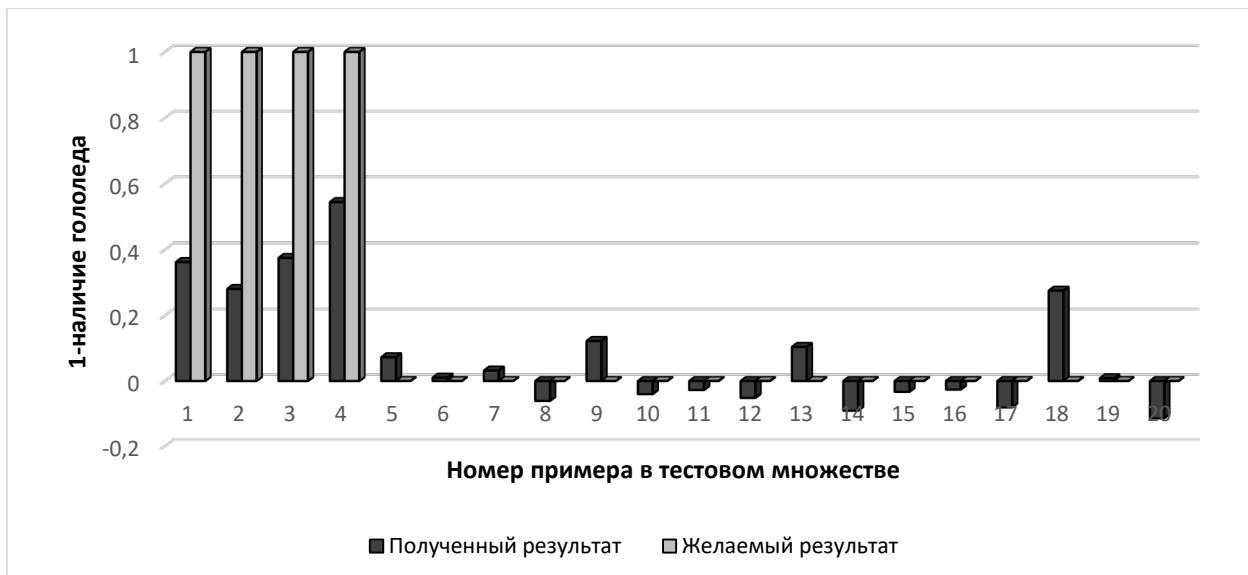


Рисунок 1. Результат тестирования нейронной сети, обученной на примерах 12–0 часов

Прогноз для первой половины дня также улучшился до среднеквадратичной ошибки (MSE) в 0,12.

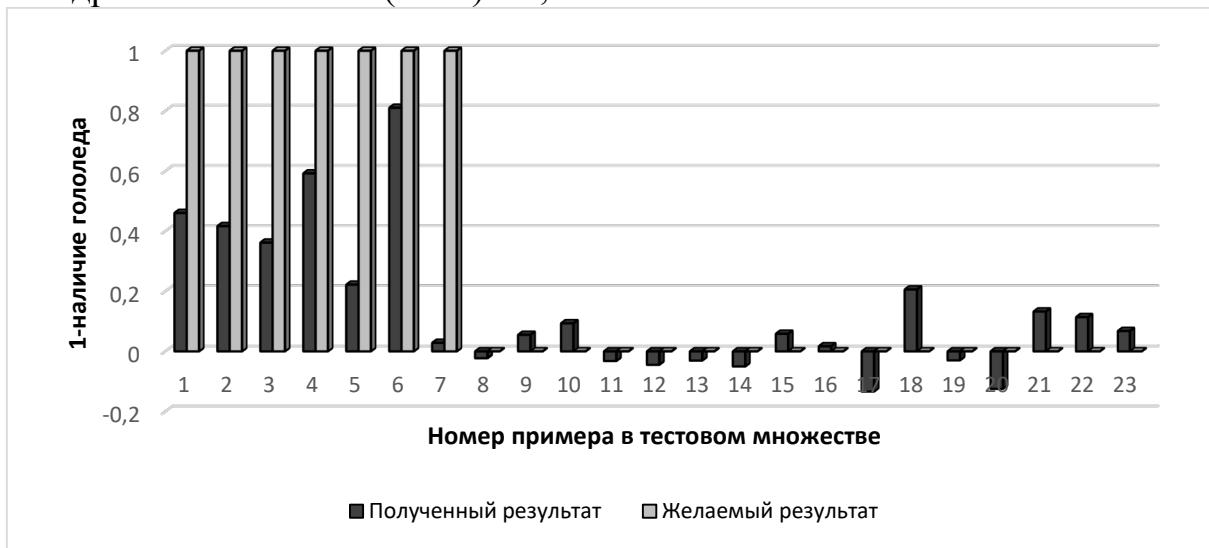


Рисунок 2. Результат тестирования нейронной сети, обученной на примерах 0–12 часов

Общая модель также улучшила показатель среднеквадратичной ошибки (MSE) до 0,14.



Рисунок 3. Результат тестирования нейронной сети, обученной всех на примерах

Заключение. Построена система нейросетевого оценивания вероятности возникновения гололеда в г. Перми. Изучены и применены методы устранения перекоса, такие как аугментация, аугментация с заменой значений и введение регуляризации.

Библиографический список

1. Kim S., Pan S., Mase H. Artificial neural network-based storm surge forecast model: Practical application to Sakai Minato, Japan. *Applied Ocean Research*. Volume 91, October 2019.
2. Baboo S. S., Shereef I. K. An efficient weather forecasting system using artificial neural network // *International journal of environmental science and development*. – 2010. – Т. 1. – №. 4. – С. 321.
3. Abhishek K. et al. Weather forecasting model using artificial neural network // *Procedia Technology*. – 2012. – Т. 4. – С. 311-318.
4. Tripathy A. K. et al. Weather forecasting using ANN and PSO // *Int. J. Sci. Eng. Res.* – 2011. – Т. 2. – С. 1-5.
5. Глазов А.В. Автоматизированная информационная система планирования уборки снега на городских улицах // Современные инновационные технологии подготовки инженерных кадров для горной промышленности и транспорта. – 2017. – №. 4. – С. 368-372.
6. Кралин А. К., Шаймухаметов С. А. Возникновение зимней скользкости дорог и свойства льда // Вісник Донбаської національної академії будівництва і архітектури. – 2016. – №. 6. – С. 115-121.
7. Зубайраев А.А. Природа возникновения гололедицы и ее влияние на безопасность дорожного движения. – 2013.
8. Погода в 243 странах мира URL: <https://rp5.ru/> (дата обращения: 02.02.2021).
9. Atmospheric Soundings URL: <http://weather.uwyo.edu/upperair/sounding.html> (дата обращения: 02.02.2021).
10. Быков А.В., Вакорин А.Р., Ветров А.Л., Ясицкий Л.Н. Нейросетевая система прогноза опасных метеорологических условий //

Интеллектуальные системы в науке и технике. Искусственный интеллект в решении актуальных социальных и экономических проблем XXI века [Электронный ресурс] : сборник статей по материалам Международной конференции «Интеллектуальные системы в науке и технике» и Шестой всероссийской научно-практической конференции «Искусственный интеллект в решении актуальных социальных и экономических проблем XXI века» (г. Пермь, 12–18 октября 2020 г.) / под редакцией Л. Н. Ясницкого ; Пермский государственный национальный исследовательский университет. – Электронные данные. – Пермь, 2020. – 16,7 Мб ; С. 471-484. – Режим доступа: <https://www.elibrary.ru/item.asp?id=44314651>

NEURAL NETWORK SYSTEM FOR FORECASTING THE ICING OF STREETS OF THE PERM

Vakorin Anton R., Sviyazov Evgeny M.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990

The article describes the development of a neural network system for predicting the likelihood of icing on the streets. The system allows people to forecast the probability of icing on the streets considering meteorological indicators.

Keywords: artificial intelligence, neural network technologies, meteorology, weather forecast.

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В ПРОБЛЕМАХ БЕЗОПАСНОСТИ

НЕЙРОСЕТЕВАЯ СИСТЕМА МОНИТОРИНГА ПОЖАРНОЙ ОБСТАНОВКИ ПО АНАЛИЗУ ВИДЕОДАННЫХ С БЕСПИЛОТНЫХ ЛЕТАТЕЛЬНЫХ АППАРАТОВ

Шевцов Максим Викторович

ФГБОУ ВО «Академия Государственной противопожарной службы МЧС
России» г. Москва, 129366, улица Бориса Галушкина, д. 4

Горбачев Игорь Николаевич, Филист Сергей Алексеевич

Юго-Западный государственный университет,
305040, Россия, г. Курск, ул. 50 лет Октября, 94, SFilist@gmail.com

В статье представлено исследование нейросетевой модели анализатора аэроснимков, полученных с квадрокоптера при мониторинга пожарной обстановки заданной местности. Для реализации модели предложено классифицировать сегменты снимков, полученных из видеопотока, размеры которых меняются в зависимости от обнаруженной зоны интереса.

Ключевые слова: анализ пожарной обстановки, беспилотный летательный аппарат, поток видеоданных, автономные интеллектуальные агенты, нейронные сети.

Введение. Определение дислокации пожаров с помощью компьютерного зрения с достаточной точностью и оперативностью является трудной задачей [1]. Принято, что в качестве дескрипторов для определения координат источника возгорания используется температурная карта, полученная посредством тепловизора или инфракрасной камеры. Однако на инфракрасных камерах пожарами будут выглядеть места с высокой температурой воздуха, а некоторые участки поверхности будут приняты за источники тепла только из-за особенностей отражения света. К тому же такие камеры существенно дороже. Поэтому при использовании в мониторинге пожарной обстановки дронов, входящих в автоматизированную систему мониторинга пожарной обстановки, на их борту для поиска очага пожара целесообразно устанавливать RGB-камеры, который используются для съёмки всего района, а фотографии затем анализируются посредством автономных интеллектуальных агентов (АИА), построенных на основе моделей машинного обучения [2, 3, 4].

Для анализа RGB-изображений в настоящее время широко используются сверточные нейронные сети (СНС) различной архитектуры. Однако у них имеются два существенных недостатка, которые препятствуют их использованию в автоматизированной системе оценки пожарной обстановки. Первый недостаток связан с большим потоком видеоданных, поступающих с видеокамер дрона на СНС в процессе мониторинга. Это обстоятельство не позволяет удовлетворить требованияния по оперативности анализа снимков. Второй

недостаток СНС связан с тем, что СНС классифицирует снимок в целом, тогда как на пульт ЛПР необходимо передать координату возгорания, то есть классификация снимка должна осуществляться сегментарно, что снижает преимущества СНС при решении этой задачи.

Методы и модели. За основу построения классификатора пожарной обстановки взят метод классификации RGB-видеоданных, поступающих от видеокамеры дрона, основанный на понятии каскадного окна [5, 6, 7]. Сущность метода классификации, используемого в этой системе, состоит в том, что каждый снимок пошагово разбивается на квадратные сегменты уменьшающегося размера, которые последовательно сканируются по правилу строчной развертки. Решения по принадлежности сегмента к одному из классов пожароопасности – «пламя», «дым», «чисто» – принимается классификатором по дескрипторам, полученным по результатам анализа соответствующего сегмента снимка.

Таким образом, если имеет место крупный пожар, то выбор крупных сегментов вначале сканирования обеспечивает оперативность принятия решения в системе в целом. Такой подход к классификации также может обеспечить двухступенчатую классификацию, когда на более крупном масштабе выбирается область интереса (ROI), а затем эта область сканируется на более мелком масштабе [8, 9].

На выходах классификатора, построенного по предлагаемому методу, будет представлено не само искомое изображение в бинарной форме, а только класс пожароопасности соответствующего сегмента. При этом классификаторы выделяемых сегментов построены не на методах попиксельной классификации, а по методу сегментарной классификации таким образом, что все пиксели изображения, попавшие в выделенный сегмент, по результатам анализа которого формируются дескрипторы, относятся к одному классу.

Процедура формирования сегментов снимка заключается в том, что растровое изображение декомпозируется на некоторое количество уровней. Каждый уровень содержит множество потомков – изображений. Изображение верхнего уровня является «материнским» изображением для множества изображений-потомков нижнего уровня, как и изображение нижнего уровня является «материнским» для изображений следующего (нижнего по отношению к этому изображению) уровня [10].

На рисунке 1 представлена схема сегментации аэроснимка. На первом уровне имеем четыре сегмента. Например, в качестве способа декомпозиции может быть использовано правило $\langle 2^{2n} \rangle$. Это значит, что на первом уровне имеем 4 изображения-потомка, на втором – 16, на третьем – 64 и т.д. [11].

Для того, чтобы отобразить классы опасности на исходном (не сегментированном) снимке, сегменты кодируются. На рисунке 1 представлен принцип кодирования сегментов. Код сегмента записан внутри каждого сегмента. На втором уровне имеем шестнадцать сегментов. Если быть более точным, то каждый сегмент на определенном уровне разбивается на четыре сегмента. Сегменты имеют одинаковые размеры. Каждый сегмент, в зависимости от решения ЛПР, которое определяется спецификой объекта мониторинга и уровнем пожароопасности, классифицируется либо на два класса:

«ROI» и «НЕ ROI», либо на три вышеупомянутых класса, характеризующих конкретный класс пожароопасности обстановки в сегменте снимка. Если принимается решение, что этот сегмент «ROI», то он переводится на следующий уровень с последующим делением на четыре одинаковых сегмента, а если классифицируется как «НЕ ROI», то осуществляется переход на классификацию следующего сегмента.

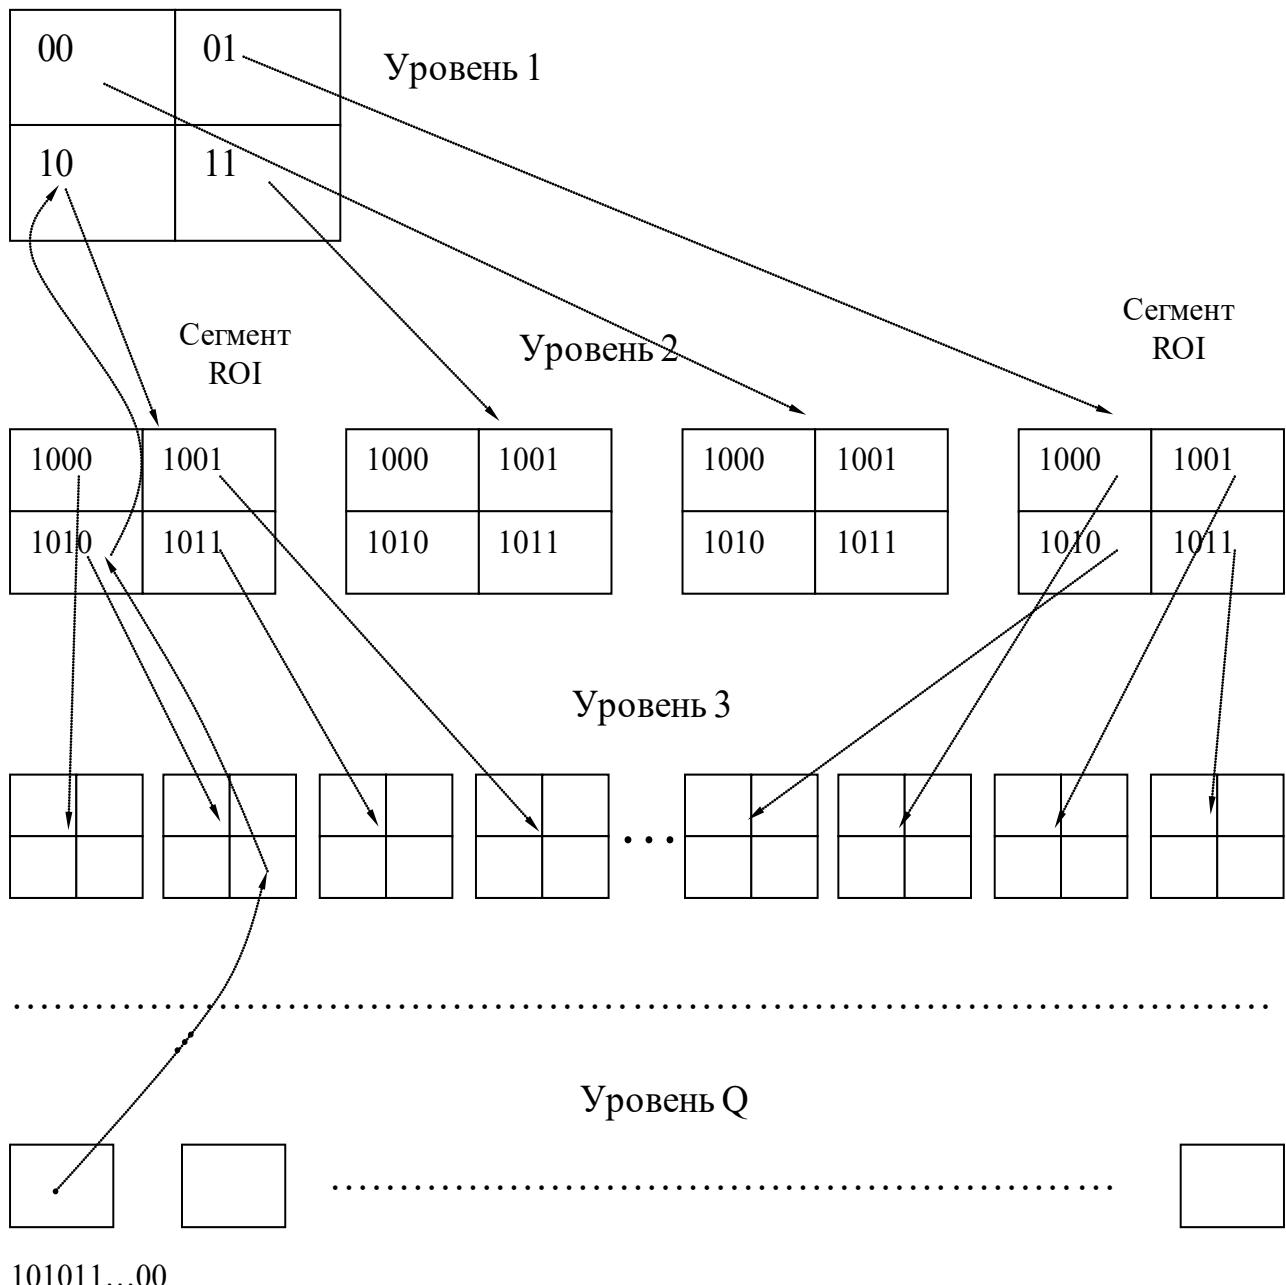


Рисунок 1. Схема формирования сегментов снимка

Каждый сегмент в полученной иерархии кодируется соответствующим числом, которое описывает его статус в этой иерархии, то есть его отношение к сегментам предшествующего (вышестоящего) уровня. Для каждого уровня декомпозиции формируется свой АИА. Агрегирование их решений осуществляется «сильный» классификатор.

Структурная схема классификатора, построенного по такому принципу, представлена на рисунке 2. Блок формирования сегментов делит снимок на квадратные сегменты и осуществляет их расщепление на три RGB-изображения, которые поступают на блоки формирования дескрипторов дескрипторов. Векторы дескрипторов подаются на соответствующие входы классификаторов, которые в этой архитектуре выступают как «слабые» классификаторы. «Сильный» классификатор, выполненный по схеме многослойного персептрона, осуществляет агрегацию их решений.

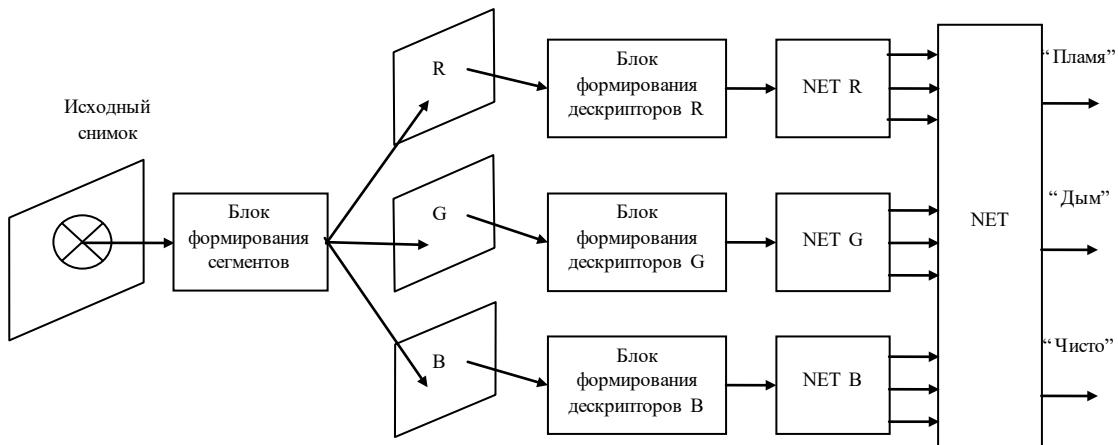


Рисунок 2. Структурная схема классификации видеоданных

Снимки формировались из различных источников по видеопотокам, поступающих с дронов. Для формирования базы данных снимков для формирования обучающих и контрольных выборок из каждого ролика извлекалось множество кадров, что позволяет быстро получить большой и качественный датасет. Снимки сегментировались в полуавтоматическом режиме. Затем выделенные сегменты марковались в ручном режиме. Таким образом, была получена база данных для формирования обучающих выборок на три класса сегментов.

Обучающие выборки включают множество дескрипторов с соответствующим маркером класса. Если в системе используются динамические сегменты, принцип формирования которых представлен на рисунке 1, то обучающие выборки формируются для каждого размера сегмента, так как размер вектора дескрипторов и значения его компонент зависят от его размера. В этом случае «слабые» и «сильные» классификаторы настраиваются для каждого размера сегмента. Таким образом, оптимизация оперативности принятия решений в системе требует дополнительных усилий по настройке классификаторов и увеличивает как объем обучающих выборок, так и количество классификаторов.

Заключение. Апробация системы показала ее высокую помехоустойчивость к погодным аномалиям. Маршруты патрулирования дронов согласуются с метеосводками и дроны направляются в «красные зоны». Это районы, в которых температура воздуха, направление и сила ветра, влажность и

атмосферное давление повышают вероятность возникновения пожаров. С дрона поток видеоданных направляется в систему для их анализа. Система определяет на снимках области, в которых высоки вероятности огня и дыма. Красная рамка или подсветка на аэроснимке с дрона определяет границы возгорания с вероятностью 67 %. Решение, есть ли на самом деле в этой координате огонь или дым, принимается ЛПР по результатам анализа потока видеоданных, обработанных системой.

Библиографический список

1. Кореневский Н.А., Филист С.А., Красковский А.Б. и др. Теория проектирования нечетких сетевых экспертных систем для управления медико-экологической безопасностью // Научные ведомости Белгородского государственного университета. Серия: История. Политология. Экономика. Информатика. 2009. № 9-1 (64). Том 11. С.146-151.
2. Томакова Р.А., Емельянов С.Г., Филист С.А. Интеллектуальные технологии сегментации и классификации биомедицинских изображений: монография. – Курск: Юго-Зап. гос. ун-т., 2012. – 222 с.
3. Филист С.А., Дюдин М.В., Зуев И.В. и др. Автоматические классификаторы сложно структурируемых изображений на основе мультиметодных технологий многокритериального выбора // Вопросы радиоэлектроники. Серия: Системы и средства отображения информации и управления спецтехникой (СОИУ). – 2015. – Выпуск 1. – С.130-140.
4. Филист С.А., Уварова В.В., Шуткин А.Н. Структурно-функциональная модель мета-анализа медико-экологических данных // Вопросы радиоэлектроники. Серия «Общетехническая» (ОТ), 2015. – Выпуск 7. – С. 102 – 110.
5. Филист С.А., Дабагов А.Р., Томакова Р.А. и др. Многослойные морфологические операторы для сегментации сложноструктурных изображений // Известия Юго-Западного государственного университета. Серия: Управление, вычислительная техника, информатика, медицинское приборостроение. – 2019. – Т.9, №3. – С. 44-63.
6. Филист С.А., Кассим К.Д.А., Кузьмин А.А., Шаталова О.В., Алябьев Е.А. Формирование признакового пространства для задач классификации сложноструктурных изображений на основе спектральных окон и нейросетевых структур // Известия Юго-Западного государственного университета. – 2016. – №4(67). – С. 56-68.
7. Филист С.А. , Томакова Р.А., Дегтярев С.В., Рыбочкин А.Ф. Гибридные интеллектуальные модели для сегментации изображений рентгенограмм грудной клетки // Медицинская техника. – №5. 2017.- С. 41-45.
8. Филист С.А. , Шаталова О.В., Ефремов М.А. Гибридная нейронная сеть с макрослоями для медицинских приложений // Нейрокомпьютеры. Разработка, применение. – М.: Радиотехника, 2014. – №6. – С. 35 – 39.

9. Филист С.А., Томакова Р.А., Шаталова О.В., Кузьмин А.А., Кассим К.Д.А. Метод классификации сложноструктурных изображений на основе самоорганизующихся нейросетевых структур // Радиопромышленность. – 2016. – №4. – С. 57-65.
10. Дабагов А.Р., Горбунов В.А., Филист С.А. и др. Автоматизированная система классификации рентгенограмм молочной железы // Медицинская техника. – 2019. – №6 (318). – С. 39-41.
11. Дабагов А.Р., Малютина И.А., Кондрашов Д.С. и др. Автоматизированная система для классификации заболеваний молочной железы по рентгеновским маммографическим снимкам // Прикаспийский журнал: управление и высокие технологии. – 2019. – № 4 (48). – С.10-24.

NEURAL NETWORK SYSTEM FOR MONITORING THE FIRE SITUATION BY ANALYSIS OF VIDEO DATA FROM UNMANNED AIRCRAFT

Shevtsov Maxim V.

Federal State Budgetary Educational Institution of Higher Education "Academy of the State Fire Service of the MES of Russia" Moscow,
129366, Boris Galushkina Street, 4

Gorbochev Igor N., Filist Sergey A.

Southwest State University,
305040, Russia, Kursk, st. 50 years of October, 94,
SFilist@gmail.com

The article presents a study of the neural network model of the analyzer of aerial photographs obtained from a quadrocopter when monitoring the fire situation in a given area. To implement the model, it is proposed to classify segments of images obtained from a video stream, the sizes of which vary depending on the detected area of interest.
Keywords: analysis of the fire situation, unmanned aerial vehicle, video data stream, autonomous intelligent agents, neural networks.

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ В СПОРТЕ

ОЦЕНКА ПОСЕЩАЕМОСТИ МАТЧЕЙ БАСКЕТБОЛЬНОГО КЛУБА "ПАРМА" (ПЕРМСКИЙ КРАЙ)

Надежина Алина Александровна, Кожинов Константин Александрович
Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
kostya.kozhinov@yandex.ru

В статье представлено описание разработки динамической нейросетевой системы для прогнозирования посещаемости матчей баскетбольного клуба Парма, Пермский край. Система позволяет выполнять оценку посещаемости матча с учетом места проведения игры, команды-соперника, даты проведения, наличия онлайн-трансляции, периода повышенной заболеваемости.

Ключевые слова: нейронная сеть, прогнозирование, спортивный клуб, баскетбол, матч, сезон, посещаемость.

Введение. Прогнозирование посещаемости матчей играет большую роль как для болельщиков, так и для администрации баскетбольного клуба.

Доходная часть бюджета спортивного клуба формируется преимущественно за счет трех основных источников:

- спонсоры и реклама;
- доходы от продажи билетов и абонементов, а также всего, что связано с посещением матча (продажа клубной атрибутики, еды и т.д.);
- продажа прав на телетрансляцию спортивного мероприятия.

Можно прийти к выводу, что прогнозирование посещаемости может быть полезно для компаний и лиц, принимающих решения в различных отраслях, например:

- прогнозирование доходов стадиона;
- оценка рекламных возможностей стадиона;
- логистика и планирование персонала на стадионах;
- прогнозирование и планирование для независимых предприятий (например: ресторанов, кафе, парковок, такси), которые работают рядом со стадионами.

Подтверждением выдвинутой гипотезы может служить сообщение [1] на форуме от владельца кафе недалеко от стадиона «Этихад» в английском городе Манчестер: «Я хотел бы получить представление о возможном пешеходном движении, проходящем через мое кафе в игровой день». Владелец был озабочен тем, что, вероятно, ему предстоит встретить большой поток посетителей, но он никак не может рассчитать даже примерное количество. Посещаемость матча

зависит от большого множества факторов. Связь между ними практически невозможно установить, не используя нейронные сети.

Основная цель настоящей работы заключается в сборе информации о факторах, оказывающих значительное влияние на посещаемость матчей Пермского баскетбольного клуба «Парма». Баскетбольный клуб «ПАРМА» был основан 2 августа 2012 года. Домашней ареной баскетбольного клуба "ПАРМА" является легендарный универсальный дворец спорта "Молот", вмещающий 7000 зрителей. В дебютном сезоне «ПАРМА» стала лидером среди команд Высшей Лиги по посещаемости на домашних матчах (в среднем 1400 зрителей).

Авторы работы [2] выделили следующие основные факторы: день проведения матча, погодный фактор, выступление домашней команды, выступление гостевой команды, статус данного матча и сезонный интерес к матчам домашней команды. Нельзя не согласиться, что данные факторы действительно оказывают большое влияние на посещаемость, однако при рассмотрении посещаемости баскетбольных матчей некоторые из них будут неактуальны, например: погодный фактор. Баскетбольные матчи проводятся в закрытом помещении, погода не имеет значения.

Авторы работы [3] выделили следующие факторы, которые напрямую связаны со снижением посещаемости: динамика цен на билеты, динамика реальных располагаемых доходов населения, качество инфраструктуры, спортивная культура. Данные факторы действительно могут влиять на снижение посещаемости, однако в нашем случае оказалось невозможным собрать данные о ценах на билет прошедших матчей и сезонов.

В результате анализа наиболее значимых факторов, был выбран следующий набор показателей: X₁ – команда-соперник, X₂ – будний день или выходной, X₃ – дата предыдущего матча, X₄ – наличие онлайн-трансляции, X₅ – наличие повышенной заболеваемости, X₆ – домашняя или гостевая игра. Выходной параметр D₁ – количество посетителей.

Параметр команда-соперник был закодирован: 1 – ЦСКА, 2 – Локомотив-Кубань, 3 – Химки, 4 – Зенит, 5 – УНИКС, 6 – Автодор, 7 – Зелена Гура, 8 – Енисей, 9 – Калев, 10 – Цмоки-Минск, 11 – VEF, 12 – Астана, 13 – Нижний Новгород. Параметр будний день или выходной закодирован: 1 – будний день, 2 – выходной. Параметр наличие онлайн-трансляции закодирован: 0 – не было, 1 – было. Параметр период повышенной заболеваемости закодирован: 0 – нет, 1 – есть. Параметр домашняя или гостевая игра закодирован: 1 – домашняя, 2 – гостевая. Оставшийся параметр является числовым, поэтому для него кодировка не требуется.

Данные о посещаемости прошедших матчей были экспортованы с сайта Единой Лиги ВТБ [4]. Полученное множество было разделено на обучающее и тестирующее в соотношении 87% и 13% соответственно. Собранные данные охватывают период сезонов 2016-2017, 2017-2018, 2018-2019, 2019-2020, 2020-2021.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [5] по методике [6]. В результате оптимизации спроектированная нейронная сеть представляет собой персепtron,

который имеет шесть входных нейронов, один выходной, три нейрона на первом скрытом слое и два нейрона на втором скрытом слое.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество. Средняя ошибка тестирования составила 12.3%, что можно считать приемлемым результатом. На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактической и прогнозируемой нейросетью посещаемостью матчей из тестирующего множества.

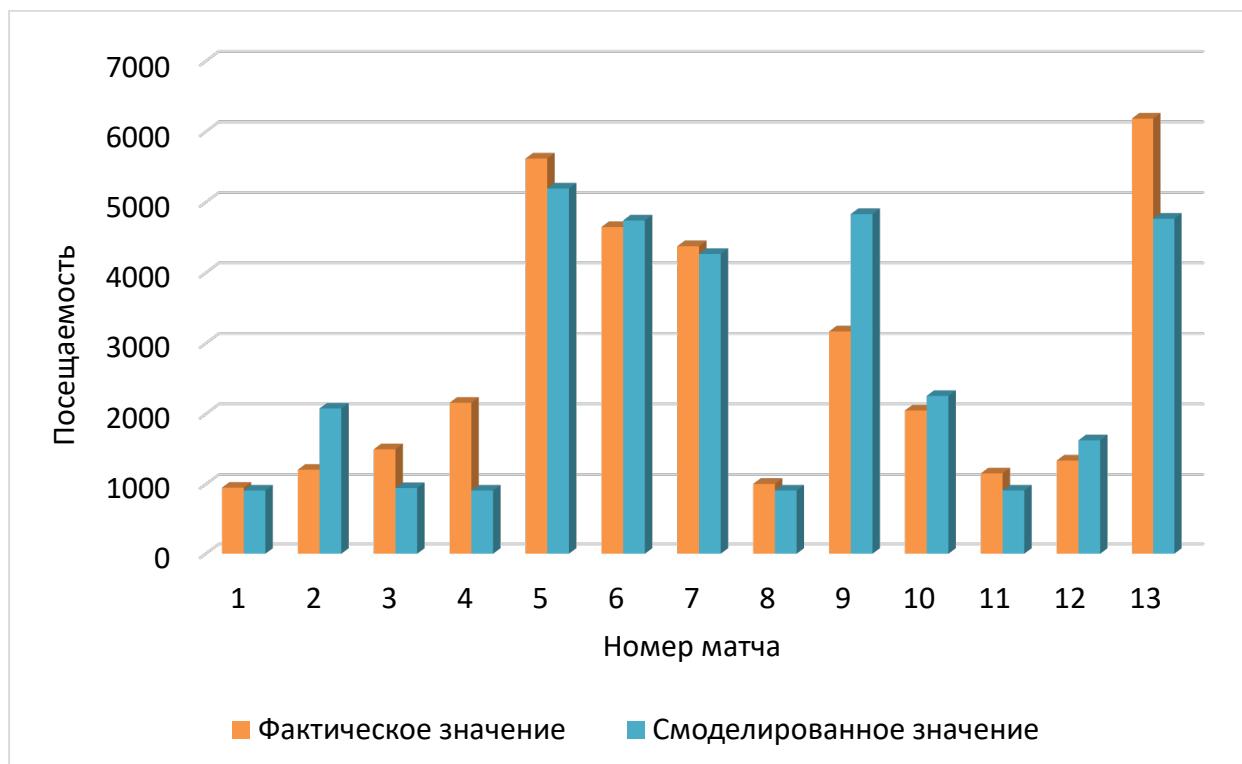


Рисунок 1. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 1, можно сделать вывод об адекватной работе спроектированной нейронной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5», результат отображен на рисунке 2.

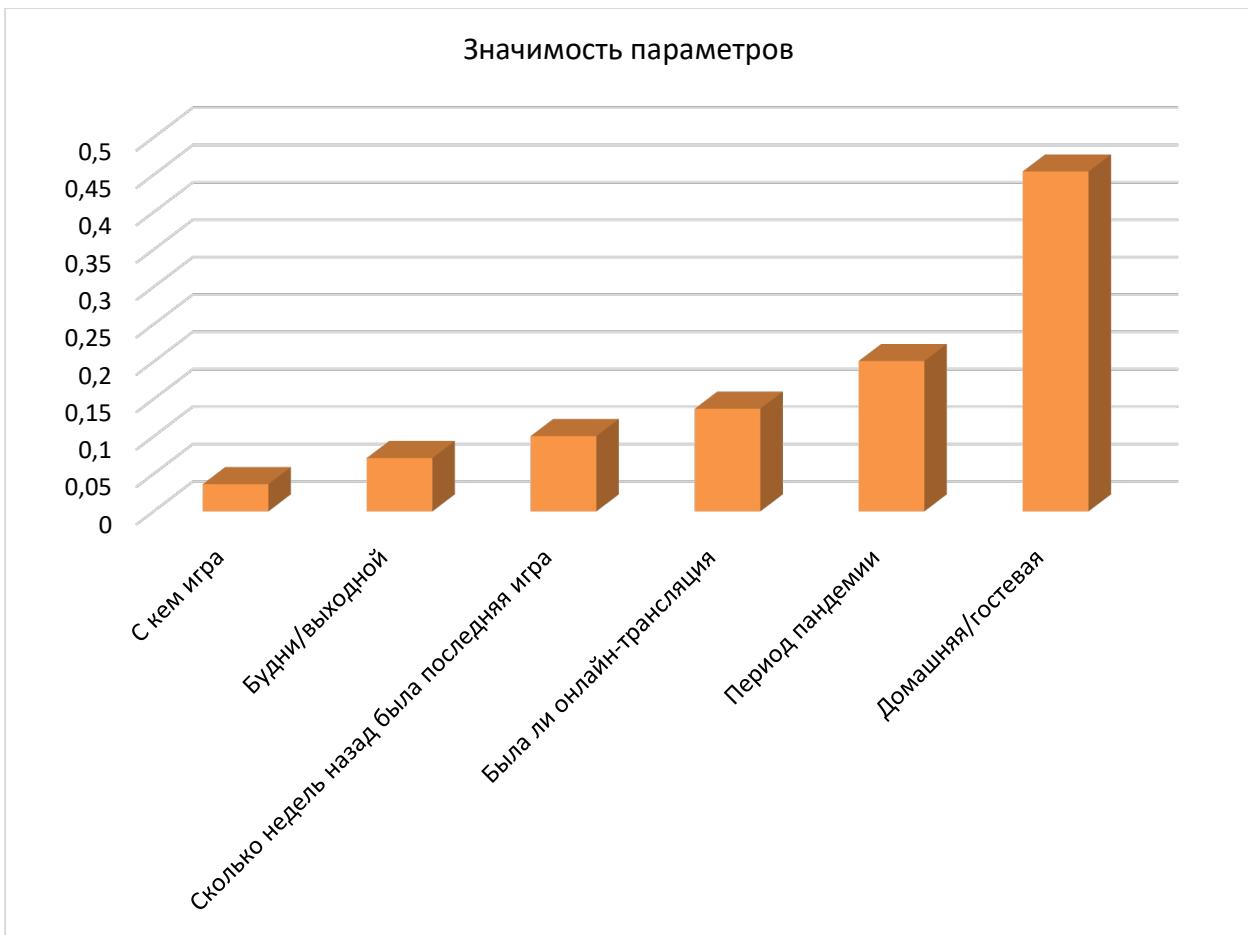


Рисунок 2. Значимость входных параметров нейросетевой модели

Как видно из рисунка 2, наиболее значимым является параметр домашняя или гостевая игра.

На основе данных о значимости параметров (рис. 2) можно сделать вывод о том, что все параметры в какой-либо степени значимы. Поэтому рассмотрим, как изменение каждого отдельного параметра повлияет на посещаемость матча:

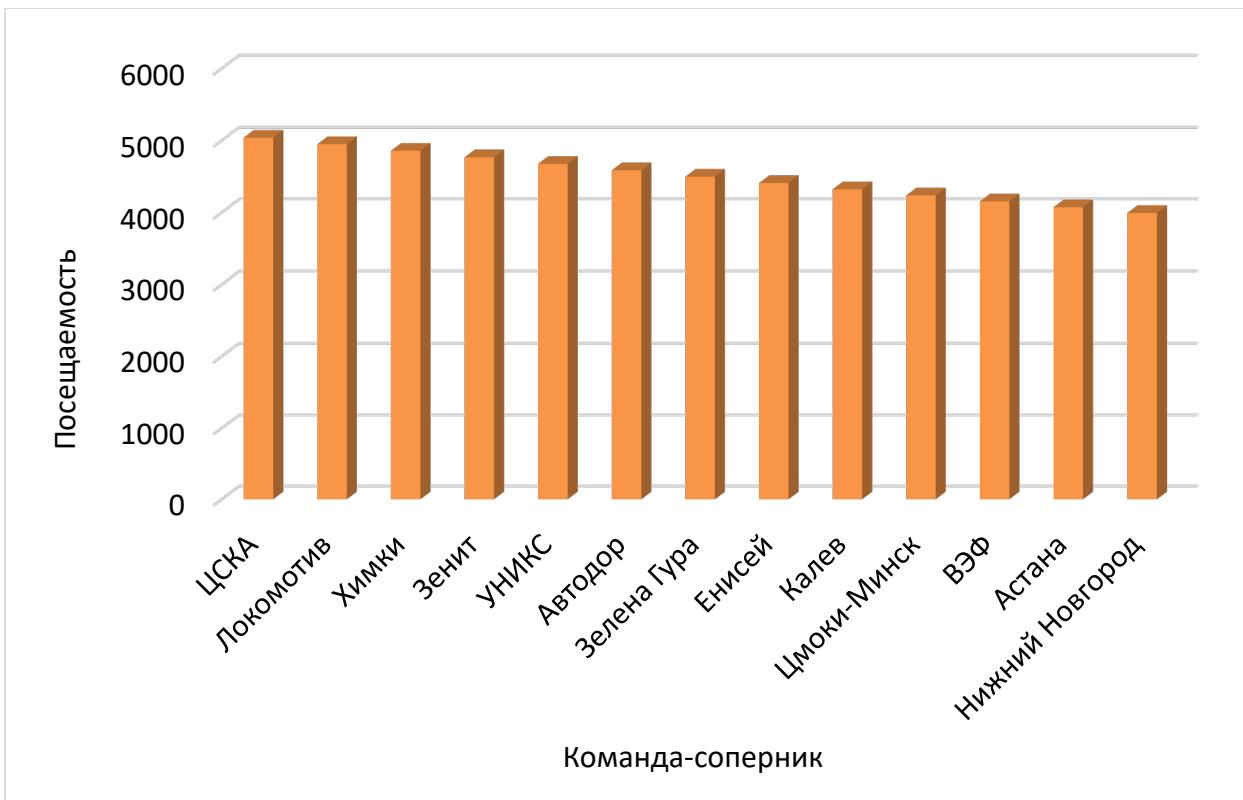


Рисунок 3. Прогнозируемая посещаемость матча в зависимости от изменения команды-соперника

На основе рисунка 3 можно сделать вывод о том, что активнее посещаются матчи, в которых принимают участие более знаменитые и успешные команды.

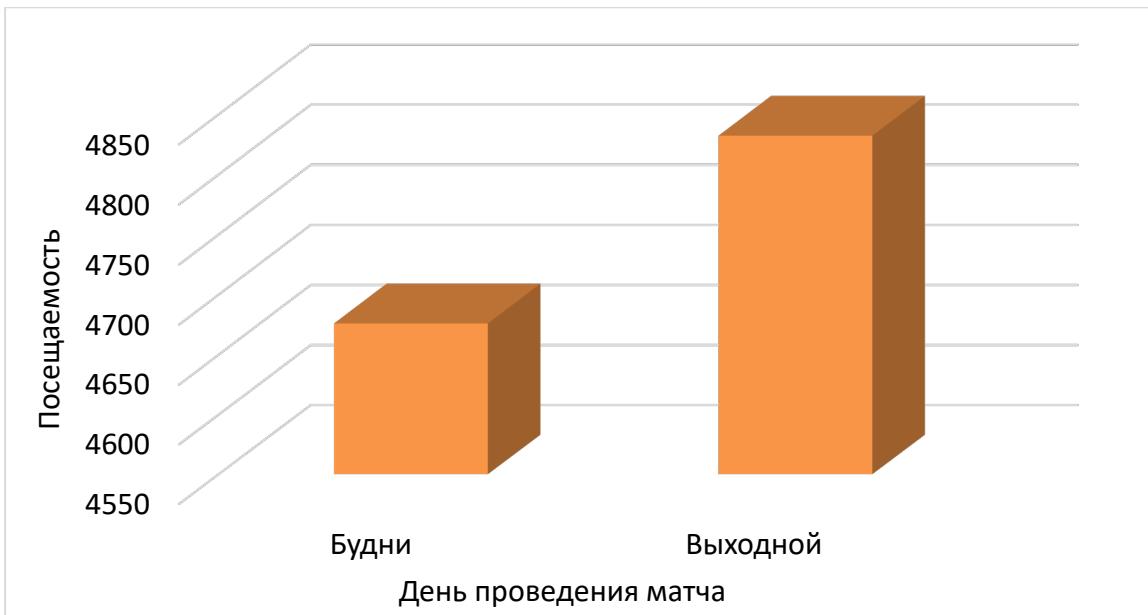


Рисунок 4. Прогнозируемая посещаемость матча в зависимости от изменения дня проведения матча

На основе рисунка 4 можно сделать вывод о том, что активнее посещаются матчи, которые проводятся в выходной день.

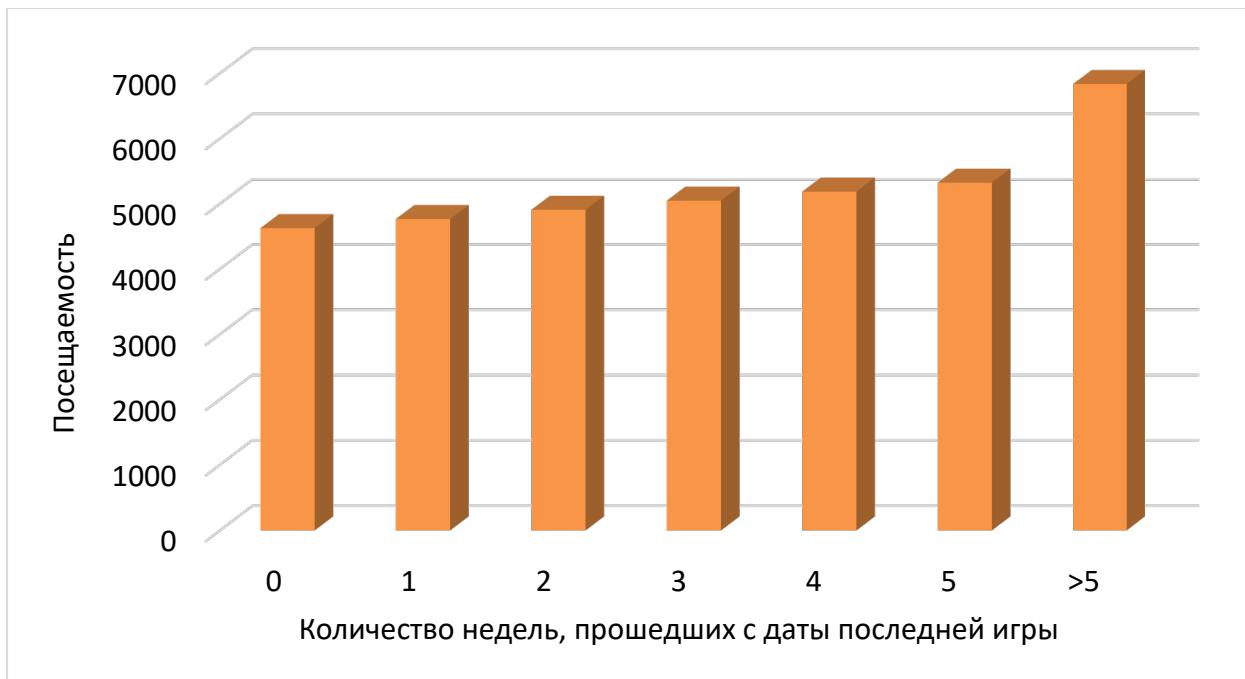


Рисунок 5. Прогнозируемая посещаемость матча в зависимости от изменения количества недель, прошедших с даты последнего матча

На основе рисунка 5 можно сделать вывод о том, что активнее посещаются первые матчи сезона и матчи, которые проводятся после длительного перерыва.

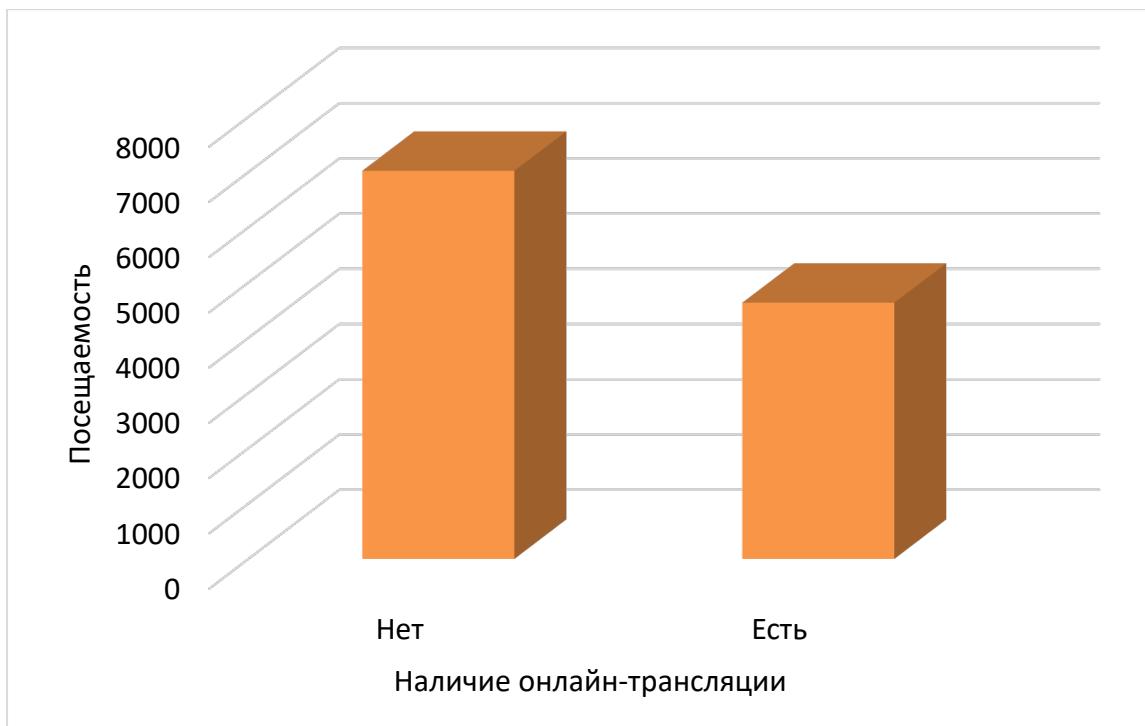


Рисунок 6. Прогнозируемая посещаемость матча в зависимости от наличия онлайн-трансляции

На основе рисунка 6 можно сделать вывод о том, что активнее посещаются матчи, на которых не ведется онлайн-трансляция.

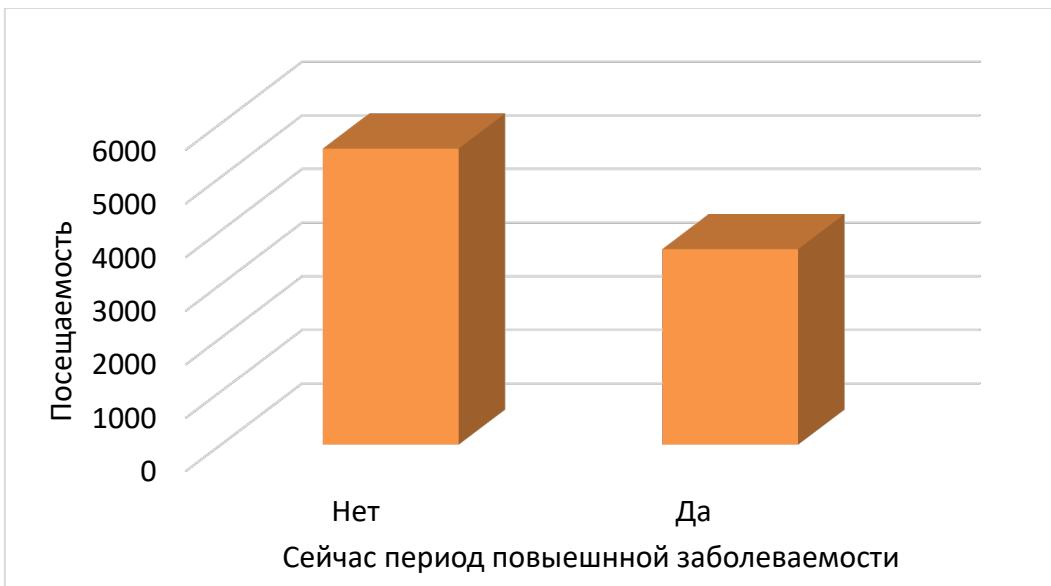


Рисунок 7. Прогнозируемая посещаемость матча в зависимости от наличия периода повышенной заболеваемости

На основе рисунка 7 можно сделать вывод о том, что активнее посещаются матчи, которые проводятся не в период повышенной заболеваемости.

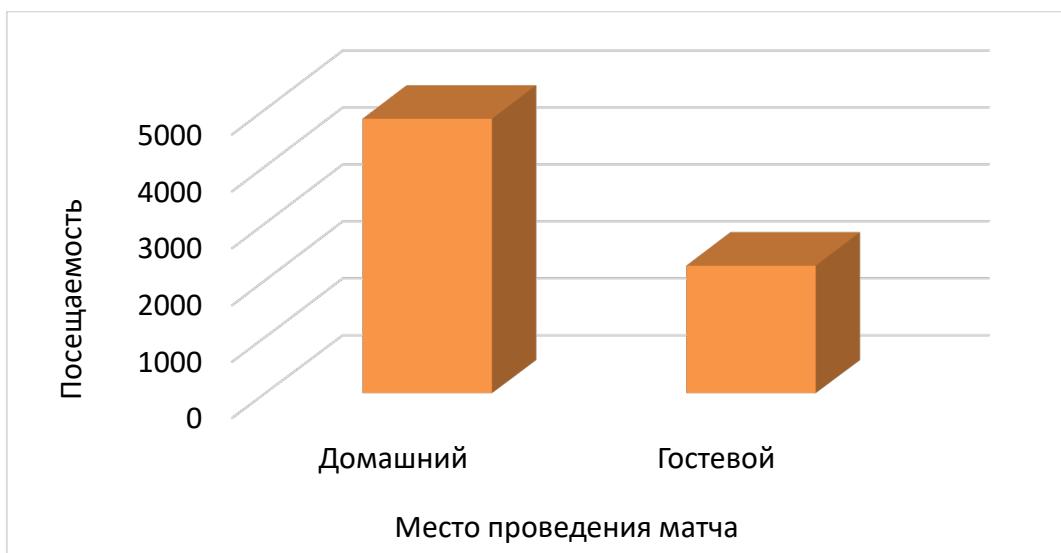


Рисунок 8. Прогнозируемая посещаемость матча в зависимости от места проведения

На основе рисунка 8 можно сделать вывод о том, что активнее посещаются домашние матчи БК «Парма».

Таким образом, исходя из данных, представленных на рисунках 3-8, можно прийти к выводу о том, что достичь максимальной посещаемости матча можно, если совместить следующие условия: наиболее знаменитая и успешная команда-соперник; матч проводится в выходной день; это первый матч сезона; отсутствует онлайн-трансляция; отсутствует период повышенной заболеваемости; это домашняя игра.

Заключение. Построена система нейросетевого оценивания посещаемости матчей БК «Парма». Спроектированная нейросетевая модель учитывает шесть факторов, влияющих на посещаемость матча: команда-соперник, будний день или выходной, дата предыдущей игры, наличие онлайн-трансляции, период повышенной заболеваемости, домашняя или гостевая игра. Применение такого набора параметров в модели позволяет прогнозировать посещаемость матчей в любое время, а также может быть в дальнейшем расширена или изменена для прогнозирования посещаемости матчей других команд.

Библиографический список

1. Forums.whirlpool.net.au – форум. [Электронный ресурс]. Режим доступа: <https://forums.whirlpool.net.au/archive/2095002>.
2. Галицын С.В., Зиганшин О.З., Дубровин К.Н., Ершов Н.Е., Ткаченко П.А. Использование нейронных сетей для прогнозирования посещаемости футбольных матчей // Ученые записки университета имени П.Ф. Лесгафта, 2019.
3. Москвичева К.В., Мальцева А.В., Дюкина Т.В. Анализ динамики факторов, влияющих на посещаемость матчей по футболу // Международная научно-практическая конференция: «Научные исследования: ключевые проблемы III тысячелетия», 2017.
4. Old.vtb-league.com – официальный сайт Единой Лиги ВТБ. [Электронный ресурс]. Режим доступа: <https://old.vtb-league.com/>.
5. Черепанов Ф.М., Ясицкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
6. Ясицкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005.
7. Parmabasket.ru – официальный сайт БК «Парма», Пермский край. [Электронный ресурс]. Режим доступа: <https://parmabasket.ru/>.

EVALUATION OF ATTENDANCE OF MATCHES OF THE PARMA BASKETBALL CLUB (PERM KRAI)

Nadezhina Alina A., Kozhinov Konstantin A.

Perm State University,

Str. Bukireva, 15, Perm, Russia, 614990,

The article describes the development of a dynamic neural network system for predicting the games of a Perm basketball club. The system allows making predictions of the match, taking into account the place of the game, the opposing team, the date of the event, the availability of online broadcasting, the period of increased incidence.

Key words: neural network, forecasting, sports club, basketball, match, season, attendance.

НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗИРОВАНИЯ РЕЗУЛЬТАТОВ КУБКА МИРА ПО БИАТЛОНУ

Касимова Кристина Маратовна, Матушкина Алина Евгеньевна

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
kasimovakristina.01@yandex.ru, alinematyshkina@gmail.com

В статье представлено описание разработки нейросетевой системы для прогнозирования результатов спортсмена в различных гонках Кубка мира по биатлону. Система позволяет определить примерное место, которое займет биатлонист в соревновании с учетом его физических и психологических показателей.

Ключевые слова: биатлон, искусственный интеллект, нейросетевые технологии, прогнозирование, процентовка стрельбы, скорострельность, скорость, спорт.

Введение. В последнее время в спортивной науке находят успешное применение нейросетевые технологии. Их можно использовать для прогнозирования результатов, отбора наиболее успешных спортсменов, выявления значимых факторов в программе подготовки к соревнованиям. Эффективность использования искусственного интеллекта при прогнозировании результатов соревнований соревнований была представлена в работах российских исследователей [1-4, 12]. Так, в одной из работ [12], опубликованной в 2013 году, был представлен подтверждившийся впоследствии прогноз места в неофициальном командном зачёте российских спортсменов на зимней Олимпиаде-2014. При создании нейросетевых систем авторы работ [1-4] учитывали не только физические и психологические качества спортсменов, но и их условия жизни (страна, раса, религия и т.д.).

Данное исследование направлено на создание системы прогнозирования результатов международных соревнований по биатлону. Основная цель настоящей работы заключается в сборе множества о действующих спортсменах, а также создание и обучение нейросетевой модели на этих данных.

В результате анализа литературных источников [1-4, 10-12] и собственного опыта был выбран следующий набор показателей: X₁ – вид гонки, X₂ – место по скорости за предыдущую гонку, X₃ – место по скорострельности за предыдущую гонку, X₄ – процентовка стрельбы на момент начала гонки, X₅ – наличие коронавирусной инфекции у спортсмена в 2020-2021 гг., X₆ – пол, X₇ – возраст (лет), X₈ – страна. Выходной параметр D₁ – итоговый результат.

Параметр «Вид гонки» был закодирован: 0 – индивидуальная гонка, 1 – спринт. Были отобраны именно эти виды гонок, так как они имеют наибольшее

количество участников и не зависят от результатов других гонок. Для кодирования параметра «Наличие коронавирусной инфекции у спортсмена в 2020-2021 гг.» использовались следующие обозначения: 0 – спортсмен переболел, 1 – спортсмен не болел. Параметр «Страна» также был закодирован: 0 – слабые страны, 1 – средние, 2 – сильные. Деление стран по категориям происходило по усредненным результатам Кубка Нации 2020/2021 [5-6]. В число сильных стран вошли страны с 1 по 9 место, в число средних – с 9 по 17, остальные – в число слабых. Другие параметры являются числовыми, поэтому для них кодировка не потребовалась.

Множество входных данных о результатах спортсменов было собрано с сайта IBU [7]. Объем итогового множества включает в себя 470 примеров. Данное множество было разделено на обучающее, тестирующее и подтверждающее в соотношении 80%, 15% и 5% соответственно. Собранные данные охватывают серию международных соревнований 2020-2021 года.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [8] по методике [9]. В результате оптимизации спроектированная нейронная сеть представляла собой персепtron, который имеет восемь входных нейронов, один выходной и один скрытый слой с четырьмя нейронами.

Для оценки корректной работы спроектированной нейронной сети использовалось подтверждающее множество, состоящее из 20 примеров. Средняя ошибка тестирования составила 11.22%, что можно считать приемлемым результатом. На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактическим и прогнозируемым нейросетью итоговым результатом случайно отобранных 20 спортсменов из подтверждающего множества.

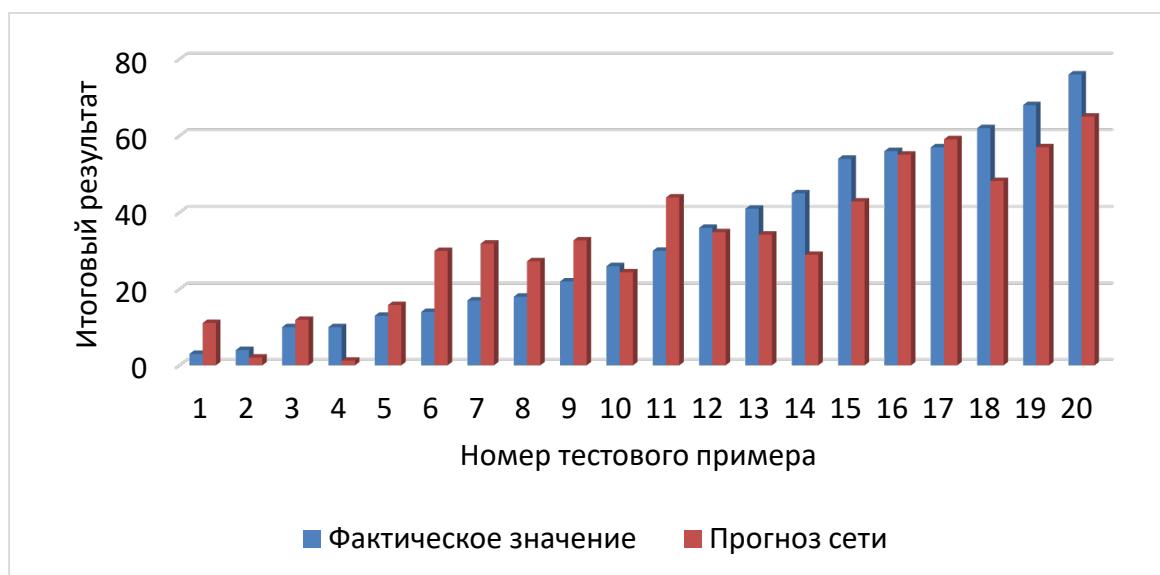


Рисунок 1. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 1, можно сделать вывод об адекватной работе спроектированной нейронной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5» [8], результат отображен на рисунке 2.

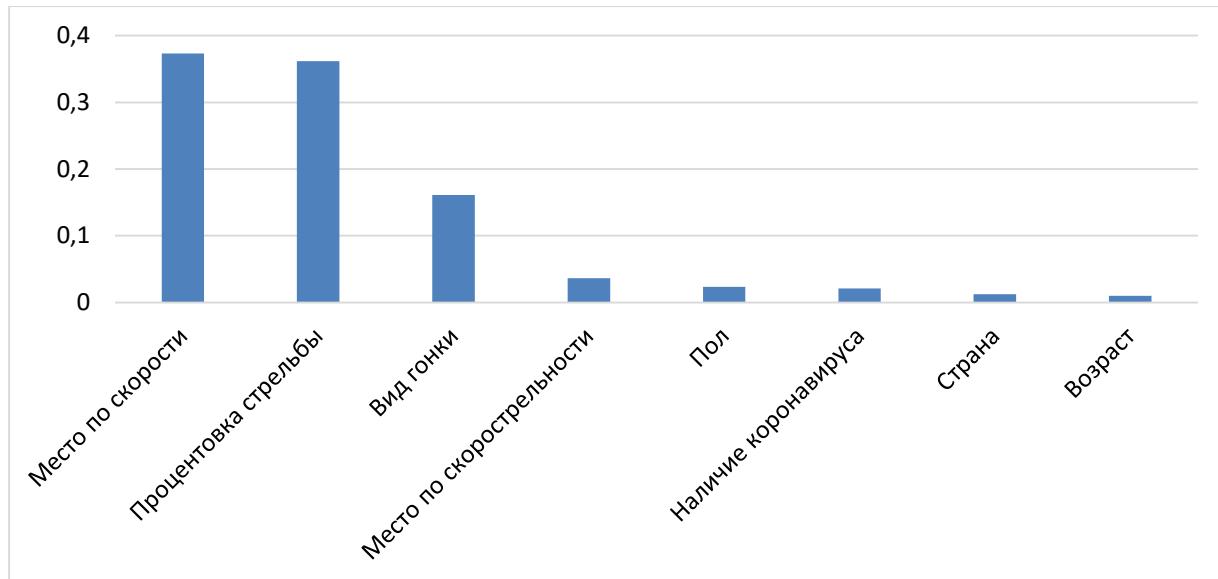


Рисунок 2. Значимость входных параметров нейросетевой модели

Как видно из рисунка 2, наиболее значимыми являются «Место по скорости», «Процентовка стрельбы» и «Вид гонки». Значительно меньшее влияние оказывают такие параметры как «Скорострельность», «Пол», «Наличие коронавирусной инфекции», «Страна» и «Возраст».

Далее было проведено исследование итоговых результатов спортсменов. Исследование производилось с помощью метода «замораживания» [8], суть которого заключается в варьировании значения одного параметра и фиксировании значений всех других параметров. Данный метод позволяет выявить влияние исследуемого параметра на выходной. Для этой цели был отобран спортсмен, информация о параметрах которого отражена в таблице 1.

Таблица 1
Характеристики спортсмена, выбранного для исследования

Входные параметры	Расшифровка	Характеристики
X2	Место по скорости за предыдущую гонку	47
X3	Место по скорострельности за предыдущую гонку	3
X4	Процентовка стрельбы на момент начала гонки	80
X5	Наличие коронавирусной инфекции в 2020-2021 гг.	1
X6	Пол (0 – м, 1 – ж)	0
X7	Возраст	28
X8	Страна (2 – сильные, 1 – средние, 0 – слабые)	2

На рисунках 3-4 показаны графики зависимости итогового результата от места по скорости и скорострельности за предыдущую гонку соответственно. Как следует из графиков, вне зависимости от вида гонки, более высокое место по скорости и скорострельности приводит к более высокому результату.

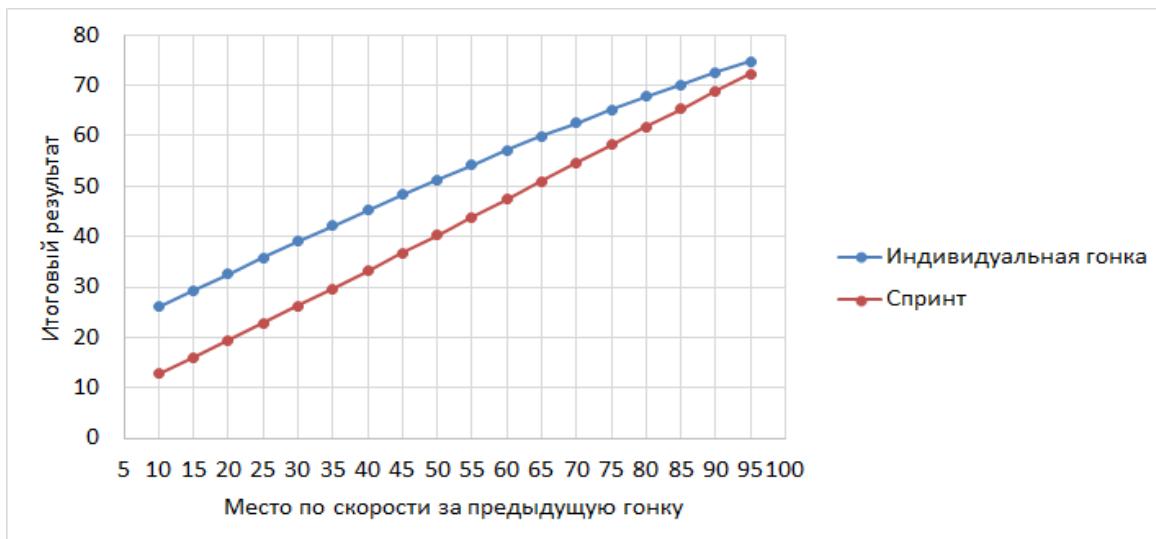


Рисунок 3. Зависимость итогового результата от места по скорости за предыдущую гонку

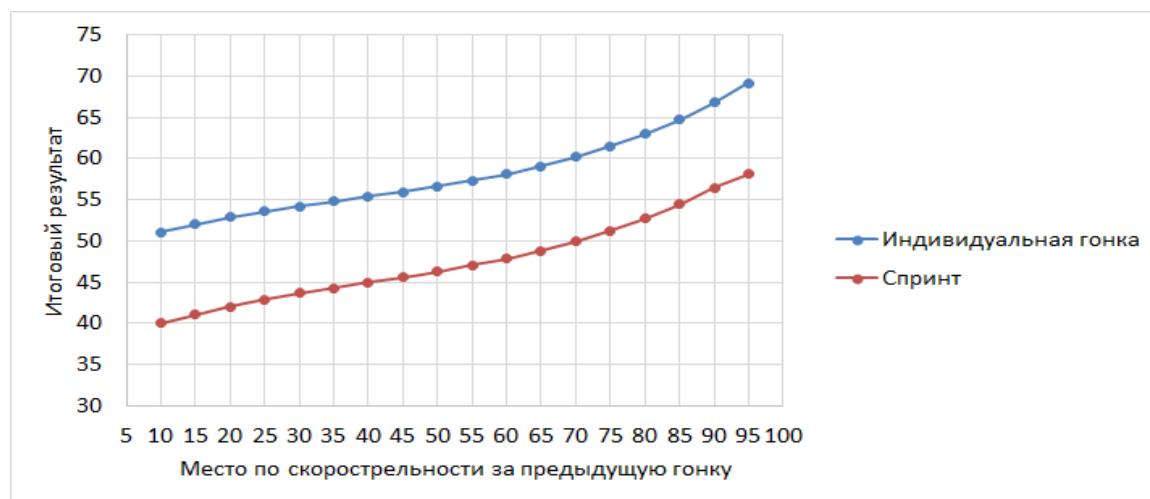


Рисунок 4. Зависимость итогового результата от места по скорострельности

На рисунке 5 продемонстрирован график зависимости результата биатлониста от процентовки стрельбы на момент начала гонки. По полученному графику можно заметить, что при увеличении процентовки стрельбы улучшается итоговый результат.

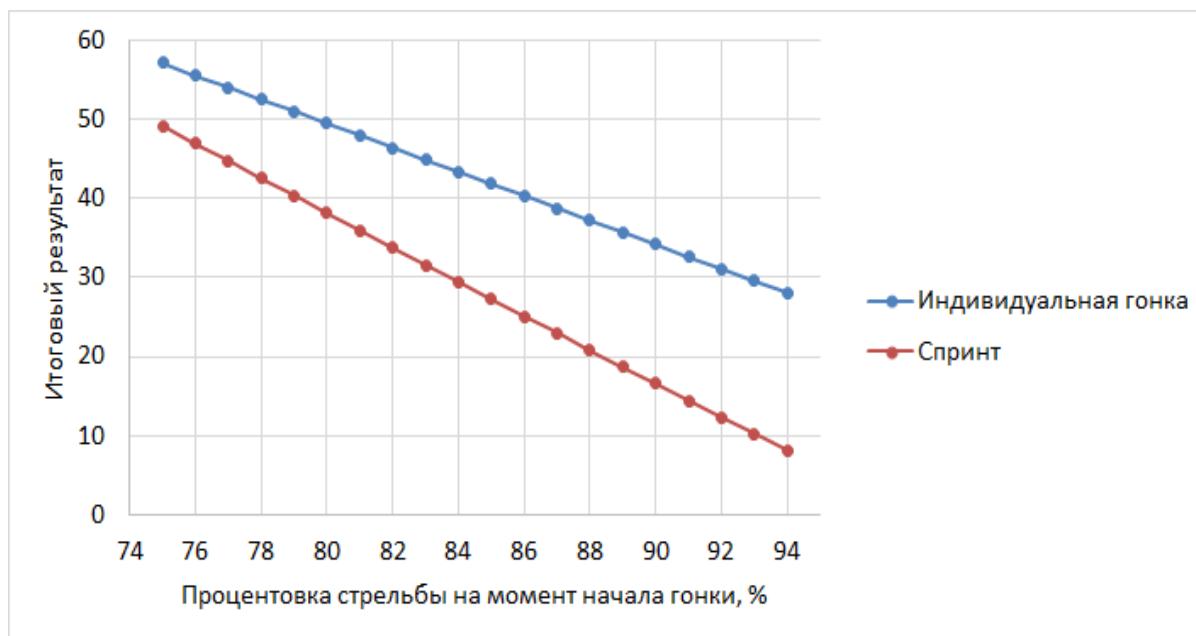


Рисунок 5. Зависимость итогового результата от процентовки стрельбы на момент начала гонки

На рисунке 6 представлен график зависимости итогового результата от возраста спортсмена. Как показывает график, этот параметр почти никак не влияет на итоговый результат, но можно заметить, что более опытный спортсмен лучше преодолевает спринтерскую гонку, чем молодой. Скорее всего это связано с тем, что с возрастом у спортсмена формируется более устойчивая нервная система, а значит и улучшается качество стрельбы, что крайне важно в гонках на короткие дистанции.

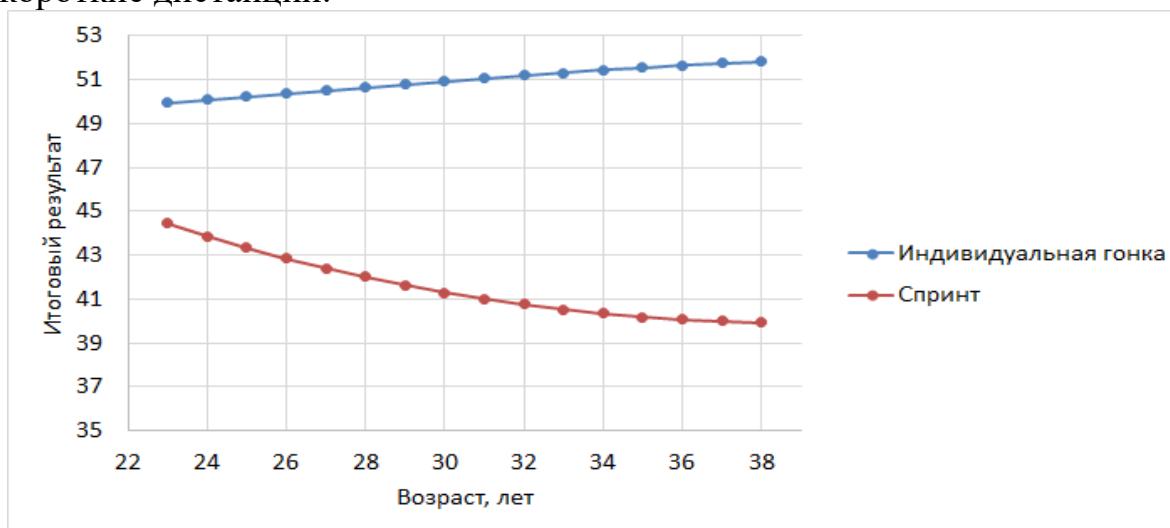


Рисунок 6. Зависимость итогового результата от возраста

Полученные результаты исследований не противоречат реальности, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для прогнозирования итогового результата спортсменов.

Заключение. Построена система нейросетевого прогнозирования результатов международных соревнований по биатлону. Спроектированная нейросетевая модель учитывает две категории показателей, влияющих на

итоговый результат спортсмена: физические и психологические. Проведено исследование итоговых результатов спортсменов. Методом сценарного прогнозирования построены графики зависимостей итогового результата от места по скорости, места по скорострельности за предыдущую гонку, процентовки стрельбы и возраста. Методика нейросетевого моделирования может быть также использована для получения полезных рекомендаций для улучшения результатов спортсмена, занимающегося данным видом спорта.

Библиографический список

1. Ясницкий Л.Н., Vnukova O.V. Прогноз результатов олимпиады-2014 в мужском одиночном фигурном катании методами искусственного интеллекта // Современные проблемы науки и образования. 2014. № 1. С. 189. ; URL: <http://www.science-education.ru/115-11339> (дата обращения: 22.03.2021).
2. Ясницкий Л.Н., Киросова А.В., Ратегова А.В., Черепанов Ф.М Методика прогнозирования результатов спортивных состязаний на примере Чемпионата мира-2015 по легкой атлетике // Вестник Пермского университета. Серия: Математика. Механика. Информатика. 2014. № 3 (26). С. 90-97.
3. Ясницкий Л.Н., Кировоса А.В., Ратегова А.В., Черепанов Ф.М. Прогноз результатов Чемпионата мира-2015 по легкой атлетике методами искусственного интеллекта // Современные проблемы науки и образования. 2014. № 4; URL: www.science-education.ru/118-14423 (дата обращения: 22.03.2021).
4. Ясницкий Л.Н., Абрамова Ю.С., Бабушкина С.Д. Возможности получения рекомендаций по улучшению результативности сборных команд, готовящихся к участию в чемпионате Европы по футболу Евро-2016 методом нейросетевого моделирования // Вестник спортивной науки. 2015. № 5. С. 15-20.
5. Olympteka.ru [Электронный ресурс]. – URL: <https://olympteka.ru/sport/biathlon/rating/355.html>
6. Olympteka.ru [Электронный ресурс]. – URL: <https://olympteka.ru/sport/biathlon/rating/356.html>
7. International Biathlon Union – IBU [Электронный ресурс]. – URL: <https://www.biathlonworld.com/calendar/#/event-2>
8. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
9. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.
10. Skattebo Ø., Losnegard T. Variability, Predictability, and Race Factors Affecting Performance in Elite Biathlon // International Journal of Sports Physiology and Performance. – vol. 13 – № 3. – P. 313-319; URL: <https://journals.human kinetics.com/view/journals/ijsspp/13/3/article-p313.xml>
11. Laaksonen M.S., Finkenzeller T., Holmberg H.-C., Sattlecker G. The influence of physiobiomechanical parameters, technical aspects of shooting, and

- psychophysiological factors on biathlon performance // Journal of Sport and Health Science. – October 2018. – vol. 7 – № 4 – P. 394-404; URL: <https://www.sciencedirect.com/science/article/pii/S2095254618300760#!>
12. Ясницкий Л.Н., Павлов И.В., Черепанов Ф.М. Прогнозирование результатов олимпийских игр 2014 года в неофициальном командном зачете методами искусственного интеллекта // Современные проблемы науки и образования. 2013. № 6. URL: <http://www.science-education.ru/113-11206> (дата обращения: 22.03.2021).

NEURAL NETWORK SYSTEM FOR PREDICTING THE RESULTS OF THE BIATLON WORLD CUP

Kasimova Kristina M., Matyshkina Alina E.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990, kasimovakristina.01@yandex.ru,
alinematyshkina@gmail.com

The article describes the development of a neural network system for predicting the results of a sportsman in various races of the Biathlon World Cup. The system allows people to determine the approximate place that a biathlete will take in the competition, taking into account his psychological and physical indicators.

Keywords: biathlon, artificial intelligence, neural network technologies, prediction, shooting percentages, rate of fire, speed, sport.

УДК 004.032.26

НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗИРОВАНИЯ РЕЗУЛЬТАТОВБОЕВ БЕЗ ПРАВИЛ НА ПЛОЩАДКИ UFC

Васильевых Михаил Геннадьевич, Жуков Андрей Евгеньевич

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
vasilevyh00@gmail.com

В статье представлено описание разработки динамической нейросетевой системы для прогнозирования исходов боев площадки UFC. Система позволяет выполнять оценку шансов бойцов с учетом их физических данных и истории боев. Использование физических параметров позволяет сделать систему адаптируемой к боям различных площадок.

Ключевые слова: искусственный интеллект, нейросетевые технологии, бои без правил, прогнозирование, UFC, тотализатор.

Введение. На данный момент бои без правил один из самых популярных видов спорта. Как и в любом виде спорта, в данном присутствуют ставки на победу того или иного спортсмена. Перед боем букмекеры оценивают вероятность победы того или иного бойца. В этом случае возникает проблема человеческого фактора: ошибочный прогноз или симпатия к тому или иному бойцу.

Эффективность искусственного интеллекта при оценке шансов на победу бойцов, была обоснована в работах зарубежных исследователей [1-3, 17]. Однако в этих исследованиях не учитывались все физические параметры бойцов и их навыки.

Данное исследование является продолжением вышеупомянутых работ по созданию динамической системы оценки шансов бойцов, а также формированию рекомендаций для отдельно взятых бойцов.

Нейронные сети уже используются для предсказания результатов спортивных состязаний [9-15, 18, 19], выявления перспективных спортсменов [16, 18]. Данное исследование в методическом плане основывается именно на этих работах.

Основная цель настоящей работы заключается в сборе множества о проведенных боях на площадке UFC, создании и обучении нейросетевой модели на этих данных.

В результате анализа литературных источников, и готовых data-sets [2-6] был выбран следующий набор показателей: X1 – Разность возраста бойцов, X2 – Разность веса бойцов, X3 – Разность роста бойцов, X4 – Разность размаха рук, X5 – Разность количества проведённых боёв, X6 – разность одержанных побед, X7 – разность поражений, X8 – разность точности ударов, X9 – разность борцовских навыков, X10 – разность навыков ударника. Выходной параметр D1 – шанс победы 1 бойца.

Параметр разность борцовских навыков был закодирован: 1 – боец #1 имеет навыки борца, боец #2 не имеет навыков борца; 0 – оба бойца имеют или не имеют борцовские навыки; -1 – боец #2 имеет борцовские навыки, боец #1 нет.

Параметр разность навыков ударника был закодирован: 1 – боец #1 имеет навыки ударника, боец #2 не имеет; 0 – оба бойца имеют или не имеют навык ударника; -1 – боец #2 имеет ударные навыки, боец #1 нет.

Остальные параметры являются числовыми, поэтому для них кодировка не требуется, разность в характеристиках бойцов взята для более адекватного представления шансов бойцов.

Множество результатов поединков, было собрано с интернет-ресурсов [3-6]. Перед переходом к проектированию и обучению нейросетевой модели была выполнена очистка исходного множества от противоречивых примеров, выбросов, дубликатов [8]. Выброс статистической информации обнаруживались с помощью нейросетевой методики [20].

В результате, объем итогового множества включает в себя 54 примера. Данное множество было разделено на обучающее и тестирующее в соотношении

85% и 15% соответственно. Собранные данные охватывают период с 2010 по 2021 года.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [7] по методике [8]. В результате оптимизации спроектированная нейронная сеть представляла собой персепtron, который имеет десять входных нейронов, один выходной и один скрытый слой с четырьмя нейронами.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 8 примеров. Средняя ошибка тестирования составила 9,58%, что можно считать приемлемым результатом. Процесс обучение представлен на рисунке 1.

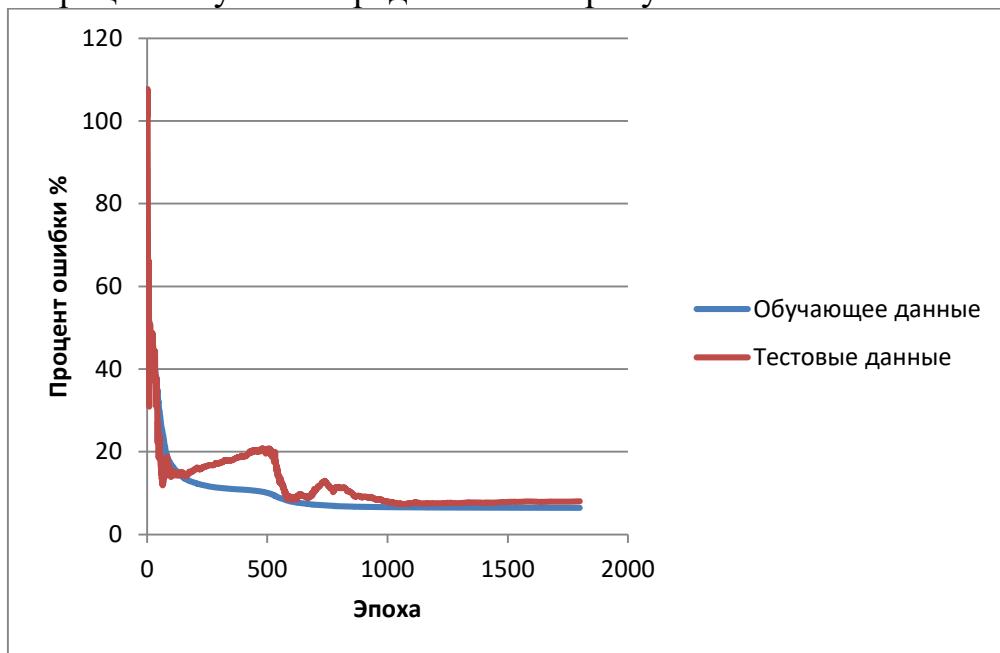


Рисунок 1. Результат обучения нейронной сети.

Рисунок 2 демонстрирует разницу между фактическими и прогнозируемыми нейросетью результатами боев, отобранных из тестирующего множества.

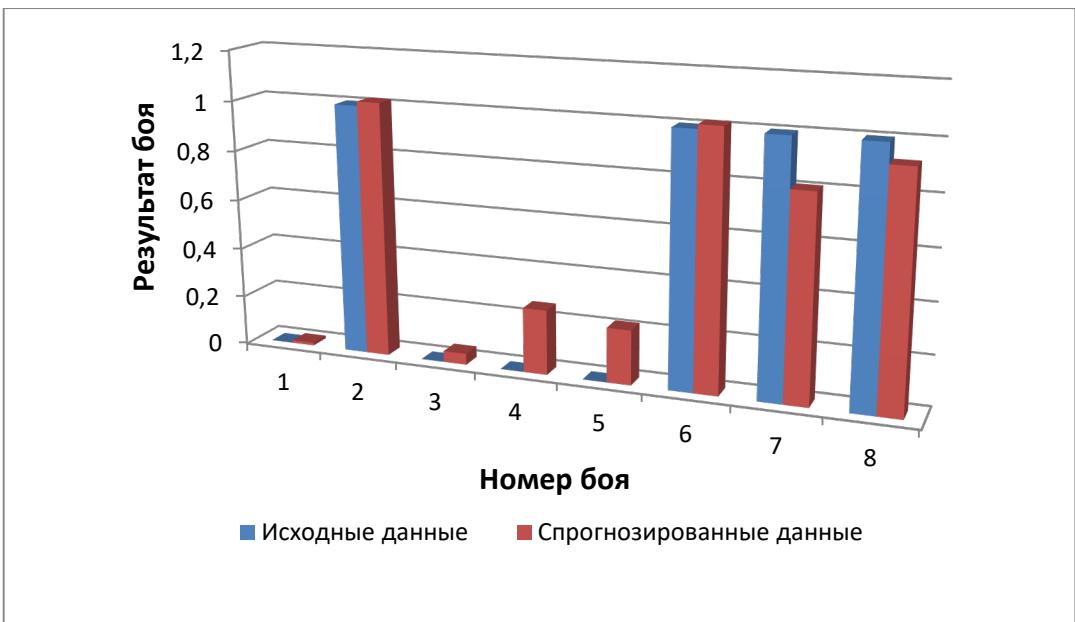


Рисунок 2. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 2, можно сделать вывод об адекватной работе спроектированной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5» [7], результаты изображены на рисунке 3.

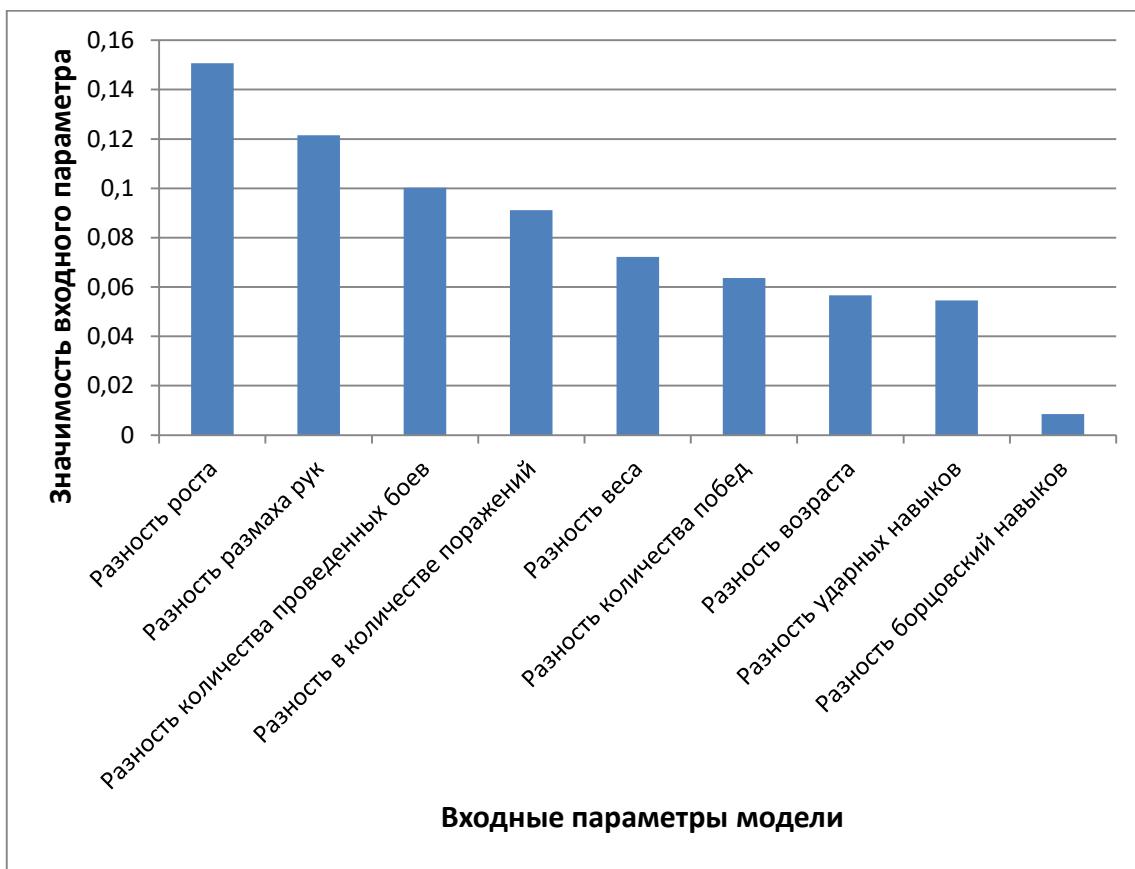


Рисунок 3. Значимость входных параметров нейронной сети

Из рисунка 3 видно, что наиболее значимыми параметрами являются: точность ударов, рост, размах рук и количество проведенных боев. Самую низкую значимость имеют борцовские навыки.

Далее было проведено исследование боев площадки UFC с помощью метода «замораживания» [8]. Суть данного метода заключается в варьировании одного параметра и фиксировании значений других параметров. Таким образом, можно выявить влияние исследуемого параметра на выходной. Для этой цели был отобран бой «Миочич vs Нганну», информация о параметрах которого отражена в таблице 1

**Таблица 1
Характеристика боя, выбранного для исследования**

Разность возраста бойцов	Разность веса бойцов	Разность роста бойцов	Разность размаха рук	Разность количества проведенных боёв	Разность количества одержанных побед	Разность количества поражений	Разность точности ударов	Разность борцовских навыков	Разность ударных навыков
4	-5	0	-7	4	4	0	14	1	0

Рисунок 4 представляет собой зависимость шансов победы первого бойца от разности возраста.

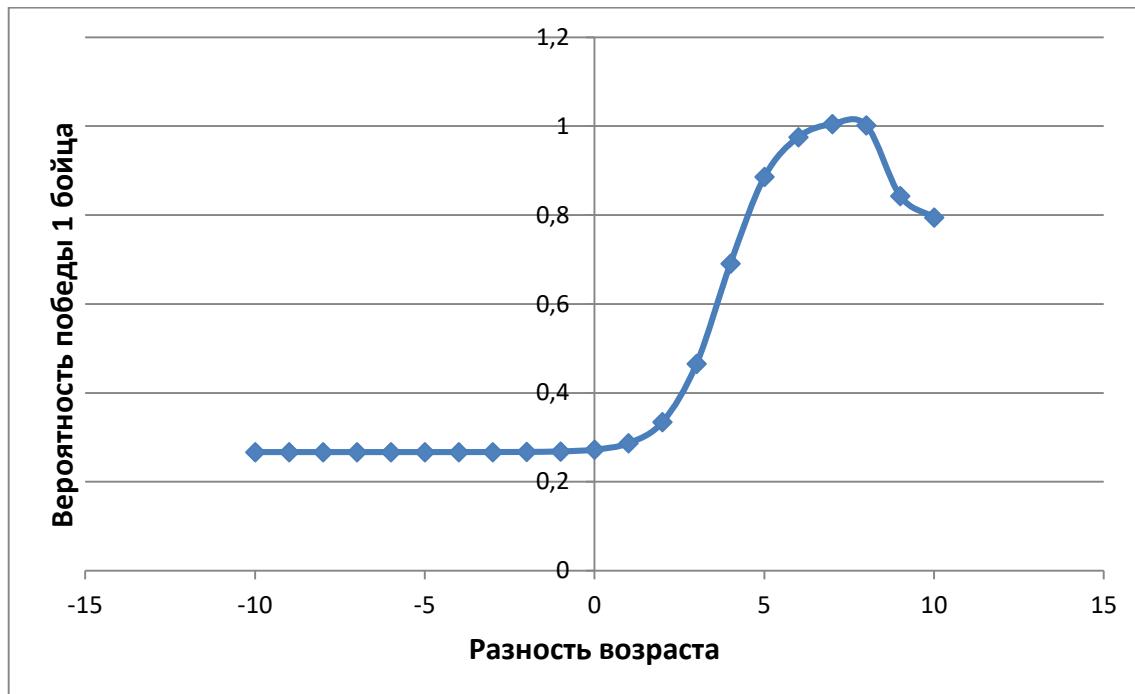


Рисунок 4. Зависимость вероятности победы первого бойца от разности возраста

Из графика следует, что, чем боец старше, тем больше у него шансов на победу. Оптимальной разностью для первого бойца будет интервал от 6 до 9 лет разницы.

На рисунке 5 продемонстрирована зависимость шанса на победу первого бойца от разности веса. Чем меньше весит боец, тем больше у него шансов на победу.

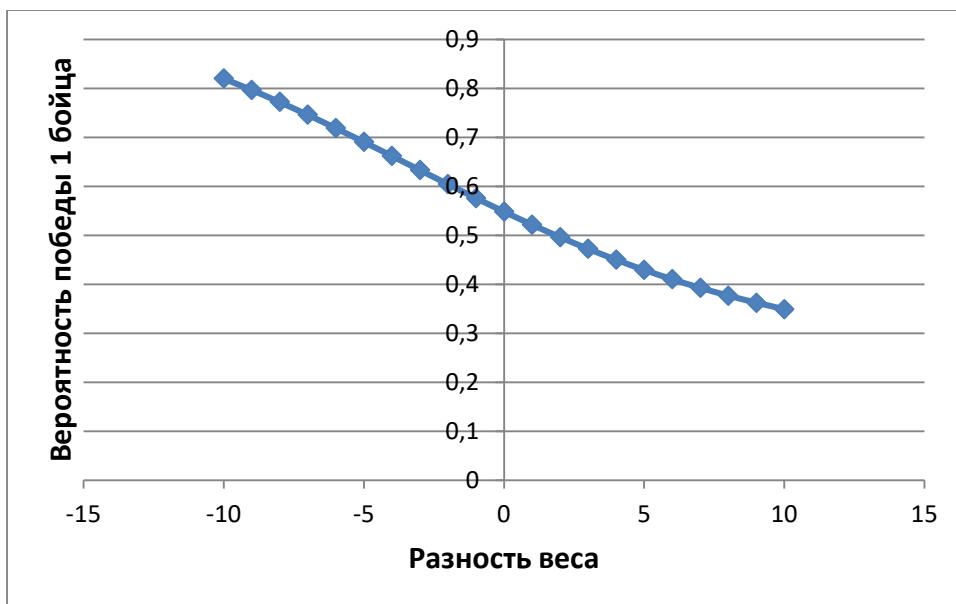


Рисунок 5. Влияние разности веса на вероятность победы первого бойца

На рисунках 6-7 продемонстрирована зависимость вероятности победы первого бойца от роста и размаха рук. В обоих случаях, чем ниже разность, тем ниже шансы на победу. Однако боец, который выше на 1-5 см, имеет низкие шансы на победу, далее с повышением роста шансы растут. При более низком росте бойцу легче применять борцовские навыки. Так же при существенно большем росте бойцу легче реализовать потенциал ударника. Что касается размаха рук, то график симметричен относительно вертикальной оси. Это говорит о том, что при большем размахе рук боец может наносить удары из безопасного расстояния, но при одинаковом размахе играют роль только ударные навыки. В целом, эти два параметра пропорциональны, чем выше рост, тем больше размах рук и наоборот.

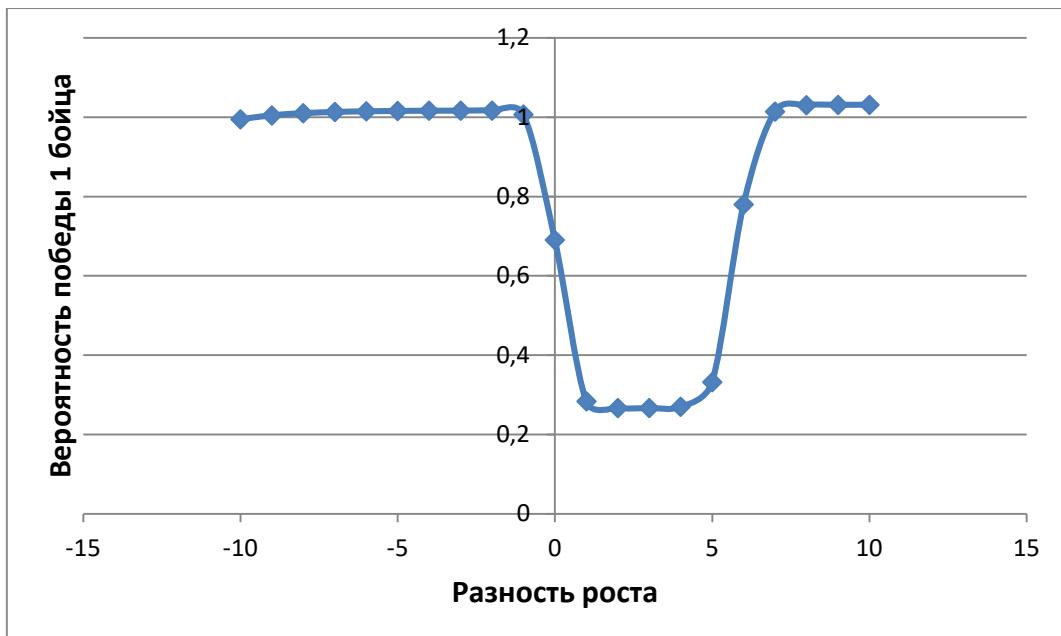


Рисунок 6. Влияние разности роста на вероятность победы первого бойца

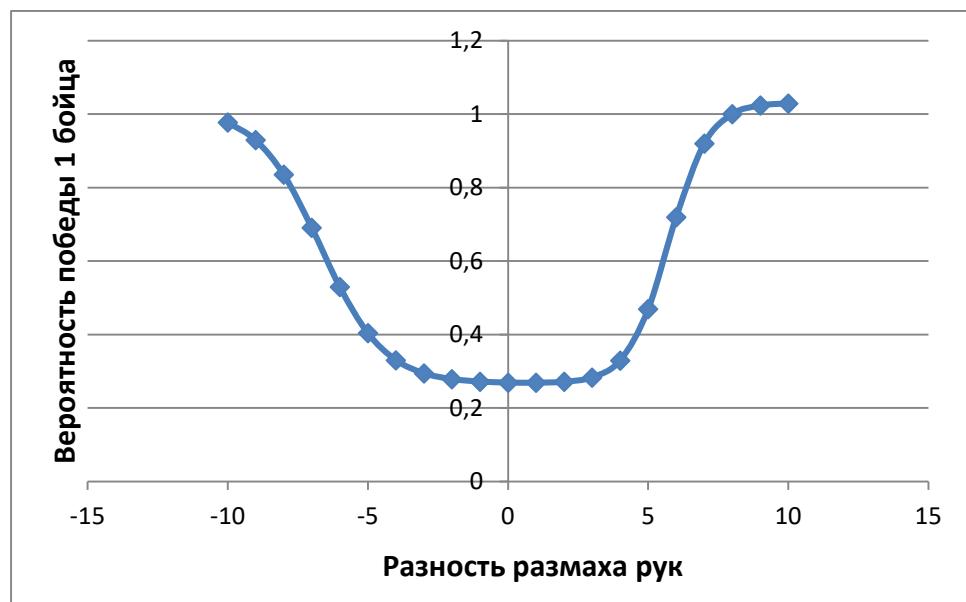


Рисунок 7. Влияние разности размаха рук на вероятность победы первого бойца

Рисунок 8 представляет собой зависимость шансов на победу первого бойца от разности количества проведенных боев. Из графика видно, что чем меньше боев у первого бойца, тем больше у него шансов на победу. Это можно объяснить тем, что с каждым боем постепенно ухудшается состояние здоровья бойца.

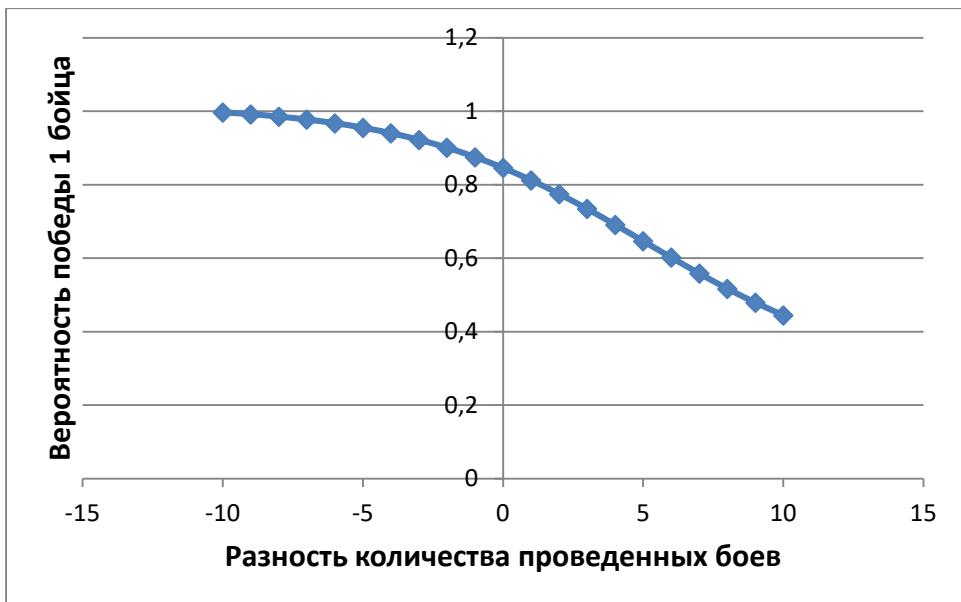


Рисунок 8. Влияние разности количества проведенных боев на вероятность победы первого бойца

Рисунки 9-10 демонстрируют влияние количества побед и поражений на шансы первого бойца. Зависимости практически обратные: чем больше побед, тем выше шансы на победу; чем больше поражений, тем ниже шансы на победу. Так как количество побед свидетельствует об опытности бойца, но количество поражений – об отсутствии должного опыта и, возможно, ухудшении здоровья бойца.

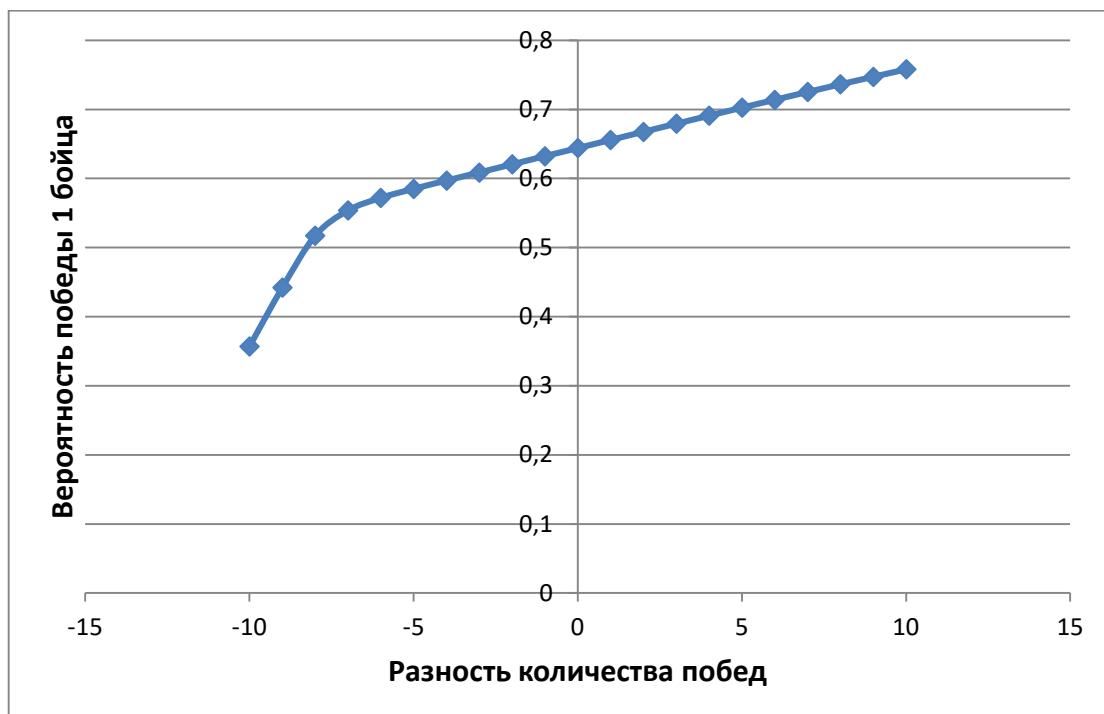


Рисунок 9. Влияние разности количества побед на вероятность победы первого бойца

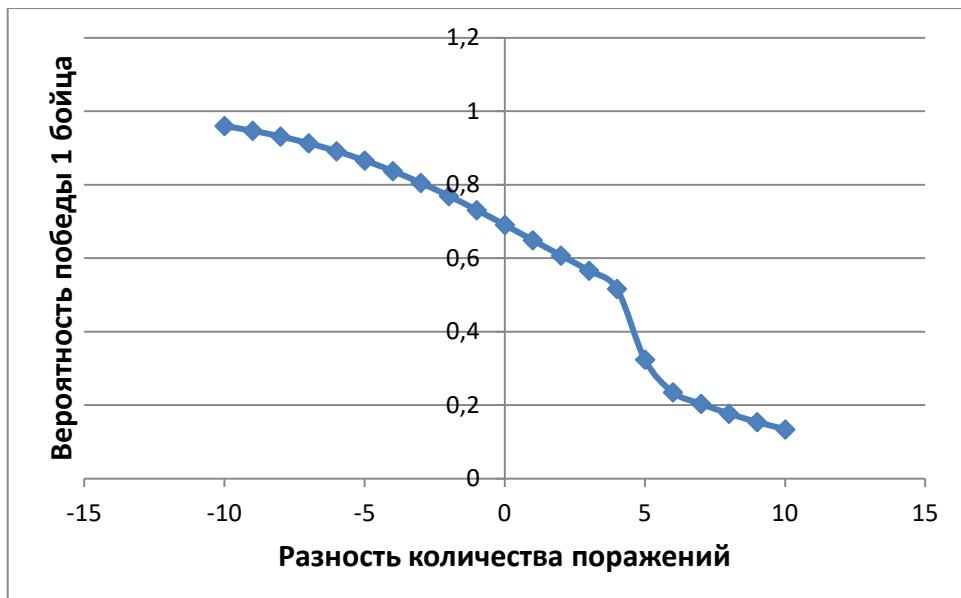


Рисунок 10. Влияние разности количества поражений на вероятность победы первого бойца

На рисунке 11 представлена зависимость шансов первого бойца от точности ударов. Чем выше точность ударов, тем шансы выше.

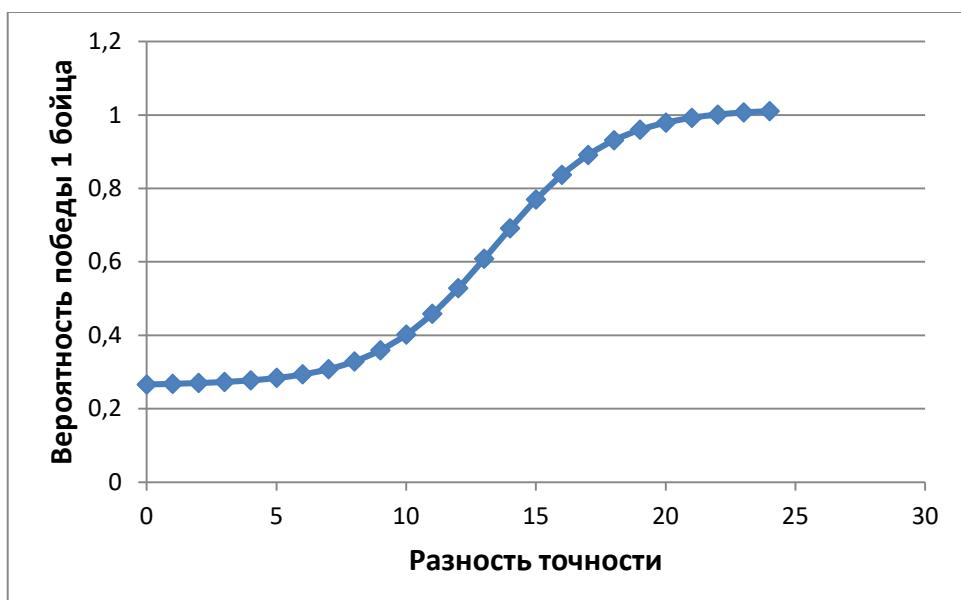


Рисунок 11. Влияние разности точности ударов на вероятность победы первого бойца

Полученные результаты исследований не противоречат реальности, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для прогнозирования исхода боев площадки UFC.

Заключение. Построена система нейросетевого прогнозирования исходов боев площадки UFC. Данная модель учитывает физические характеристики и историю боев, влияющие на исход боя. Методом сценарного прогнозирования [8] построены графики зависимостей шансов на победу бойца от всех входных данных. Применение такого набора параметров позволяет более полно

учитывать физические данные бойцов, а также может быть в дальнейшем расширена на прогнозирование исходов других площадок боев без правил.

Библиографический список

1. Towards Data Science. – URL: <https://towardsdatascience.com/predicting-ufc-bouts-with-dnn-classifier-f955e9abeb6c6>
2. UFC-Data [Электронный ресурс]. – URL: <https://github.com/ktonthat/UFC-data>
3. UFC Fights and Fighter Data [Электронный ресурс]. – URL: https://www.reddit.com/r/datasets/comments/47a7wh/ufc_fights_and_fighter_data/?utm_source=amp&utm_medium=&utm_content=post_title
4. Ultimate UFC Dataset [Электронный ресурс]. – URL: <https://www.kaggle.com/mdabbert/ultimate-ufc-dataset>
5. UFC. – URL: <http://ufc.com>
6. UFC-Stats [Электронный ресурс]. – URL: <http://ufcstats.com/statistics/events/completed>
7. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
8. Ясницкий Л.Н. Интеллектуальные системы. – М.: Лаборатория знаний, 2016. – 221 с.
9. Ясницкий Л.Н., Vnukova O.V. Прогноз результатов олимпиады-2014 в мужском одиночном фигурном катании методами искусственного интеллекта // Современные проблемы науки и образования. 2014. № 1. С. 189.
10. Ясницкий Л.Н., Кирюкова А.В., Ратегова А.В., Черепанов Ф.М. Методика прогнозирования результатов спортивных состязаний на примере Чемпионата мира-2015 по легкой атлетике // Вестник Пермского университета. Серия: Математика. Механика. Информатика. 2014. № 3. С. 90-97.
11. Ясницкий Л.Н., Кирюкова А.В., Ратегова А.В., Черепанов Ф.М. Прогноз результатов Чемпионата мира-2015 по легкой атлетике методами искусственного интеллекта // Современные проблемы науки и образования. 2014. № 4; URL: www.science-education.ru/118-14423
12. Ясницкий Л.Н., Павлов И.В., Черепанов Ф.М. Прогнозирование результатов олимпийских игр 2014 года в неофициальном командном зачете методами искусственного интеллекта // Современные проблемы науки и образования. 2013. № 6. С. 985; URL: <http://www.science-education.ru/113-11206>
13. Blaikie A.D., Abud G.J., David J.A., and Pasteur R.D. NFL and NCAA Football Prediction using Artificial Neural Networks // Proceedings of the Midstates Conference for Undergraduate Research in Computer Science and Mathematics, Denison University, Granville, OH, 2011.

14. David J.A., Pasteur R.D., Ahmad M.S., Janning M.C. NFL Prediction using Committees of Artificial Neural Networks // Journal of Quantitative Analysis in Sports. 2011. Vol. 7. Iss. 2, Article 9.
15. Loeffelholz B., Bednar E., Bauer K.W. Predicting NBA Games Using Neural Networks // Journal of Quantitative Analysis in Sports. 2009. Vol. 5. Issue 1. Article 7.
16. McCullagh J. Data Mining in Sport: A Neural Network Approach // International Journal of Sports Science and Engineering. 2010. Vol. 04. No. 03. Pp. 131-138.
17. Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery Volume 10, Issue 5, 1 September 2020, Article number e138
18. Ясницкий Л.Н., Киросова А.В., Черепанов Ф.М. О возможностях применения методов искусственного интеллекта в спорте // Вестник спортивной науки. 2012. № 5.
19. Ясницкий Л.Н., Абрамова Ю.С., Бабушкина С.Д. Возможности получения рекомендаций по улучшению результативности сборных команд, готовящихся к участию в чемпионате Европы по футболу Евро-2016 методом нейросетевого моделирования // Вестник спортивной науки. 2015. № 5. С. 15-20.
20. Yasnitsky L.N. Algorithm for searching and analyzing abnormal observations of statistical information based on the Arnold – Kolmogorov – Hecht-Nielsen theorem // International Journal of Advanced Trends in Computer Science and Engineering. 2020. 9(2). Pp. 1814-1819. DOI:
10.30534/ijatcse/2020/139922020
<http://www.warse.org/IJATCSE/static/pdf/file/ijatcse139922020.pdf>

NEURAL NETWORK SYSTEM FOR PREDICTION OF THE RESULTS OF BATTLES OF THE UFC SITE

Vasilevykh Mikhail G., Zhukov Andrey E.
 Perm State National Research University,
 PMI. 614990, Russia, Perm, st. Bukireva, 15

The article describes the development of a dynamic neural network system for predicting the outcomes of the UFC battlegrounds. The system allows you to assess the chances of fighters, taking into account their physical data and the history of combat operations. The use of physical parameters makes the system adaptable to the battles of various sites.

Keywords: artificial intelligence, neural network technologies, fights without rules, forecasting, UFC, sweepstakes.

НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗИРОВАНИЯ ПОБЕДИТЕЛЯ МАТЧА БИЛЬЯРДНОЙ ИГРЫ СНУКЕР

Ко Дмитрий Викторович

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
ruinmath@bk.ru

В статье представлено описание разработки нейросетевой системы для прогнозирования результатов матчей в игре снукер. Система позволяет с большой точностью предсказать победителя следующего матча на основании данных о двух играх и истории их личных встреч.

Ключевые слова: искусственный интеллект, нейросетевые технологии, прогнозирование, бильярд, снукер.

Введение. В отличие от азартных игр, результаты матчей в спорте гораздо меньше зависят от случая. Поэтому прогнозирование победителя в спортивных соревнованиях является более точным. Как показал опыт Пермской научной школы искусственного интеллекта, например, [1-3], правильно натренированная нейросетевая система может добиться успешности большей части прогнозов. Знание результатов матчей может помочь букмекерским сайтам и их пользователям извлечь больше прибыли.

При анализе литературных источников выяснилось, что работ на тему прогнозирования результатов матчей в снукере было проведено очень мало. Так, Джеймс Колингвуд в своей работе [4] предложил использовать количество призовых денег, мировой рейтинг игроков, счет личных встреч и процент выигранных матчей в качестве параметров для прогноза. Использованные им статистические модели позволили правильно предсказать победителя в 70% матчей. В данной работе автор использует более маленькое множество игроков, состоящее из лучших игроков мира, а также большее количество параметров, для того чтобы увеличить процент правильных прогнозов.

Основная цель настоящей работы заключается в сборе множества публичных данных об играх и их матчах, а также создание и обучение нейросетевой модели на этих данных. Конечным результатом должна быть нейросетевая система, способная прогнозировать матчи сильнейших игроков мира в снукер в больше чем 70% случаев.

Для создания нейросетевой системы были выбраны следующие параметры: X₁ – разность позиций первого и второго игрока в таблице мирового рейтинга, X₂ – разность позиций первого и второго игрока в таблице заработанных призовых, X₃ – разность сделанных 50+ серий, X₄ – разность возрастов, X₅ – разность процента побед за последний сезон, X₆ – прогноз

букмекерского сайта, X7 – опубликованный результат опроса фанатов снукера о победителе матча, X8 – разность счета последней встречи в фреймах, X9 – победитель предыдущей встречи, X10 – процент побед первого игрока в личных встречах. Выходной параметр – победитель следующей встречи.

Обучающее множество было собрано с помощью программы-парсера с интернет-ресурсов, а также вручную. Перед переходом к проектированию и обучению нейросетевой модели, была выполнена очистка исходного множества от противоречивых примеров, выбросов, дубликатов. Например, некорректными примерами считались те, где абсолютный фаворит матча проигрывал, а также те, где у двух игроков не хватало информации о личных встречах. Таким образом, объем итогового множества включает в себя 120 примеров. Данное множество было разделено на обучающее и тестирующее в соотношении 80% и 20% соответственно. Большая часть данных была собрана с интернет ресурсов [5-6].

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [7] по методике [8]. В результате оптимизации спроектированная нейронная сеть представляла собой персептрон, который имеет десять входных нейронов, один выходной и один скрытый слой с тремя нейронами.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 21 примера. Средняя относительная ошибка тестирования составила 9.6%, что можно считать приемлемым результатом. На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактическим и прогнозируемым нейросетью победителями матчей

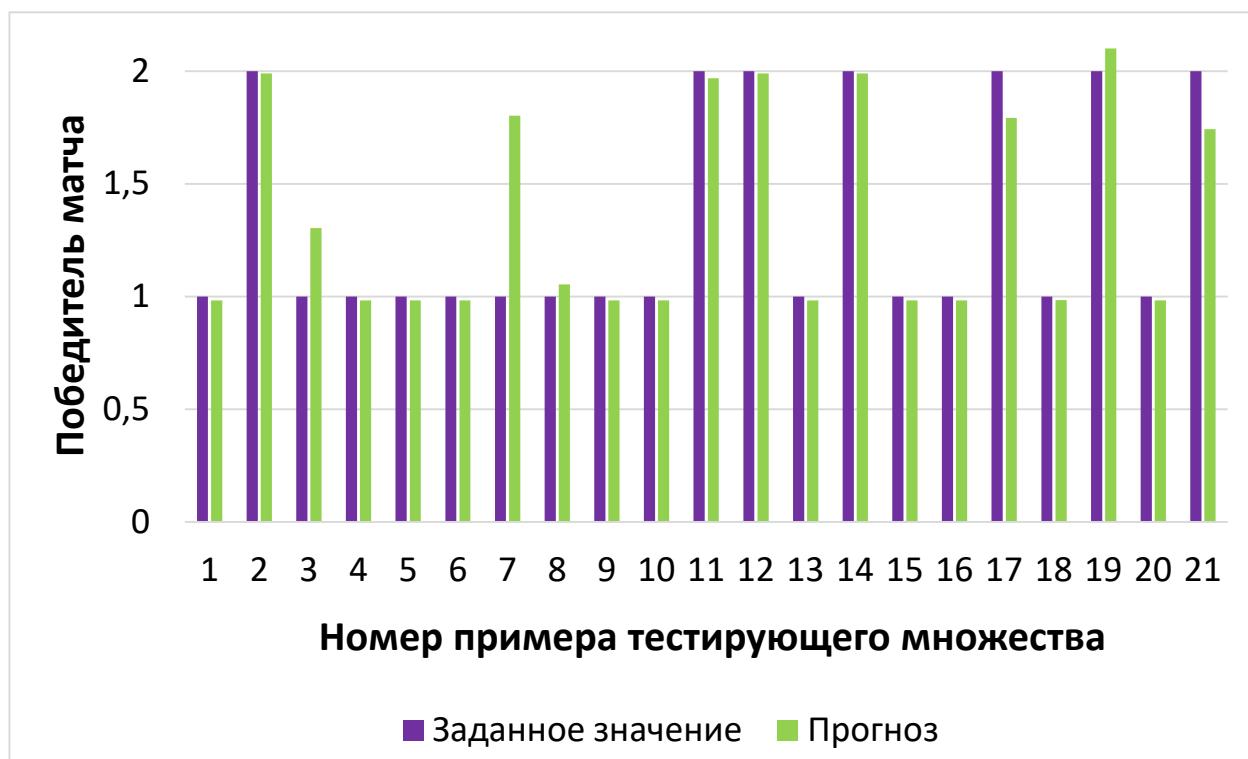


Рисунок 1. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 1, можно сделать вывод об адекватной работе спроектированной нейронной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5», результат отображен на рисунке 2.

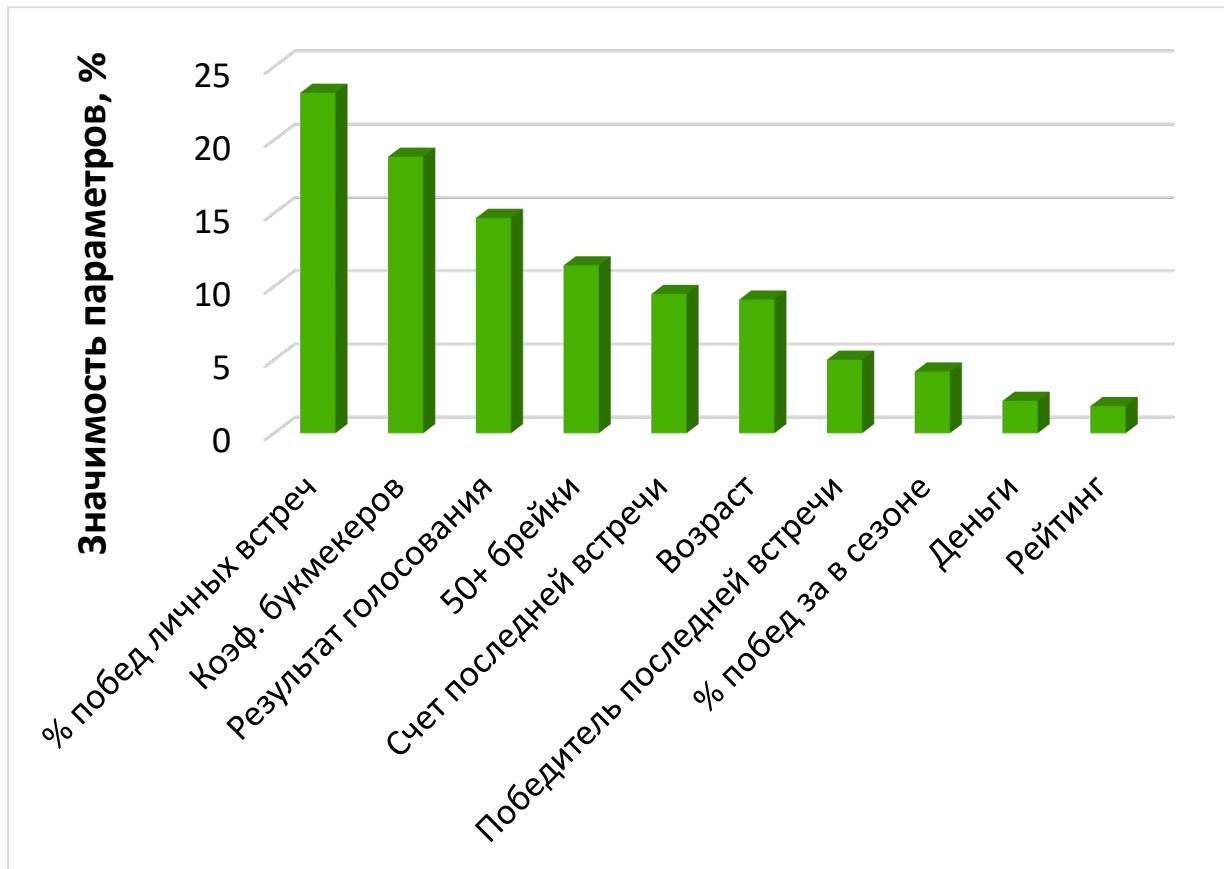


Рисунок 2. Значимость входных параметров нейросетевой модели

Как видно из рисунка 2, наиболее значимыми являются процент побед личных встреч, прогноз взятый с букмекерского сайта, результат опроса фанатов снукера, и т.д. Как и ожидалось, наиболее влиятельным параметром является процент побед личных встреч. Снукер – это игра, в которой большое значение имеет психологический фактор. Если человек будет нервничать из-за того, что играет против сильного противника, то начнет чаще проигрывать, потому что в снукере большое значение имеет способность игрока забивать длинные серии шаров.

Далее было проведено исследование полученных зависимостей между входными параметрами и победителем матча. Исследование производилось с помощью метода «замораживания» [1-3, 8], суть которого заключается в варьировании значения одного параметра и фиксировании значений всех других параметров. Для этой цели был отобран «нейтральный пример», про который нейросеть не может с уверенностью сказать, у кого из игроков значительное преимущество.

На рисунке 3 показан график зависимости прогнозируемого победителя от результата личных встреч. В том случае, когда у первого игрока большой

процент побед в личных встречах против его текущего противника, нейросеть прогнозирует значительное увеличение шанса на победу первым игроком.

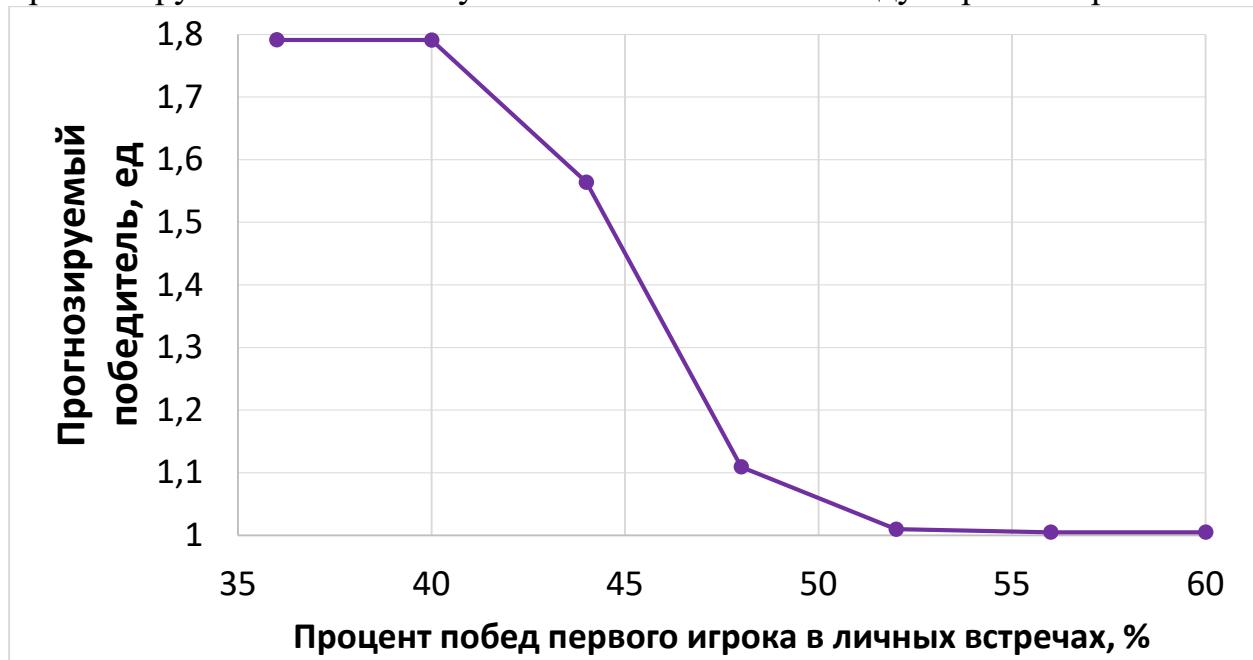


Рисунок 3. Зависимость прогнозируемого победителя от результата личных встреч

На рисунке 4 продемонстрирована зависимость прогнозируемого победителя от прогноза букмекерского сайта. Можно заметить, что данный сайт преувеличивает вероятность победы.

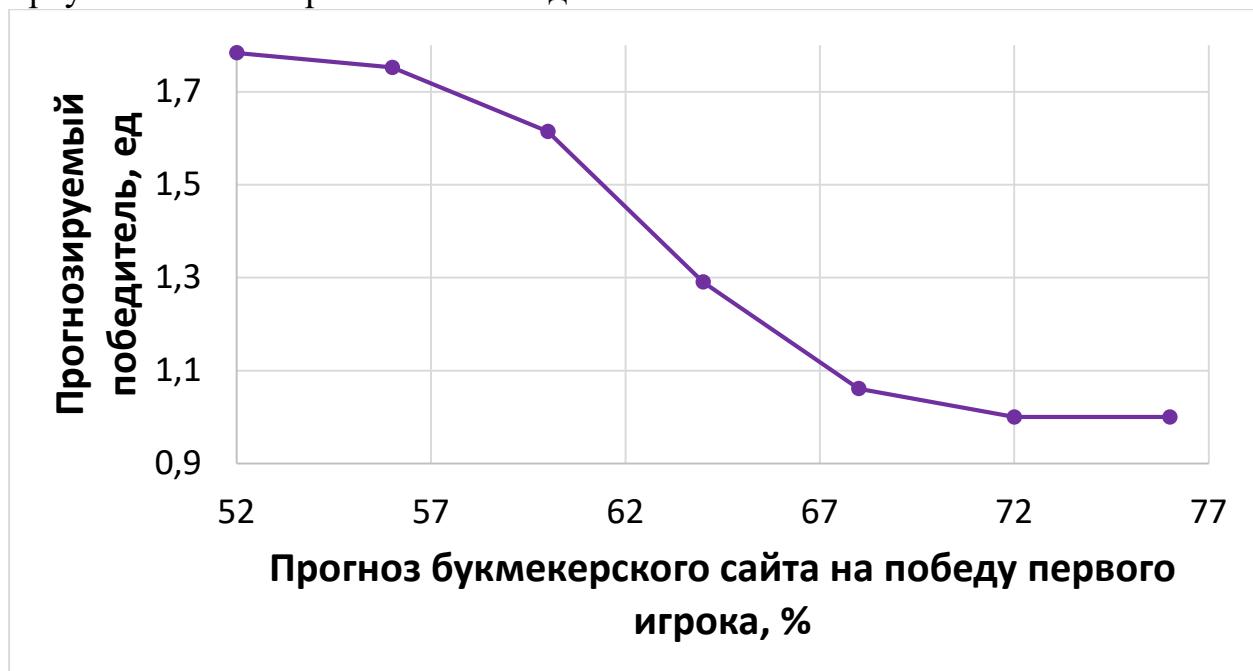


Рисунок 4. Зависимость прогнозируемого победителя от прогноза букмекерского сайта

На рисунке 5 изображен график зависимости победителя от результатов опроса. Как видно из графика, результат голосования хорошо отражает вероятность победы второго игрока.

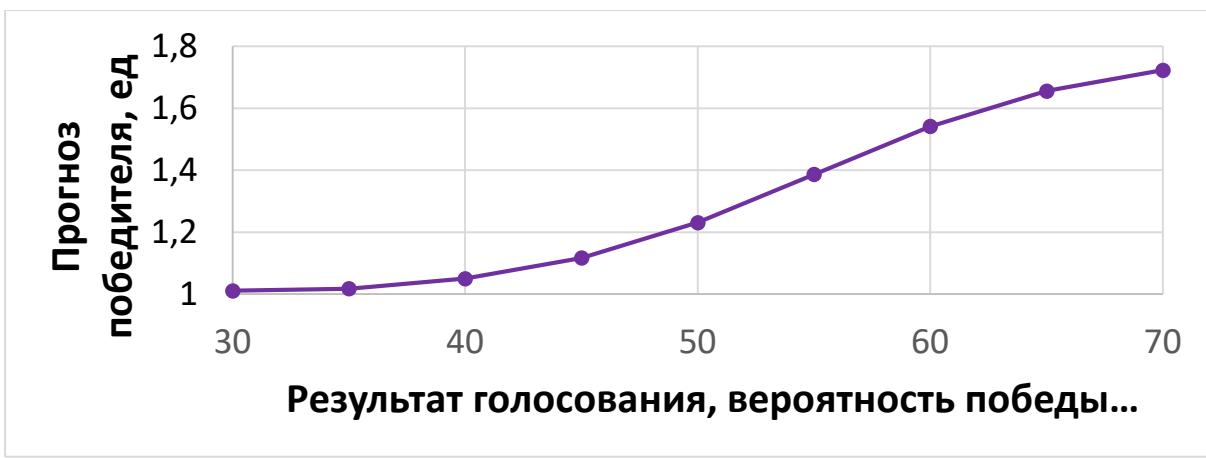


Рисунок 5. Зависимость прогнозируемого победителя от результатов опроса

На рисунке 6 продемонстрирована зависимость прогнозируемого победителя матча от возраста. Как видно из графика, с увеличением возраста повышается шанс на победу. Это объясняется тем, что в выборке оказались примеры матчей сильнейших игроков мира, которые по совпадению также имеют самый большой возраст из всех игроков выборки. Например, Ронни О'Салливан, занимающий 2 место в мировой таблице игроков, имеет возраст 45 лет, что на 8 лет больше, чем средний возраст попавших в выборку игроков.



Рисунок 6. Зависимость прогнозируемого победителя от разности возрастов

На рисунке 7 продемонстрирована зависимость прогнозируемого победителя от победителя предыдущей встречи данной пары игроков. Если предыдущую встречу выиграл первый игрок, то нейросеть прогнозирует вероятную победу первого игрока в следующей встрече, и наоборот.

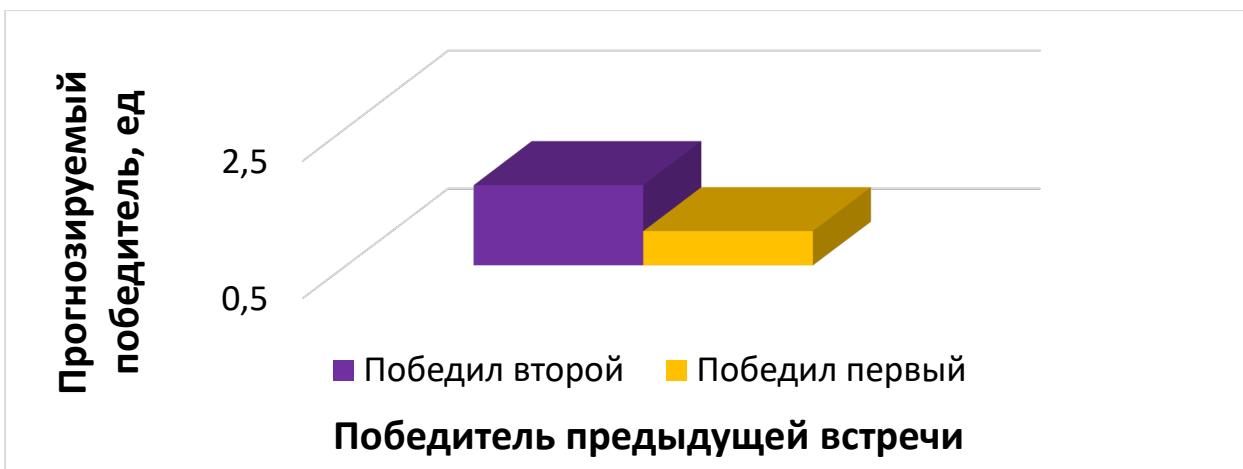


Рисунок 7. Зависимость прогнозируемого победителя от победителя предыдущей встречи

На рисунке 8 продемонстрирована зависимость прогнозируемого победителя матча от разницы процента побед двух игроков за прошлый сезон. С увеличением процента побед одного из игроков повышается вероятность победы в данном матче.

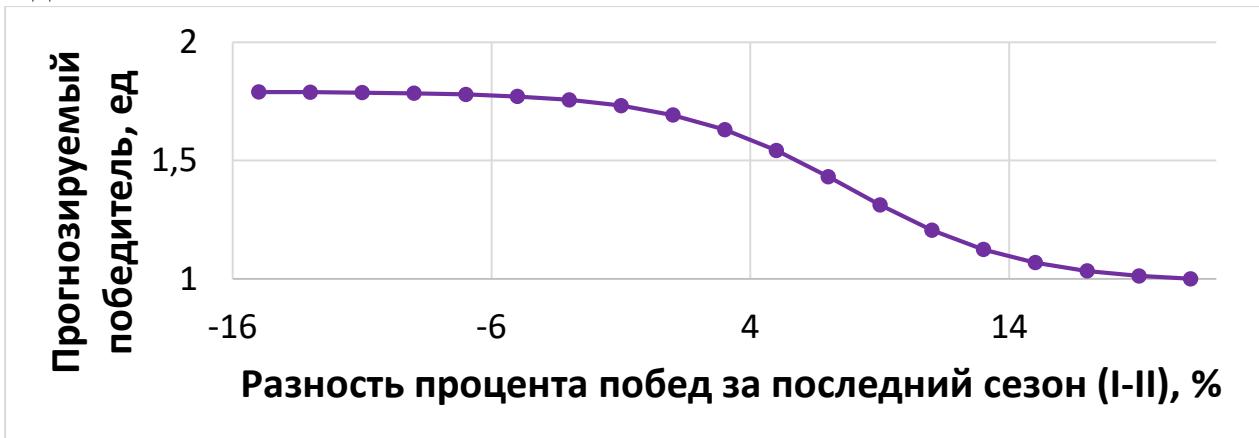


Рисунок 8. Зависимость прогнозируемого победителя от разности процента побед

Полученные результаты исследований не противоречат реальности, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для прогнозирования результатов матчей профессиональных игроков в снукер.

Заключение. Построена система нейросетевого прогнозирования победителя профессиональных матчей в снукер. Спроектированная нейросетевая модель учитывает 10 параметров: мировой рейтинг, количество заработанных призовых, количество 50+ серий, возраст, процент побед за последний сезон, букмекерский прогноз, результат опроса фанатов снукера, счет последней встречи, победитель последней встречи, процент побед личных встреч пары игроков. Методом сценарного прогнозирования построены графики зависимостей прогнозируемого победителя матча от изменения входных параметров. Применение такого набора параметров в модели позволяет с высокой точностью прогнозировать победителя матчей. Данный набор параметров может быть изменен для прогнозирования результатов матчей непрофессиональных игроков.

Библиографический список

1. Ясницкий Л.Н., Павлов И.В., Черепанов Ф.М. Прогнозирование результатов олимпийских игр 2014 года в неофициальном командном зачете методами искусственного интеллекта // Современные проблемы науки и образования. 2013. № 6. С. 985.
2. Ясницкий Л.Н., Vnukova O.V. Прогноз результатов олимпиады-2014 в мужском одиночном фигурном катании методами искусственного интеллекта // Современные проблемы науки и образования. 2014. № 1. С. 189.
3. Ясницкий Л.Н., Кировоса А.В., Ратегова А.В., Черепанов Ф.М. Прогноз результатов чемпионата мира-2015 по легкой атлетике методами искусственного интеллекта // Современные проблемы науки и образования. 2014. № 4. С. 624.
4. www2.stat-athens.aueb.gr – презентация на тему: «Прогнозирование результатов профессиональных матчей в снукер». [Электронный ресурс]. Режим доступа: http://www2.stat-athens.aueb.gr/~jbn/conferences/MathSport_presentations/TRACK%20B/B3%20-%20Sports%20Modelling%20and%20Prediction/Collingwood_Snooker.pdf
5. Cuetracker.net – статистика игроков в снукер. [Электронный ресурс]. Режим доступа: <https://cuetracker.net/>
6. Sofascore.com – прогноз результатов спортивных матчей. [Электронный ресурс]. Режим доступа: <https://www.sofascore.com/>
7. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
8. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.

NEURAL NETWORK SYSTEM FOR PREDICTING THE WINNER OF A SNOOKER MATCH

Ko Dmitry V.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990,
ruinmath@bk.ru

The article describes the development of a neural network system for predicting the results of snooker matches. The system allows to accurately predict the winner of the next match based on the data on two players and the history of their face-to-face encounters.

Keywords: artificial intelligence, neural network, prediction, billiard, snooker.

ПРОГНОЗИРОВАНИЕ РЕЗУЛЬТАТА КИБЕРСПОРТИВНЫХ МАТЧЕЙ

Власов Андрей Алексеевич

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15, andreyperm109@mail.ru

В статье представлено описание разработки нейросетевой системы для прогнозирования результата киберспортивных матчей. Система позволяет оценить, какая команда победит. Это поможет киберспортсменам улучшить их навыки, а букмекерским организациям работать эффективнее.

Ключевые слова: искусственный интеллект, нейросетевые технологии, прогнозирование, киберспорт.

Введение. Киберспорт с каждым годом становится всё популярнее, турниры в нём сейчас такие же престижные, как и в обычном спорте. Мы же рассмотрим одну из самых популярных киберспортивных дисциплин – игру Counter-Strike: Global Offensive. Суть этой игры заключается в противостоянии 2 команд по 5 человек в каждой. Побеждает та команда, которая первая выиграет 16 раундов из 30. Так как в этом спорте участвуют живые люди, то от множества человеческих факторов (которые невозможно предугадать) может зависеть результат игры, поэтому прогнозировать мы будем результат только 1 и 16 раундов каждой игры, которые из-за внутриигровых правил являются самыми сбалансированными и не так сильно зависят от человеческих факторов.

Одним из наиболее важных аспектов проекта машинного обучения является понимание основных функций, которые соотносятся с атрибутом, который мы пытаемся предсказать [1]. Основная цель заключается в поиске множества данных, на котором будет обучаться и тестироваться нейросеть. Найденное готовое множество включает в себя 6 входных параметра и 1 выходной. Оно собиралось в течении полугода на результатах прошедших матчей 20 сильнейших команд мира.

Количество параметров в множестве данных, по сравнению с исходным, остается неизменным: X₁ – команда 1, X₂ – команда 2, X₃ – карта, название местности в которой проходит противостояние, X₄ – позиция на которой начинает команда 1, X₅ – количество побед команды 1 против команды 2 за последний 5 игр, X₆ – количество побед команды 2 против команды 1 за последний 5 игр. Выходной параметр D₁ – результат противостояния.

Многие параметры были закодированы: Команда 1 (1-Natus Vincere; 2-Gambit; 3-G2; 4-Astralis; 5-Virtus.pro; 6-Faze; 7-NiP; 8-Heroic; 9-Vitality; 10-BiG; 11-mousesports; 12-Spirit; 13-Liquid; 14-OG; 15-Furia; 16-Complexity;

17-EG; 18-ENCE; 19-Fnatic; 20-mibr;), Команда 2 (1-Natus Vincere; 2-Gambit; 3-G2; 4-Astralis; 5-Virtus.pro; 6-Faze; 7-NiP; 8-Heroic; 9-Vitality; 10-BiG; 11-mousesports; 12-Spirit; 13-Liquid; 14-OG; 15-Furia; 16-Complexity; 17-EG; 18-ENCE; 19-Fnatic; 20-mibr;), Карта, название местности где происходит игра (1-dust2; 2-mirage; 3-inferno; 4-nuke; 5-overpass; 6-ancient; 7-vertigo;) позиция на которой начинает команда 1(СТ-1; Т-2), в выходном параметре (1 – победа команды 1, 2 – победа команды 2). Количество побед команд за последние 5 игр (X5, X6) варьируется в диапазоне 0-10, оно не было закодировано.

Исходное множество было взято с HLTV [2] и содержало 600 строк, поэтому для удобства обучения и тестирования случайным образом было отобрано 500 примеров.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [4] по методике [3] с использованием опыта применения нейросетевых технологий в спортивной сфере [5-7]. В результате оптимизации спроектированная нейронная сеть представляла собой персепtron, который имеет шесть входных нейронов, один выходной и два скрытых слоя с восьмью нейронами, количество которых оказалось оптимальнее всего.

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 50 примеров, что является 10% от обучающего множества. Средняя ошибка тестирования составила 25%. На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактическим и прогнозируемым нейросетью результатом случайно отобранных 50 матчей.

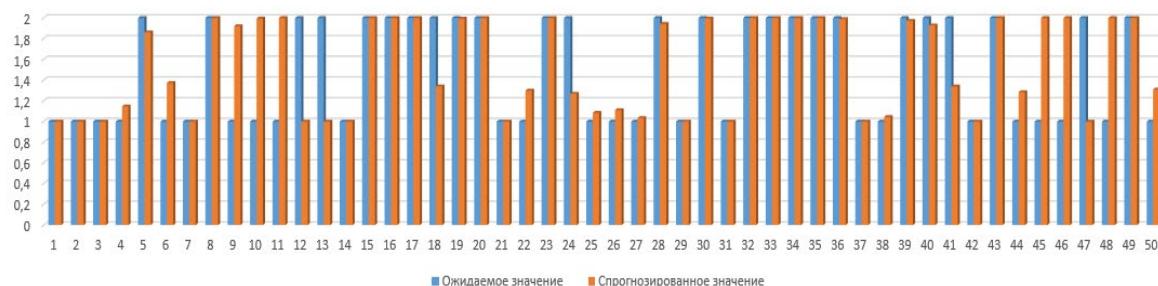


Рисунок 35. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 1, можно сделать вывод об адекватной работе спроектированной нейронной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5», результат отображен на рисунке 2.

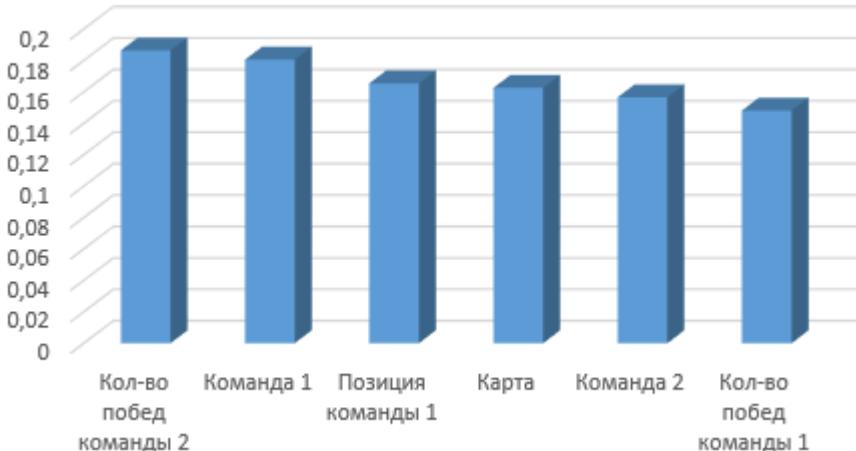


Рисунок 36. Значимость входных параметров нейросетевой модели

Из рисунка 2 видно, что все параметры практически одинаково значимы. Это можно объяснить тем, что на текущем собранном множестве данных параметры имеют одинаковое значение.

Далее было проведено исследование результатов киберспортивных матчей. Исследование производилось с помощью метода «замораживания» [3], суть которого заключается в варьировании значения одного параметра и фиксировании значений всех других параметров. Данный метод позволяет выявить влияние исследуемого параметра на выходной. Для этой цели были отобраны 5 примеров, информация о параметрах, которых отражена в таблице 1.

Таблица 1
Примеры, отобранных
для исследования

№ отзыва	1	2	3	4	5
X1	1	2	3	2	7
X2	2	1	1	16	2
X3	1	1	2	2	3
X4	1	2	1	1	2
X5	5	4	4	8	5
X6	5	6	6	2	5

На рисунке 3 показан график зависимости результата от кол-ва побед команды 2 – самым значимым показателем. Из графика следует, что при

увеличении количества побед команды 2 в прошлых играх, возрастает вероятность победы команды 2 в текущей игре.

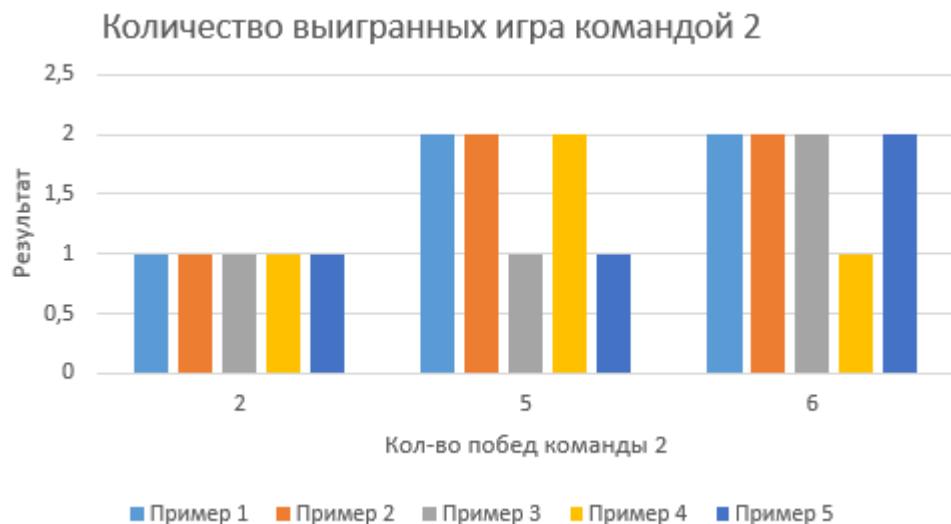


Рисунок 37. Зависимость результата от побед команды 2

На рисунках 4-5 показаны графики зависимости результата пассажира от команды 1 и позиции команды 1. Как видно, некоторые команды сильнее других и, следовательно, побеждают чаще, это видно на рисунке 4. На рисунке 5 видно, что позиция команды 1 влияет в меньшей степени на результат игры.

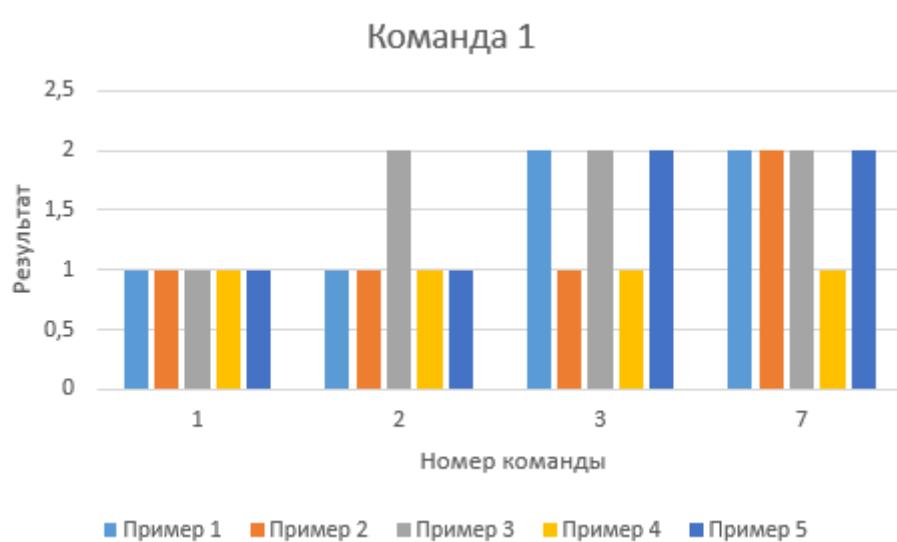


Рисунок 38. Зависимость результата от команды 1

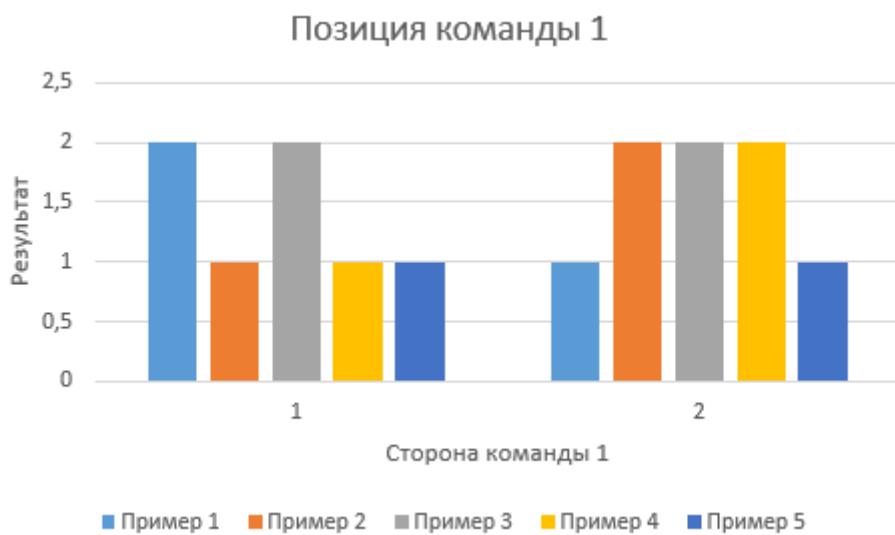


Рисунок 39. Зависимость результата от позиции команды 1

Полученные результаты исследований не противоречат реальности, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для прогнозирования результатов киберспортивных матчей.

Заключение. Построена система нейросетевого предсказания результата киберспортивного матча. Спроектированная нейросетевая модель учитывает шесть категорий показателей, влияющих на результат матча: команда 1, команда 2, карта, позиция команды 1, кол-во побед команды 1, кол-во побед команды 2. Методом сценарного прогнозирования построены графики зависимостей результата от команды 1, позиции команды 1, кол-во побед команды 2.

Библиографический список

1. Ясницкий Л.Н. Интеллектуальные системы: учебник. – М.: Лаборатория знаний, 2016. – 221 с.
2. HLTV.org CS:GO results. – URL: <https://www.hltv.org/results>.
3. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.
4. Нейросимулятор 5.0: свидетельство о государственной регистрации программы для № 2014618208 от 12.07.2014 г. / Черепанов Ф.М., Ясницкий В.Л. (РФ).
5. Ясницкий Л.Н., Vnukova O.V. Прогноз результатов олимпиады-2014 в мужском одиночном фигурном катании методами искусственного интеллекта // Современные проблемы науки и образования. 2014. № 1. С. 189. ; URL: <http://www.science-education.ru/115-11339> (дата обращения: 22.03.2021).
6. Ясницкий Л.Н., Кирюкова А.В., Ратегова А.В., Черепанов Ф.М. Методика прогнозирования результатов спортивных состязаний на примере Чемпионата мира-2015 по легкой атлетике // Вестник Пермского университета. Серия: Математика. Механика. Информатика. 2014. № 3 (26). С. 90-97.

7. Ясницкий Л.Н., Павлов И.В., Черепанов Ф.М. Прогнозирование результатов олимпийских игр 2014 года в неофициальном командном зачете методами искусственного интеллекта // Современные проблемы науки и образования. 2013. № 6. URL: <http://www.science-education.ru/113-11206> (дата обращения: 22.03.2021).

PREDICTION OF THE RESULT OF E-SPORT MATCHES

Vlasov Andrey Alekseevich

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990

The article describes the development of a dynamic neural network system for predicting the result of eSports matches. The system allows you to evaluate which team will win. This will help esports players to improve their own skills, as well as bookmaker organizations to operate more profitably.

Key words: artificial intelligence, neural network technologies, forecasting, esports.

УДК 004.032.26, 796.332

НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗИРОВАНИЯ РЕЗУЛЬТАТОВ СЕЗОНА НЕМЕЦКОЙ ФУТБОЛЬНОЙ ЛИГИ «БУНДЕСЛИГИ»

Бутина Дарья Владимировна

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
dbutiina@gmail.com

В статье представлено описание разработки нейросетевой системы для прогнозирования результатов сезона немецкой футбольной лиги «Бундеслиги». Система позволяет выполнять оценку выступления футбольной команды в сезоне. В разработанной системе учитываются биологические и спортивные показатели.

Ключевые слова: искусственный интеллект, нейросетевые технологии, футбольная лига, прогнозирование результатов матча, футбол.

Введение. В современном мире одним из наиболее популярных видов спорта является футбол – спортивная игра двух команд, состоящая из одиннадцати игроков в каждой, целью которых является ударами ноги загнать мяч в ворота противника. Миллионы людей по всему миру смотрят матчи

каждую неделю, год, два, четыре. Многие из болельщиков делают ставки на различных сайтах, пытаются определить исход матча.

Известно, что определить исход события в спортивной сфере очень трудно, так как существует большое количество факторов, которые влияют на него. Для выполнения прогнозов одним из наиболее эффективных методов являются нейросетевые технологии. Нейронные сети, реализованные по принципу построения и функционирования человеческого мозга, способны извлекать знания из статистических данных, обобщать их и верно прогнозировать исходы в каких-либо областях. Правильно обученные нейронные сети способны обнаружить закономерности в практически любых сферах деятельности. Таким образом, в области спорта с помощью данных технологий были предсказаны результаты Олимпийских игр 2014 года в неофициальном командном зачете [9] и спрогнозированы результаты в мужском одиночном фигурном катании так же на Олимпийских играх 2014 года [10].

Исследование возможности применения экономико-математического моделирования в области спорта, в частности – прогнозирования результатов футбольного сезона «Бундеслиги» – не является каким-либо исключением. Исходя из этого, можно выявить факторы, влияющие на успешность выступления команды в сезоне, а также попробовать оптимизировать эти факторы.

Методика прогнозирования. Модель нейронной сети имеет 8 входных и 1 выходной параметр, представленные в таблице 1. Некоторые из них были взяты из ранее опубликованных работ [7, 8], посвященных прогнозированию мест на чемпионате Европы по футболу Евро-2016 и Чемпионате мира-2015 по легкой атлетике. После ознакомления с данными статьями, были выбраны параметры «средний возраст игроков» и «возраст тренера», которые показались уместными в рамках данного исследования. Некоторые из параметров, значимые в прогнозировании чемпионата Европы по футболу Евро-2016 в обычном ежегодном чемпионате либо отсутствуют, либо являются малозначимыми. К таким относятся «хозяйка чемпионата», «государственный язык» и «религия». Разумеется, в данном прогнозировании они браться не будут. Был добавлен такой параметр как «место в текущем сезоне», которое показывает не только явных лидеров или аутсайдеров, но и «средние» места.

Таблица 1. Описание входных/выходных параметров

X1	Средний возраст игроков команды
X2	Средний рост игроков команды
X3	Средний вес игроков команды
X4	Количество очков, набранных командой в текущем сезоне
X5	Количество забитых мячей в текущем сезоне
X6	Количество пропущенных мячей в текущем сезоне
X7	Место в текущем сезоне
X8	Возраст тренера
Y1	Какую позицию займет команда в следующем сезоне?

В таблице 2 указаны различные значения, принимаемые входными параметрами.

Таблица 2. Значения входных параметров

X1	От 20 до 30
X2	От 180 до 185
X3	От 70 до 80
X4	От 0 до 102
X5	От 0 до 150
X6	От 0 до 150
X7	От 1 до 18
X8	От 20 до 90

Выходные данные могут принимать 4 значения: «1» – команда займет с 1 по 7 место в следующем сезоне, «2» – команда займет с 8 по 15 место в следующем сезоне, «3» – команда займет с 16 по 18 место в следующем сезоне, «4» – команда покинет «Бундеслигу» и окажется в «Бундеслиге-2».

Для получения изначального множества были использованы сайты «Soccer365» и официальный сайт «Бундеслиги» [1, 2]. В результате для обучающего множества было использовано 75 примеров, а для тестового – 15.

Для создания самой нейронной сети было использовано программное обеспечение «Нейросимулятор 5-10s» [3].

Для нахождения необходимого числа нейронов воспользуемся следствием из теоремы Арнольда-Колмогорова (формула 1) [4], чтобы найти оптимальное количество нейронов на скрытом слое.

$$\frac{Ny \cdot Q}{\log_2 Q + 1} \leq N_w \leq Ny \cdot \left(\frac{Q}{Nx} + 1 \right) (Nx + Ny + 1) + Ny \quad (1)$$

В формуле: Ny – количество выходных нейронов, Nx – количество входных нейрона, Q – количество примеров в обучающем множестве, Nw – необходимое число синоптических связей. Полученная оценка: $13 \leq N_w \leq 123$.

Найдем оценку для количества входных нейронов – N: $1 \leq N \leq 14$.

Самым оптимальным количеством нейронов оказалось N = 6.

Функциями активации выступал тангенс гиперболический.

Структура нейронной сети представлена на рисунке 1.

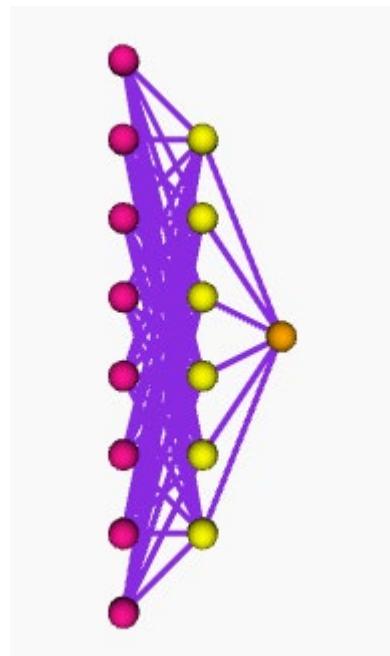


Рисунок 1. Структура нейронной сети

Обучение сети. Результаты обучения представлены на рисунке 3. Результаты подтверждающего множества со среднеквадратичным отклонением в 7% изображены на диаграмме рисунка 2.

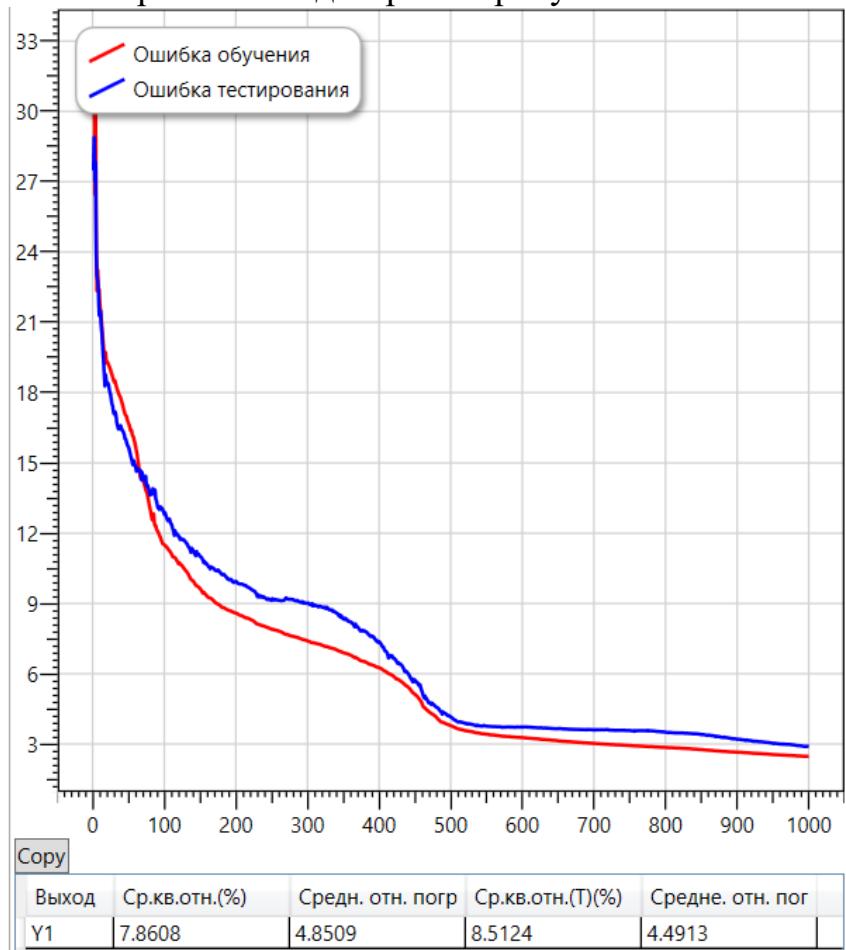


Рисунок 2. Результаты обучения

Анализ влияния входных параметров. Необходимо выяснить значимость входных параметров: степень влияния на результат моделирования. Объективную оценку такого влияния можно получить с помощью нейронной сети путем поочередного изменения входных параметров и наблюдения за погрешностью ее тестирования. Чем выше оказывается погрешность тестирования, тем значимее соответствующий измененный параметр. На рисунке 3 приведена гистограмма, построенная по полученным таким образом данным. Высота столбцов соответствует погрешности тестирования, полученной при исключенном входном параметре, подписанном под столбцом, поэтому ее можно интерпретировать как значимость этого параметра.

Самым значимым параметром является средний рост игрока, вторым по значимости – количество очков, заработанных командой в текущем сезоне.

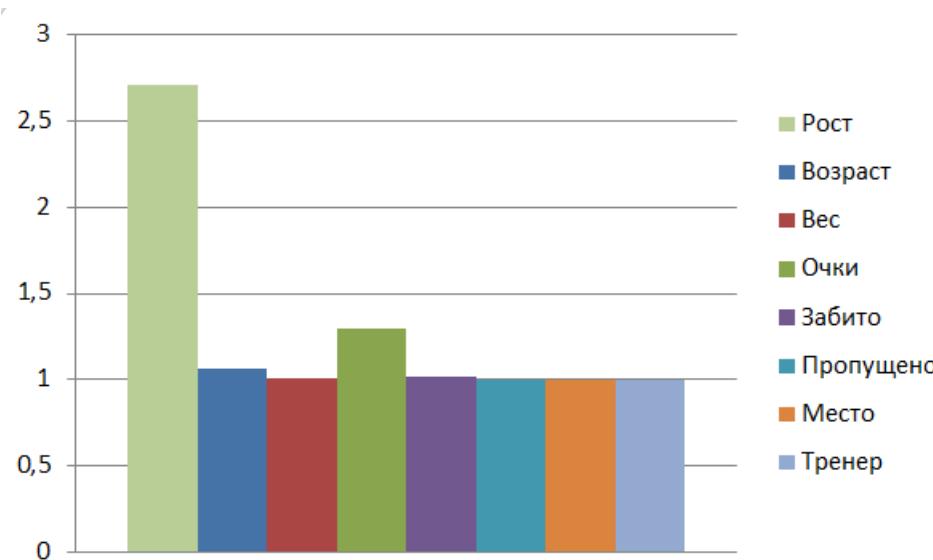


Рисунок 3. Значимость входных параметров

На примере немецкой команды «Вердер» сезона 2014/2015 рассмотрим влияние входных параметров на итоговое расположение команды в сезоне 2015/2016. Данные по команде имеют следующий вид. Средний рост игроков – 23,18 лет; средний возраст игроков – 184,29 см; средний вес игроков – 78 кг; количество очков в текущем сезоне – 43; количество забитых мячей – 50; количество пропущенных мячей – 65; место в итоговой таблице турнира – 10; возраст тренера – 46 лет.

Рассмотрим влияние среднего роста игроков. График влияния показан на рисунке 4.



Рисунок 4. Влияние среднего роста игрока

Рассмотрим влияние среднего возраста игроков. График влияния показан на рисунке 5. В возрасте 24-25 лет наблюдается незначительный выброс, что, скорее всего, связано с недостаточным количеством данных. Однако при данном среднем возрасте команда действительно занимала места с 8 по 15.



Рисунок 5. Влияние среднего возраста игрока

Благодаря рисунку 6 можно заметить, что если команда наберет 10 очков в текущем сезоне, то она, вероятнее всего, выйдет из первой лиги и попадёт во вторую. Если же команда наберет 80 очков (и более), то попадет в топ 7 команд и сыграет в «Лиге чемпионов» или «Лиге Европы».

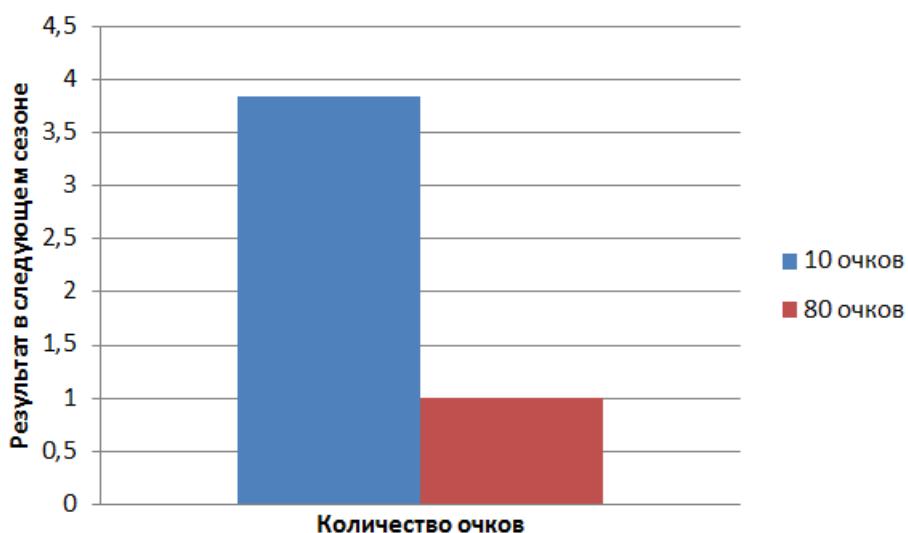


Рисунок 6. Влияние количества очков в текущем сезоне

Заключение. Создана нейросетевая модель, которая позволяет выполнять прогнозирование расположение немецких команд в рамках чемпионата Германии «Бундеслига».

Показано влияние входных параметров на результат. Так, например, обновление состава команды с целью увеличения или уменьшения среднего роста игроков может привести как к повышению места в итоговом зачёте, так и к снижению. Модель может быть использована для обновления игрового состава, анализа успехов и неудач команд.

Библиографический список

1. Soccer 365: сайт – URL: <http://soccer365.ru/> (дата обращения: 23.03.2021).
2. Bundesliga: сайт – URL: <https://www.bundesliga.com/en/bundesliga> (дата обращения: 23.03.2021).
3. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 5.0 // Свидетельство о государственной регистрации программы для ЭВМ № 2014618208. Заявка Роспатент № 2014614649. Зарегистрировано в Реестре программ для ЭВМ 12 августа 2014г.
4. Ясницкий Л.Н. Интеллектуальные системы : учебник. – М.: Лаборатория знаний, 2016. – 221с.
5. Ясницкий Л.Н. Нейронные сети – инструмент для получения новых знаний: успехи, проблемы, перспективы // Нейрокомпьютеры: разработка, применение. – 2015. – № 5. – С. 48-56.
6. Ясницкий Л.Н. Интеллектуальные информационные технологии и системы: учеб.-метод пособие / Л. Н. Ясницкий; Перм. Ун-т. – Пермь, 2007. – 271 с.
7. Ясницкий Л.Н., Кирюкова А.В., Ратегова А.В., Черепанов Ф.М. Методика прогнозирования результатов спортивных состязаний на примере Чемпионата мира-2015 по легкой атлетике // Вестник Пермского университета. Серия: Математика. Механика. Информатика. 2014. № 3 (26). С. 90–97.

8. Ясницкий Л.Н., Абрамова Ю.С., Бабушкина С.Д. Возможности получения рекомендаций по улучшению результативности сборных команд, готовящихся к участию в чемпионате Европы по футболу Евро-2016 методом нейросетевого моделирования // Вестник спортивной науки. 2015. № 5. С. 15-20.
9. Ясницкий Л.Н., Павлов И.В., Черепанов Ф.М. Прогнозирование результатов олимпийских игр 2014 года в неофициальном командном зачете методами искусственного интеллекта // Современные проблемы науки и образования. 2013. № 6. С. 985; URL: <http://www.science-education.ru/ru/article/view?id=11206> (дата обращения: 22.03.2021).
10. Ясницкий Л.Н., Vnukova O.V. Прогноз результатов олимпиады-2014 в мужском одиночном фигурном катании методами искусственного интеллекта // Современные проблемы науки и образования. 2014. № 1. С. 189.

**NEURAL NETWORK SYSTEM FOR PREDICTING THE RESULTS OF THE SEASON OF THE GERMAN FOOTBALL LEAGUE
«BUNDESLIGA»**

Butina Daria Vladimirovna

Perm State University, PMI. 614990, Russia, Perm, Bukireva str., 15,
dbutiina@gmail.com

The article describes the development of a neural network system for predicting the results of the season of the German football league "Bundesliga". The system allows you to evaluate the performance of a football team in a season. The developed system takes into account biological and sports indicators.

Keywords: artificial intelligence, neural network technologies, football league, match results forecasting, football.

ВОЗМОЖНОСТЬ ПРОГНОЗИРОВАНИЯ ИСХОДА ФУТБОЛЬНОГО МАТЧА НА ПРИМЕРЕ РОССИЙСКОЙ ПРЕМЬЕР-ЛИГИ

Валеев Рустам Равилевич

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, г. Пермь, ул. Букирева, 15,
valrusrav@gmail.com

В статье представлено описание разработки нейросетевой системы для прогнозирования результатов футбольных матчей Российской Премьер-Лиги (РПЛ). Программа позволяет получить ожидаемый исход в предстоящем матче, анализируя продвинутые статистические параметры в футболе, текущую форму команд и букмекерские котировки. Использование статистических показателей позволяет лучше оценивать уровень команд и качество их игры, делая более точный прогноз.

Ключевые слова: искусственный интеллект, нейросетевые технологии, прогноз, футбол, Российская Премьер-Лига.

Введение. В современном футболе растёт использование статистических данных. До недавнего времени футбол страдал от недостатка отслеживаемой статистики. В основном осуществлялся ручной подсчёт различного рода технико-тактических действий футболистов. С развитием современных технологий продвинутая статистика становится неотъемлемой частью футбола. Для сбора и анализа статистических данных, футбольные команды нанимают целый штат аналитиков. Исходя из статистических показателей тренеры корректируют игру своей команды, вносят изменения в тренировочный процесс и подбирают оптимальный состав на матч. Скауты используют статистику для оценивания игровых качеств и потенциала футболистов.

С появлением расширенной футбольной статистики появилась возможность использовать её не только для оценки какого-то определённого аспекта игры, но и для прогнозирования. Футбол – вид спорта с низкой результативностью. Поэтому любое событие, произошедшее на поле, может повлиять на исход матча. Использование всевозможных статистических показателей не гарантирует правильность прогноза, но позволяет выявить тенденции в игре команд, которые могут помочь в построении точного прогноза. Из-за большого числа характеристик, человеку сложно спрогнозировать с высокой точностью результат футбольного матча. Поэтому, для прогнозирования исходов спортивных состязаний начали использовать нейронные сети.

Эффективность использования искусственного интеллекта для прогнозирования результатов в футболе была обоснована в работах российских и зарубежных исследователей [1-6]. Авторы работ [1-2] учитывают большое количество параметров и предлагают различные модели для прогнозирования исходов матчей. В статья [3-6] впервые продемонстрирована возможность использования нейронных сетей для получения рекомендаций, которые могут повлиять на исход спортивных состязаний.

Данная работа является продолжением идей, предложенных в вышеупомянутых исследованиях. Основная цель настоящей работы заключается в сборе информации о матчах Российской Премьер-Лиги, а также создание и обучение нейросети на этих данных.

В результате анализа литературных источников [1-3] был определён набор показателей: X1 – номер тура, X2-X3 – место в турнирной таблице, X4-X5 – число забитых голов, X6-X7 – число пропущенных голов, X8-X9 – число набранных очков, X10-X11 – число «ожидаемых забитых голов» (xG), X12-X13 – число «ожидаемых пропущенных голов» (xGA), X14-X15 – интенсивность прессинга (PPDA), X16-X17 – число «ожидаемых набранных очков» (xPTS), X18-X19 – везение, X20-X21 – отношение «ожидаемых забитых голов» к «ожидаемым пропущенным голам», X22-X23 – число очков, набранных в последних пяти личных встречах, X24-X25 – число очков, набранных в последних пяти матчах чемпионата, X26 – котировки на победу хозяев, X27 – котировки на ничейный исход, X28 – котировки на победу гостевой команды. Параметры X2-X25 представлены как для команды, играющей дома, так и для гостевой. Показатели X1 и X26-X28 являются общими. Выходной параметр D1 – итог матча.

Параметр итог матча был закодирован: -1 – победа домашней команды, 0 – ничья, 1 – победа гостевой команды. Остальные параметры являются числовыми, поэтому для них кодировка не требуется.

В отличие от работ [1-2], для прогнозирования результата, также использовалась модель XG – модель расчета ожидаемых голов в футболе, в основе которой лежит анализ опасности ударов по воротам каждой из команд.

Множество примеров сформировано на основе результатов матчей Российской Премьер-Лиги в сезоне 2020/2021. Данные были собраны с интернет-ресурсов [7-10]. Перед переходом к проектированию и обучению нейросетевой модели, из исходного множества были исключены матчи первого тура, так как в начале сезона многие команды находятся в неоптимальной форме после летнего перерыва. Также во множество не вошли матчи, которые закончились техническим поражением одной из команд. Данные по итогам прошлого сезона не рассматривались, так как они являются не совсем актуальными. Это связано с тем, что во время межсезонья, составы и тренерские штабы команд обновляются, а в РПЛ переходят команды из лиги рангом ниже. Таким образом, объем итогового множества включает в себя 174 примера. Все множество собранных примеров было разделено в соотношении 80:15:5 на обучающее, тестирующее и прогнозирующее.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [11]. В результате оптимизации спроектированная нейронная сеть представляла собой персепtron, который имеет двадцать восемь входных нейронов, один выходной и один скрытый слой с тремя нейронами.

Для оценки правильности работы спроектированной нейронной сети использовалось тестовое множество, состоящее из 24 примеров. Средняя ошибка тестирования составила 20%. На рисунке 1 представлена гистограмма, демонстрирующая разницу между фактическим и прогнозируемым нейросетью исходом матчей.

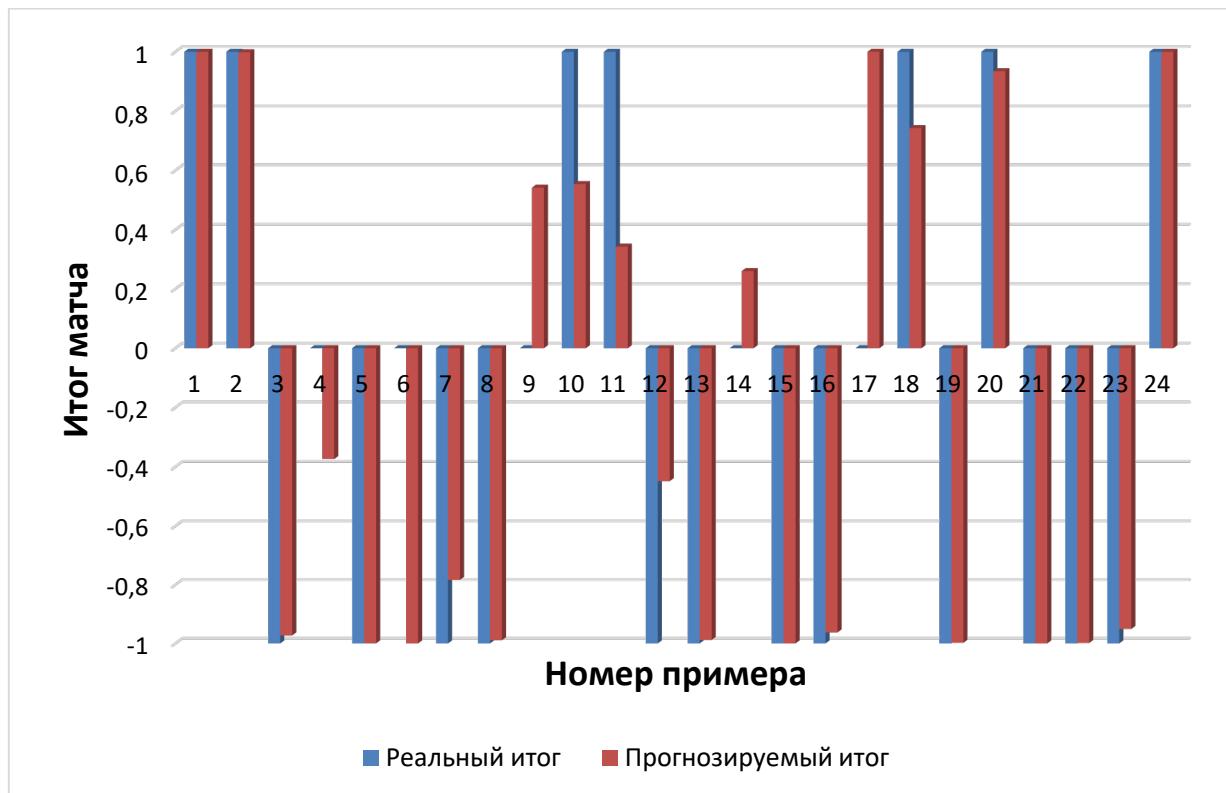
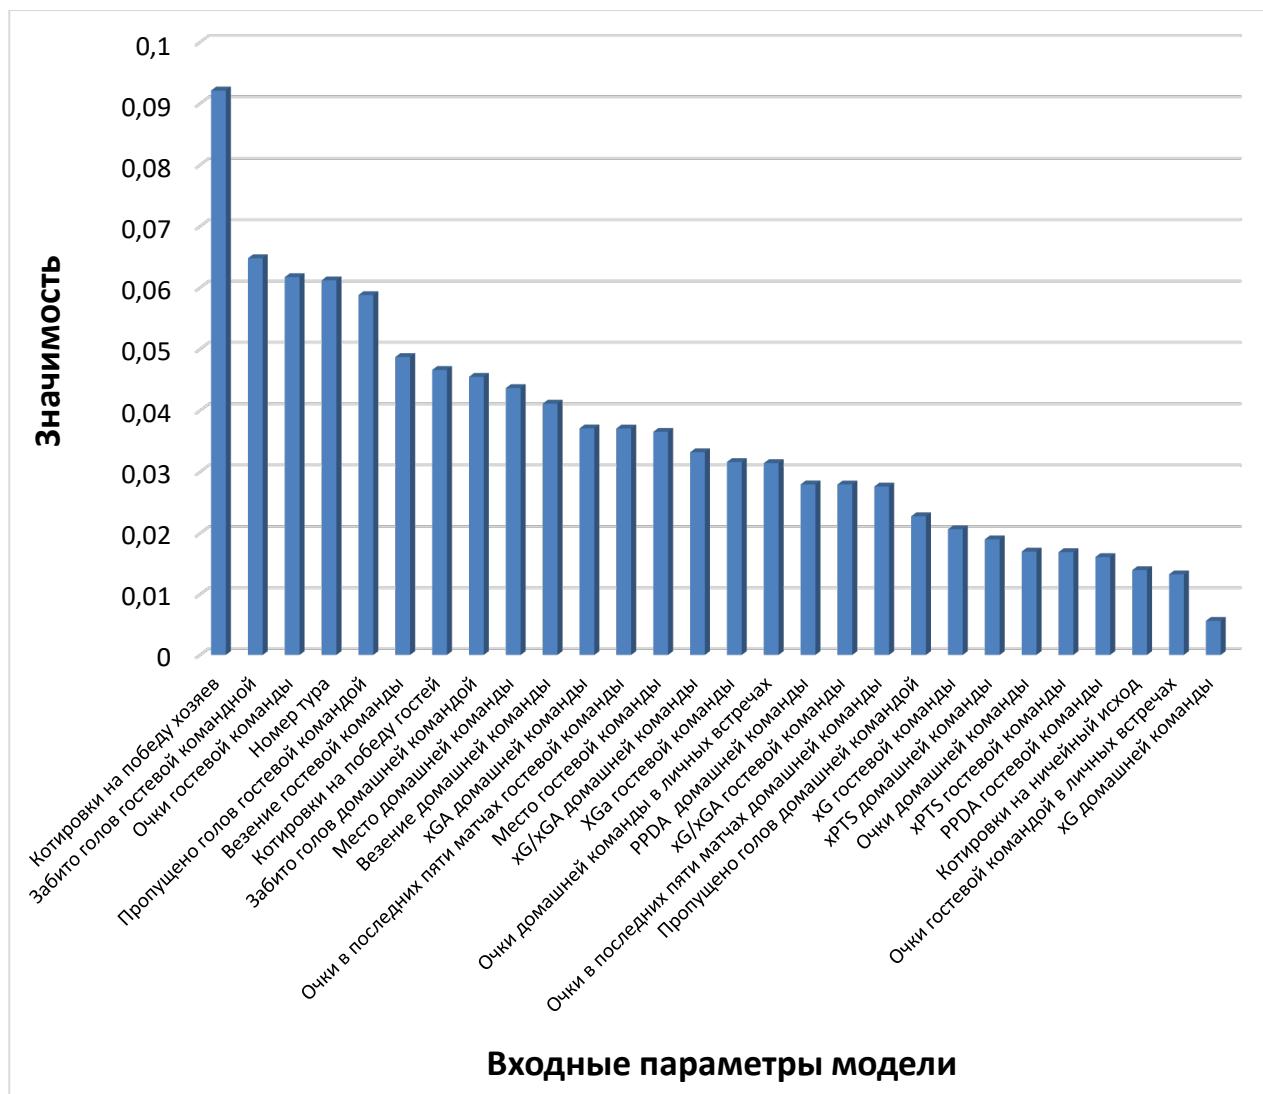


Рисунок 40. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке выше, можно сделать вывод о неплохой способности нейронной сети к прогнозированию.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5» [11], результат представлен на рисунке 2.



Входные параметры модели

Рисунок 41. Значимость входных параметров нейросетевой модели

Из рисунка 2 видно, что наиболее значимыми являются следующие параметры: котировки на победу хозяев, число голов, забитых гостевой командой, очки гостевой команды, номер тура и число пропущенных голов гостевой командой. Это объясняется тем, что в футболе чаще всего побеждают команды, играющие дома. Поэтому чем сильнее уровень игры гостевой команды, тем больше у неё шансов добиться положительного результата. В свою очередь, домашние команды, уступающие по уровню игры своему сопернику, нередко побеждают на своём поле даже явных фаворитов.

Следующим этапом стало исследование матчей Российской Премьер-Лиги. Они проводились при помощи метода «замораживания» [12], суть которого заключается в изменении значения одного параметра и фиксировании значений остальных параметров. Данный метод позволяет оценить степень влияния исследуемого параметра на выходной. Для исследования был выбран матч Рубин – Химки, прошедший 19 марта 2021 года и закончившийся победой гостевой команды. Информация о параметрах данного матча представлена ниже.

Таблица 5
**Характеристики матча,
выбранного для исследования**

Номер тура	23
Место домашней команды	5
Место гостевой команды	10
Число забитых голов домашней командой	31
Число забитых голов гостевой командой	27
Число пропущенных голов домашней командой	26
Число пропущенных голов гостевой командой	31
Число набранных очков домашней командой	37
Число набранных очков гостевой командой	32
Число «ожидаемых забитых голов» домашней командой	33,95
Число «ожидаемых забитых голов» гостевой командой	24,81
Число «ожидаемых пропущенных голов» домашней командой	24,71
Число «ожидаемых пропущенных голов» гостевой командой	34,66
Интенсивность прессинга домашней команды	10,42
Интенсивность прессинга гостевой команды	12,3
Число «ожидаемых набранных очков» домашней команды	35,95
Число «ожидаемых набранных очков» гостевой команды	24,46
Везение домашней команды	-4,24
Везение гостевой команды	5,85
Отношение «ожидаемых забитых голов» к «ожидаемым пропущенным голам» домашней команды	1,37
Отношение «ожидаемых забитых голов» к «ожидаемым пропущенным голам» гостевой командой	0,72
Очки, набранные в последних пяти личных встречах домашней командой	9
Очки, набранные в последних пяти личных встречах гостевой командой	6
Очки, набранные в последних пяти матчах домашней командой	13
Очки, набранные в последних пяти матчах гостевой командой	13
Котировки на победу домашней команды	1,9
Котировки на ничейный исход	3,54
Котировки на победу гостевой команды	4,78

На рисунках 3 и 4 представлена зависимость результата матча от параметра «Ожидаемые забитые голы» (xG). Данный показатель характеризует сколько моментов создала команда и насколько они были опасны. Если показатель xG превышает число забитых голов, то команда забивает меньше голов, чем могла бы. Это свидетельствует о плохой реализации моментов. Чем меньше команде нужно провести атак, чтобы забить гол, тем больше у неё шансов на успех. Поэтому уменьшение показателя «Ожидаемые забитые голы» увеличивает вероятность победы в матче.



Рисунок 42. Зависимость результата матча от показателя xG домашней команды



Рисунок 43. Зависимость результата матча от показателя xG гостевой команды

На рисунках 5-6 показан график зависимости результата от показателя «Ожидаемые пропущенные голы» (xGA). Из графика следует, что после уменьшения этого параметра, наблюдается понижение шанса на победу. Это

не противоречит логике, так как этот показатель нельзя рассматривать без учёта реального числа пропущенных голов. Так, домашняя команда до этого матча пропустила 26 мячей, а гостевая – 31. Если команда пропускает больше голов, чем заслуживает по игре, то это говорит или о невезении, или о проблемах в структуре командных действий.



Рисунок 44. Зависимость результата матча от показателя xGA домашней команды



Рисунок 45. Зависимость результата матча от показателя xGA гостевой команды

На рисунке 7 продемонстрирован график зависимости результата матча от разности очков в последних пяти личных встречах. Как видно из графика, история личных противостояний имеет важное значение. Если одна из команд на протяжении всех последних матчей проигрывает другой, то часто говорят, что соперник является для неё «неудобным». Мотивация команды, которая долгое время не может обыграть своего соперника, значительно увеличивается. Перед этим матчем, команда Рубин имела на одну победу больше, чем команда Химки. Это говорит о том, что во встречах этих команд сложно определить фаворита исходя из недавних матчей между собой. В случае, если разность очков в личных встречах была бы более значительной, то исход матча мог бы измениться.

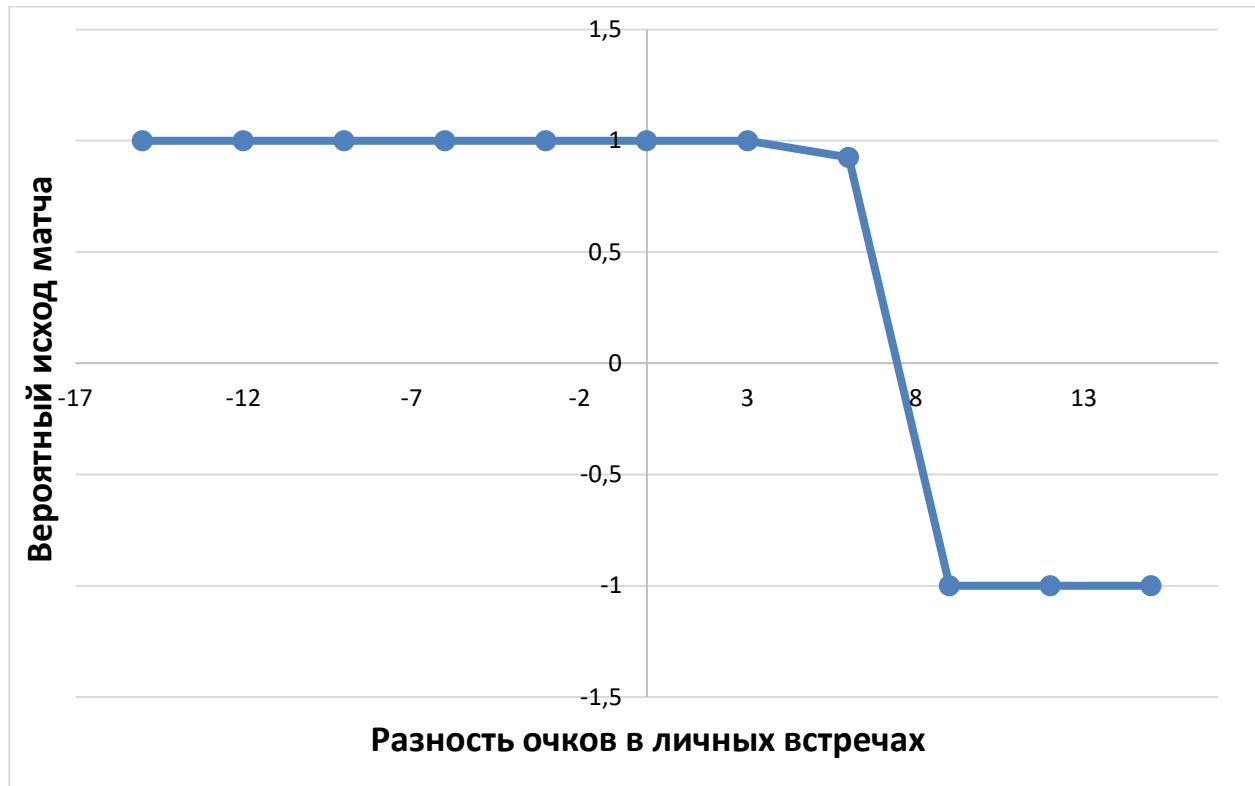


Рисунок 46. Зависимость результата матча от разности очков в личных встречах

Полученные результаты исследований не противоречат реальности. Спроектированную нейронную сеть можно считать пригодной для прогнозирования результатов матчей. При помощи оценки состояния команд и использования расширенной статистики появляется возможность делать более точные прогнозы.

Заключение. В результате проведенных исследований была разработана нейросеть, которая позволяет прогнозировать результаты матчей Российской Премьер-Лиги. Методом сценарного прогнозирования построены графики зависимостей исхода матча от разности очков в личных встречах, показателей «ожидаемые забитые голы» и «ожидаемые пропущенные голы». В построенной модели использовался набор параметров, включающий в себя продвинутые статистические параметры, текущую форму команд и

букмекерские котировки, что обеспечивает большую точность прогноза. В будущем модель может быть расширена для прогнозирования матчей других футбольных лиг.

Библиографический список

1. G. Fialho, A. Manhães, João Paulo Teixeira Predicting Sports Results with Artificial Intelligence – A Proposal Framework for Soccer Games // Journal of Procedia Computer Science. – 2019. -Vol. 164. – P. 131-136.
2. Igiri C.P., Nwachukwu E.O. An improved prediction system for football a match result // IOSR Journal of Engineering. – 2014. – Vol. 04. – Iss 12. – P. 12-20.
3. Ясницкий Л.Н., Абрамова Ю.С., Бабушкина С.Д. Возможности получения рекомендаций по улучшению результативности сборных команд, готовящихся к участию в чемпионате Европы по футболу Евро-2016 методом нейросетевого моделирования // Вестник спортивной науки. 2015. № 5. С. 15-20.
4. Ясницкий Л.Н., Vnukova O.V. Прогноз результатов олимпиады-2014 в мужском одиночном фигурном катании методами искусственного интеллекта // Современные проблемы науки и образования. 2014. № 1. С. 189.
5. Ясницкий Л.Н., Киросова А.В., Ратегова А.В., Черепанов Ф.М. Методика нейросетевого прогнозирования результатов спортивных соревнований на примере Чемпионата мира-2015 по легкой атлетике // Вестник Пермского университета. Серия: Математика. Механика. Информатика. 2014. № 3 (26). С. 90–97.
6. Ясницкий Л.Н., Павлов И.В., Черепанов Ф.М. Прогнозирование результатов олимпийских игр 2014 года в неофициальном командном зачете методами искусственного интеллекта // Современные проблемы науки и образования. 2013. № 6. С. 985.
7. Сайт Soccer365 [Электронный ресурс], 2021, URL: <https://soccer365.ru/> (дата обращения: 16.03.21).
8. Сайт Understat [Электронный ресурс], 2021, URL: <https://understat.com/> (дата обращения: 16.03.21).
9. Сайт NB-Bet [Электронный ресурс], 2021, URL: <https://nb-bet.com/> (дата обращения: 16.03.21).
10. Сайт Sportbox [Электронный ресурс], 2021, URL: <https://news.sportbox.ru/> (дата обращения: 16.03.21).
11. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
12. Ясницкий Л.Н. Введение в искусственный интеллект. М.: Издательский центр «Академия», 2005. – 176 с.

THE POSSIBILITY OF PREDICTION THE OUTCOME OF A FOOTBALL MATCH ON THE EXAMPLE OF GAMES RUSSIAN FOOTBALL PREMIER LEAGUE

Valeev R.R.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990,

valrusrav@gmail.com

The article describes the development of a neural network system for predicting the outcomes of football matches of the Russian Premier League. The program allows you to get the expected result in the match before it starts by analyzing advanced statistics in football, the current form of teams and betting odds. The use of statistical indicators allows you to better assess the level of teams and the quality of their play, making a more accurate prediction.

Keywords: artificial intelligence, neural network technologies, prediction, football, Russian Premier League.

УДК 004.032.26

НЕЙРОСЕТЕВАЯ СИСТЕМА ПРОГНОЗИРОВАНИЯ И АНАЛИЗА ПОСЕЩАЕМОСТИ МАТЧЕЙ АНГЛИЙСКОЙ ПРЕМЬЕР ЛИГИ

Паскар Алексей Владимирович, Акбуляков Вадим Финатович

Пермский государственный национальный исследовательский университет,
ПМИ. 614990, Россия, Пермь, ул. Букирева, 15,
alexkarate.s@mail.ru

В статье представлен процесс разработки экспертной системы, осуществляющей прогноз посещаемости футбольных матчей Английской премьер лиги (далее указана как АПЛ). Экспериментальным образом была получена оптимальная нейросетевая модель, а также факторы предметной области, в той или иной степени, влияющие на посещаемость футбольного матча, был приведен подробный анализ влияния каждого параметра на итоговый результат прогноза, а также составлены рекомендации, увеличивающие потенциальную посещаемость стадиона.

Ключевые слова: искусственный интеллект, нейронная сеть, закономерности, спорт, футбол, прогнозирование, посещаемость, моделирование.

Введение. Футбол является один из самых популярных видов спорта, благодаря своей непредсказуемости [2] на футбольном поле. Но непредсказуемость наблюдается и за его пределами, например, посещаемость футбольного матча. Поэтому спортивное прогнозирование является перспективным направлением для нейросетевого анализа. Информация о

количество фанатов на матче дает возможность определить количество еды, которое будет продаваться на стадионе, рекламным компаниям скорректировать расценки на кампанию бренда непосредственно на стадионе. Так же данные могут быть полезны силовым структурам, осуществляющим защиту населения от радикальных фанатов.

Целью настоящей работы является попытка применения современных методов искусственного интеллекта для количественного прогнозирования посещаемости футбольного матча.

В начале данной работы были изучены исследовательские работы со смежной предметной областью [1-8]. После этого были выбраны входные параметры, влияющие на результат прогнозирования, этот этап был ключевым, ведь при ошибочном выборе было бы проблематично правильно обучить нейронную сеть. В изначальной выборке были следующие параметры: влажность воздуха, расстояние между футбольными клубами, наличие крыши у стадиона, цена, но они были отброшены в процессе изучения статей [3, 5]. Остались следующие параметры:

X1 – День недели. Этот параметр кодируется следующим образом: 1 – понедельник, 2 – вторник и так далее.

X2 – Вместимость стадиона, в котором проходит матч, человек.

X3 – Население города, в котором проходит матч, человек.

X4 – Рейтинг домашней команды, от 1 до 20.

X5 – Рейтинг гостевой команды, от 1 до 20.

X6 – Этап АПЛ (тур). Принимает значения от 1 до 38.

X7 – Время начала матча, в часах. Например, 19:00 – 19, 13:30 – 13.

X8 – Погода в день матча. Кодируется следующим образом: 1 – ясно, 2 – небольшая облачность, 3 – переменная облачность, 4 – в основном облачно, 5 – облачно, 6 – частично ясно и кратковременные осадки, 7 – переменная облачность и кратковременный дождь, 8 – частично ясно и небольшой дождь, 9 – переменная облачность, возможны грозы с дождем, 10 – облачно и небольшой дождь, 11 – облачно и небольшой снег, 12 – облачно и кратковременные осадки, 13 – облачно и дождь.

X9 – Температура в день проведения матча, °F.

X10 – Количество команд из большой шестёрки (Арсенал, Челси, Тоттенхэм Хотспур, Ливерпуль, Манчестер Сити, Манчестер Юнайтед).

D1 – Доля посещаемости (посещаемость / вместимость стадиона). Доля посещаемости может быть больше 1, т.к. в вместимости стадиона указывается количество сидящих мест, а в большем количестве матчей делают фанатские зоны со стоящими местами.

Проектирование, обучение, тестирование нейронной сети выполнялись с помощью программы «Нейросимулятор 5» [9] по методике [10]. В результате оптимизации спроектированная нейронная сеть представляет собой персептрон, который имеет десять входных нейронов, один выходной и два скрытых слоя, первый имеет пять нейронов, второй три (рисунок 1).

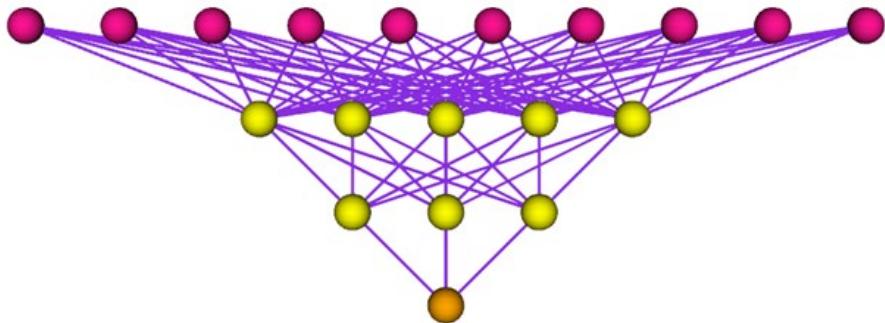


Рисунок 1. Итоговая нейронная сеть

Для оценки корректной работы спроектированной нейронной сети использовалось тестирующее множество, состоящее из 31 примера, а также подтверждающее множество, состоящее из 17 примеров. Средняя ошибка тестирования составила 6,7%, что можно считать приемлемым результатом. На рисунке 2 представлена гистограмма, демонстрирующая разницу между фактической и прогнозируемой нейросетью посещаемостью из подтверждающего множества.

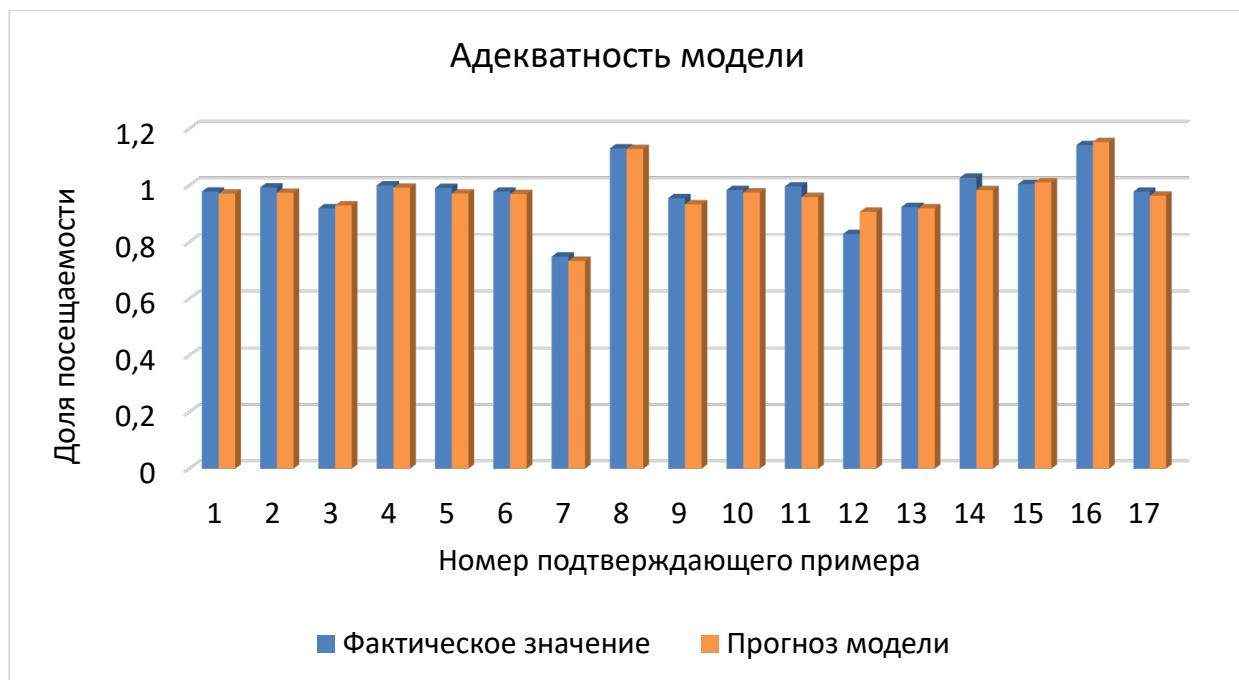


Рисунок 2. Результат тестирования нейронной сети

Из результатов, изображенных на рисунке 2, можно сделать вывод об адекватной работе спроектированной нейронной сети.

Оценка значимости входных параметров была выполнена с помощью программы «Нейросимулятор 5», результат отображен на рисунке 4.

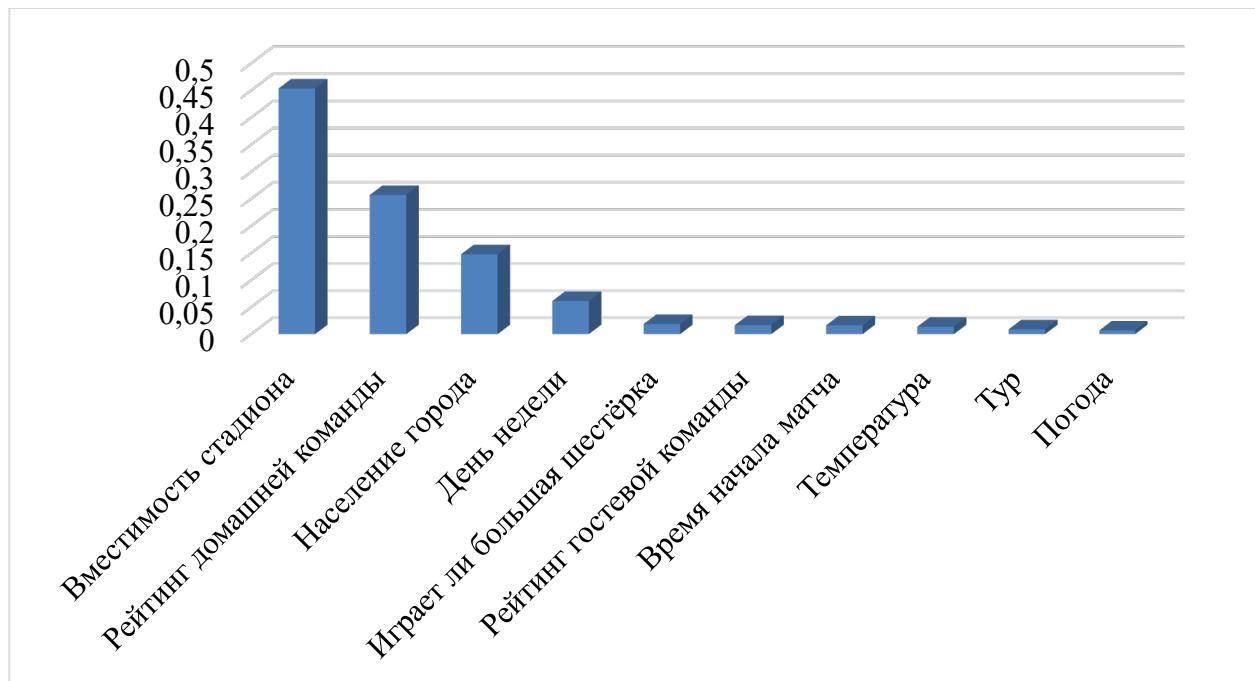


Рисунок 3. Значимость входных параметров нейросетевой модели

Как видно из рисунка 3, наиболее значимыми являются вместимость стадиона, рейтинг домашней команды, население города, день недели, играет ли большая шестёрка и т.д. Также на графике можно видеть ряд параметров, которые имеют нулевую значимость, такие как тур и погода. Это можно объяснить тем, что на текущем собранном множестве для Нижнего Новгорода, данные параметры имеют одинаковое значение.

Далее было проведено исследование матчей АПЛ. Исследование производилось с помощью метода «замораживания» [8], суть которого заключается в замораживании значения одного параметра и фиксировании значений всех других параметров. Данный метод позволяет выявить влияние исследуемого параметра на выходной. Для этой цели были отобраны 4 матча, информация о параметрах, которых отражена в таблице 1.

Таблица 1
Характеристики матчей,
выбранных для исследования

№ матча	1	2	3	4
X1	6	7	6	7
X2	10700	19920	47726	26309
X3	183491	96800	552558	8908081
X4	14	11	1	12
X5	16	12	4	5
X6	9	3	35	10
X7	14	12	11	13
X8	1	13	2	2
X9	61	55	68	48
X10	0	0	2	1

На рисунке 4 показан график зависимости посещаемости стадиона от вместимости стадиона. Как следует из графика увеличение вместимости

приводит к уменьшению доли посещаемости, так как сложнее заполнить более вместимый стадион.

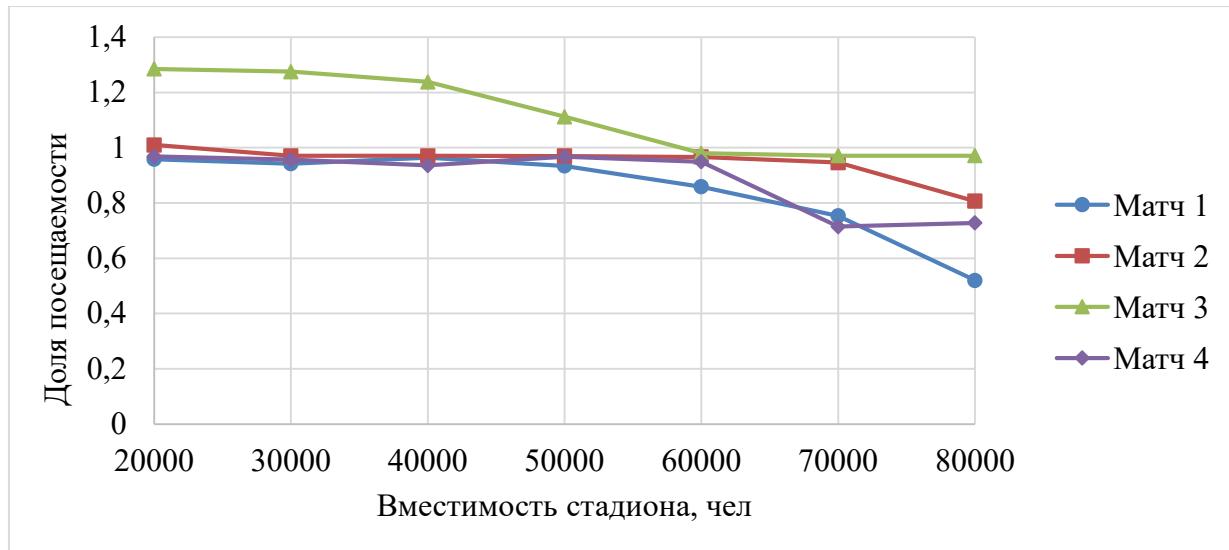


Рисунок 4. Зависимость посещаемости от вместимости стадиона

На рисунках 5-6 продемонстрирована зависимость посещаемости от рейтинга команд. В обоих случаях прослеживается тенденция уменьшения посещаемости, от уменьшения рейтинга команды. Это вполне логично, ведь большинство посетителей являются туристами или фанатами команд из верхней части таблицы, которых в разы больше в сравнении с фанатами команд из нижней части таблицы, причем влияние рейтинга домашней команды более выраженное. Так же есть склонность к увеличению посещаемости у команд, с небольшим рейтингом. Это можно объяснить тем, что большинство команд, которые имеют маленький рейтинг обладают низким бюджетом, в следствии чего имеют стадионы с небольшой вместимостью, которые легко заполняются вне зависимости от команд, участвующих в матче.

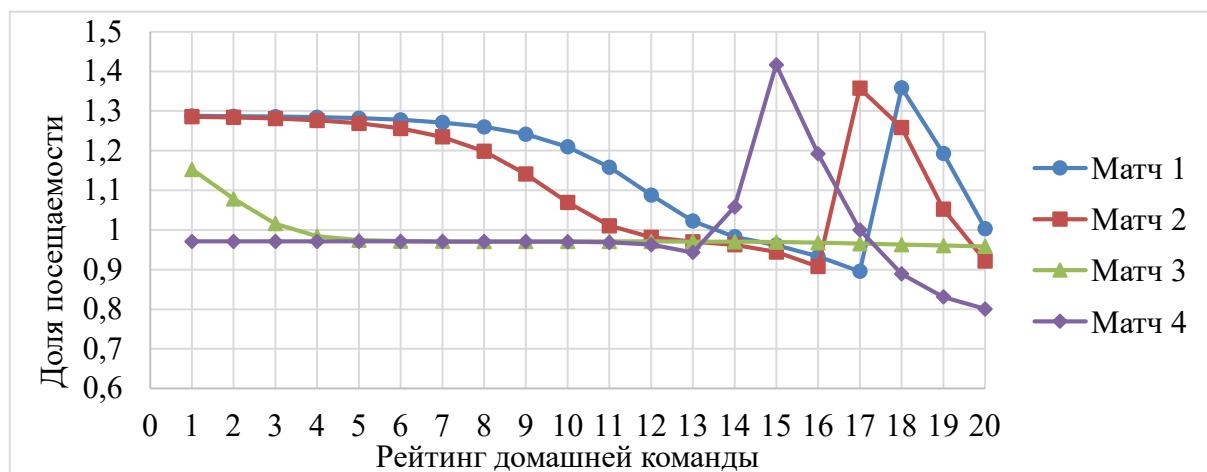


Рисунок 5. Зависимость посещаемости от рейтинга домашней команды

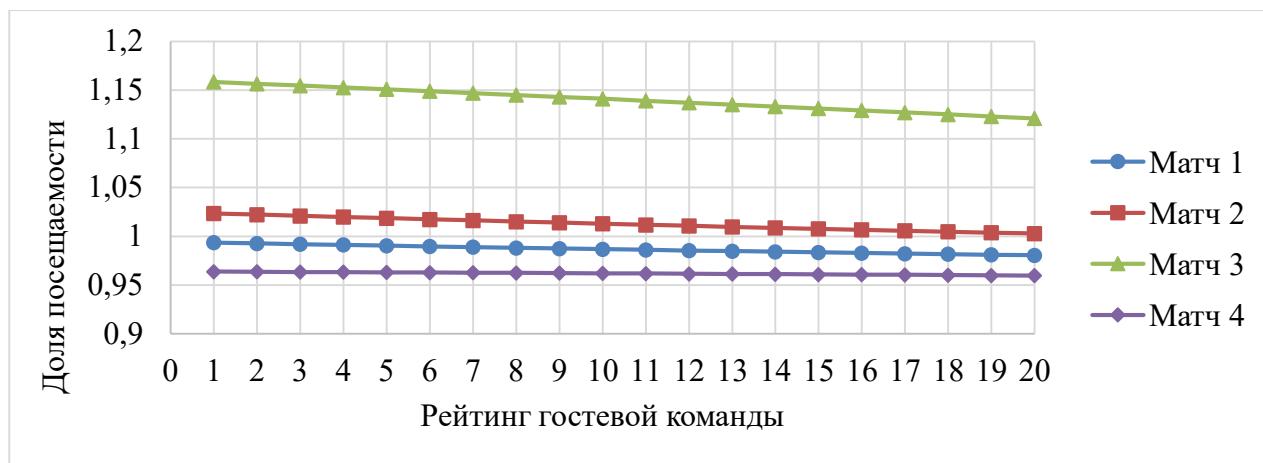


Рисунок 6. Зависимость посещаемости от рейтинга гостевой команды

На рисунке 8 показана продемонстрирована зависимость посещаемости от большой шестерки. Изменение количества команд большой шестерки влияет на посещаемость матча в целом, каждый раз перед матчем накаляет отношения между фанатами. В матче могут быть 0, 1 или 2 команды большой шестёрки. Как видим из графика увеличение команд большой шестёрки приводит к увеличению посещаемости матча. Результаты были предсказуемы, только мы считали, что от участия команд большой шестерки посещаемость будет меняться больше, большинство туристов стараются посещать эти матчи из-за постоянного соперничества данных команд за места в лига чемпионской зоне.

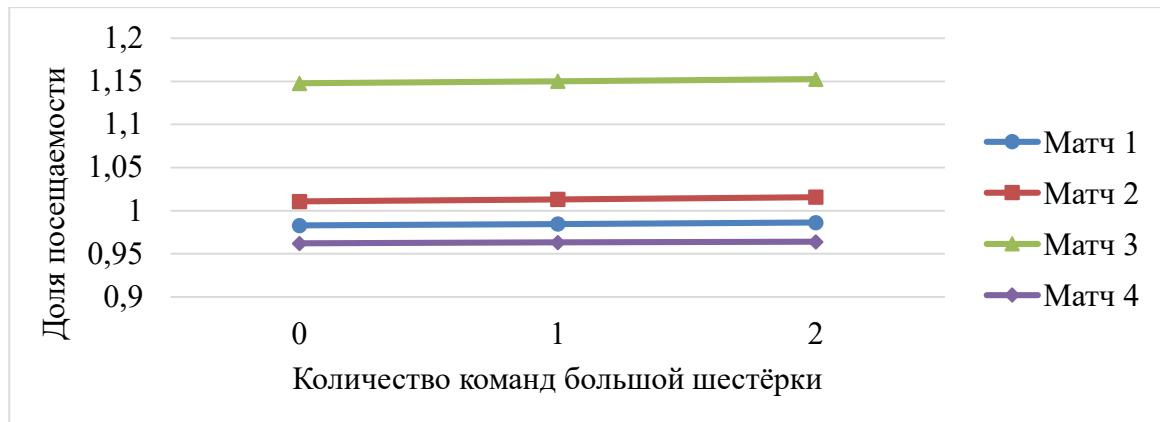


Рисунок 8. Зависимость посещаемости от количества команд «большой шестёрки»

Если посмотреть на значимость, то можно увидеть, что тур не сильно влияет на посещаемость матча, что частично отличается от наших предположений. Например, мы считали, что в 1 и 38 туре посещаемость будет выше по сравнению с остальными турами из-за того, что до первого тура матчей АПЛ не было 2 месяца, а 38 тур – это последний тур, где обычно решается, кто станет победителем, и кто займет места в лига чемпионской зоне, кто покинет турнир.

Проанализировав значимость можно сказать, что посещаемость не зависит от погоды. Это происходит потому, что матчи АПЛ посещают фанаты или заинтересованные в этом матче люди, и они придут в любую погоду.

Полученные результаты исследований не противоречат реальности, что подтверждает, что спроектированную нейронную сеть можно считать пригодной для прогнозирования посещаемости матчей АПЛ.

Заключение. Построена система нейросетевого оценивания посещаемости матчей АПЛ. Проведены исследования матчей АПЛ. Методом сценарного прогнозирования построены графики зависимостей вместимости стадиона, населения города, рейтинга домашней и гостевой команды и т.д. В качестве итога можно сказать, что идеальный по посещаемости будет матч в субботу между 1 и 2 командой чемпионата, где оба из них являются командами из большой шестерки.

Библиографический список

1. Гришин Н.А. Прогнозирование занятого места футбольной команды в лиге чемпионов // Интеллектуальные системы в науке и технике. Искусственный интеллект в решении актуальных социальных и экономических проблем XXI века. 2020. С. 600-607.
2. Почему финал футбольного сезона – самый непредсказуемый период? // BetSportsLive. 2019. URL: <https://betsportslive.ru/articles/pochemu-final-futbolnogo-sezona-samyj-nepredskazuemyj-period/>
3. Шестаков Е. С. Возможность прогнозирования количества голов, забитых командой Челси в одном матче // Интеллектуальные системы в науке и технике. Искусственный интеллект в решении актуальных социальных и экономических проблем XXI века, 2019 №2. С. 60-66.
4. Ясницкий Л.Н., Абрамова Ю.С., Бабушкина С.Д. Возможности получения рекомендаций по улучшению результативности сборных команд, готовящихся к участию в чемпионате Европы по футболу Евро-2016 методом нейросетевого моделирования // Вестник спортивной науки. 2015. № 5. С. 15-20.
5. Ясницкий Л.Н., Vnukova O.V. Прогноз результатов олимпиады-2014 в мужском одиночном фигурном катании методами искусственного интеллекта // Современные проблемы науки и образования. 2014. № 1. С. 189.
6. Ясницкий Л.Н., Киросова А.В., Ратегова А.В., Черепанов Ф.М. Методика нейросетевого прогнозирования результатов спортивных состязаний на примере чемпионата мира-2015 по легкой атлетике // Вестник Пермского университета. Серия: Математика. Механика. Информатика. 2014. № 3 (26). С. 90-97.
7. Ясницкий Л.Н., Павлов И.В., Черепанов Ф.М. Прогнозирование результатов олимпийских игр 2014 года в неофициальном командном зачете методами искусственного интеллекта // Современные проблемы науки и образования. 2013. № 6. С. 985.
8. Ясницкий Л.Н., Кировска А.В., Ратегова А.В., Черепанов Ф.М. Прогноз результатов чемпионата мира-2015 по легкой атлетике методами

- искусственного интеллекта // Современные проблемы науки и образования. 2014. № 4. С. 624.
9. Ясницкий Л.Н. Черепанов Ф.М., Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 15.01.2014.
10. Ясницкий Л.Н. Введение в искусственный интеллект // М.: Издательский центр «Академия», 2005. – 176 с.

DYNAMIC NEURAL NETWORK SYSTEM FOR EVALUATING THE ATTENDANCE OF ENGLISH PREMIER LEAGUE FOOTBALL MATCHES

Paskar Aleksey V., Akbulakov Vadim F.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990

The article describes the development of a dynamic neural network system for predicting the attendance of English Premier League football matches. The system allows people to forecast the attendance of football matches using the information that is available before the match starts.

Keywords: artificial intelligence, model, neural network technologies, forecasting, patterns, sport, football, attendance.

УДК 004.032.26, 796.332

НЕЙРОСЕТЕВАЯ МОДЕЛЬ ПРОГНОЗИРОВАНИЯ ЗАНЯТОГО МЕСТА ФУТБОЛИСТА В ГОЛОСОВАНИИ ЗА «ЗОЛОТОЙ МЯЧ»

Старцев Илья Дмитриевич

Пермский государственный национальный исследовательский университет,
ПМИ 614990, Россия, г. Пермь, ул. Букирева, 15,
s.ilja2009@yandex.ru, silja3964@gmail.com

В статье представлена методика разработки нейросетевой модели прогнозирования занятого места в голосовании за «Золотой мяч». В ходе работы была спроектирована и обучена с помощью существующей статистики результатов футболистов за сезон нейронная сеть, были проанализированы параметры, влияющие на место в голосовании, определена их значимость. С помощью полученной компьютерной программы возможно формирование полезных рекомендаций для футболиста.

Ключевые слова: прогнозирование, голосование, золотой мяч, футбол, искусственный интеллект, спорт.

Методы искусственного интеллекта применяются в различных сферах человеческой деятельности. Одним из перспективных направлений является прогнозирование результатов в спорте. Изучение данной области позволит спортсменам выстраивать свою карьеру, зная в чем нужно добавить. Данная область хороша тем, что по спортивным событиям ведется достаточно подробная статистика по каждому виду спорта результатов игроков и команд. Однако в этих результатах слишком много факторов и установить взаимосвязь достаточно непросто. Именно в данном аспекте находят свое применение нейросети.

В настоящее время уже существует множество работ, посвященных прогнозированию результатов в различных видах спорта. Например, прогнозирование результата «Чемпионата Европы» по футболу, состязаний по бегу, соревнований по спортивной ходьбе, результата хоккейных матчей, соревнований по плаванию [1-9].

Однако в научных журналах практически отсутствуют статьи, посвященные прогнозированию в голосовании за «Золотой мяч». Именно поэтому эта тема была выбрана для исследования. В качестве предметной области была выбрана следующая: прогнозирование занятого места в голосовании за «Золотой мяч». Результаты, полученные в ходе работы, могут быть интересны в основном футболистам, а также букмекерам.

Для построения нейросетевой модели было составлено множество примеров за последние три года, полученное из открытых источников данных [10, 11].

В качестве входных параметров были выбраны следующие:

X1 – Позиция игрока

X2 – Количество забитых голов

X3 – Количество голевых передач

X4 – Процент успешности передач за матч

X5 – Количество отборов мяча в среднем за матч

X6 – Количество званий лучшего игрока матча

X7 – Средний рейтинг за матч

X8 – Победил ли в «Лиге Чемпионов»

X9 – Победил ли в «Лиге Европы»

X10 – Победил ли в Чемпионате своей страны

X11 – Победил ли на «Чемпионате Мира» или «Чемпионате Европы»

Для параметра «X1» есть выбор из 4 позиций, а именно: 1 – нападающий, 2 – полузащитник, 3 – защитник, 4 – вратарь. Значения параметров «X4», «X5», «X7» берутся в среднем за сезон. Все данные берутся за один сезон.

Выходным параметром Y является место игрока в голосовании за «Золотой мяч».

Множество примеров, состоящее из 100 записей, было поделено на обучающее, предназначенное для обучения нейронной сети, и тестовое, предназначенное для проверки нейронной сети, множества. В тестовое множество вошло 15% от общего числа примеров, т. е. 15 записей. Количество

примеров обучающегося множества удовлетворяет требованию репрезентативности: оно немного больше, чем $7N_x + 15$, где N_x – число входных параметров.

На следующем этапе была спроектирована, оптимизирована, обучена нейронная сеть. Проектирование нейронной сети выполнялось с помощью Нейросимулятора Nsim [11]. Структура нейронной сети представляет собой персептрон, имеющий одиннадцать входных нейронов, один скрытый слой с двумя нейронами и один выходной нейрон, соответствующий прогнозируемому значению – месту игрока в голосовании за «Золотой мяч». Количество нейронов на скрытом слое было определено с помощью формулы, являющейся следствием теоремы Арнольда – Колмогорова – Хект-Нильсена:

$$\frac{N_y Q}{1 + \log(Q)} \leq N_w \leq N_y \left(\frac{Q}{N_x} + 1 \right) (N_x + N_y + 1) + N_y,$$

где N_y – размерность выходного сигнала; Q – число элементов обучающей выборки; N_w – необходимое число синаптических весов; N_x – размерность входного сигнала. Оценив с помощью этой формулы необходимое число синаптических весов, можно рассчитать число нейронов в скрытых слоях. Например, число нейронов скрытого слоя двухслойного персептрона будет равно

$$N = \frac{N_w}{N_x + N_y}.$$

Для проектируемой нейронной сети необходимое число синаптических весов лежит в диапазоне $29 \leq N_w \leq 114$, а число нейронов на скрытом слое – в диапазоне $2 \leq N \leq 10$.

В качестве активационных функций нейронов скрытого слоя и выходного слоя использовался тангенс гиперболический, а в качестве алгоритма обучения – алгоритм Левенберга-Марквардта с равномерной инициализацией весов от -1,5 до 1.

Так как футбол стремительно развивается, результаты прошлых лет быстро устаревают, поэтому было принято решение оценивать последние три сезона. В результате получилась нейронная сеть, в процессе тестирования получили отклонение 8,45%. В результате тестирования были получены результаты, представленные на рис. 1, которые показали, что нейронная сеть не может предсказать результат с высокой точностью, отклонение от действительного значения составляет чуть более 2 мест.

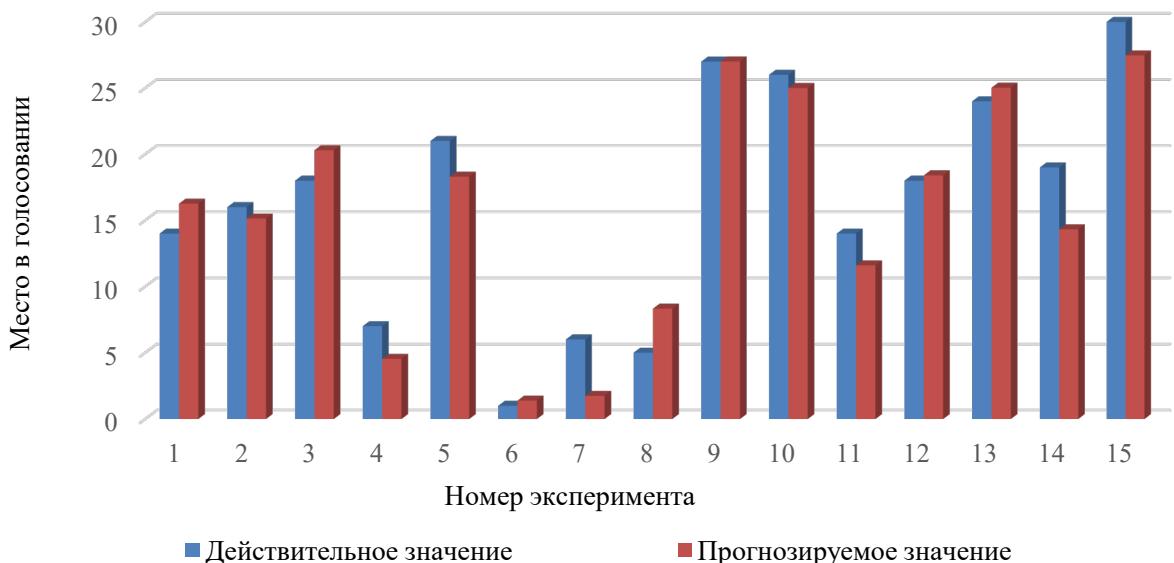


Рисунок 1. Результаты тестирования

Таким образом, нейронная сеть была проверена на тестовых примерах и была доказана адекватность нейросетевой математической модели. После этого мы можем приступать к ее исследованию и прогнозированию.

Для начала выясним какие параметры модели оказывают наибольшее влияние на результат моделирования – место в голосовании за «Золотой мяч». Такими параметрами для прогнозирования оказались: количество забитых голов, что вполне логично, ведь голы играют важнейшую роль для победы в матче. Также победа в «Лиге Чемпионов», «Чемпионате Мира» или «Чемпионате Европы» сильно влияют на место в голосовании, так как это самые престижные футбольные турниры, и победить в них достаточно непросто.

Значимость параметров представлена на рис. 2.

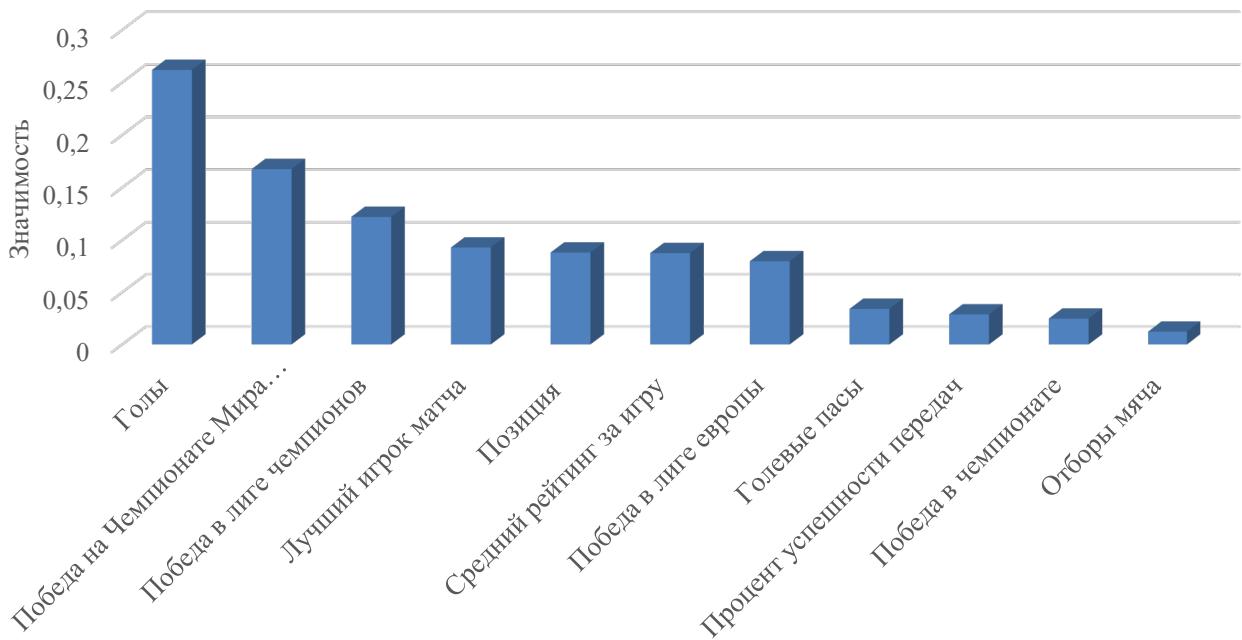


Рисунок 2. Значимость параметров

Далее выясним степень влияния входных параметров модели на результат моделирования. Для этого был проведен эксперимент: изменены значения семи параметров (Количество забитых голов, Победил ли на «Чемпионате Мира» или «Чемпионате Европы», Победил ли в «Лиге чемпионов», Количество званий лучшего игрока матча, Средний рейтинг за матч, Победил ли в «Лиге Европы») одного футболиста и спрогнозировано место в голосовании за «Золотой мяч». В качестве базового футболиста был взят игрок со следующими параметрами: футболист является нападающим, забил 20 голов, отдал 9 голевых передач, процент успешности передач – 78.4, совершил в среднем 1 отбор за матч, 5 раз стал лучшим игроком матча, средний рейтинг за игру – 7.4, не победил ни в «Лиге Чемпионов», ни в «Лиге Европы», ни в Чемпионате своей страны, ни на «Чемпионате Мира» или «Чемпионате Европы».

Изменяя количество голов футболиста, и производя вычисления с помощью нейросети, можно проследить, как будет меняться место в голосовании с изменением этого параметра. Анализируя полученную таким образом кривую, изображенную на рис. 3, можно сделать вывод, что футболисту нужно забивать как можно больше голов, чтобы занять первое место.

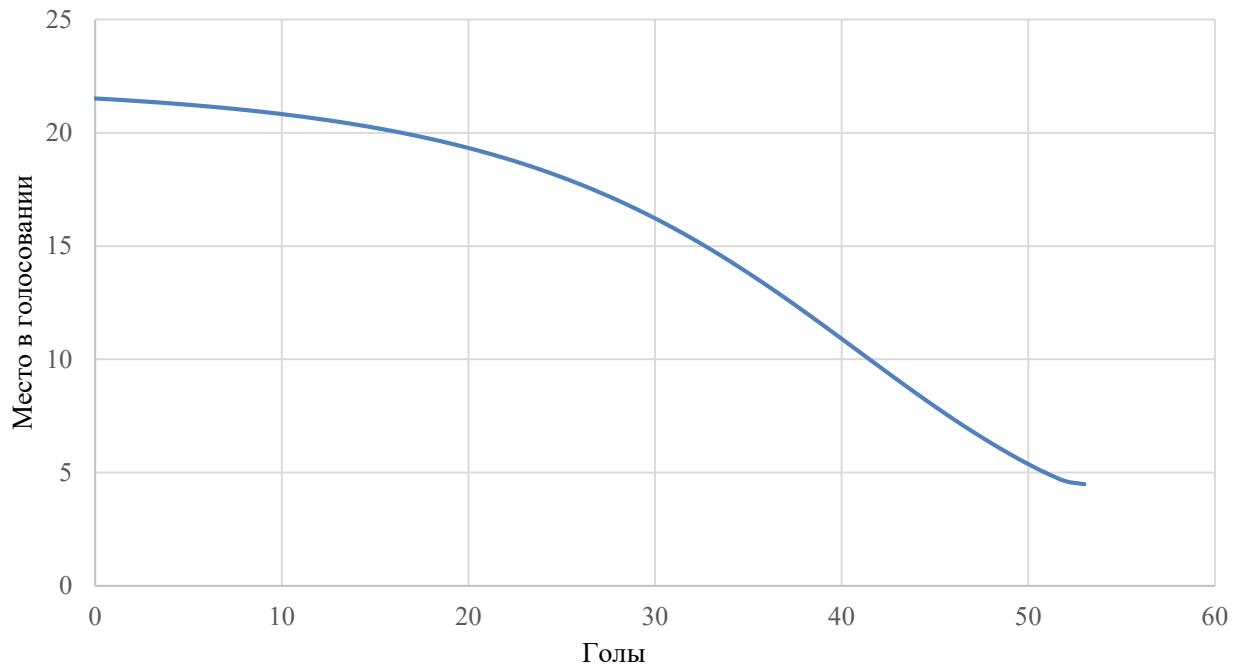


Рисунок 3. Исследование влияния параметра «Количество забитых голов»

Аналогично изменению количества голов, попробуем изменить количество наград лучшего игрока матча. Анализируя полученную таким образом кривую, изображенную на рис. 4, можно заключить, что чем больше званий игрока матча, тем ниже место в голосовании.

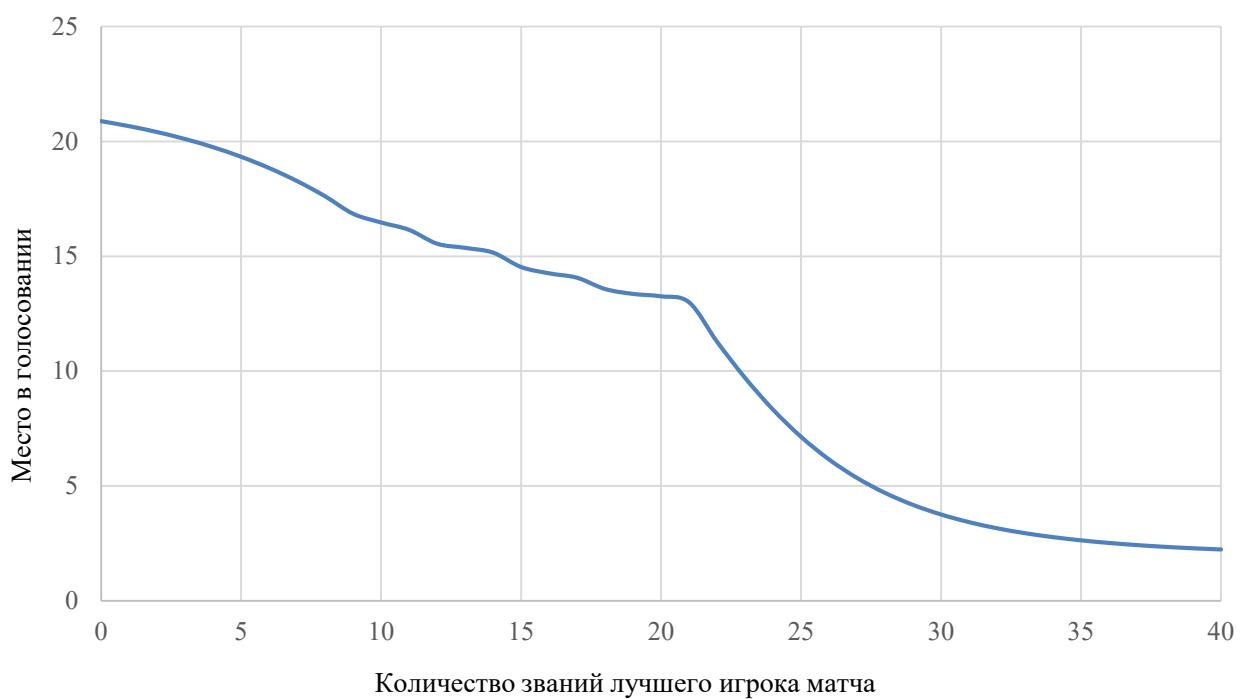


Рисунок 4. Исследование влияния параметра «Количество званий лучшего игрока матча»

Глядя на кривую, можно сделать вывод, что футболисту необходимо получать рейтинг за игру как можно выше, чтобы победить в голосовании.

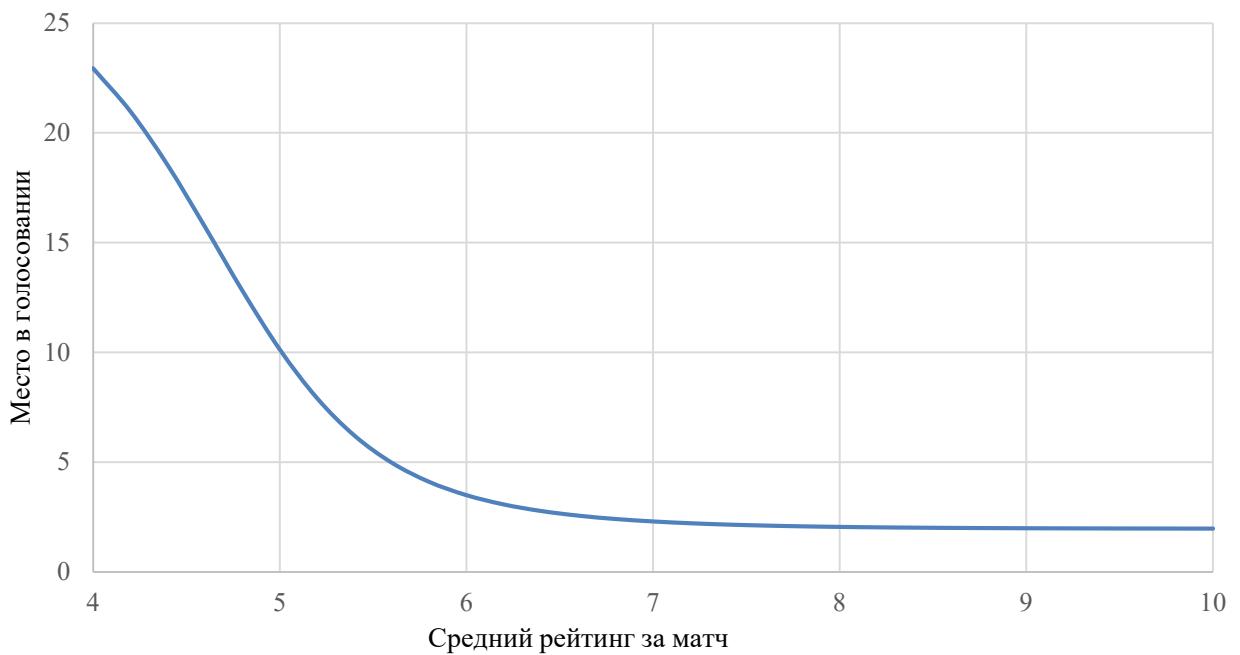


Рисунок 5. Исследование влияния параметра «Средний рейтинг за матч»

Затем предположим, что футболист выиграл Чемпионат Мира или Чемпионат Европы. Исследование показало, что и это бы привело к тому, что место в голосовании стало бы стремиться к 1. Это можно увидеть на рис. 6.

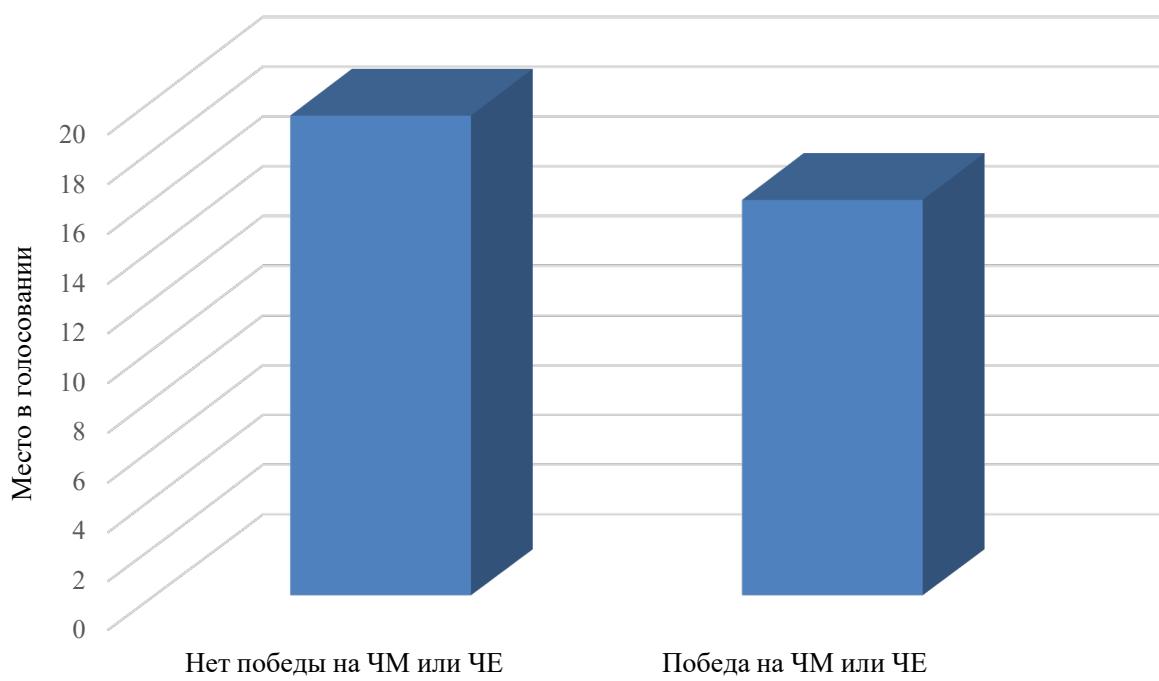


Рисунок 6. Исследование влияния параметра «Победил ли на «Чемпионате Мира» или «Чемпионате Европы»»

Аналогично предположим, что футболист выиграл Лигу Чемпионов. Результат изображен на рис. 7.

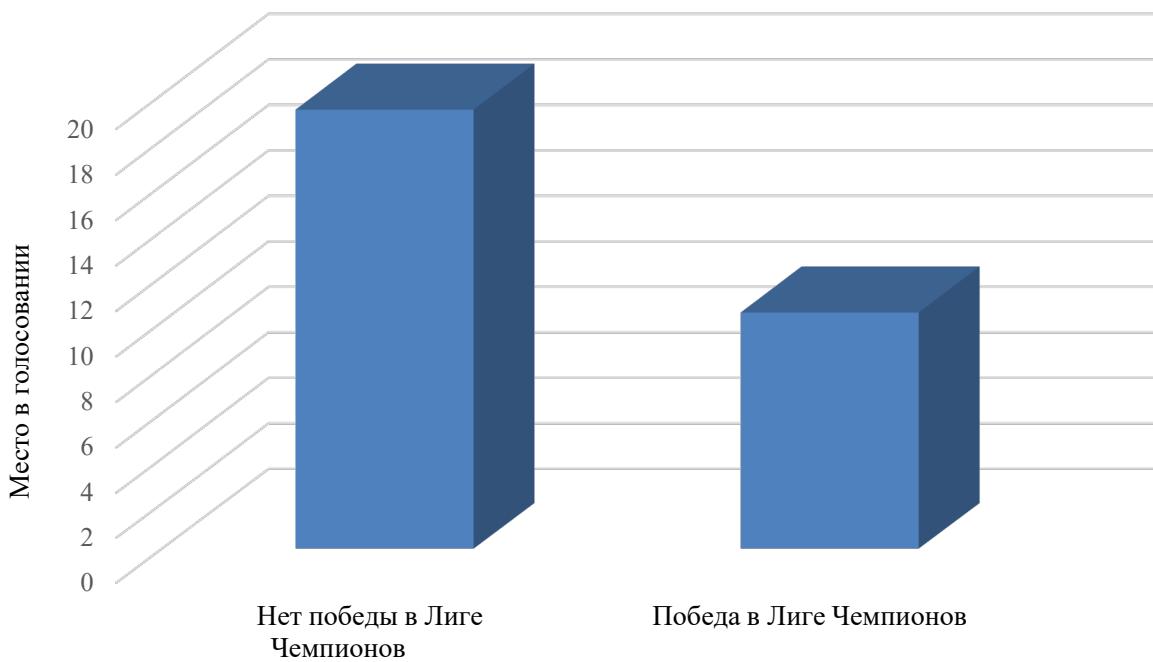


Рисунок 7. Исследование влияния параметра «Победил ли в «Лиге Чемпионов»»

Таким образом, в данной работе была предложена методика прогнозирования места игрока в голосовании за «Золотой мяч». Была получена и исследована нейросетевая математическая модель, соответствующая предметной области. Исследовано влияние на место в

голосовании некоторых параметров спортсменов и сделана попытка разработки рекомендаций по улучшению их спортивных результатов.

Библиографический список

1. Ясницкий Л.Н., Абрамова Ю.С., Бабушкина С.Д. Возможности получения рекомендаций по улучшению результативности сборных команд, готовящихся к участию в чемпионате Европы по футболу Евро-2016 методом нейросетевого моделирования // Вестник спортивной науки. 2015. № 5. С. 15-20.
2. Przednowek K, Iskra J, Maszczyk A, Nawrocka M. Regression shrinkage and neural models in predicting the results of 400-metres hurdles races. Biol Sport, no. 33(4), pp. 415–421, 2016.
3. K. Przednowek and K. Wiktorowicz. Prediction of the result in race walking using regularized regression models. Journal of Theoretical and Applied Computer Science, vol. 7, no. 2, pp. 45-58, 2013.
4. Крутиков А.К. Прогнозирование результата хоккейного матча с использованием специализированного программного модуля на основе искусственной нейронной сети // Научное обозрение. Технические науки. No 2. 2019. С. 19-22.
5. A. Maszczyk, R. Rocznik, Z. Waśkiewicz et al., “Application of regression and neural models to predict competitive swimming performance,” Perceptual and Motor Skills, vol. 114, no. 2, pp. 610–626, 2012.
6. Ясницкий Л.Н., Vnukova O.V. Прогноз результатов олимпиады-2014 в мужском одиночном фигурном катании методами искусственного интеллекта // Современные проблемы науки и образования. 2014. № 1. С. 189.
7. Ясницкий Л.Н., Кирсовая А.В., Ратегова А.В., Черепанов Ф.М. Методика нейросетевого прогнозирования результатов спортивных соревнований на примере чемпионата мира-2015 по легкой атлетике // Вестник Пермского университета. Серия: Математика. Механика. Информатика. 2014. № 3 (26). С. 90-97.
8. Ясницкий Л.Н., Павлов И.В., Черепанов Ф.М. Прогнозирование результатов олимпийских игр 2014 года в неофициальном командном зачете методами искусственного интеллекта // Современные проблемы науки и образования. 2013. № 6. С. 985.
9. Ясницкий Л.Н., Кирсовая А.В., Ратегова А.В., Черепанов Ф.М. Прогноз результатов чемпионата мира-2015 по легкой атлетике методами искусственного интеллекта // Современные проблемы науки и образования. 2014. № 4. С. 624.
10. Wikipedia URL:
[https://ru.wikipedia.org/wiki/Золотой_мяч_\(France_Football\)](https://ru.wikipedia.org/wiki/Золотой_мяч_(France_Football))
11. Whoscored URL: <https://ru.whoscored.com>
12. Черепанов Ф.М., Ясницкий Л.Н. Нейросимулятор 4.0. Свидетельство о регистрации программы для ЭВМ RUS 2014612546. Заявка № 2014610341 от 5.01.2014.

NEURAL NETWORK MODEL OF FORECASTING THE FOOTBALL PLAYER'S POSITION IN THE BALLON D'OR VOTE

Startsev Ilya D.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990,

s.ilja2009@yandex.ru

The article presents a methodology for developing a neural network model for predicting the occupied place in voting for the "Golden Ball". In the course of the work, a neural network was designed and trained using the existing statistics of the results of football players for the season, the parameters affecting the place in the voting were analyzed, and their significance was determined. Using the obtained computer program, it is possible to form useful recommendations for a football player.

Keywords: forecasting, voting, golden ball, football, artificial intelligence, sports.

ИНСТРУМЕНТЫ ИСКУССТВЕННОГО ИНТЕЛЕКТА

МЕТОДЫ И ИНСТРУМЕНТЫ СОЗДАНИЯ ИНТЕЛЛЕКТУАЛЬНЫХ СИСТЕМ УПРАВЛЕНИЯ

*Хижняков Юрий Николаевич, Сторожев Сергей Александрович,
Загвоздкин Владимир Дмитриевич, Никулин Вячеслав Сергеевич*

Пермский национальный исследовательский политехнический университет,
614000, Россия, г. Пермь, ул. Комсомольский проспект, 29
h1941@yandex.ru

В статье представлены основные методы и инструментарий построения интеллектуальных систем.

Ключевые слова: искусственный интеллект, нейросетевые технологии, математическое моделирование, RBF-сети, нечеткое управление.

Введение. Основные направления развития искусственного интеллекта (ИС) основаны на разработке баз знаний, образующих ядро экспертических систем, нейросетевых и нейрокомпьютерных технологиях, распознавания образов, компьютерной лингвистики, интеллектуального математического моделирования и т.д.

Способность человека чувствовать, думать, обучаться и помнить осуществляется биологическими нейронами головного мозга. Биологический нейрон – электрически возбудимая клетка предназначена для приема, обработки, хранения, передачи и вывода вовне информации с помощью электрических и химических сигналов. Интеллектуальная нервная клетка (бионический нейрон В.Б.Вальцева, 1996 г.) включает в себя входы запрета, торможения, возбуждения, памяти и аксоновый холмик, который при превышении потенциала тела клетки некоторого порогового значения генерирует на выходе нервной клетки импульсы с переменной частотой.

Биологический нейрон мозга, число которых 10^{11} , состоит из клеточного тела с ядром в миелиновой оболочке, единственного аксона разной длины, дендритов с синапсами. Биологические нейроны имеют следующие разновидности: безаксоновые, сгруппированные вблизи спинного мозга, униполярные и биполярные с одним и двумя дендритами, мультиполярные с несколькими дендритами, которые преобладают в центральной нервной системе.

Микроструктурной функциональной единицей мозга является нейронный модуль, состоящий из популяции нервных клеток (большой пирамидальный нейрон (БПН)), имеющий один эффекторный выход. БПН имеет наибольшую разветвленность дендритов, ответственных за восприятие информации от всех слоев коры головного мозга. Эволюция мозга сопровождается ростом числа БПН.

Первая (формальная) модель нервной клетки, разработанная в 1943 г. Уорреном Мак – Каллоком и Вальтером Питтсом, состоит из сумматора входных сигналов, выход которого является аргументом пороговой функции [1].

Искусственные интеллектуальные нейроны, построенные на базе формальной модели нейрона, отличаются друг от друга активационными функциями: логистические, функция Гаусса, линейная, пороговая и т.д. Основным недостатком данных нейронов является отсутствие переменных задержек во времени.

Основные методы создания интеллектуальных систем управления недетерминированными объектами (лингвистических, стохастических) и процессами с фреймовым описанием базируются на интеллектуальных искусственных нейронах, на элементах нечеткой логики и их комбинациях.

История развития искусственных интеллектуальных систем связана с учеными: Н. Винер, Д. Хэбб, Ф. Розенблат, А.П. Петров, Т. Кохонен, Б.В. Хакимов, А.И. Галушкин, Фуксима, Д. Хопфилд, Л. Заде, Хемминг, Гроссберг и т.д.

На базе логистических нейронов построены статические нейронные сети прямого распространения сигнала (персептрон) (без обратной связи), встречного распространения сигнала (алгоритм Кохонена, ядро Гроссбера), динамические нейронные сети (с обратной связью) (сеть Хемминга, сеть Хопфилда) и гибридные сети. Данные архитектуры нейронных сетей базируются на теореме существования, а также первой и второй конструктивных теоремах.

Проблемой формирования искусственной нейронной сети является субъективизм при выборе архитектуры. Число выборок для обучения сети с учителем и без него определяется быстродействием обучения и характером решаемой задачи [1, 2].

Отбор данных проводится согласно будущему не похоже на прошлое. Обычно в качестве обучающих данных берут исторические данные. Если обстоятельства изменились, то закономерности, имевшие в прошлом, могут больше не действовать; ИНС может обучаться только на тех данных, которыми она располагает.

Для обучения персептрана с помощью пакета MATLAB необходимо задать конфигурацию сети, задать матрицу с конкретным набором коэффициентов, подготовить необходимое число выборок для обучения, тестирования и валидации, проинициализировать элементы весовой матрицы вещественными числами в интервале $-1, 0, +1$, задать коэффициент скорости обучения (шаг итерации). Далее вычислить разность между идеальными и полученными значениями выхода в процессе обучения и по ним рассчитать критерий Х. Тейла (корень квадратный из среднеквадратического отклонения) либо критерий согласия Паркинсона (хи-квадрат).

Существует несколько способов выбора скорости обучения: начинать с большим шагом с последующим уменьшением во время коррекции; начинать с малым шагом для определения знака весовых коэффициентов с

последующим увеличением, а затем вновь уменьшать на завершающей стадии обучения.

Для обучения *RBF*-сети на радиально-базисных нейронах с помощью пакета MATLAB необходимо задать число нейронов единственного внутреннего слоя и соответственно число выборок в пределах десяти. Составить матрицу Грина. Обучение выполнить по алгоритму с учителем (без итераций). Вычисление коэффициентов выходного слоя выполнить по методу наименьших квадратов с запоминанием коэффициентов после каждой эпохи [3].

Для локальной сети, где всего два логистических нейрона и обучение не требуется, с помощью алгоритма Д. Хэбба (1949 г.) можно выполнить управление недетерминированного объекта [3].

Все алгоритмы обучения делятся: детерминистские и стохастические. При детерминистском обучении подстройка весов есть жесткая последовательность действий, а стохастическом обучении подстройка весов производится на основе действий, подчиняющихся не которому случайному процессу (закону распределения). Введение в нейрон одного дополнительного входа смещает взвешенную сумму нейрона. Работа ИНС сводится к классификации (обобщению) входных сигналов, принадлежащих к n -мерному гиперпространству, по некоторому числу классов. С математической точки зрения это происходит путем разбиения гиперпространства гиперплоскостями или гиперсферами. Дональд Хебб высказал постулат, что обучение в первую очередь связано в изменениях силы синаптических связей. При проектировании ИНС необходимо выбирать такие переменные, которые влияют на результат. Чем больше выбранных переменных, тем больше нужно имеет выборок. Необученная сеть не является адаптивной.

Обучение сети с учителем возможно, когда имеются ответы на исходные данные и без учителя, когда ответов нет и необходимо лишь сделать соответствующие выводы (обобщение, кластеризация). Существуют следующие методы обучения ИНС с учителем: метод обратного распространения ошибки (ОРО); метод Левенберга-Марквардта; генетические алгоритмы и т.д. [3].

В методе ОРО вычисляется вектор градиента поверхности ошибок. Он указывает направление кратчайшего спуска по поверхности из данной точки. Важным здесь является скорость обучения или выбор шага, который определяется опытным путем. Здесь возможно недообучение и переобучение. Для проверки переобучения включают механизм контрольной кросс-проверки. Если переобучение обнаружено, то нужно уменьшить число скрытых элементов (слоев, нейронов в слое), так как сеть является слишком мощной для решения данной задачи. Если ИНС оказалась небогатой, то переобучение не произойдет, так как обе ошибки: обучения и проверки – не достигнут достаточного числа малости.

Метод Левенберга-Марквардта реализуется самым быстрым алгоритмом, так как работает с производной функции ошибок. Он применим только для сетей с одним выходом. Для больших ИНС он не применим.

В генетическом алгоритме используется эволюционный подход, и он является универсальным, так как допускает оптимизировать ИНС с любыми конфигурациями нейронов.

Подводя итог по нейронному управлению, следует считать наиболее перспективными *RBF*-сети по отношению к персепtronам, даже если там применять обучение согласно алгоритму Левенберга-Марквардта.

Как альтернатива нейронному управлению рассмотрим нечеткое управление [4].

История развития нечеткого управления связана с учеными: Н. Л. Заде, И. Мамдани, Лукашевич, Ларсен, Цукамото, Сугено, Такаги. А. Пегат и т.д.

Основателем нечеткого управления является Лотфи Заде (1965 г., который расширил понятия четкой логики (Аристотель) до нечеткой логики).

Область нечеткого управления перекрывает области четкого и нейронного управлений. Особенностью нечеткого управления является: логическое управление, связанное с условными высказываниями ЕСЛИ-ТО; параллельное управление, позволяющее заменить формулу числом логических правил; связь с теорией вероятности, где функцию принадлежности рассматривается как вероятность накрытия элемента случайным множеством; позволяет разрабатывать интеллектуальные системы управления в условия неопределенности исходной информации, слабо формализуемого описания объекта и управления им.

Основные термины и понятия нечеткого управления: лингвистическая переменная, функция принадлежности (терм), степень принадлежности, база знаний, блок нечеткого вывода (нечеткая импликация, нечеткая композиция), фазификация и дефазификация [3].

Особенностью нечеткого управления является то, что нечеткий регулятор имеет жесткую архитектуру, включающую в себя блок фазификатора, базы знаний, блок нечеткого вывода и блок дефазификатора. Реализация каждого блока нечеткого регулятора многозначна. Нечеткое управление, является прозрачным, но неадаптивным, что можно корректировать с применением технологии мягких вычислений (Л. Заде в 1994 г.) Однако существуют проблемы мягких вычислений, связанные с субъективным определением вида функций принадлежности, определением оптимальной структуры нейронных сетей, применением генетического алгоритма в задачах многокритериального управления при наличии дискретных ограничений на параметры объекта.

Заключение. Разработаны интеллектуальные системы управления (ИСУ) разных поколений.

В ИСУ первого поколения выбор функции принадлежности зависит от уровня квалификации эксперта; проблема сложности проектирования базы знаний, так как отсутствует конструктивный алгоритм формировании базы знаний; требует знаний по выбору вариантов реализации фазификатора, блока нечеткого вывода и дефазификатора.

В ИСУ второго поколения дополнительно введена интеллектуальная глобальная обратная связь (ИГОС), что позволило извлекать объективные

знания непосредственно из динамического поведения объекта и исполнительного устройства. ИГОС состоит из генетического алгоритма (ГА) и нейронной сети. ГА извлекает информацию об оптимальном сигнале управления, а нейронная сеть аппроксимирует данный сигнал.

В ИСУ третьего поколения дополнительно в ИГОС ИСУ второго поколения введен оптимизатор базы знаний, который формирует базу знаний нечеткого регулятора, корректирующего настройки ПИД-регулятора САР, с целью увеличения частных критериев качества управления.

Отрицательное свойство нечеткого управления его неадаптивность устраняется также с помощью метода эталонных моделей, методом последовательного обучения, методом пройденного пути.

Развивается направление векторного анализа математического описания нечетких систем управления недетерминированными объектами [7...9].

Библиографический список

1. Эндрю А. Искусственный интеллект. М.: Мир 1985, 265 с.
2. Ясницкий Л.Н. О приоритете Советской науки в области нейроинформатики (Пленарный доклад) // Всероссийская научная конференция нейроинформатика и их применение. Тезисы докладов г. Москва, 14 марта 2017 г.; под ред, А.В, Чечкина, Л.С. Куравского и др. –: МГППУ. 2017, С. 16–19.
3. Хижняков Ю.Н. Нечеткое, нейронное и гибридное управление: учеб. пособие / Ю.Н. Хижняков. – Пермь: Изд-во Перм. нац. исслед. политехн. ун-та, 2013. – 303 с.
4. Осовский С. Нейронные сети для обработки информации / Пер. с польского И.Д. Рудинского. М. : Финансы и статистика, 2004. 344
5. Рутковская Д., Пилиньский М., Рутковский Л. Нейронные сети, генетические алгоритмы и нечёткие системы: Пер. с польск. И. Д. Рудинского. – М.: Горячая линия -Телеком, 2006. – 452 с.
5. Хижняков Ю.Н. Нечеткое, нейронное и гибридное управление: учеб. пособие / Ю.Н. Хижняков. – Пермь: Изд-во Перм. нац. исслед. политехн. ун-та, 2013. – 303 с.
6. Пегат А. Нечёткое моделирование и управление. Пер. с англ. – М.: Бином, 2009. – 798 с.
7. Марценюк М.А., Поляков В.Б., Селетков И.П. Матричная реализация алгоритмов нечёткого вывода. // Научно-технические ведомости Санкт-Петербургского государственного политехнического университета. Информатика. Телекоммуникации. Управление. – 2012. – № 6 (162). – С. 133-141: граф. – Библиогр.: с. 140–141 (10 назв.).
8. Марценюк М.А. Матричное представление нечёткой логики / Труды IX международной конференции "Интеллектуальные системы и компьютерные науки", Москва, МГУ, 2006. Т. 4. С. 3–36.
9. Марценюк М. А. Матричное представление нечёткой логики // Нечёткие системы и мягкие вычисления. Научный журнал Российской ассоциации нечётких систем и мягких вычислений. 2007. Т. 2, № 3. С. 7–35.

METHODS AND TOOLS FOR CREATING INTELLIGENT CONTROL SYSTEMS

*Khizhnyakov Yuri N., Storozhev Sergey A.,
Zagvozkin Vladimir D., Nikulin Vyacheslav S.*
Perm National Research Polytechnic University

Str. Komsomolsky prospect, 29, Perm, Russia, 614000, h1941@yandex.ru

The article presents the main methods and tools for building intelligent systems.

Keywords: artificial intelligence, neural network technologies, mathematical modeling, RBF networks, fuzzy control.

УДК 004.8

СВЕРТОЧНАЯ НЕЙРОННАЯ СЕТЬ НА ОСНОВЕ ЗНАНИЙ ДЛЯ РАСПОЗНАВАНИЯ СИМВОЛОВ

Гладкий Сергей Леонидович

ООО «ВИПАКС+», 614000, Россия, г. Пермь, ул. Краснова, 24,
lrndlrnd@mail.ru

Представлена методика внедрения знаний в сверточную нейронную сеть. Выдвигается гипотеза о том, что знания эксперта, внедренные в нейронную сеть, позволяют сделать ее более надежной и эффективной и добиться более высокой обобщающей способности модели. Одним из способов заложить знания в сверточную сеть является контролируемое обучение, когда определенный блок нейронной сети обучается отдельно на специально сформированной выборке изображений. В работе данная методика обучения применена для создания блока выделения линий. Формирование примитивов линий для контролируемого обучения выполнено основываясь на знаниях о топологиях элементов, формирующих символы алфавитов для адаптации к зрительной системе человека. Выполнено сравнение двух нейронных сетей для распознавания цифр: сверточной сети на основе стандартной архитектуры и сети на основе предобученного блока выделения линий с внедренными знаниями. Предложен метод визуализации результатов работы блока выделения линий, который адаптирован к цветовому восприятию человеческой зрительной системы и позволяет визуально верифицировать правильность принятия решения нейронной сетью.

Ключевые слова: сверточная нейронная сеть, нейронная сеть на основе знаний, оптическое распознавание символов, распознавание цифр, глубокое обучение.

Введение. На протяжении второй половины XX-го века искусственный интеллект развивался в двух основных направлениях – нейронные сети и экспертные системы [1]. Нейросетевой подход основан на попытке создания системы, по архитектуре имитирующей устройство человеческого мозга: совокупность нейронов, связанных друг с другом нелинейной функцией.

Обучение нейросетевой модели так же имитирует процессы, происходящие в мозге – меняются связи между нейронами таким образом, чтобы конечная система достигала максимальной точности на некотором обучающем множестве. Сама система при этом остается ‘черным ящиком’, то есть неизвестно, как нейросеть принимает то или иное решение. Экспертные системы так же имитируют человеческий мозг, но в смысле алгоритма принятия решений. В систему закладываются знания экспертов из некоторой области и при необходимости решения задачи происходит извлечение необходимых знаний и вывод решения на их основе. В этом случае процесс принятия решения является прозрачным, то есть можно легко проследить цепочку логических выводов, которые привели к данному заключению.

Два основных направления ИИ фактически являлись противоборствующими. С переменным успехом в различные периоды доминировал один из этих подходов. С началом XXI века можно сказать, что доминирующим является нейросетевой подход. Особенно это касается такой области, как компьютерное зрение и распознавание изображений [2, 3]. Сверточные нейронные сети (СНС) за последние десятилетие совершили настоящую революцию в компьютерном зрении и даже превзошли человека по точности распознавания лиц.

Не смотря на все преимущества, нейронные сети не лишены недостатков, например, как упоминалось ранее, нейронная сеть является ‘черным ящиком’. При всем многообразии существующих инструментов визуализации карт признаков (feature maps) сверточных нейронных сетей [3-6], практически представляется невозможным понять, как нейросеть с несколькими десятками или сотнями слоев и тысячами ядер принимает решение. Кроме того, развитие нейронных сетей сейчас идет по экстенсивному пути (эволюция), а именно, использование грубой силы – чем больше слоев содержит сеть, тем более точным будет результат [7]. Основным ‘двигателем’ такого ‘развития’ являются популярные соревнования нейросетевых моделей, где победитель борется буквально за десятые или сотые доли процента точности [4-6]. Фактически, на данных соревнованиях разработчики нейронных сетей меряются ‘размером’ своих моделей.

Для интенсивного (революционного) развития в этой области необходимо использование новых подходов к проектированию и обучению нейронных сетей. Одним из возможных путей такого развития может быть объединение нейросетевого подхода с элементами, позаимствованными из области экспертных систем. А именно, заложить в нейронную сеть знания эксперта из той области, для которой будет применена данная модель.

Аналогичный подход был использован для создания компьютерной системы моделирования физических явлений REGIONS [8]. В систему REGIONS были заложены знания экспертов в области решения краевых задач математической физики. Эти знания представляли собой общие решения дифференциальных уравнений в частных производных для канонических областей, полученные великими математиками, такими, как Фурье, Даламбер, Лямэ, и др., а также идеи и теоремы метода фиктивных канонических областей

[9, 10]. На основе этих знаний, система REGIONS строит решения для сложных геометрических областей с учетом заданных граничных условий, причем решения ищется путем минимизации конечной ошибки – аналог обучения нейронной сети. Таким образом, система REGIONS сочетает в себе два подхода – наличие введенных экспертных знаний и численное решение конкретной задачи с учетом этих знаний. Такое сочетание позволяет получать надежные решения краевых задач со сложными границами и краевыми условиями.

Опыт внедрения знаний в систему для решения краевых задач математической физики, а также успешное применение знаний в нейросетевом моделировании [11], показывают, что такой подход может повысить качество решения. Использование знаний в нейронных сетях позволит создавать более надежные и эффективные модели с высокой обобщающей способностью. В данной работе предлагается один из возможных подходов для внедрения знаний в сверточные нейронные сети.

Знания в СНС. С одной стороны, нейронные сети считаются моделями типа ‘черный ящик’, которые дают результат без возможности объяснения правил вывода результата из исходных данных. С другой стороны, считается, что нейронные сети в процессе обучения сами получают новые знания. Особенно это касается СНС, которые сами выделяют полезные признаки, кодируемые ядрами свертки. При несомненной практической пользе таких признаков для решения конкретных задач, их нельзя строго отнести к категории знаний. Основной проблемой здесь является неконтролируемый процесс обучения СНС [7]. Признаки, получаемые в процессе традиционного обучения СНС, являются часто избыточными, неупорядоченными и зависят от данных, на которых проходит обучение. Фактически, выделенные признаки являются набором фактов о наличии различных элементов в исходных данных. Восстановить логику принятия решения на основе данных признаков практически невозможно. Таким образом, современные СНС работают, вероятно, по принципу простого запоминания огромного количества различных сочетаний признаков, которые дают решение задачи. Этим объясняется постоянное увеличения объема СНС – чем больше сочетаний способна запомнить нейронная сеть, тем точнее она работает. При этом нельзя отрицать очень эффективный способ выделения и хранения признаков, обеспечиваемый СНС, особенно для обработки изображений. Именно этим была обусловлена последняя революция в распознавании изображений.

Чтобы заложить в нейронную сеть знания эксперта, необходимо обеспечить контролируемое обучение СНС, то есть обучить ее именно тем признакам, которые эксперт считает определяющими для решения задачи из определенной области. В [7] предложена методика контролируемого обучения сверточных слоев нейронной сети, позволяющая обучать их выделению определенных признаков. Методика заключается в следующем. Во-первых, нейронная сеть разбивается на блоки, которые предназначены для решения определенной задачи. Во-вторых, каждый блок должен обучаться отдельно, именно той задаче, за которую он отвечает. В-третьих, каждый блок обучается

на своих данных. Данные для обучения блока должны быть сгенерированы искусственно и не должны включать в себя никакие изображения, используемые в конечной нейронной сети, включающей данный блок. В [7] также приведен пример обучения блока выделения границ на основе 8 ядер размером 4x4 пикселя. В данной работе будет использована аналогичная методика обучения для внедрения знаний в СНС. Как пример, рассматривается СНС для распознавания печатных символов, в частности, цифр на государственных автономерах.

Разработка блока выделения линий. Поскольку целью конечной СНС, в которую будут заложены знания, является распознавание печатных символов, необходимо обучить специальный блок. В данном случае это блок выделения линий, поскольку все символы состоят из набора различных линий. Будем считать, что символы изображаются белыми линиями на черном фоне, поскольку в конечной системе распознавания с помощью предварительной обработки всегда можно конвертировать изображение в такой вид.

Для создания блока выделения линий необходимо выбрать набор примитивов (базовых линий), которым будет обучен блок. Именно на этом этапе фактически определяются знания, которые будут заложены в этот блок. Были реализованы и протестированы несколько наборов базовых линий для обучения, в частности, 12 примитивов 7x7 пикселей (рис. 1).

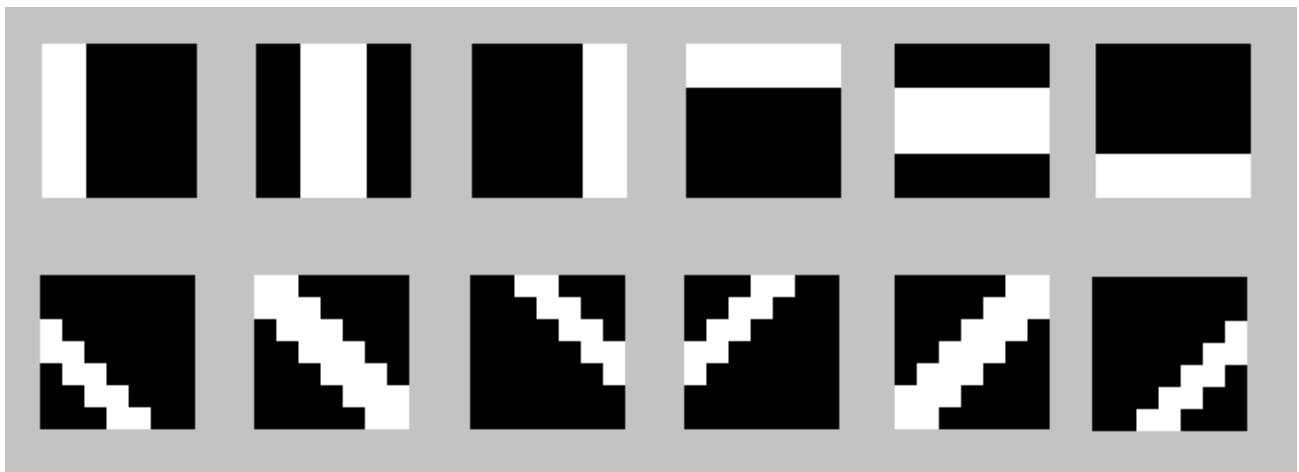


Рисунок 1. Изображения примитивов линий 7x7

Данный набор примитивов содержит вертикальные и горизонтальные линии, а также линии с наклоном 45 градусов влево и вправо. Для контролируемого обучения блока необходимо научить его выделению именно данных примитивов. Для этого формируется набор примеров, который содержит эти примитивы с различной степенью контрастности темных и светлых элементов изображения. Кроме того, в набор добавляются данные для двух дополнительных примитивов: пустого (черного) и полного (белого). Эти два примитива используются только при обучении и исключаются из конечной модели нейронной сети. Так же, в обучающую выборку изображений добавляются данные с шумом: белые или черные пиксели в

случайных позициях, по 3 пикселя на изображении. Всего в обучающей выборке получено 5728 изображений.

Обучение блока выполняется по принципу обычного классификатора. Для этого создается нейронная сеть с одним сверточным слоем. Сверточный слой содержит 12 ядер размером 7×7 , по одному на каждый примитив, и нелинейную функцию активации. После сверточного слоя добавляется слой классификации – функция активации Soft-max [4] с 12-ю выходами. Данные из обучающей выборки размечаются как данные классификации: каждое изображение примитива относится к одному из 12 классов с вероятностью 100%; отрицательные данные размечаются как не принадлежащие ни одному классу (вероятность принадлежности всем классам равна 0).

После обучения, как показано в [7], ядра сверточного слоя выделяют именно те признаки, которые соответствуют базовым примитивам, причем номер класса всегда соответствует номеру примитива. Таким образом, получен блок выделения линий на основе знаний, то есть он обучен выделять определенные признаки, которые, по мнению эксперта, важны при решении задачи. Такой блок затем может быть использован как составная часть нейронной сети для распознавания символов. Использование сверточного слоя в другой нейронной сети может быть легко реализовано с помощью стандартных методов переносимого обучения [5].

Были проведены эксперименты по распознаванию цифр на основе блоков выделения линий, обученных на различных наборах примитивов. Результаты экспериментов показали недостаточную точность. Поэтому была выдвинута гипотеза и том, что необходим другой набор примитивов.

В [12] проведено исследование и выдвинута гипотеза, что символы алфавита были сформированы не случайным образом. Они были приспособлены так, чтобы зрительная система человека распознавала их наиболее быстро. Поскольку письменность возникла уже после сформировавшейся в процессе эволюции зрительной системы, элементами символов являются те же элементы, которые наиболее важны для зрительной системы с точки зрения получения преимуществ в естественном отборе. Одними из ключевых структур для распознавания предметов являются *пересечения* (сочленения) линий. Именно из различных типов пересечений и формируются символы алфавитов. В работе приводятся различные по топологии пересечения, типа L, T, X, Y, K, F и другие, а также статистика их распространенности в разных алфавитах.

Принимая во внимание данное исследование, был сформирован окончательный набор примитивов линий (рис 2). Этот набор также содержит вертикальные, горизонтальные и наклонные линии, но они выбраны таким образом, чтобы формировать пересечения различных типов.

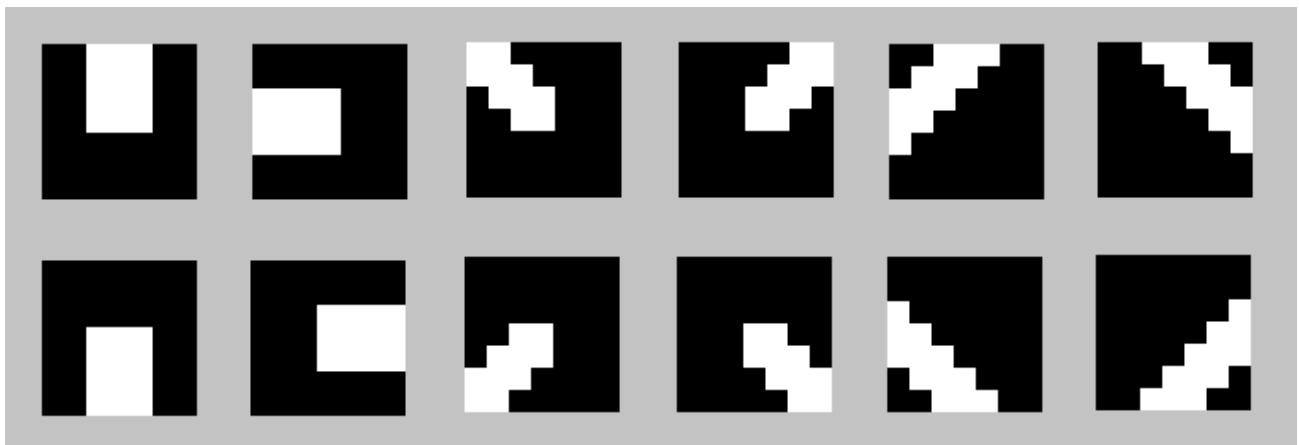


Рисунок 2. Примитивы линий 7x7 для распознавания символов

Распознавание цифр. Основной гипотезой настоящей работы является утверждение о том, что внедрение знаний эксперта в СНС позволит повысить эффективность, надежность и обобщающую способность нейросетевой модели. Для подтверждения гипотезы необходимо провести сравнение работы моделей на основе стандартных архитектур и модели на основе знаний. Современные модели стандартных архитектур имеют от нескольких десятков до тысячи слоев и сравнение с моделью, на основе одного слоя является некорректным. Поэтому был проведен следующий эксперимент.

Созданы две модели, каждая с двумя сверточными слоями. Первая модель является обычной СНС, выполненной по рекомендациям проектирования моделей [4-6]. Вторая модель содержит предобученный слой выделения линий. В классической модели все слои являются обучаемыми. В модели на основе знаний слой выделения линий не обучается. Количество ядер в сверточных слоях первой модели больше, чем во второй, для обеспечения гибкости при обучении.

Для проведения эксперимента обе модели обучаются на одном и том же наборе изображений цифр, сгенерированном специально для распознавания символов на автомобильных номерах (рис. 3). Затем работа обеих нейросетей проверяется на распознавании реальных изображений цифр, полученных с видео системой фиксации автономеров (рис. 4). В таблице 1 приведены результаты сравнения двух моделей по различным параметрам.



Рисунок 3. Примеры изображений цифр из обучающей выборки



Рисунок 4. Примеры изображений цифр из проверочной выборки

Таблица 1
Данные сравнения нейросетевых моделей

Модель/Параметр	Стандартная модель	Модель на основе знаний
Количество ядер в 2-х сверточных слоях и 1-м полно связном	32-128-256	12-32-0
Размер модели, МВ	1.33	0.17
Время обучения, мин	30	1
Точность обучения тестирования, %	100-100	100-100
Точность валидации, %	93.2	96.0
Время распознавания, мс	0.60	0.12

Как видно из таблицы, модель на основе знаний является более компактной, то есть содержит меньше параметров для обучения. Соответственно, время обучения данной модели на порядок меньше, чем стандартной модели. При этом, стандартная модель достигла 100% точности на тестирующем множестве. Однако при валидации на изображениях цифр, полученных с реальных камер, модель на основе знаний показала почти вдвое большую точность. Кроме того, скорость распознавания у модели на основе знаний в 5 раз выше.

Таким образом, полученная модель на основе знаний является более эффективной и надежной, имеющей более высокую обобщающую способность, чем эквивалентная модель, построенная по стандартной архитектуре. Кроме того, блок выделения линий может быть так же использован для обучения моделей распознавания различных символов (английского, русского и др.). Более того, с помощью стандартных методов переносимого обучения, предобученный блок выделения линий можно сделать общим блоком для нескольких нейросетей. Данный блок будет

осуществлять первичную обработку изображения и результат его работы будет поступать на вход нескольких нейросетей для распознавания символов различного типа.

Визуализация результатов. Одним из преимуществ контролируемого обучения (внедрения знаний в СНС) является то, что в этом случае результаты работы слоев нейронной сети поддаются более простой визуализации и интерпретации. Поскольку разработчик точно знает, какому геометрическому примитиву соответствует активация нейрона, можно восстановить результаты работы блока. Одним из способов является следующий: создается простой классификатор, в основе которого блок выделения линий и результатом которого является вероятности активации каждого примитива. Данный классификатор обрабатывает исходное изображение. Формируется новое изображение, на которое накладываются изображения геометрических примитивов, с коэффициентом, равным вычисленной вероятности активации. На рисунке 5 приведены результаты визуализации работы блока выделения линий на некоторых изображениях цифр.

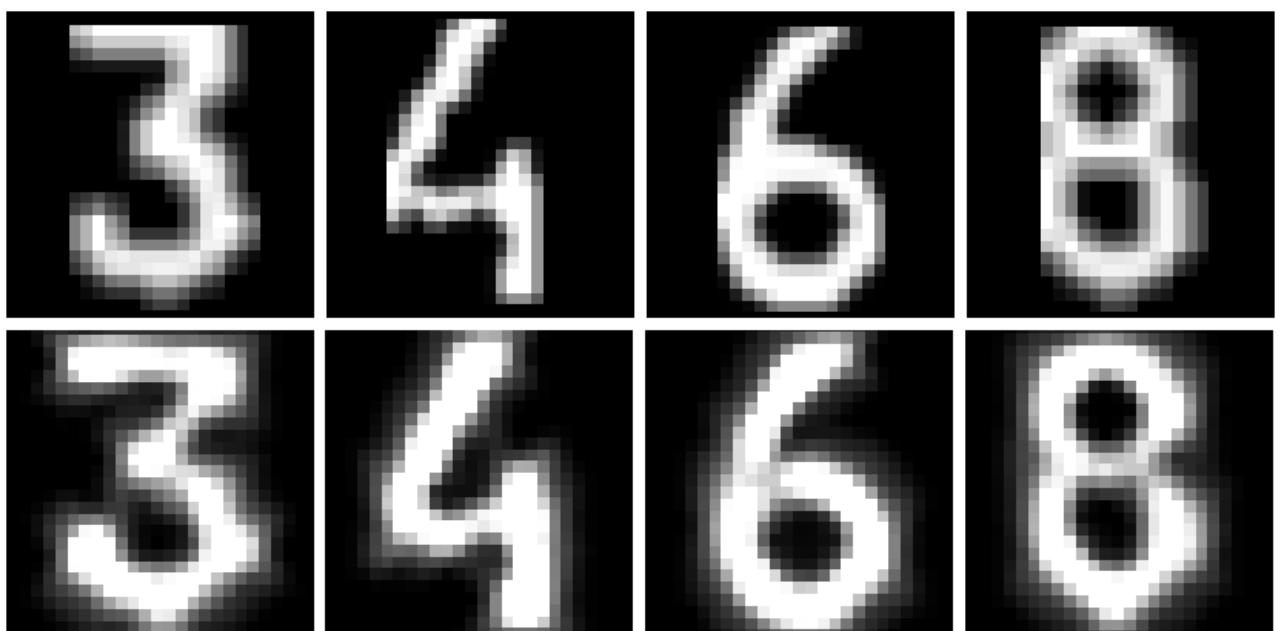


Рисунок 5. Визуализация работы блока выделения линий на основе вероятности активации (вверху – исходное изображение, внизу – активация примитивов линий)

Такая визуализация в принципе позволяет определить, что нейронная сеть дает адекватный отклик на изображение. Недостатком такого метода является то, что по восстановленному изображению не понятно, на основе каких именно примитивов была выполнена реконструкция. Для устранения этого недостатка предложен другой метод, основанный на особенности восприятия цветов зрительной системой человека.

Известно, что для человеческого зрения две пары цветов – красный и зеленый, синий и желтый – представляют перцепционные противоположности [12]. То есть цвета из этих пар кажутся человеку противоположными. В наборе примитивов линий есть так же 2 пары перпендикулярных линий:

горизонтальная и вертикальная, наклон влево и наклон вправо на 45 градусов. Предлагается визуализировать результаты работы блока выделения линий, используя 4 цвета для 4-х типов наклона (рис. 6).

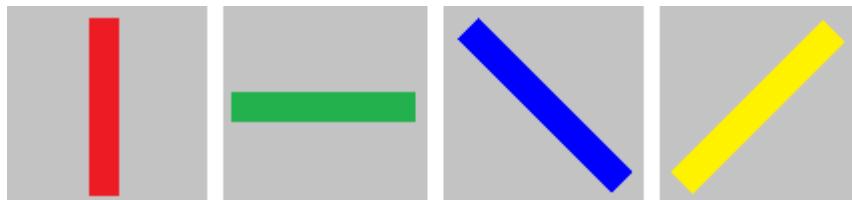


Рисунок 6. Цвета для визуализации 4-х наклонов линий

Такая визуализация позволяет, во-первых, представить наклон линии, определенный нейронной сетью с помощью цвета. Во-вторых, поскольку система визуализации разработана с учетом особенностей работы цветового зрения человека, она позволяет быстро адаптировать восприятие разработчика к изображению результатов и их интерпретации. На рисунке 7 представлены результаты визуализации работы блока выделения линий на изображениях цифр.

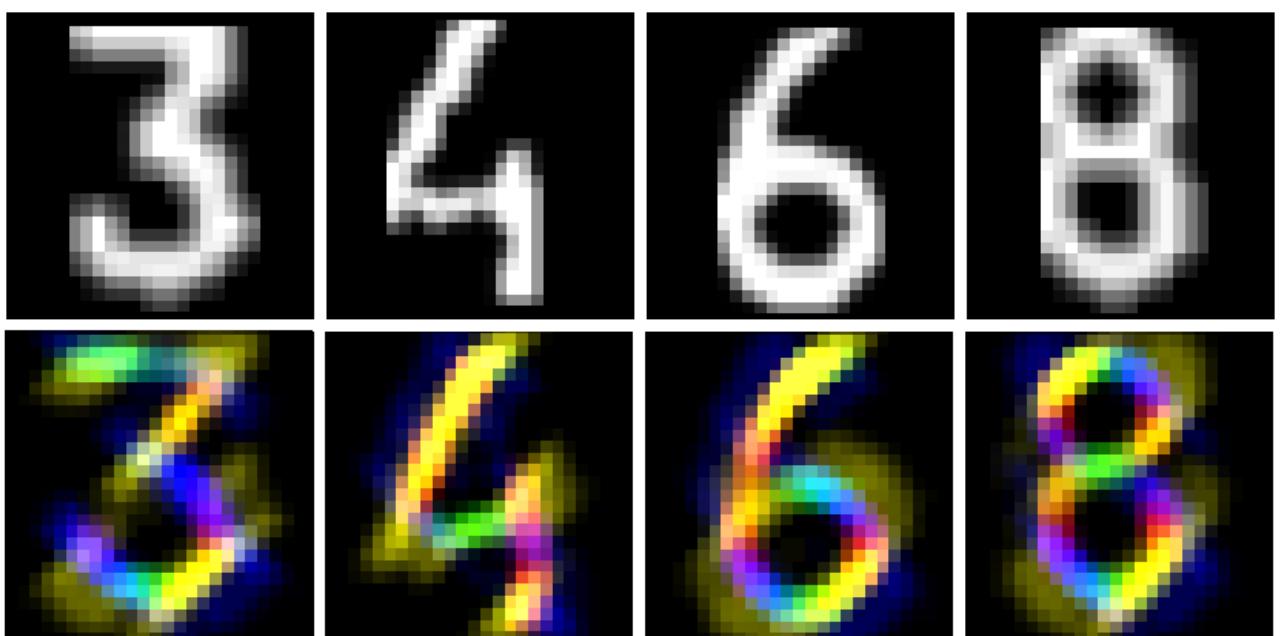


Рисунок 7. Визуализация работы блока выделения линий на основе перцептивно противоположных цветов (вверху – исходное изображение, внизу – активация примитивов линий)

Результаты визуализации показывают, что нейронная сеть правильно выделяет положение и угол наклона линий на изображениях цифр.

Заключение. Итак, в работе представлен один из методов внедрения знаний в СНС с использованием контролируемого обучения. Согласно данному подходу, нейронную сеть необходимо обучать именно тем признакам, которые эксперт считает наиболее значимыми для решения задачи из определенной области. Контролируемое обучение было применено для разработки блока выделения линий, который использован для нейронной сети распознавания цифр. Примитивы линий для данного блока были выбраны с

учетом основных топологий элементов, встречающихся в различных алфавитах и адаптированных для восприятия системой зрения человека.

Проведено сравнение работы двух эквивалентных нейронных сетей для распознавания цифр. Одна из моделей была разработана на основе стандартной архитектуры сверточных сетей, вторая модель включала блок выделения линий с внедренными знаниями. Результаты сравнения показали, что модель на основе знаний является более компактной и эффективной и обладает более высокой степенью обобщения.

На настоящий момент разработана методика внедрения знаний только для одного слоя нейронной сети с базовыми геометрическими примитивами. Для дальнейшего развития направления СНС на основе знаний необходимо разработать методики обучения последующих слоев для выделения более сложных примитивов и объектов. Кроме того, необходимо разработать методику объединения таких слоев в единую архитектуру.

Библиографический список

1. Гудфеллоу Я., Бенджио И., Курвильт А. Глубокое обучение / пер. с анг. А. А. Слинкина. – 2-е изд., испр. – М.: ДМК Пресс, 2018. – 652 с.: цв. ил.
2. Николенко С., Кадурин А., Архангельская Е. Глубокое обучение. Погружение в мир нейронных сетей. – СПб.: Питер, 2018. – 480 с.: ил.
3. Chollet F. Deep Learning with Python. – NY.: Manning Publications Co., 2018. – 386 р.
4. Rosebrock A. Deep Learning for Computer Vision with Python. Starter Bundle. – pyimagesearch.com, 2017. – 332 р.
5. Rosebrock A. Deep Learning for Computer Vision with Python. Practitioner Bundle. – pyimagesearch.com, 2017. – 210 р.
6. Rosebrock A. Deep Learning for Computer Vision with Python. ImageNet Bundle. – pyimagesearch.com, 2017. – 323 р.
7. Гладкий С.Л. Переносимое обучение на основе знаний в компьютерном зрении. // Сборник статей по материалам Международной конференции «Интеллектуальные системы в науке и технике» (г. Пермь, 12-18 октября 2020 г) / под редакцией Л. Н. Ясницкого; Пермский государственный национальный исследовательский университет. – Пермь, 2020. С. 76-86.
8. Гладкий С.Л., Степанов Н.А., Ясницкий Л.Н. Интеллектуальное моделирование физических проблем. Москва–Ижевск: НИЦ «Регулярная и хаотическая динамика», 2006. – 200 с.
9. Ясницкий Л.Н. Метод фиктивных канонических областей в механике сплошных сред. М.: ФИЗМАТЛИТ, 1992.
10. Ясницкий Л.Н. Суперпозиция базисных решений в методах типа Треффтца // Известия Академии наук СССР. Механика твердого тела. 1989. № 2. С. 95-101.
11. Ясницкий Л.Н., Черепанов Ф.М. Гибридная нейро-экспертная система моделирования диагностики и развития сердечно-

- сосудистых заболеваний // Нейрокомпьютеры и их применение: Тезисы докладов XV Всероссийской научной конференции. (г. Москва, 14 марта 2017 г.); Под ред. А.В.Чечкина, Л.С.Куравского и др. – М: МГППУ, 2017. С. 211-215.
12. Чангизи М. Революция в зрении. Что, как и почему мы видим на самом деле. – М.: Издательство ACT, 2015. – 302 с.: ил.

KNOLEDGE BASED CONVOLUTIONAL NEURAL NETWORK FOR CHARACTER RECOGNITION

Gladkiy Sergey L.

LLC «VIPAKS», Krasnova st., 24, Perm, Russia, 614000,
lrndlrnd@mail.ru

The article presents a methodology for developing knowledge-based neural networks. The main hypothesis is that an expert's knowledge, embedded into a neural network makes it more reliable and effective, allowing to reach higher generalization. One approach of embedding knowledge into a neural network is controlled learning when each block of a network is trained separately with a specially generated set of sample images. The line primitives for the controlled learning are formed based on the knowledge about the topology of elements of alphabet characters, that are adopted for the human visual system. The comparison of two neural networks for digit recognition is provided: one neural network is based on a standard architecture and another is based on the line detection block with embedded knowledge. An algorithm of result visualization for the line detection block is developed. The algorithm is adopted for the color perception of the human visual system and allows to verify visually the correctness of the neural network results.

Keywords: convolutional neural network, knowledge-based neural network, optical character recognition, digit recognition, deep learning.

СРАВНЕНИЕ РАЗЛИЧНЫХ СПОСОБОВ РАСПОЗНАВАНИЯ КЛЮЧЕВОГО СЛОВА С ПОМОЩЬЮ НЕЙРОННЫХ СЕТЕЙ

Неверов Антон Робертович

Пермский государственный национальный исследовательский университет,
614990, Россия, г. Пермь, ул. Букирева, 15,
astrohaker@outlook.com

В статье представлено описание разработки различными способами нейросетевых систем для распознавания ключевого слова, а также их сравнение. Такие системы позволяют распознавать с большой точностью нужное слово из общего звукового потока.

Ключевые слова: искусственный интеллект, нейросетевые технологии, распознавание, ключевое слово, звук.

Введение. В современном мире для взаимодействия человека с компьютером все больше популярности набирает голосовой интерфейс. Это позволяет передавать и получать информацию не находясь непосредственно рядом со средствами ввода-вывода, такими как клавиатура или мышь. Кроме того, повышается удобство пользования компьютером для людей с ограниченными возможностями.

Однако остается открытым вопрос, каким образом инициируется начало взаимодействия. На настоящий момент это использование ключевого слова, т.е. слова, при произношении которого человеком, компьютер всю дальнейшую речь воспринимает, как обращенную к нему.

Очевидно, что для обнаружения ключевого слова, необходимо «прослушивать» весь аудиопоток непрерывно и пытаться распознать в нем ключевое слово, для этого будем использовать нейронные сети.

При анализе литературных источников выяснилось, что работ на тему распознавания ключевого слова существует довольно много, все они используют различные способы и технологии, однако становится непонятно, чем лучше или хуже тот или иной способ. Так, в работе [1] предложено делить аудиопоток на фреймы и делать их анализ, в работе [2] использовать наиболее подходящую математическую модель. В данной работе мы воспользуемся тремя наиболее распространенными подходами в настоящий момент: построение спектrogramм ключевого слова, использование мел-кепстральных коэффициентов и обучим ключевому слову уже предобученную на других словах нейронную сеть.

Для обучения нейронных сетей необходимо иметь обучающую выборку. В данном случае был записан звуковой датасет, со следующими характеристиками: в одном аудиофайле только одно слово или какой-либо звук, длина аудиозаписи 1 секунда, формат файла wav, частота дискретизации 16000 Гц. В данном датасете 8325 ключевых слов и 42787 других слов или различных звуков. В тестовой выборке было 735 примеров ключевого слова и 3878 примеров других слов, все остальное находилось в обучающей выборке.

Для начала рассмотрим распознавание ключевого слова с помощью спектрограмм. Авторы библиотеки tensorflow выложили достаточно подробную инструкцию по распознаванию ключевого слова с помощью этого способа [3]. Для каждого аудиофайла строим спектрограмму и затем подаем данные на вход нейронной сети, обучая ее. Пример одной из спектрограмм приведен на рисунке 1:

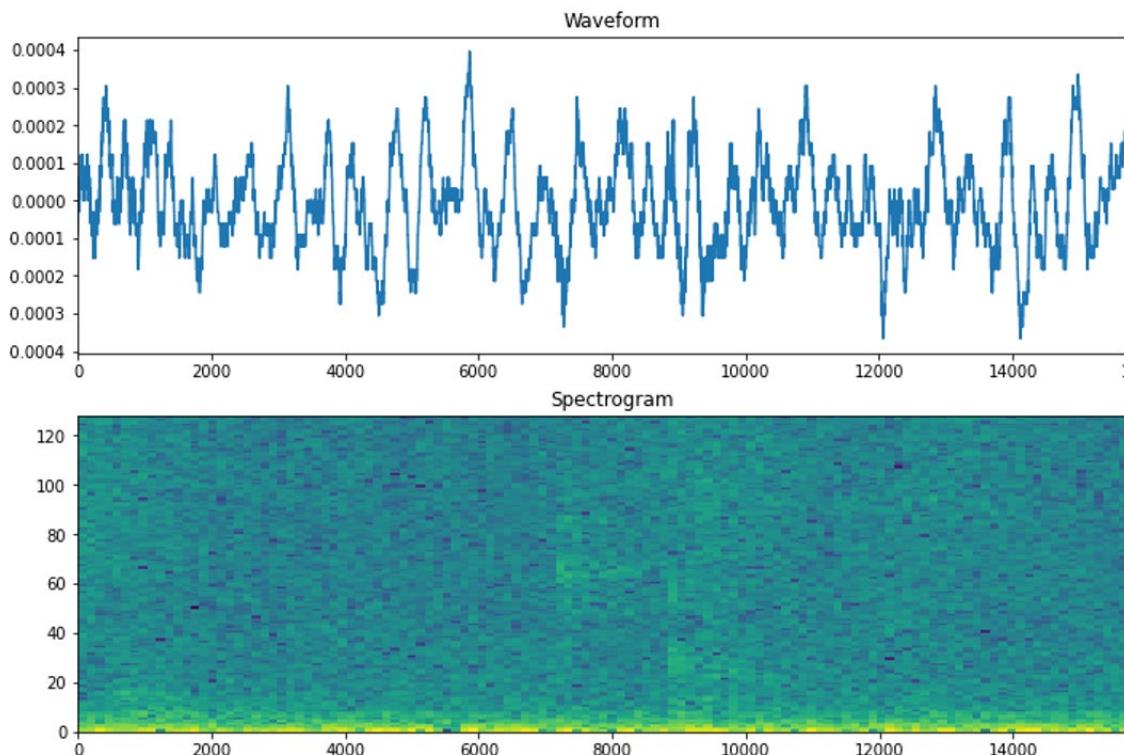


Рисунок 1. Пример спектрограммы

Архитектура нейронной сети, которая использовалась для обучения ключевому слову показана на рисунке 2:

```

Model: "sequential"

Layer (type)                 Output Shape              Param #
=====                      =====
resizing (Resizing)          (None, 32, 32, 1)        0
normalization_1 (Normalizati (None, 32, 32, 1)        3
conv2d (Conv2D)              (None, 30, 30, 32)       320
conv2d_1 (Conv2D)             (None, 28, 28, 64)      18496
max_pooling2d (MaxPooling2D) (None, 14, 14, 64)       0
dropout (Dropout)            (None, 14, 14, 64)       0
flatten (Flatten)            (None, 12544)           0
dense (Dense)                (None, 128)             1605760
dropout_1 (Dropout)          (None, 128)             0
dense_1 (Dense)              (None, 2)               258
=====
Total params: 1,624,837
Trainable params: 1,624,834
Non-trainable params: 3

```

Рисунок 2. Структура нейронной сети

После обучения было проведено тестирование, которое показало успешно распознанных ключевых слов 707 (96.19%) и других слов 3842 (99.07%). Видно, что иногда происходили ложные срабатывания, когда система распознавала ключевое слово там, где его нет. Время распознавания одного слова составило 501.755 сек.

Для реализации подхода с помощью мел-кепстральных коэффициентов была использована статья на электронном ресурсе [4]. В качестве нейронной сети была использована все та же нейронная сеть, показанная на рисунке 2. Только в данном случае для каждого аудиофайла были вычислены MFCCs: мел-кепстральные коэффициенты. Результаты следующие: успешно распознанных ключевых слов 690 (93.88%), других – 3850(99.28%). Время распознавания составило 179.495 сек. Видно, что также присутствуют ложные срабатывания, однако время распознавания намного меньше.

Распознавание с помощью уже предобученной нейронной сети было реализовано на базе Yamnet [5]. Это нейронная сеть, которая была обучена на 8 миллионах записей различных звуков с интернет-портала youtube.com для распознавания 521 класса. Будем дообучать ее выходной слой на нашем датасете [6].

Результат тестирования на ключевых словах оказался очень мал и составил 257 слов (34.9%), на других словах 421(57.2%). Время распознавания 153.596 сек.

Заключение.

Из полученных результатов можно сделать вывод, что спектрограммы достаточно качественный подход для распознавания ключевых слов, однако большое количество времени, необходимого для построения спектрограммы делает данный способ малопригодным в случае реализации на мобильных или других маломощных устройствах. Лучше всего в таком случае использовать мел-кепстральные коэффициенты, которые при совсем незначительном менее качественном распознавании ключевого слова вычисляются намного быстрее.

Обучение на уже предобученной нейронной сети показало самый худший результат. При точности менее 50% нет смысла рассматривать такой подход, так как в реальном мире человеку быстро надоест обращаться к компьютеру голосом. Компьютер просто не будет его «слышать», а большое количество ложных срабатываний будет постоянно его «активировать», что станет причиной недовольства со стороны человека.

Библиографический список

1. E. Nöth, S. Harbeck, H. Niemann, and V. Warnke, "A frame and segment based approach for topic spotting," in Proc. Eurospeech, Rhodes, Greece, Sep. 1997.
2. R. Schwartz, T. Imai, L. Nguyen, and J. Makhoul, "A maximum likelihood model for topic classification of Broadcast News," in Proc Eurospeech, Rhodes, Greece, Sep. 1997.
3. Tensorflow.org – Simple audio recognition: Recognizing keywords.[Электронный ресурс]. Режим доступа:
https://www.tensorflow.org/tutorials/audio/simple_audio
4. Habr.com – Мел-кепстральные коэффициенты (MFCC) и распознавание речи.[Электронный ресурс]. Режим доступа: <https://habr.com/ru/post/140828/>
5. Mathworks.com – Yamnet.[Электронный ресурс]. Режим доступа:
<https://www.mathworks.com/help/audio/ref/yamnet.html>
6. Tensorflow.org – Transfer learning with YAMNet for environmental sound classification. [Электронный ресурс]. Режим доступа:
https://www.tensorflow.org/tutorials/audio/transfer_learning_audio

COMPARISON OF DIFFERENT WAYS OF KEYWORD RECOGNITION USING NEURAL NETWORKS

Neverov Anton R.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990,

astrohaker@outlook.com

The article describes the development of methods of neural network systems for keyword recognition, as well as their comparison. Such systems recognize with great accuracy the desired word from the audio stream.

Keywords: artificial intelligence, neural network, prediction, keyword, sound.

СРАВНЕНИЕ ОСНОВАННЫХ НА ФИЗИКЕ ПОЛНОСВЯЗНЫХ НЕЙРОННЫХ СЕТЕЙ И СЕТЕЙ РАДИАЛЬНЫХ БАЗИСНЫХ ФУНКЦИЙ

Глумсков Роман Алексеевич

Пензенский государственный университет, 440026, Россия, г. Пенза,
ул. Красная, 40, gromared@gmail.com

Горбаченко Владимир Иванович

Пензенский государственный университет, 440026, Россия, г. Пенза,
ул. Красная, 40, gorvi@mail.ru

Стенькин Дмитрий Александрович

Пензенский государственный университет, 440026, Россия, г. Пенза,
ул. Красная, 40, stynukin@mail.ru

Проведено сравнение решения краевых задач для дифференциальных уравнений в частных производных на основанных на физике полносвязных нейронных сетях (*physics-informed neural networks*) и сетях радиальных базисных функций. При решении краевых задач оба вида сетей обучаются не на примерах, а на проверке физических закономерностей, выраженных в виде уравнения и краевых условий, на ограниченном наборе пробных точек внутри и на границе области. Сравнение проведено на модельных задачах с помощью библиотеки TensorFlow. Авторами разработан быстрый алгоритм метода Левенберга-Марквардта обучения сетей радиальных базисных функций. Для реализации алгоритма Левенберга-Марквардта и сетей радиальных базисных функций разработаны расширения библиотеки TensorFlow. Решение модельных задач показало преимущества использования сетей радиальных базисных функций в качестве *physics-informed neural networks*.

Ключевые слова: основанные на физике нейронные сети, полносвязные нейронные сети, сети радиальных базисных функций, краевая задача, дифференциальные уравнения в частных производных, обучение нейронных сетей, метод Левенберга-Марквардта.

Возможность решения дифференциальных уравнений в частных производных (ДУЧП) на полносвязных нейронных сетях прямого распространения известна достаточно давно [1] и основана на универсальная теореме аппроксимации [2]. Но универсальная теорема аппроксимации не является конструктивной и говорит только о принципиальной возможности построения нейронной сети, содержащей один скрытый слой, аппроксимировать гладкую функцию. На практике такая сеть может потребовать очень большого количества нейронов в скрытом слое, что

практически не позволяет обучить сеть. Кроме того, такие сети имеют тенденцию к переобучению.

Эти проблемы в значительной степени решаются использованием для решения ДУЧП глубоких полносвязных сетей. Как доказано в [3], глубокие сети с функцией активации ReLU являются универсальными аппроксиматорами функций. Решающую роль в применении глубоких полносвязных сетей для решения ДУЧП сыграли свободно распространяемые библиотеки, например, TensorFlow, поддерживающие автоматическое дифференцирование при обучении нейронных сетей. Автоматическое дифференцирование, реализованное в TensorFlow, основано на использовании вычислительных графов для вычисления градиентов. Причем в TensorFlow 2 для вычисления градиента используются специальные градиентные ленты (GradientTape), не требующие от пользователя построения графа [4]. Глубокие полносвязные сети для решения ДУЧП, реализованные с использованием библиотек, поддерживающих автоматическое дифференцирование, получили название *physics-informed neural networks* [5]. Особенностью, объединяющей *physics informed neural networks*, является то, что такие сети обучаются не на примерах, а на проверке физических закономерностей. При решении ДУЧП в процессе обучения параметры сети настраиваются таким образом, чтобы невязки в некотором наборе пробных точек внутри и на границе области стали малыми.

Существующие библиотеки глубокого обучения ориентированы не на решение ДУЧП, а на построение больших сетей для распознавания изображений. Для обучения используются градиентные алгоритмы первого порядка, так как более быстрые алгоритмы второго порядка требуют недопустимо больших ресурсов. Обученная сеть применяется для решения многих задач распознавания. При этом основное внимание уделяется точности работы сети, а не времени обучения. При решении ДУЧП для каждой задачи требуется заново обучать сеть на относительно небольшом наборе пробных точек. При этом необходимо обеспечить как высокую точность, так и малое время обучения, что не позволяют алгоритмы первого порядка. Поэтому для *physics informed neural networks* является актуальной разработка быстрых алгоритмов обучения второго порядка.

Для решения ДУЧП используются также нейронные сети другого типа – сети радиальных базисных функций (СРБФ) [6, 7], являющиеся универсальными аппроксиматорами [8]. СРБФ отличаются от глубоких полносвязных сетей простотой, так как содержат только два слоя и позволяют настраивать не только веса, но и нелинейные параметры – параметры радиальных базисных функций (РБФ). Эти особенности СРБФ открывают широкие возможности применения градиентных алгоритмов обучения второго порядка. Особенностью СРБФ является формирование приближённого дифференцируемого аналитического решения в любой точке исследуемой области.

Однако в настоящее время быстрые градиентные алгоритмы второго порядка практически не применяются для обучения СРБФ. Авторами статьи

разработаны алгоритмы обучения СРБФ для решения ДУЧП методом доверительных областей [9] и эквивалентным ему, но более простым методом Левенберга-Марквардта [10]. Эти алгоритмы одновременно настраивают как веса, так и параметры базисных функций. Вычисления параметров алгоритмов проводилось аналитически, что ускоряет вычисления, но требует подготовительной работы.

В настоящее время в библиотеках типа TensorFlow отсутствует реализация СРБФ для решения ДУЧП. Также отсутствует сравнение глубоких сетей и СРБФ для решения ДУЧП. Целью работы являются разработка и реализация в TensorFlow 2 алгоритмов обучения глубоких нейронных сетей прямого распространения и СРБФ для решения ДУЧП и сравнение решения модельных задач на этих сетях.

Рассмотрим стационарную краевую задачу в операторной форме

$$Lu(\mathbf{x}) = f(\mathbf{x}), \quad \mathbf{x} \in \Omega, \quad (1)$$

$$Bu(\mathbf{x}) = p(\mathbf{x}), \quad \mathbf{x} \in \partial\Omega, \quad (2)$$

где u – искомое решение; L – дифференциальный оператор; B – оператор граничных условий; Ω – область решения; $\partial\Omega$ – граница области; f и p – известные функции.

При решении нестационарных задач время можно рассматривать как одну из координат, т.е. рассматривать задачу вида (1)–(2). Но такой подход увеличивает размерность задачи, что может быть неприемлемым. Более распространенный подход подразумевает явную разностную аппроксимацию производных по времени и решение на каждом временном шаге стационарной задачи вида (1)–(2), что не увеличивает размерность задачи.

Выберем множество пробных точек внутри и на границе области решения $\{(\mathbf{x}_i)|_{i=1,N-M} \subset \Omega, (\mathbf{x}_i)|_{i=N-M+1,N} \subset \partial\Omega\}$, где N – количество пробных точек внутри области решения, K – количество граничных пробных точек. Обучение сети основано на минимизации функции потерь, представляющей собой сумму квадратов невязок в пробных точках

$$J(\mathbf{w}, \mathbf{p}) = \sum_{i=1}^N [Lu(\mathbf{x}_i) - f(\mathbf{x}_i)]^2 + \lambda \sum_{j=1}^K [Bu(\mathbf{x}_j) - p(\mathbf{x}_j)]^2 \rightarrow \min, \quad (3)$$

где λ – штрафной множитель.

Решение ДУЧП на СРБФ имеет вид

$$u_{RBF}(\mathbf{x}) = \sum_{j=1}^N w_j \varphi_j(\mathbf{x}), \quad \mathbf{x} \in \bar{\Omega} = \Omega \cup \partial\Omega, \quad (4)$$

где φ_j – РБФ; w_j – веса СРБФ.

В качестве РБФ используем функцию Гаусса (Гауссиан) $\varphi(\|\mathbf{x} - \mathbf{c}\|, a) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{c}\|^2}{2a^2}\right)$, где \mathbf{c} – координаты центра функции, a – параметр формы (ширина).

Среди градиентных алгоритмов первого порядка для обучения нейронных сетей лучшим в настоящее время признан алгоритм Adam [11],

реализованный в TensorFlow. Этот алгоритм является алгоритмом с адаптивной скоростью обучения, обеспечивающий различную скорость обучения для различных компонентов вектора параметров. Для обучения СРБФ рассмотрим единый вектор весов и параметров РБФ для двумерной задачи имеющий вид

$$\boldsymbol{\theta} = \left[w_1, w_2, \dots, w_{n_{RBF}}, c_{11}, c_{21}, \dots, c_{n_{RBF}1}, c_{12}, c_{22}, \dots, c_{n_{RBF}2}, a_1, a_2, \dots, a_{n_{RBF}} \right]^T, \quad (5)$$

где w_j – веса, $j = 1, 2, 3, \dots, n_{RBF}$, n_{RBF} – количество РБФ, c_{j1} и c_{j2} – координаты центров, a_j – ширина.

В алгоритме Adam на $(k+1)$ -ом шаге обучения сети вектор параметров (5) корректируется по формуле

$$\boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(k)} - \eta \mathbf{m}^{(k+1)} / \sqrt{\mathbf{s}^{(k+1)}} + \varepsilon,$$

где $\mathbf{m}^{(k+1)} = \frac{\mathbf{m}}{1 - \beta_1^{k+1}}$, $\mathbf{m} = \beta_1 \mathbf{m}^{(k)} - (1 - \beta_1) \mathbf{g}(\mathbf{w}^{(k)})$, $\mathbf{s}^{(k+1)} = \frac{\mathbf{s}}{1 - \beta_2^{k+1}}$,

$\mathbf{s} = \beta_2 \mathbf{s}^{(k)} + (1 - \beta_2) \mathbf{g}(\mathbf{w}^{(k)}) \otimes \mathbf{g}(\mathbf{w}^{(k)})$, ./ – поэлементное деление, \otimes – поэлементное умножение, ε – сглаживающий член, обычно $\varepsilon \approx 10^{-8}$, $\beta_1 = 0.9, \beta_2 = 0.999$ – рекомендуемые параметры.

Популярным численным методом оптимизации второго порядка является метод Левенберга-Марквардта [12, 13]. В разработанном алгоритме на основе метода Левенберга-Марквардта [10], коррекция весов в k -ой эпохе обучения нейронной сети производится на вектор поправки параметров сети $\Delta \boldsymbol{\theta}^k$. Вектор поправки формируется как результат решения системы линейных алгебраических уравнений

$$(\mathbf{J}_{k-1}^T \mathbf{J}_{k-1} + \mu_k \mathbf{E}) \Delta \boldsymbol{\theta}^k = \mathbf{J}^T \mathbf{r} \quad (6)$$

где \mathbf{J}_{k-1} – матрица Якоби, вычисленная по значениям параметров сети на $(k-1)$ -ой эпохе обучения, \mathbf{E} – единичная матрица, μ_k – параметр регуляризации, $\mathbf{r}^{(k-1)}$ – вектор невязок в пробных точках на $(k-1)$ -ой эпохе обучения.

Алгоритм предусматривает аналитическое вычисление элементов матрицы Якоби. В данной статье в реализации алгоритма Левенберга-Марквардта обучения как глубоких полносвязных сетей, так и СРБФ используется автоматическое дифференцирование.

Для создания моделей, описывающих обучение как глубоких полносвязных сетей, так и СРБФ, были разработаны классы, являющиеся наследниками базового класса библиотеки Keras. Для реализации алгоритма Adam использована одноименная встроенная функция. Функция для реализации алгоритма оптимизации методом Левенберга-Марквардта не является встроенной функцией Tensorflow и по этой причине была реализована с нуля. Вектор поправки весов в методе Левенберга-Марквардта формируется как результат решения системы (6). Для решения системы использовался встроенный в Tensorflow алгоритм LU-разложения.

Для проведения экспериментов использовался компьютер с характеристиками: процессор – Intel Core i5 2310, частотой 2,9 GHz, объем оперативной памяти – 24,0 GB.

Для исследования разработанных алгоритмов обучения были выбраны задачи, описываемые уравнение Пуассона

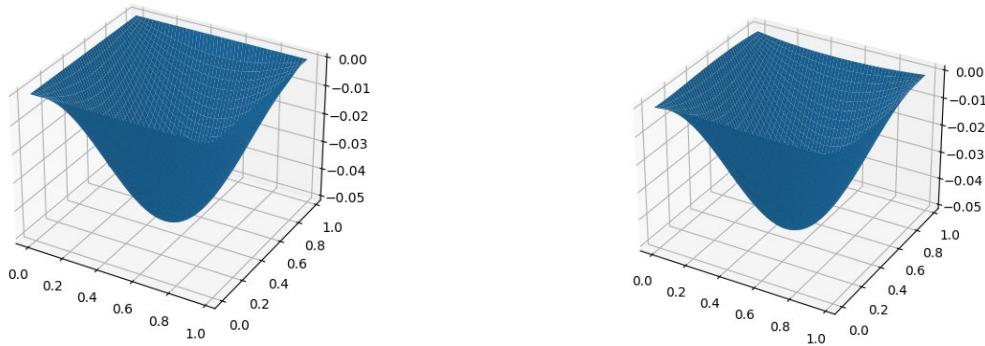
$$\frac{\partial^2 u}{\partial x_1^2} + \frac{\partial^2 u}{\partial x_2^2} = f(x_1, x_2), \quad (x_1, x_2) \in \Omega,$$

$$u = p(x_1, x_2), \quad (x_1, x_2) \in \partial\Omega,$$

где $\partial\Omega$ – граница области; f и p – известные функции

Первое ДУЧП решалось при $f(x_1, x_2) = \sin(\pi x_1) \sin(\pi x_2)$ и $p(x_1, x_2) = 0$.

Задача имеет аналитическое решение (рис. 1а) $u = -\frac{1}{2\pi^2} \sin(\pi x_1) \sin(\pi x_2)$. В качестве области решения был выбран квадрат $[0, 1]^2$. Было случайно сгенерировано 100 пробных точек внутри области решения и 40 точек на границе.



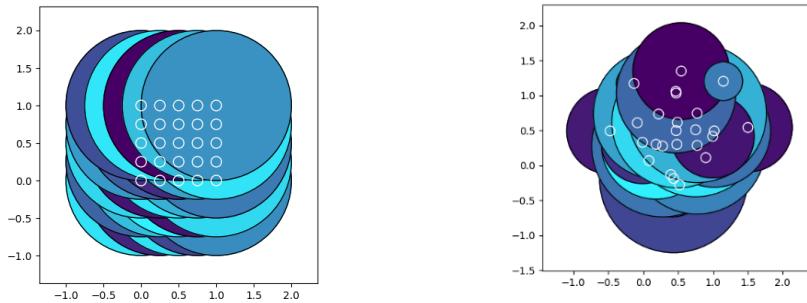
а) аналитическое решение

б) результат решения на СРБФ

Рисунок 1. Решение первого ДУЧП

Количество РБФ выбрано равным 25. Для инициализации веса использовались случайные числа, равномерно распределенные на интервале от 0 до 0.001. Начальные значения ширины РБФ задавались равными 1.0. СРБФ обучалась алгоритмами Adam и Левенберга-Марквардта. На рис. 2 показаны значения параметров СРБФ при инициализации и после обучения сети алгоритмом метода Левенберга-Марквардта. На рис. 2 показаны центры РБФ, ширина РБФ условно показана диаметрами кругов, а величины весов показаны заливкой кругов. Рис. 2 демонстрирует важность настройки не только весов, но и параметров РБФ.

Полносвязная сеть, обучавшаяся алгоритмом Adam, задавалась с 3 скрытыми слоями по 200 нейронов в каждом. Полносвязная сеть, обучавшаяся алгоритмом метода Левенберга-Марквардта, задавалась с одним скрытым слоем из 100 нейронов. Веса обеих полносвязных сетей инициализировались случайными числами, равномерно распределенными от -1 до 1. Функцией активации слоя была выбрана сигмоидальная функция. Для сетей, использовавших алгоритм Левенберга-Марквардта в качестве алгоритма обучения, начальное значение параметра регуляризации задавалось равным 0.1.



а) при инициализации

б) после обучения

Рисунок 2. Параметры СРБФ при решении первого ДУЧП

В таблице 3 показаны результаты обучения сетей различной конфигурации при решении первого ДУЧП. По причине зависимости результатов эксперимента от случайной генерации параметров сетей, проводилась серия из 10 экспериментов. В таблице 3 представлены усредненные результаты по проведенной серии экспериментов. Как видно из таблицы 1, оба вида сетей при решении первой задачи показали близкие результаты.

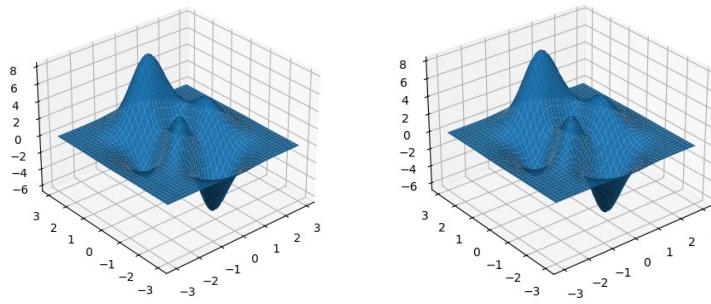
Таблица.
Сравнение сетей различной конфигурации при решении ДУЧП 1

Тип сети	Алгоритм оптимизации	Функция потерь	Количество эпох обучения	Время обучения, с
СРБФ	Adam	1.6429e-05	2000	42
СРБФ	Левенберга-Марквардта	4.0341e-07	100	5
Полносвязная	Adam	1.5427e-05	2000	43
Полносвязная	Левенберга-Марквардта	2.2194e-07	100	5

Для проведения второй серии экспериментов было выбрано ДУЧП с аналитическим решением, являющимся мультимодальной функцией [14] (рис. 3).

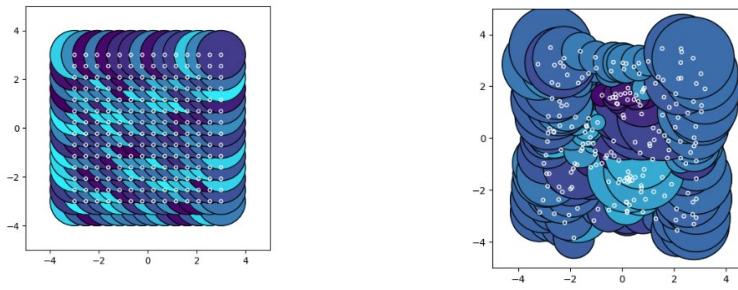
$$u(x, y) = 3(x-1)^2 e^{-x^2-(y+1)^2} - 10 \left(\frac{x}{5} - x^3 - y^5 \right) e^{-x^2-y^2} - \frac{1}{3} e^{-(x+1)^2-y^2}. \quad (7)$$

Правая часть ДУЧП получена в результате дифференцирования аналитического решения (7). Областью решения являлся квадрат $[-3, 3]^2$. Границные условия равны аналитическому решению на границе области. Было выбрано случайным образом 150 внутренних пробных точек и 50 граничных пробных точек. В СРБФ количество РБФ выбрано равным 196. Для инициализации весов использовались случайные числа, равномерно распределенные на интервале от 0 до 0.001. Начальные значения ширины РБФ задавались равными 1.0. Параметры СРБФ показаны на рис. 4. Глубокая сеть задавалась с 3 скрытыми слоями по 200 нейронов в каждом. Веса инициализировались случайными числами, равномерно распределенными от -1 до 1. Функцией активации слоя была выбрана сигмоидальная функция.



а) аналитическое решение б) результат решения на СРБФ

Рисунок 3. Решение ДУЧП 2



а) при инициализации б) после обучения

Рисунок 4. Параметры СРБФ при решении второго ДУЧП

При реализации алгоритма Левенберга-Марквардта возникла проблема с решением систем линейных уравнений достаточно большого порядка. Решение подобных систем линейных уравнений с помощью встроенных функций TensorFlow занимает слишком много времени. При этом, если использовать меньше нейронов, то не получается аппроксимировать решение с достаточной точностью. Чтобы уменьшить количество эпох обучения с использованием алгоритма метода Левенберга-Марквардта параметры СРБФ инициализировались не случайным образом, а весами, полученными после 100 эпох обучения алгоритмом Adam, на что потребовалось 4 с. Дальнейшая настройка всех параметров СРБФ в течение 10 эпох, на что потребовалось 63 с, позволила получить значение функции потерь 1.0087e-05. Для DNN даже такой подход оказался не приемлем из-за слишком больших временных затрат на обучение. Для второго ДУЧП лучшие результаты показала СРБФ.

Таблица 2.
Сравнение сетей различной конфигурации при решении ДУЧП 2

Тип сети	Алгоритм оптимизации	Функция потерь	Количество эпох обучения	Время обучения, с
СРБФ	Adam	1.3412e-04	2000	37
СРБФ	Adam	4.6429e-05	20000	402
СРБФ	Левенберга-Марквардта	1.0087e-05	110	67
Полносвязная	Adam	1.4409e-04	2000	46

Из результатов экспериментов видно, что оба вида сетей имеют примерно одинаковую точность при обучении алгоритмом Adam. С другой стороны, хотя обучение алгоритмом Левенберга-Марквардта происходило достаточно долго, с его использованием удалось получить точность, не достижимую при использовании алгоритма Adam. Таким образом, для эффективного использования алгоритма метода Левенберга-Марквардта необходимо реализовывать собственные, более эффективные функции, чем встроенные функции TensorFlow. Перспективным является предварительное обучение СРБФ до невысокой точности алгоритмом Adam с последующим дообучением всех параметров сети алгоритмом метода Левенберга-Марквардта. В то же время алгоритм Adam можно успешно применять для задач достаточно большой размерности, где не требуется добиваться высокой точности.

Библиографический список

1. Lagaris E., Likas A., Fotiadis D.I. Artificial Neural Networks for Solving Ordinary and Partial Differential Equations // IEEE Transactions on Neural Networks. 1998.9(5), P. 987–1000.
2. Cybenko G. Approximation by Superposition of a Sigmoidal Function. Mathematics of Control // Signals and Systems. 1989. 2. P. 303–314.
3. Hanin B. Universal Function Approximation by Deep Neural Nets with Bounded Width and ReLU Activations. <https://arxiv.org/abs/1708.02691v2> (2017).
4. Рашка С., Мирджалили В. Python и машинное обучение: машинное и глубокое обучение с использованием Python, Scikit-learn и TensorFlow 2. СПб. ООО "Диалектика", 2020. 848 с.
5. Raissia M., Perdikaris P., Karniadakis G.E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations // Journal of Computational Physics. 2019. 378. P. 686–707.
6. Yadav N., Yadav A., Kumar M. An introduction to neural network methods for differential equations. Dordrecht. Springer. 2015. 127 p.
7. Tarkhov D., Vasilyev A. Semi-Empirical Neural Network Modeling and Digital Twins Development. Cambridge MA. Academic Press. 2019. 288 p.
8. Park J., Sandberg I.W. Approximation and Radial-Basis-Function Networks // Neural Computation. 1993. 5(2). P. 305–316.
9. Горбаченко В.И., Жуков М.В. Решение краевых задач математической физики с помощью сетей радиальных базисных функций // Журнал вычислительной математики и математической физики. 2017(57). № 1. С. 133–143.
10. Горбаченко В. И., Алкезуини М. М. Моделирование объектов с распределенными параметрами на нейронных сетях // Модели, системы, сети в экономике, технике, природе и обществе. 2019. 4 (32). С. 50–64.
11. Kingma D.P., Ba J. Adam: A method for stochastic optimization. <https://arxiv.org/abs/1412.6980>.
12. Levenberg K. A method for the solution of certain non-linear problems in least squares // Quarterly of Applied Mathematics. 1944. 2(2), P. 164–168.

13. Marquardt D. An Algorithm for Least-Squares Estimation of Nonlinear Parameters // Journal of the Society for Industrial and Applied Mathematics. 11/ 1963. P. 431–441.
14. Safarpoor M. Takhtabnoos F., Shirzadi A. A localized RBF-MLPG method and its application to elliptic PDEs // Engineering with Computers. 2019.36(1). P. 171–183.

COMPARISON OF PHYSICS-BASED FULLY CONNECTED NEURAL NETWORK AND RADIAL BASIS FUNCTION NETWORKS

Glumskov Roman A.

Penza State University, 40 Krasnaya St., Penza, Russia, 440026,
gromared@gmail.com

Gorbachenko Vladimir I.

Penza State University, 40 Krasnaya St., Penza, Russia, 440026,
gorvi@mail.ru

Stenkin Dmitry A.

Penza State University, 40 Krasnaya St., Penza, Russia, 440026,
stynukin@mail.ru

This article compares the solution of boundary value problems for partial differential equations using physics-informed neural networks and radial basis function networks. When solving boundary value problems, both types of networks are trained not on examples but on verification of physical laws expressed in the form of equation and boundary conditions in a limited set of test points inside and on the boundary of a domain. Comparisons are made on model problems using the TensorFlow library. The authors have developed a fast algorithm for learning radial basis function networks using the Levenberg-Marquardt method. Extensions to the TensorFlow library were developed to implement the Levenberg-Marquardt algorithm and radial basis function networks. The solution of model problems has shown the advantages of using radial basis function networks as physics-informed neural networks.

Keywords: physics-based neural networks, full-coupled neural networks, radial basis function networks, boundary value problem, partial differential equations, neural network training, Levenberg-Marquardt method.

АНАЛИЗ СТАТИСТИЧЕСКОЙ ИНФОРМАЦИИ НА ОСНОВЕ МЕТОДОВ МАШИННОГО ОБУЧЕНИЯ

Жиленкова Елена Петровна

ФГБОУ ФО «Брянский государственный инженерно-технологический университет», 241037 г.Брянск, пр-кт Станке Димитрова,3,
JHelen21@yandex.ru

Азаренко Наталья Юрьевна

ФГБОУ ФО «Брянский государственный инженерно-технологический университет», 241037 г.Брянск, пр-кт Станке Димитрова,3,
salovanat@mail.ru

В статье дано обоснование возможностей применения методов машинного обучения при обработке и анализе статистической информации, обозначена актуальность применения современных цифровых технологий в процессах сбора, хранения и формирования аналитической базы в различных предметных областях, представлены условные этапы анализа статистических данных на основе машинного обучения, сделан вывод о необходимости применения S.M.A.R.T. метода при постановке целей аналитического исследования.

Ключевые слова: статистическая информация, анализ данных, машинное обучение, искусственный интеллект

Введение. Полнота и достоверность статистической информации является базисом принятия грамотных управлеченческих решений, что непосредственно сказывается на целевых показателях устойчивого развития государства.

Статистическая информация, получаемая путем сбора, обработки и анализа посредством официального статистического учета в стране, является источником формирования аналитической базы для разработки государственной политики и принятия решений по социально значимым проблемам.

Современная действительность характеризуется процессами стремительного роста объемов получаемой и передаваемой информации. Результатом аналитического доклада фирмы IDC «Эра данных 2025» является вывод о том, что к 2025 году объем информации во всем мире будет в 10 раз больше, чем в 2016 году [2].

Одним из главных вызовов современного этапа развития цифровой экономики является экспоненциальный рост количества, качества и многообразия [3] статистической информации, включая анализ нетипичных

результатов или «выбросов» [6], что требует от человека новых навыков и компетенций в сфере обработки данных. Ускоренно растущий объем информации значительно превышает способности человека по ее усвоению и обработке, что приводит к необходимости в привлечении технологий искусственного интеллекта.

Увеличение объемов данных, которые создаются и сохраняются в единицу времени, привело к кардинальным изменениям в жизни людей и определило траекторию цифровизации общества – весомые результаты научных исследований могут быть сформированы в результате «интеллектуального анализа огромного массива данных в различных предметных областях» [3].

Согласно основным тезисам Стратегии развития Росстата до 2024 года [4] официальный статистический учет в России должен осуществить переход от традиционной отчетности к новым источникам данных (альтернативных источников информации и потенциала больших данных) с применением Цифровой аналитической платформы.

Современная цифровая реальность, благодаря искусственному интеллекту, дает возможность наделять машины способностями, которые имитируют интеллектуальное поведение человека и его умение рассуждать.

Круг применения возможностей искусственного интеллекта относительно анализа данных чрезвычайно быстро расширяется и применяется во многих областях. Так, например, компьютерное зрение используется при анализе содержания изображений и извлечении из них необходимой полезной информации, основываясь на типовых образцах, визуализирующих данные. Анализ текстовой информации осуществимо проводить на основе систем распознавания текста. Благодаря системам распознавания речи имеется возможность воспринимать звуковую информацию, а также способность понимать произносимые слова.

В экспертных системах методики искусственного интеллекта применяются с целью принятия решений либо предоставления соответствующих рекомендаций. На рисунке 1 представлена модель экспертной системы и ее взаимодействия с пользователем.

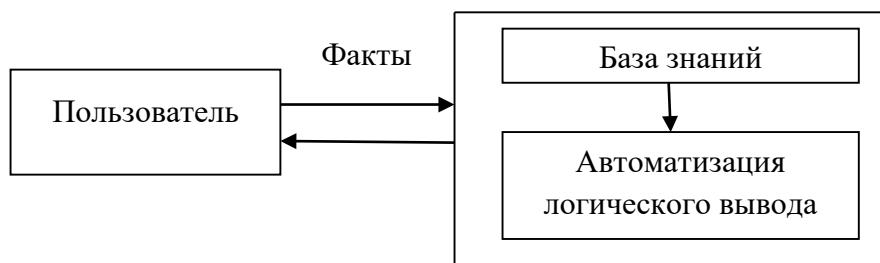


Рисунок 1. Экспертная система и её взаимодействие с пользователем

Машинное обучение, как одно из направлений искусственного интеллекта, не просто использует заранее написанный алгоритм, но также на основе применения статистических методов анализа позволяет машинам

совершенствоваться с приобретенным опытом при выполнении задач. Индуктивный подход лежит в основе машинного обучения: «на основе части данных делается вывод об общем состоянии системы или процесса» [5].

С помощью методов машинного обучения извлекаются знания из данных в результате их сегментации и прогнозирования вероятности будущих событий на основе прошлых событий (рисунок 2).



Рисунок 2. Алгоритм машинного обучения [1]

Цикл решения задачи по анализу данных на основе методов машинного обучения включает в себя предварительную обработку данных, выбор метода классификации и параметров, проведение обучения и оценку качества модели (рисунок 3)

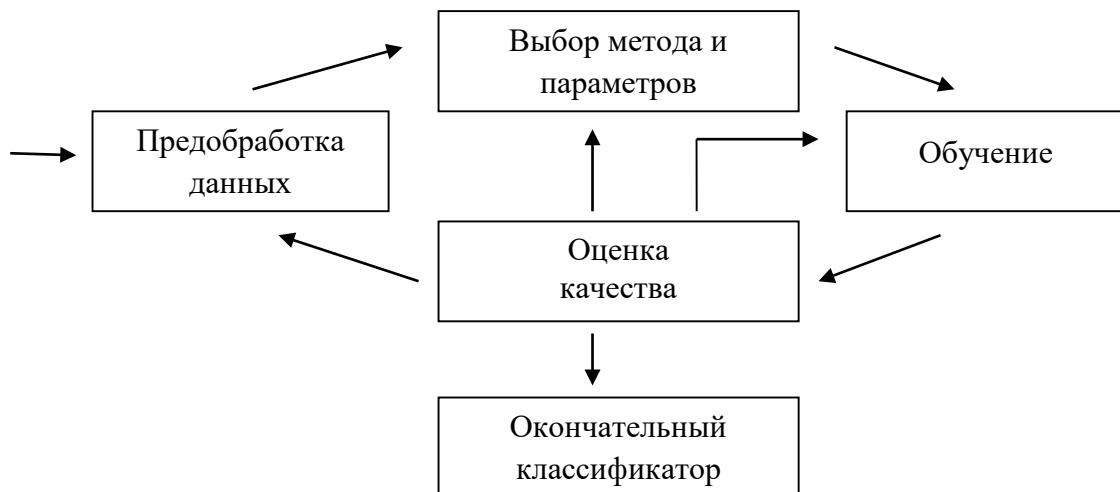


Рисунок 3. Цикл решения аналитической задачи по машинному обучению [1]

При постановке целей анализа данных необходимо применять методы S.M.A.R.T. подхода, который предполагает, что цель «должна отвечать запросам ключевых» [5] пользователей и соответствовать критериям конкретности, измеримости, достижимости, актуальности и ограниченности по времени.

Условно интеллектуальный анализ статистических данных можно разделить на несколько этапов (рисунок 4):

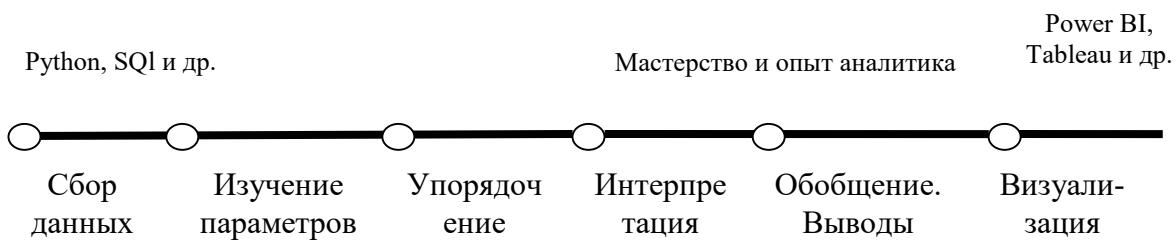


Рисунок 4. Этапы анализа статистических данных на основе машинного обучения

Вывод. Методы машинного обучения обладают свойствами, которые позволяют быть более гибкими по сравнению с традиционными аналитическими методами исследования, поэтому новые цифровые технологии расширяют возможности в сфере сбора, хранения, обработки данных, оптимизируют многие этапы анализа, позволяют строить алгоритмы поведения, прогнозные модели и повышают качество принятия решений.

Библиографический список

1. Машинное обучение и анализ данных. [Электронный ресурс] Режим доступа: <https://habr.com/ru/company/yandex/blog/206058/>
2. Data age 2025 // Сайт компании «Seagate» [Электронный ресурс] Режим доступа: <https://www.seagate.com/files/www-content/ourstory/trends/files/idc-seagate-dataage-whitepaper.pdf>
3. Что такое цифровая экономика? Тренды, компетенции, измерение[Текст]: докл. к XX Апр. междунар. науч. конф. по проблемам развития экономики и общества, Москва, 9–12 апр. 2019 г. / Г. И. Абдрахманова, К. О. Вишневский, Л. М. Гохберг и др. ; науч. ред.Л. М. Гохберг ; Нац. исслед. ун-т «Высшая школа экономики». – М.: Изд. дом Высшей школы экономики, 2019. – 82 с.
4. Стратегия Росстата до 2024 года [Электронный ресурс] Режим доступа: <https://rosstat.gov.ru/strategy>
5. Прохорова М.М. Основные направления совершенствования методики статистического анализа цифровой экономики // Вестник Евразийской науки, 2020 №5, <https://esj.today/PDF/50ECVN520.pdf> (доступ свободный). Загл. с экрана. Яз. рус., англ
6. Yasnitsky L.N. Algorithm for searching and analyzing abnormal observations of statistical information based on the Arnold – Kolmogorov – Hecht-Nielsen theorem // International Journal of Advanced Trends in Computer Science and Engineering. 2020. 9(2). Pp. 1814-1819. DOI: 10.30534/ijatcse/2020/139922020
<http://www.warse.org/IJATCSE/static/pdf/file/ijatcse139922020.pdf>

ANALYSIS OF STATISTICAL INFORMATION BASED ON MACHINE LEARNING METHODS

Zhilenkova Elena P.

Bryansk State University of Engineering and Technology, Bryansk, Stanke Dimitrova Ave., 3, 241037, JHelen21@yandex.ru

Azarenko Natalia Y.

Bryansk State University of Engineering and Technology, Bryansk, Stanke Dimitrova Ave., 3, 241037, salovanat@mail.ru

The article substantiates the possibilities of using machine learning methods in the processing and analysis of statistical information, identifies the relevance of the use of modern digital technologies in the processes of collecting, storing and forming an analytical database in various subject areas, presents the conditional stages of analyzing statistical data based on machine learning, concludes that the S.M.A.R.T. method should be used in setting the goals of analytical research.

Keywords: statistical information, data analysis, machine learning, artificial intelligence

ДОВЕРЕННЫЙ ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ, ПОСТРОЕННЫЙ С ИСПОЛЬЗОВАНИЕМ НЕЙРОНОВ СРЕДНЕГО ГАРМОНИЧЕСКОГО

Лукин Виталий Сергеевич

Пензенский государственный университет,
440000, Россия, г. Пенза, ул. Красная, 40, vitaly-lukin@mail.ru

Иванов Александр Иванович

АО «Пензенский научно-исследовательский электротехнический институт»
440000, Россия, г. Пенза, ул. Советская, 9, ivan@pniei.penza.ru

В статье утверждается, что для реализации искусственного интеллекта в защищенном исполнении недостаточно только сетей искусственных нейронов, автоматически обученных по ГОСТ Р 52633.5, обогащающих входные «сырые» данные в линейном пространстве. Утверждается, что дополнительно желательно использовать сети искусственных нейронов, обогащающих входные «сырые» данные в пространстве среднего гармонического.

Ключевые слова: доверенный искусственный интеллект, нейроны среднего гармонического, автоматическое обучение, преобразование биометрии в код аутентификации.

Введение. В России вопросы регламентирования требований к доверенному профессиональному интеллекту (ИИ) попадают в компетенцию сразу трех технических комитетов: ТК 164 «Искусственный интеллект», ТК 26 «Криптографическая защита информации», ТК 362 «Техника защиты информации».

Наиболее глубоко проработан вопрос защиты нейросетевых преобразователей биометрия-код, автоматически обучаемых по ГОСТ Р 52633.5 [1] и быстро тестируемых алгоритмом ГОСТ Р 52633.3 [2] на малых тестовых выборках. Кроме того, таблицы обученной нейросети могут быть зашифрованы по в соответствии с технической спецификацией ТК 26 [3]. Очевидно, что нейросетевое преобразование биометрических образов относится к частным приложениям ИИ, однако все стандарты, регламентирующие требования к этим частным приложениям, легко могут быть обобщены и на любые иные приложения ИИ. В этом отношении нейросетевая отечественная биометрия, несомненно, является образцом для приложений доверенного ИИ, выполненных в криптографически защищенном исполнении.

Следует отметить что уровень международной стандартизации доверенного ИИ в криптографически защищенном исполнении существенно выше мирового уровня. Это, видимо, связано, с нежеланием США и стран НАТО делать международную биометрию защищенной полноценной

криптографией. В этом случае БОЛЬШОЙ БРАТ утрачивает возможность видеть биометрию граждан Китая, Индии, Вьетнама, России, Беларуси. Именно с этим обстоятельством и связана активность России по созданию национальных стандартов, регламентирующих требования к доверенному ИИ в криптографически защищенном исполнении.

Следует отметить, что впервые вопрос о необходимости криптографической защиты биометрии встал при публичном обсуждении национального стандарта США БиоАПИ в 1998 году. Позднее этот национальный стандарт был переведен в ранг международного [4]. Криптографическая общественность была озабочена тем, что просто зашифровать биометрический шаблон БиоАПИ нельзя, после его зашифровывания им нельзя пользоваться. На это разработчики стандарта пообещали в ближайшие два-три года появления специальной криптографии гомоморфного шифрования. Стандарт по гомоморфному шифрованию [4] появился только через 21 год. При этом технология оказалась дефектной. Обычное шифрование позволяет защищать данные любого объема. Гомоморфно зашифровать можно так же очень сложные решающие правила, состоящие из большого числа сложений и умножений. Однако начиная с некоторого уровня сложности решающих правил итоговый их результат перестает гомоморфно расшифровываться [6]. Именно по этой причине, не текущий момент нет реально работающих биометрических приложений в исполнении, защищенном гомоморфным шифрованием.

Применение стандарта [1], совместно с технической спецификации [3], так же имеет существенный недостаток. К сожалению, даже для стойких в биометрическом отношении образов сочетание противоречивых требований [1, 3] дает длину выходного криптографического ключа от 21 до 51 бита. Этого явно недостаточно для ряда приложений доверенного искусственного интеллекта.

Обойти эту проблему можно в том случае, если параллельно с сетью линейных нейронов (персепtronов) использовать квадратичные нейроны [7], либо корреляционные нейроны Байеса [8]. Еще одним перспективным направлением является использование сетей искусственных нейронов, обогащающих «сырые» данные в пространстве среднего гармонического [8, 9, 10, 11].

Основным отличием линейных нейронов (1) от нейронов среднего гармонического (2) является то, что многократно снижается число запоминаемых параметров:

$$\left\{ \begin{array}{l} y \leftarrow \sum_{i=1}^{16} \mu_i \cdot x_i \\ z(y) \leftarrow "0" \text{ if } y < k \\ z(y) \leftarrow "1" \text{ if } y > k \end{array} \right. \quad (1),$$

$$\left\{ \begin{array}{l} x \leftarrow x - \min(x) + 1 \\ y \leftarrow \sqrt[16]{\prod_{i=1}^{16} x_i} \\ z(y) \leftarrow "0" \text{ if } y < k \\ z(y) \leftarrow "1" \text{ if } y > k \end{array} \right. \quad (2),$$

где μ – весовые коэффициенты. $E(x)$ – математическое ожидание входных смещенных данных.

Линейный нейрон (1) после его обучения должен запоминать 16 весовых коэффициентов и значение порога квантования (всего 17 параметров). Нейрон среднего гармонического запоминает только значение порога квантования (один параметр).

При этом автоматы обучения линейных нейронов и нейронов среднего геометрического оказываются просто реализуемыми. Это позволило «Пензенскому государственному университету» [12] создать для нейронов среднего гармонического среду моделирования «БиоНейроАвтограф 2.0». Экранная форма этой среды приведена на рисунке 1.

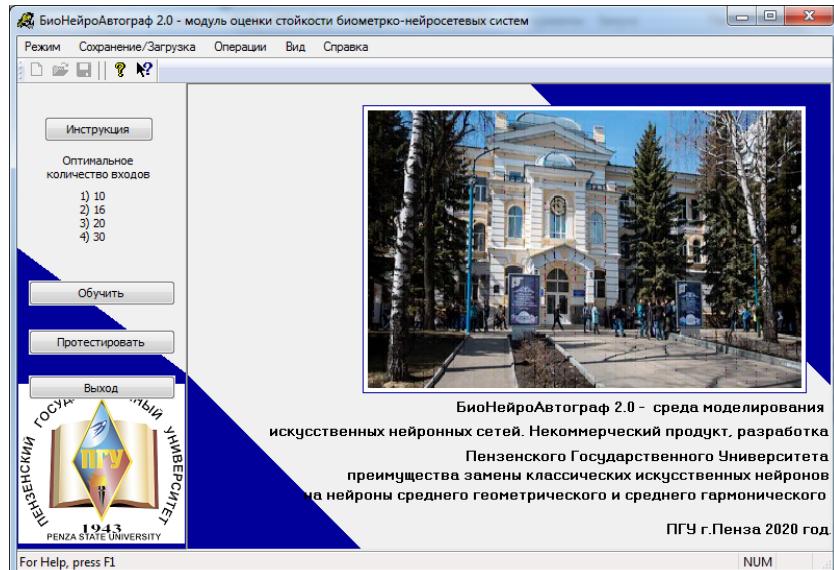


Рисунок 1. Первая экранная форма среды моделирования сетей нейронов среднего гармонического

Программный продукт [12] написан на языке промышленного программирования и позволил провести испытания сетей нейронов среднего гармонического на больших тестовых базах биометрических образов.

Заключение. Создана среда моделирования сетей нейронов среднего гармонического. Проведенные испытания показали, что по своим качественным биометрическим характеристикам (вероятностям ошибок первого и второго рода) сети линейных нейронов и сети нейронов среднего

гармонического сопоставимы. При этом длина выходного ключа у них так же сопоставима, а разряды выходных кодов слабо коррелированы. Это фактически позволяет удвоить длину выходного криптографического ключа при совместном использовании двух типов нейросетей и сокрытии их параметров в соответствии с технической спецификацией [3].

Библиографический список

1. ГОСТ Р 52633.5-2011 «Защита информации. Техника защиты информации. Автоматическое обучение нейросетевых преобразователей биометрия-код доступа».
2. ГОСТ Р 52633.2-2010 «Защита информации. Техника защиты информации. Требования к формированию синтетических биометрических образов, предназначенных для тестирования средств высоконадежной биометрической аутентификации»
3. Техническая спецификация «Системы обработки информации. Криптографическая защита информации. Защита нейросетевых биометрических контейнеров с использованием криптографических алгоритмов» принята 19.11.2020 на XXV заседании технического комитета № 26.
4. ГОСТ Р ИСО/МЭК 24708-2013 Информационные технологии. Биометрия. Протокол межсетевого обмена БиоАПИ.
5. ISO/IES 18033-6: 2019 IT Security techniques-Encryption algorithms – Part 6: Homomorphic incryption
6. Князьков В.С. Необходимость расширения функциональных возможностей гомоморфного шифрования для защиты нейросетевых решающих правил биометрических приложений искусственного интеллекта /В.С. Князьков, А.И. Иванов, А.В. Безяев // Безопасность информационных технологий: тр. II Всерос. науч.-техн. конф. – Пенза: Изд-во ПГУ, 2020. – С. 5–10.
7. Иванов А. И., Безяев А. В., Малыгина Е. А., Серикова Ю. И. Второй национальный стандарт России по быстрому автоматическому обучению больших искусственных нейронных сетей на малых выборках биометрических данных /Сборник научных статей по материалам I Всероссийской научно-технической конференции «Безопасность информационных технологий», 24 апреля, Пенза 2019, с. 174-177.
8. Иванов А.И., Сулавко А.Е. Проект третьего национального стандарта России по быстрому автоматическому обучению больших сетей корреляционных нейронов на малых обучающих выборках биометрических данных // Вопросы кибербезопасности. 2021. № 3 (43). С. 84-93.
9. Лукин В.С. Сравнение мощности обычной и логарифмической форм статистических критериев среднего гармонического при использовании для проверки гипотезы нормального распределения данных малой выборки // "Известия высших учебных заведений. Поволжский регион. Технические науки" №4, 2020 с. 19-26.

- 10.Иванов А.И., Банных А.Г., Куприянов Е.Н., Лукин В.С., Перфилов К.А., Савинов К.Н. Коллекция искусственных нейронов эквивалентных статистическим критериям для их совместного применения при проверке гипотезы нормальности малых выборок биометрических данных. /Сборник научных статей по материалам I Всероссийской научно-технической конференции «Безопасность информационных технологий», 24 апреля, Пенза 2019, с. 156-164.
- 11.Иванов А.И., Перфилов К.А, Лукин В.С. Нейросетевое обобщение семейства статистических критериев среднего геометрического и среднего гармонического для прецизионного анализа малых выборок биометрических данных. // Сборник научных ст. Всероссийской научно-технической конференции «Информационно-управляющие телекоммуникационные системы, средства поражения и их техническое обеспечение» / под общ. ред. В. С. Безяева. – Пенза: АО «НПП "Рубин"», 2019 с.50-63.
- 12.Свидетельство о госрегистрации программы для ЭВМ RU 2021661505 от 12 июля 2021 г. «Среда моделирования «БиоНейроАвтограф» с нейронами среднего гармонического». Авторы: Лукин Виталий Сергеевич (RU), Иванов Александр Иванович (RU) и др. //ФБГОУ ВО «Пензенский государственный университет».

A TRUSTED ARTIFICIAL INTELLIGENCE BUILT USING MEDIUM HARMONIC NEURONS

Lukin Vitaly S.

Penza State University

Str. Krasnaya, 40, Penza, Pussia, 440000, vitaly-lukin@mail.ru

Ivanov Alexander I.

Penza Scientific Research Electrotechnical Institute

Str. Sovetskaya, 9, Penza, Pussia, 440000, ivan@pniei.penza.ru

The article states that for the implementation of artificial intelligence in a protected version, only networks of artificial neurons automatically trained according to GOST R 52633.5, enriching the input "raw" data in linear space, are not enough. It is stated that it is additionally desirable to use networks of artificial neurons that enrich the input " raw " data in the space of the harmonic mean.

Keywords: trusted artificial intelligence, medium harmonic neurons, automatic learning, conversion of biometrics into authentication code.

РАЗРАБОТКА СИСТЕМЫ КОММУНИКАЦИИ ИНТЕЛЛЕКТУАЛЬНЫХ АГЕНТОВ НА ОСНОВЕ ОНТОЛОГИЧЕСКОГО ПОДХОДА

Третьяков Вячеслав Николаевич, Ланин Вячеслав Владимирович

Пермский государственный национальный исследовательский университет,
МОВС, 614990, Россия, г. Пермь, ул. Букирева, 15,
tretiakovslava@gmail.com

Рассматривается разработка метода коммуникации интеллектуальных агентов на основе онтологий при реализации процессов управления производством. Рассмотрены и проанализированы язык коммуникации FIPA ACL, среда разработки многоагентных систем JADE, применение онтологического инжиниринга при реализации многоакцентных систем. На основе анализа предметной области разработана онтология, в дальнейшем интегрированная в систему в качестве источника представления знаний. В статье описаны основной алгоритм работы системы, типы агентов, а также способ применения онтологий.

Ключевые слова: интеллектуальный агент, многоагентная система, язык коммуникации, механизмы коммуникации, онтология, умное производство, интернет вещей.

Введение. Сегодня количество оборудования, подключенного к интернету, продолжает расти, а вместе с этим активно развивается концепция «Интернет вещей» (IOT) [3]. Производители оценивают важность внедрении технологий, приводящих к автоматизации, повышению качества и ускорения производства. Вместе с этим термин «Умное производство» становится многообещающей тенденцией в развитии новых информационных и коммуникационных технологий в области разработки интеллектуальных агентов, многоагентных систем (МАС) [4] и реализации бизнес-сред на их основе. Тем не менее, остаются вопросы связанные с процессами взаимодействия агентов [1]. Необходимы методы и механизмы, которые бы позволяли решать задачи реальной практической сложности.

Типы агентов и алгоритм работы системы. Функционально можно выделить следующих агентов:

- агент внешнего взаимодействия – (External Management Agent – EMA). Основная задача заключается в принятии и получении запросов из внешней среды;

- внутренний агент-менеджер или управлеңец (Internal Management Agent – IMA). Выполняет такие задачи управления как планирование, распределение задач;
- агент-работник (Worker Agent – WA). Основной агент, выполняющий порученные менеджером задач.
- агент управления знаниями (Knowledge Management Agent – KMA). Имеет доступ к онтологиям и предоставляет другим агентам знания по запросам.

В системе есть несколько этапов: получение и обработка заказа, планирование и распределение задач, основная и завершающая часть работы. На первом этапе внешний агент обрабатывает и отправляет информацию о заказе менеджерам, далее на этапе планирования агент-менеджер подбирает походящих исполнителей, ориентируясь на их возможностях. Как уже говорилось ранее, задача агента-работника проста – выполнить поставленную задачу. При этом и менеджер и работник могут обращаться к агенту, работающему непосредственно с онтологией и знаниями. Его основная задача – поставлять знания по запросу. Онтологий может быть несколько: разделенные по уровням, по предметным областям. Тогда агентов можно сделать разноплановыми. То есть заставить работать с разными онтологиями. При таком раскладе знания будут разделены по областям, а с ними и агенты. Таким образом, когда условному агенту-работнику понадобиться информация о сборке *продукта N*, то он обратиться к КМА, работающего с знаниями о *продукте N*. Схематично алгоритм работы представлен на рисунке 1.

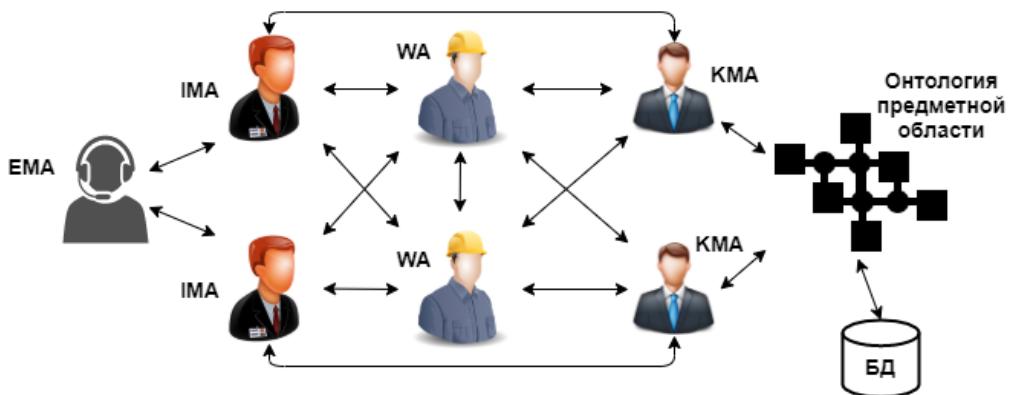


Рис. 1 Схема взаимодействия агентов в системе

Коммуникация агентов. Коммуникации между агентами основаны на теории переговоров [2]. Агенты общаются на языке FIPA ACL (FIPA Agent Communication Language), разработанного организацией FIPA [5] с использованием протоколов, определяющих множество правил для порождения сообщений и взаимодействует с целью кооперативного решения некоторой общей крупной задачи. Обмен сообщений в данном случае асинхронный. Возможно использовать как децентрализованную систему с локальным управлением, так и с помощью архитектура «доски объявлений» – посредника для осуществления различных взаимодействий между агентами. Например, в разработанной системе агенты-работники (WA) размещают

информацию о себе и о своих свойствах, а агенты-менеджеры могут выбрать подходящего для конкретной задачи агента, основываясь на его возможностях.

Онтологии в МАС. Для высокоэффективного производства требуется большая автоматизация и универсальность. Онтологии призваны автоматизировать инженерные задачи, которые в большинстве случаев выполняются вручную. Они становятся

В распределённых и разнородных многоагентных системах агенты должны организованно взаимодействовать для достижения своих целей. Для этого им необходимо говорить на одном языке или, говоря другими словами, должна быть определена некая терминология, определяющая общие знания. Схематично такое взаимодействие можно представлено на рисунке 2.

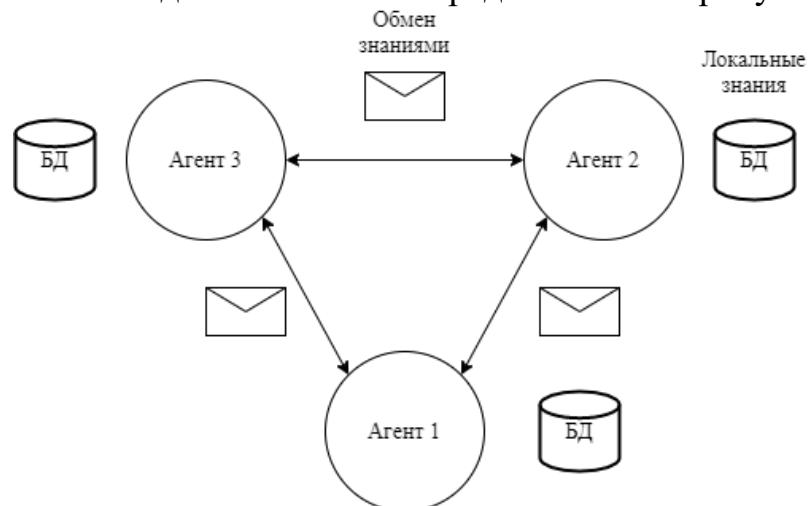


Рис. 2 Обмен знаниями в многоагентной среде

В системе выделяются онтологии внешнего и внутреннего уровня. Соответственно на внешнем уровне могут рассматриваться такие понятия как заказ, журналы, продукты, этапы необходимые, информация о агентах необходимые менеджеру для планирования и распределения (см. рис. 3). На нижнем уровне онтология углубляется и конкретизируется относительно производимого продукта, материалов, его составных частей, связей между ними. Например, агенту можно передать знания о том, что «Люк продукта стиральная машина крепится на переднюю панель, используется винт типа А». Кроме этого, планируется, что онтология должна быть расширяема, как на уровне объектов языка, на котором написана система, так и на уровне самой онтологии: концепций и связей.



Рис. 3 Концептуальная онтология предметной области с интеграцией JADE

Заключение. В статье предложен метод использования онтологий в реализации процессов управления производством. Онтология, являясь основным источником знаний, позволяет агентам общаться в рамках одной терминологии.

Проведенный анализ позволил разработать прототип многоагентной системы в предметной области производственного конвейера. Разработанная онтология была интегрирована и использована в системе как источник знаний при передаче сообщений на языке FIPA ACL.

Библиографический список

1. Скobelев П.О., Городецкий В.И., Бухвалов О.Л., Майоров И.В. Современное Состояние И Перспективы Индустриальных Применений Многоагентных Систем // Управление техническими системами и технологическими процессами. 2017. № 66. С. 94–157.
2. Gmytrasiewicz P. J., Durfee E. H. Rational Communication in Multi-Agent Environments // Autonomous Agents and Multi-Agent Systems. 2001.
3. Gubbi J., Buyya R., Marusic S., Palaniswami M. Internet of Things (IoT): A vision, architectural elements, and future directions // Future Generation Computer Systems. 2013. № 7 (29).
4. Wooldridge M. An Introduction to MultiAgent Systems – 2nd Edition / M. Wooldridge, 2009.
5. The Foundation for Intelligent Physical Agents (FIPA) [Электронный ресурс]. URL: <http://www.fipa.org/about/index.html> (дата обращения: 20.09.2021).

DEVELOPMENT OF AN INTELLIGENT AGENT COMMUNICATION SYSTEM BASED ON AN ONTOLOGICAL APPROACH

Tretyakov Vyacheslav, Lanin Viacheslav

Perm State University, 15, Bukireva st., Perm, 614990, Russia,

tretiakovslava@gmail.com

Abstract. The development of a communication method for intelligent agents based on ontologies in the implementation of production management processes is considered. For the development, the FIPA ACL communication language, the JADE multi-agent system development environment, and ontological engineering are considered and analyzed. On the basis of the analysis of the subject area of production, an ontology was developed, which was later integrated into the system as a source of knowledge representation. The article describes the main algorithm of the system, its types of agents, as well as the method of using ontologies.

Keywords: intelligent agent, multi-agent system, communication language, communication mechanisms, ontology, smart manufacturing, internet of things.

УДК 517.983.22: 330.4

АЛГОРИТМЫ АНАЛИЗА ЗНАЧЕНИЙ ЦЕЛЕВЫХ ПОКАЗАТЕЛЕЙ НА ДОСТИЖИМОСТЬ ПРИ ПОЛИЭДРАЛЬНЫХ ОГРАНИЧЕНИЯХ

Максимов Владимир Петрович

Пермский государственный национальный исследовательский университет,
614990, Россия, г. Пермь, ул. Букирева, 15, maksimov@econ.psu.ru

Дается описание основных конструкций и алгоритмов построения оценок множества достижимых значений целевых показателей в задаче управления для линейных систем с последействием при наличии полиэдральных ограничений на управляющие воздействия. Предлагаемый подход может служить теоретической основой при разработке систем поддержки принятия решений, ориентированных на исследование и решение задач управления для широкого класса динамических моделей.

Ключевые слова: системы поддержки принятия решений, динамические модели, задачи управления, множества достижимости.

Введение. При решении задач управления динамическими моделями реальных процессов с широкой сферой применения ключевую роль играют ограничения на управляющие воздействия. От согласования таких ограничений с целями управления зависит разрешимость задачи управления,

– существование допустимого программного управления, решающего задачу достижения поставленных целей. При заданных ограничениях возникает естественная задача описания множества достижимых значений целевых показателей, называемого множеством достижимости (attainability set или reachability set). В ситуации, когда заданные значения не принадлежат множеству достижимости, задача управления оказывается неразрешимой. В любом случае лицу, принимающему решение, полезно знать об этом до попыток найти решение практической задачи. Различным аспектам исследования и описания множеств достижимости для различных классов динамических моделей посвящено большое число работ отечественных и зарубежных авторов, см., например, работы [1,3,9-14]. и библиографию к ним. Ниже мы предлагаем оценки множеств достижимости для широкого класса линейных систем управления.

Следует отметить, что в части прикладных задач допускается возможность ослабления (релаксации) заданных ограничений, причем с минимальной (в определенном смысле) деформацией исходных ограничений. Для статических моделей методы коррекции противоречивых задач оптимального планирования детально разработаны в [2].

Множество достижимости. Рассмотрим систему управления

$$(Lx)(t) = (Gu)(t), \quad t \in [0, T] \quad (1)$$

с линейными вольтерровыми операторами L и G , предполагая, что все ее абсолютно непрерывные траектории $x : [0, T] \rightarrow R^n$, определяемые нулевым начальным состоянием и управлением $u : [0, T] \rightarrow R^r$, имеют интегральное представление

$$x(t) = \int_0^t C(t, s)(Gu)(s)ds, \quad (2)$$

где $C(t, s)$ – матрица Коши. Точное описание такого класса систем и свойств матрицы Коши дается в [5, 6].

Векторная цель управления задается равенством

$$\ell x \equiv \int_0^T \Phi(s) \frac{d}{ds} x(s) ds = \beta \in R^N, \quad (3)$$

где $\Phi(\cdot)$ – заданная $(N \times n)$ -матрица с кусочно-непрерывными на $[0, T]$ элементами. Условия (3) охватывают многочисленные формы задания целевых условий, включая многоточечные, интегральные условия и их линейные комбинации.

Задача управления решается в классе управлений, удовлетворяющих линейной системе ограничений

$$\Lambda \cdot u(t) \leq \gamma, \quad t \in [0, T] \quad (4)$$

с заданной $(N_1 \times r)$ -матрицей и заданным $\gamma \in R^{N_1}$. Ниже всюду предполагается, что множество V всех решений линейной системы неравенств $\Lambda \cdot v \leq \gamma$ непусто и ограничено.

Множество всех таких $\beta \in R^N$, что задача управления

$$(Lx)(t) = (Gu)(t), \quad t \in [0, T], \quad x(0) = 0, \quad \ell x = \beta \in R^N \quad (5)$$

с ограничениями (4) разрешима, называется множеством достижимости в задаче (5).

Как показано в [7, 8], задача (5) сводится к обобщенной проблеме моментов [4]

$$\int_0^T M(s)u(s)ds = \beta, \quad \Lambda \cdot u(t) \leq \gamma, \quad t \in [0, T]. \quad (6)$$

Теперь задача состоит в описании всех значений вектора β , для которых задача (6) имеет решение, т.е. найдется допустимое управление $u(t)$,

доставляющее интегралу $\int_0^T M(s)u(s)ds$ значение β .

Для описания множества достижимости введем в рассмотрение семейство задач линейного программирования. Зафиксируем $s \in [0, T]$, $\mu \in R^{N_1}$ и поставим задачу

$$y(s, \mu) = \mu' \cdot M(s) \cdot v \rightarrow \max, \quad v \in V. \quad (7)$$

Будем предполагать, что каждая такая задача имеет единственное решение

$$w(s, \mu) = \arg \max_{v \in V} \mu' \cdot M(s) \cdot v.$$

Определим множество S равенством

$$S = \{\rho \in R^N : \mu' \rho \leq \int_0^T \mu' \cdot M(t) \cdot w(t, \mu) dt \quad \forall \mu \in R^{N_1}\}.$$

В предположении кусочной непрерывности матрицы $M(\cdot)$ на $[0, T]$ необходимым и достаточным условием разрешимости задачи (6) является принадлежность β множеству S (Теорема 7.1 [4]), таким образом, S – множество достижимости в задаче (5).

Точное описание множества достижимости носит теоретический характер и требует решения всего бесконечного семейства задач линейного программирования (7). Представляющие практический интерес верхние и нижние оценки множества достижимости предлагаются в следующих разделах.

Верхние оценки множества достижимости. Для получения верхних оценок множества достижимости воспользуемся конечной совокупностью задач линейного программирования. Фиксируем целое положительное число K , набор векторов $\{\mu_1, \dots, \mu_K\}, \mu_k \in R^{N_1}$, и разбиение

$\{0 = \tau_0 < \tau_1 < \dots < \tau_{\sigma-1} < \tau_\sigma = T\}$ основного промежутка $[0, T]$ точками τ_j . Каждой паре (k, j) , $k = 1, \dots, K$, $j = 1, \dots, \sigma - 1$, ставим в соответствие решение соответствующей задачи линейного программирования:

$$w_{kj} = \arg \max(\mu'_k \cdot M(\tau_j) \cdot v : v \in \mathcal{V}), k = 1, \dots, K, j = 1, \dots, \sigma - 1. \quad (8)$$

Этот набор экстремальных угловых точек используется для мажорирования интегралов

$\int_0^T \mu'_k \cdot M(t) \cdot w(t, \mu_k) dt$: находятся такие неотрицательные δ_k , что для каждого

k выполняется неравенство

$$\int_0^T \mu'_k \cdot M(t) \cdot w(t, \mu_k) dt \leq q_k = \int_0^T \mu'_k \cdot M(t) \cdot \sum_{j=1}^{\sigma} w_{kj} \chi_{[\tau_{j-1}, \tau_j)}(t) dt + \delta_k,$$

где $\chi_{[\tau_{j-1}, \tau_j)}(t)$ – характеристическая функция промежутка $[\tau_{j-1}, \tau_j)$. По числам q_k определяется многогранник

$$\bar{S} = \{\rho \in R^N : \mu'_k \cdot \rho \leq q_k, k = 1, \dots, K\},$$

дающий оценку сверху по включению для множества S : $\bar{S} \supset S$.

Точность получаемой оценки множества S зависит от разбиения основного промежутка $[0, T]$ и «разнообразия» используемых направлений μ_k , которые вместе с матрицей $M(t)$ определяют градиент целевой функции в соответствующей задаче линейного программирования. Представляется целесообразным начинать с набора всевозможных векторов μ_k , каждая координата которых принимает одно из трех значений 0, 1, -1, при этом из набора исключается вектор с нулевыми координатами. При необходимости уточнения оценки в исходный набор добавляются полусуммы каждого двух различных векторов исходного набора, затем так же можно поступить с новым набором и т.д.

Нижние оценки множества достижимости. Нижние по включению оценки множеств достижимости могут быть получены с использованием кусочно-постоянных допустимых управлений. Дадим описание соответствующих конструкций.

Используя значения w_{kj} , определенные равенством (8), построим программные управления $u(t, \mu_k)$ по правилу:

$$u(t, \mu_k) = \sum_{j=1}^{\sigma} w_{kj} \chi_{[\tau_{j-1}, \tau_j)}(t).$$

По построению такие управлении являются допустимыми, им соответствуют значения

$$\rho_k = \int_0^T M(t) \cdot u(t, \mu_k) dt, \quad k = 1, \dots, K,$$

в пространстве целевых значений. Выпуклая оболочка таких точек дает внутреннюю оценку \underline{S} для множества S :

$$\underline{S} = \text{Conv}(\{\rho_1, \dots, \rho_K\}) \subset S.$$

Действительно, пусть

$$\rho = \sum_{k=1}^K \omega_k \rho_k, \text{ где } \omega_k \geq 0, \sum_{k=1}^K \omega_k = 1.$$

Покажем, что управление

$$u_\rho(t) = \sum_{k=1}^K \omega_k \sum_{j=1}^\sigma w_{jk} \chi_{[\tau_{j-1}, \tau_j)}(t) dt$$

является допустимым. Для любого $j \in \{1, 2, \dots, \sigma\}$ имеем

$$\Lambda \cdot w_{jk} \chi_{[\tau_{j-1}, \tau_j)}(t) \leq \gamma \quad \text{и} \quad \omega_k \cdot \Lambda \cdot w_{jk} \chi_{[\tau_{j-1}, \tau_j)}(t) \leq \omega_k \cdot \gamma.$$

Суммируя почленно эти неравенства, получаем

$$\sum_{k=1}^\sigma \omega_k \cdot \Lambda \cdot w_{jk} \chi_{[\tau_{j-1}, \tau_j)}(t) \leq \sum_{k=1}^\sigma \omega_k \cdot \gamma,$$

$$\text{или,} \quad \Lambda \cdot \sum_{k=1}^\sigma \omega_k w_{jk} \chi_{[\tau_{j-1}, \tau_j)}(t) \leq \gamma \sum_{k=1}^\sigma \omega_k = \gamma.$$

Заключение. Дано описание основных конструкций и алгоритмов построения верхних и нижних по включению оценок множества достижимости для задачи управления линейной системой с векторным заданием целей управления и полиэдральными ограничениями на управляющие воздействия. Описанный подход может служить теоретической основой при разработке систем поддержки принятия решений, ориентированных на исследование и решение задач управления для широкого класса динамических моделей.

Библиографический список

1. Гусев М.С., Осипов И.О. Асимптотическое поведение множеств достижимости на малых временных промежутках // Труды института математики и механики УрО РАН. 2019. Т. 25. №3. С. 86.
2. Еремин И.И. Противоречивые модели оптимального планирования. М.: Наука, 1988. – 160 с.
3. Костоусова Е.К. О полиэдральных оценках множеств достижимости дифференциальных систем с билинейной неопределенностью // Труды института математики и механики УрО РАН. 2012. Т. 18. №4. С. 195.
4. Крейн М.Г., Нудельман А.А. Проблема моментов Маркова и экстремальные задачи. М.: Наука, 1973. – 552 с.
5. Максимов В.П. О формуле Коши для функционально-дифференциального уравнения // Дифференциальные уравнения. 1977. Т.13. № 4. С. 601.

6. Максимов В.П. Вопросы общей теории функционально-дифференциальных уравнений. Избранные труды. Пермь : ПГУ, ПСИ, ПССГК, 2003. – 306 с.
7. Максимов В.П. Достижимые значения целевых функционалов в задачах экономической динамики // Прикладная математика и вопросы управления. 2019. № 4. С. 124.
8. Максимов В.П. О построении программных управлений в задаче о достижимых значениях целевых функционалов для динамических моделей экономики с дискретной памятью// Прикладная математика и вопросы управления. 2020. № 3. С. 89.
9. Никольский М.С. Оценивание множества достижимости сверху по включению для некоторых нелинейных систем управления // Труды института математики и механики УрО РАН. 2019. Т. 25. №3. С. 163.
10. Digo G.B., Digo N.B. Approximation of domains of serviceability and attainability of control system on the basic of the inductive approach // Reliability: Theory & Applications. 2011. V. 6. No. 21. P. 41.
11. Gurman V.I., Trushkova E.A. Estimates for attainability sets of control systems // Differential Equations. 2009. V. 45. No. 11. P. 1636.
12. Kurzhanski A.B., Varaiya P. On ellipsoidal techniques for reachability analysis // Optimization methods and software. 2002. V. 17. P. 177.
13. Polyak B.T. Convexity of the reachable set of nonlinear systems under L_2 bounded controls // Dynamics of continuous, discrete and impulsive systems. Series A. Mathematical Analysis. Watam Press. 2004. V. 11. No. 2-3. P. 255.
14. Rodina L. I. Estimation of statistical characteristics of attainability sets of controllable systems // Russian Math. (Iz. VUZ). 2013. V. 57. No. 11. P. 17.

ALGORITHMS FOR ANALYSIS OF THE ATTAINABILITY OF ON-TARGET INDEXES VALUES

Maksimov Vladimir P.

Perm State University

Str. Bukireva, 15, Perm, Russia, 614990,

maksimov@econ.psu.ru

The article describes basic relationships and algorithms aimed at constructing estimates of the attainability sets for on-target indexes as applied to control problems for linear systems with aftereffect under polyhedral constraints with respect to control. The proposed approach can be considered as a theoretical base while constructing decision support systems that are aimed at studying and solving control problems for a wide class of dynamic models.

Keywords: decision making systems, dynamic models, control problems, attainability sets.

Научное издание

**Искусственный интеллект в решении актуальных
социальных и экономических проблем XXI века**

Сборник статей по материалам
Седьмой всероссийская научно-практической конференции
с международным участием

(г. Пермь, 21–22 октября 2021 г.)

Ответственный редактор
Леонид Нахимович Ясницкий

Издается в авторской редакции
Компьютерная верстка: *И. А. Ясницкая*

Подписано в печать 05.10.2021. Тираж 30 экз.
Усл. печ. л. 14,88. Формат 60×84/16. Заказ № 1320/2021.

Отпечатано с готового оригинал-макета
в типографии издательства Пермского национального
исследовательского политехнического университета
614990, г. Пермь, Комсомольский пр., 29, к. 113.
Тел.: (342) 219-80-33

ОРГАНИЗАТОРЫ:



Министерство
образования
и науки
Пермского края

**СПОНСОРЫ
И ПАРТНЕРЫ
МЕХАНИКО-
МАТЕМАТИЧЕСКОГО
ФАКУЛЬТЕТА:**



Ростелеком
Информационные Технологии

BioNT
ВАША ИНФОРМАЦИЯ
ПОД НАДЕЖНОЙ ЗАЩИТОЙ

BOTAN
INVESTMENTS

PARMA
Technologies Group